

MAE 5834 - ESTATÍSTICA AVANÇADA I

PROF. SILVIA FERRARI

INTRODUÇÃO (CAP1, TPE)

O PROBLEMA

Dados (observações): assume-se que são valores observados de variáveis aleatórias (r.a.'s) que seguem uma distribuição de probabilidades conjunta P pertencente a uma classe \mathcal{P} .

Frequentemente, P é indexada por um parâmetro $\theta \in \Omega$.

$$\mathcal{P} = \{P_\theta, \theta \in \Omega\}$$

Exemplos.

1. Tempos de vida de lâmpadas

Admite-se que $T \sim \text{Exp}(\theta)$ (exponencial de média θ).

Observam-se T_1, \dots, T_n (réplicas de T)

T_1, \dots, T_n : r.a.'s i.i.d.; $T_i \sim \text{Exp}(\theta), \theta > 0$.

$$2. X \sim N(\theta, 1), \theta \in \mathbb{R}$$

Observam-se x_1, \dots, x_n (réplicas de X)
 x_1, \dots, x_n : r.a.'s i.i.d., $x_i \sim N(\theta, 1)$.

3. Proporção de óleo bruto que se transforma em gasolina após processamento (X)

$$X \sim \text{Beta}(p, q), \quad \Omega \subseteq \{(p, q) \in \mathbb{R}^2 : p > 0, q > 0\} = \mathcal{L}$$

Observam-se x_1, \dots, x_n : réplicas de X .
 x_1, \dots, x_n : r.a.'s i.i.d., $x_i \sim \text{Beta}(p, q)$

4. $\underline{Y} = \underline{X}\underline{\beta} + \underline{\varepsilon}$ (modelo de regressão normal linear)

$$\underline{Y} = (y_1, \dots, y_n)'$$

\underline{X} : matriz $n \times p$ (de posto p) fixa

$$\underline{\beta} = (\beta_1, \dots, \beta_p)' \in \mathbb{R}^p$$

$\underline{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)':$ vetor de r.a.'s i.i.d.,
 $\varepsilon_i \sim N(0, \sigma^2), \sigma^2 > 0$

$$\Omega = (\beta_1, \dots, \beta_p, \sigma^2) \in \mathbb{R}^p \times \mathbb{R}^+$$

5. Regressão Logística

$\underline{y} = (y_1, \dots, y_n)'$ tq $y_i \sim \text{Bernoulli}(\mu_i)$, ind.

$$\log \frac{\mu_i}{1-\mu_i} = \underline{x}_i' \underline{\beta}, \quad i=1, \dots, n.$$

$\underline{x}_i = (x_{i1}, \dots, x_{ip})'$ fixados

$$\underline{\beta} = (\beta_1, \dots, \beta_p)' \in \mathbb{R}^p = \Omega.$$

OBJETIVO: fazer inferências sobre θ ou $g(\theta)$ com base nos dados observados.

- Estimacão pontual e intervalar
- Testes de hipóteses - problema de decisão
- Previsão de novas observações.

ANALISE BAYESIANA: assume-se que θ é uma v.a. (não observável) com uma distribuição conhecida (distribuição a priori). Esta é modificada após a observação dos dados e é determinada então a distribuição a posteriori (distribuição condicional de θ dadas as observações).

2

Estimacão Pontual

Ingredientes:

1. Uma função g definida sobre Ω (espaço paramétrico), a valores reais, cujo valor em θ , $g(\theta)$, será estimado.

$g(\theta)$: estimando

2. Uma r.a. (ou vetor aleatório) X , tomando valores em um espaço amostral \mathcal{X} de acordo com a distribuição $P_\theta \in \mathcal{P}$.

O valor observado, x , de X constitui o conjunto de dados.

Objetivo: obter um bom estimador para $g(\theta)$

Um estimador é uma função δ , a valores reais, definida sobre \mathcal{X} . É usado para estimar um estimando $g(\theta)$.

$\delta(X)$: estimador de $g(\theta)$

$\delta(x)$: estimativa de $g(\theta)$

Obs: pode-se definir estimador como acima mas impondo que δ tome valores apenas no conjunto dos possíveis valores de $g(\theta)$.

3.

E' desejável que δ "esteja perto" de $g(\theta)$.

Medidas de proximidade ou distância entre δ e $g(\theta)$:

- $P(|\delta(x) - g(\theta)| < c)$, para algum $c > 0$;
- $E\{|\delta(x) - g(\theta)|^p\}$, para algum $p > 0$;
- $E\left\{\left|\frac{\delta(x)}{g(\theta)} - 1\right|^p\right\}$ (se δ e g só tomam valores positivos), para algum $p > 0$;
- $\lambda(\theta) E\{|\delta(x) - g(\theta)|^p\}$.

Suponha que as consequências (perda) de se estimar $g(\theta)$ por um valor δ de δ são medidas por $L(\theta, \delta)$ (função de perda).

Assumimos que

$$L(\theta, \delta) \geq 0, \text{ para todo } \theta, \delta$$

$$L(\theta, g(\theta)) = 0, \text{ para todo } \theta.$$

Funções de risco (perda média)

$$R(\theta, \delta) = E_{\theta} \{ L(\theta, \delta(x)) \}$$

Um critério para escolha do estimador: tomar δ que minimize o risco para todo $\theta \in \Omega$.

Problema: não existe tal estimador.

Seja $\delta(x) = g(\theta_0)$, $\forall x \in \mathcal{X}$. Este tem risco nulo para $\theta = \theta_0$. Não existe um estimador com risco uniformemente menor ou igual aos demais.

Solução: restringir a classe dos estimadores.

Classe dos estimadores não viésados: requer que

$$\underbrace{E_{\theta} [\delta(x)] - g(\theta)}_{\text{vício (viés) do estimador}} = 0, \text{ para todo } \theta \in \Omega.$$

Classe dos estimadores não viésados com respeito à mediana: requer que

$$\text{Mediana}_{\theta} [\delta(x)] - g(\theta) = 0, \text{ para todo } \theta \in \Omega.$$

Outros critérios para escolha de estimadores

1. Escolher δ que minimiza

$$\int_{\Omega} R(\theta, \delta) w(\theta) d\theta$$

para alguma função de peso w . Se w é a fdp de θ , este é o estimador de Bayes.

2. Escolher δ que minimiza

$$\sup_{\Omega} R(\theta, \delta)$$

(estimador minimax).

MODELO ESTATÍSTICO

Para a descrição de um modelo estatístico seria natural tomar como ponto de partida um espaço mensurável $(\mathcal{E}, \mathcal{B})$ e uma família de distribuições de probabilidade definida sobre ele. Aqui \mathcal{E} é o conjunto dos possíveis resultados de um experimento e \mathcal{B} é uma σ -álgebra de sub-conjuntos de \mathcal{E} .

$(\mathcal{E}, \mathcal{B})$, sendo \mathcal{B} uma σ -álgebra de sub-conjuntos de \mathcal{E} , é chamado de "espaço mensurável" e os conjuntos $B \in \mathcal{B}$ são "mensuráveis".

No entanto, toma-se como ponto de partida uma r.a. X (ou vetor, $X = (X_1, \dots, X_n)$) e todos os outros aspectos do experimento são ignoradas.

A especificação do modelo começa com X (dados), um espaço mensurável $(\mathcal{X}, \mathcal{Q})$, sendo \mathcal{X} o conjunto dos possíveis valores de X e \mathcal{Q} uma σ -álgebra de sub-conjuntos de \mathcal{X} , e uma família \mathcal{P} de distribuições de probabilidades à qual a distribuição de X (desconhecida) pertence.

6

MODELO ESTATÍSTICO

$(\mathcal{X}, \mathcal{Q}, \mathcal{P})$

onde

\mathcal{X} : conjunto

\mathcal{Q} : σ -álgebra de sub-conjuntos de \mathcal{X}

\mathcal{P} : família de medidas (distribuições) de probabilidade.

$$\mathcal{P} = \{P_\theta, \theta \in \Omega\}$$

Ω : espaço paramétrico

Suposição usual (identificabilidade): para qualquer $\theta_1 \in \Omega$ e $\theta_2 \in \Omega$,

$$\theta_1 \neq \theta_2 \Rightarrow P_{\theta_1} \neq P_{\theta_2}.$$

Dizemos que $(\mathcal{X}, \mathcal{Q})$ é o espaço amostral. Muitas vezes, \mathcal{Q} é omitido (sub-entendido) e dizemos que \mathcal{X} é o espaço amostral.

Alunos: ler Seções 3 e 4, Cap¹ (TPE) sobre Teoria da Medida e Integração e Teoria da Probabilidade.

Vamos trabalhar no contexto em que Ω é dominado por uma medida μ , σ -finita; em geral, a medida de contagem ou a medida de Lebesgue

Nota: μ é σ -finita se $\exists A_1, A_2, \dots \in \mathcal{C}$, tais que

$$\bigcup A_i = \mathbb{X} \text{ e } \mu(A_i) < \infty.$$

Ω é dominado por μ se todos os elementos de Ω são absolutamente contínuos com respeito a μ , i.e., para cada $A \in \mathcal{Q}$,

$$\mu(A) = 0 \Rightarrow P_\theta(A) = 0, \forall \theta \in \Omega.$$

Também,

$$P_\theta(A) = \int_A p_\theta d\mu, \text{ para todo } \theta \in \Omega$$

(integral de Lebesgue),

sendo p_θ a derivada de Radon-Nikodym de P_θ com respeito a μ .

p_θ é chamada de densidade de probabilidade de P_θ com respeito a μ .

Escrevemos

$$p_\theta = \frac{dp_\theta}{d\mu}.$$

Abordaremos os seguintes casos:

i) μ é a medida de contagem

\mathbb{X} é contável; \mathcal{C} é a classe de todos os subconjuntos de \mathbb{X} e para cada $A \in \mathcal{C}$, $\mu(A)$ é o nº de pontos de A se A é finito e $\mu(A) = +\infty$, caso contrário.

Aqui,

$$P_\theta(A) = \int_A p_\theta d\mu = \sum p_\theta(x_i),$$

onde a soma varre todos os x_i 's pertencentes a A .

Caso discreto: \mathbb{X} é \mathbb{N} como acima e Ω dominada pela medida de contagem.

ii) μ é a medida de Lebesgue

\mathbb{X} é o espaço Euclidiano n -dimensional \mathbb{R}^n ; \mathcal{Q} é a menor σ -álgebra contendo todos os retângulos abertos

$$A = \{(x_1, \dots, x_n) : a_i < x_i < b_i\}, -\infty < a_i < b_i < \infty.$$

Os conjuntos de \mathcal{C} são chamados Boreelianos.

Nota: Dizemos que " \mathbb{X} (ou $(\mathbb{X}, \mathcal{C})$) é Euclidiano" para indicar que \mathbb{X} é um Boreiano e assumimos que \mathcal{C} é a classe dos subconjuntos Boreelianos de \mathbb{X} .

Nota: \mathcal{Q} como definido acima contém, entre outras, todos os subconjuntos abertos e fechados de \mathbb{X} .

E' a menor σ -álgebra com essa propriedade.

Aqui,

$$\mu(A) = (b_1 - a_1) \dots (b_n - a_n) \quad (\text{volume}) - \text{Medida de Lebesgue}$$

e

$\int_P d\mu$ existe sempre que a integral de

Riemann existe e as duas coincidem (mas pode existir sem que a de Riemann exista).

Caso absolutamente contínuo: $(\mathbb{X}, \mathcal{G})$ é Euclídeo
no e P é dominada pela medida de Lebesgue.

Nota: Em ambos os casos (discreto e contínuo) p_θ
é chamada de "densidade de probabilidade".

Notação para densidades:

$$p_\theta(x), p(x|\theta), f_\theta(x), f(x), f(x|\theta), p(x;\theta), f(x;\theta).$$

Nota: $(\mathbb{X}, \mathcal{G}, \mu)$ é um espaço de medida.

Para definir um modelo estatístico, substituímos
 μ por P , uma família de medidas de proba-
bilidade. Admitimos que P é dominada por
uma medida μ σ -finita.

Supor. O suporte de uma distribuição P sobre
 $(\mathbb{X}, \mathcal{G})$ é o conjunto de todos os pontos
 x para os quais $P(A) > 0$ para todo
retângulo aberto A que contém x .

Inferências sobre θ são feitas com base
em estatísticas, que são transformações dos
dados.

Nos exemplos 1 e 2, é razoável utilizar a
média amostral para fazer inferências sobre θ .

Mais especificamente, variáveis (ou vetores)
aleatórias, T digamos, que são transforma-
ções mensuráveis de $(\mathbb{X}, \mathcal{G})$ em algum
 $(\mathbb{Y}, \mathcal{G})$ são chamadas estatísticas.

\mathcal{B} é uma σ -álgebra de sub-conjuntos de \mathbb{Y}
tq a imagem inversa

$$T^{-1}(\mathcal{B}) = \{x \in \mathbb{X} : T(x) \in \mathcal{B}\}$$

esta em \mathcal{G} .

Em particular, estimadores são estatísticas.

Notas.

- O foco do curso está em questões estatísticas.
Alguns aspectos técnicos (ex.: verificação de mensurabilidade de transformações) não serão abordados.
- Sempre que for mencionada uma medida, μ digamos, estará sub-entendido que é σ -finita, mesmo se não mencionado.

FAMÍLIAS DE MODELOS

FAMÍLIAS DE GRUPO

Uma "família de grupo" de distribuições é uma família obtida submetendo uma v.a. com uma dada distribuição a um grupo de transformações.

Uma classe de transformações 1-a-1 (1) é um "grupo de transformações" se e' fechada sob composição e inversão.

Fechada sob composição

$$g_1 \in J, g_2 \in J \Rightarrow g_2 \cdot g_1 \in J$$

Fechada sob inversão

$$g \in J \Rightarrow g^{-1} \in J.$$

(ler Secção 1.4, TPE)

(a) Família de locação

Seja U uma v.a. com distribuição F . Sejam $a \in (-\infty, +\infty)$ e $X = U + a$.

$$P(X \leq x) = F(x-a).$$

O conjunto das distribuições $F(x-a)$, F fixo, com a variando de $-\infty$ a $+\infty$ constitui uma família de locacão. (Um caso de família de grupo)

(b) Família de escala (outro caso)

E' gerada pela transformação $X = bU$, $b > 0$.

$$P(X \leq x) = F\left(\frac{x}{b}\right).$$

Exemplo: $U \sim N(0,1)$

(a) $X = U + a$

$$P(X \leq x) = P(U \leq x-a) = \Phi(x-a) \quad \text{Locação}$$

: Normal com média a e VAR. 1.

(b) $X = bU$

$$P(X \leq x) = P(U \leq x/b) = \Phi\left(\frac{x}{b}\right) \quad \text{Escala}$$

: Normais com $\mu=0$ e $\sigma^2=b^2$.

c) Família de locação-escala: é gerada pela transformação

$$X = a + bU, \quad b > 0, \quad a \in (-\infty, +\infty)$$

$$P(X \leq x) = F\left(\frac{x-a}{b}\right) \cdot \text{Locação} \cdot \text{Escala}$$

Em geral, F tem densidade f com respeito à medida de Lebesgue. No caso de locação-escala, a densidade é

$$\frac{p(x|a,b)}{b} f\left(\frac{x-a}{b}\right).$$

Exemplos:

1. Normal: $N(a, b^2)$; $U \sim N(0,1)$, $X = bU + a$

$$p(x|a,b) = \frac{1}{\sqrt{2\pi}b} \exp\left\{-\frac{(x-a)^2}{2b^2}\right\}, \quad -\infty < x < \infty$$

Normalmente $\mu = a$ e $\sigma^2 = b^2$.

2. Exponencial Dupla: $DE(a,b)$; $U \sim DE(0,1)$

$$p(x|a,b) = \frac{1}{2b} \exp\left\{-\frac{|x-a|}{b}\right\}, \quad -\infty < x < \infty$$

3. Cauchy: $C(a,b)$; $U \sim C(0,1)$

$$p(x|a,b) = \frac{b}{\pi} \frac{1}{b^2 + (x-a)^2}, \quad -\infty < x < \infty$$

4. Logística: $L(a,b)$; $U \sim L(0,1)$

$$p(x|a,b) = \frac{1}{b} \frac{\exp\left\{-(x-a)/b\right\}}{\left[1 + \exp\left\{-(x-a)/b\right\}\right]^2}, \quad -\infty < x < \infty$$

Outros exemplos: uniforme, exponencial, etc (ver Tabela 4.1, TPE, p18).

Generalizações: $U = (U_1, \dots, U_n)$

$X = (U_1+a, \dots, U_n+a)$ - de locação

$X = (bU_1, \dots, bU_n)$ - de escala

$X = (U_1+a_1, \dots, U_n+a_n)$ - de locação com comp. dif.

$X = (b_1U_1, \dots, b_nU_n), \dots$ - de escala com comp. dif.

Ex. Distribuição Normal Multivariada

$U = (U_1, \dots, U_p)'$ tq $U_i \sim N(0,1)$, independentes.

$$\begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} = \begin{pmatrix} a_1 \\ \vdots \\ a_p \end{pmatrix} + B \begin{pmatrix} U_1 \\ \vdots \\ U_p \end{pmatrix},$$

onde B é matriz $p \times p$ não singular, ou seja,

$$X = a + BU,$$

com $X = (X_1, \dots, X_p)'$, $a = (a_1, \dots, a_p)'$. Aqui,
 $E(X) = a$ e $\text{Cov}(X) = \Sigma = E[(X-a)(X-a)'] = BB'$.

A densidade de U é (fazer os cálculos)

$$\frac{1}{(\sqrt{2\pi})^p} \exp\left\{-\frac{1}{2} u'u\right\}, \quad u = (u_1, \dots, u_n)',$$

e $U = B^{-1}(X-a)$. O jacobiano da transformação ($\det B$) é o determinante $|B|$ de B . Então, a densidade de X é

$$p(x|a, \Sigma) = \frac{|B|^{-1}}{(\sqrt{2\pi})^p} \exp\left\{-\frac{1}{2} (x-a)' \Sigma^{-1} (x-a)\right\}$$

e escrevemos $X \sim N_p(a, \Sigma)$.

Ex. Modelo linear

$U = (U_1, \dots, U_n)$ com uma dada distribuição conjunta

$$X_i = a_i + b U_i, \quad i=1, \dots, n,$$

tais que

$$a_i = \sum_{j=1}^p d_{ij} \beta_j, \quad i=1, \dots, n,$$

e os d_{ij} são fixos e os β_j são arbitrários. Sem perda de generalidade, assume-se que $D = (d_{ij})$ é de posto p .

Se $U_i \sim N(0,1)$ e são iid, a densidade de X é

$$\frac{1}{(\sqrt{2\pi} b)^n} \exp \left[-\frac{1}{2b^2} \sum (x_i - a_i)^2 \right]$$

[Compare com ex. 14, p. 1A-mod. de regressão normal linear].

Ex. Família não-paramétrica

U : r.a. com uma distribuição contínua (ex.: $N(0,1)$), cujo suporte é a reta toda.

G : classe de transformações tais que

$$x = g(u), \quad \text{onde } g \text{ é qualquer função contínua, estritamente crescente com} \\ \lim_{u \rightarrow -\infty} g(u) = -\infty \text{ e } \lim_{u \rightarrow +\infty} g(u) = +\infty.$$

Deve provar que:

- G é um grupo de transformações
- A classe $\{F_g : g \in G\}$ das distribuições de $g(U)$, fazendo g variar em G , é a classe de todas as distribuições contínuas cujo suporte é $(-\infty, +\infty)$, i.e., a classe de todas as distribuições com f.d.a. contínua e estritamente crescente em $(-\infty, +\infty)$.

Ex. Família não paramétrica simétrica

Igual ao exemplo anterior, mas com U tendo distribuição simétrica em torno de zero e G restrito às funções ímpares, i.e.,

$$g(-u) = -g(u), \text{ para todo } u.$$

A classe resultante é a de todas as distribuições simétricas com relação à origem, com suporte em }(-\infty, +\infty).

Simetria:

$$\begin{aligned} F_x: & \text{ fda de } X; \quad F_U: \text{ fda de } U; \quad x = g(U). \\ \text{P}1+U \geq 0, \quad F_U(u) &= 1 - F_U(-u) \quad (\text{pois } U \text{ é simétrica em torno de } 0). \\ \text{que } F_U(-u) &= 1 - F_U(u) \quad (\text{por que } F_U \text{ é ímpar}). \\ \text{ppq } F_X(x) &= 1 - F_X(-x), \quad \forall x \geq 0 \end{aligned}$$

Para $\forall x \geq 0$, seja $u = g^{-1}(x)$ e

$$\begin{aligned} F_X(x) &= P(X \leq x) = P(g(U) \leq x) = P(U \leq u) \\ &= F_U(u) = 1 - F_U(-u) = 1 - P(U \leq -u) \\ &= 1 - P(g(U) \leq g(-u)) = \\ &= 1 - P(X \leq -g(u)) = 1 - P(X \leq -x) \\ &= 1 - F_X(-x). \quad \square_{\infty} \end{aligned}$$

Generalização: $x = g(u) + a$, $-\infty < a \leq \infty$.
(simetria em relação ao ponto a).

(Como mostrar que são todos?)

FAMÍLIAS EXPONENCIAIS

Uma família $\{P_\theta\}$ de distribuições forma uma família exponencial s-dimensional se as distribuições P_θ têm densidade da forma:

$$p_\theta(x) = \exp \left[\sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right] h(x) \quad (*)$$

com respeito a alguma medida (comum) μ . Os η_i 's e B são funções dos parâmetros a valores reais, T_i 's são funções (estatísticas) a valores reais definidas sobre \mathbb{X} , o suporte da densidade, $\rightarrow x$ é um ponto de \mathbb{X} e h é uma função definida sobre \mathbb{X} a valores reais não negativos.

Ex 1. Poisson; $X \sim \text{Poisson}(\lambda)$, $\lambda > 0$.

$$p_\lambda(x) = \frac{1}{x!} \lambda^x e^{-\lambda}, \quad x=0,1,2,\dots \quad S=1 \quad \text{(unidimensional)}$$

(densidade de X com respeito à medida de contagem)

$$p_\lambda(x) = \exp [(\log \lambda)x - \lambda] \frac{1}{x!}, \quad x=0,1,2,\dots$$

Tem a forma (*) com $T(x)=x$, $\eta_1=\log \lambda$, $B(1)=1$, $h(x)=\frac{1}{x!}$, $\mathbb{X}=\{0,1,2,\dots\}$.

(família exponencial unidimensional)

Ex 2. Distribuição de Rayleigh (Ver em casa)

$$p_{\theta}(x) = \frac{x}{\theta^2} \exp\left\{-\frac{x^2}{2\theta^2}\right\}, \quad x > 0$$

(densidade com respeito à medida de Lebesgue)

$$p_{\theta}(x) = \exp\left[-\frac{x^2}{2\theta^2} - \log\theta^2\right] x, \quad x > 0$$

Tem a forma (*) com $T(x) = x^2$, $\eta(\theta) = -\frac{1}{2\theta^2}$,

$$B(\theta) = \log\theta^2, \quad h(x) = x, \quad \mathcal{X} = \{x \in \mathbb{R}: x > 0\}$$

Ex 3. Suponha que $x = (z, y)$ onde $y = z + \theta w$, $\theta > 0$, $z \in w$ são indep., $z \sim N(0, 1)$, $w \sim N(0, 1)$.
(Ver em casa)

$$p_{\theta}(x) = p_{\theta}(z, y) = p(z) p_{\theta}(y|z) =$$

$$= \phi(z) \frac{1}{\theta} \phi\left((y-z)/\theta\right)$$

onde ϕ é a fdp $N(0, 1)$.

$$p_{\theta}(x) = \frac{1}{(\sqrt{2\pi})^2} \exp\left\{-\frac{1}{2}\left(z^2 + \frac{(y-z)^2}{\theta^2}\right)\right\}$$

$$= \frac{1}{2\pi} \exp\left\{-\frac{1}{2}z^2\right\} \exp\left\{-\frac{1}{2\theta^2}(y-z)^2 - \log\theta\right\}$$

Tem a forma (*) com $T(x) = (y-z)^2$, $\eta = -\frac{1}{2\theta^2}$,

$$B(\theta) = \log\theta, \quad h(x) = \frac{1}{2\pi} \exp\left\{-\frac{1}{2}z^2\right\}, \quad \mathcal{X} = \mathbb{R}^2.$$

Ex 4. $x \sim N(\xi, \sigma^2)$, $\xi \in \mathbb{R}$, $\sigma^2 > 0$, $\theta = (\xi, \sigma^2)$

$$p_{\theta}(x) = \exp\left[\frac{\xi}{\sigma^2}x - \frac{1}{2\sigma^2}x^2 - \frac{\xi^2}{2\sigma^2}\right] \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}$$

$\frac{1}{\sigma} = e^{-\log\sigma}$
 $s = 2$
bidimens.

$$\text{Tem a forma (*) com } T_1(x) = x, \quad T_2(x) = x^2,$$

$$\eta_1(\theta) = \frac{\xi}{\sigma^2}, \quad \eta_2(\theta) = -\frac{1}{2\sigma^2}, \quad B(\theta) = \frac{\xi^2 + \log\sigma^2}{2\sigma^2}, \quad h(x) = \frac{1}{\sqrt{2\pi}\sigma},$$

$$\mathcal{X} = \mathbb{R}^2$$

(família exponencial bi-dimensional)

Outros exemplos importantes: Gama(a, b), Qui-quadrado χ_f^2 , Beta(a, b), Bernoulli(p), Binomial(p, n), n fixo, Binomial negativa BN(p, m), m fixo (ver TPE Tabela 5.1, p. 25).

Forma canônica (forma natural): os η_i 's são visões como os parâmetros.

$$p(x|\eta) = \exp\left[\sum_{i=1}^s \eta_i T_i(x) - A(\eta)\right] h(x) \quad (***)$$

$$\eta = (\eta_1, \dots, \eta_s)$$

↓

$$\eta_i = \eta_i(\theta), \quad B(\theta) = A(\eta)$$

: escrito em função de η
“reparametrização!”

Para que $\frac{1}{\alpha} \int_{\mathbb{R}} \exp \left[\sum_{i=1}^s \eta_i T_i(x) - A(\eta) \right] h(x) d\mu(x)$ seja uma densidade de probabilidade integral com respeito a μ deve ser 1, i.e,

$$\int_{\mathbb{R}} \exp \left[\sum_{i=1}^s \eta_i T_i(x) - A(\eta) \right] h(x) d\mu(x) = 1,$$

ou seja,

$$\exp[-A(\eta)] \int_{\mathbb{R}} \exp \left[\sum_{i=1}^s \eta_i T_i(x) \right] h(x) d\mu(x) = 1.$$

A(η) tal que $\int_{\mathbb{R}} \exp \left[\sum_{i=1}^s \eta_i T_i(x) \right] h(x) d\mu(x) < \infty$

O conjunto Δ de pontas $\eta = (\eta_1, \dots, \eta_s)$ tais que isso ocorre é chamado de **espaço paramétrico natural (canônico)** da família e η é chamada de **parâmetro natural (canônico)**.

Nota: Δ é convexo (TS4, Lema 7, p. 57).

Ex 1. Poisson (cont.)

$\eta = \log \lambda$ é o parâmetro natural e o espaço paramétrico natural é \mathbb{R} .

$$p(x|\eta) = \exp \{ \eta x - \exp(\eta) \} \frac{1}{x!}$$

$$A(\eta) = \exp(\eta), B(\lambda) = \lambda$$

Ex 4. $X \sim N(\xi, \sigma^2)$ (cont)

$$p(x|\eta) = \exp \left[\eta_1 x + \eta_2 x^2 - A(\eta) \right] \frac{1}{\sqrt{2\pi}}$$

$$\eta = (\eta_1, \eta_2) = \left(\frac{\xi}{\sigma^2}, -\frac{1}{2\sigma^2} \right) \text{ é o parâmetro natural,}$$

$$A(\eta) = \frac{\xi^2}{2\sigma^2} + \log \Gamma = -\frac{\eta_1^2}{2\eta_2} + \log \sqrt{-\frac{1}{2\eta_2}}, \text{ e o}$$

espaço paramétrico natural é $\{(\eta_1, \eta_2) \in \mathbb{R}^2 : \eta_2 < 0\}$

Exercício: Colocar as densidades dos exemplos 2 e 3 na forma natural. Idem p/ as distribuições da Tabela 5.1, TPE:

Se nem os T 's nem os η 's satisfazem restrições lineares e o espaço paramétrico para os η 's contém retângulos s -dimensionais, digamos que a família é de **posto completo**.

Ex 4. $X \sim N(\xi, \sigma^2)$ (cont)

Família exponencial bi-dimensional de posto completo.

Nota. Considere $(\eta = (\eta_1, \eta_2))$

$$p(x|\eta) = \exp \left\{ \eta_1 T_1(x) + \eta_2 T_2(x) - A(\eta_1, \eta_2) \right\} h(x)$$

(fam. exp. bi-dimensional)

i) Suponha que $T_2(x) = a T_1(x) + b$, a, b fixos, $a \neq 0$

$$p(x|\eta) = \exp \left\{ \eta_1 T_1(x) + \eta_2 (a T_1(x) + b) - A(\eta) \right\} h(x)$$

$$= \exp \left\{ (\eta_1 + a\eta_2) T_1(x) - A^*(\eta) \right\} h(x),$$

onde $A^*(\eta) = -\eta_2 b + A(\eta)$ Nesse caso, não é de posto completo. Pode

(fam. exp. uni-dimensional) Ser reduzida em dim! $(T_1, T_2 \text{ rest. lineares})$

ii) Suponha que $\eta_2 = a\eta_1 + b$, a, b fixos, $a \neq 0$

$$p(x|\eta) = \exp \left\{ \eta_1 T_1(x) + [a\eta_1 + b] T_2(x) - A(\eta) \right\} h(x)$$

$$= \exp \left\{ \eta_1 T_1(x) - A(\eta) \right\} h^*(x),$$

onde $T_1^*(x) = T_1(x) + a T_2(x)$ e $h^*(x) = h(x) \exp \{ b T_2(x) \}$

(fam. exp. uni-dimensional). rest. lineares

Ex 5. Família normal curvada

$$x \sim N(\xi, \xi^2), \xi > 0$$

$$p_\xi(x) = \exp \left[\frac{1}{\xi} x - \frac{1}{2\xi^2} - \frac{1}{2} \right] \frac{1}{\sqrt{2\pi}\xi},$$

Tem a forma (*) com $T_1(x) = x$, $T_2(x) = x^2$,
 $\eta_1(\xi) = \frac{1}{\xi}$, $\eta_2(\xi) = -\frac{1}{2\xi^2}$, $B(\xi) = +\log \xi$,

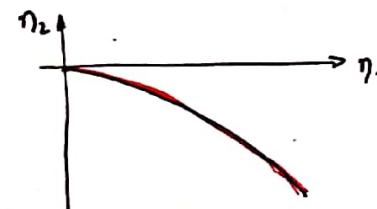
$$h(x) = \exp \left\{ -\frac{1}{2} \right\} \frac{1}{\sqrt{2\pi}}.$$

Família exponencial bi-dimensional com parâmetro natural $\eta = (\eta_1, \eta_2) = \left(\frac{1}{\xi}, -\frac{1}{2\xi^2} \right)$.

o espaço paramétrico curvado

$$\left\{ (\eta_1, \eta_2) \in \mathbb{R}^2 : \eta_1 > 0 \wedge \eta_2 = -\frac{1}{2} \eta_1^2 \right\}.$$

(não é de posto completo).



o espaço paramétrico não contém retângulos bi-dimensionais (aque s=2).

Quando os parâmetros naturais da distribuição estão relacionados de uma forma não linear, dizemos que (*) ou (**) forma uma família exponencial curvada.

Nota. A estrutura exponencial é preservada sob amostragem aleatória. Se $X = (X_1, \dots, X_n)$ e X_1, \dots, X_n são iid com dist. na fam. exp. exponencial s -dimensional sua densidade conjunta é

$$\exp \left[\sum_{i=1}^n \eta_i T_i^*(x) - n A(\eta) \right] h(x_1) \dots h(x_n)$$

onde

$$T_i^*(x) = \sum_{j=1}^n T_i(x_j), \quad x = (x_1, \dots, x_n).$$

Ex 6. $x_i \sim N(\bar{x}, \sigma^2)$, $i = 1, \dots, n$, iid.

A densidade conjunta de X_1, \dots, X_n (com respeito à medida de Lebesgue) é

$$\exp \left\{ \frac{\bar{x}}{\sigma^2} \sum_{i=1}^n x_i - \frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 - \frac{n}{2\sigma^2} \bar{x}^2 \right\} \frac{1}{(\sqrt{2\pi}\sigma)^n}.$$

$$\text{Aqui } T_1^*(x) = \sum_{i=1}^n x_i, \quad T_2^*(x) = \sum_{i=1}^n x_i^2.$$

Alunas: ver Ex 5.7, TPE, p. 27 (normal bivariada).

Teorema. Para qualquer função integrável f e qualquer η no interior de Δ , a integral

$$\int f(x) \exp \left[\sum_{i=1}^n \eta_i T_i(x) \right] h(x) d\mu(x)$$

é contínua e têm derivadas de todas as ordens com respeito aos η 's e essas podem ser obtidas sob o sinal de integração.

Prova: TSH (Cap 2, Teo 9, p 59).

Tomemos η , ponto interior de Δ . Como

$$\int \exp \left[\sum_{i=1}^n \eta_i T_i(x) - A(\eta) \right] h(x) d\mu(x) = 1 \quad \frac{\partial}{\partial \eta_j}$$

temos $\int \frac{\partial}{\partial \eta_j} \exp \left[\sum_{i=1}^n \eta_i T_i(x) - A(\eta) \right] h(x) d\mu(x) = 0$

$$\int \left[T_j(x) - \frac{\partial}{\partial \eta_j} A(\eta) \right] \exp \left[\sum_{i=1}^n \eta_i T_i(x) - A(\eta) \right] h(x) d\mu(x) = 0$$

ou seja,

Xmarcado

$$E_\eta \left(T_j(x) \right) = \frac{\partial}{\partial \eta_j} A(\eta).$$

Média das est.

obtidas pelas derivadas em relação aos η 's.

Mostrar que diferenciando ambos os lados da equação com respeito a η_k tem-se

$$\text{cov}_\eta \left(T_j(x), T_k(x) \right) = \frac{\partial^2}{\partial \eta_j \partial \eta_k} A(\eta).$$

Função geradora de momentos (f.g.m.)

$$T = (T_1, \dots, T_s)$$

$$M_T(u_1, \dots, u_s) = E\{\exp(u_1 T_1 + \dots + u_s T_s)\}, \quad [*]$$

$u = (u_1, \dots, u_s) \in \mathbb{R}^s$.

Suponha que a f.g.m. de T existe ($*$) e é finita numa vizinhança da origem de \mathbb{R}^s , i.e., $\|u\| < \delta$, $\delta > 0$, ou seja, $[\sum_{i=1}^s u_i^2]^{1/2} < \delta$.

A f.g.m. pode então ser expandida em uma série de potências multivariada da forma

$$M_T(u_1, \dots, u_s) = \sum \alpha_{r_1, \dots, r_s} \frac{u_1^{r_1} \dots u_s^{r_s}}{r_1! \dots r_s!},$$

onde $\alpha_{r_1, \dots, r_s} = E(T_1^{r_1} \dots T_s^{r_s})$

$$= \frac{\partial^{r_1+ \dots + r_s} M_T(u_1, \dots, u_s)}{\partial u_1^{r_1} \dots \partial u_s^{r_s}} \Big|_{u=(0, \dots, 0)}$$

Note que o 1º termo da expansão é obtido quando $r_1 = \dots = r_s = 0$ e é igual a 1.

2

X Os cumulantes X_{r_1, \dots, r_s} são definidos como os coeficientes na expansão da função geradora de cumulantes

$$K_T(u_1, \dots, u_s) = \log M_T(u_1, \dots, u_s)$$

$$= \sum_{r_1, \dots, r_s} X_{r_1, \dots, r_s} \frac{u_1^{r_1} \dots u_s^{r_s}}{r_1! \dots r_s!}.$$

Note que

$$X_{r_1, \dots, r_s} = \left. \frac{\partial^{r_1+ \dots + r_s} K_T(u_1, \dots, u_s)}{\partial u_1^{r_1} \dots \partial u_s^{r_s}} \right|_{u=(0, \dots, 0)}$$

Relações entre momentos e cumulantes podem ser obtidas comparando as duas séries de potências.

Ex. $s=1, T=T_1$

$$M_T(u) = \sum_{j=0}^{+\infty} \frac{\alpha_j u^j}{j!}, \alpha_i = E(T^i), i=1, 2, \dots, \quad (1)$$

$$K_T(u) = \log M_T(u) \Rightarrow K_T(0) = 0.$$

$$\exp(K_T(u)) = M_T(u)$$

Seja $K_T(u) = x$. Expandido e^x em torno de $x=0$ (em série de Taylor) vêm

$$e^x = 1 + x + \frac{x^2}{2!} + \dots$$

Avaliando e^x em $x = K_T(u)$ temos:

$$\begin{aligned} \exp(K_T(u)) &= 1 + K_T(u) + \frac{(K_T(u))^2}{2!} + \dots \\ &= 1 + \sum_{j=0}^{+\infty} \frac{k_j u^j}{j!} + \frac{1}{2!} \left(\sum_{j=0}^{+\infty} \frac{k_j u^j}{j!} \right)^2 + \dots \quad (2) \end{aligned}$$

Igualando (1) e (2) vem

$$k_0 = 0$$

$$k_1 = \alpha_1 = E(T)$$

$$\frac{k_2}{2!} + \frac{k_1^2}{2!} = \frac{\alpha_2}{2!}, \text{ i.e., } k_2 = \alpha_2 - \alpha_1^2 = \text{Var}(T)$$

$k_2 \in \text{Var}$.

Exercício: Mostrar que

$$1. \quad \lambda_3 = E[(T-\alpha_1)^3] \quad 3^{\text{a}} \text{ mom central de } T$$

$$\lambda_4 = E[(T-\alpha_1)^4] - 3[\text{Var}(T)]^2 \quad 4^{\text{a}} \text{ mom central - 3Var}^2$$

$$\lambda_5 = E[(T-\alpha_1)^5] - 10\text{Var}(T)E[(T-\alpha_1)^3]$$

$$\lambda_6 = E[(T-\alpha_1)^6] - 15\text{Var}(T)E[(T-\alpha_1)^4]$$

$$-10\{E[(T-\alpha_1)^3]\}^2 + 30\{\text{Var}(T)\}^3$$

$$2. \quad \lambda_j(T+a) = \lambda_j(T), \quad j=2, 3, \dots$$

$$3. \quad \mu_j(T+a) = \mu_j(T), \quad j=2, 3, \dots; \quad \mu_j = E[(T-\alpha_1)^j]$$

$$4. \quad \lambda_j(a, T) = a^j \lambda_j(T), \quad j=1, 2, \dots$$

5. Se T_1 e T_2 são independentes, então

$$\lambda_j(T_1+T_2) = \lambda_j(T_1) + \lambda_j(T_2), \quad j=1, 2, \dots$$

6. Se $T \sim N(\mu, \sigma^2)$ então

$$\lambda_1(T) = \mu, \quad \lambda_2(T) = \sigma^2 \quad \lambda_j(T) = 0, \quad j=3, 4, \dots$$

Ref.: Bening, V.E. (2000). Asymptotic Theory of Testing Statistical Hypotheses: Efficient Statistics, Optimality, Power Loss and Deficiency. VSP: Utrecht.

Teorema: TPE, T. 5.10, p28.

Se X tem densidade na forma

$$p(x|\eta) = \exp \left[\sum_{i=1}^s \eta_i T_i(x) - A(\eta) \right] h(x),$$

então para qualquer η no interior de Δ , as funções geradoras de momentos e de cumulantes dos T_i 's, $M_T(u)$ e $K_T(u)$, existem (em alguma vizinhança da origem) e são dadas por

$$\underline{M_T(u)} = \frac{\exp(A(\eta+u))}{\exp(A(\eta))}$$

$$\text{e } \underline{K_T(u)} = A(\eta+u) - A(\eta).$$

$$\text{Dem. } M_T(u) = E[\exp(u_1 T_1 + \dots + u_s T_s)]$$

$$\begin{aligned} &= \int_{\mathbb{R}^s} \exp \left(\sum_{i=1}^s (\eta_i + u_i) T_i(x) - A(\eta) \right) h(x) d\mu(x) \\ &= \frac{\exp(-A(\eta))}{\exp(-A(\eta+u))} \int_{\mathbb{R}^s} \exp \left(\sum_{i=1}^s (\eta_i + u_i) T_i(x) - A(\eta+u) \right) h(x) \\ &\quad d\mu(x); \end{aligned}$$

$$\eta = (\eta_1, \dots, \eta_s); \quad u = (u_1, \dots, u_s).$$

Como η é pt. interior de Δ , se pode estar numa vizinhança adequada da origem de \mathbb{R}^s , $\eta+u$ também é ponto interior de η . A integral acima vale 1 e segue o resultado.

$$K_T(u) = \log M_T(u) = A(\eta+u) - A(\eta).$$

Ex. Binomial

$$\text{Para } x=0,1,2,\dots,n \\ P(X=x) = \binom{n}{x} p^x (1-p)^{n-x}; \quad 0 < p < 1$$

$$= \exp \left\{ x \log \frac{p}{1-p} + n \log(1-p) \right\} \binom{n}{x}$$

família exponencial com μ sendo a medida de contagem sobre $x=0,1,\dots,n$ e com

$$\eta = \log \frac{p}{1-p}; \quad A(\eta) = n \log(1+e^\eta).$$

$$\begin{aligned} \underline{M_X(u)} &= \frac{\exp(A(\eta+u))}{\exp(A(\eta))} = \\ &= \left[\frac{1+e^{\eta+u}}{1+e^\eta} \right]^n = (1-p+pe^u)^n. \end{aligned}$$

$$\underline{K_X(u)} = n \log(1-p+pe^u).$$

$$\begin{aligned} E(X) &= \alpha_1 = M'_X(u) \Big|_{u=0} = n(1-p+pe^u)^{n-1} pe^u \Big|_{u=0} \\ &= np. \end{aligned}$$

$$\text{Var}(X) = \chi_2 = K''_X(u) \Big|_{u=0} = n p(1-p).$$

Alunos: Estudar exemplos 5.11-5.14 (TPE, p.29-31).

MODELOS LINEARES GENERALIZADOS

Seja Y v.a. com f.d.p.

$$f(y; \theta) = \exp\{\phi(y\theta - b(\theta)) + c(y, \phi)\}, \quad [*]$$

$\phi > 0$ (fixado). \downarrow par. de precisão (maior ϕ , maior precisão)

A f.d.p. de Y está na forma da família exponencial (*) (p. 17) com

$$\eta(\theta) = \phi\theta ; \quad T(y) = y ;$$

$$B(\theta) = \phi b(\theta) ; \quad h(y) = \exp\{c(y, \phi)\}.$$

Na forma natural da fam. exponencial, temos que a f.d.p. de Y pode ser reescrita como

$$\underline{f^*(y; \theta)} = \exp\{\eta y - \phi b\left(\frac{\eta}{\phi}\right)\} \exp\{c(y, \phi)\}.$$

Aqui, $\eta = \phi\theta$ e $A(\eta) = \phi b\left(\frac{\eta}{\phi}\right)$.

$$\underline{E(Y)} = A'(\eta) = \frac{\partial}{\partial \eta} \left[\phi b\left(\frac{\eta}{\phi}\right) \right] = \underline{b'(\theta)} = \mu.$$

$$\begin{aligned} \underline{\text{Var}(Y)} = \underline{A''(\eta)} &= \frac{\partial^2}{\partial \eta^2} \left[\phi b\left(\frac{\eta}{\phi}\right) \right] = \frac{1}{\phi} b''(\theta) \\ &= \frac{1}{\phi} \frac{du}{d\theta}. \end{aligned}$$

$$\boxed{E(Y) = \mu = b'(\theta)}$$

$$\text{Var}(Y) = \frac{1}{\phi} V \xrightarrow{\text{f. de variação}} ; \quad V = \frac{du}{d\theta}$$

ϕ : parâmetro de precisão

μ : média

V : função de variação

Veja...:
 y_i satisfaz $[*]$:
 y_i, Y_i estão na famíl.
ia exponencial. Nas
 rigas η ma $\Rightarrow T(y_i)$ deve
 ser uma função linear da
 observação
Exemplo: Beta($T(y_i)$) $\xrightarrow{\text{f. lin}}$
 (depende de μ) $\xrightarrow{\text{em x}}$

$\theta_1 \quad \theta_2$
 Nos MLG's admite-se que y_1, \dots, y_n são v.a.'s
 com f.d.p. $f(y_i; \theta_i)$ (ver $[*]$) e que

$$g(\mu_i) = \eta_i = x_i^T \beta \quad \mu_i = E(Y_i) = b(\theta_i)$$

em que $\mu_i = b'(\theta_i)$, $x_i = (x_{i1}, \dots, x_{ip})^T$, $p \leq n$,
 é um vetor de constantes (variáveis explicativas), $\beta = (\beta_1, \dots, \beta_p)^T$ é um vetor de parâmetros desconhecidos e $g(\cdot)$ é uma função monótona e diferenciável, denominada função de ligação.

- Casos particulares de $[*]$:

- Normal (μ, σ^2) ; $\phi = \sigma^{-2}$ (Fix. ϕ ; deve estar na fam. exp linear)
- Poisson (μ)
- Binomial (μ, n) ; n fixo
- Gama, Normal inversa

Modelos Lin. Gen. considera v.a. ~~na~~ na famíl. expon. linear.

ESTATÍSTICAS SUFICIENTES

Ligação canônica: $\theta_i = \eta_i = \sum_{j=1}^p x_{ij} \beta_j$

Nesse caso, a fdp conjunta de $\underline{y} = (y_1, \dots, y_n)$ é

$$f_y(\underline{y}; \beta) = \exp \left\{ \phi \left(\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i) + \sum_{i=1}^n c(y_i, \phi) \right) \right\}$$

$$\underline{y} = (y_1, \dots, y_n); \quad \underline{\theta} = (\theta_1, \dots, \theta_n)$$

$$f_y(\underline{y}; \beta) = \exp \left\{ \phi \sum_{j=1}^p \left(\sum_{i=1}^n y_{ij} x_{ij} \right) \beta_j - \phi \sum_{j=1}^p b \left(\sum_{i=1}^n x_{ij} \beta_j \right) \right. \\ \left. + \sum_{i=1}^n c(y_i, \phi) \right\}$$

Nesse caso, ter. uma

FAMÍLIA EXPONENCIAL p-DIMENSIONAL DE POSTO COMPLETO (estamos admitindo aqui que ϕ é conhecido e que o espaço paramétrico é \mathbb{R}^p).

No caso, da ligação canônica, vale (2)

OBS: (1) Nas MLG's pode-se admitir que ϕ é desconhecido

(2) A estatística $S = (S_1, \dots, S_p)$, com $S_j = \sum_{i=1}^n y_{ij} x_{ij}$, $j = 1, \dots, p$, é uma estatística suficiente completa para β (conclui que será visto a seguir)

Uma estatística $T = T(\underline{x})$ é suficiente para θ [ou para \underline{x} , ou para a família $P = \{P_\theta, \theta \in \Omega\}$] se a distribuição condicional de \underline{x} dado $T = t$ é independente de θ para todo t .

Ideia: Redução dos dados sem perda de informação sobre θ .

"Depois que observou $T=t$, $T=t$ se torna irrelevante para θ "

Ex 1. Poisson

$$\underline{x} \sim \text{Poisson}(\lambda), \quad \lambda > 0$$

Foram feitas n observações de \underline{x}

$$x_1, \dots, x_n: \text{r.a.'s iid}, \quad x_i \sim \text{Poisson}(\lambda)$$

a) Perdeu-se a última observação de \underline{x} . Houve "perda de informação"?

Sim \rightarrow Festa calc. a dist. cond. de X da x_1, \dots, x_{n-1} , que dep de λ

b) Perderam-se todas as observações, mas ficou o registro da média \bar{x} .
Houve "perda de informação"?

Não \rightarrow Dist. cond. de $X / \bar{X} = \bar{x}$ não dep. de λ .

b) Para $t = 0, 1, 2, \dots$, $x_1, x_2, \dots, x_n \in \{0, 1, \dots\}$,

$$\sum_{i=1}^n x_i = t :$$

$$P(X_1=x_1, \dots, X_n=x_n \mid \sum_{i=1}^n X_i = t) =$$

$$\frac{P(X_1=x_1, \dots, X_n=x_n)}{P(\sum_{i=1}^n X_i = t)} = \frac{\prod_{i=1}^n P(X_i=x_i)}{\frac{e^{-n\lambda} (\lambda)^t}{t!}}$$

$$= \frac{\prod_{i=1}^n e^{-\lambda} \lambda^{x_i} / x_i!}{\frac{e^{-n\lambda} (\lambda)^t}{t!}} = \frac{1}{n^t} \frac{t!}{x_1! \dots x_n!}$$

(não depende de λ)

"Se ~~$\sum x_i \neq t$~~ ,

$$P(X_1=x_1, \dots, X_n=x_n \mid \sum_{i=1}^n X_i \neq \sum_{i=1}^n x_i) = 0,$$

que não dep. de λ "

Se $\sum_{i=1}^n x_i \neq t$, tal probabilidade condicional é zero. Logo, $T(x_1, \dots, x_n) = \sum_{i=1}^n x_i$ é uma estatística suficiente para λ .

E' fácil ver que, como \bar{x} é função 1-a-1 de T , \bar{x} é estatística suficiente para λ .

Resposta: não houve "perda de informação".

OBS. Suponha que $n=2$. (caso (b))

A distribuição de X_1 dado $T=X_1+X_2=t$

e' binomial ($1/2, t$) (se $t=0$ essa distr.

é degenerada em zero, i.e.,

$$P(X_1=0 \mid T=0) = 1]. \rightarrow \text{Exercício}$$

Para "recuperar" (X_1, X_2) a partir de $T=t$,

pode-se gerar uma v.a. X'_1 com distr.

$b(1/2, t)$ e definir $X'_2 = t - X'_1$.

distribuição condicional de (X'_1, X'_2) dado

$T=t$ é a mesma de (X_1, X_2) dado $T=t$.

Logo, as distribuições marginais de

(X_1, X_2) e (X'_1, X'_2) coincidem. (sempre é possível obter a condicional?) P.P.

a) Para $x_1, \dots, x_n \in \{0, 1, 2, \dots\}$:

$$P(X_1 = x_1, \dots, X_n = x_n \mid X_1 = x_1, \dots, X_{n-1} = x_{n-1}) =$$

$$\frac{P(X_1 = x_1, \dots, X_n = x_n)}{P(X_1 = x_1, \dots, X_{n-1} = x_{n-1})} =$$

$$\frac{\prod_{i=1}^n P(X_i = x_i)}{\prod_{i=1}^n P(X_i = x_i)} = P(X_n = x_n) = \frac{e^{-\lambda} \lambda^{x_n}}{x_n!}$$

(depende de λ)

Logo, $H(x_1, \dots, x_n) = (x_1, \dots, x_{n-1})$ não é uma estatística suficiente para λ .

Resposta: sim, houve "perda de informação".

Exercícios: X_1, \dots, X_n iid, $X_i \sim \text{Binomial}(p, n)$, n fixo $0 < p < 1$. (Fazer!)

Mostrar que \bar{X} é suficiente para p , mas (x_1, \dots, x_{n-1}) não é.

↑ dist em rel.
à origem

Ex 2. $X \sim N(0, \sigma^2)$, $\sigma^2 > 0$; $T = |X|$. (Intuitivo)

A distribuição condicional de $X \mid T = t$, $t > 0$,
é tg

$$P(X = t \mid T = t) = P(X = -t \mid T = t) = 1/2.$$

"Como se fosse 1
(Bernoulli 1/2). em $\{-t, t\}$ ".

redução
"tirar
o sinal"

Simetria da
normal.

Verificação:

- Para $t > 0$:

$$F_T(t) = P(|X| \leq t) = P(-t \leq X \leq t)$$

ACUMULADA DA NORMAL PADRÃO

Recton.

$$= \Phi\left(\frac{t}{\sigma}\right) - \Phi\left(-\frac{t}{\sigma}\right).$$

$$f_T(t) = \frac{1}{\sigma} \phi\left(\frac{t}{\sigma}\right) + \frac{1}{\sigma} \phi\left(-\frac{t}{\sigma}\right) = \frac{2}{\sigma} \phi\left(\frac{t}{\sigma}\right).$$

PENSIDADE DA NORMAL PADRÃO

- Vamos construir a distr. de X combinando a distr. de $X \mid T = t$ (supondo Bernoulli 1/2) e a distr. marginal de T (acima) para verificar se, de fato, chegamos a $N(0, \sigma^2)$.

Para $t > 0$:

$$f_T(t) \cdot P(X=t | T=t) = \frac{1}{\sigma} \phi\left(\frac{t}{\sigma}\right)$$

$$f_T(t) \cdot P(X=-t | T=t) = \frac{1}{\sigma} \phi\left(\frac{-t}{\sigma}\right)$$

$$\therefore f_X(t) = \frac{1}{\sigma} \phi\left(\frac{t}{\sigma}\right), \quad t \in \mathbb{R}, \text{ i.e.}$$

$$X \sim N(0, \sigma^2).$$

A definição de estatística suficiente envolve o conceito de probabilidade condicional.

A definição de probabilidade condicional pode ser alterada para qualquer conjunto de valores de t que tenha probabilidade zero, sem alterar a distribuição de X , esta obliqua combinando-se a distribuição de T com a distribuição condicional de X dado T .

Note que, no ex. 2, $P_\theta(T=t) = 0$.

Uma estatística T será dita suficiente se existir uma determinação das funções distribuições condicionais de X dado T que seja independente de θ .

TPE, p. 34-35; TSM, Seção 2.6.

Teorema. CRITÉRIO DA FATORAÇÃO

Uma condição necessária e suficiente para que uma estatística T seja suficiente para a família $\mathcal{P} = \{P_\theta, \theta \in \Omega\}$ de distribuições de X dominada por uma medida μ σ -finita e que existam funções g_θ e h tais que as densidades p_θ de P_θ satisfaçam

$$p_\theta(x) = g_\theta[T(x)] h(x) \quad (\text{q.c.m.})$$

Def. (caso discreto)

μ : medida de contagem sobre \mathbb{X} , o conjunto de possíveis valores de X .

(\Rightarrow) Vale $\boxed{\text{cida}}$

Para todo $x \in \mathbb{X}$ tq $p_\theta(x) \neq 0$, defina $t = T(x)$. Temos

$$\begin{aligned} P_\theta\{T=t\} &= \sum_{\{x \in \mathbb{X}: T(x)=t\}} p_\theta(x) = \sum_{\{\dots\}} g_\theta[T(x)] h(x) \\ &= g_\theta(t) \sum_{\{\dots\}} h(x). \end{aligned}$$

$$P_\theta\{X=x | T=t\} = \begin{cases} \frac{p_\theta(x)}{g_\theta(t) \sum_{\{\dots\}} h(x)} & = \frac{g_\theta(t) h(x)}{g_\theta(t) \sum_{\{\dots\}} h(x)}, \quad T(x)=t \\ 0; & T(x) \neq t \end{cases}$$

e' independente de θ .

$\Leftrightarrow T$ é suficiente (vetor)

A distribuição condicional de X dado T é independente de θ

$$\begin{aligned} P_{\theta}(X=x) &= P_{\theta}(X=x, T=t) = \underbrace{P(X=x | T=t)}_{\text{Indep } \theta \text{ dasuf.}} \underbrace{P_{\theta}(T=t)}_{g_{\theta}(t)} \\ &= h(x) g_{\theta}(t). \end{aligned}$$

Dem. no caso geral: TSH, Secção 2.6, Teo 8, Cor. A.

Ex 1. Poisson (cont.)

$$P_{\lambda}(X_1=x_1, \dots, X_n=x_n) = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod x_i!}, \quad x_i \in \{0, 1, \dots\}, \quad i=1, \dots, n.$$

Tem a forma \star com $T = \sum X_i$ (est. suficiente),
 $g_{\theta}(t) = e^{-\lambda} \lambda^t$

Ex 2. $N(0, \sigma^2)$ (cont.)

$$P_{\theta^2}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{|x|^2}{2\sigma^2}\right\}, \quad x \in \mathbb{R}.$$

$$h(x) = \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{\sigma} e^{-\frac{|x|^2}{2\sigma^2}}$$

$|x|$ é est. suficiente.

Ex 3. X_1, \dots, X_n iid, $X_i \sim U(0, \theta)$, $\theta > 0$.

$$x = (x_1, \dots, x_n)$$

$$\begin{aligned} P_{\theta}(x) &= \frac{1}{\theta^n} \prod_{i=1}^n I(x_i \geq 0) I(x_i < \theta) \\ &= \frac{1}{\theta^n} I(x_{(n)} \leq \theta) \prod_{i=1}^n I(x_i \geq 0), \quad x_{(n)} = \max(x_1, \dots, x_n) \end{aligned}$$

Tem a forma \star com $T = X_{(n)} = \max(X_1, \dots, X_n)$.

Ex 4. X_1, \dots, X_n iid, $X_i \sim N(\mu, \sigma^2)$ (Tarefa)

$$\begin{aligned} T_1 &= (\sum X_i, \sum X_i^2) \text{ é estat. suficiente} \\ f_{i=1} &\left(\begin{array}{l} T_2 = (\sum X_i, \sum (X_i - \bar{X})^2) \\ g_{i=1} \left(\begin{array}{l} T_3 = (\bar{X}, \frac{\sum (X_i - \bar{X})^2}{n}) \end{array} \right) \end{array} \right. \end{aligned}$$

Podem existir diferentes estatísticas suficientes.

Nota: As 3 estatísticas são equivalentes (para cada par de estatísticas, uma é função da outra).

Elas identificam os mesmos pontos do espaço amostral, i.e., se $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^n$, tem-se

$$T_1(x) = T_2(y) \Leftrightarrow T_2(x) = T_2(y).$$

(idem para os pares (T_1, T_3) e (T_2, T_3)).

Ex 5. Estatísticas de ordem

31

X_1, \dots, X_n : v.a's iid com densidade conjunta

$$p_{\theta}(x) = \prod_{i=1}^n p(x_i | \theta), \quad x = (x_1, \dots, x_n)$$

Sendo $p(x_i | \theta)$ a densidade de X_i , avalia-se que

$$p_{\theta}(x) = \prod_{i=1}^n p(x_{(i)} | \theta)$$

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

$x_{(i)}$: i-estatística de ordem

$(x_{(1)}, \dots, x_{(n)})$ é uma estatística suficiente.

Redução: informar ordem em que foram obtidos

Composta de 2 s.s. (agrupar, pouca redução).

Nota. Na família exponencial s-dimensional a densidade de uma a.a. X_1, \dots, X_n é

$$\exp \left[\sum_{i=1}^s \eta_i(\theta) T_i^*(x) - n B(\theta) \right] \prod_{i=1}^n h(x_i)$$

$$\text{onde } T_i^*(x) = \sum_{j=1}^n T_i(x_j), \quad x = (x_1, \dots, x_n).$$

Pelo critério da fatoração,

$$\left(\sum_{j=1}^n T_1(x_j), \dots, \sum_{j=1}^n T_s(x_j) \right)$$

c' uma estatística suficiente, qualquer que seja o tamanho da amostra.

Redução de dimensionalidade: de n pr. s.

Redução máxima dos dados sem perda de informação sobre θ : estatística suficiente minimal.

SUFICIÊNCIA MINIMAL

Uma estatística T é dita ser suficiente minimal se é suficiente e, entre todas as estatísticas suficientes, é aquela que produz maior redução nos dados, ou seja, para qualquer estatística suficiente U , existe uma função H tal que $T = H(U)$ (g.c. β').

Teorema. Seja \mathcal{P} uma família finita com densidades p_i , $i=0, 1, \dots, R$, todas tendo o mesmo suporte. Então, a estatística

$$T(x) = \left(\frac{p_1(x)}{p_0(x)}, \frac{p_2(x)}{p_0(x)}, \dots, \frac{p_n(x)}{p_0(x)} \right)$$

e' sufficiente minima.

Para provar o teorema vamos usar o seguinte corolário do critério de fatoração (cf).

Corolário do CF. Sob as condições do C.F., uma condição necessária e suficiente para uma estatística U ser suficiente é que para qualquer θ e θ_0 fixados, a razão $P_U(x) / P_{U_0}(x)$ seja

uma função apenas de $U(x)$.

Quarantine: 8:00 → 10:00

Terga: 14 → 15:80

Dem. (\Rightarrow) U é suficiente

Pelo CF, $\exists g_0 \in L$, f_{g_0} s não negativas, t.q.

$$P_\theta(x) = g_\theta [v(x)] h(x)$$

e

$$P_{\theta_0}(x) = g_{\theta_0}[U(x)] - h(x) \quad (\text{q.c. } \mu)$$

Então, p/ q θ, θ₀ fixado

$$\frac{p_0(x)}{p_{\theta_0}(x)} = \frac{g_{\theta}[U(x)]}{g_{\theta_0}[U(x)]} \quad (\text{q. c. } \mu)$$

$e \cdot e' \therefore$ uma f_f apenas de $U(x)$.

(\Leftarrow) Para $\forall \theta, \theta_0$, $\exists f_{\theta} H_{\theta, \theta_0}$ t.c.

$$\frac{p_{\theta}(x)}{p_{\theta_0}(x)} = H_{\theta, \theta_0}(V(x))$$

Tomando um Bo fixado

$$P_0(x) = P_{\theta_0}(x) H_{\theta, \theta_0}(U(x))$$

$$= h(x) g_{\theta}[U(x)],$$

onde $h(x) = p_{\theta_0}(x) = g_{\theta_0}[U(x)] = H_{\theta_0, \theta_0}(U(x))$.

Dem. do Teorema.

$$\underline{T} = \underline{T}(x) = (T_1, \dots, T_k), \quad \underline{T}_i = T_i(x) = \frac{p_i(x)}{p_0(x)}, \quad i=1, \dots, k.$$

Sejam $g_0(T) = 1$ e $g_i(T) = T_i$, $i=1, \dots, k$.

Então $p_i(x) = g_i(T(x)) p_0(x)$ e \therefore ,

pelo C.F., $T(x)$ é suficiente.

Pelo corolário, U é uma estatística suficiente para que T é uma ff de U . Isso prova que T é minimal. ■

Extensão do Teorema para \mathcal{P} contável é imediata (exercício).

Para \mathcal{P} não contável, é útil o Lema a seguir.

38A

Lema. Se \mathcal{P} é uma família de distribuições com suporte comum (o mesmo para todos os membros da família) e $\mathcal{P}_0 \subset \mathcal{P}$, e se T é suficiente minimal para \mathcal{P}_0 e suficiente para \mathcal{P} , então T é suficiente minimal para \mathcal{P} .

Dem. Se U é suficiente para \mathcal{P} , também é para \mathcal{P}_0 . Então, T é ff de U , pois T é suficiente minimal para \mathcal{P}_0 .

(caso de medida contínua em \mathcal{P} tem o resultado med. nula em \mathcal{P} , dado o sup. comum)

Ex. $N(\theta, 1)$, $\theta \in \mathbb{R}$

$$x_1, \dots, x_n: iid, x_i \sim N(\theta, 1)$$

\mathcal{P}_0 : consiste de 2 distribuições $N(\theta_0, 1) \times N(\theta_1, 1)$.

$$T(x) = \frac{p_{\theta_1}(x)}{p_{\theta_0}(x)} \text{ é suficiente minimal; } x = (x_1, \dots, x_n).$$

$$T(x) = \exp \left\{ -\sum \frac{(x_i - \theta_1)^2}{2} + \sum \frac{(x_i - \theta_0)^2}{2} \right\} \text{ expandir,} \\ = \exp \left\{ n\bar{x}(\theta_1 - \theta_0) - \frac{n}{2} (\theta_1^2 - \theta_0^2) \right\} \text{ rearranjar}$$

que é equivalente a \bar{x} (ff 1 a 1 de \bar{x}).

Como \bar{x} é suficiente para $\mathcal{P} = \{N(\theta, 1) : \theta \in \mathbb{R}\}$,

então \bar{x} é suficiente minimal para \mathcal{P} .

O Teorema abaixo (Shervish, p. 92) daí uma maneira bem geral de se obter estatísticas suficientes mínimas.

Teorema. Sob as condições do C.F., assuma que

$$T(x) = T(y) \iff y \in D(x)$$

onde

$$D(x) = \{y \in \mathbb{X} : P_\theta(y) = P_\theta(x) h(x, y), \forall \theta \in \Omega\}$$

para alguma função h não negativa. Então $T(x)$ é suficiente mímimal.

Dem. Devemos mostrar que para \forall estatística suficiente S , existe uma função v tq $T = v(S)$ e que T é suficiente.

Sendo $x \neq y$ tq $S(x) = S(y)$ temos do CF que, para $\forall \theta \in \Omega$,

$$\begin{aligned} P_\theta(x) &= g(S(x), \theta) h(x) = g(S(y), \theta) h(x) \\ &= g(S(y), \theta) h(y) \frac{h(x)}{h(y)} = P_\theta(y) h(x, y). \end{aligned}$$

Então,

$$\begin{aligned} S(x) = S(y) &\Rightarrow P_\theta(x) = P_\theta(y) h(x, y), \forall \theta \in \Omega \Rightarrow \\ T(x) &= T(y). \end{aligned}$$

Logo, $T = v(S)$ para alguma fç v .

4c

41

Falta mostrar que T é suficiente. Faremos isso no caso discreto (\mathbb{X} é contável).

Para um $x_0 \in \mathbb{X}$ arbitrário, denotemos por c_0 $T(x_0)$.

$$P_\theta [X = x_0 | T(X) = c_0] = \frac{P_\theta [X = x_0, T(X) = c_0]}{P_\theta [T(X) = c_0]}$$

$$= \frac{P_\theta [X = x_0]}{P_\theta [T(X) = c_0]}$$

$$= \frac{P_\theta [X = x_0]}{\sum_{d \in \{x \in \mathbb{X} : T(x) = c_0\}} P_\theta [X = d]} = \frac{1}{\sum_{d \in \{-\}} \frac{P_\theta(d)}{P_\theta(x_0)}}$$

$$= \frac{1}{\sum_{d \in \{-\}} h(d, x_0)} \quad \text{e' indip. de } \theta.$$

$$P_\theta [X = x | T(X) = c] = 0, \quad \text{para } c \neq c_0 \quad (\text{ind.-de } \theta).$$

Ver: - Dudewicz & Mishra (1988). Modern Mathematical Statistics. Wiley (p. 401. Teo 8.1.23).

- Shervish, Teo 2.29, p. 92 (demonstração mais geral).

Ex1. X_1, \dots, X_n : iid, $X_i \sim N(\theta, 1)$, $\theta \in \mathbb{R}$
(cont.)

42

$T(x) = \sum x_i$ é suficiente para θ ; $x = (x_1, \dots, x_n)$

$$\begin{aligned} p_{\theta}(x) &= \frac{1}{(2\pi)^n} \exp \left\{ -\sum \frac{(x_i - \theta)^2}{2} \right\} \\ &= \frac{1}{(2\pi)^n} \exp \left\{ -\frac{\sum x_i^2}{2} + \theta \sum x_i - \frac{n\theta^2}{2} \right\}. \end{aligned}$$

$$p_{\theta}(y) = \frac{1}{(2\pi)^n} \exp \left\{ -\frac{\sum y_i^2}{2} + \theta \sum x_i - \frac{n\theta^2}{2} \right\}$$

$$\times \exp \left\{ -\frac{\sum y_i^2 - \sum x_i^2}{2} + \theta (\sum y_i - \sum x_i) \right\}$$

$$= p_{\theta}(x) \exp \left\{ -\frac{\sum y_i^2 - \sum x_i^2}{2} + \theta (\sum y_i - \sum x_i) \right\}. \quad \text{Voltemos } \overset{a}{\underset{b}{\leftrightarrow}} \quad \text{a}$$

Note que $T(x) = T(y) \Leftrightarrow \sum x_i = \sum y_i \Leftrightarrow$

$$y \in \{y = (y_1, \dots, y_n) \in \mathbb{R}^n : \sum y_i = \sum x_i\} \Leftrightarrow$$

$$y \in D(x) = \{y \in \mathbb{R}^n : p_{\theta}(x) = p_{\theta}(y) \cdot h(x, y), \forall \theta \in \mathbb{R}\},$$

$$\text{onde } h(x, y) = \exp \left\{ -\frac{\sum y_i^2 - \sum x_i^2}{2} \right\}.$$

$\therefore T(x) = \sum x_i$ ($e \bar{x}$) é suficiente minimal.

Exercício.

Ex2. X_1, \dots, X_n : iid, $X_i \sim \text{Bernoulli}(\theta)$, $0 < \theta < 1$.

$\sum x_i$ e \bar{x} são estatísticas suficientes mínimas
(exercício).

Ex3. X_1, \dots, X_n : iid, $X_i \sim U(0, \theta)$, $\theta > 0$.

$$p_{\theta}(x) = \frac{1}{\theta^n} I_{(0, \theta)}(x_m), \quad x_i > 0, \quad i=1, \dots, n$$

Sója

$T(x) = x_m$ (é uma estat. suficiente).

Definimos

$$D(x) = \{y = (y_1, \dots, y_n) \in \mathbb{R}^n : y_i > 0, \forall i = 1, \dots, n\}$$

$$p_{\theta}(y) = p_{\theta}(x) \cdot 1, \quad \theta > 0\}.$$

Assim

$$T(x) = T(y) \Leftrightarrow y \in D(x)$$

e $\therefore T(x) = x_m$ é suficiente minimal. (\Leftarrow) $p_{\theta}(y) = p_{\theta}(x)$

$$\max(x_1, \dots, x_n) = \max(y_1, \dots, y_n)$$

$$I_{(0, \theta)}(x_m) = I_{(0, y_m)}$$

$$I_{(0, \theta)}(x_m) = I_{(0, y_m)}$$

Ex. Ex4. Exponencial, $X_i \sim E(\theta, 1)$, $\theta \in \mathbb{R}$, iid, $i=1, \dots, n$. $T(x) = \bar{x}$

Se $X \sim E(a, b)$, $a \in \mathbb{R}, b > 0$,

$$p_{a,b}(x) = \frac{1}{b} \exp \left\{ -\frac{(x-a)}{b} \right\} I_{[a, +\infty)}(x).$$

Aqui, x_m é estatística suficiente minimal
(exercício).

Ex5. Uniforme, $X_i \sim U(\theta - 1/2, \theta + 1/2)$, iid, $i=1, \dots, n$.
 (x_m, x_m) é suf. minimal (exercício)

Ex 6. Logístico, $x_i \sim L(\theta, 1)$, $i=1, \dots, n$, iid.



Se $x \sim L(a, b)$, $a \in \mathbb{R}$, $b > 0$,

$$p_{a,b}(x) = \frac{1}{b} \frac{\exp\{-(x-a)/b\}}{\left[1 + \exp\{-(x-a)/b\}\right]^2}$$

$$p_\theta(x) = \exp\left[-\sum x_i + n\theta\right] \frac{1}{\pi \left\{1 + \exp\{-(x_i - \theta)\}\right\}^2}$$

Dejam
 $\tau(x) = (x_{(1)}, \dots, x_{(n)})$, $u_i = e^{-y_i}$, $v_i = e^{-x_i}$

$$\xi = e^\theta, \quad \eta = \xi^{-1}.$$

Note que

$$\begin{aligned} \frac{p_\theta(y)}{p_\theta(x)} &= \exp\left[\sum x_i - \sum y_i\right] \prod_{i=1}^n \frac{\left[1 + \exp\{-(y_i - \theta)\}\right]^2}{\left[1 + \exp\{-(x_i - \theta)\}\right]^2} \\ &= \exp\left[\sum x_i - \sum y_i\right] \prod_{i=1}^n \left[\frac{1 + u_i \xi}{1 + v_i \xi}\right]^{-2} \\ &= \exp\left[\sum x_i - \sum y_i\right] \prod_{i=1}^n \left[\frac{\eta + v_i}{\eta + u_i}\right]^2. \end{aligned}$$

$$\tau(x) = \tau(y) \Rightarrow \frac{p_\theta(y)}{p_\theta(x)} = 1, \quad \forall \theta \in \mathbb{R}.$$

Por outro lado,

$$\frac{p_\theta(y)}{p_\theta(x)} = h(x, y), \quad \forall \theta \in \mathbb{R} \Rightarrow \underline{\pi(\eta + u_i) = \pi(\eta + v_i)}, \quad \forall \eta \geq 0$$

(igualdade de 2 polinômios de grau n em η)

$\Rightarrow (u_1, \dots, u_n)$ deve ser uma permutação de (v_1, \dots, v_n)
 (os 2 polinômios têm as mesmas raízes).

$$\Rightarrow (x_{(1)}, \dots, x_{(n)}) = (y_{(1)}, \dots, y_{(n)}) \Rightarrow \tau(x) = \tau(y).$$

$$\therefore \tau(x) = \tau(y) \Leftrightarrow y \in D(x) = \{y \in \mathbb{R}^n : p_\theta(y) = p_\theta(x) \quad \forall \theta \in \mathbb{R}\},$$

onde $h(x, y) = \exp\{\sum x_i - \sum y_i\}$.

Conclui-se que o vetor de estatísticas de ordem é suficiente minimal.

Alunos: usar esta ideia para Cauchy e Exponencial Dupla. (família de locação).

Porque (X_1, X_2, \dots, X_n) não é?

Ex.7. Família exponencial s-dimensional de postos completos

46

$$p_{\theta}(x, \eta) = \exp \left\{ \sum_{i=1}^s \eta_i T_i(x) - A(\eta) \right\} h(x)$$

$\eta \in \Delta$ (não necessariamente o espaço paramétrico natural).

$$p(y, \eta) = p(x, \eta) \exp \left\{ \sum_{i=1}^s \eta_i (T_i(y) - T_i(x)) \right\} h(x, y),$$

$$\forall \eta \in \Delta, \quad h(x, y) = \frac{h(y)}{h(x)}.$$

$$D(x) = \{ y \in \mathbb{X} : p(y, \eta) = p(x, \eta) h(x, y), \forall \eta \in \Delta \}$$

$$\Rightarrow T(x) = (T_1(x), \dots, T_s(x))$$

$$T(x) = T(y) \Rightarrow y \in D(x)$$

$$y \in D(x) \Rightarrow \sum_{i=1}^s \eta_i (T_i(y) - T_i(x)) = 0, \forall \eta \in \Delta$$

posto completo

$$\Rightarrow T_i(x) = T_i(y), i=1, \dots, s \Rightarrow T(x) = T(y).$$

Logo, $T = (T_1(x), \dots, T_s(x))$ é uma estatística suficiente minimal.

Ex.8. Família exponencial curvada (Exercício) 46

Igual ao ex anterior, mas aqui a família não é de posto completo necessariamente.

Assumimos que o espaço paramétrico contém $s+1$ pontos $\eta^{(j)}, j=0, 1, \dots, s$, que geram \mathbb{R}^s .

Mostrar que $T = (T_1(x), \dots, T_s(x))$ é uma estatística suficiente minimal.

Ex.9. Família normal curvada

x_1, \dots, x_n iid, $x_i \sim N(\xi, \xi^2)$, $\xi > 0$.

$(\sum x_i, \sum x_i^2)$ é est. suficiente.

E' também suficiente minimal pelo Ex.8.

De fato, como $\eta = \left(\frac{1}{\xi}, -\frac{1}{2\xi^2} \right)$ (ver p.22),

podemos escolher

$$\eta^{(0)} = (1, -1/2), \quad \eta^{(1)} = (1/2, -1/8) \in \eta^{(2)} = (1/3, -1/18)$$

e temos que os vetores $\eta^{(1)} - \eta^{(0)}$ e $\eta^{(2)} - \eta^{(0)}$ são L.I.. Note que a matriz

$$\begin{pmatrix} 1/2 - 1 & 1/3 - 1 \\ -\frac{1}{8} + \frac{1}{2} & -\frac{1}{18} + \frac{1}{2} \end{pmatrix}$$

é inversível (tem posto igual a 2).

ANCILIARIDADE

Uma estatística $v(x)$ é dita ser ancilar para a família $P = \{P_\theta, \theta \in \Omega\}$ de possíveis distribuições para X se sua distribuição não depende de θ . É dita ser ancilar de primeira ordem se $E_\theta[v(X)]$ não depende de θ .

Idéia: Uma estatística ancilar não contém informação sobre θ .

Nota: Estatísticas suficientes mínimas podem conter algum "material ancilar". Por exemplo, no Ex 6 (Logística $L(\theta, 1)$), mostramos que $(x_{(1)}, \dots, x_{(n)})$ é suficiente minimal, mas as diferenças $x_{(n)} - x_{(i)}$, $i = 1, \dots, n-1$ são ancilares (mostrar).

Ex 1. (cont) . x_1, \dots, x_n iid, $x_i \sim N(\theta, 1)$

$$\sum (x_i - \bar{x})^2 \sim \chi^2_{n-1} \quad (\text{é estatística ancilar})$$

Idem c/ $x_i \sim N(\theta, \sigma^2)$, $\sigma^2 > 0$ fixado

$$\frac{\sum (x_i - \bar{x})^2}{\sigma^2} \sim \chi^2_{n-1} \quad (\text{é est. ancilar})$$

$\sum \frac{(x_i - \bar{x})^2}{n-1}$ é est. ancilar.

(variancia amostral)

OBSERVAÇÕES SOBRE ANCILIARIDADE

1. O que chamamos aqui de "estatística ancilar" é chamado por alguns autores de "estatística de distribuição constante" (distribution constant statistic).

Ex:

Pace, L. & Salvan, A. (1997). Principles of statistical Inference from a Neo-Fisherian Perspective. World Scientific. Singapore.

Pace & Salvan (Definition 2.6, p. 52):

"Under a parametric model F with minimal sufficient statistic s , a statistic a is called auxiliary if (θ, a) is a one-to-one func of s . If a is auxiliary and distribution constant, a is said to be ancillary.

$\hat{\theta}$: estimador de máxima verossimilhança de θ (veremos de pois).

Comentário: Relevância da estatística anciliar

(Casella & Berger, p. 285)

X_1, X_2 : 2 v.a.'s ind com a mesma distr. de X :

$$P_{\theta}(X=\theta) = P_{\theta}(X=\theta+1) = P_{\theta}(X=\theta+2) = \frac{1}{3};$$

θ inteiro, desconhecido.

$X_{(1)} \leq X_{(2)}$: estatísticas de ordem

$$\left. \begin{array}{l} R = X_{(2)} - X_{(1)} \\ M = \frac{X_{(1)} + X_{(2)}}{2} \end{array} \right\} \text{Note que } (R, M) \text{ é equivalente a } (X_{(1)}, X_{(2)}). \text{ (amarelo)}$$

- (R, M) é estatística suficiente minimal
- R é estatística anciliar
- R sozinho não fornece informação sobre θ , pois sua distribuição não depende de θ .

Suponha que foi observado $(R, M) = (r, m)$ (m inteiro).

Mas considere apenas a observação de M .

Para esse ponto ter probabilidade positiva, θ deve ser igual a m , $m-1$ ou $m-2$.

Note que

$$P(M=m \mid \theta=m-2) = 1/9;$$

$$P(M=m \mid \theta=m-1) = 2/9;$$

$$P(M=m \mid \theta=m) = 1/9.$$

Suponha agora que usamos a informação adicional de que $R=r=2$.

O único valor possível para θ é $m-1$.

[Note que $(R, M) = (2, m) \Rightarrow X_{(1)} = m-1$ e $X_{(2)} = m+1$]

O conhecimento (adicional) de que $R=2$ aumentou a informação sobre θ .

($\theta, \theta+1, \theta+2$)

(

Seria interessante procurar estatísticas suficientes tais que nenhuma função não constante de T fosse anciliar, nem mesmo anciliar da primeira ordem, ou seja, t.q.

$$\text{Se } \underline{E_{\theta}[f(T)] = c, \text{ p/ todos } \theta \in \Omega, \text{ entao}} \\ \underline{f(T) = c. \quad (\text{q.c. G})}.$$

Subtraindo c , esta condição é equivalente à definição de estatística completa.

COMPLETIVIDADE

Uma estatística T é completa se, para qualquer função f de T a valores reais

$$\underline{E_{\theta}[f(T)] = 0, \text{ p/ todos } \theta \in \Omega \Rightarrow f(T) = 0 \text{ (q.c. G)}},$$

onde $\theta = \{P_{\theta}, \theta \in \Omega\}$.

Nota: Se existe uma estatística suficiente minimal, então uma condição necessária para que uma estatística suficiente seja completa é que ela seja suficiente minimal (ver Problema 6.29, p.72; Schervish, Teo. 2.36, p. 94 - Teorema de Bahadur).

Teorema de Basu

Se T é uma estatística suficiente completa para a família $\theta = \{P_{\theta}, \theta \in \Omega\}$, então qualquer estatística anciliar V é independente de T .

Dem. Se V é anciliar,

$$P_A = P(V \in A)$$

e' independente de θ para todo A .

$$\text{Seja } \eta_A(t) = P(V \in A | T=t)$$

(note que $\eta_A(t)$ não depende de θ pois T é suficiente)

Então,

$$\bullet E_{\theta}[\eta_A(T)] = P_A \quad \text{e, como } T \text{ é completa,}$$

$$\eta_A(T) = P_A \quad (\text{q.c. G}).$$

Isto estabelece a independência de T e V .

$$\begin{aligned} * E_{\theta}[\eta_A(T)] &= E_{\theta}[P(V \in A | T=t)] \\ &= E_{\theta}[E[I_A(V) | T]] \\ &= E_{\theta}[I_A(V)] = P(V \in A) = P_A \end{aligned}$$

Teorema. Se X tem distribuição numa família exponencial s -dimensional de posto completo, então $T = (T_1(x), \dots, T_s(x))$ é suficiente completa.

Dem. TSH, Teo 1, Secção 4.3.

Ex 1. $X_i \sim \text{Bernoulli}(p)$, $0 < p < 1$

$$\mathcal{P} = \{ \text{Bernoulli}(p), 0 < p < 1 \}$$

$T(X) = \sum X_i$: estatística suficiente (minimal) completa

Ex 2. $X_i \sim \text{Poisson}(\theta)$, $\theta > 0$

$$\mathcal{P} = \{ \text{Poisson}(\theta), \theta > 0 \}$$

$T(X) = \sum X_i$: est. suf. (minimal) completa

Ex 3. $X_i \sim E(a, b)$, $a \in \mathbb{R}$ fixado, $b > 0$ (Exp. de dois par.)

$$\mathcal{P} = \{ E(a, b), b > 0 \}, a \in \mathbb{R}$$

$$p_{a,b}(x) = \frac{1}{b} \exp\left\{-\frac{(x-a)}{b}\right\}, x > a; b > 0.$$

$T(X) = \sum X_i$: est. suf. (minimal) completa.

"Mostrar que é de posto completo
 $\rightarrow T(X)$ é suf. completa"

5

Ex 4. X_1, \dots, X_n iid, $X_i \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$

$$\mathcal{P} = \{ N(\mu, \sigma^2), \mu \in \mathbb{R}, \sigma^2 > 0 \}$$

(\bar{X}, S^2) é estatística suficiente completa.

$$\bar{X} = \frac{\sum X_i}{n}, S^2 = \frac{\sum (X_i - \bar{X})^2}{n-1}.$$

Ex 5. X_1, \dots, X_n iid, X_i com dist. uniforme discreta

$$x_m \in \{1, 2, \dots, N\}; N \in \{1, 2, \dots\}.$$

Para $x = (x_1, \dots, x_n)$, $x_i \in \{1, 2, \dots\}$, $i=1, \dots, n$:

$$p_N(x) = \frac{1}{N^n} \prod_{i=1}^n I_{\{1, \dots, N\}}(x_{im}).$$

Suficiência segue do C.F.
de $X_{(m)}$

Para $y = 1, 2, \dots, N$:

$$P(X_{(m)} \leq y) = \prod_{i=1}^n P(X_i \leq y) = \left(\frac{y}{N}\right)^n$$

$$\text{e } P_N(X_{(m)} = y) = \left(\frac{y}{N}\right)^n - \left(\frac{y-1}{N}\right)^n = \frac{1}{N^n} [y^n - (y-1)^n].$$

$E_N[f(X_{(m)})] = 0$, para todo $N \in \{1, 2, \dots\} \Rightarrow$

$$\sum_{y=1}^N f(y) [y^n - (y-1)^n] = 0, " " " \Rightarrow$$

$$N=1 \Rightarrow f(1)=0$$

$$N=2 \Rightarrow f(1) + f(2)(2^n - 1) = 0$$

$$N=3 \Rightarrow f(1) + f(2)(2^n - 1) + f(3)(3^n - 2^n) = 0 \Rightarrow$$

$$\Rightarrow f(y) = 0, \text{ p/ } y = 1, 2, \dots$$

$X_{(m)}$ é uma est. suficiente completa

Ex6. Suf. minimal, mas não completa
 x_1, \dots, x_n iid, $x_i \sim U(\theta - 1/2, \theta + 1/2)$, $\theta \in \mathbb{R}$.

$T = (x_{(1)}, x_{(n)})$ é suficiente minimal (mostrar)

T não é completa pois

$$E_\theta [x_{(n)} - x_{(1)} - \frac{(n-1)}{(n+1)}] = 0 \text{ para todos } \theta \in \mathbb{R}.$$

~~1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80 81 82 83 84 85 86 87 88 89 90 91 92 93 94 95 96 97 98 99 100~~

Ex7. Suf. minimal, mas não completa
 x_1, \dots, x_n iid, $x_i \sim N(\mu, \mu^2)$, $\mu > 0$.

Mostrar que $T = (\sum x_i, \sum x_i^2)$ é suficiente minimal, mas não é completa.

Ex8. x_1, \dots, x_n iid, $x_i \sim U(0, \theta)$, $\theta > 0$
 $\mathcal{P} = \{U(0, \theta), \theta > 0\}$

$T = \underline{x}_{(n)}$ é estat. suficiente (pelo CF).

T é completa?

$$P_\theta (T \leq t) = \frac{t^n}{\theta^n}, \quad 0 < t < \theta;$$

$$P_\theta (t) = \frac{n t^{n-1}}{\theta^n}, \quad 0 < t < \theta$$

$$\begin{aligned} E_\theta [f(T)] &= 0, \forall \theta > 0 \Rightarrow \int_0^\theta f(t) t^{n-1} dt = 0, \forall \theta > 0 \\ &\Rightarrow \int_A f(t) t^{n-1} dt = 0, \forall A \text{ Boreliano de } \mathbb{R}_+, \\ &\Rightarrow f(t) t^{n-1} = 0 \text{ qc (segundo a medida de Lebesgue)} \\ &\Rightarrow f(t) = 0 \text{ qc} \Rightarrow x_{(n)} \text{ é completa.} \end{aligned}$$

Ex9. y_1, \dots, y_n iid; $y_i \sim E(\eta, 1)$

$$\mathcal{P} = \{E(\eta, 1); \eta \in \mathbb{R}\}$$

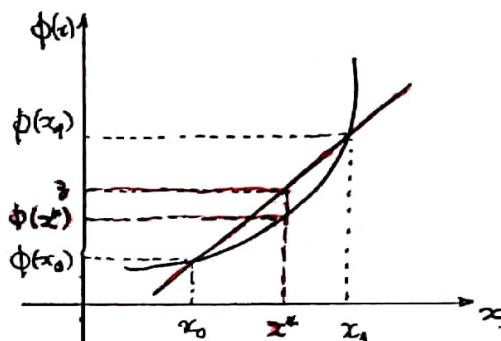
Se $x_i = e^{-y_i}$ e $\theta = e^{-\eta}$, então x_1, \dots, x_n são iid, $x_i \sim U(0, \theta)$. (mostrar). Pelo ex acima $x_{(n)}$ é suficiente completa. Mas $x_{(n)}$ é equivalente a $y_{(1)}$. Então, $y_{(1)}$ é suficiente completa.

FUNÇÕES DE PERDA CONVEXAS

Def. Uma função ϕ a valores reais definida sobre um intervalo aberto $I = (a, b)$ com $-\infty \leq a < b \leq +\infty$ é convexa se para quaisquer $a < x < y < b$ e qualquer $0 < \gamma < 1$

$$\underline{\underline{\phi(\gamma x + (1-\gamma)y) \leq \gamma \phi(x) + (1-\gamma)\phi(y)}}.$$

A função ϕ é dita ser estritamente convexa se a desigualdade acima é estrita. A função ϕ é côncava sobre (a, b) se $-\phi$ é convexa.



OBS: se ϕ é convexa sobre (a, b) , então é contínua em (a, b) .

Teorema

(i) Se ϕ é definida e diferenciável sobre (a, b) então uma condição necessária e suficiente para ϕ ser convexa é que

$\text{(*) } \underline{\underline{\phi'(x) \leq \phi'(y)}}, \text{ para todo } a < x < y < b$

estritamente convexa: (\leq no lugar de \leq).

(ii) Se, adicionalmente, ϕ é duplamente diferenciável, então, a condição (*) é equivalente a $\underline{\underline{\phi''(x) \geq 0}}, \text{ para todo } a < x < b$, com desigualdade estrita sendo condição suficiente (mas não necessária) para convexidade estrita.

Obs. Em geral, uma função convexa é estritamente convexa a menos que seja linear num subconjunto de (a, b) .

Exemplos: As seguintes funções são convexas (mostrar). Quais são estritamente convexas?

$\phi(x) = |x|, \quad x \in \mathbb{R} \rightarrow \dots \dots \text{ do valor absoluto}$

$\rightarrow \phi(x) = x^2, \quad x \in \mathbb{R} \rightarrow \text{var me levar à perda quadrática}$

$\phi(x) = x^p, \quad x > 0 \quad (p \geq 1)$

$\phi(x) = \frac{1}{x^p}, \quad x > 0 \quad (p > 0)$

$\phi(x) = e^x, \quad x \in \mathbb{R}$

$\phi(x) = -\log x, \quad x \in \mathbb{R}^+$

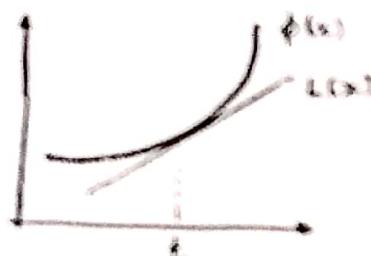
Nota: Propriedades interessantes de estimadores são obtidas desde que a função de perda considerada seja (estritamente) convexa.

Teorema. Seja ϕ uma função convexa definida sobre $I = (a, b)$ e seja t um ponto em I . Então, existe uma única reta

$$j = L(x) = c(x-t) + \phi(t)$$

que passa no ponto $(t, \phi(t))$ tal que
 $L(x) \leq \phi(x)$, para todo $x \in I$.

Se ϕ é estritamente convexa $L(x) < \phi(x)$, exceto em $x=t$.



Teorema. Desigualdade de Jensen

Se ϕ é uma função convexa definida sobre um intervalo aberto I e X é uma r.v. com $P(X \in I) = 1$ e tem esperança finita, então

$$\phi(E(X)) \leq E[\phi(X)].$$

Se ϕ é estritamente convexa a desigualdade é estrita a menos que X seja uma constante com probabilidade 1.

Dem. Usaremos a propriedade: $\forall x \in I$ vale

- $\forall y \in I$ s.t. $y = t \Rightarrow E(Y) \geq E(X)$ desde que os esperanças existem.
- $X \geq 0$ s.t. $E(X) = 0 \Rightarrow X = 0$ s.c.

Suje $y = L(x) = c(x-t) + \phi(t)$, sendo $t = E(X)$ que assumimos ser finita. Note que $E[L(X)]$ é finita.

Por (i), se $E[X(t)]$ é finita:

$$\begin{aligned} E[\phi(X)] &\geq E[L(X)] = L[E(X)] = L(t) \\ &= \phi(t) = \phi(E(X)). \end{aligned}$$

Note que a desigualdade também vale se $E[X(t)] = +\infty$.

Suponha agora que ϕ é estritamente convexa.

Por • temos

$$E[\phi(x) - L(x)] \geq 0.$$

Por (ii),

$$E[\phi(x) - L(x)] = 0 \Rightarrow \phi(x) = L(x) \text{ a.c. } (**)$$

Como ϕ é estritamente convexa, temos que $\phi(x) > L(x)$ exceto em $x=t$ e $\phi(t) = L(t)$.

Assim, $(**)$ implica que $x=t=E(x)$ com probabilidade 1.

Conclui-se que se ϕ é estritamente convexa

$$E[\phi(x)] > E[L(x)] = \phi[E(x)] \quad (\text{ver } *).$$

a menos que $x=t$ com probabilidade 1.

$$\bullet E(\eta(T)) = E[E(\delta(x)|T)] = E[\delta(x)]$$

Teorema de Rao-Blackwell

Seja X uma v.a. observável com distribuição $P_\theta \in \mathcal{P} = \{P_\theta, \theta' \in \Omega\}$ e seja T uma

estatística suficiente para \mathcal{P} . Seja δ um estimador de um estimando $g(\theta)$ e seja $L(\theta, d)$ uma função de perda estritamente convexa de d . Então, se δ tem média finita e risco

$$R(\theta, \delta) = E[L(\theta, \delta(x))] < \infty$$

$$\text{e se } \eta(t) = E[\delta(x) | T=t],$$

então o risco do estimador $\eta(T)$ satisfaz

$$R(\theta, \eta) \leq R(\theta, \delta)$$

a menos que $\delta(x) = \eta(T)$ com probab. 1.

Dem.: Seja $\phi(d) = L(\theta, d)$ estritamente convexa; sejam $\delta = \delta(x) \in X$ uma v.a.

Pela desigualdade de Jensen

$$L(\theta, \eta(t)) \leq E\{L(\theta, \delta(x)) | T=t\}$$

a menos que $\delta(x) = \eta(T)$ com probabilidade 1. Tomando esperança em ambos os lados vem

$$R(\theta, \eta) \leq R(\theta, \delta)$$

a menos que $\delta(x) = \eta(T)$ com probabilidade 1. *

Nota: Suficiência de T foi usada para assegurar que $\eta(T)$ não depende de θ (é um estimador de $g(\theta)$).

Note: L convexa mas não estritamente convexa
 $\Rightarrow R(\theta, \eta) \leq R(\theta, \delta)$.
 O estimador η é pelo menos "tão bom quanto" δ .

Note: O teorema sugere que estimadores que não sejam funções de estatísticas suficientes não devem ser usados.

PERDA QUADRÁTICA. $L(\theta, d) = (d - g(\theta))^2$
 (estritamente convexa). $\Rightarrow g''(d) = (2(d - \theta))' = 2 > 0$

Seja δ um estimador não viciado de $g(\theta)$, isto é:
 $E_\theta[\delta(x)] = g(\theta)$, $\forall \theta \in \Omega$, de forma

$$\eta(t) = E[\delta(x) | T=t],$$

com T sendo uma estatística suficiente.

Aqui,

$$R(\theta, \delta) = E_\theta[(\delta(x) - g(\theta))^2]$$

$$= \text{Var}_\theta[\delta(x)] + \underbrace{\{E_\theta[\delta(x)] - g(\theta)\}^2}_{\text{vies}} = \text{Var}_\theta[\delta(x)]$$

Se $\text{Var}_\theta[\delta(x)] < 0$,

$$\text{Var}_\theta(\eta(T)) < \text{Var}_\theta(\delta(x)),$$

a menos que $\delta(x) = \eta(T)$ com prob. 1.

ADMISSIBILIDADE

Um estimador é dito ser inadmissível se existe outro estimador δ' que o domina, i.e., tal que $R(\theta, \delta') \leq R(\theta, \delta)$ para todo θ , com desigualdade estrita para algum θ e é admissível se tal estimador não existe.

Ex. Estimadores inadmissíveis

$$X_1, \dots, X_n: iid, \quad X_i \sim N(\mu, \sigma^2), \quad \theta = (\mu, \sigma^2)$$

$$\bar{X} = (X_1, \dots, X_n)$$

Estimando: σ^2

$$L(\theta, \delta) = (\delta - \sigma^2)^2$$

$$\delta_1(x) = \frac{1}{n-1} \sum (X_i - \bar{X})^2; \quad \delta_2(x) = \frac{1}{n+1} \sum (X_i - \bar{X})^2.$$

$$\text{Seja } S^2 = \sum (X_i - \bar{X})^2 / \sigma^2 \sim \chi^2_{n-1}.$$

$$R(\theta, \delta_1) = E[(\delta_1(x) - \sigma^2)^2] = E\left[\left[\frac{\sigma^2 S^2}{n-1} - \sigma^2\right]^2\right]$$

$$= \frac{\sigma^4}{(n-1)^2} E\left[\left[S^2 - E(S^2)\right]^2\right] = \frac{\sigma^4}{(n-1)^2} \text{Var}(S^2)$$

$$= \frac{\sigma^4}{(n-1)^2} 2(n-1) = \frac{2\sigma^4}{n-1}.$$

$$R(\theta, \delta_2) = \text{exercício} = \frac{2\sigma^4}{n+1} < R(\theta, \delta_1), \quad \forall \theta$$

viesado

$\therefore \delta_1$ é inadmissível.

Note: Os conceitos e resultados acima podem ser generalizados para o caso em que

$$g(\theta) = [g_1(\theta), \dots, g_k(\theta)]$$

$$\delta(x) = [\delta_1(x), \dots, \delta_k(x)]$$

Ver Def. 7.11, Teo. 7.13, TPE, p. 49.