

31/08

Pasta

5

Nº cópias

5

1

MAE 5834 - Estatística Avançada I

Lista de Exercícios 2 - 2º semestre de 2015 - Prof. Silvia L.P. Ferrari

1. Suponha que $X \sim U(0, \theta)$, $\theta > 0$.(a) Mostre que para que $g(\theta)$ seja estimável é necessário que $\theta g(\theta) \rightarrow 0$ quando $\theta \downarrow 0$ (b) Mostre que, se g é derivável, então $\delta(X) = g(X) + Xg'(X)$ é um estimador não viciado de $g(\theta)$.2. Suponha que X_1, \dots, X_n sejam independentes e tenham distribuição de Poisson de média $\lambda > 0$.Use o Método 1 para encontrar o ENVVUM de $\sum_{i=1}^n X_i$. $N(\lambda, n\lambda)$ (a) λ^k para qualquer inteiro k positivo; $E(S(X)) = g(\lambda) = \lambda^k$ (b) $e^{-\lambda}$. $E(S(X)) = g(\lambda) = e^{-\lambda} \cdot \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-2\lambda}$ 3. Resolva o problema anterior (parte b) pelo Método 2 usando o fato de que um estimador não viciado de $e^{-\lambda}$ é: $\delta = 1$, se $X_1 = 0$, e $\delta = 0$, caso contrário.4. Seja \mathcal{X} o conjunto dos números naturais, i.e. $\mathcal{X} = \{0, 1, 2, 3, \dots\}$, e $A \subset \mathcal{X}$, não vazio. Suponha que X tem distribuição de Poisson de parâmetro λ truncada em A , ou seja, a distribuição de X coincide com a distribuição de Y condicional a que $Y \in A$, sendo que $Y \sim \text{Poisson}(\lambda)$.(a) Suponha que $A = \{0, 1, 2, \dots, a\}$, em que a é um inteiro positivo. Mostre que λ não tem um estimador não viciado.(b) Suponha que $A = \{1, 2, 3, \dots\}$. Encontre o ENVVUM de λ .(c) Suponha que $A = \{1, 2, 3, \dots\}$. Encontre o ENVVUM de $e^{-\lambda}$. Critique o estimador encontrado.5. Considere uma variável aleatória X com função de probabilidade dada por

$$f(x; \theta) = \left(\frac{\theta}{2}\right)^{|x|} (1-\theta)^{(1-|x|)} I_{[-1, 0, 1]}(x), \quad L(\theta; x) = \begin{cases} \frac{1}{2} \theta(1-\theta) & \text{se } x \in \{-1, 0, 1\} \\ 0 & \text{caso contrário} \end{cases}$$

 $\theta \in (0, 1)$. Considere a estatística $T = T(X) = 2I_{\{1\}}(X)$.(a) $|X|$ é uma estatística suficiente e completa? (justifique)(b) T é um estimador não viciado para θ ? (justifique)(c) Encontre, se existir, um estimador não viciado de θ cuja variância seja uniformemente (em θ) menor que a de T .(d) Discuta a estimativa por máxima verossimilhança para θ . Não existe.6. Suponha que $X_1, \dots, X_m, Y_1, \dots, Y_n$ sejam v.a's independentes tais que $X_i \sim N(\zeta, \sigma^2)$, para $i = 1, \dots, m$, e $Y_j \sim N(\eta, \sigma^2)$, para $j = 1, \dots, n$.(a) Mostre que se $n = m = 1$, σ^2 não é estimável.(b) Suponha que $m \geq 2$, $n \geq 2$. Encontre o ENVVUM de σ^r , para $r > -2$.(c) Encontre o ENVVUM de $(\eta - \zeta)/\sigma$.**Nota:** Se $V \sim \chi_n^2$, então $E(V^{r/2}) = 2^{r/2} \Gamma((n+r)/2)/\Gamma(n/2)$, para $n > -r$.7. Se T tem distribuição binomial $b(p, n)$ com $n > 3$, use o Método 1 para encontrar o ENVVUM de p^β .

8. Seja $X = (X_1, \dots, X_n)$ uma amostra aleatória de uma distribuição $N(\theta, 1)$, onde $\theta = 0$ ou 1 . Considere estimadores de θ que assumam apenas os valores 0 e 1 . Mostre que não existe nenhum estimador não viciado de θ .
9. Proposição: Sejam $\mathcal{P} = \{P_\theta, \theta \in \Omega\}$ uma família de distribuições e $\gamma = g(\theta) \in \mathcal{R}$ o estimando. Sempre uma das seguintes afirmações é verdadeira.
- Não existe nenhum estimador não viesado de γ .
 - Existe apenas um estimador não viesado de γ .
 - Existem infinitos estimadores não viesados de γ .
- Demos exemplos em sala de aula dos casos (i.) e (ii.) acima. Complete a demonstração.
10. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $U(-\theta, \theta)$, $\theta > 0$.
- Mostre que a família de distribuições $\mathcal{P} = \{U(-\theta, \theta), \theta > 0\}$ é uma família de escala.
 - Mostre que $T = \max(|X_1|, \dots, |X_n|)$ é uma estatística suficiente minimal para θ .
 - Encontre o estimador não viesado de variância uniformemente mínima de θ .
11. (a) Mostre que se δ é um estimador inadmissível de $g(\theta)$ sob perda quadrática, então $a\delta + b$ é um estimador inadmissível de $ag(\theta) + b$; $a, b \in \mathcal{R}$, $a \neq 0$.
- (b) Mostre que, se δ_i é estimador ENVVUM de $g_i(\theta)$, então $\sum_{i=1}^k c_i \delta_i$ é estimador ENVVUM de $\sum_{i=1}^k c_i g_i(\theta)$, em que c_1, \dots, c_n são constantes quaisquer.
12. Sejam X_1, \dots, X_m e Y_1, \dots, Y_n variáveis aleatórias independentes com distribuições $U(0, \theta)$ e $U(0, \theta')$, respectivamente. Se $n > 1$, determine o ENVVUM de θ/θ' .
13. Prove ou dê contra-exemplo. Seja X variável aleatória com distribuição P_θ pertencente a uma família de distribuições $\mathcal{P} = \{P_\theta, \theta \in \Omega\}$ e sejam $g_1(\theta)$ e $g_2(\theta)$ funções de θ a valores reais. Sejam $\delta_1(X)$ e $\delta_2(X)$ estimadores de $g_1(\theta)$ e $g_2(\theta)$ respectivamente, com $E(\delta_1(X)^2) < \infty$ e $E(\delta_2(X)^2) < \infty$. Se estes estimadores são não viciados de variância uniformemente mínima (ENVVUM) então $a\delta_1(X) + b\delta_2(X)$ tem variância finita e é ENVVUM de $ag_1(\theta) + bg_2(\theta)$. Aqui a e b são números reais fixados.
14. Seja X uma variável aleatória que toma os valores $-1, 0, 1, 2, 3$ com probabilidades $P(X = -1) = 2pq$ e $P(X = k) = p^k q^{3-k}$, para $k = 0, 1, 2, 3$.
- Verifique que esta é uma distribuição de probabilidade.
 - Obtenha o estimador não viciado de variância localmente mínima (ENVVLM) em p_0 de
 - p
 - pq
 e verifique, para cada caso, se o estimador é ENVVUM.
15. Suponha que X_1, \dots, X_n sejam variáveis aleatórias independentes com distribuição $N(\theta_i, 1)$, para $i = 1, \dots, n$. Seja $\omega = n^{-1} \sum_{i=1}^n \theta_i^2$. Obtenha o ENVVUM e o EMV de ω e compare seus erros quadráticos médios.
16. Prove o Teorema 1.11, p. 88, TPE.

17. Seja (X_1, \dots, X_n) uma amostra aleatória de uma distribuição discreta com função de probabilidade $f_{\theta,j}$, em que $\theta > 0$ e $j = 1, 2$; $f_{\theta,1}$ é a distribuição de Poisson de média θ e $f_{\theta,2}$ é a distribuição geométrica de parâmetro $\theta/(1+\theta)$, isto é,

$$f_{\theta,2}(x) = \left[1 - \frac{\theta}{1+\theta}\right] \left[\frac{\theta}{1+\theta}\right]^x, \quad x = 0, 1, 2, \dots$$

Existe ENVVUM de θ ? Justifique.

18. Sejam X_1, \dots, X_n variáveis aleatórias i.i.d. com função densidade de probabilidade $f_\theta(x) = \theta/x^2$, se $x > \theta$ e $= 0$, se $x < \theta$; $\theta > 0$. Encontre um ENVVUM de $g(\theta)$ assumindo que $g(\theta)/\theta^n \rightarrow 0$ quando $\theta \rightarrow \infty$ e que g é diferenciável.
19. Sejam X_1, \dots, X_n ($n \geq 2$) variáveis aleatórias independentes com distribuição $U(0, \theta)$, $\theta \in \Omega = (0, +\infty)$. Sabemos que $X_{(n)} = \max(X_1, \dots, X_n)$ é uma estatística suficiente completa para θ .
- Suponha que $k > -n$ e encontre o ENVVUM de θ^k
 - Encontre o EMV de θ^k e compare seu erro quadrático médio com a variância do ENVVUM.
 - Encontre o estimador de máxima verossimilhança de θ supondo que o espaço paramétrico é $\Omega_0 = [1, +\infty)$.

20. Sejam X_1, \dots, X_n n observações independentes de X , que tem função de probabilidade

$$f_N(x) = P_N(X = x) = \frac{a(x)}{C(N)}, \quad x = 1, 2, \dots, N,$$

em que N é inteiro positivo desconhecido, $a(x) > 0$, $C(N) = \sum_{x=1}^N a(x)$.

- Mostre que $X_{(n)} = \max(X_1, \dots, X_n)$ é uma estatística suficiente completa.
 - Obtenha o estimador de máxima verossimilhança de N .
21. Se X_1, \dots, X_n são iid com distribuição $N(\zeta, \sigma^2)$, com σ conhecido, encontre o ENVVUM de ζ^2 , ζ^3 e de ζ^4 . Sugestão: Para calcular $E(\bar{X}^k)$, escreva $\bar{X} = Y + \zeta$, onde $Y \sim N(0, \sigma^2/n)$ e expanda $E[(Y + \zeta)^k]$.
22. Resolva o problema anterior admitindo que σ é desconhecido.

23. Dizemos que X tem distribuição exponencial de parâmetros a e b ($a \in \mathbb{R}$, $b > 0$), e escrevemos $X \sim E(a, b)$, se sua função densidade de probabilidade é

$$f(x; a, b) = \frac{1}{b} \exp\left\{-\frac{x-a}{b}\right\} I_{[a, \infty)}(x).$$

Seja (X_1, \dots, X_n) uma amostra aleatória de $X \sim E(\theta, \theta)$ em que $\theta > 0$ é desconhecido.

- Mostrar que a classe de distribuições $\mathcal{P} = \{E(\theta, \theta), \theta > 0\}$ é uma família de escala.
 - Esboce a função de verossimilhança. Encontre o estimador de máxima verossimilhança de θ . Este estimador é admissível sob perda quadrática?
24. Sejam X_1, \dots, X_n n observações independentes de uma distribuição exponencial $E(a, b)$, $a \in (-\infty, 0]$ e $b > 0$ é conhecido.
- Mostre que $X_{(1)} = \min_{i \in \{1, \dots, n\}} X_i$ é uma estatística suficiente, mas não é completa.

Q
D
C
N
X
U
N
exp(1)

- (b) Encontre o ENVVUM de a .
 Sugestão: Considere $g(X_{(1)}) = (cX_{(1)} + d)I_{(-\infty, 0]}(X_{(1)})$, com c e d constantes. Mostre que $g(X_{(1)})$ é não correlacionado com os estimadores não viciados de zero.
25. Seja (X_1, \dots, X_n) uma amostra casual simples de $X \sim E(a, b)$. Mostre que $X_{(1)} = \min_{i \in \{1, \dots, n\}} X_i$ e $\sum[X_i - X_{(1)}]$ são independentes e têm distribuições $E(a, b/n)$ e $b\text{Gama}(n-1, 1)$. Sugestão: Se $a = 0$ e $b = 1$, as variáveis $Y_i = (n-i+1)[X_{(i)} - X_{(i-1)}]$, para $i = 2, \dots, n$, são iid e têm distribuição $E(0, 1)$.
26. Suponha que X_i , para $i = 1, \dots, n$, sejam v.a's com distribuição $N(\alpha + \beta t_i, \sigma^2)$, onde α, β e σ^2 são desconhecidos, e os t 's são constantes conhecidas não todas nulas. Encontre o ENVVUM de α e β .
27. Seja (X_1, \dots, X_n) , $n \geq 2$, uma amostra aleatória de tamanho n de uma distribuição discreta $P_{\theta,j}$, em que $\theta \in (0, 1)$, $j = 1, 2$, sendo $P_{\theta,1}$ a distribuição de Poisson com média θ e $P_{\theta,2}$ a distribuição de Bernoulli de parâmetro θ .
- Mostre que $T = \sum_{i=1}^n X_i$ não é uma estatística suficiente.
 - Encontre um ENVVUM de θ .
28. Sejam Z_1, \dots, Z_n variáveis aleatórias i.i.d. com distribuição exponencial de média θ , i.e. com densidade $\theta^{-1} \exp(-z\theta^{-1})$, $z \geq 0$; $\theta > 0$. Sejam x_1, \dots, x_n constantes positivas. Suponha que Y_1, \dots, Y_n sejam uma amostra observável que segue o modelo
- $$Y_i = \beta x_i + Z_i, \quad i = 1, \dots, n,$$
- em que $\beta > 0$, sendo β e θ desconhecidos.
- Encontre o estimador de máxima verossimilhança $(\hat{\beta}, \hat{\theta})$ de (β, θ) .
 - $\hat{\beta}$ e $\hat{\theta}$ são estimadores não viciados de β e de θ respectivamente?
 - Obtenha a distribuição, a média e a variância do estimador de máxima verossimilhança de β .
29. Suponha que X_1, \dots, X_n sejam v.a's independentes com distribuição $N(\mu, \sigma^2)$.
- Verifique se \bar{X}/S e S , onde $\bar{X} = \sum X_i/n$ e $S^2 = \sum(X_i - \bar{X})^2/(n-1)$, são independentes.
 - Obtenha o ENVVUM de e^μ com σ^2 conhecido. Sugestão: Mostrar que $E(e^{\bar{X}}) = \exp\{\sigma^2/(2n) + \mu\}$ usando a função geradora de momentos de $\bar{X} \sim N(\mu, \sigma^2/n)$ dada por $E(e^{t\bar{X}}) = \exp\{\mu t + t^2\sigma^2/(2n)\}$.
 - Encontre um estimador não viciado de e^{μ} com σ^2 desconhecido. Ele é ENVVUM? Sugestão: Expandir $e^{-\sigma^2/(2n)}$ em série de potências e estimar termo a termo.
30. Seja X uma variável aleatória com função de probabilidade

$$p_\theta(x) = P_\theta(X = x) = \frac{a(x)\theta^x}{C(\theta)}, \quad x = 0, 1, \dots;$$

$\theta > 0$, $a(x) \geq 0$, $\sum_{x=0}^{\infty} a(x)\theta^x = C(\theta) < \infty$ (distribuição de série de potências).

- (a) Mostre que se $a(x) > 0$ para todo $x = 0, 1, \dots$, então θ^r é estimável para qualquer r inteiro positivo e seu estimador não viciado de variância uniformemente mínima baseado

em uma amostra X_1, \dots, X_n de observações independentes da distribuição de X é $\delta(T)$, sendo $T = \sum_{i=1}^n X_i$ e

$$\delta(t) = \begin{cases} 0, & t = 0, \dots, r-1, \\ \frac{A(t-r,n)}{A(t,n)}, & t = r, r+1, \dots \end{cases}$$

onde $A(t, n)$ é o coeficiente de θ^t na expansão em série de $[C(\theta)]^n$.

- (b) Se X_1, \dots, X_n são observações independentes da distribuição de Poisson de média θ , $\theta > 0$, utilize o resultado em (b) para encontrar o ENVVUM de θ^r , r inteiro positivo.
- (c) Mostre que a distribuição de Poisson truncada à direita em b ($b \geq 1$, inteiro) e parâmetro θ é um caso especial da distribuição de série de potências. (Se X tem distribuição de Poisson truncada à direita em b e parâmetro θ , então $P_\theta(X = x) = P_\theta(Y = x | Y \leq b)$, $x = 0, 1, \dots, b$, onde Y tem distribuição de Poisson de parâmetro θ .)
- (d) Mostre que se X é uma única observação de uma distribuição de Poisson truncada à direita em b ($b \geq 1$, inteiro), então θ não é estimável (equivalente ao Exercício 4). Esta afirmação contradiz à do item (b)? Por que?

MAE 5834 - Estatística Avançada I

Lista de Exercícios 3 – 2º semestre de 2015 – Prof. Sílvia L.P. Ferrari

1. Considere a distribuição exponencial de média θ e fdp $f(x; \lambda) = (1/\lambda) \exp(-x/\lambda)$, para $x > 0$ e $=0$, caso contrário. Encontre uma função de θ que define uma nova parametrização $\theta = h(\lambda)$ de tal forma que a informação de Fisher seja constante.
2. Seja X uma variável aleatória com função de probabilidade

$$f_\theta(x) = P_\theta(X = x) = \frac{a(x)\theta^x}{C(\theta)}, \quad x = 0, 1, \dots; \quad (1)$$

$a(x) \geq 0$ e $\theta \in \Omega \subset \mathbb{R}^+$; $C(\theta) = \sum_{x=0}^{\infty} a(x)\theta^x < \infty$ (distribuição de série de potências). Considere uma amostra de uma única observação de X . Obs.: Quando necessário você pode fazer alguma suposição sobre o espaço paramétrico.

- (a) Obtenha o limite inferior de Cramér-Rao para a variância de estimadores não viciados de θ^r , r inteiro positivo.
- (b) Mostre que se $a(x) > 0$ para todo $x = 0, 1, \dots$, então θ^r é estimável para qualquer r inteiro positivo e seu estimador não viciado de variância uniformemente mínima (ENVVUM) é

$$\delta_r(X) = \begin{cases} 0, & X = 0, \dots, r-1, \\ \frac{a(X-r)}{a(X)}, & X = r, r+1, \dots \end{cases}$$

- (c) Dizemos que X tem distribuição binomial negativa com parâmetros p e m ($0 < p < 1$, m inteiro positivo) se sua função de probabilidade é

$$P_{p,m}(X = x) = \binom{m+x-1}{m-1} p^m (1-p)^x, \quad x = 0, 1, \dots$$

e escrevemos $X \sim BN(p, m)$. Admitindo que m é conhecido, obtenha o ENVVUM de p baseado em uma única observação de $X \sim BN(\theta, m)$ usando (b).

- (d) Considere agora uma amostra X_1, \dots, X_n de observações independentes da distribuição (1). Mostre que se $a(x) > 0$ para todo $x = 0, 1, \dots$, então θ^r é estimável para qualquer r inteiro positivo e encontre seu ENVVUM.
3. Sejam X_1, \dots, X_n observações independentes de uma distribuição geométrica de parâmetro θ ($0 < \theta < 1$) com função de probabilidade

$$P_\theta(X = x) = \theta(1-\theta)^x, \quad x = 0, 1, 2, \dots;$$

$$E_\theta(X) = (1-\theta)/\theta \text{ e } \text{var}_\theta(X) = (1-\theta)/\theta^2.$$

Encontre o limite inferior de Cramér-Rao (LICR) para variância de estimadores não viesados de $E_\theta(X)$ e mostre que coincide com a variância de $\bar{X} = \sum_{i=1}^n X_i/n$.

4. Seja X uma variável aleatória com distribuição geométrica e função de probabilidade $P_\theta(X = x) = \theta(1-\theta)^x$, $x = 0, 1, \dots$. Qual é a menor variância possível para um estimador não viciado de θ ? Compare essa variância com o limite inferior de Cramér-Rao.
5. Sejam X_1, \dots, X_n variáveis aleatórias independentes e identicamente distribuídas de acordo com uma distribuição de Pareto $P(a, c)$ com densidade

$$f(x) = \frac{ac^a}{x^{a+1}}, \quad 0 < c \leq x, \quad a > 0.$$

$$E_\theta \left(-\frac{\partial^2}{\partial \theta^2} \log P_\theta(x) \right) = \frac{n}{\theta^2(1-\theta)}$$

Pasta 05
Nº cópias 05

.../...

- (a) Encontre o estimador de máxima verossimilhança (EMV) para c quando a é conhecido e o de a quando c é conhecido.
- (b) Encontre o EMV (\hat{a}, \hat{c}) para (a, c) quando a e c são desconhecidos.
- (c) Mostre que \hat{a} e \hat{c} são independentes, $\hat{c} \sim P(na, c)$ e $2na/\hat{a} \sim \chi^2_{2(n-1)}$.
Sugestão: Mostre que se $X_i \sim P(a, c)$, então, $V_i = a(\log X_i - \log c) \sim E(0, 1)$. Considere as variáveis aleatórias $(n-i+1)[V_{(i)} - V_{(i-1)}]$, para $i = 2, \dots, n$.
- (d) Encontre o viés de \hat{c} . Comente.
6. Suponha que X_1, \dots, X_n sejam variáveis aleatórias iid com distribuição $U(0, \theta)$, $\theta > 0$.
- (a) Mostre que
- $$\frac{d}{d\theta} \int_0^\theta xf_\theta(x)dx \neq \int_0^\theta x \frac{d}{d\theta} f_\theta(x)dx,$$
- em que f_θ é a densidade de $X_{(n)}$, a maior estatística de ordem.
- (b) Mostre que a desigualdade da informação não vale para o ENVVUM de θ .
7. Suponha que X_1, \dots, X_n sejam variáveis aleatórias iid com distribuição $N(\zeta, 1)$ com $\zeta > 0$. Mostre que a estimativa de máxima verossimilhança de ζ é a média amostral quando esta é positiva e não existe quando é negativa.
8. Seja X variável aleatória tomando os valores 0 e 1 com probabilidades $1-p$ e p respectivamente; $1/3 \leq p \leq 2/3$.
- (a) Encontre o EMV de p .
- (b) Mostre que o erro quadrático médio do EMV é uniformemente maior do que o de $\delta(X) = 1/2$.
9. Suponha que X seja uma variável aleatória com distribuição binomial de parâmetros p e n sendo n um inteiro positivo (fixado) e p um parâmetro desconhecido, $1/3 < p < 2/3$. Discuta o problema de estimação por máxima verossimilhança de p .
10. Seja $\mathbf{X} = (X_1, \dots, X_n)$ amostra aleatória da variável aleatória X que tem função densidade de probabilidade
- $$f(x; a, \theta) = \theta a^\theta x^{-(\theta+1)} I_{(a, \infty)}(x),$$
- em que $a \in (0, 1]$ e $\theta > 0$.
- (a) Supondo a conhecido, encontre a informação de Fisher para θ .
- (b) Mostre que o estimador não viesado de variância uniformemente mínima de a , quando θ é conhecido, é
- $$\hat{a} = I_{(1, +\infty)}(X_{(1)}) + \left(1 - \frac{1}{n\theta}\right) X_{(1)} I_{[0, 1)}(X_{(1)}),$$
- em que $X_{(1)} = \min(X_1, \dots, X_n)$.
Sugestão: Mostre que $X_{(1)}$ é uma estatística suficiente e caracterize a classe de estimadores não viesados do zero, que sejam funções de $X_{(1)}$.
11. Provar a Desigualdade da Informação no caso uniparamétrico (Teorema 5.10, TPE).
12. Mostre que se $E(\delta) = g(\theta)$ e $\text{var}(\delta)$ atinge o limite da desigualdade da informação, então,

$$\delta(x) = g(\theta) \pm \frac{g'(\theta)}{I(\theta)} \frac{\partial}{\partial \theta} \log p_\theta(x).$$

13. Sejam X_1, \dots, X_n variáveis aleatórias independentes com distribuição de Bernoulli com parâmetro $\theta \in (0, 1)$.
- Encontre o ENVVUM de $g(\theta) = P_\theta(X_1 + \dots + X_m = k)$, onde m e k são fixados, $0 < m < n$, $0 \leq k \leq m$.
 - Encontre o limite inferior de Cramér-Rao para a variância de estimadores não viciados de $g(\theta) = P_\theta(X_1 + \dots + X_m = k)$.
14. Seja \mathcal{F} a classe das densidades de parâmetro θ ($\theta > 0$) com média $1/\theta$ e variância $1/\theta^2$ e que satisfazem as condições para a validade da desigualdade da informação.
- Mostre que uma densidade que minimiza a informação de Fisher para θ na classe \mathcal{F} é $f(x; \theta) = \theta e^{-\theta x} I_{(0, \infty)}(x)$. Sugestão: use a desigualdade da informação.
 - Considere a distribuição $N(1/\theta, 1/\theta^2)$ e encontre o LICR (limite inferior de Cramér-Rao para variâncias de estimadores não viciados de $g(\theta)$). Compare-o com o correspondente LICR para a distribuição exponencial.
15. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$.
- Encontre a matriz de informação (total) para (μ, σ^2) . Mostre que os parâmetros μ e σ^2 são globalmente ortogonais no sentido de que os elementos de fora da diagonal principal dessa matriz são nulos.
 - Obtenha a matriz de covariância de (\bar{X}_n, S_n^2) , onde $\bar{X}_n = \sum_{i=1}^n X_i/n$ e $S_n^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2/(n-1)$, e compare com o limite da desigualdade da informação.
16. Considere uma família de escala com densidade $(1/\theta)f(x/\theta)$, $x \in (-\infty, \infty)$; $\theta > 0$.
- Faça suposições adequadas e mostre que a quantidade de informação que uma única observação X contém sobre θ é
- $$\frac{1}{\theta^2} \int \left[\frac{x f'(x)}{f(x)} + 1 \right]^2 f(x) dx$$
- e que a informação que X contém sobre $\zeta = \log \theta$ é independente de θ .
- Encontre a informação que X contém sobre θ e $\zeta = \log \theta$ se $f(x) = \exp(-x)$ (distribuição exponencial).
17. Sejam Y_1, \dots, Y_n variáveis aleatórias independentes tais que $Y_i \sim \text{Poisson}(\exp\{\alpha + x_i\beta\})$, $i = 1, \dots, n$, onde $\alpha \in \mathbb{R}$ e $\beta \in \mathbb{R}$ são parâmetros desconhecidos, x_i são constantes conhecidas, não todas nulas e não todas iguais. Obtenha a matriz de informação (total) de Fisher para (α, β) e o limite inferior de Cramér-Rao para estimadores não viciados de α e de β .
18. Seja (X_1, \dots, X_n) uma amostra casual simples de $X \sim \text{Poisson}(\theta)$, $\theta \in [0, +\infty)$.
- Encontre o estimador de máxima verossimilhança de $\exp(-3\theta)$.
 - Faça $n = 1$ na parte (a). Encontre a variância do estimador e compare-a com o limite inferior de Cramér-Rao.
 - Compare o estimador obtido em (b) com o ENVVUM. Qual dos dois você recomenda? Justifique.
19. Seja (X_1, \dots, X_n) uma amostra casual simples de $X \sim N(\zeta, \sigma^2)$. Seja $\theta = (\zeta, \sigma^2)$.

- (a) Mostre que o ENVVUM e o EMV de ζ^2 são, respectivamente, $\delta_{1n} = \bar{X}^2 - S^2/n$ e $\delta_{2n} = \bar{X}^2$, onde $\bar{X} = n^{-1} \sum_{i=1}^n X_i$ e $S^2 = (n-1)^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$.
- (b) Obtenha o viés do EMV e mostre que este pode ser escrito como $B(\theta)/n$, onde $B(\theta)$ não depende de n .
20. Sejam X_1, \dots, X_n variáveis aleatórias iid com densidade na família exponencial unidimensional como definida na Lista 1.
- (a) Mostre que a equação de verossimilhança se reduz a $E_\eta[T(X_j)] = n^{-1} \sum_{i=1}^n T(X_i)$.
- (b) Mostre que a equação acima tem, no máximo, uma solução.
21. Seja (X_1, \dots, X_n) uma amostra casual simples de uma distribuição de Weibull com densidade $f(x; \theta) = \theta x^{\theta-1} \exp\{-x^\theta\}$, $x > 0$, $\theta > 0$. Obtenha a equação de verossimilhança e mostre que esta tem uma única solução.
22. Mostre que uma função u satisfaz
- $$u(x_1 + a, \dots, x_n + a) = u(x_1, \dots, x_n), \quad (2)$$
- para todo (x_1, \dots, x_n) e todo a , se e somente se é uma função das diferenças $y_i = x_i - x_n$, para $i = 1, \dots, n-1$, se $n \geq 2$; se $n = 1$, se e somente se é uma constante.
23. Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes cada qual com densidade $f(x - \xi)$, $\xi \in \mathcal{R}$, e $f(x) = \exp\{-(x+1)\}$, $x \geq -1$.
- (a) Encontre o estimador de máxima verossimilhança $\delta(X)$ de ξ e verifique que é equivariante.
- (b) Encontre a distribuição de $n(\delta(X) - \xi)$. Mostre que $\delta(X)$ é um estimador viciado de ξ e obtenha seu risco sob perda quadrática.
- (c) Obtenha o estimador de Pitman de ξ (estimador equivariante de risco mínimo sob perda quadrática). Mostre que é não viciado e calcule seu risco. Mostre que o estimador $\delta(X)$ é inadmissível.
24. Suponha que X e Y são variáveis aleatórias independentes com $X \sim N(\theta, 1)$ e Y com densidade $\exp\{-(y-\theta)\}$, para $y > \theta$ e $= 0$, caso contrário. Determine o estimador equivariante de risco mínimo de θ baseado em (X, Y) sob perda quadrática.
25. Seja $\mathbf{X} = (X_1, \dots, X_n)$ com função densidade de probabilidade
- $$f_{\mathbf{X}}(\mathbf{x}; \tau) = \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \mathbf{x} = (x_1, \dots, x_n) \in \mathcal{R}^n; \quad \tau > 0,$$
- em que f é conhecida e τ é um parâmetro de escala desconhecido. Considere o problema de estimar τ^r , $r \geq 1$, inteiro. Dizemos que um estimador $\delta(\mathbf{X})$, tal que $\delta(\mathbf{x}) > 0$ para todo $\mathbf{x} \in \mathcal{R}^n$, é equivariante por escala se $\delta(b\mathbf{x}) = b^r \delta(\mathbf{x})$, para todo $b > 0$ e todo $\mathbf{x} \in \mathcal{R}^n$. Considere a função de perda $L(\tau, d) = [(d - \tau^r)/\tau^r]^2$.
- (a) Mostre que o risco $R(\tau, \delta(\mathbf{X}))$ de qualquer estimador equivariante por escala $\delta(\mathbf{X})$ é constante.
- (b) Seja $\delta_0(\mathbf{X})$ um estimador equivariante por escala. Mostre que um estimador $\delta(\mathbf{X})$ é equivariante por escala se e somente se $\delta(\mathbf{x}) = \delta_0(\mathbf{x})/v(\mathbf{x})$, em que $v(\mathbf{x})$ é tal que
- $$v(c\mathbf{x}) = v(\mathbf{x}) > 0, \quad \text{para todo } c > 0 \text{ e todo } \mathbf{x} \in \mathcal{R}^n. \quad (3)$$
- Mostre ainda que, se $x_n \neq 0$ e $n > 1$, uma condição necessária e suficiente para que $v(\mathbf{x})$ satisfaça (2) é que exista uma função $w(\mathbf{y})$ tal que $v(\mathbf{x}) = w(\mathbf{y})$ em que $\mathbf{y} = (x_1/|x_n|, \dots, x_n/|x_n|)$.

- (c) Seja $\delta_0(\mathbf{X})$ um estimador equivariante de risco finito. Mostre que o estimador equivariante de risco mínimo de τ^r é dado por

$$\delta^*(\mathbf{X}) = \delta_0(\mathbf{X}) \frac{\mathbb{E}_1[\delta_0(\mathbf{X})|\mathbf{Y}]}{\mathbb{E}_1[\delta_0^2(\mathbf{X})|\mathbf{Y}]},$$

em que $\mathbf{Y} = (X_1/|X_n|, \dots, X_n/|X_n|)$.

- (d) Considere a situação em que (X_1, \dots, X_n) é uma amostra aleatória da distribuição $N(0, \tau^2)$, $\tau > 0$. Encontre o estimador equivariante de risco mínimo de τ^2 . Sugestão: usar o Teorema de Basu.

26. Seja $\mathbf{X} = (X_1, \dots, X_n)$ com função densidade de probabilidade conjunta

$$f_{\mathbf{X}}(\mathbf{x}; \tau) = \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \mathbf{x} = (x_1, \dots, x_n) \in \mathcal{R}^n; \quad \tau > 0,$$

em que f é conhecida e τ é um parâmetro de escala desconhecido. Considere o problema de estimar τ^r , $r \geq 1$, inteiro. Dizemos que um estimador $\delta(\mathbf{X})$ é equivariante por escala se $\delta(b\mathbf{X}) = b^r \delta(\mathbf{X})$, para todo $b > 0$. Pode-se mostrar que o estimador de Pitman de τ^r , dado por $\delta^*(\mathbf{X})$ sendo

$$\delta^*(\mathbf{x}) = \frac{\int_0^\infty v^{n+r-1} f(vx_1, \dots, vx_n) dv}{\int_0^\infty v^{n+2r-1} f(vx_1, \dots, vx_n) dv},$$

é um estimador equivariante por escala de risco mínimo sob perda $[(d - \tau^r)/\tau^r]^2$.

- (a) Mostre que, de fato, o estimador $\delta^*(\mathbf{X})$ é equivariante por escala.
- (b) Obtenha o estimador $\delta^*(\mathbf{X})$ de τ^r para a situação em que \mathbf{X} é uma amostra aleatória da distribuição exponencial de média $\tau > 0$.
- (c) No contexto do item (b), encontre o estimador não viésado de risco mínimo de τ^r considerando a perda dada acima.

MAE 5834 - Estatística Avançada I

Lista de Exercícios 4 – 2º semestre de 2015 – Prof. Silvia L.P. Ferrari

1. Suponha que, dado θ ($\theta > 0$), X_1, \dots, X_n sejam variáveis aleatórias independentes e identicamente distribuídas com distribuição $U(0, \theta)$, $\theta > 0$. Considere uma distribuição a priori Pareto(α, γ) para θ com densidade

$$p(\theta) = \frac{\alpha\gamma^\alpha}{\theta^{\alpha+1}}, \quad 0 < \gamma < \theta, \quad \alpha > 0.$$

Encontre o estimador de Bayes de θ sob perda quadrática.

2. Admita que, dado θ , X_1, \dots, X_n sejam i.i.d. e tenham distribuição de potência com função densidade de probabilidade

$$f(x|\theta) = \theta x^{\theta-1} I_{(0,1)}(x); \quad \theta > 0.$$

Suponha que, a priori, θ tem distribuição exponencial de parâmetro γ e função densidade de probabilidade $p(\theta) = \gamma \exp(-\theta\gamma) I_{(0,+\infty)}(\theta)$, sendo $\gamma > 0$ conhecido. Encontre o estimador de Bayes de θ sob perda quadrática.

- (6) 3. Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes e identicamente distribuídas segundo uma distribuição $N(0, \sigma^2)$. Considere o problema de estimar σ^2 com a função de perda $L(\sigma^2, d) = (d/\sigma^2 - 1)^2 = (d - \sigma^2)^2/\sigma^4$. Considere uma distribuição a priori Gama(a, b) para $\theta = 1/(2\sigma^2)$ com densidade

$$\pi(\theta) = \frac{1}{\Gamma(a)b^a} \theta^{a-1} \exp\left\{-\frac{\theta}{b}\right\}; \quad a > 0, \quad b > 0.$$

Encontre o estimador de Bayes de σ^2 .

4. Seja X uma única observação de uma distribuição $N(\theta, 1)$ e considere a seguinte densidade a priori imprópria para θ : $\pi(\theta) = \exp\{\theta\}$. Considere perda quadrática. Encontre o estimador de Bayes generalizado de θ e mostre que não é nem admissível nem minimax.
5. Prove: Se um estimador equivariante por locação de risco mínimo é admissível, então ele é minimax.
6. Seja X uma única observação de uma distribuição $U(0, \theta)$ e considere a seguinte densidade a priori para θ : $\pi(\theta) = 1/(1 + \theta)^2$, $\theta > 0$.
- Mostre que a densidade marginal de X é $q(x) = \log[(1+x)/x] - 1/(1+x)$, $x > 0$.
 - Mostre que o estimador de Bayes ($\delta(X)$) de θ sob perda $L(\theta, d) = |d - \theta|$ é solução de $q(\delta(X)) = q(X)/2$.
7. Dizemos que X tem distribuição binomial negativa com parâmetros p e m ($0 < p < 1$, m inteiro positivo) se sua função de probabilidade é

$$P_{p,m}(X = x) = \binom{m+x-1}{m-1} p^m (1-p)^x, \quad x = 0, 1, \dots$$

e escrevemos $X \sim BN(p, m)$. Seja (X_1, \dots, X_n) uma amostra aleatória de $X \sim BN(p, m)$ e admita que m é conhecido. Considere uma distribuição a priori Beta(α, β) para p . Encontre o estimador de Bayes de p sob perda quadrática.

- (2) 8. Seja X única observação de uma variável aleatória com densidade $f(x; \theta) = 2x/\theta^2$, $0 < x < \theta$; $\theta > 0$. Considere para θ uma distribuição uniforme no intervalo unitário.
- Obtenha a função densidade de probabilidade a posteriori de θ .
 - Encontre o estimador de Bayes com respeito à perda $\theta^2(d - \theta)^2$.
9. Seja $\tilde{\theta}$ um estimador não viciado de um parâmetro $\theta \in \mathcal{R}$. Seja $R(\theta, \tilde{\theta})$ o risco do estimador $\tilde{\theta}$ de θ .
- Sob perda quadrática, mostre que o estimador $\tilde{\theta} + c$, em que $c \neq 0$ é uma constante conhecida, não é estimador minimax de θ , a menos que $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty$ para todo estimador $\tilde{\theta}$ de θ .
 - Sob perda quadrática, mostre que o estimador $c\tilde{\theta}$, em que $c \in (0, 1)$ é uma constante conhecida, não é estimador minimax de θ , a menos que $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty$ para todo estimador $\tilde{\theta}$ de θ .
 - Considere a função de perda $L(\theta, d) = (d - \theta)^2/\theta^2$, assumindo que $\theta \neq 0$. Mostre que o estimador $\tilde{\theta}$ não é estimador minimax de θ , a menos que $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty$ para todo estimador $\tilde{\theta}$ de θ . Sugestão: Obtenha o risco de $c\tilde{\theta}$ com $c = 1/(1 + \zeta)$, em que $\zeta = \sup_{\theta} R(\theta, \tilde{\theta})$, e compare com o risco de $\tilde{\theta}$.
- (3) 10. Sejam X e Y variáveis aleatórias independentes com distribuições P_{ζ} e Q_{η} respectivamente. Suponha que ζ e η são consideradas variáveis aleatórias independentes, reais, com distribuições Λ e Λ' respectivamente. Se, com perda quadrática, δ_{Λ} é o estimador de Bayes de ζ com base em X e $\delta_{\Lambda'}$ é o estimador de Bayes de η com base em Y ,
- mostre que $\delta_{\Lambda'} - \delta_{\Lambda}$ é o estimador de Bayes de $\eta - \zeta$ com base em (X, Y) .
 - Se $\eta > 0$ e $\delta_{\Lambda'}^*$ é o estimador de Bayes de $1/\eta$ com base em Y , mostre que $\delta_{\Lambda} \cdot \delta_{\Lambda'}^*$ é o estimador de Bayes de ζ/η com base em (X, Y) .
- (4) 11. Seja X uma variável aleatória representando o tempo de vida de um sistema eletrônico, com função distribuição acumulada $F_{\theta}(x)$, $\theta \in \Omega$. Defina a confiabilidade do sistema por

$$R_{\theta}(\tau) = P_{\theta}(X > \tau) = 1 - F_{\theta}(\tau), \quad \tau > 0.$$

Considere n observações independentes X_1, \dots, X_n de X . Admita que, dado θ , X tem distribuição exponencial de parâmetro θ e função densidade de probabilidade

$$f(x; \theta) = \theta \exp(-\theta x), \quad x > 0; \quad \theta > 0.$$

- Mostre que, neste caso, $R_{\theta}(\tau) = \exp\{-\tau\theta\}$.
- Encontre o estimador de máxima verossimilhança de $R_{\theta}(\tau)$.
- Encontre o ENVVUM de $R_{\theta}(\tau)$.
- Mostre que o estimador de Bayes de $R_{\theta}(\tau)$ sob perda quadrática e função densidade a priori para θ

$$\pi(\theta) = \frac{1}{\gamma^{\nu}\Gamma(\nu)}\theta^{\nu-1} \exp(-\theta/\gamma), \quad \theta > 0,$$

é dado por

$$\left(1 + \frac{\tau}{\sum_{i=1}^n X_i + 1/\gamma}\right)^{-(n+\nu)}.$$

- (8) 12. Suponha que X tenha distribuição binomial $b(\theta, n)$. Considere uma distribuição a priori Beta(a, b) com $a = b = 0$ (priori imprópria) e a perda quadrática. Considere estimadores δ que satisfazem $\delta(0) = 0$ e $\delta(n) = 1$. Mostre que o risco a posteriori é minimizado em $\delta(x) = x/n$. [Ver Exemplo 2.8, p. 238-239, TPE].
- (9) 13. Suponha que, dados θ e σ^2 , X_1, \dots, X_n sejam variáveis aleatórias independentes com distribuição $N(\theta, \sigma^2)$. Admita que, a priori, $\tau = 1/(2\sigma^2)$ tem distribuição Gama($g, 1/\alpha$) e θ , independente de τ , tem distribuição uniforme (imprópria) na reta.
- Mostre que a densidade conjunta a posteriori é proporcional a $\tau^{r+g-1} e^{-\tau[\alpha+z+n(\bar{x}-\theta)^2]}$ onde $z = \sum(x_i - \bar{x})^2$ e $r = n/2$.
 - Mostre que distribuição a posteriori de τ é Gama($r + g - 1/2, 1/(\alpha + z)$).
 - Mostre que se $\alpha = g = 0$, o estimador de Bayes (generalizado) de σ^2 é $Z/(n-3)$ para perda quadrática. Para a perda $(d - \sigma^2)^2/\sigma^4$, este estimador é $Z/(n+1)$.
 - Mostre que a densidade a posteriori de θ é simétrica em relação a \bar{X} e que o estimador de Bayes (generalizado) é \bar{X} .
- (11) 14. Suponha que X tem distribuição $b(p, n)$ e considere o problema de estimar p com perda $(d - p)^2/[(p(1-p))]$. Obtenha o estimador minimax.
15. Seja $\mathbf{X} = (X_1, \dots, X_n)$ um vetor de variáveis aleatórias independentes e identicamente distribuídas com distribuição de Bernoulli(p). Considere o problema de estimar p com perda quadrática. Mostre que $\bar{X} = \sum_{i=1}^n X_i/n$ não é estimador mininax de p comparando seu risco com o do estimador aleatorizado $T(\mathbf{X})$ que é igual a \bar{X} com probabilidade $n/(n+1)$ e $1/2$ com probabilidade $1/(n+1)$.
16. Sejam X_1, \dots, X_m e Y_1, \dots, Y_n amostras aleatórias independentes das distribuições $N(\mu_x, \sigma_x^2)$ e $N(\mu_y, \sigma_y^2)$, respectivamente; aqui $\mu_x \in \mathcal{R}$, $\mu_y \in \mathcal{R}$, $\sigma_x^2 > 0$ e $\sigma_y^2 > 0$. Considere o problema de estimar $\Delta = \mu_y - \mu_x$ sob perda quadrática.
- Mostre que $\bar{Y} - \bar{X}$ é estimador minimax de Δ quando σ_x e σ_y são conhecidos; $\bar{X} = m^{-1} \sum_{i=1}^m X_i$ e $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$.
 - Mostre que $\bar{Y} - \bar{X}$ é estimador minimax de Δ quando $\sigma_x^2 \leq M_x$ e $\sigma_y^2 \leq M_y$, sendo $M_x > 0$ e $M_y > 0$ constantes conhecidas.
- Sugestão:** Use o seguinte resultado: Se, dado ξ , Z_1, \dots, Z_n são independentes e têm distribuição $N(\xi, \sigma^2)$, e se a distribuição a priori para ξ é $N(\zeta, b^2)$, então a distribuição a posteriori de ξ , dado que $Z_1 = z_1, \dots, Z_n = z_n$, é normal de média $(n\bar{z}/\sigma^2 + \zeta/b^2)/(n/\sigma^2 + 1/b^2)$ e variância $(n/\sigma^2 + 1/b^2)^{-1}$, onde $\bar{z} = \sum_{i=1}^n z_i/n$.
17. Prove: Seja δ um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $g(\theta)$ sob perda quadrática. Então, $a\delta + b$ é um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $ag(\theta) + b$. Aqui, a e b são números reais.

MAE 5834 - Estatística Avançada I
Lista de Exercícios 5 – 2º semestre de 2015 – Prof. Silvia Ferrari

1. Seja (X_1, \dots, X_n) uma amostra aleatória de variável aleatória com função densidade de probabilidade

$$f(x; \theta) = \theta^{-c} cx^{c-1} \exp\{-(x/\theta)^c\}, \quad x > 0; \theta > 0, c > 0;$$

em que c é conhecido.

- (a) Obtenha o teste uniformemente mais poderoso de $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$ de nível α .
- (b) Obtenha um limite superior de confiança uniformemente mais acurado para θ com coeficiente de confiança $1 - \alpha$.
- (c) Obtenha o teste da razão de verossimilhanças de $H : \theta = \theta_0$ contra $K' : \theta \neq \theta_0$ de nível α .
- (d) Obtenha uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente minimal e determine um intervalo de confiança para θ com coeficiente de confiança $1 - \alpha$.

2. Sejam X_1, \dots, X_n uma amostra aleatória da densidade

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \theta > 0.$$

- (a) Obtenha um teste UMP de $H_0 : \theta \leq \theta_0$ ($\theta_0 > 0$) versus $H_1 : \theta > \theta_0$ de nível α .
- (b) Obtenha um teste UMP de $H_0 : \theta \geq \theta_0$ ($\theta_0 > 0$) versus $H_1 : \theta < \theta_0$ de nível α .
- (c) Existe teste UMP de $H_0 : \theta = \theta_0$ ($\theta_0 > 0$) versus $H_1 : \theta \neq \theta_0$ de nível α ? Justifique.
- (d) Encontre o teste da razão de verossimilhanças de $H_0 : \theta = \theta_0$ ($\theta_0 > 0$) versus $H_1 : \theta \neq \theta_0$ de nível α .
- (e) Encontre um limite inferior de confiança mais acurado com coeficiente de confiança $1 - \alpha$.
- (f) Encontre um limite superior de confiança mais acurado com coeficiente de confiança $1 - \alpha$.
- (g) Determine uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente minimal e encontre um intervalo de confiança para θ com coeficiente de confiança $1 - \alpha$.
- (h) Suponha que, a priori, θ tem distribuição exponencial de parâmetro γ e função densidade de probabilidade $p(\theta) = \gamma \exp(-\theta\gamma)I_{(0,+\infty)}(\theta)$, sendo $\gamma > 0$ conhecido. Encontre o estimador de Bayes de θ sob perda quadrática.

3. Considere uma família de locação com densidades $f_\theta(x) = g(x - \theta)$. Mostre que se g é duas vezes diferenciável e $d^2 \log g(x)/dx^2 \leq 0$, para todo x , então as densidades têm razão de verossimilhanças monótona em x .

4. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $N(\mu, 1)$. Considere o teste de $H_0 : \mu = 0$ versus $H_1 : \mu > 0$ que rejeita H_0 quando $\bar{X}_n > c$, onde $\bar{X}_n = n^{-1} \sum_{i=1}^n X_i$. Qual deve ser o valor de c e o tamanho da amostra para que o teste tenha nível 0.05 e poder 0.99 quando $\mu = 1$?
5. Sejam X_i variáveis aleatórias independentes com distribuição $N(d_i \theta, 1)$, $d_i \neq 0$, $i = 1, \dots, n$. Encontre um teste UMP de $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$ de nível α .
6. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $U(0, \theta)$.
- (a) Mostre que, para testar $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$, qualquer teste para o qual $E_{\theta_0}(\phi(X)) = \alpha$, $E_\theta(\phi(X)) \leq \alpha$, para $\theta \leq \theta_0$, e $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$, é UMP de nível α . Sugestão: Use o Lema de Neyman Pearson, com $k = (\theta_0/\theta_1)^n$.

- (b) Mostre que, para testar $H : \theta = \theta_0$ contra $K : \theta \neq \theta_0$, o teste $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$ ou $\max(x_1, \dots, x_n) \leq \theta_0 \alpha^{1/n}$ e $\phi(x) = 0$, caso contrário, é UMP.
 Sugestão: Considere separadamente 3 situações: (i) $H : \theta = \theta_0$ contra $K_1 : \theta = \theta_1 > \theta_0$; (ii) $H : \theta = \theta_0$ contra $K_2 : \theta = \theta_1, \theta_0 \alpha^{1/n} < \theta_1 < \theta_0$; (iii) $H : \theta = \theta_0$ contra $K_3 : \theta = \theta_1 \leq \theta_0 \alpha^{1/n}$.

7. Sejam X_1, \dots, X_n variáveis aleatórias independentes e identicamente distribuídas de acordo com uma distribuição de Pareto(β, γ) com densidade

$$f(x) = \frac{\beta \gamma^\beta}{x^{\beta+1}}, \quad 0 < \gamma < x, \quad \beta > 0.$$

Admita que γ é conhecido.

- (a) Mostre que $Q = 2 \sum \beta \log(X_i/\gamma) \sim \chi^2_{2n}$ e é, portanto, uma quantidade pivotal. Construa um intervalo de confiança para β com coeficiente de confiança $1 - \alpha$ baseado em Q .
 (b) Obtenha um limite superior de confiança uniformemente mais acurado para β com coeficiente de confiança $1 - \alpha$.
 (c) Obtenha o teste uniformemente mais poderoso de $H : \beta \leq \beta_0$ contra $H : \beta > \beta_0$ ($\beta_0 > 0$) de nível $\alpha \in (0, 1)$.
 (d) Agora admita γ é desconhecido e β é conhecido. Encontre um teste mais poderoso de $H : \gamma = \gamma_0$ contra $K : \gamma = \gamma_1$, em que $\gamma_1 > \gamma_0$, de nível α .

8. Sejam X_1, \dots, X_n variáveis aleatórias independentes tais que X_i tem distribuição exponencial de média $(\lambda \beta^i)^{-1}$; $\lambda > 0, \beta > 0$. Suponha que β é conhecido.

- (a) Encontre um limite inferior de confiança uniformemente mais acurado para λ com coeficiente de confiança $1 - \alpha$.
 (b) Mostre que $\lambda \sum X_i \beta^i$ é uma quantidade pivotal.
 (c) Construa um intervalo de confiança para λ com coeficiente de confiança γ baseado na quantidade pivotal dada em (b).
 (d) Suponha que, a priori, λ tem distribuição gama de parâmetros $a > 0$ e $b > 0$, e função densidade de probabilidade

$$\pi(\lambda) = \frac{1}{b^a \Gamma(a)} \lambda^{a-1} \exp\left\{-\frac{\lambda}{b}\right\}, \quad \lambda > 0.$$

Encontre o estimador de Bayes de λ sob perda quadrática.

- (e) No contexto do item (b), suponha que a é inteiro ($a \geq 1$) e obtenha um intervalo de credibilidade para λ da forma $(\tilde{\lambda}, +\infty)$ com probabilidade $1 - \alpha$.

9. Sejam X_1, \dots, X_n variáveis aleatórias independentes com distribuição $U(-\theta, \theta)$, $\theta > 0$.

- (a) Considere o teste ϕ tal que $\phi(x_1, \dots, x_n) = 1$, se $\max(|x_1|, \dots, |x_n|) > \theta_0$ e $\phi(x_1, \dots, x_n) = 0$, caso contrário. Mostre que ϕ é uniformemente mais poderoso (UMP) de nível α para testar $H : \theta = \theta_0$ contra $K : \theta > \theta_0$. Este teste é UMP para testar $H^* : \theta \leq \theta_0$ contra $K : \theta > \theta_0$? Justifique.
 (b) Encontre a função de poder do teste ϕ .

10. Considere uma única observação de uma variável aleatória X .

- (a) Use o Lema de Neyman-Pearson para encontrar o teste mais poderoso de nível α de $H : X \sim U(0, 1)$ contra $K : X \sim \text{Beta}(1, b)$, sendo $b > 1$ fixado. Se $\alpha = 0,05$ e se foi observado $x = 0,1$, qual é sua decisão? Qual é o nível descritivo (*p-value*) do teste?

- (b) O teste obtido em (a) é uniformemente mais poderoso de $H : X \sim U(0,1)$ contra $K' : X \sim Beta(1,b)$, $b > 1$? Justifique.
- (c) Existe teste uniformemente mais poderoso de $H : X \sim U(0,1)$, contra $K'' : X \sim Beta(1,b)$, $b \neq 1$? Justifique.
11. Seja X distribuída de acordo com P_θ , $\theta \in \Omega$, e seja T uma estatística suficiente para θ . Mostre que, se $\phi(X)$ é qualquer teste de hipótese sobre θ , então $\psi(T)$ dado por $\psi(t) = E(\phi(X)|T = t)$ é um teste que depende apenas de T e sua função de poder é idêntica à de $\phi(X)$.
12. Sejam X_{i1}, \dots, X_{in_i} observações independentes de distribuições normais de média μ_i e variância σ_i^2 para $i = 1, 2$; $\mu_1, \mu_2 \in \mathbb{R}$, $\sigma_1^2, \sigma_2^2 > 0$.
- Obtenha o teste da razão de verossimilhanças de $H_0 : \mu_1 = \mu_2$ versus $H_1 : \mu_1 \neq \mu_2$ de nível α ($0 < \alpha < 1$) supondo que σ_1^2 e σ_2^2 são conhecidos.
 - Obtenha o teste da razão de verossimilhanças de $H_0 : \sigma_1^2 = \sigma_2^2$ versus $H_1 : \sigma_1^2 \neq \sigma_2^2$ de nível α .
 - Suponha agora que as variâncias são desconhecidas mas iguais (isto é, $\sigma_1^2 = \sigma_2^2 = \sigma^2$) e refaça a parte (a).
13. Sejam X_1, \dots, X_n e Y_1, \dots, Y_n amostras aleatórias de distribuições exponenciais de médias $\mu > 0$ e $\lambda > 0$ respectivamente. Obtenha o teste da razão de verossimilhanças de $H_0 : \mu = \lambda$ versus $H_1 : \mu \neq \lambda$ de nível α ($0 < \alpha < 1$).

$$\lambda - \mu = 0 \quad \hat{\theta} = \frac{\bar{X} - \bar{Y}}{2}$$

Seja $\mathcal{D}_b(X) = \{f_b : f \text{ é uma função p.d. para a v.a. } X\}$

Uma vez que $\mathcal{D}_b(X)$ é família de escala, por definição, \exists v.a. U com

Estatística Avançada I, dada f.d. $F + g$.

$$f_b(x) = F(Ux), \quad x \in \mathbb{R}, \quad b > 0$$

o que garante que

Lista 1, 39 exercícios

1. Se a família de (possíveis) distribuições de uma v.a. X é uma família de escala, mostre que a família de (possíveis) distribuições de $\log X$ é uma família de locações.

Por definição, \exists uma v.a. U com função distribuição F , tal que

$$X = U/b, \quad b > 0,$$

o que garante $P(X \leq x) = F(x/b)$, que para F fixo e $b > 0$ constitui uma família de ~~escalas~~ locações.

Dai,

$$\log X = \log U + \log b \quad \cancel{\log U + \cancel{\log b}}$$

Como $b > 0, +\log b \in \mathbb{R}$, o que faz com que

$$\begin{aligned} P(\log X \leq x) &= P(\log U + \log b \leq x) = \\ &= P(\log U \leq x - \log b) = F_{\log U}(x - \log b) \end{aligned}$$

que por definição, constitui uma família de ~~escalas~~ locações.

2. Segue U uma v.a. pos. e $X = bU^c$, $b > 0$ e $c > 0$.

a) Mostre que isso define uma família de grupo.

Por def., uma "família do grupo" de dist. é uma família obtida submetendo uma v.a. com uma dada dist. a um grupo de transformações.

No nosso caso, a v.a. em questão é dada por U .

Agora, basta mostrar que $X = b^{\frac{1}{c}} w^{\frac{1}{c}}$, $b > 0, c > 0$ é obtida a partir de U por meio de um grupo de transf. Para tal, considere a transformação $w \mapsto b^{\frac{1}{c}} w^{\frac{1}{c}}$.

$$g: \mathbb{R}_+ \rightarrow \mathbb{R}_+, \quad b > 0, c > 0$$

$$w \mapsto g(w) = b^{\frac{1}{c}} w^{\frac{1}{c}}$$

Note que $X = g(U)$. Ademais, a coleção de todos os $g \in \mathcal{J}$ constitui um grupo de transf., já que

$g_1 \in \mathcal{J}, g_2 \in \mathcal{J}$, então

$$g_1 = b_1 w^{\frac{1}{c_1}}, \quad g_2 = b_2 w^{\frac{1}{c_2}} \Rightarrow$$

$$\begin{matrix} \overset{g_1}{\frac{w}{b_1}} \\ \times \\ \overset{g_2}{\frac{w}{b_2}} \end{matrix}$$

$$g_2 \circ g_1 = g_2(b_1 w^{\frac{1}{c_1}}) = b_2(b_1 w^{\frac{1}{c_1}})^{\frac{1}{c_2}}$$

$$= \underbrace{b_2}_{b_3} \underbrace{b_1}_{b_3}^{\frac{1}{c_1}} w^{\frac{1}{c_1 c_2}}.$$

$$= b_3 w^{\frac{1}{c_3}} \in \mathcal{J}$$

Se $g \in \mathcal{J}$, i.e.

$$g = b^{\frac{1}{c}} w^{\frac{1}{c}}, \quad b > 0, c > 0,$$

então

$$g^{-1} = \left(\frac{w}{b} \right)^c = \left(\frac{1}{b} \right)^c w^c = b^{\frac{1}{c}} w^{\frac{c}{c}} = b^{\frac{1}{c}} w^{\frac{1}{c}}, \quad b > 0, c > 0$$

de modo que $g^{-1} \in \mathcal{J}$.

b) Mostre que se $U \sim \exp(1)$, então $X \sim$ Weibull com dens.

$$\frac{1}{b} \left(\frac{w}{b} \right)^{c-1} e^{-\left(\frac{w}{b} \right)^c}, \quad w > 0$$

Se $U \sim \exp(1)$, então $F(w) = 1 - e^{-w}$, $w > 0$.

Assim,

$$\begin{aligned} P(X \leq x) &= P(b U^{1/c} \leq x) = \\ &= P(U^{1/c} \leq x/b) \\ &= P(U \leq (x/b)^c). \end{aligned}$$

Dai,

$$\begin{aligned} f_X(x) &= f_U((x/b)^c) \frac{c}{b} x^{c-1} \\ &= e^{-(x/b)^c} \frac{c}{b} x^{c-1}, \quad b > 0 \text{ e } c > 0. \end{aligned}$$

5. A partir das prop. da fam. exponencial (1) encontre as funções geradoras de momentos e de cumulantes, a média e o segundo, o terceiro e o quarto momento central das seg. distribuições,

• Gamma(a, b) ; • Binomial(p, n) ; Poisson(λ) e Binomial Negativa (p, m).

De antemão, sabemos que cada uma das dadas acima pertencem à fam. exponencial. A fim de tornar a resolução mais completa, vamos encontrar a forma canônica para cada uma delas.

A partir daí, usaremos resultado visto em aula para determinar as funções geradoras de momentos e de cumulantes, possibilitando assim a determinação da média e dos 2º, 3º e 4º mom. centrais.

• Gamma(a, b). Dizemos que $X \sim \text{Gamma}(a, b)$ se

$$f_X(x) = \frac{b^a}{\Gamma(a)} x^{a-1} e^{-bx}, \quad x > 0$$

$$= \frac{1}{\Gamma(a)} \exp \left\{ -bx + a \log x + a \log b - \log \Gamma(a) \right\}$$

Uma vez que estaremos interessados em obter a função geradora e anfóntantes de $T(x) = x$, vamos considerar a fixo.

Nessas condições,

$$f_x(\omega) = \frac{\omega^{a-1}}{\Gamma(a)} e^{-b\omega + a \log b} \mathbb{1}_{\mathbb{R}_+}(x) \quad , \quad b > 0$$

Tomando $h(\omega) = \omega^{a-1} / \Gamma(a)$, $\eta = -b$ e $T(\omega) = \omega$ e $A(\eta) = -a \log(-\eta)$, temos que

$$f_x(\omega) = h(\omega) e^{\eta T(\omega) - A(\eta)}$$

Daí,

$$\begin{aligned} K_x(w) &= A(\eta+w) - A(\eta) \\ &= -a \log(-\eta-w) + a \log(-\eta) \\ &= -a \log(b-w) + a \log(b) \\ &= -a \log \frac{b-w}{b} \\ &= \log \left(\frac{b-w}{b} \right)^a \quad , \quad \frac{b-w}{b} > 0 \Leftrightarrow w < b \end{aligned}$$

e, portanto,

$$M_x(w) = \left(1 - \frac{w}{b} \right)^{-a} = \left(\frac{b}{b-w} \right)^a, \quad w < b$$

$$\text{Média } \frac{d}{dw} M_x(w) \Big|_{w=0} = a \left(\frac{b}{b-w} \right)^{a-1} \left(\frac{1}{(b-w)^2} \right) \Big|_{w=0} = \frac{a}{b^2}$$

Ademais,

$$\frac{d}{dw^2} M_x(w) \Big|_{w=0} = a(a-1) \left(\frac{b}{b-w} \right)^{a-2} \left(\frac{1}{(b-w)^3} \right) + a \left(\frac{b}{b-w} \right)^{a-1} \left(\frac{2(b-w)}{(b-w)^4} \right) \Big|_{w=0}$$

1. Binomial(p, n), n fixo

$$\begin{aligned}
 P(X=x) &= \binom{n}{x} p^x (1-p)^{n-x}, \\
 &= \binom{n}{x} e^{x \log p + (n-x) \log(1-p)} \\
 &= \binom{n}{x} e^{x(\log p - \log(1-p)) + n \log(1-p)} \\
 &= \binom{n}{x} e^{x \frac{\log p}{1-p} + n \log(1-p)}
 \end{aligned}$$

$$\eta = \log p - \log(1-p)$$

$$\frac{-p}{1-p} = e^\eta$$

$$h(x) = \binom{n}{x}, \quad \eta = \log \frac{p}{1-p} \Rightarrow \log \frac{1-p}{p} = -\eta \log(1+e^\eta), \quad T(x) = x$$

$$A(\eta) = n \log(1+e^\eta), \quad \text{segue}$$

$$\begin{aligned}
 p + pe^\eta &= e^\eta \\
 p &= \frac{e^\eta}{1+e^\eta}
 \end{aligned}$$

$$P(X=x) = h(x) e^{T(x)\eta - A(\eta)}$$

$$\kappa_x(w) = A(\eta+w) - A(\eta)$$

$$= -n \log(1+e^{\eta+w}) - n \log(1+e^\eta)$$

$$= -n \log \left(\frac{1+e^{\eta+w}}{1+e^\eta} \right) - \log(p+n)$$

$$= \log \left(\frac{1+e^w e^\eta}{1+e^\eta} \right)^n$$

$$= \log \left(\frac{1+pe^w/(1-p)}{1+p/(1-p)} \right)^n = \log \left(\frac{1-p+pe^w}{(1-p)+p} \right)^n$$

$$= \log (1-p+pe^w)^n, \quad w>0$$

Dar,

$$M_x(w) = (1-p+pe^w)^n, \quad w \in \mathbb{R}$$

7. Poisson

$$f_X(x) = \frac{\lambda^x e^{-\lambda}}{x!}, \lambda > 0$$

$$f_X(x) = \frac{1}{x!} e^{\cancel{x \log \lambda} - \lambda} \quad , \lambda > 0$$

$\eta(x)$

$$\eta = B(\lambda) \Rightarrow A(n) = e^n$$

Dar,

$$\begin{aligned} K_X(w) &= A(\eta+w) - A(\eta) \\ &= e^{\eta+w} - e^\eta \\ &= e^\eta (e^w - 1) \\ &= \lambda (e^w - 1) \end{aligned}$$

$$M_X(w) = e^{K_X(w)} = e^{\lambda(e^w - 1)}$$

• Binomial Negativa (p, m) . m fixo

$$\begin{aligned} P(X=x) &= \binom{m+x-\Delta}{m-\Delta} p^m q^x \\ &= h(x) e^{\cancel{m \log p + x \log(1-p)}} \\ &\quad - m \log(1-e^\lambda) = A(n) \end{aligned}$$

Dar,

$$\begin{aligned} K_X(w) &= A(\eta+w) - A(n) \\ &= -m \log(1-e^{\eta+w}) + m \log(1-e^\eta) \\ &= -m \log \left(\frac{1-e^{\eta+w}}{1-e^\eta} \right) \\ &= \log \left(\frac{1-e^w e^\eta}{1-e^\eta} \right)^{-m} = \log \left(\frac{1-(1-p)e^w}{p} \right)^{-m} \end{aligned}$$

23/08/2010

6. Seja $T(X) = (T_1(X), \dots, T_s(X))'$ e considere a densidade (1).

a) Para $s=1$, mostre que $E_\theta[T(X)] = B'(\theta)$ e var. $[T(X)] = B''(\theta) - \eta''(\theta) [B'(\theta)]^2$

$$-\eta''(\theta) B'(\theta) \\ [\eta'(\theta)]^2$$

$$\therefore p_\theta(x) = \exp \left[\sum_{i=1}^n \eta_i(\theta) T_i(x) - B(\theta) \right] h(x)$$

Para $s=1$,

$$p_\theta(x) = \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x)$$

Como $p_\theta(x)$ é uma densidade, tem-se que:

C
densidade
de probabilidade

$$\exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x) du(x) = 1 \quad x \in \text{espaço amostral}$$

$$\int_{\mathbb{R}} \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x) du(x) = 1$$

$$\int_{\mathbb{R}} \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x) du(x) = 0$$

$$\int_{\mathbb{R}} \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x) \cdot [\eta'(\theta) T(x) - B'(\theta)] du(x) = 0$$

$$\int_{\mathbb{R}} \eta'(\theta) T(x) \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x) du(x) - \int_{\mathbb{R}} B'(\theta) \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x) du(x) = 0$$

$$\eta'(\theta) \int_{\mathbb{R}} T(x) \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x) du(x) = B'(\theta) \int_{\mathbb{R}} \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x) du(x)$$

$E_\theta(T(X))$

$$\eta'(\theta) \cdot E_\theta(T(X)) = B'(\theta) \cdot 1$$

$$E_\theta[T(X)] = \frac{B'(\theta)}{\eta'(\theta)}$$

$$E_{\theta} [T(X)] = \underline{B'(\theta)}$$

$$\eta'(\theta)$$

$$\int_{\mathbb{R}} T(x) \exp [\eta(\theta) T(x) - B(\theta)] h(x) du(x) = \underline{B'(\theta)} \eta'(\theta)$$

$$\frac{\partial}{\partial \theta} \int_{\mathbb{R}} T(x) \exp [\eta(\theta) T(x) - B(\theta)] h(x) du(x) = \frac{\partial}{\partial \theta} \underline{B'(\theta)} \eta'(\theta)$$

$$\int_{\mathbb{R}} \frac{\partial}{\partial \theta} T(x) \exp [\eta(\theta) T(x) - B(\theta)] h(x) du(x) = \underline{B''(\theta)} \eta'^2(\theta) - B'(\theta) \cdot \eta''(\theta)$$

$$\int_{\mathbb{R}} T(x) \exp [\eta(\theta) T(x) - B(\theta)] h(x) \cdot [\eta'(\theta) T(x) - B'(\theta)] du(x) = \underline{B''(\theta)} \eta'^2(\theta) - B'(\theta) \eta''(\theta)$$

$$\eta'(\theta) \int_{\mathbb{R}} [T(x)]^2 \exp [\eta(\theta) T(x) - B(\theta)] h(x) du(x) - B'(\theta) \int_{\mathbb{R}} T(x) \exp [\eta(\theta) T(x) - B(\theta)] h(x) du(x)$$

$$- B''(\theta) \eta'(\theta) - B'(\theta) \eta''(\theta)$$

$$[\eta'(\theta)]^2$$

$$\eta'(\theta) E[T(X)^2] - B'(\theta) E[T(X)] = B''(\theta) \eta'^2(\theta) - B'(\theta) \eta''(\theta)$$

$$[\eta'(\theta)]^2$$

$$\eta'(\theta) E[T(X)^2] - B'(\theta) \cdot B'(\theta) = B''(\theta) \eta'^2(\theta) - B'(\theta) \eta''(\theta)$$

$$[\eta'(\theta)]^2$$

$$E[T(X)^2] = 1 \left[(B'(\theta))^2 + B''(\theta) \eta'^2(\theta) - B'(\theta) \eta''(\theta) \right]$$

$$\eta'(\theta) \left[\eta'(\theta) \cdot (B'(\theta))^2 + B''(\theta) \eta'^2(\theta) - B'(\theta) \eta''(\theta) \right]$$

$$= 1 \left[\eta'(\theta) [B'(\theta)]^2 + B''(\theta) \eta'^2(\theta) - B'(\theta) \eta''(\theta) \right]$$

$$\eta'(\theta) \left[\eta'(\theta) \right]^2$$

$$\text{Var}(T(X)) = E[T(X)^2] - [E[T(X)]]^2 = \eta'(\theta) [B'(\theta)]^2 + B''(\theta) \eta'^2(\theta) - B'(\theta) \eta''(\theta) - [B'(\theta)]^2$$

$$[\eta'(\theta)]^2$$

$$[\eta'(\theta)]^2$$

$$\text{Var}(T(X)) = \underline{B''(\theta)} - \eta''(\theta) \underline{B'(\theta)}$$

$$[\eta'(\theta)]^2 \quad [\eta'(\theta)]^3$$

28 / 08 / 2020

b) Para $\lambda > 1$, note que $E_{\theta} [T(X)] = J^{-1} \nabla B$, onde J é a matriz jacobiana definida por $J = \begin{bmatrix} \frac{\partial \eta_j}{\partial \theta_i} \end{bmatrix}$ e ∇B é o vetor gradiente $\nabla B = \begin{bmatrix} \frac{\partial B(\theta)}{\partial \theta_1} \\ \vdots \\ \frac{\partial B(\theta)}{\partial \theta_n} \end{bmatrix}$

$$\begin{array}{c} F_E [E[T(X)] - E[T(X_0)] \\ = \end{array} \begin{array}{c} T(x_1) \\ \vdots \\ T(x_n) \end{array} - \begin{array}{c} E(T(x_1)) \\ \vdots \\ E(T(x_n)) \end{array} = \begin{array}{c} \frac{B(\theta_1)}{\eta^*(\theta_1)} \\ \vdots \\ \frac{B(\theta_n)}{\eta^*(\theta_n)} \end{array} = \begin{array}{c} \frac{\partial B(\theta_1)}{\partial \theta_1} \cdot \frac{\partial \theta_1}{\partial \eta^*(\theta_1)} \\ \vdots \\ \frac{\partial B(\theta_n)}{\partial \theta_n} \cdot \frac{\partial \theta_n}{\partial \eta^*(\theta_n)} \end{array} =$$

$$\begin{array}{c} \frac{\partial \theta_1}{\partial \eta^*(\theta_1)} \quad 0 \dots 0 \\ 0 \quad \frac{\partial \theta_2}{\partial \eta^*(\theta_2)} \dots 0 \\ \vdots \quad \vdots \\ 0 \quad \frac{\partial \theta_n}{\partial \eta^*(\theta_n)} \quad \frac{\partial B(\theta_2)}{\partial \theta_2} \end{array} \stackrel{S \times S}{=} \stackrel{S \times 1}{J^{-1} \nabla B} \stackrel{M=5}{=} \begin{array}{c} \vdots \\ \vdots \\ \vdots \end{array}$$

$$\theta = (\theta_1, \dots, \theta_S)$$

$$M_x(\omega) = \left(\frac{1 - (1-p)e^{\omega}}{p} \right)^{-m}$$

F. Considere a dist. da série de potências com função de prob.

$$f_\theta(x) = P_\theta(X=x) = \frac{a(x)\theta^x}{C(\theta)}, \quad x=0,1,\dots; \quad a(x) > 0, \quad \theta > 0.$$

a) Mostre que essa dist. faz parte da fam. expon. unidimensional.

$$f_\theta(x) = a(x) e^{x \log \theta - \log C(\theta)}$$

b) Mostre que sua f. geradora é $M_x(\omega) = \cup$

$$\begin{aligned} R_x(\omega) &= A(\eta + \omega) - A(\eta) \\ &= \log C(e^{\eta + \omega}) - \log C(e^\eta) \\ &= \log \frac{C(e^{\eta + \omega})}{C(e^\eta)} \Rightarrow \log \frac{C(e^{\eta + \omega} \cdot \theta)}{C(\theta)} \end{aligned}$$

$$M_x(\omega) = \frac{C(\theta e^\omega)}{C(\theta)} \quad \left(\frac{p}{\theta e^\omega} \right)^n \cdot \frac{\theta^n}{p^n} =$$

c) Binomial $\boxed{\text{f. gen.}}$ $(1+p+pe^\omega)^n \rightarrow \theta = \frac{p}{1-p}, C(\theta) = (p/\theta)^n$

Binomial Negativa

$$\left(\frac{p}{1-qe^\omega} \right)^m \rightarrow$$

Poisson

7 d)

Messas cont.,)

$$M_X(u) = \frac{-\log(1-\theta e^u)}{1-\log(1-\theta)} = \frac{\log(1-\theta e^u)}{\log(1-\theta)}$$

Dati,

$$E(X) = \left. \frac{d}{du} M_X(u) \right|_{u=0} = -\left. \frac{\theta e^u}{(1-\theta e^u) \log(1-\theta)} \right|_{u=0}$$

$$= \frac{\theta}{(1-\theta) \log(1-\theta)}$$

$$E(X^2) = \left. \frac{d^2}{du^2} M_X(u) \right|_{u=0} = \left. \frac{\theta e^u ((1-\theta e^u) \log(1-\theta e^u) + \theta^2 e^{2u} \log(1-\theta))}{(1-\theta e^u)^2 \log(1-\theta)} \right|_{u=0}$$

$$= \frac{-\theta(1-\theta) + \theta^2}{(1-\theta)^2 \log(1-\theta)} =$$

$$= \underbrace{\frac{\theta^2}{(1-\theta)^2 \log(1-\theta)}}_{*} - \frac{\theta}{(1-\theta) \log(1-\theta)}$$

$$\text{Dati, } \text{Var}(X) = E X^2 - (EX)^2 = * - \frac{\theta^2}{(1-\theta)^2 (\log(1-\theta))^2}$$

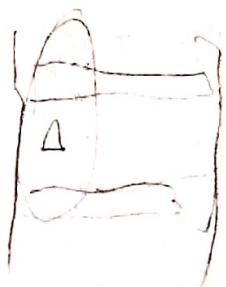
$$= \frac{1}{\log(1-\theta)} \left[\frac{\theta^2}{(1-\theta)^2} \left(1 - \frac{1}{\log(1-\theta)} \right) - \frac{\theta}{(1-\theta)} \right]$$

$$= \frac{\theta}{(1-\theta) \log(1-\theta)} \left[\frac{\theta}{1-\theta} \left(1 - \frac{1}{\log(1-\theta)} \right) - 1 \right]$$

4.

$$\mathcal{X} = \{x_1, \dots, x_n\}$$

$$e^{\left(\log \frac{1}{x}\right)} = e^{\log x^{-1}} = e^{-\log x}$$



$$\exp \left\{ \sum_{i=1}^n \eta_i(\theta) T_i(x) - B(\theta) - \log P_\theta(A) \right\} \cdot \eta_i(\theta) T_i(x)$$

$$P_\theta(A) = \int p_\theta(x) \mathbb{I}_A(x) dx$$

Observar que A é fixo

$$6. X_i \sim \text{Pois}(e^{\alpha + \beta t_i}), t_1, \dots, t_n, \alpha \in \mathbb{R}$$

$$\lambda = (\lambda_1, \dots, \lambda_n) \quad x \in \mathbb{R}^n$$

$$P(x_1, \dots, x_n | \lambda)$$

$$8. P(Y \leq y) = P(c \log X \leq y) = P(X \leq e^{y/c})$$

$$f_Y(y) = f_X(e^{y/c}) \frac{e^{y/c}}{c} \mathbb{I}_{\mathbb{R}_+}(y) \quad \text{Há } e^{y/c} \frac{1}{\beta}$$

$$= \frac{e^{y/c}}{\Gamma(\alpha) \beta^\alpha} e^{(\alpha-1)\frac{y}{c}} e^{-e^{y/c}/\beta} \mathbb{I}_{\mathbb{R}_+}(y) \quad \text{d}Y \stackrel{f_Y(y)}{\sim} e^{-\frac{y}{c}}, \quad c \in \mathbb{R}^*$$

$$= h(x) e^{\left\{ -e^{y/c} \frac{1}{\beta} - \alpha \log \beta \right\}}$$

Há que superar c fixo!

$$\begin{aligned} & \text{C desc.} \quad e^{\left\{ -e^{y/c} \frac{1}{\beta} + (\alpha-1)\frac{y}{c} - \alpha \log \beta \right\}} \\ & = \frac{1}{\Gamma(\alpha)} e^{\left\{ -e^{y/c} \frac{1}{\beta} + (\alpha-1)\frac{y}{c} - \alpha \log \beta \right\}} \end{aligned}$$

$$X = \frac{1}{\pi} \log \left(\frac{Y}{1-Y} \right)$$

$$Y \sim \text{Beta} \left(\frac{1+\theta}{2}, \frac{1-\theta}{2} \right), \quad 1 < \pi$$

$$\frac{d}{dx} P(X \leq x) = P \left(\frac{1}{\pi} \log \left(\frac{Y}{1-Y} \right) \leq x \right) =$$

$$= P \left(\log \left(\frac{Y}{1-Y} \right) \leq \pi x \right)$$

$$= P \left(\frac{Y}{1-Y} \leq e^{\pi x} \right)$$

$$= P \left(\frac{e^w}{1+e^w} \leq e^{\pi x} \right)$$

$$= P(w \leq \pi x)$$

$$= P(Y \leq e^{\pi x}(1-Y))$$

$$= P(Y \leq \frac{e^{\pi x}}{1+e^{\pi x}})$$

$$\log \frac{Y}{1-Y} = w$$

$$\frac{Y}{1-Y} = e^w$$

$$Y = e^w - Y e^w$$

$$Y(1+e^w) = e^w$$

$$= \frac{e^w}{1+e^w}$$

$$f_X(x) = f_Y \left(\frac{e^{\pi x}}{1+e^{\pi x}} \right) \left(\frac{\pi e^{\pi x} (1+e^{\pi x}) - \pi e^{\pi x} e^{\pi x}}{1+e^{\pi x}} \right)$$

Est. Avançada I

13. $\{X_i\}_{i=1}^n$ i.i.d. tais que

$$P(X_i \leq x) = F_{1,\theta}(x) = x^{t_1/\theta}, \quad x \in [0,1], \quad \theta > 0; \quad (1)$$

com t_1, \dots, t_n const. conhecidas. Encontre uma estatística suficiente mínima para θ .

De (1), segue que

$$f_{i,\theta}(x) = \theta t_i x^{\theta t_i - 1}, \quad x \in [0,1], \quad \theta > 0$$

Dai

$$\begin{aligned} p_\theta(x) &= \theta^n \prod_{i=1}^n t_i x_i^{\theta t_i - 1} = \frac{1}{\prod_{i=1}^n x_i} \theta^n \prod_{i=1}^n t_i x_i^{\theta t_i - 1} = \frac{\prod_{i=1}^n t_i}{\prod_{i=1}^n x_i} \theta^n \prod_{i=1}^n x_i^{\theta t_i} \\ &= \frac{\prod_{i=1}^n t_i}{\prod_{i=1}^n x_i} e^{\sum_{i=1}^n \theta t_i \log(x_i) + n \theta} = h(x) e^{\theta \sum_{i=1}^n t_i \log x_i + n \theta} \end{aligned}$$

Pelo critério da fatoração, $T(X) = \sum_{i=1}^n t_i \log(X_i)$ é uma estatística suficiente para θ . Agora, dados x e y em \mathcal{X} , note que

$$\begin{aligned} p_\theta(x) = p_\theta(y) &\Leftrightarrow \frac{\prod_{i=1}^n t_i}{\prod_{i=1}^n x_i} e^{\sum_{i=1}^n \theta t_i \log(x_i)} = \frac{\prod_{i=1}^n t_i}{\prod_{i=1}^n y_i} e^{\sum_{i=1}^n \theta t_i \log(y_i)} \\ &\Leftrightarrow \frac{1}{\prod_{i=1}^n x_i} e^{\sum_{i=1}^n \theta t_i \log(x_i)} = \frac{1}{\prod_{i=1}^n y_i} e^{\sum_{i=1}^n \theta t_i \log(y_i)} \\ &\Leftrightarrow \theta \sum_{i=1}^n t_i \log(x_i) - \sum_{i=1}^n \log(x_i) = \theta \sum_{i=1}^n t_i \log(y_i) - \sum_{i=1}^n \log(y_i) \\ &\Leftrightarrow \sum_{i=1}^n t_i \log(x_i) = \sum_{i=1}^n t_i \log(y_i) \text{ e } \sum_{i=1}^n \log(x_i) = \sum_{i=1}^n \log(y_i) \end{aligned}$$

Dai, $T(X) = \sum_{i=1}^n t_i \log X_i$ é uma estatística suf. mínima para θ .

15. $X \sim N(0, \theta)$; $|X|$ é suficiente para θ ?

A dist. condicional de $X | T=t, t > 0$ é t.q.

$$P(X=t | T=t) = P(X=-t | T=t) = \frac{1}{2}, \text{ pois} \quad (1)$$

Para $t > 0$:

$$\begin{aligned} F_T(t) = P(|X| \leq t) &= P(-t \leq X \leq t) = \Phi\left(\frac{t}{\sqrt{\theta}}\right) - \Phi\left(\frac{-t}{\sqrt{\theta}}\right) \\ \Rightarrow f_T(t) &= \frac{1}{\sqrt{\theta}} \phi\left(\frac{t}{\sqrt{\theta}}\right) + \frac{1}{\sqrt{\theta}} \phi\left(\frac{-t}{\sqrt{\theta}}\right) = \frac{2}{\sqrt{\theta}} \phi\left(\frac{t}{\sqrt{\theta}}\right) \end{aligned}$$

$$\begin{aligned} f_T(t) \cdot P(X=t | T=t) &= \frac{1}{\sqrt{\theta}} \phi\left(\frac{t}{\sqrt{\theta}}\right) \Rightarrow \therefore f_X(t) \in \text{t.q } X \sim N(0, \theta). \\ f_T(t) \cdot P(X=-t | T=t) &= \frac{1}{\sqrt{\theta}} \phi\left(\frac{-t}{\sqrt{\theta}}\right) \end{aligned}$$

Dai, vale (1) e, portanto, da definição de estatística suficiente, segue o resultado.

17. (X_1, \dots, X_n) é suf. minimal p/ a form de locapão

$$p_{\theta}(x) = f(x_1 - \theta) \cdots f(x_n - \theta),$$

podrás

qdo f é a densidade da Cauchy. Diz-se que γ N Cauchy $(\theta, \frac{1}{2})$ se.

$$f_Y(y) = \frac{1}{\pi} \frac{1}{1+y^2} I_R(y).$$

Dai,

$$\begin{aligned} p_{\theta}(x) &= \left(\frac{1}{\pi}\right)^n \frac{1}{1+(x_1 - \theta)^2} \cdots \frac{1}{1+(x_n - \theta)^2} \\ &= \left(\frac{1}{\pi}\right)^n \prod_{i=1}^n \frac{1}{1+(x_i - \theta)^2} = \left(\frac{1}{\pi}\right)^n e^{-\sum_{i=1}^n \log(1+(x_i - \theta)^2)} \end{aligned}$$

Daqui, segue que $X = (X_1, \dots, X_n)$ é suf. p/ θ . Ademais, uma vez

$$\begin{aligned} p_{\theta}(x) = p_{\theta}(y) &\Leftrightarrow \sum \log(1+(x_i - \theta)^2) = \sum \log(1+(y_i - \theta)^2) \\ &\Leftrightarrow x_{(1)} = y_{(1)}, \dots, x_{(n)} = y_{(n)} \end{aligned}$$

segue que $X = (X_1, \dots, X_n)$ é suf. minimal para θ .

19. $X = (X_1, \dots, X_n)$

$$f(x, \theta) = \frac{1}{\theta} e^{-\frac{(x-\theta)}{\theta}} \mathbb{I}_{(0, \infty)}(x)$$

Temos que

$$\begin{aligned} p_\theta(x) &= \left(\frac{1}{\theta}\right)^n e^{\frac{-1}{\theta} \sum x_i + n} \prod_{i=1}^n \mathbb{I}_{(0, \infty)}(x_i) \\ &= e^{-n\theta} e^{-\frac{\sum x_i}{\theta}} e^n \mathbb{I}_{(0, \infty)}(x_{(1)}) \end{aligned}$$

$$\text{pois } \prod \mathbb{I}_{(0, \infty)}(x_i) = \begin{cases} 1 \Leftrightarrow x_i > \theta \forall i \Leftrightarrow x_{(1)} > \theta \Leftrightarrow I_{(0, \infty)}(x_{(1)}) = 1 \\ 0 \Leftrightarrow \text{algum } x_i \leq \theta \Leftrightarrow x_{(1)} \leq \theta \Leftrightarrow I_{(0, \infty)}(x_{(1)}) = 0 \end{cases}$$

Dai, pelo critério da fatoração, segue que

$$T(X) = (\bar{x}, x_{(1)}) \text{ é uma cat. suf. para } \theta.$$

Ademais, para $x \in \mathcal{X}$,

$$\begin{aligned} p_\theta(x) = p_\theta(y) &\Leftrightarrow e^{-n\theta} e^{-\frac{\sum x_i}{\theta}} e^n \mathbb{I}_{(0, \theta)}(x_{(1)}) = e^{-n\theta} e^{-\frac{\sum y_i}{\theta}} e^n \mathbb{I}_{(0, \theta)}(y_{(1)}) \\ &\Leftrightarrow e^{-\frac{n\bar{x}}{\theta}} \mathbb{I}_{(0, \theta)}(x_{(1)}) = e^{-\frac{n\bar{y}}{\theta}} \mathbb{I}_{(0, \theta)}(y_{(1)}) \\ &\Leftrightarrow x_{(1)} - \theta > \bar{x} - \bar{y} \quad \text{e} \\ &\quad (\bar{x}, x_{(1)}) = (\bar{y}, y_{(1)}) \end{aligned}$$

Assim $(\bar{x}, x_{(1)})$ é suficiente minimal.

No entanto não é completo...

21. $\{X_i\}_{i=1}^n$ a.a. de $\mathcal{U}(\theta - 1/2, \theta + 1/2)$, $\theta \in \mathbb{R}$.

a) $(x_{(1)}, x_{(n)})$ suf. mnimal

Note que

$$p_\theta(x) = \prod_{i=1}^n \mathbb{I}_{(\theta-1/2, \theta+1/2)}(x_i) = \begin{cases} 1, & \text{se } \theta - 1/2 < x_{(1)} < x_{(n)} < \theta + 1/2 \\ 0, & \text{c.r.} \end{cases}$$

$$= \prod_{i=1}^n \mathbb{I}_{(\theta-1/2, \theta+1/2)}(x_i) \mathbb{I}_{(x_{(1)}, \theta+1/2)}(x_{(n)})$$

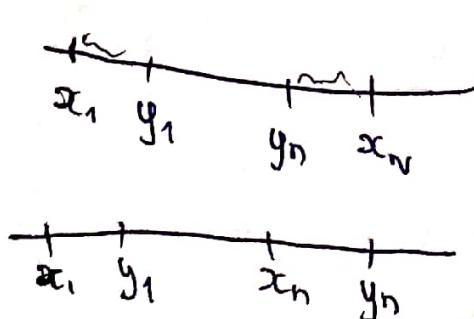
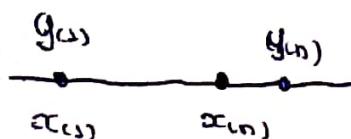
Dar, p.ej. Crit. Fat., $(x_{(1)}, x_{(n)})$ é suficiente. Ademais,

$$p_\theta(x) = p_\theta(y) \Leftrightarrow \prod_{i=1}^n \mathbb{I}_{(\theta-1/2, \theta+1/2)}(x_{(i)}) \mathbb{I}_{(x_{(1)}, \theta+1/2)}(x_{(n)}) \Leftrightarrow$$

$$(x_{(1)}, x_{(n)}) = (y_{(1)}, y_{(n)})$$

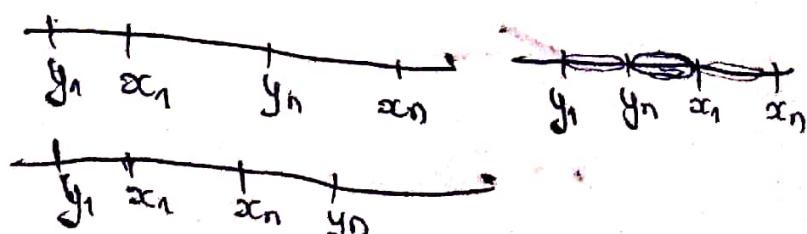
$\Rightarrow T(X) = (x_{(1)}, x_{(n)})$ é suf. mnimal.

b) $(x_{(1)}, x_{(n)})$ não é completa



$$\max \left\{ \max \{x_1, y_1\}, \min \{x_1, y_n\} \right\},$$

$$\min \{x_n, y_n\} \right\}$$



23. $(X_i)_{i=1}^n$, $X_i \sim \text{Poi}(\theta)$

Mostrar que $\bar{X} = \sum X_i / n$ é suficiente e completa sem usar propriedades da fam. exp.

Basta ver que

$$\begin{aligned} P_\theta(x | T(x) = \alpha) &= \frac{P_\theta(x, T(x) = \alpha)}{P_\theta(T(x) = \alpha)} = \frac{P_\theta(x)}{P_\theta(T(x) = \alpha)} = \\ &= \frac{\theta^{\sum x_i} e^{-n\theta}}{\prod x_i!} \cdot \frac{(n\theta)^{\sum x_i}}{(n\theta)^{\sum x_i} e^{n\theta}} = \frac{n^{\sum x_i}}{n^{\sum x_i} \prod x_i!}, \end{aligned}$$

que não depende de θ . Agora, basta mostrar que é completa

25.

a) $\mathcal{P}_0 \in \mathcal{B}$, form. da dist.

$\forall A \in \mathcal{B} \quad \forall f_i \in \mathcal{P}_0 \quad f_i \in \mathcal{P}_0$

$$P(X_1 \in A) = 0 \Rightarrow P(X_2 \in A) = 0, \quad \text{separado}$$

onde $X_i, i=1,2$ são t.q. $P(X_i \leq x_i) = F_i(x)$

$P_0(x | T(x))$ não dep de Θ , p/ todo x com f_x em \mathcal{P}_0 .

9.8

MAE583A - ESTATÍSTICA AVANÇADA I.

Lista de Exercícios 1 - Prof. Silvia Ferrari.

Alunos: Mario José Pacheco López - 9034981

Hugo Alberto Brango García - 9176006

IME-USP , 2º semestre de 2014.

Exercício 5. Considere a distribuição de série de potências com função de probabilidade

$$f_{\theta}(x) = P_{\theta}(X=x) = \frac{a(x)\theta^x}{C(\theta)}, \quad x=0,1,\dots; \quad a(x) \geq 0, \quad \theta > 0$$

(a) Mostre que essa distribuição faz parte da família exponencial unidimensional.

Note que,

$$f_{\theta}(x) = \frac{a(x)\theta^x}{C(\theta)} = a(x)\theta^x [C(\theta)]^{-1} = a(x) \exp\{x \log \theta - \log C(\theta)\}$$

para $x=0,1,\dots$, $a(x) \geq 0$, $\theta > 0$ e $C(\theta) > 0$.

Logo, fazendo $T(x)=x$, $\eta(\theta)=\log \theta$, $B(\theta)=\log C(\theta)$ e $h(x)=a(x)$, temos que $f_{\theta}(x)=\exp\{\eta(\theta)T(x)-B(\theta)\} h(x)$, portanto a distribuição de série de potências faz parte da família exponencial unidimensional.

(b) Mostre que sua função geradora de momentos é $M_X(u) = C(\theta e^u)/C(\theta)$.

Para obter a função geradora de momentos da variável X , primeiro reescrevemos sua função de probabilidade na forma canônica, fazendo:

$$\eta = \log \theta \quad (\Rightarrow \theta = e^{\eta}) ; \quad T(x) = x ; \quad A(\eta) = \log(C(e^{\eta}))$$

Assim,

$$f_{\theta}(x) = \exp\{\eta T(x) - A(\eta)\} h(x), \quad x=0,1,\dots; \quad h(x) \geq 0, \quad \eta \in \mathbb{R}$$

portanto, pode ser obtida como

$$\begin{aligned} M_X(u) = M_T(u) &= \frac{\exp\{A(\eta+u)\}}{\exp\{A(\eta)\}} = \frac{\exp\{\log C(e^{\eta+u})\}}{\exp\{\log C(e^{\eta})\}} = \frac{C(e^{\eta+u})}{C(e^{\eta})} \\ &= \frac{C(e^{\eta}e^u)}{C(e^{\eta})} = \frac{C(e^{\log \theta}e^u)}{C(e^{\log \theta})} = \frac{C(\theta e^u)}{C(\theta)}, \quad \boxed{x} \end{aligned}$$

(c) Mostre que as distribuições binomial, binomial negativa e Poisson são casos especiais da distribuição de série de potências e determine $\theta \in C(\theta)$.

Binomial:

$$\text{Se } X \sim \text{Binomial}(n, \pi), \text{ então } p(x) = \binom{n}{x} \pi^x (1-\pi)^{n-x}, \quad x=0,1,\dots,n; \quad 0 < \pi < 1.$$

Mas,

$$p(x) = \binom{n}{x} \pi^x (1-\pi)^{n-x} = \binom{n}{x} \pi^x (1-\pi)^{-x} (1-\pi)^n = \binom{n}{x} \left(\frac{\pi}{1-\pi}\right)^x (1-\pi)^n = \binom{n}{x} \left(\frac{\pi}{1-\pi}\right)^x \left(1 + \frac{\pi}{1-\pi}\right)^n$$

Note que, se $\frac{\pi}{1-\pi} = \theta$, fazendo $a(x) = \binom{n}{x}$ e $C(\theta) = (1+\theta)^n$, temos que

$$p(x) = \frac{a(x)\theta^x}{C(\theta)}, \quad \text{para } x=0,1,\dots,n \quad \text{e } a(x) > 0.$$

Binomial negativa:

$$\text{Se } X \sim BN(r, \pi), \text{ então } p(x) = \binom{x-1}{r-1} \pi^r (1-\pi)^{x-r} \quad x=r, r+1, \dots, \quad 0 < \pi < 1.$$

Logo,

$$p(x) = \binom{x-1}{r-1} \pi^r (1-\pi)^{x-r} = \binom{x-1}{r-1} \left(\frac{\pi}{1-\pi}\right)^r (1-\pi)^x = \binom{x-1}{r-1} (1-\pi)^x / \left(\frac{1}{1-\pi} - 1\right)^r$$

Assim, se $\theta = 1-\pi$, $a(x) = \binom{x-1}{r-1}$ e $C(\theta) = \left(\frac{1}{\theta} - 1\right)^r$, temos que

$$p(x) = \frac{a(x)\theta^x}{C(\theta)}, \quad x=r, r+1, \dots, \quad a(x) > 0.$$

Poisson:

$$\text{Se } X \sim \text{Poisson}(\lambda), \text{ então } p(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x=0,1,\dots, \quad \lambda > 0$$

$$\text{Note que } p(x) = \frac{\lambda^x e^{-\lambda}}{x!} = \frac{(x!)^{-1} \lambda^x}{e^x}$$

Assim, fazendo $\theta = \lambda$, $a(x) = (x!)^{-1}$ e $C(\theta) = e^{\theta}$, segue que

$$p(x) = \frac{a(x)\theta^x}{C(\theta)}, \quad x=0,1,\dots, \quad a(x) > 0$$

(d) Mostre que a distribuição série logarítmica, que é uma distribuição de potências com $a(x) = 1/x$ e $C(\theta) = -\log(1-\theta)$, $x=1,2,\dots$, $0 < \theta < 1$, tem função geradora de momentos $\log(1-\theta e^u)/\log(1-\theta)$ e determine $E(X)$ e $\text{Var}(X)$.

Se X tem distribuição série logarítmica, então sua função de probabilidade é dada por

$$f_\theta(x) = \frac{a(x)\theta^x}{C(\theta)} = \frac{\theta^x}{-x\log(1-\theta)}, \quad x=1,2,\dots; \quad 0 < \theta < 1.$$

Logo, pelo item (b), a função geradora de momentos é dada por

$$M_X(u) = \frac{C(\theta e^u)}{C(\theta)} = \frac{-\log(1-\theta e^u)}{-\log(1-\theta)} = \frac{\log(1-\theta e^u)}{\log(1-\theta)}, \quad x, \quad x=1,2,\dots \quad 0 < \theta < 1.$$

Assim,

$$\frac{d}{du} M_X(u) = \frac{-\theta e^u}{\log(1-\theta)} = \frac{\theta e^u}{\log(1-\theta)\{\theta e^{u-1}\}} = \frac{1}{\log(1-\theta)\{1-\theta^{-1}e^{-u}\}}$$

$$\frac{d^2}{du^2} M_X(u) = \frac{-\theta^{-1}e^{-u}}{\log(1-\theta)\{1-\theta^{-1}e^{-u}\}^2} = \frac{-\theta e^u}{\log(1-\theta)\{1-\theta e^{u-1}\}^2}$$

Logo, como $E(X) = \frac{d}{du} M_X(u) \Big|_{u=0}$ e $E(X^2) = \frac{d^2}{du^2} M_X(u) \Big|_{u=0}$, então

$$E(X) = \frac{-1}{\log(1-\theta)\{1-\theta^{-1}\}} = \frac{-\theta}{\log(1-\theta)\{\theta-1\}} \times \quad \text{e}$$

$$E(X^2) = \frac{-\theta}{\log(1-\theta)\{1-\theta\}^2} = \frac{-\theta}{\log(1-\theta)\{\theta-1\}^2}$$

Portanto,

$$\begin{aligned} \text{Var}(X) &= E(X^2) - E(X)^2 = \frac{-\theta}{\log(1-\theta)\{\theta-1\}^2} - \left[\frac{-\theta}{\log(1-\theta)\{\theta-1\}} \right]^2 \\ &= \frac{-\theta}{\log^2(1-\theta)\{\theta-1\}^2} \left\{ \log(1-\theta) + \theta \right\} \end{aligned}$$

Note que, para $0 < \theta < 1$

$$\begin{aligned} -\theta > \log(1-\theta) &\Rightarrow \log(1-\theta) + \theta \leq 0 \\ &\Rightarrow \text{Var}(X) \geq 0. \end{aligned}$$

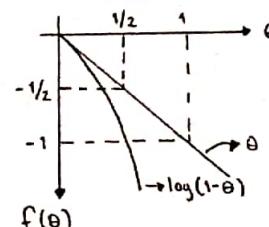
Justificação:

seja $f(x) = e^{-x} - 1 + x$, f continua em $(0,1)$, Pelo Teorema do valor médio, $\forall x \in (0,1)$, $\exists c_x \in (0,1)$; $f'(c_x) = (f(x) - f(0))/(x-0)$,

$$\Rightarrow 1 - e^{-c_x} = (e^{-x} - 1 + x)/x \Rightarrow e^{-x} - 1 + x = x(1 - e^{-c_x}) > 0$$

$$\Rightarrow e^{-x} - 1 + x > 0 \Rightarrow e^{-x} > 1 - x \Rightarrow -x > \log(1-x), \quad x \in (0,1)$$

Graficamente:



Exercício 8. Seja $T(X) = (T_1(x), \dots, T_s(x))^t$ e considere a densidade

$$p_\theta(x) = \exp \left[\sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right] h(x)$$

(a) Para $s=1$, mostre que $E_\theta[T(x)] = B'(\theta)/\eta'(\theta)$ e $\text{var}_\theta[T(x)] = B''(\theta)/[\eta'(\theta)]^2 - \eta''(\theta)B'(\theta)/[\eta'(\theta)^3]$.

Note que, se $s=1$, $p_\theta(x) = \exp \left[\eta(\theta) T(x) - B(\theta) \right] h(x)$ e dado que $p_\theta(x)$ é uma função densidade de probabilidade, então respeito a alguma medida μ ,

$$\int_{\mathbb{X}} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) d\mu x = 1$$

$$\Rightarrow \frac{d}{d\theta} \int_{\mathbb{X}} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) d\mu x = 0$$

$$\Rightarrow \int_{\mathbb{X}} \frac{d}{d\theta} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) d\mu x = 0 \quad (\text{sob condição de regularidade}) \checkmark$$

$$\Rightarrow \int_{\mathbb{X}} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) \left\{ \frac{d\eta(\theta)}{d\theta} T(x) - \frac{dB(\theta)}{d\theta} \right\} d\mu x = 0$$

$$\Rightarrow \frac{d\eta(\theta)}{d\theta} \underbrace{\int_{\mathbb{X}} T(x) \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) d\mu x}_{E_\theta[T(x)]} -$$

$$\underbrace{\frac{dB(\theta)}{d\theta} \int_{\mathbb{X}} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) d\mu x}_{1} = 0$$

$$\Rightarrow \frac{d\eta(\theta)}{d\theta} E_\theta[T(x)] - \frac{dB(\theta)}{d\theta} = 0 \quad \checkmark$$

Assim, seja $\eta'(\theta) = \frac{d\eta(\theta)}{d\theta}$ e $B'(\theta) = \frac{dB(\theta)}{d\theta}$, então

$$\eta'(\theta) E_\theta[T(x)] = B'(\theta) \Rightarrow E_\theta[T(x)] = B'(\theta)/\eta'(\theta).$$

Também, sob condições de regularidade

$$\frac{d^2}{d\theta^2} \int_{\mathbb{X}} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) d\mu x = 0$$

$$\Rightarrow \int_{\mathbb{X}} \frac{d^2}{d\theta^2} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) d\mu x = 0$$

$$\Rightarrow \int_{\mathbb{X}} \frac{d}{d\theta} \left[\exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) \left\{ \eta'(\theta) T(x) - B'(\theta) \right\} \right] d\mu x = 0$$

$$\Rightarrow \int_{\mathbb{X}} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) \left[\eta'(\theta) T(x) - B'(\theta) \right]^2 d\mu x +$$

$$\int_{\mathbb{X}} \exp \left\{ \eta(\theta) T(x) - B(\theta) \right\} h(x) [\eta''(\theta) T(x) - B''(\theta)] d\mu x = 0$$

$$\text{com } \eta''(\theta) = \frac{d^2\eta(\theta)}{d\theta^2} \text{ e } B''(\theta) = \frac{d^2B(\theta)}{d\theta^2}.$$

$$\Rightarrow \int_{\mathbb{X}} p_\theta(x) [\eta'(\theta) T(x) - B'(\theta)]^2 d\mu x + \int_{\mathbb{X}} p_\theta(x) [\eta''(\theta) T(x) - B''(\theta)] d\mu x = 0$$

$$\Rightarrow [\eta'(\theta)]^2 \underbrace{\int_{\mathbb{X}} [T(x)]^2 p_\theta(x) d\mu x}_{E_\theta[T(x)]^2} - 2\eta'(\theta) B'(\theta) \underbrace{\int_{\mathbb{X}} T(x) p_\theta(x) d\mu x}_{E_\theta[T(x)]} +$$

$$[B'(\theta)]^2 \underbrace{\int_{\mathbb{X}} p_\theta(x) d\mu x}_{1} + \eta''(\theta) \underbrace{\int_{\mathbb{X}} T(x) p_\theta(x) d\mu x}_{E_\theta[T(x)]} - B''(\theta) \underbrace{\int_{\mathbb{X}} p_\theta(x) d\mu x}_{1} = 0$$

Assim,

$$[\eta'(\theta)]^2 E_\theta[T(x)]^2 - 2\eta'(\theta) B'(\theta) E_\theta[T(x)] + [B'(\theta)]^2 + \eta''(\theta) E_\theta[T(x)] - B''(\theta) = 0$$

E substituindo $E_\theta[T(x)] = B'(\theta)/\eta'(\theta)$, temos

$$[\eta'(\theta)]^2 E_\theta[T(x)]^2 - 2[B'(\theta)]^2 + [B'(\theta)]^2 + \eta''(\theta) B'(\theta)/\eta'(\theta) - B''(\theta) = 0$$

$$\Rightarrow [\eta'(\theta)]^2 E_\theta[T(x)]^2 - [B'(\theta)]^2 + \eta''(\theta) B'(\theta)/\eta'(\theta) - B''(\theta) = 0$$

$$\Rightarrow E_\theta[T(x)]^2 = \frac{[B'(\theta)]^2 + B''(\theta) - \eta''(\theta) B'(\theta)/\eta'(\theta)}{[\eta'(\theta)]^2}$$

Portanto,

$$\begin{aligned} \text{Var}_{\theta}[T(x)] &= E_{\theta}[T(x)]^2 - [E_{\theta}[T(x)]]^2 \\ &= \frac{[B'(\theta)]^2 + B''(\theta) - \eta''(\theta) B'(\theta) / \eta'(\theta)}{[\eta'(\theta)]^2} - \left[\frac{B'(\theta)}{\eta'(\theta)} \right]^2 \\ &= \frac{B''(\theta) - \eta''(\theta) B'(\theta) / \eta'(\theta)}{[\eta'(\theta)]^2} \\ &= \frac{B'(\theta)}{[\eta'(\theta)]^2} - \frac{\eta''(\theta) B'(\theta)}{[\eta'(\theta)]^3} \end{aligned}$$

(b) Para $s > 1$, mostre que $E_{\theta}[T(x)] = J^{-1} \nabla B$, onde J é a matriz Jacobiana definida por $J = \{\partial \eta_i / \partial \theta_j\}$ e ∇B é o vetor gradiente $\nabla B = \{\partial B(\theta) / \partial \theta_j\}$. Seja $\eta(\theta) = (\eta_1(\theta), \dots, \eta_s(\theta))$, $T(x) = (T_1(x), \dots, T_s(x))$ e $\theta = (\theta_1, \dots, \theta_p)$, então, sob condições de regularidade, para $i=1, \dots, p$, respeito a alguma medida μ ,

$$\begin{aligned} &\int_x \exp \left\{ \sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right\} h(x) d\mu x = 1 \\ \Rightarrow &\frac{\partial}{\partial \theta_i} \int_x \exp \left\{ \sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right\} h(x) d\mu x = 0 \\ \Rightarrow &\int_x \frac{\partial}{\partial \theta_i} \exp \left\{ \sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right\} h(x) d\mu x = 0 \\ \Rightarrow &\int_x \exp \left\{ \sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right\} h(x) \left\{ \sum_{i=1}^s \frac{\partial \eta_i(\theta)}{\partial \theta_i} T_i(x) - \frac{\partial B(\theta)}{\partial \theta_i} \right\} d\mu x = 0 \\ \Rightarrow &\sum_{i=1}^s \frac{\partial \eta_i(\theta)}{\partial \theta_i} \underbrace{\int_x T_i(x) P_{\theta}(x) d\mu x}_{E_{\theta}[T_i(x)]} - \frac{\partial B(\theta)}{\partial \theta_i} \underbrace{\int_x P_{\theta}(x) d\mu x}_{1} = 0 \\ \Rightarrow &\sum_{i=1}^s \frac{\partial \eta_i(\theta)}{\partial \theta_i} E_{\theta}[T_i(x)] = \frac{\partial B(\theta)}{\partial \theta_i}, \text{ para } i=1, \dots, p \end{aligned}$$

Assim, temos o sistema

$$\left\{ \begin{array}{l} \sum_{i=1}^s \frac{\partial \eta_i(\theta)}{\partial \theta_1} E_{\theta}[T_i(x)] = \frac{\partial B(\theta)}{\partial \theta_1} \\ \sum_{i=1}^s \frac{\partial \eta_i(\theta)}{\partial \theta_2} E_{\theta}[T_i(x)] = \frac{\partial B(\theta)}{\partial \theta_2} \\ \vdots \\ \sum_{i=1}^s \frac{\partial \eta_i(\theta)}{\partial \theta_p} E_{\theta}[T_i(x)] = \frac{\partial B(\theta)}{\partial \theta_p} \end{array} \right\} \Rightarrow \left\{ \begin{array}{l} \frac{\partial \eta_1(\theta)}{\partial \theta_1} E_{\theta}[T_1(x)] + \dots + \frac{\partial \eta_s(\theta)}{\partial \theta_1} E_{\theta}[T_s(x)] = \frac{\partial B(\theta)}{\partial \theta_1} \\ \frac{\partial \eta_1(\theta)}{\partial \theta_2} E_{\theta}[T_1(x)] + \dots + \frac{\partial \eta_s(\theta)}{\partial \theta_2} E_{\theta}[T_s(x)] = \frac{\partial B(\theta)}{\partial \theta_2} \\ \vdots \\ \frac{\partial \eta_1(\theta)}{\partial \theta_p} E_{\theta}[T_1(x)] + \dots + \frac{\partial \eta_s(\theta)}{\partial \theta_p} E_{\theta}[T_s(x)] = \frac{\partial B(\theta)}{\partial \theta_p} \end{array} \right.$$

O anterior pode ser escrito com matrizes como

$$\underbrace{\begin{bmatrix} \frac{\partial \eta_1(\theta)}{\partial \theta_1} & \frac{\partial \eta_2(\theta)}{\partial \theta_1} & \dots & \frac{\partial \eta_s(\theta)}{\partial \theta_1} \\ \frac{\partial \eta_1(\theta)}{\partial \theta_2} & \frac{\partial \eta_2(\theta)}{\partial \theta_2} & \dots & \frac{\partial \eta_s(\theta)}{\partial \theta_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \eta_1(\theta)}{\partial \theta_p} & \frac{\partial \eta_2(\theta)}{\partial \theta_p} & \dots & \frac{\partial \eta_s(\theta)}{\partial \theta_p} \end{bmatrix}}_J \begin{bmatrix} E_{\theta}[T_1(x)] \\ E_{\theta}[T_2(x)] \\ \vdots \\ E_{\theta}[T_s(x)] \end{bmatrix} = \underbrace{\begin{bmatrix} \frac{\partial B(\theta)}{\partial \theta_1} \\ \frac{\partial B(\theta)}{\partial \theta_2} \\ \vdots \\ \frac{\partial B(\theta)}{\partial \theta_p} \end{bmatrix}}_{\nabla B}$$

Assim, seja $J = \left\{ \frac{\partial \eta_i(\theta)}{\partial \theta_j} \right\}_{i,j}$, $i=1, \dots, s$, $j=1, \dots, p$, J^{-1} existe se $\nabla B = \left\{ \frac{\partial B(\theta)}{\partial \theta_j} \right\}$, $j=1, \dots, p$ e J é quadrada. ($p=s$)

$$E_{\theta}[T(x)] = \left\{ E_{\theta}[T_i(x)] \right\}, \quad i=1, \dots, s$$

$$\text{Então, } J \cdot E_{\theta}[T(x)] = \nabla B \Rightarrow E_{\theta}[T(x)] = J^{-1} \nabla B.$$

Exercício 11. Seja U uma variável aleatória com distribuição uniforme no intervalo unitário e considere as variáveis $X = U^\alpha$, $\alpha > 0$.

(a) Mostre que isso define uma família de grupo e determine a distribuição de X .

Temos que a v.a. U foi submetida ao grupo de transformações $X = g(u) = u^\alpha$.

Vamos verificar que a classe é fechada sob composição e inversão:

"fechada sob composição"

Seja T a classe de transformações 1-a-1 definidas por T , e seja

$$g_1 = U^{\alpha_1}, \alpha_1 > 0 \quad \wedge \quad g_2 = U^{\alpha_2}, \alpha_2 > 0, \quad g_1, g_2 \in T$$

então,

$$g_2 \circ g_1 = g_2(g_1(u)) = g_2(u^{\alpha_1}) = (u^{\alpha_1})^{\alpha_2} = u^{\alpha_1 \alpha_2} = U^\alpha$$

com $\alpha = \alpha_1 \alpha_2 > 0$, então $g_2 \circ g_1 \in T$.

"fechada sob inversão"

Seja $g \in T$, então $g^{-1}(x) = x^{1/\alpha} = x^\beta$, com $\beta = 1/\alpha > 0$, portanto $g^{-1} \in T$.

Assim, a classe de transformações é fechada sob composição e inversão, portanto $X = U^\alpha$, $\alpha > 0$, define uma família de grupo.

(b) Considere uma amostra aleatória (x_1, \dots, x_n) de X . Encontre uma estatística suficiente para α .

Dado que $U \sim U(0,1)$, então $f_U(u) = I_{(0,1)}(u)$, portanto, se $x_i = U^\alpha$

então $U = x_i^{1/\alpha}$, $\alpha > 0$ e

$$f_\alpha(x_i) = \frac{1}{\alpha} x_i^{1/\alpha - 1} I_{(0,1)}(x_i) = \frac{\Gamma(\frac{1}{\alpha} + 1)}{\Gamma(\frac{1}{\alpha}) \Gamma(1)} x_i^{\frac{1}{\alpha} - 1} (1-x_i)^{1-1} \\ \Rightarrow x_i \sim \text{BETA}\left(\frac{1}{\alpha}, 1\right)$$

Logo,

$$f_\alpha(x) = \prod_{i=1}^n f_\alpha(x_i) = \frac{1}{\alpha^n} \prod_{i=1}^n x_i^{\frac{1}{\alpha} - 1} I_{(0,1)}(x_i) \\ = \frac{1}{\alpha^n} \left[\prod_{i=1}^n x_i \right]^{\frac{1}{\alpha} - 1} \prod_{i=1}^n I_{(0,1)}(x_i), \quad \alpha > 0.$$

Assim, fazendo $T(x) = \prod_{i=1}^n x_i$, $g_\alpha(T(x)) = \frac{1}{\alpha^n} [T(x)]^{\frac{1}{\alpha} - 1}$ e $h(x) = \prod_{i=1}^n I_{(0,1)}(x_i)$

então $f_\alpha(x)$ pode-se escrever como

$$f_\alpha(x) = g_\alpha(T(x)) h(x), \quad \alpha > 0 \quad g^{-c} \cdot h.$$

portanto, pelo critério da fatoração $T(x) = \prod_{i=1}^n x_i$ é uma estatística suficiente para α .

Exercício 17. Seja $X = (X_1, \dots, X_n)$ amostra aleatória da distribuição $E(\theta, \theta)$, $\theta > 0$ é desconhecido, com função densidade de probabilidade

$$f(x; \theta) = \frac{1}{\theta} \exp\left\{-\frac{x-\theta}{\theta}\right\} I_{[\theta, \infty)}(x).$$

Mostrar que $(\bar{x}, x_{(1)})$, onde $\bar{x} = \sum_{i=1}^n x_i/n$ e $x_{(1)} = \min(X_1, \dots, X_n)$, é suficiente minimal mas não é completa.

Suficiência:

Para a amostra aleatória X ,

$$f_\theta(x) = \prod_{i=1}^n \frac{1}{\theta} \exp\left\{-\frac{x_i-\theta}{\theta}\right\} I_{[\theta, \infty)}(x_i), \quad \theta > 0$$

$$= \frac{1}{\theta^n} \exp\left\{-\frac{1}{\theta} \sum_{i=1}^n (x_i - \theta)\right\} \prod_{i=1}^n I_{[\theta, \infty)}(x_i), \quad \theta > 0$$

$$= \frac{1}{\theta^n} \exp\left\{-\frac{1}{\theta} n \bar{x} + n\right\} \prod_{i=1}^n I_{[\theta, \infty)}(x_i), \quad \theta > 0$$

$$= \frac{e^n}{\theta^n} \exp\left\{-\frac{n \bar{x}}{\theta}\right\} \prod_{i=1}^n I_{[\theta, \infty)}(x_i) \quad /, \quad \theta > 0.$$

Mos, $\prod_{i=1}^n I_{[\theta, \infty)}(x_i) = 1 \iff x_{(1)} \geq \theta$, então

$$f_\theta(x) = \frac{1}{\theta^n} \exp\left\{-\frac{n \bar{x}}{\theta}\right\} I_{[\theta, \infty)}(x_{(1)}) e^n \quad /, \quad \theta > 0$$

logo, fazendo $T(x) = (\bar{x}, x_{(1)})$, $g_\theta(T(x)) = \frac{1}{\theta^n} \exp\left\{-\frac{n \bar{x}}{\theta}\right\} I_{[\theta, \infty)}(x_{(1)})$

e $h(x) = \exp(n)$, temos

$$f_\theta(x) = g_\theta(T(x)) h(x), \quad \theta > 0.$$

Assim, pelo critério da fatoração $T(x) = (\bar{x}, x_{(1)})$ é uma estatística suficiente para θ .

Suficiência minimal.

Note que, para uma amostra aleatória y

$$f_\theta(y) = \frac{e^n}{\theta^n} \exp\left\{-\frac{n \bar{y}}{\theta}\right\} I_{[\theta, \infty)}(y_{(1)})$$

$$= \frac{e^n}{\theta^n} \exp\left\{-\frac{n \bar{y}}{\theta}\right\} \exp\left\{\frac{n \bar{x}}{\theta} - \frac{n \bar{y}}{\theta}\right\} I_{[\theta, \infty)}(x_{(1)}) \frac{I_{[\theta, \infty)}(y_{(1)})}{I_{[\theta, \infty)}(x_{(1)})}$$

$$= f_\theta(x) \exp\left\{\frac{n}{\theta}(\bar{x} - \bar{y})\right\} \frac{I_{[\theta, \infty)}(y_{(1)})}{I_{[\theta, \infty)}(x_{(1)})} \quad (1)$$

↓
Não fazer divi-
são por zero

Seja $D = \{y \in \mathbb{R}, f_\theta(y) = f_\theta(x) \cdot 1, \forall \theta \in \Omega\}$

" \Rightarrow "

suponhamos que $T(x) = T(y)$, isto é $\bar{x} = \bar{y}$ e $x_{(1)} = y_{(1)}$, segue de (1) que $f_\theta(y) = f_\theta(x) \cdot 1 \quad \forall \theta \in \Omega$, portanto $y \in D$.

" \Leftarrow "

suponhamos que $y \in D$, isto é, para todo $\theta \in \Omega$ $f_\theta(y) = f_\theta(x) \cdot 1$ segue de (1) que

$$\exp\left\{\frac{n}{\theta}(\bar{x} - \bar{y})\right\} = 1 \quad \text{e} \quad I_{[\theta, \infty)}(y_{(1)}) = I_{[\theta, \infty)}(x_{(1)}) \quad \forall \theta \in \Omega$$

e então*

$$\bar{x} = \bar{y} \quad \text{e} \quad x_{(1)} = y_{(1)} \Rightarrow T(x) = T(y)$$

Portanto, $T(x) = (\bar{x}, x_{(1)})$ é uma estatística suficiente minimal para θ .

* Note que $I_{[\theta, \infty)}(x_{(1)}) = I_{(-\infty, x_{(1)}]}(\theta) \quad \forall \theta \in \Omega$.

Também, se $x_{(1)} \neq y_{(1)}$ então $\exists \theta : y_{(1)} < \theta < x_{(1)}$ portanto

$I_{(-\infty, \theta]}(y_{(1)}) = 0$ e $I_{(-\infty, \theta]}(x_{(1)}) = 1$, então se $I_{[\theta, \infty)}(y_{(1)}) = I_{[\theta, \infty)}(x_{(1)})$ então $x_{(1)} = y_{(1)}$. [se $\sim q \rightarrow \sim p \Rightarrow p \rightarrow q$].

completa:

Dado que, se $X \sim E(\theta, \theta)$ então para alguma medida μ

$$\begin{aligned} E_\theta(x) &= \int_0^\infty x \frac{1}{\theta} \exp\left\{-\frac{x-\theta}{\theta}\right\} d_\mu x = \lim_{b \rightarrow \infty} \left\{ \left[-x \exp\left(-\frac{x-\theta}{\theta}\right) \right]_0^b + \int_0^b \exp\left\{-\frac{x-\theta}{\theta}\right\} d_\mu x \right\} \\ &= \lim_{b \rightarrow \infty} \left\{ \theta - b \exp\left(-\frac{b-\theta}{\theta}\right) \right\} + \lim_{b \rightarrow \infty} \left\{ -\theta \exp\left(-\frac{b-\theta}{\theta}\right) \Big|_0^b \right\} \\ &= \theta + \lim_{b \rightarrow \infty} \left\{ \theta - \theta \exp\left(-\frac{b-\theta}{\theta}\right) \right\} = 2\theta \end{aligned}$$

Assim, para a amostra aleatória $E(\bar{x}) = 2\theta$.

Também,

$$\begin{aligned} f_{X_{(1)}}(y) &= n \left[1 - F_X(y) \right]^{n-1} f_X(y) = n \left[1 - \left(1 - \exp\left\{-\frac{y-\theta}{\theta}\right\} \right) \right]^{n-1} \frac{1}{\theta} \exp\left\{-\frac{y-\theta}{\theta}\right\} I_{[\theta, \infty)}(y) \\ &= n \exp\left\{-(n-1) \frac{y-\theta}{\theta}\right\} \frac{1}{\theta} \exp\left\{-\frac{y-\theta}{\theta}\right\} I_{[\theta, \infty)}(y) \\ &= \frac{1}{\theta/n} \exp\left\{-\frac{y-\theta}{\theta/n}\right\} I_{[\theta, \infty)}(y) \end{aligned}$$

Portanto $X_{(1)} \sim E(\theta, \theta/n)$. Logo,

$$\begin{aligned} E_\theta(X_{(1)}) &= \int_0^\infty \frac{y}{\theta/n} \exp\left\{-\frac{y-\theta}{\theta/n}\right\} dy = \lim_{b \rightarrow \infty} \left\{ \theta - b \exp\left\{-\frac{b-\theta}{\theta/n}\right\} \right\} + \\ &\quad \lim_{b \rightarrow \infty} \left\{ \frac{\theta}{n} - \frac{\theta}{n} \exp\left\{-\frac{b-\theta}{\theta/n}\right\} \right\} \\ &= \theta \left(\frac{n+1}{n} \right) \end{aligned}$$

Logo, tomando $g(T) = T_1 - \frac{2n}{n+1} T_2$, com $T_1 = \bar{x}$ e $T_2 = X_{(1)}$, então

$$g(T) = \bar{x} - \frac{2n}{n+1} X_{(1)} \neq 0 \quad \text{e} \quad E(g(T)) = 2\theta - \frac{2n}{n+1} \theta \left(\frac{n+1}{n} \right) = 0$$

Portanto, $T(x) = (\bar{x}, X_{(1)})$ não é uma estatística completa para θ .

Exercício 29. Suponha que x_1, \dots, x_n sejam uma amostra aleatória de uma família de locação-escala com função distribuição $F((x-a)/b)$.

(a) Se b é conhecido, mostre que as diferenças $(x_i - x_1)/b$, $i=2, \dots, n$ são anciliares. Seja x_1, \dots, x_n uma a.a. de uma família de locação-escala, então para $a \in \mathbb{R}$ desconhecido e $b > 0$ conhecido podemos escrever

$$x_i = a + b z_i, \quad i=1, \dots, n$$

em que z_i é uma u.a. com f.d.a. $F(\cdot)$ e f.d.p. $f(\cdot)$ que não depende de parâmetros desconhecidos e z_1, \dots, z_n independentes.

Defina os estatísticos $y_j = \phi_j(x) = \frac{x_1 - x_j}{b}$, $j=2, \dots, n$, onde $x = x_1, \dots, x_n$. Note que, os $\phi_j(x)$ são tais que

$$\phi_j(x) = \phi_j(x_1, \dots, x_n) = \frac{x_1 - x_j}{b} = \frac{(x_1 - a) - (x_j - a)}{b}$$

$$= \phi_j(x_1 - a, x_2 - a, \dots, x_n - a), \quad j=2, \dots, n$$

Assim, para $j=2, \dots, n$

$$\begin{aligned} P(y_j \leq y) &= P(\phi_j(x) \leq y) = P(\phi_j(x_1, \dots, x_n) \leq y) = P(\phi_j(x_1 - a, \dots, x_n - a) \leq y) \\ &= P\left(\frac{(x_1 - a) - (x_j - a)}{b} \leq y\right) = P\left(\frac{x_1 - a}{b} - \frac{x_j - a}{b} \leq y\right) \\ &= P(z_1 - z_j \leq y) \quad (1) \end{aligned}$$

Logo, dado que z_j , $j=2, \dots, n$ são independentes e sua distribuição não depende de a , por (1) as diferenças $(x_i - x_1)/b$, $i=2, \dots, n$ com b conhecido, são anciliares.

(b) Se a é conhecido, mostre que as razões $(x_i - a)/(x_i - a)$, $i=2, \dots, n$ são anciliares.

Neste caso, com a conhecido, seja $y_j = \frac{x_1 - a}{x_j - a} = \frac{(x_1 - a)/b}{(x_j - a)/b}$, $j=2, \dots, n$.

Logo,

$$P(y_j \leq y) = P\left(\frac{x_1 - a}{x_j - a} \leq y\right) = P\left(\frac{(x_1 - a)/b}{(x_j - a)/b} \leq y\right) = P\left(\frac{z_1}{z_j} \leq y\right)$$

Assim, ao igual que em (a), dado que $x_j = a + b z_j$ e z_j , $j=1, 2, \dots, n$, independentes, com distribuição padrão $F(\cdot)$, então a distribuição das razões y_j , $j=2, 3, \dots, n$, não depende de b quando a é conhecido. Portanto as razões y_j são anciliares.

(c) Se a e b são desconhecidos, mostre que as quantidades $(x_i - x_1)/(x_2 - x_1)$, $i=3, \dots, n$, são anciliares.

Novamente temos $x_i = a + b z_i$, $i=1, \dots, n$, mas agora a e b não desconhecidos. Os z_i , $i=1, \dots, n$, independentes, com distribuição que não depende de $\theta = (a, b)$.

$$\text{Seja } y_j = \phi_j(x) = \phi_j(x_1, \dots, x_n) = \frac{x_1 - x_j}{x_2 - x_j} = \frac{\frac{x_1 - a}{b} - \frac{x_j - a}{b}}{\frac{x_2 - a}{b} - \frac{x_j - a}{b}} = \phi\left(\frac{x_1 - a}{b}, \dots, \frac{x_n - a}{b}\right)$$

para $j=3, \dots, n$.

Assim, para $j=3, \dots, n$,

$$\begin{aligned} P(y_j \leq y) &= P(\phi_j(x) \leq y) = P(\phi_j(x_1, \dots, x_n) \leq y) = P\left(\phi_j\left(\frac{x_1 - a}{b}, \dots, \frac{x_n - a}{b}\right) \leq y\right) \\ &= P(\phi_j(z_1, \dots, z_n) \leq y) \end{aligned}$$

Então, dada a independência de z_1, \dots, z_n e que sua distribuição não depende de $\theta = (a, b)$, então, os $y_j = (x_i - x_1)/(x_2 - x_1)$, $i=3, \dots, n$, são anciliares.

Exercício 31. Assuma válidas as suposições do Criterio do Fatoração. Seja A qualquer conjunto fixado do espaço amostral, P_θ^* a distribuição P_θ truncada sobre A e $\mathcal{P}^* = \{P_\theta^*, \theta \in \Omega\}$. Mostre que

(a) Se T é suficiente para \mathcal{P} , é também suficiente para \mathcal{P}^*

Assumindo válidos as suposições do C.F., se $T(x)$ é uma estatística suficiente para $\mathcal{P} = \{P_\theta, \theta \in \Omega\}$, então, existem funções g_θ e h tais que $P_\theta(x) = g_\theta(T(x)) h(x)$.

Temos que A é qualquer conjunto fixado do espaço amostral, e P_θ^* a distribuição truncada sobre A , então

$$P_\theta^*(x) = \frac{P_\theta(x)}{P_\theta(A)} I_A(x) = P_\theta(x) \frac{1}{P_\theta(A)} I_A(x)$$

$$\Rightarrow P_\theta^*(x) = g_\theta(T(x)) h(x) \frac{1}{P_\theta(A)} I_A(x)$$

$$= g_\theta^*(T(x)) h^*(x)$$

com $g_\theta^*(T(x)) = g_\theta(T(x))/P_\theta(A)$ e $h^*(x) = h(x) I_A(x)$

Assim, pelo C.F., dado que existem funções g_θ^* e h^* tais que $P_\theta^*(x) = g_\theta^*(T(x)) h^*(x)$, a estatística $T(x)$ é também suficiente para P_θ^* .

(b) Se T é completa para \mathcal{P} , é também completa para \mathcal{P}^*

Temos que provar que se $E_\theta[g(T(x))] = 0$ então $g(T(x))$ q.c. \mathcal{P}^* , $\forall \theta$ e qualquer função g da estatística T .

Seja g uma função qualquer e suponhamos que $E_\theta[g(T(x))], \forall \theta \in \Omega$. Se T é completa para \mathcal{P} , então $g(T(x)) = 0$ q.c. \mathcal{P} e isto é equivalente com $P[g(T(x)) = 0] = 1 \Leftrightarrow P[g(T(x)) \neq 0] = 0$.

Assim,

$$\int_{\{w: g(T(w)) \neq 0\}} P_\theta(t) dt = 0$$

logo,

$$\begin{aligned} 0 &\leq \int_{\{w: g(T(w)) \neq 0\}} P_\theta^*(t) dt = \int_{\{w: g(T(w)) \neq 0\}} \frac{P_\theta(t)}{P_\theta(A)} I_A(t) dt = \frac{1}{P_\theta(A)} \int_{\{w: g(T(w)) \neq 0\}} P_\theta(t) dt \leq \\ &\leq \frac{1}{P_\theta(A)} \int_{\{w: g(T(w)) \neq 0\}} P_\theta(t) dt = 0 \end{aligned}$$

então,

$$\int_{\{w: g(T(w)) \neq 0\}} P_\theta^*(t) dt = 0 \Leftrightarrow P^*(g(T(x)) \neq 0) = 0 \Leftrightarrow P^*(g(T(x)) = 0) = 1$$

$$\Leftrightarrow g(T(x)) = 0 \text{ q.c. } \mathcal{P}^*$$

Portanto, T é completa para \mathcal{P}^* .

9.9

Lista de Exercícios 2.

MAE 5839 - ESTATÍSTICA AVANÇADA I

Prof. Dra. Silvia L. P. Ferrari

Alunos: Mario José Pacheco López - 9034481

Hugo Alberto Brango García - 9176006

IME - USP , 22/09/2014

④ Seja X o conjunto dos números naturais, i.e. $X = \{0, 1, 2, \dots\}$, e $A \subset X$, não vazio. Suponha que X tem distribuição de Poisson de parâmetro λ truncada em A , ou seja, a distribuição de X coincide com a distribuição de Y condicional a que $Y \in A$, sendo que $Y \sim \text{Poisson}(\lambda)$.

(a) Suponha que $A = \{0, 1, 2, \dots, a\}$, em que a é um inteiro positivo. Mostre que λ não tem um estimador não viciado.

Para $X = \mathbb{N}$, $A = \{0, 1, \dots, a\} \subset Y \sim \text{Poisson}(\lambda)$, temos que a densidade de X é

$$P_\lambda(x) = \frac{\frac{\lambda^x}{x!}}{\sum_{y=0}^a \frac{\lambda^y}{y!}} I_A(x)$$

Suponhamos que λ tem um estimador não viciado $\delta(x)$, isto é $E[\delta(x)] = \lambda$, vejamos que isto leva a uma contradição

$$\begin{aligned} E[\delta(x)] = \lambda &\Leftrightarrow \sum_{x=0}^a \delta(x) P_\lambda(x) = \lambda \\ &\Leftrightarrow \sum_{x=0}^a \delta(x) \frac{\lambda^x}{x!} = \sum_{y=0}^a \frac{\lambda^y}{y!} \\ &\Leftrightarrow \frac{\delta(0)}{0!} = 0, \quad \frac{\delta(1)}{1!} = \frac{1}{0!}, \quad \frac{\delta(2)}{2!} = \frac{1}{1!}, \dots, \frac{\delta(a)}{a!} = \frac{1}{(a-1)!}, \quad \frac{1}{a!} = 0 \end{aligned}$$

A última igualdade não é possível porque $\frac{1}{a!} > 0$, para todo $a \in \mathbb{N} \setminus \{0\}$.

Portanto λ não tem um estimador não viciado.

b) Suponha que $A = \{1, 2, 3, \dots\}$. Encontre o ENVVUM de λ

Vamos determinar $\delta(x)$ tal que $E[\delta(x)] = \lambda$, i.e., $\sum_{x=0}^{\infty} \delta(x) P_\lambda(x) = \lambda$, sendo

$$P_\lambda(x) = \frac{\frac{\lambda^x}{x!}}{\sum_{y=1}^{\infty} \frac{\lambda^y}{y!}} \cdot I_A(x); \quad A = \{1, 2, \dots\}$$

Assim,

$$\begin{aligned} E[\delta(x)] = \lambda &\Leftrightarrow \sum_{x=1}^{\infty} \delta(x) \frac{\lambda^x}{x!} = \sum_{y=1}^{\infty} \frac{\lambda^y}{y!} \\ &\Leftrightarrow \frac{\delta(1)}{1!} = 0, \quad \frac{\delta(2)}{2!} = \frac{1}{1!}, \quad \frac{\delta(3)}{3!} = \frac{1}{2!}, \dots, \quad \frac{\delta(k)}{k!} = \frac{1}{(k-1)!}, \dots \end{aligned}$$

O estimador não viciado será $\delta(x) = \begin{cases} x, & \text{se } x \geq 2 \\ 0, & \text{se } x=1 \end{cases}$
Vejamos que $\delta(x)$ é o ENVVUM para λ .

$$P_\lambda(x) = \exp \left[-\lambda + x \log \lambda + \lambda - \log \left(\sum_{y=1}^{\infty} \frac{\lambda^y}{y!} \right) \right] \cdot \frac{I_A(x)}{x!}$$

$$= \exp \left[\log \lambda + x - \log (\lambda^{x-1}) \right] \cdot \frac{I_A(x)}{x!}$$

$$= \exp [n(\lambda) \delta(x) - b(\lambda)] h(x),$$

onde $n(\lambda) = \log \lambda$, $\delta(x) = x$, $b(\lambda) = \log(\lambda^{x-1})$ e $h(x) = \frac{I_A(x)}{x!}$

Como $\eta(\lambda) = \log \lambda$ está definido sobre o espaço paramétrico $\mathcal{S} = \{\lambda | \lambda > 0\}$ que contém rectângulos 1-dimensionais, então P_λ pertence à família exponencial unidimensional de posto completo, logo, $\delta(x) = x$ é suficiente completa e portanto é ENVVUM para λ .

- (10) Sejam x_1, \dots, x_m e y_1, \dots, y_n variáveis aleatórias independentes com distribuições $U(0, \theta)$ e $U(0, \theta')$, respectivamente. Se $n > 1$, determine o ENVVUM de θ/θ' .

Temos que x_1, \dots, x_m é uma amostra aleatória com $X \sim U(0, \theta)$

$$\Rightarrow f(x_i) = \frac{1}{\theta} I_{(0, \theta)}(x_i), \quad i=1, \dots, m$$

$$\Rightarrow P_\theta(x) = \prod_{i=1}^m I_{(0, \theta)}(x_i) = \frac{1}{\theta^m} I_{(0, \theta)}(x_m)$$

Pelo critério da factorização temos que $X_{(m)} = \max\{x_1, \dots, x_m\} = T(x)$

é uma estatística suficiente para θ . Então

$$f_{X_{(m)}} = \frac{m}{\theta^m} x^{m-1} I_{(0, \theta)}(x_{(m)})$$

Agora, veremos que $T(x) = X_{(m)}$ é completa para θ .

$$\Rightarrow E[g(T)] = 0 \Rightarrow \int_0^\theta g(t) f_T(t) dt = 0 \Rightarrow \int_0^\theta g(t) \frac{1}{\theta^m} m t^{m-1} dt = 0$$

$$\Rightarrow \int_0^\theta g(t) t^{m-1} dt = 0 \Rightarrow g(t) \equiv 0 \quad \forall \theta \in \mathcal{S}$$

Então $T(x) = X_{(m)}$ é uma estatística completa para θ . Note que,

$$\begin{aligned} E[T] &= \int_0^\theta t \frac{m}{\theta^m} t^{m-1} dt = \frac{m}{\theta^m} \int_0^\theta t^m dt = \frac{m}{\theta^m} \frac{t^{m+1}}{m+1} \Big|_0^\theta = \frac{m}{\theta^m} \frac{\theta^{m+1}}{m+1} = \frac{m}{m+1} \theta \\ \Rightarrow E[T] &= \frac{m}{m+1} \theta \Rightarrow E\left(\frac{m+1}{m} T\right) = \theta \end{aligned}$$

Portanto, $\delta(x) = \frac{m+1}{m} X_{(m)}$ é o ENVVUM de θ , pois ele é não viciado e é função da estatística suficiente completa.

Assim mesmo, temos que para y_1, \dots, y_n iid com distribuição $Y \sim U(0, \theta')$ $T(Y) = Y_{(n)}$ é suficiente completa para θ' .

$$\text{Também } E(Y_{(n)}) = \frac{n}{n+1} \theta' \Rightarrow E\left(\frac{n+1}{n} Y_{(n)}\right) = \theta'.$$

$$\text{Assim, } \delta(Y) = \frac{n+1}{n} Y_{(n)} \text{ é o ENVVUM para } \theta'.$$

Devemos calcular,

$$E\left(\frac{1}{Y_{(n)}}\right) = \int_0^{\theta'} \frac{1}{y} f_{Y_{(n)}}(y) dy = \int_0^{\theta'} \frac{1}{y} \frac{n}{\theta'^n} y^{n-1} dy = \frac{n}{\theta'^n} \int_0^{\theta'} y^{n-2} dy = \frac{n}{\theta'^n} \frac{y^{n-1}}{n-1} \Big|_0^{\theta'} = \frac{n}{\theta'^n} \frac{\theta'^{n-1}}{n-1} = \frac{n}{n-1} \frac{1}{\theta'}$$

Portanto, considerando

$$\delta(x, y) = \frac{\frac{m+1}{m} X_{(m)}}{\frac{n}{n-1} Y_{(n)}}$$

$$E\left(\frac{m+1}{m} X_{(m)}\right) E\left(\frac{1}{\frac{n}{n-1} Y_{(n)}}\right) = \frac{m+1}{m} E(X_{(m)}) \frac{1}{\frac{n}{n-1}} E\left(\frac{1}{Y_{(n)}}\right) = \frac{m+1}{m} \frac{m}{m+1} \theta = \frac{n-1}{n} \frac{m}{m+1} \theta = \frac{\theta}{\theta'}$$

Como $\delta(x, y)$ é função da estatística suficiente e completa então $\delta(x, y)$ é o ENVVUM de θ/θ' .

11) Prove ou dê contra-exemplo. Seja X variável aleatória com distribuição pertencente a uma família de distribuições $P = \{P_\theta, \theta \in \Omega\}$ e sejam $g_1(\theta)$ e $g_2(\theta)$ funções de θ a valores reais. Sejam $\delta_1(X)$ e $\delta_2(X)$ estimadores de $g_1(\theta)$ e $g_2(\theta)$ respectivamente, com $E(\delta_1(X)^2) < \infty$ e $E(\delta_2(X)^2) < \infty$. Se estes estimadores não são viciados de variância uniformemente mínima (ENVVUM) então $a\delta_1(X) + b\delta_2(X)$ tem variância finita e é ENVVUM de $ag_1(\theta) + bg_2(\theta)$. Aqui a e b são números reais fixados.

Seja $\delta_1 = \delta_1(X)$ e $\delta_2 = \delta_2(X)$

Temos que δ_1 e δ_2 pertencem à classe dos estimadores δ com $E_\theta(\delta^2) < \infty$, Δ , para todo $\theta \in \Omega$, portanto $\text{Var}_\theta(\delta_1(X)) < \infty$ e $\text{Var}_\theta(\delta_2(X)) < \infty$.

Logo, seja \mathcal{U} o conjunto de todos os estimadores não viciados de zero que estão em Δ e seja $U = \delta_2 - g_2(\theta)$. Então $U \in \mathcal{U}$ e dado que δ_1 é UNVVUM

$$\begin{aligned} E_\theta(\delta_1 U) &= 0 \Rightarrow E_\theta(\delta_1(\delta_2 - g_2(\theta))) = 0 \Rightarrow E_\theta(\delta_1 \delta_2) - \underbrace{E_\theta(\delta_1)}_{g_1(\theta)} g_2(\theta) = 0 \\ &\Rightarrow E_\theta(\delta_1 \delta_2) = g_2(\theta) g_1(\theta), \quad \forall \theta \in \Omega. \end{aligned}$$

$$\text{Assim, } \text{Cov}_\theta(\delta_1, \delta_2) = E_\theta(\delta_1 \delta_2) - E_\theta(\delta_1) E_\theta(\delta_2) = g_1(\theta) g_2(\theta) - g_2(\theta) g_1(\theta) = 0$$

Logo,

$$\begin{aligned} \text{Var}_\theta(a\delta_1 + b\delta_2) &= a^2 \text{Var}_\theta(\delta_1) + b^2 \text{Var}_\theta(\delta_2) - ab \text{Cov}_\theta(\delta_1, \delta_2) \\ &= a^2 \underbrace{\text{Var}_\theta(\delta_1)}_{< \infty} + b^2 \underbrace{\text{Var}_\theta(\delta_2)}_{< \infty} \end{aligned}$$

e dado que a e b são números reais fixados e $\text{Var}_\theta(\delta_1) < \infty$ e $\text{Var}_\theta(\delta_2) < \infty$, então $\text{Var}_\theta(a\delta_1 + b\delta_2) < \infty$. Assim, $a\delta_1(X) + b\delta_2(X)$ tem variância finita.

Por outro lado, seja $V \in \mathcal{U}$, então como δ_1 e δ_2 não ENVVUM, $\forall \theta \in \Omega$

$$E_\theta(\delta_1 V) = 0 \quad \text{e} \quad E_\theta(\delta_2 V) = 0$$

Portanto,

$$\begin{aligned} E_\theta[(a\delta_1 + b\delta_2)V] &= a E_\theta[\delta_1 V] + b E_\theta[\delta_2 V] \\ &= a \cancel{0} + b \cdot \cancel{0} \\ &= 0 \end{aligned}$$

assim, dada esta condição necessária e suficiente, o estimador $a\delta_1(X) + b\delta_2(X)$ com a e b números reais fixados é ENVVUM de $ag_1(\theta) + bg_2(\theta)$.

(15) Seja (x_1, \dots, x_n) uma amostra aleatória de uma distribuição discreta com função de probabilidade $f_{\theta,j}$, em que $\theta > 0$ e $j=1,2$; $f_{\theta,1}$ é a distribuição de Poisson de média θ e $f_{\theta,2}$ é a distribuição geométrica de parâmetro $\theta/(1+\theta)$, isto é,

$$f_{\theta,2}(x) = \left[1 - \frac{\theta}{1+\theta}\right] \left[\frac{\theta}{1+\theta}\right]^x, \quad x=0,1,2,\dots$$

Existe ENVVUM de θ ? Justifique.

x_1, x_2, \dots, x_n amostra aleatória de uma distribuição discreta com

$$f_{\theta,j} = \begin{cases} \frac{\bar{\theta}^x \theta^x}{x!}, & \theta > 0 \text{ e } j=1, x=0,1,2,\dots \\ \left(1 - \frac{\theta}{1+\theta}\right) \left(\frac{\theta}{1+\theta}\right)^x, & \theta > 0 \text{ e } j=2, x=0,1,2,\dots \end{cases}$$

Se existe o ENVVUM ele deve ser igual para $j=1$ e $j=2$.

\Rightarrow Para $j=1$, sabemos que \bar{x} é o ENVVUM para θ .

\Rightarrow Para $j=2$, temos:

$$P_\theta(x) = \prod_{i=1}^n \left(1 - \frac{\theta}{1+\theta}\right) \left(\frac{\theta}{1+\theta}\right)^{x_i} = \prod_{i=1}^n \left(\frac{1}{1+\theta}\right) \left(\frac{\theta}{1+\theta}\right)^{x_i} = \left(\frac{1}{1+\theta}\right)^n \left(\frac{\theta}{1+\theta}\right)^{\sum_{i=1}^n x_i}$$

$$= \exp\left[-n \log(1+\theta) + \log\left(\frac{\theta}{1+\theta}\right) \sum_{i=1}^n x_i\right]$$

$$= \exp\left[\underbrace{\log\left(\frac{\theta}{1+\theta}\right) \sum_{i=1}^n x_i}_{T(x)} - n \log(1+\theta)\right] \cdot \underbrace{1}_{h(x)}$$

Como o domínio de $\eta(\theta) = \log\left(\frac{\theta}{1+\theta}\right)$ contém retângulos abertos, então $T(x) = \sum_{i=1}^n x_i$ é suficiente e completa.

$$\text{Temos que } p = \frac{1}{1+\theta} \text{ e } q = \frac{\theta}{1+\theta}$$

$$\Rightarrow E(X) = \frac{q}{p} = \frac{\theta/(1+\theta)}{1/(1+\theta)} = \theta \Rightarrow E(\bar{x}) = \theta$$

Assim, para $j=1$ e $j=2$, temos que \bar{x} é o ENVVUM de θ . Portanto \bar{x} é o ENVVUM de θ , $\forall j=1$ e $j=2$.

(17) Sejam x_1, \dots, x_n n observações independentes de X , que tem função de probabilidade

$$f_N(x) = P_N(x=x) = \frac{a(x)}{C(N)}, \quad x=1, 2, \dots, N,$$

em que N é inteiro positivo desconhecido, $a(x) > 0$, $C(N) = \sum_{x=1}^N a(x)$.

(a) Mostre que $x_{(n)} = \max(x_1, \dots, x_n)$ é uma estatística suficiente completa.

(b) Obtenha o estimador de máxima verossimilhança de N .

(a) Dada a f.p. de X , temos que se $\bar{x} = \{x_1, \dots, x_n\}$, então

$$\begin{aligned} P_N(\bar{x}) &= \prod_{i=1}^n P_N(x_i=x_i) = \prod_{i=1}^n \frac{a(x_i)}{C(N)} I_{[1,N]}(x_i) \\ &= \frac{\prod_{i=1}^n a(x_i)}{[C(N)]^n} \cdot I_{[1,N]}(x_{(n)}) \end{aligned}$$

Notação $[1, N]$
está errada, medida
 $\{1, 2, \dots, N\}$.

Logo, se $g_N(x_{(n)}) = [C(N)]^{-1} I_{[1,N]}(x_{(n)})$ e $h(\bar{x}) = \prod_{i=1}^n a(x_i)$, então, $x_{(n)}$ é uma estatística suficiente para N , pelo C.F.

Pois que $x_{(n)}$ seja completa temos que mostrar que para qualquer função f de $x_{(n)}$ a valores reais $E_N[f(x_{(n)})] = 0$, $\forall N \in \{1, 2, \dots\}$ então $f(x_{(n)}) = 0$, q.c.P.

De jeito, se $\forall N$

$$E_N[f(x_{(n)})] = 0 \Rightarrow \sum_{y=0}^N f_{x_{(n)}}(y) f(y) = 0$$

$$\text{Então, } f_{x_{(n)}}(y) = n \left[\frac{C(y)}{C(N)} \right]^{n-1} \frac{a(y)}{C(N)}, \quad y=1, \dots, N.$$

Como $a(y) > 0 \Rightarrow C(N) = \sum_{y=1}^N a(y) > 0$ e portanto $f_{x_{(n)}}(y) > 0$, $y=1, \dots, N$.

Assim, se $E_N[f(y)] = 0 \quad \forall N \in \{1, 2, \dots\}$, então se

$N=1$:

$$E_N[f(y)] = \underbrace{f_{x_{(n)}}(1)}_{>0} f(1) = 0 \Rightarrow f(1) = 0$$

$N=2$:

$$E_N[f(y)] = \underbrace{f_{x_{(n)}}(1)}_{=0} f(1) + \underbrace{f_{x_{(n)}}(2)}_{>0} f(2) = 0 \Rightarrow f(2) = 0$$

Assumindo que para $N=k \geq 2$, $E_N[f(y)] = 0 \Rightarrow f(y) = 0$ q.c.P. então, para

$N=k+1$ temos que

$$E_N[f(y)] = \sum_{y=0}^{k+1} f_{x_{(n)}}(y) f(y) = \underbrace{\sum_{y=0}^k f_{x_{(n)}}(y) f(y)}_{=0} + \underbrace{f_{x_{(n)}}(k+1) f(k+1)}_{>0} = 0$$

$$\Rightarrow f(k+1) = 0$$

Portanto, $\forall N \in \{1, 2, \dots\}$ $E_N[f(x_{(n)})] = 0 \Rightarrow f(x_{(n)}) = 0$, q.c.P. e assim $x_{(n)}$ é uma estatística completa para N .

(b) Dada a amostra \bar{x} de tamanho n , a função de verossimilhança de N é

$$L(N) = \prod_{i=1}^n \frac{a(x_i)}{[C(N)]^n} I_{[1,N]}(x_{(n)})$$

função de N ,
então melhor escrever a indicadora como $I_{\{x_{(n)}, x_{(n)+1}, \dots, N\}}(N)$
mas, $I_{[1,N]}(x_{(n)})$ é um ou zero, e dado a amostra $\prod_{i=1}^n a(x_i)$ é fixado, assim
maximizar $L(N)$ equivale a minimizar $C(N)$ e dado que $C(N)$ é crescente e $N \geq x_{(n)}$
o valor de maximiza $L(N)$ é $\hat{N} = x_{(n)}$. Portanto o estimador de máxima
verossimilhança de N é $\hat{N} = x_{(n)}$.

$$\rightarrow I_{\{1, 2, \dots, N\}}(x_{(n)}) = 1 \Leftrightarrow x_{(n)} \leq N \Leftrightarrow N \in \{x_{(n)}, x_{(n)+1}, \dots\}$$

$$\therefore I_{\{1, 2, \dots, N\}}(x_{(n)}) = I_{\{x_{(n)}, x_{(n)+1}, \dots\}}(N).$$

(2) Sejam x_1, \dots, x_n n observações independentes de uma distribuição exponencial $E(a, b)$, $a \in (-\infty, 0]$ e $b > 0$ é conhecido

(a) Mostre que $X_{(1)} = \min_{i \in \{1, \dots, n\}} x_i$ é uma estatística suficiente, mas não é completa.

$$f_a(x_i) = \frac{1}{b} \exp\left[-\frac{x_i - a}{b}\right] I_{[a, \infty)}(x_i)$$

$$\Rightarrow f_a(x_1, \dots, x_n) = \frac{1}{b^n} \exp\left[-\sum_{i=1}^n \frac{x_i - a}{b}\right] \prod_{i=1}^n I_{[a, \infty)}(x_i)$$

$$= \frac{1}{b^n} \exp\left[-\frac{n\bar{x}}{b} + \frac{na}{b}\right] \prod_{i=1}^n I_{[a, \infty)}(x_i)$$

$$= \frac{1}{b^n} \exp\left[\frac{na}{b}\right] I_{[a, \infty)}(x_{(1)}) \cdot \exp\left[-\frac{n\bar{x}}{b}\right]$$

$$= g_a(T(x)) h(x_1, \dots, x_n)$$

onde $T(x) = X_{(1)}$, $g_a(T(x)) = \frac{1}{b^n} \exp\left[\frac{na}{b}\right] I_{[a, \infty)}(x_{(1)})$

$h(x_1, \dots, x_n) = \exp\left[-\frac{n\bar{x}}{b}\right]$. Logo, $X_{(1)}$ é uma estatística suficiente.

Agora, vamos mostrar que $X_{(1)}$ não é completa. Temos que se $T = X_{(1)}$, então

$$E_a[g(T)] = 0 \quad \forall a < 0 \Leftrightarrow \frac{1}{b} \int_a^\infty g(t) \exp\left[-\frac{n}{b}(t-a)\right] dt = 0 \quad \forall a < 0$$

Escolhemos g como:

$$g(t) = \begin{cases} 0 & ; \text{se } a < t \leq 0 \\ ct+d; & \text{se } t > 0 \end{cases}$$

Logo,

$$E_a[g(T)] = 0 \quad \forall a < 0 \quad (\Leftrightarrow) \quad \frac{1}{b} \int_a^\infty (ct+d) \exp\left[-\frac{n}{b}(t-a)\right] dt = 0 \quad \forall a < 0$$

$$\Leftrightarrow c \int_0^\infty t \cdot \exp\left[-\frac{n}{b}t\right] dt + d \int_0^\infty \exp\left[-\frac{n}{b}t\right] dt = 0$$

$$\Leftrightarrow \frac{b^2 c}{n^2} \Gamma(1) + \frac{bd}{n} = 0$$

$$\Leftrightarrow \frac{bc}{n} + d = 0$$

Consideramos $c=1$ e $d=-\frac{b}{n}$. Então

$$g(t) = \begin{cases} 0 & ; \text{se } a < t \leq 0 \\ t - \frac{b}{n}; & \text{se } t > 0 \end{cases}$$

Note que $E_a[g(T)] = 0$, mas $g(T) \neq 0$. Portanto $X_{(1)}$ não é completa.

(b) Encontre o ENVVUM de a .

Sugestão: Considere $g(X_{(1)}) = (cX_{(1)} + d)I_{(-\infty, 0]}(X_{(1)})$, com c e d constantes. Mostre que $g(X_{(1)})$ é não correlacionado com os estimadores não viciados de zero.

Vamos caracterizar os estimadores não viciados do zero. Temos que $U(X_{(1)})$ é não viciado do zero se e só se $E[U(X_{(1)})] = 0$, $\forall a \in (-\infty, 0]$,

$$\Rightarrow \frac{n}{b} \int_a^{\infty} U(t) \exp\left[-\frac{n}{b}(t-a)\right] dt = 0 \quad \forall a \in (-\infty, 0]$$

Em particular, se $a=0$ temos que

$$\frac{n}{b} \int_0^{\infty} U(t) \exp\left[-\frac{n}{b}(t-a)\right] dt = 0$$

Se $a < 0$, então

$$\begin{aligned} \frac{n}{b} \int_a^0 U(t) \exp\left[-\frac{n}{b}(t-a)\right] dt &= \frac{n}{b} \int_a^0 U(t) \exp\left[-\frac{n}{b}(t-a)\right] dt - \frac{n}{b} \int_0^0 U(t) \exp\left[-\frac{n}{b}(t-a)\right] dt \\ &= 0 \end{aligned}$$

Logo $U(t)=0$ q.c. $\forall t \in (-\infty, 0]$, pois $U(t)$ não pode depender do parâmetro a . Isto mostra que o único estimador não viciado de zero deve ser o estimador nulo para $t \in (-\infty, 0]$.

Consideremos $g(X_{(1)}) = (cX_{(1)} + d)I_{(-\infty, 0]}(X_{(1)})$ e determinemos as constantes c e d de modo que $g(X_{(1)})$ seja não viciado para a , i.e., $E[g(X_{(1)})] = a$

$$E\left[(cX_{(1)} + d)I_{(-\infty, 0]}(X_{(1)})\right] = a \quad \forall a < 0 \Leftrightarrow \underbrace{\frac{n}{b} \int_a^{\infty} (ct+d) \exp\left[-\frac{n}{b}(t-a)\right] dt = a}_{*}$$

Fazendo, $u = ct+d \Rightarrow du = cdt$

$$dv = \exp\left[-\frac{n}{b}(t-a)\right] dt \Rightarrow v = -\frac{b}{n} \exp\left[-\frac{n}{b}(t-a)\right] \text{ em } *$$

Então,

$$E\left[(cX_{(1)} + d)I_{(-\infty, 0]}(X_{(1)})\right] = a \quad \forall a < 0 \Leftrightarrow$$

$$\frac{n}{b} \left\{ \frac{b}{n} (ct+d) \exp\left[-\frac{n}{b}(t-a)\right] \Big|_0^a + \frac{bc}{n} \int_a^0 \exp\left[-\frac{n}{b}(t-a)\right] dt \right\} = a$$

\Leftrightarrow

$$\frac{n}{b} \left\{ \frac{b}{n} (ac+d) - \frac{bd}{n} \exp\left[\frac{na}{b}\right] + \frac{bc}{n^2} \exp\left[-\frac{n}{b}(t-a)\right] \Big|_0^a \right\} = a$$

\Leftrightarrow

$$ac + d - d \exp\left[\frac{na}{b}\right] + \frac{bc}{n} - \frac{bc}{n} \exp\left[\frac{na}{b}\right] = a$$

\Leftrightarrow

$$ac - \left(\frac{bc}{n} + d\right) \exp\left[\frac{na}{b}\right] + \left(\frac{bc}{n} + d\right) = a \Leftrightarrow c=1 \text{ e } \frac{bc}{n} + d = 0 \Rightarrow d = -\frac{b}{n}$$

Portanto $g(X_{(1)}) = \left(X_{(1)} - \frac{b}{n}\right) I_{(-\infty, 0]}(X_{(1)})$ é o estimador não viciado de a .

para provar que $g(x_{ii})$ é o ENVVUM mostraremos que ele é não
correlacionado com os estimadores não viésados do zero, os quais são os
 $\tilde{U}(x_{ii})$ tais que $\tilde{U}(x_{ii}) = 0$, se $X_{ii} < 0$. Assim,

$$E[g(x_{ii}) \times \tilde{U}(x_{ii})] = E(0) = 0.$$

Portanto, $g(x_{ii}) = (X_{ii} - \frac{b}{n}) I_{[0, \infty]}(x_{ii})$ é o ENVVUM de a .

9.8

MAE 5834 - Estatística Avançada I

Lista de Exercícios 3 - 2º semestre de 2014

Prof. Silvia L. P. Ferrari,

Alunos: Mario José Pacheco López - 9034481

Hugo Alberto Brango García - 9196006

IME - USP , 06/10/2014 .

① Seja X uma variável aleatória com função de probabilidade

$$f_\theta(x) = P_\theta(X=x) = \frac{a(x)\theta^x}{C(\theta)}, \quad x=0,1,\dots; \quad (1)$$

$a(x) \geq 0 \in \theta \in \mathbb{R} \subset \mathbb{R}^+$; $C(\theta) = \sum_{x=0}^{\infty} a(x)\theta^x < \infty$ (distribuição de série de potências). Considere uma amostra de uma única observação de x . Obs. Quando necessário você pode fazer alguma suposição sobre o espaço paramétrico.

(a) Obtenha o limite inferior de Cramér-Rao para a variação de estimadores não viésados de θ^r , r inteiro positivo.

Seja $\delta(x)$ um estimador não viésado de $g(\theta) = \theta^r$, r inteiro positivo, então

$$\text{Var}_\theta(\delta) \geq \frac{[g'(\theta)]^2}{I(\theta)}$$

Seja $\theta \neq 0$.

$$\log f_\theta(x) = \log \left[\frac{a(x)\theta^x}{C(\theta)} \right] = \log a(x) + x \log \theta - \log C(\theta)$$

$$\Rightarrow \frac{\partial}{\partial \theta} \log f_\theta(x) = \frac{x}{\theta} - \frac{C'(\theta)}{C(\theta)}, \quad C'(\theta) = \frac{\partial C(\theta)}{\partial \theta}$$

$$\text{mas, } C(\theta) = \sum_{x=0}^{\infty} a(x)\theta^x < \infty \Rightarrow C'(\theta) = \sum_{x=0}^{\infty} a(x)x\theta^{x-1}$$

$$\begin{aligned} \Rightarrow \frac{\partial^2}{\partial \theta^2} \log f_\theta(x) &= -\frac{x}{\theta^2} - \frac{C''(\theta)C(\theta) - [C'(\theta)]^2}{[C(\theta)]^2} \\ &= -\frac{x}{\theta^2} - \frac{C''(\theta)}{C(\theta)} + \frac{[C'(\theta)]^2}{[C(\theta)]^2}, \quad C''(\theta) = \frac{\partial^2 C(\theta)}{\partial \theta^2} \end{aligned}$$

$$\Rightarrow I(\theta) = E\left[-\frac{\partial^2}{\partial \theta^2} \log f_\theta(x)\right] = \frac{E(x)}{\theta^2} + \frac{C''(\theta)}{C(\theta)} - \left[\frac{C'(\theta)}{C(\theta)}\right]^2$$

$$\text{mas, } E_\theta(x) = \sum_{x=0}^{\infty} x \frac{a(x)\theta^x}{C(\theta)} = \frac{\theta}{C(\theta)} \sum_{x=0}^{\infty} a(x)x\theta^{x-1} = \frac{\theta C'(\theta)}{C(\theta)}$$

Então,

$$I(\theta) = \frac{C'(\theta)}{\theta C(\theta)} + \frac{C''(\theta)}{C(\theta)} - \left[\frac{C'(\theta)}{C(\theta)} \right]^2, \quad \theta \neq 0$$

mas,

$$\theta C'(\theta) = \sum_{x=0}^{\infty} x a(x) \theta^x = C(\theta) E_\theta(x) \Rightarrow E_\theta(x) = \frac{\theta C'(\theta)}{C(\theta)}$$

$$\theta^2 C''(\theta) = \sum_{x=0}^{\infty} x(x-1)a(x)\theta^x = \sum_{x=0}^{\infty} x^2 a(x)\theta^x - \sum_{x=0}^{\infty} x a(x)\theta^x = C(\theta) E(x^2) - C(\theta) E(x)$$

$$= C(\theta) [E(x^2) - E(x)] \Rightarrow [E(x^2) - E(x)] = \frac{\theta^2 C''(\theta)}{C(\theta)}$$

$$\Rightarrow I(\theta) = \frac{E(x)}{\theta^2} + \frac{E(x^2) - E(x)}{\theta^2} - \left[\frac{E(x)}{\theta} \right]^2 = \frac{1}{\theta^2} [E(x^2) - [E(x)]^2]$$

$$= \frac{1}{\theta^2} \text{Var}_\theta(x), \quad \theta \neq 0$$

Logo, como $g'(\theta) = r\theta^{r-1}$, então o LICR é

$$\text{Var}_\theta(\delta(x)) \geq \frac{r^2 \theta^{2(r-1)}}{\frac{1}{\theta^2} \text{Var}_\theta(x)} = \frac{r^2 \theta^{r+2}}{\text{Var}_\theta(x)}, \quad \theta \neq 0.$$

Eua que,

$$\text{Var}_\theta(x) = \sum_{x=0}^{\infty} x^2 \frac{a(x)\theta^x}{C(\theta)} - \left[\sum_{x=0}^{\infty} x \frac{a(x)\theta^x}{C(\theta)} \right]^2$$

(b) Mostre que se $a(x) > 0$ para todo $x=0,1,\dots$ então θ^r é estimável para qualquer r inteiro positivo e seu estimador não viésado de variação uniforme mínima (ENVVUM) é

$$\delta_r(x) = \begin{cases} 0, & x=0,\dots,r-1 \\ \frac{a(x-r)}{a(x)}, & x=r,r+1,\dots \end{cases}$$

Temos que, se $a(x) > 0 \forall x=0,1,\dots$, então

$$\begin{aligned} E_\theta(\delta_r(x)) &= \sum_{x=r}^{\infty} \frac{a(x-r)}{a(x)} \frac{a(x)\theta^x}{C(\theta)} = \sum_{x=r}^{\infty} \frac{a(x-r)\theta^x}{C(\theta)} = \sum_{y=0}^{\infty} \frac{a(y)\theta^{y+r}}{C(\theta)} = \theta^r \sum_{y=0}^{\infty} \frac{a(y)\theta^y}{C(\theta)} \\ &= \theta^r \end{aligned}$$

Seria interessante calcular $\text{Var}_\theta(\delta_r(x))$.

então, $S_r(x)$ é não viésado para θ^r , portanto $g(\theta) = \theta^r$ é estimável, para qualquer r inteiro positivo.

Também,

$$f_\theta(x) = \frac{a(x)\theta^x}{c(\theta)} = \exp\{\alpha \log \theta - \log c(\theta)\} a(x), \quad \theta > 0$$

e se $a(x) > 0, \forall x=0,1,\dots$, então $f_\theta(x)$ pertence à família exponencial unidimensional, com $\eta(\theta) = \log \theta$, $T(x) = x$, $B(\theta) = \log c(\theta)$ e $h(x) = a(x)$, ou à família na forma canônica, com $\eta = \log(\theta)$ e $A(\eta) = \log c(e^\eta)$, e dado que nem T nem η satisfazem restrições lineares, e o espaço paramétrico para η contém intervalos então a distribuição $f_\theta(x)$ pertence à família exponencial canônica de posto completo, portanto $T(x)$ é uma estatística suficiente e completa para θ , e dado que $S_r(x)$ é função de $T(x)$ e é não viésado a estatística $S_r(x)$ é o ENVVUM para θ^r .

(c) Dizemos que X tem distribuição binomial negativa com parâmetros p e m ($0 < p < 1$, m inteiro positivo) se sua função de probabilidade é

$$P_{p,m}(x=x) = \binom{m+x-1}{m-1} p^m (1-p)^x, \quad x=0,1,\dots$$

e escrevemos $X \sim BN(p,m)$. Admitindo que m é conhecido, obtenha o ENVVUM de p baseado em uma única observação de $X \sim BN(p,m)$ usando (b).

Se m é conhecido, dada uma a.a. de tamanho um de $BN(p,m)$, então

$$P_p(x=x) = \binom{m+x-1}{m-1} p^m (1-p)^x, \quad x=0,1,\dots, p \in (0,1), m \text{ inteiro positivo.}$$

Então

$$P_\theta(x=x) = \binom{m+x-1}{m-1} (1-\theta)^m \theta^x, \quad x=0,1,\dots, \theta \in (0,1)$$

e dado que, para $y \neq 1$, $\frac{1}{(1-y)^s} = \sum_{k=0}^{\infty} \binom{s+k-1}{s-1} y^k$, s inteiro positivo,

então,

$$P_\theta(x=x) = \frac{\binom{m+x-1}{m-1} \theta^x}{\sum_{k=0}^{\infty} \binom{m+x-1}{m-1} \theta^x} = \frac{a(x) \theta^x}{\sum_{k=0}^{\infty} a(x) \theta^x} = \frac{a(x) \theta^x}{c(\theta)}, \quad x=0,1,\dots, \theta \in (0,1)$$

então que $a(x) = \binom{m+x-1}{m-1} > 0$ e $c(\theta) = \sum_{k=0}^{\infty} a(x) \theta^x < \infty$.

Assim, X tem distribuição de série de potências e o ENVVUM de θ é

Por (b)

$$\delta(x) = ?$$

$$a(x) = ?$$

$$\delta(x) = \begin{cases} 0, & x=0 \\ \frac{a(x-1)}{a(x)}, & x=1,2,\dots \end{cases} \rightarrow \underline{\text{Calcular!}}$$

Logo, dado que $p = 1-\theta$, seja $T(x) = 1-\delta(x)$. Como $E(T(x)) = 1-\theta = p$ e $T(x)$ é também função de x , estatística suficiente completa, então $T(x)$ é o ENVVUM de p .

Notar aqui que: $f_p(x) = \frac{a(x)(1-p)^x}{c(p)} = \exp\{\alpha \log(1-p) - \log c(p)\} a(x)$ também pertence à família exponencial de posto completo, com parâmetro natural $\eta = \log(1-p)$, $T(x) = x$, $A(\eta) = \log c(1-e^\eta)$ e $h(x) = a(x)$, portanto X é suf. completa para p .

(d) Considere agora uma amostra x_1, \dots, x_n de observações independentes da distribuição (1).

Mostre que se $a(x) > 0$ para todo $x=0,1,\dots$, então θ^r é estimável para qualquer r inteiro positivo e encontre seu ENVVUM.

Dada a a.a. da distribuição (1), temos que

$$f_{\theta}(\underline{x}) = \prod_{i=1}^n f_{\theta}(x_i) = \prod_{i=1}^n \frac{a(x_i) \theta^{x_i}}{c(\theta)} = \frac{\gamma_n(\underline{x}) \theta^{\sum_{i=1}^n x_i}}{[c(\theta)]^n}$$

$$= \exp \left\{ (\log \theta) \sum_{i=1}^n x_i - n \log c(\theta) \right\} \gamma_n(\underline{x}) , \quad \gamma_n(\underline{x}) = \prod_{i=1}^n a(x_i)$$

Assim, $f_{\theta}(\underline{x})$ pertence a família exponencial com $\eta(\theta) = \log \theta$, $T(\underline{x}) = \sum_{i=1}^n x_i$, $B(\theta) = n \log c(\theta)$ e $h(\underline{x}) = \gamma_n(\underline{x})$. Além disso, nem o parâmetro natural $\eta = \log \theta$ nem a estatística $T(\underline{x})$ satisfazem restrições lineares, e o espaço paramétrico para η contém intervalos, então $T(\underline{x}) = \sum_{i=1}^n x_i$ é uma estatística suficiente completa para θ .

Por outro lado,

$$M_T(t) = E_{\theta} [e^{tT}] = E_{\theta} \left[e^{t \sum_{i=1}^n x_i} \right] = E_{\theta} \left[\prod_{i=1}^n e^{tx_i} \right] \stackrel{\text{ind}}{=} \prod_{i=1}^n E_{\theta} [e^{tx_i}] \stackrel{i.i.d.}{=} [E(e^{tx})]^n$$

$$= \left[\sum_{x=0}^{+\infty} e^{tx} \frac{a(x) \theta^x}{c(\theta)} \right]^n = \frac{1}{[c(\theta)]^n} \left[\sum_{y=0}^{+\infty} a(y) (\theta e^t)^y \right]^n = \frac{[c(\theta e^t)]^n}{[c(\theta)]^n} \quad (1)$$

Também, seja $P_{\theta}(Y=y) = \frac{\gamma_n(y) \theta^y}{[c(\theta)]^n}$, $y=0,1,\dots$, com $\sum_{y=0}^{+\infty} \gamma_n(y) \theta^y = [c(\theta)]^n$

com $\gamma_n(y)$ o coeficiente de θ^y na expansão de série de potência de $[c(\theta)]^n$, então

$$M_Y(t) = E_{\theta} [e^{ty}] = \sum_{y=0}^{+\infty} \frac{\gamma_n(y) (\theta e^t)^y}{[c(\theta)]^n} = \frac{[c(\theta e^t)]^n}{[c(\theta)]^n} \quad (2)$$

Assim, de (1) e (2), $T = \sum_{i=1}^n x_i$, distribuição de séries de potências ($M_Y(t) = M_T(t)$)

$$P_{\theta}(T=t) = \frac{\gamma_n(t) \theta^t}{[c(\theta)]^n}, \quad t=0,1,\dots$$

Então, um estimador de θ^r é

$$\delta_r(T) = \begin{cases} 0, & T < r \\ \frac{\gamma_n(T-r)}{\gamma_n(T)}, & T \geq r \end{cases}$$

com,

$$E_{\theta}(\delta_r(T)) = \sum_{t=r}^{+\infty} \frac{\gamma_n(t-r)}{\gamma_n(t)} \frac{\gamma_n(t) \theta^t}{[c(\theta)]^n} \underset{y=t-r}{\int} = \sum_{y=0}^{+\infty} \frac{\gamma_n(y) \theta^{y+r}}{[c(\theta)]^n} = \theta^r \sum_{y=0}^{+\infty} \frac{\gamma_n(y) \theta^{y+r}}{[c(\theta)]^n} = \theta^r$$

Assim, temos que $T = \sum_{i=1}^n x_i$ é uma estatística suficiente e completa para θ e $\delta_r(T)$ é não viésado para $g(\theta) = \theta^r$, $r=1,2,\dots$, por tanto $\delta_r(T)$ é ENVVUM de θ^r .

(3)

3) Suponha que X_1, \dots, X_n sejam variáveis aleatórias iid com distribuição $\mathcal{U}(0, \theta)$, $\theta > 0$.

(a) Mostre que

$$\frac{d}{d\theta} \int_0^\theta x f_\theta(x) dx \neq \int_0^\theta x \frac{d}{d\theta} f_\theta(x) dx$$

em que f_θ é a densidade de $X_{(n)}$, a maior estatística de ordem.

Solução:

$$X_{(n)} = \max\{x_1, \dots, x_n\}$$

$$P[X_{(n)} \leq x] = P[X_1 \leq x, \dots, X_n \leq x] = \prod_{i=1}^n P[X_i \leq x] = [F_{X_1}(x)]^n \quad (1)$$

$$F_{X_1}(x) = \int_0^x \frac{1}{\theta} dx_1 = \frac{1}{\theta} x_1 \Big|_0^x = \frac{x}{\theta} \Rightarrow F_{X_1}(x) = \frac{x}{\theta} I_{(0, \theta)}(x) \quad (2)$$

$$\text{Por (1) e (2) temos que: } F_{X_{(n)}}(x) = \frac{x^n}{\theta^n} I_{(0, \theta)}(x)$$

$$\Rightarrow f_{X_{(n)}}(x) = \frac{d}{dx} F_{X_{(n)}}(x) = \frac{n x^{n-1}}{\theta^n} I_{(0, \theta)}(x) \Rightarrow f_{X_{(n)}}(x) = \frac{n x^{n-1}}{\theta^n} I_{(0, \theta)}(x)$$

$$\begin{aligned} \Rightarrow \frac{d}{d\theta} \int_0^\theta x f_{X_{(n)}}(x) dx &= \frac{d}{d\theta} \int_0^\theta x \frac{n x^{n-1}}{\theta^n} I_{(0, \theta)}(x) dx = \frac{d}{d\theta} \frac{n}{\theta^n} \int_0^\theta x^n dx = \frac{d}{d\theta} \frac{n}{\theta^n} \left[\frac{x^{n+1}}{n+1} \right]_0^\theta \\ &= \frac{d}{d\theta} \frac{n}{\theta^n} \frac{\theta^{n+1}}{n+1} = \frac{d}{d\theta} \frac{n}{\theta^{n+1}} \theta = \frac{n}{n+1} \end{aligned}$$

$$\Rightarrow \frac{d}{d\theta} \int_0^\theta x f_\theta(x) dx = \frac{n}{n+1} \quad (3)$$

$$\cdot \int_0^\theta x \frac{d}{d\theta} f_\theta(x) dx = \int_0^\theta x \left[\frac{d}{d\theta} \frac{n x^{n-1}}{\theta^n} \right] dx = \int_0^\theta n x^n \left[\frac{d}{d\theta} \frac{1}{\theta^n} \right] dx$$

$$= \int_0^\theta n x^n (-n) \theta^{-n-1} dx = -\frac{n^2}{\theta^{n+1}} \int_0^\theta x^n dx =$$

$$= -\frac{n^2}{\theta^{n+1}} \cdot \frac{x^{n+1}}{n+1} \Big|_0^\theta = -\frac{n^2}{\theta^{n+1}} \cdot \frac{\theta^{n+1}}{n+1}$$

$$\Rightarrow \int_0^\theta x \frac{d}{d\theta} f_\theta(x) dx = -\frac{n^2}{n+1} \quad (4)$$

Por (3) e (4) temos que:

$$\frac{d}{d\theta} \int_0^\theta x f_\theta(x) dx \neq \int_0^\theta x \frac{d}{d\theta} f_\theta(x) dx$$

(b) Mostre que a desigualdade da informação vale para o ENVVUM de θ .

Nesse caso, $\delta(x) = \frac{n+1}{n} x_{(n)}$ é o ENVVUM de θ

$$\cdot f_{X_{(n)}}(x) = \frac{1}{\theta} I_{(0, \theta)}(x) \Rightarrow \lambda(\theta) = \log f_{X_{(n)}}(x) = -\log \theta \Rightarrow \frac{d\lambda(\theta)}{d\theta} = -\frac{1}{\theta}$$

$$\cdot I(\theta) = E_{\theta} \left[\left(\frac{d\lambda(\theta)}{d\theta} \right)^2 \right] = E_{\theta} \left[\frac{1}{\theta^2} \right] = \frac{1}{\theta^2}$$

$$\Rightarrow I(\theta) = n I_1(\theta) = \frac{n}{\theta^2} \text{ onde } I_1(\theta) \text{ é a informação sobre } \theta \text{ contida em } x_{(n)}$$

$$\cdot \text{Var}(\delta(x)) = \frac{(n+1)^2}{n^2} \text{Var}(X_{(n)})$$

$$\text{Note que, } \frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1) \Rightarrow \text{Var}\left(\frac{X_{(n)}}{\theta}\right) = \frac{(n)(1)\theta^2}{(n+1)^2(n+1)} = \frac{n}{(n+1)^2(n+1)}\theta^2$$

Portanto

$$\text{Var}(g(x)) = \frac{(n+1)^2}{n} \cdot \frac{n}{(n+1)^2} \cdot \frac{\theta^2}{(n+1)} = \frac{\theta^2}{n(n+1)} \quad (6)$$

Supor que a desigualdade da informação de Fisher é verdadeira, em nesse caso, então

Por (5) e (6) temos

$$\text{Var}_\theta(\delta(x)) \geq \frac{[g'(\theta)]^2}{I(\theta)}, \text{ onde } g(\theta) = \theta$$

$$\Leftrightarrow \frac{\theta^2}{n(n+1)} \geq \frac{(\frac{1}{\theta})^2}{\frac{n}{\theta}} = \frac{\theta^2}{n} \Leftrightarrow \frac{1}{n+1} \geq \frac{1}{n}$$

$$\Leftrightarrow 1 \geq n+1 \quad (\rightarrow \leftarrow)$$

Assim, a desigualdade da informação não vale para o ENNUM de θ .

$$[\text{Justificacão *}] \quad X \sim U(0, \theta) \Rightarrow f_x(x) = \frac{1}{\theta} I_{(0,\theta)}(x) \text{ e } f_{X_{(n)}}(x) = \frac{n x^{n-1}}{\theta^n} I_{(0,\theta)}(x)$$

$$\text{Se } E[g(X_{(n)})] = 0 \Rightarrow \int_0^\theta g(t) f_{X_{(n)}}(t) dt = \int_0^\theta g(t) \frac{n t^{n-1}}{\theta^n} dt = \frac{n}{\theta^n} \int_0^\theta g(t) t^{n-1} dt = 0$$

$$\Rightarrow \int_0^\theta g(t) t^{n-1} dt = 0 \Rightarrow g(t) = 0 \quad \text{a.c. } \forall \theta \in (0, \infty)$$

Assim, $X_{(n)}$ é uma estatística completa.

$$\bullet f(x) = \prod_{i=1}^n \frac{1}{\theta} I_{(0,\theta)}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n I_{(0,\theta)}(x_i)$$

$$\text{onde } \prod_{i=1}^n I_{(0,\theta)}(x_i) = 1 \Leftrightarrow 0 < x_i < \theta, \quad \forall i = 1, \dots, n$$

$$\Leftrightarrow 0 < X_{(n)} < \theta$$

$$\Leftrightarrow I_{(0,\theta)}(X_{(n)}) = 1$$

$$\Rightarrow f(x) = \frac{1}{\theta^n} I_{(0,\theta)}(X_{(n)}). 1 = g_\theta(X_{(n)}) h(x) \text{ Sendo, } g_\theta(X_{(n)}) = \frac{1}{\theta^n} I_{(0,\theta)}(X_{(n)}) \text{ e } h(x) = 1$$

∴ Pelo critério da factorização temos que $X_{(n)}$ é uma estatística suficiente

$$\bullet E(X_{(n)}) = \frac{n}{n+1}\theta \Rightarrow E\left(\frac{n+1}{n} X_{(n)}\right) = \theta$$

$$\text{então } \boxed{g(x) = \frac{n+1}{\theta} X_{(n)}} \text{ é não-viciado para } \theta.$$

$$\text{portanto, } \boxed{\delta(x) = \frac{n+1}{\theta} X_{(n)}} \text{ é o ENNUM de } \theta.$$

$\delta(x)$ não pode depender de θ .

5) Seja $X = (X_1, \dots, X_n)$ amostra aleatória X que tem função densidade de probabilidade

$$f(x; \alpha, \theta) = \theta \alpha^{\theta} x^{-(\theta+1)} I_{(0, \infty)}(x),$$

em que $\alpha \in (0, 1]$ e $\theta > 0$.

(a) Supondo α conhecido, encontre a informação de Fisher para θ .

$$\begin{aligned} l(\theta) &= \log f(x; \alpha, \theta) = \log \theta + \log \alpha - (\theta+1) \log x \\ &= \log \theta + \log \alpha - \theta \log x - \log x \end{aligned}$$

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{1}{\theta} + \log \alpha - \log x \Rightarrow \frac{\partial^2 l(\theta)}{\partial \theta^2} = -\frac{1}{\theta^2}$$

$$\Rightarrow I_1(\theta) = E_{\theta} \left[-\frac{\partial^2 l(\theta)}{\partial \theta^2} \right] = \frac{1}{\theta^2}$$

$$\Rightarrow I(\theta) = n I_1(\theta) = \frac{n}{\theta^2} \text{ onde } I_1(\theta) \text{ é a informação sobre } \theta \text{ contida em } x_1.$$

$\therefore I(\theta) = \frac{n}{\theta^2}$ é a informação de Fisher para θ .

(b) Mostre que o estimador não viésado de variância uniformemente mínima de α , quando θ é conhecido, é

$$\hat{\alpha} = I_{(1, \infty)}(x_{(1)}) + \left(1 - \frac{1}{n\theta}\right) x_{(1)} I_{[0, 1]}(x_{(1)}),$$

em que $x_{(1)} = \min(X_1, \dots, X_n)$.

Sugestão: Mostre que $x_{(1)}$ é uma estatística suficiente e caracterize a classe de estimadores não viésados do zero, que sejam funções de $x_{(1)}$.

Vamos determinar a classe dos estimadores não viésados de zero, isto é

$$U = \{U, E(U) = 0, E(U^2) < \infty, U \in \mathcal{S}\}$$

Notemos que,

$$f(x) = \prod_{i=1}^n f(x_i) = \theta^n \alpha^{n\theta} \prod_{i=1}^n x_i^{-(\theta+1)} I_{(0, \infty)}(x_i) \text{ onde } \prod_{i=1}^n I_{(0, \infty)}(x_i) = 1 \Leftrightarrow 0 < x_i < \infty \forall i \Leftrightarrow x_{(1)} > a \forall i \Leftrightarrow I_{(a, \infty)}(x_{(1)})$$

$$\Rightarrow f(x) = \underbrace{\theta^n \alpha^{n\theta} I_{(0, \infty)}(x_{(1)})}_{g_\theta(x_{(1)})} \underbrace{\prod_{i=1}^n x_i^{-(\theta+1)}}_{h(x)} = g_\theta(x_{(1)}) h(x)$$

Pelo critério da factorização $T(x) = X_{(1)}$ é uma estatística suficiente para α .

Agora, vamos encontrar a distribuição de $X_{(1)}$.

Temos que a distribuição para o j -ésimo estatístico de ordem é

$$f_{X_{(j)}}(x) = \frac{n!}{(n-j)!} f_X(x) [1 - F_X(x)]^{n-j} \text{ para } j=1, \text{ então}$$

$$f_{X_{(1)}}(x) = n f_X(x) [1 - F_X(x)]^{n-1} \quad (1)$$

onde

$$F_X(x) = \int_a^x \theta a^\theta t^{-(\theta+1)} dt = \theta a^\theta \int_a^x t^{-\theta-1} dt = \theta a^\theta \frac{t^{-\theta}}{-\theta} \Big|_a^x = -a^\theta (x^\theta - a^\theta) = 1 - a^\theta x^\theta, \theta > 0, a \in (0, 1]$$

$$\begin{aligned} \Rightarrow f_{X_{(1)}}(x) &= n \theta a^\theta x^{-(\theta+1)} [1 - (1 - a^\theta x^\theta)]^{n-1} \text{ por (1)} \\ &= n \theta a^\theta x^{-(\theta+1)} (a^\theta x^\theta)^{n-1} \\ &= n \theta a^{\theta(n-1)} x^{-\theta-1-n\theta+\theta} \\ &= n \theta a^{n\theta-1} x^{-(n\theta+1)} \end{aligned}$$

$$\Rightarrow f_{X_{(1)}}(x) = n \theta a^{n\theta-1} x^{-(n\theta+1)}, a \in (0, 1], \theta > 0, x > a$$

Agora, vamos determinar U , resolvendo a equação $E[g(x_{(1)})] = 0$.

$$0 = E[g(x_{(1)})] = \int_a^\infty g(t) n\theta a^{n\theta} t^{-(n\theta+1)} dt = n\theta a^{n\theta} \int_a^\infty g(t) t^{-(n\theta+1)} dt$$

$$\Rightarrow \int_a^\infty g(t) t^{-(n\theta+1)} dt = 0. \quad \text{Como } a \in (0, 1] \text{ temos}$$

$$0 = \int_a^1 g(t) t^{-(n\theta+1)} dt + \int_1^\infty g(t) t^{-(n\theta+1)} dt = 0 \quad \forall a \in (0, 1]$$

$$\text{Fazendo } a=1 \Rightarrow \int_1^\infty g(t) t^{-(n\theta+1)} dt = 0 \Rightarrow \int_a^1 g(t) t^{-(n\theta+1)} dt = 0$$

Portanto, a classe de estimadores não viésados do zero é dada por

$$\boxed{\left. \begin{array}{l} U = \left\{ g(x_{(1)}) = 0, \text{ q.c em } (0, 1) \text{ com } \int_1^\infty g(t) t^{-(n\theta+1)} dt = 0 \right\} \end{array} \right.} \quad \checkmark$$

Note que,

$$E[\hat{\alpha}] = \int_1^\infty \frac{n\theta a^{n\theta}}{t^{n\theta+1}} dt + \left(1 - \frac{1}{n\theta}\right) \int_a^1 t \frac{n\theta a^{n\theta}}{t^{n\theta+1}} dt$$

$$= n\theta a^{n\theta} \int_1^\infty t^{-n\theta-1} dt + (n\theta-1)a^{n\theta} \int_a^1 t^{n\theta} dt$$

$$= n\theta a^{n\theta} \left[\frac{t^{-n\theta}}{-n\theta} \right]_1^\infty + (n\theta-1)a^{n\theta} \left[\frac{t^{n\theta+1}}{n\theta+1} \right]_a^1 = a^{n\theta} - \frac{n\theta-1}{n\theta+1} a^{n\theta} [1 - \bar{a}^{n\theta+1}]$$

$$= a^{n\theta} - a^{n\theta} - a^{n\theta} \bar{a}^{n\theta+1} = a$$

$\Rightarrow \hat{\alpha}$ é não viésado para a .

Como $E\left(\frac{\partial}{\partial \theta} \log P_\theta(x)\right) = 0$, então

$$I(\theta) = E\left[\left(\frac{\partial}{\partial \theta} \log P_\theta(x)\right)^2\right] - \left[E\left(\frac{\partial}{\partial \theta} \log P_\theta(x)\right)\right]^2 = \text{Var}\left(\frac{\partial}{\partial \theta} \log P_\theta(x)\right)$$

Sabemos que:

$$P(Z, Y) \leq 1 \Rightarrow \frac{\text{Cov}(Z, Y)}{\sqrt{\text{Var}(Z)} \sqrt{\text{Var}(Y)}} \leq 1$$

$$\Rightarrow \text{Cov}(Z, Y) \leq \sqrt{\text{Var}(Z)} \sqrt{\text{Var}(Y)} \Rightarrow [\text{Cov}(Z, Y)]^2 \leq \text{Var}(Z) \text{Var}(Y)$$

Tomando, $Z = \delta(x)$ e $Y = \frac{\partial}{\partial \theta} \log P_\theta(x)$, temos

$$\text{Cov}(\delta(x), \frac{\partial}{\partial \theta} \log P_\theta(x)) = E\left(\delta(x) \frac{\partial}{\partial \theta} \log P_\theta(x)\right) - E(\delta(x)) E\left(\frac{\partial}{\partial \theta} \log P_\theta(x)\right)$$

$$= E\left(\delta(x) \frac{\partial}{\partial \theta} \log P_\theta(x)\right)$$

$$= \int \delta(x) \frac{\partial}{\partial \theta} \log P_\theta(x) P_\theta(x) dx = \int \delta(x) \frac{\frac{\partial}{\partial \theta} P_\theta(x)}{P_\theta(x)} P_\theta(x) dx$$

$$= \frac{\partial}{\partial \theta} \int \delta(x) P_\theta(x) dx = \frac{\partial}{\partial \theta} E(\delta(x))$$

$$\Rightarrow \text{Cov}^2(\delta(x), \frac{\partial}{\partial \theta} \log P_\theta(x)) = \left[\frac{\partial}{\partial \theta} E(\delta(x)) \right]^2$$

Como,

$$E(g(x_{(1)}), \hat{\alpha}) = E\left(g(x_{(1)}) I_{(1, \infty)}(x_{(1)})\right) + \left(1 - \frac{1}{n\theta}\right) E\left(x_{(1)} g(x_{(1)}) I_{(0, 1)}(x_{(1)})\right)$$

$$= \int_1^\infty g(t) \int_{x_{(1)}}(t) dt + \left(1 - \frac{1}{n\theta}\right) \int_a^1 g(t) \cdot t \int_{x_{(1)}}(t) dt$$

$$= \int_1^\infty g(t) \cdot \int_{x_{(1)}}(t) dt = 0 \quad \text{por (2)}$$

Como $\hat{\alpha}$ é não viésado para a e $E[g(x_{(1)}) \cdot \hat{\alpha}] = 0$, então $\hat{\alpha}$ é o ENVVUM da a.

19) Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes cada qual com densidade $f(x-\xi)$, $\xi \in \mathbb{R}$, e $f(x) = \exp\{-(\alpha+1)x\}$, $x > -1$

(a) Encontre o estimador de máxima verossimilhança $\delta(x)$ de ξ e verifique que é equivariante.

$$f(x) = \exp\{-(\alpha+1)x\} I_{(-1, \infty)}(x)$$

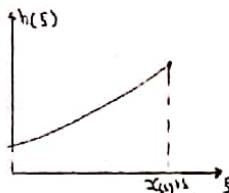
$$L(\xi) = \prod_{i=1}^n \exp\{-(\alpha+1)x_i\} I_{(-1, \infty)}(x_i) = \exp\{-n\bar{x} + n\xi - n\} \prod_{i=1}^n I_{(-1, \infty)}(x_i)$$

onde,

$$\begin{aligned} \prod_{i=1}^n I_{(-1, \infty)}(x_i) = 1 &\iff -1 \leq x_i \quad \forall i \\ &\iff \xi \leq x_{(1)} + 1 \\ &\iff I_{(-\infty, x_{(1)} + 1)}(\xi) \end{aligned}$$

$$\Rightarrow f(x) = \exp\{-(n\bar{x} + n)\} \exp\{n\xi\} I_{(-\infty, x_{(1)} + 1)}(\xi)$$

Assim, $\delta(x) = x_{(1)} + 1$ é EMV pois a função exponencial é crescente em \mathbb{R} .



$$\begin{aligned} \bullet \delta(x_1 + a, \dots, x_n + a) &= \min\{x_1 + a, \dots, x_n + a\} + 1 \\ &= \min\{x_1, \dots, x_n\} + 1 + a \\ &= \delta(x_1, \dots, x_n) + a \end{aligned}$$

\therefore O estimador de máxima verossimilhança $\delta(x) = x_{(1)} + 1$ de ξ é equivariante

b) Encontre a distribuição de $n(\delta(x) - \xi)$. Mostre que $\delta(x)$ é um estimador viciado de ξ e obtenha seu risco sob perda quadrática.

Seja $y = n(\delta(x) - \xi)$

$$\begin{aligned} F_y(y) &= P[Y \leq y] = P[n(\delta(x) - \xi) \leq y] = P[\delta(x) \leq \frac{y}{n} + \xi] \\ &= P[x_{(1)} + 1 \leq \frac{y}{n} + \xi] = P[x_{(1)} \leq \frac{y}{n} + \xi - 1] \\ &= 1 - P[x_{(1)} > \frac{y}{n} + \xi - 1] = 1 - [P(x_1 > \frac{y}{n} + \xi - 1)]^n \\ &= 1 - [1 - P(x_1 \leq \frac{y}{n} + \xi - 1)]^n \end{aligned}$$

onde:

$$\begin{aligned} P(x_1 \leq \frac{y}{n} + \xi - 1) &= \int_{-\xi+1}^{\frac{y}{n}+\xi-1} \exp\{-x_1 - \xi\} dx \\ &= \int_0^{-y/\ln} \exp\{u\} du = \int_{y/\ln}^0 \exp\{u\} du \\ &= \exp\{u\} \Big|_{y/\ln}^0 = \exp\{0\} - \exp\{-y/\ln\} \\ &= 1 - \exp\{-y/\ln\} \end{aligned}$$

$$\boxed{\begin{aligned} U &= -x_1 - \xi \\ du &= -dx \end{aligned}}$$

$$\begin{aligned} \Rightarrow F_y(y) &= 1 - [1 - \exp\{-y/\ln\}]^n = 1 - [1 - 1 + \exp\{-y/\ln\}]^n \\ &= 1 - [\exp\{-y/\ln\}]^n \end{aligned}$$

$$\text{Portanto, } F_Y(y) = 1 - \exp\{-y\} \quad \text{e} \quad g_Y(y) = \exp\{-y\} \quad (1)$$

$$\text{Agora, } E_{\xi}(n(\delta(x) - \xi)) = 1 \quad \text{pois} \quad Y \sim \exp\{1\} \quad \text{por (1)}$$

$$\Leftrightarrow E(\delta(x) - \xi) = \frac{1}{n} \quad \Leftrightarrow \boxed{E(\delta(x)) = \frac{1}{n} + \xi} \quad (2)$$

$$\bullet \text{Var}_{\xi}(n(\delta(x) - \xi)) = 1 \quad \text{por (1)}$$

$$\Leftrightarrow n^2 \text{Var}_{\xi}(\delta(x) - \xi) = 1 \quad \Leftrightarrow \text{Var}_{\xi}(\delta(x) - \xi) = \frac{1}{n^2} \quad \Leftrightarrow \boxed{\text{Var}_{\xi}(\delta(x)) = \frac{1}{n^2}} \quad (3)$$

$$\bullet R(\xi, \delta(x)) = \text{Var}_{\xi}(\delta(x)) + [E_{\xi}(\delta(x)) - \xi]^2 = \frac{1}{n^2} + \left[\frac{1}{n} + \xi - \xi \right]^2 \quad \text{por (2) e (3)}$$

$$\Rightarrow \boxed{R(\xi, \delta(x)) = \frac{2}{n^2}}$$

(c) Obtenha o estimador de Pitman de ξ (estimador equivariante de risco mínimo sob perda quadrática). Mostre que é não viciado e calcule seu risco. Mostre que o estimador $\delta(x)$ é inadmissível.

$$\delta^*(x) = \frac{\int_{-\infty}^{\infty} u \delta(x_1 - u, \dots, x_n - u) du}{\int_{-\infty}^{\infty} \delta(x_1 - u, \dots, x_n - u) du} \quad \text{é o estimador de Pitman}$$

Temos que, $\delta(x-u) = \exp\{-(n\bar{x}+u)\} \exp\{nu\} I_{(-\infty, x_1, \dots, x_n)}(u)$, então

$$\begin{aligned} & \int_{-\infty}^{x_{(1),1}} \exp\{-(n\bar{x}+u)\} \exp\{nu\} du = \exp\{-n\bar{x}-n\} \int_{-\infty}^{x_{(1),1}} \exp\{nu\} du \\ &= \exp\{-n\bar{x}-n\} \int_{-\infty}^{nx_{(1),1}+n} \exp\{z\} \frac{dz}{n} \\ &= \frac{\exp\{-n\bar{x}-n\}}{n} [\exp\{nx_{(1),1}+n\} - 0] \end{aligned}$$

$$\Rightarrow \int_{-\infty}^{x_{(1),1}} u \exp\{-n\bar{x}-n+nu\} du = \frac{1}{n} \exp\{n x_{(1),1} - n \bar{x}\} \quad (4)$$

$$\begin{aligned} & \int_{-\infty}^{x_{(1),1}} u \exp\{-n\bar{x}-n+nu\} du = \exp\{-n\bar{x}-n\} \int_{-\infty}^{x_{(1),1}} u \exp\{nu\} du \\ &= \exp\{-n\bar{x}-n\} \int_{-\infty}^{nx_{(1),1}+n} \frac{z}{n} \exp(z) \frac{dz}{n} \\ &= \frac{1}{n^2} \exp\{-n\bar{x}-n\} \int_{-\infty}^{nx_{(1),1}+n} z \exp(z) dz \\ &= \frac{1}{n^2} \exp\{-n\bar{x}-n\} \left[z \exp(z) \Big|_{-\infty}^{nx_{(1),1}+n} - \int_{-\infty}^{nx_{(1),1}+n} \exp(z) dz \right] \\ &= \frac{1}{n^2} \exp\{-n\bar{x}-n\} [(nx_{(1),1}+n) \exp\{nx_{(1),1}+n\} - 0 - \exp\{nx_{(1),1}+n\} + 0] \end{aligned}$$

$$\Rightarrow \int_{-\infty}^{x_{(1),1}} u \exp\{-n\bar{x}-n+nu\} du = \frac{1}{n^2} \exp\{-n\bar{x}-n\} \exp\{nx_{(1),1}+n\} [nx_{(1),1}+n - 1] \quad (5)$$

Por (4) e (5) temos que:

$$\delta^*(x) = \frac{\frac{1}{n} \exp\{-n\bar{x} - n\bar{x}_{(1)}\} [n\bar{x}_{(1)} + n-1]}{\frac{1}{n} \exp\{-n\bar{x} - n\bar{x}_{(1)}\}} = \frac{1}{n} \{n\bar{x}_{(1)} + n-1\}$$

$$\Rightarrow \delta^*(x) = \bar{x}_{(1)} + 1 - \frac{1}{n}$$

$$\bullet E(\delta^*(x)) = E(\bar{x}_{(1)} + 1 - \frac{1}{n}) = E(\bar{x}_{(1)}) + 1 - \frac{1}{n}$$

Note que: $E(\xi(x)) = \frac{1}{n} + \xi$ Por (2)

$$\Leftrightarrow E(\bar{x}_{(1)}) = \frac{1}{n} + \xi \Leftrightarrow E(\bar{x}_{(1)}) = \frac{1}{n} + \xi - 1$$

$$\Rightarrow E(\delta^*(x)) = \frac{1}{n} + \xi - 1 + 1 - \frac{1}{n} = \xi$$

∴ Assim, $\delta^*(x)$ é não viciado para ξ

$$\bullet R(\xi, \delta^*(x)) = \text{Var}(\delta^*(x)) \text{ Pois } \delta^* \text{ é não viciado}$$

$$= \text{Var}(\bar{x}_{(1)} + 1 - \frac{1}{n}) = \text{Var}(\bar{x}_{(1)})$$

Por: $\text{Var}(\xi(x)) = \frac{1}{n^2}$ Por (3)

$$\Leftrightarrow \text{Var}(\bar{x}_{(1)}) = \frac{1}{n^2} \Leftrightarrow \text{Var}(\bar{x}_{(1)}) = \frac{1}{n^2}$$

Assim,

$$R(\xi, \delta^*(x)) = \frac{1}{n^2}$$

• Como $R(\xi, \delta^*(x)) = \frac{1}{n^2} < \frac{2}{n^2} = R(\xi, \delta(x))$, então $\delta(x)$ é inadmissível.

(20) Seja $\mathbf{x} = (x_1, \dots, x_n)$ com função densidade de probabilidade

$$f_{\mathbf{x}}(\mathbf{x}; \tau) = \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n, \quad \tau > 0,$$

em que f é conhecida e τ é um parâmetro de escala desconhecido. Considere o problema de estimar τ^r , $r \geq 1$, inteiro. Dizemos que um estimador $s(\mathbf{x})$, tal que $s(\mathbf{x}) > 0$ para todo $\mathbf{x} \in \mathbb{R}^n$, é equivariante por escala se $s(b\mathbf{x}) = b^r s(\mathbf{x})$, para todo $b > 0$ e todo $\mathbf{x} \in \mathbb{R}^n$.

Considere a função de perda $L(\tau, d) = [(d - \tau^r)/\tau^r]^2$.

(a) Mostre que o risco $R(\tau, s(\mathbf{x}))$ de qualquer estimador equivariante por escala é constante.

Dada a função de perda $L(\tau, d) = [(d - \tau^r)/\tau^r]^2$, o risco de $s(\mathbf{x})$ é

$$\begin{aligned} R(\tau, s(\mathbf{x})) &= E_d \left\{ \left[\frac{s(\mathbf{x}) - \tau^r}{\tau^r} \right]^2 \right\} = E_{\tau} \left\{ \left[\frac{1}{\tau^r} s(\mathbf{x}) - 1 \right]^2 \right\} \\ &= \frac{1}{\tau^{2r}} E_{\tau} \left[(s(\mathbf{x}))^2 \right] - 2 \frac{1}{\tau^r} E_{\tau} [s(\mathbf{x})] + 1, \quad \tau > 0 \end{aligned}$$

mas,

$$E_{\tau} [s(\mathbf{x})] = \int_{\mathbb{R}^n} s(\mathbf{x}) \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right) d\mathbf{x}, \quad \tau > 0$$

e fazendo $u_i = x_i/\tau \Rightarrow du_i = \frac{1}{\tau} dx_i \Rightarrow du = dx/\tau^n$, então

$$\begin{aligned} E_{\tau} [s(\mathbf{x})] &= \int_{\mathbb{R}^n} s(u_1\tau, \dots, u_n\tau) f(u_1, \dots, u_n) du, \quad u = (u_1, \dots, u_n), \quad \tau > 0 \\ &= \int_{\mathbb{R}^n} s(\tau u) f(u) du = \int_{\mathbb{R}^n} \tau^r s(u) f(u) du, \quad \tau > 0 \\ &\quad \downarrow \\ &\text{por hipótese } s(b\mathbf{x}) = b^r s(\mathbf{x}), \forall b > 0 \\ &= \tau^r \int_{\mathbb{R}^n} s(u) f(u) du, \quad \tau > 0. \end{aligned}$$

e semelhantemente,

$$\begin{aligned} E_{\tau} \left\{ [s(\mathbf{x})]^2 \right\} &= \int_{\mathbb{R}^n} [s(\mathbf{x})]^2 \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right) d\mathbf{x}, \quad \tau > 0 \\ &= \int_{\mathbb{R}^n} [\delta(u, \tau, \dots, u_n\tau)]^2 f(u) du, \quad \tau > 0 \\ &= \int_{\mathbb{R}^n} [\delta(\tau u)]^2 f(u) du, \quad \tau > 0 \\ &= \int_{\mathbb{R}^n} [\tau^r \delta(u)]^2 f(u) du, \quad \tau > 0 \\ &= \tau^{2r} \int_{\mathbb{R}^n} [\delta(u)]^2 f(u) du, \quad \tau > 0 \end{aligned}$$

Assim

$$\begin{aligned} R(\tau, s(\mathbf{x})) &= \frac{1}{\tau^{2r}} \tau^{2r} \int_{\mathbb{R}^n} [\delta(u)]^2 f(u) du - 2 \frac{1}{\tau^r} \tau^r \int_{\mathbb{R}^n} \delta(u) f(u) du + 1 \\ &= \underbrace{\int_{\mathbb{R}^n} [\delta(u)]^2 f(u) du}_{\text{não depende de } \tau} - 2 \underbrace{\int_{\mathbb{R}^n} \delta(u) f(u) du}_{\text{não depende de } \tau} + 1 \end{aligned}$$

Então o risco de qualquer estimador equivariante por escala sob a função de perda dada é constante (não depende de τ).

(b) Seja $\delta_0(\mathbf{x})$ um estimador equivariante por escala. Mostre que um estimador $s(\mathbf{x})$ é equivariante por escala se e somente se $s(\mathbf{x}) = \delta_0(\mathbf{x})/v(\mathbf{x})$, em que $v(\mathbf{x})$ é tal que

$$v(cx) = v(\mathbf{x}) > 0, \quad \text{para todo } c > 0 \text{ e todo } \mathbf{x} \in \mathbb{R}^n. \quad (3)$$

Mostre ainda que, se $n \neq 0$ e $n > 1$, uma condição necessária e suficiente para que $v(\mathbf{x})$ satisfaca (3) é que exista uma função $w(\mathbf{y})$ tal que $v(\mathbf{x}) = w(\mathbf{y})$ em que $\mathbf{y} = \left(\frac{x_1}{|x_n|}, \dots, \frac{x_n}{|x_n|}\right)$.

Temos que $\delta_0(\mathbf{x})$ é um estimador equivariante por escala, então para todo $b > 0$, temos

Se $\delta_0(bx) = b^r \delta_0(x)$, $r \geq 1$, para todo $x \in \mathbb{R}^n$, e $\delta_0(x) > 0 \forall x \in \mathbb{R}^n$

" \Rightarrow "

Se $\delta(x)$ é equivariante por escala, então $\delta(bx) = b^r \delta(x)$, $\delta(x) > 0 \forall b > 0, x \in \mathbb{R}^n$
 $\Rightarrow \delta(x) = \frac{\delta(bx)}{b^r} = \frac{\delta(bx)}{b^r} \frac{\delta_0(x)}{\delta_0(x)} = \delta_0(x) \frac{\delta(bx)}{\delta_0(bx)}$

$\Rightarrow \delta(x) = \frac{\delta_0(x)}{v(bx)}$, em que $v(bx) = \frac{\delta_0(bx)}{\delta(bx)} = \frac{b^r \delta(x)}{b^r \delta_0(x)} = \frac{\delta(x)}{\delta_0(x)} > 0$

$\Rightarrow \delta(x) = \frac{\delta_0(x)}{v(x)}$, em que $v(x) > 0$ e $v(x) = v(bx)$, $\forall x \in \mathbb{R}^n, b > 0$

" \Leftarrow "

Se $\delta(x) = \frac{\delta_0(x)}{v(x)}$, $v(x) > 0$, $v(x) = v(bx)$, $\forall x \in \mathbb{R}^n, b > 0$

$\Rightarrow \delta(bx) = \frac{\delta_0(bx)}{v(bx)} = \frac{b^r \delta_0(x)}{v(x)} = b^r \delta(x) \Rightarrow \delta(bx) = b^r \delta(x), \forall x \in \mathbb{R}^n, b > 0$

Então $\delta(x)$ é equivariante por escala.

Ainda, se $x_n \neq 0$ e $n > 1$ temos que:

"Suficiência"

Se $v(x) = w(y) = w\left(\frac{x_1}{|x_n|}, \dots, \frac{x_n}{|x_n|}\right)$ e $v(cx) = v(cx_1, \dots, cx_n)$

$\Rightarrow v(cx) = w\left(\frac{cx_1}{|cx_n|}, \dots, \frac{cx_n}{|cx_n|}\right), c > 0$

$$= w\left(\frac{c x_1}{c |x_n|}, \dots, \frac{c x_n}{c |x_n|}\right), c > 0$$

$$= w\left(\frac{x_1}{|x_n|}, \dots, \frac{x_n}{|x_n|}\right)$$

$$= w(y)$$

$$= v(x)$$

Assim $v(x)$ satisfaçõe (3).

"Necessária"

Se $v(cx) = v(x)$, seja $v(x) = \tilde{w}(x)$, então $\forall b > 0$,

$v\left(\frac{x}{b}\right) = \tilde{w}\left(\frac{x}{b}\right) \Rightarrow v(x) = \tilde{w}\left(\frac{x}{b}\right)$, dado que $x \in \mathbb{R}^n$, $v\left(\frac{x}{b}\right) = v(x)$,

fazendo logo $b = |x_n|$ temos que $v(x) = \tilde{w}(y)$, portanto o resultado segue com $w(y) = \tilde{w}(y)$.

(c) Seja $\delta_0(x)$ um estimador equivariante de risco finito. Mostre que o estimador equivariante de risco mínimo de τ' é dado por

$$\delta^*(x) = \delta_0(x) \frac{E_1[\delta_0(x)|y]}{E_1[\delta_0^2(x)|y]},$$

em que $y = (x_1/|x_n|, \dots, x_n/|x_n|)$.

Se $\delta(x)$ é um estimador equivariante, então $\delta(x) = \frac{\delta_0(x)}{v(x)} = \frac{\delta_0(x)}{w(y)}$, em que $y = x/|x_n|$.

Logo,

$$R(\tau, \delta(x)) = E_1 \left\{ \left[\frac{\delta(x) - \tau'}{\tau'} \right]^2 \right\} = E_1 \left\{ \left[\frac{\delta(x)}{\tau'} - 1 \right]^2 \right\} = E_1 \left\{ [\delta(u) - 1]^2 \right\}$$

$$\text{em que } u = \frac{x}{\tau} \text{ e } (\frac{x}{\tau})^r \delta(x) = \delta(\frac{x}{\tau}) = \delta(u)$$

$$\Rightarrow R(\tau, \delta(x)) = E_1 \left\{ [\delta(u) - 1]^2 \right\} = E_1 \left\{ \left[\frac{\delta_0(u)}{w(v)} - 1 \right]^2 \right\}$$

$$\text{em que } v = \frac{u}{|V_n|} = \frac{x}{|x_n|} = y$$

$$\Rightarrow R(\tau, \delta(x)) = E_1 \left\{ \left[\frac{\delta_0(u)}{w(y)} - 1 \right]^2 \right\} = \int E_1 \left\{ \left[\frac{\delta_0(u)}{w(y)} - 1 \right]^2 | y \right\} dP(y)$$

Esta integral é minimizada em $w(y)$, minimizando o integrando para cada y .

Assim, dada y

$$\begin{aligned} E_1 \left\{ \left[\frac{\delta_0(u)}{w(y)} - 1 \right]^2 | y \right\} &= \frac{1}{[w(y)]^2} E_1 \left\{ [\delta_0(u) - w(y)]^2 | y \right\} \\ &= \frac{1}{[w(y)]^2} \left\{ E_1 [(\delta_0(u))^2 | y] - 2w(y)E_1(\delta_0(u) | y) + (w(y))^2 \right\} \\ &= \frac{1}{[w(y)]^2} E_1 [(\delta_0(u))^2 | y] - \frac{2}{w(y)} E_1(\delta_0(u) | y) + 1 \\ &= h(w(y)) = h(w). \end{aligned}$$

Esfato,

$$h'(w) = -\frac{2}{w^3} E_1 [(\delta_0(u))^2 | y] + \frac{2}{w^2} E_1(\delta_0(u) | y)$$

e

$$h''(w) = \frac{6}{w^4} E_1 [(\delta_0(u))^2 | y] - \frac{4}{w^3} E_1(\delta_0(u) | y)$$

$$\Rightarrow h'(w) = 0 \Rightarrow \frac{1}{w} E_1 [(\delta_0(u))^2 | y] - E_1(\delta_0(u) | y) = 0$$

$$\Rightarrow w^* = \frac{E_1 [(\delta_0(u))^2 | y]}{E_1(\delta_0(u) | y)} \quad (*)$$

$$\text{e } h''(w^*) = 6 \frac{[E_1(\delta_0(u) | y)]^4}{[E_1[(\delta_0(u))^2 | y]]^3} - 4 \frac{[E_1(\delta_0(u) | y)]^3}{[E_1[(\delta_0(u))^2 | y]]^3} > 0$$

Esfato, w^* em $(*)$ minimiza o risco e dado que para uma estatística equivalente por escala $\delta^*(x)$, $\delta^*(x) = \frac{\delta_0(x)}{w^*(y)}$, então o estimador equivalente de risco mínimo de τ^r é dado por

$$\delta^*(x) = \frac{\delta_0 E_1[\delta_0(x) | y]}{E_1[(\delta_0(x))^2 | y]}$$

(d) considere a situação em que (x_1, \dots, x_n) é uma amostra aleatória da distribuição $N(0, \tau^2)$, $\tau > 0$. Encontre o estimador equivalente de risco mínimo de τ^2 . Sugestão: usar o Teorema de Basu.

Seja $T_0(x) = \sum_{i=1}^n x_i^2$, então $T_0(\tau x) = \sum_{i=1}^n (\tau x_i)^2 = \tau^2 \sum_{i=1}^n x_i^2 = \tau^2 T_0(x)$ portanto $T_0(x)$ é invariante por escala ($r=2$). Também, $T_0(x) = \sum_{i=1}^n x_i^2$ é uma estatística suficiente completa (visto em aula).

$$\begin{aligned} \text{Dado que } Y &= \frac{X}{|X_n|} = \left(\frac{x_1}{|x_n|}, \dots, \frac{x_n}{|x_n|} \right) = \left(\frac{x_1/\tau}{|x_n/\tau|}, \dots, \frac{x_n/\tau}{|x_n/\tau|} \right) \\ &= \left(\frac{z_1}{\sqrt{x_1^2/\tau^2}}, \dots, \frac{z_n}{\sqrt{x_n^2/\tau^2}} \right) = (t_1, \dots, t_n) \end{aligned}$$

com $z_i \sim N(0, 1)$, $x_i^2/\tau^2 \sim \chi^2_1$ e $t_i \sim t_1$, $i=1, \dots, n-1$, e t_n uma v.a. degenerada com valores 1 ou -1. Assim a distribuição de Y não depende de τ^2 e portanto é anciliar. Assim, por Basu, T_0 e Y não independentes e então

$$\delta^*(x) = \frac{T_0(x) E_1[T_0(x) | Y]}{E_1[T_0^2(x) | Y]} = \frac{T_0(x) E_1[T_0(x)]}{E_1[T_0^2(x)]}$$

mas, $T_0(x) \sim \chi^2_n$, então

$$\delta^*(x) = \frac{\left(\sum_{i=1}^n x_i^2 \right) n}{2n+n^2} = \frac{1}{2+n} \sum_{i=1}^n x_i^2 \quad \checkmark$$

(2) Seja $\mathbf{x} = (x_1, \dots, x_n)$ com função densidade de probabilidade conjunta

$$f_{\mathbf{x}}(\mathbf{x}, \tau) = \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n, \tau > 0,$$

em que f é conhecida e τ é um parâmetro de escala desconhecido. Considere o problema de estimar τ^r , $r \geq 1$, inteiro. Dizemos que um estimador $\delta(\mathbf{x})$ é equivariante por escala se $\delta(b\mathbf{x}) = b^r \delta(\mathbf{x})$, para todo $b > 0$. Pode-se mostrar que o estimador de Pitman de τ^r , dado por $\delta^*(\mathbf{x})$ sendo

$$\delta^*(\mathbf{x}) = \frac{\int_0^{+\infty} v^{n+r-1} f(vx_1, \dots, vx_n) dv}{\int_0^{+\infty} v^{n+r-1} f(vx_1, \dots, vx_n) dv},$$

é um estimador equivariante por escala de risco mínimo sob perda $[(d - \tau^r)/\tau^r]^2$.

(a) Mostre que, de fato, o estimador $\delta^*(\mathbf{x})$ é equivariante por escala.

Fazendo $w = bv \Rightarrow dw = b dv$, então

$$\begin{aligned} \delta^*(b\mathbf{x}) &= \frac{\int_0^{+\infty} \left(\frac{w}{b}\right)^{n+r-1} f(wx_1, \dots, wx_n) \frac{1}{b} dw}{\int_0^{+\infty} \left(\frac{w}{b}\right)^{n+2r-1} f(wx_1, \dots, wx_n) \frac{1}{b} dw} \\ &= \frac{b^{n+2r-1}}{b^{n+r-1}} \frac{\int_0^{+\infty} w^{n+r-1} f(wx_1, \dots, wx_n) dw}{\int_0^{+\infty} w^{n+2r-1} f(wx_1, \dots, wx_n) dw} \\ &= b^r \delta^*(\mathbf{x}) \end{aligned}$$

Assim, δ^* é equivariante por escala.

(b) Obtenha o estimador $\delta^*(\mathbf{x})$ de τ^r para a situação em que \mathbf{x} é uma amostra aleatória da distribuição exponencial de média $\tau > 0$.

Se $X_i \sim \text{Exp}(\tau)$ então $f_{X_i}(x_i; \tau) = \frac{1}{\tau} \exp(-x_i/\tau)$, $x_i \in (0, +\infty)$, $\tau > 0$.

Então,

$$f_{\mathbf{x}}(x; \tau) = \prod_{i=1}^n f_{X_i}(x_i; \tau) = \frac{1}{\tau^n} \exp\left\{-\sum_{i=1}^n x_i / \tau\right\}, \quad x \in (0, +\infty)^n$$

Assim, se

$$f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right) = \exp\left\{-\sum_{i=1}^n \frac{x_i}{\tau}\right\}, \quad x \in (0, +\infty)^n$$

Então, para o nosso caso

$$\begin{aligned} \int_0^{+\infty} v^{n+r-1} f(vx_1, \dots, vx_n) dv &= \int_0^{+\infty} v^{n+r-1} \exp\left\{-\sum_{i=1}^n vx_i\right\} dv \\ &= \int_0^{+\infty} v^{n+r-1} \exp(-cv) dv, \quad \text{com } c = \sum_{i=1}^n x_i \\ &\stackrel{w=cv}{=} \int_0^{+\infty} e^{-(r+n)} w^{n+r-1} \exp(-w) dw = e^{-(r+n)} \int_0^{+\infty} w^{n+r-1} \exp(-w) dw \\ &\quad w=cv \Rightarrow dw = \frac{1}{c} dv \end{aligned}$$

mas, para uma constante K , inteiro positivo,

$$\int x^k e^{-x} dx = -e^{-x} \left[\sum_{i=0}^k \frac{d^i(x^k)}{dx^i} \right]; \quad \frac{d^0(x^k)}{dx^0} = x^k; \quad \frac{d^k(x^k)}{dx^k} = k!$$

Então, fazendo $k=n+r-1$, temos

$$\begin{aligned} \int_0^{+\infty} w^{n+r-1} e^{-w} dw &= \underbrace{\left\{ -e^{-w} \left[\sum_{i=0}^{n+r-1} \frac{d^i(w^{n+r-1})}{dw^i} \right] \right\}}_B \Big|_0^{+\infty} \\ &= -e^{-w} (n+r-1)! \Big|_0^{+\infty} = (n+r-1)! \end{aligned}$$

Os termos em B não sempre com $-w^s e^{-w} \Big|_0^{+\infty}$ e são zero quando $s \geq 1$, exceto no último termo é da forma $-k! e^{-w} \Big|_0^{+\infty} \neq 0$, com k cte.

Então,

$$\int_0^{+\infty} v^{n+r-1} f(vx_1, \dots, vx_n) dv = e^{-(r+n)} (n+r-1)!$$

similarmente,

$$\begin{aligned} \int_0^{+\infty} v^{n+2r-1} f(vx_1, \dots, vx_n) dv &= e^{-(2r+n)} \int_0^{+\infty} w^{n+2r-1} \exp(-w) dw \\ &= e^{-(2r+n)} (n+2r-1)! \end{aligned}$$

Portanto,

$$\delta^*(\mathbf{x}) = \frac{e^{-(r+n)} (n+r-1)!}{e^{-(2r+n)} (n+2r-1)!} = \frac{e^r (n+r-1)!}{(n+2r-1)!} = \frac{\left(\sum_{i=1}^n x_i\right) (n+r-1)!}{(n+2r-1)!}$$

é o estimador de τ^r .

- (c) No contexto do item (b), encontre o estimador não viésado de risco mínimo de τ^r considerando a perda dada acima.

Dado que $x_i \sim \text{Exp}(\tau)$, $i=1, \dots, n$, então $y = \sum_{i=1}^n x_i \sim \text{Gamma}(n, 1/\tau)$ e portanto

$$E_\tau(Y^r) = \frac{n(n\tau)^r}{r(n)(1/\tau)^r} = \frac{(n+r-1)! \tau^r}{(n-1)!}, \quad r \text{ inteiro positivo}, \quad r \geq 1.$$

Assim,

$$E_\tau(\delta^*(x)) = \frac{(n+r-1)!}{(n+2r-1)!} E_\tau\left[\left(\sum_{i=1}^n x_i\right)^r\right] = \frac{(n+r-1)!}{(n+2r-1)!} \frac{(n+r-1)!}{(n-1)!} \tau^r = \frac{[(n+r-1)!]^2 \tau^r}{(n+2r-1)! (n-1)!}$$

Portanto um estimador não viésado para τ^r é

$$\begin{aligned}\delta^*(x) &= \frac{(n-1)! (n+2r-1)!}{[(n+r-1)!]^2} \delta^*(x) \\ &= \frac{(n-1)!}{(n+r-1)!} \left(\sum_{i=1}^n x_i\right)^r, \quad r \geq 1, \text{ inteiro positivo}\end{aligned}$$

Assim, dado que $\delta^*(x)$ é não viésado, é de risco constante e portanto é de risco mínimo.

9.9

MAE 5834 - ESTATÍSTICA AVANÇADA I

Lista de Exercícios 4.

Prof. Silvia L. P. Ferrari

Alunos: Mario José Pacheco López - 9034481

Hugo A. Brango García - 9176006

USP-IME, 20/10/2014

- ⑥ Seja X única observação de uma variável aleatória com densidade $f(x|\theta) = 2x/\theta^2$, $0 < x < \theta$; $\theta > 0$. Considere para θ uma distribuição uniforme no intervalo unitário.

(a) Obtenha o função densidade de probabilidade a posteriori de θ .

Temos que a.v.a. X tem distribuição $f(x|\theta) = \frac{2x}{\theta^2} I_{(0,\theta)}(x)$, $\theta > 0$, e que a. tem distribuição a priori $U(0,1)$, ouim, $\pi(\theta) = I_{(0,1)}(\theta)$, portanto a distribuição a posteriori de θ é

$$\begin{aligned}\pi(\theta|x) &\propto \pi(\theta)f(x|\theta) = I_{(0,1)}(\theta) \frac{2x}{\theta^2} I_{(0,\theta)}(x) \\ &= \frac{2x}{\theta^2} I_{(0,1)}(\theta) I_{(x,\infty)}(0) = \frac{2x}{\theta^2} I_{(x,1)}(\theta)\end{aligned}$$

Logo, dado que

$$\int_x^1 \frac{2x}{\theta^2} d\theta = -\frac{2x}{\theta} \Big|_x^1 = 2 - 2x = 2(1-x), \quad x \in (0,1)$$

então a f.d.p. a posteriori de θ é

$$\pi(\theta|x) = \frac{2x/\theta^2}{2(1-x)} I_{(x,1)}(\theta) \quad x \in (0,1)$$

$$\Rightarrow \pi(\theta|x) = \frac{x}{(1-x)\theta^2} I_{(x,1)}(\theta), \quad x \in (0,1)$$

(b) Encontre o estimador de Bayes com respeito à perda $\theta^2(d-\theta)^2$.

Dado que a função de perda $L(\theta, d) = \theta^2(d-\theta)^2$ tem a forma

$$L(\theta, d) = w(\theta)[d - g(\theta)]^2,$$

em que $w(\theta) = \theta^2 > 0$, pt todo $\theta > 0$ e $g(\theta) = \theta$, então o estimador de Bayes com respeito à perda dada é

$$\delta_B(x) = \frac{E[w(\theta)g(\theta)|X=x]}{E[w(\theta)|X=x]}$$

Era que $\Delta \in U(0,1)$ e então,

$$\delta_B(x) = \frac{E[\theta^2 \theta | X=x]}{E[\theta^2 | X=x]} = \frac{E[\theta^3 | X=x]}{E[\theta^2 | X=x]}$$

mas,

$$\begin{aligned}E[\theta^3 | X=x] &= \int_x^1 \frac{x}{1-x} \frac{\theta^3}{\theta^2} d\theta = \int_x^1 \frac{x}{1-x} \theta d\theta = \left[\frac{x}{1-x} \frac{\theta^2}{2} \right]_x^1 \\ &= \frac{x}{1-x} \left\{ \frac{1}{2} - \frac{x^2}{2} \right\} = \frac{x}{1-x} \sqrt{(1-x)(1+x)} = \frac{x(1+x)}{2}, \text{ zeta!}\end{aligned}$$

$$\begin{aligned}E[\theta^2 | X=x] &= \int_x^1 \frac{x}{1-x} \frac{\theta^2}{\theta^2} d\theta = \int_x^1 \frac{x}{1-x} d\theta = \left[\frac{x}{1-x} \theta \right]_x^1 = \frac{x}{1-x}(1-x) \\ &= x \in (0,1)\end{aligned}$$

Portanto, o estimador de Bayes com respeito à perda $\theta^2(d-\theta)^2$ é

$$\delta_B(x) = \frac{x(1+x)/2}{x} = \frac{1+x}{2}, \quad x \in (0,1)$$

$$\Rightarrow \delta_B(x) = \frac{1+x}{2}, \quad x \in (0,1).$$

① Seja $\hat{\theta}$ um estimador não viciado de um parâmetro $\theta \in \mathbb{R}$, seja $R(\theta, \hat{\theta})$ o risco do estimador $\hat{\theta}$ de θ .

(a) sob perda quadrática, mostre que o estimador $c\hat{\theta}$, em que $c \in (0,1)$ é uma constante conhecida, não é estimador minimax de θ , a menos que $\sup_{\theta} R(\theta, \hat{\theta}) = \infty$ para todo estimador $\hat{\theta}$ de θ .

Seja $L(\theta, \delta) = (\delta - \theta)^2$ a função de perda e $\tilde{\theta} = c\hat{\theta}$, $c \in (0,1)$ cte conhecida, então,

$$\begin{aligned} R(\theta, \tilde{\theta}) &= E_{\theta}[(\tilde{\theta} - \theta)^2] = E_{\theta}[(c\hat{\theta} - \theta)^2] = E_{\theta}[(c\hat{\theta} - c\theta + c\theta - \theta)^2] \\ &= c^2 E_{\theta}[(\hat{\theta} - \theta)^2] + 2c(c-1)\theta E_{\theta}[(\hat{\theta} - \theta)] + (c-1)^2\theta^2 \\ &= c^2 E_{\theta}[(\hat{\theta} - \theta)^2] + (c-1)^2\theta^2 \\ &= c^2 R(\theta, \hat{\theta}) + (c-1)^2\theta^2 \end{aligned}$$

$\hat{\theta}$ é não viciado

mas $\theta \in \mathbb{R}$, então

$$\begin{aligned} \sup_{\theta} R(\theta, \tilde{\theta}) &= \sup_{\theta} [c^2 R(\theta, \hat{\theta})] + \sup_{\theta} [(c-1)^2\theta^2] \\ \Rightarrow \sup_{\theta} R(\theta, \tilde{\theta}) &= +\infty \end{aligned}$$

Portanto, o estimador $\tilde{\theta}$ é minimax de θ apenas se $\sup_{\theta} R(\theta, \hat{\theta}) = +\infty$ para todo estimador $\hat{\theta}$ de θ , dado que

$$\inf_{\delta} \sup_{\theta} R(\theta, \delta) = \sup_{\theta} R(\theta, \hat{\theta})$$

somente se $\sup_{\theta} R(\theta, \delta) = +\infty$ para todo estimador δ de θ .

(b) Considere a função de perda $L(\theta, d) = (d - \theta)^2 / \theta^2$, assumindo que $\theta \neq 0$. Mostre que o estimador $\hat{\theta}$ não é estimador minimax de θ , a menos que $\sup_{\theta} R(\theta, \hat{\theta}) = +\infty$ para todo estimador $\hat{\theta}$ de θ . Sugestão: obtenha o risco de $c\hat{\theta}$ com $c = 1/(1+\xi)$, em que $\xi = \sup_{\theta} R(\theta, \hat{\theta})$, e compare com o risco de $\hat{\theta}$.

Dada a função de perda,

$$\begin{aligned} R(\theta, \hat{\theta}) &= E_{\theta} \left[\frac{(\hat{\theta} - \theta)^2}{\theta^2} \right] = \frac{1}{\theta^2} E_{\theta}[(\hat{\theta} - \theta)^2] \\ &\stackrel{(a)}{=} \frac{1}{\theta^2} \left[c^2 E_{\theta}[(\hat{\theta} - \theta)^2] + (c-1)^2 \theta^2 \right] \\ &= c^2 E_{\theta} \left[\frac{(\hat{\theta} - \theta)^2}{\theta} \right] + (c-1)^2 \theta^2 \\ &= c^2 R(\theta, \hat{\theta}) + (c-1)^2 \theta^2 \end{aligned}$$

Agora, seja $\zeta = \sup_{\theta} R(\theta, \hat{\theta})$ e $c = 1/(1+\zeta)$, então

$$\begin{aligned} \sup_{\theta} R(\theta, \tilde{\theta}) &= c^2 \sup_{\theta} R(\theta, \hat{\theta}) + (c-1)^2 \theta^2 \\ &= c^2 \zeta + (c-1)^2 \theta^2 \\ &= \frac{\zeta}{(1+\zeta)^2} + \left(\frac{1}{1+\zeta} - 1 \right)^2 \theta^2 \\ &= \frac{\zeta}{(1+\zeta)^2} + \frac{\zeta^2}{(1+\zeta)^2} \\ &= \frac{\zeta(1+\zeta)}{(1+\zeta)^2} \\ &= \frac{\zeta}{1+\zeta} \end{aligned}$$

Assim, $\sup_{\theta} R(\theta, \tilde{\theta}) = \frac{\zeta}{1+\zeta} < \zeta$, ou $0 < \zeta < \infty$, portanto a menos que $\sup_{\theta} R(\theta, \hat{\theta}) = \infty$ para todo estimador $\hat{\theta}$ de θ , $\tilde{\theta}$ não é minimax de θ dado que $\sup_{\theta} R(\theta, \tilde{\theta}) < \sup_{\theta} R(\theta, \hat{\theta})$.

⑨ Seja X uma variável aleatória representando o tempo de vida de um sistema eletrônico, com função distribuição acumulada $F_\theta(x)$, $\theta \in \Omega$. Defina a confiabilidade do sistema por

$$R_\theta(\tau) = P_\theta(X > \tau) = 1 - F_\theta(\tau), \quad \tau > 0$$

considere n observações independentes x_1, \dots, x_n de X . Admita que, dado θ , X tem distribuição exponencial de parâmetro θ e função densidade de probabilidade

$$f(x; \theta) = \theta \exp(-\theta x), \quad x > 0; \theta > 0.$$

(a) Mostre que, neste caso, $R_\theta(\tau) = \exp(-\tau\theta)$.

Dado que

$$\begin{aligned} R_\theta(\tau) &= P_\theta(X > \tau) = 1 - F_\theta(\tau) = 1 - \int_0^\tau \theta \exp(-\theta x) dx \\ &= 1 - \left(-\exp(-\theta x) \right) \Big|_0^\tau = 1 - (1 - \exp(-\theta\tau)) \\ &= \exp(-\theta\tau), \quad \tau > 0 \end{aligned}$$

então $R_\theta(\tau) = \exp(-\tau\theta)$, $\tau > 0$

(b) Encontre o estimador de máxima verossimilhança de $R_\theta(\tau)$.

Fazendo $g(\theta) = R_\theta(\tau) = \exp\{-\tau\theta\}$, o estimador de máxima verossimilhança de $g(\theta)$ é dado por $g(\hat{\theta})$, em que $\hat{\theta}$ é o estimador de máxima verossimilhança de θ .

Notar que, a função de verossimilhança de θ é dada por

$$\begin{aligned} L(\theta; \underline{x}) &= \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n \theta \exp(-\theta x_i) = \theta^n \exp\left\{-\theta \sum_{i=1}^n x_i\right\} \\ &= \theta^n \exp\{-n\theta \bar{x}\} \end{aligned}$$

em que $x_i > 0$, $i = 1, \dots, n$; $\theta > 0$ e $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

logo, a função de log-verossimilhança é dada por

$$l(\theta; \underline{x}) = \log L(\theta; \underline{x}) = n \log \theta - n\theta \bar{x}$$

Assim,

$$\frac{\partial l(\theta; \underline{x})}{\partial \theta} = \frac{n}{\theta} - n\bar{x} \Rightarrow \frac{\partial l(\theta; \underline{x})}{\partial \theta} = 0 \Rightarrow \frac{n}{\theta} - n\bar{x} = 0 \Rightarrow \hat{\theta} = \frac{1}{\bar{x}}$$

e dado que $\frac{\partial^2 l(\theta; \underline{x})}{\partial \theta^2} = -\frac{n}{\theta^2} < 0$, para todo θ e portanto para $\theta = \hat{\theta}$,

então $\hat{\theta} = 1/\bar{x}$ é o estimador de máxima verossimilhança de θ e

$$g(\hat{\theta}) = R_{\hat{\theta}}(\tau) = \exp\{-\tau\hat{\theta}\} = \exp\{-\tau/\bar{x}\}$$

é o estimador de máxima verossimilhança de $g(\theta) = R_\theta(\tau)$.

(c) Encontre o ENVVUM de $R_\theta(\tau)$.

Dado que

$$\begin{aligned} f(\underline{x}; \theta) &= \theta^n \exp\left\{-\theta \sum_{i=1}^n x_i\right\}, \quad x_i > 0, i = 1, \dots, n \\ &= \exp\left\{-\theta \sum_{i=1}^n x_i + n \log \theta\right\}, \quad x_i > 0, i = 1, \dots, n \end{aligned}$$

então $f(\underline{x}; \theta)$ pertence à família exponencial multidimensional, com $\eta(\theta) = \theta$, $T(\underline{x}) = \sum_{i=1}^n x_i$, $B(\theta) = -n \log \theta$ e $h(\underline{x}) = 1$. Também, $\Omega = \{\theta; \theta > 0\}$. então o domínio de $\eta(\theta)$ contém intervalos abertos de \mathbb{R} e $\eta(\theta)$ num $T(\underline{x})$ satisfaz restrições lineares, então $T(\underline{x}) = \sum_{i=1}^n x_i$ é uma estatística suficiente e completa para θ .

Logo, dado que $s(\underline{x}) = \begin{cases} 1, & x_i > \tau \\ 0, & x_i \leq \tau \end{cases}$ é tal que

$$E(s(\underline{x})) = 1 \cdot P(X_i > \tau) + 0 \cdot P(X_i \leq \tau) = P(X_i > \tau) = e^{-\theta \tau} = R_\theta(\tau)$$

então $s(\underline{x})$ é um estimador não viésado de $R_\theta(\tau)$

Logo, dado que

$$\phi(t) = E[\delta(x) | T=t] = P(X_1 > \tau | T=t) = P\left(\frac{X_1}{T} > \frac{\tau}{t} | T=t\right)$$

$$= P\left(\frac{X_1}{T} > \frac{\tau}{t}\right)$$

com $T = T(\underline{x}) = \sum_{i=1}^n x_i > 0$, dado que $x_i > 0$, $i=1, \dots, n$.

mas,

$$P\left(\frac{X_1}{T} > \frac{\tau}{t}\right) = P\left(\frac{X_1}{X_1 + \sum_{i=2}^n x_i} > \frac{\tau}{t}\right)$$

com $X_1 \sim \text{Exp}(\theta)$, $\sum_{i=2}^n x_i \sim \text{Gama}(n-1, \theta)$ e $\frac{X_1}{X_1 + \sum_{i=2}^n x_i} \sim \text{Beta}(1, n-1)$

Então, para $t > 0$

$$\begin{aligned} \phi(t) &= P\left(\frac{X_1}{T} > \frac{\tau}{t}\right) = \int_{\tau/t}^1 \frac{\Gamma(n)}{\Gamma(1)\Gamma(n-1)} (1-y)^{n-2} dy = (n-1) \int_{\tau/t}^1 (1-y)^{n-2} dy \\ &= -(n-1) \left[\frac{(1-y)^{n-1}}{n-1} \right]_{\tau/t}^1 = \left(1 - \frac{\tau}{t}\right)^{n-1} \end{aligned}$$

Portanto, pelo teorema de Rad-Blockwell, $\phi(t) = (1 - \tau/t)^{n-1}$, $T > 0$ é o ENVVUM de $R_\theta(\tau)$.

(d) Mostre que o estimador de Bayes de $R_\theta(\tau)$ sob perda quadrática é função densidade a priori para θ

$$\pi(\theta) = \frac{1}{\gamma^v \Gamma(v)} \theta^{v-1} \exp(-\theta/\gamma), \quad \theta > 0$$

é dado por

$$\left(1 + \frac{\tau}{\sum_{i=1}^n x_i + 1/\gamma}\right)^{-(n+v)}$$

Dado que $f(x|\theta) = \theta^n \exp\{-n\theta\bar{x}\}$; $x_i > 0$, $i=1, \dots, n$ então, a distribuição posterior de θ é dada por

$$\pi(\theta|x) \propto f(x|\theta) \pi(\theta) \propto \theta^n e^{-n\theta\bar{x}} \theta^{v-1} e^{\theta/\gamma} = \theta^{n+v-1} \exp\{-\theta(n\bar{x} + 1/\gamma)\}$$

Portanto, $\theta|x \sim \text{Gama}(n+v, n\bar{x} + 1/\gamma)$.

Logo, dado que $L(\theta, d) = (d - g(\theta))^2$, ou seja $w(\theta) = 1$ e $g(\theta) = R_\theta(\tau)$, então o estimador de Bayes de $R_\theta(\tau)$ é dado por

$$S_A(\underline{x}) = E[R_\theta(\tau) | \underline{x} = \underline{x}]$$

mas,

$$\begin{aligned} E[R_\theta(\tau) | \underline{x} = \underline{x}] &= \int_0^{+\infty} e^{-\theta\tau} \frac{1}{\Gamma(n+v)} \left(\frac{n\bar{x}+1}{\gamma}\right)^{n+v} \theta^{n+v-1} \exp\{-\theta\left(\frac{n\bar{x}+1}{\gamma}\right)\} d\theta \\ &= \frac{(n\bar{x}+1)^{n+v}}{\gamma^{n+v}} \int_0^{+\infty} \frac{\theta^{n+v-1}}{\Gamma(n+v)} \exp\{-\theta\left(\frac{n\bar{x}+1+\gamma\tau}{\gamma}\right)\} d\theta \\ &= \frac{(n\bar{x}+1)^{n+v}}{\gamma^{n+v}} \cdot \frac{1}{\left(\frac{n\bar{x}+1+\gamma\tau}{\gamma}\right)^{n+v}} \int_0^{+\infty} \frac{\left(\frac{n\bar{x}+1+\gamma\tau}{\gamma}\right)^{n+v-1}}{\Gamma(n+v)} \cdot \exp\{-\theta\left(\frac{n\bar{x}+1+\gamma\tau}{\gamma}\right)\} d\theta \\ &\quad \text{Gama}(n+v, \frac{n\bar{x}+1+\gamma\tau}{\gamma}) \\ &= \frac{(n\bar{x}+1)^{n+v}}{\left(n\bar{x}+1+\gamma\tau\right)^{n+v}} = \frac{1}{\left(1 + \frac{\gamma\tau}{n\bar{x}+1}\right)^{n+v}} \\ &= \left(1 + \frac{\tau}{n\bar{x} + 1/\gamma}\right)^{-(n+v)} = \left(1 + \frac{\tau}{\sum_{i=1}^n x_i + 1/\gamma}\right)^{-(n+v)} \end{aligned}$$

Assim, o estimador de Bayes de $R_\theta(\tau)$, sob perda quadrática é

$$S_A(\underline{x}) = \left(1 + \frac{\tau}{\sum_{i=1}^n x_i + 1/\gamma}\right)^{-(n+v)}$$

(12) suponha que x tem distribuição $b(p, n)$ e considere o problema de estimar p com perda $(d-p)^2 / [p(1-p)]$. Obtenha o estimador minimax.

Dada uma distribuição a priori $\text{Beta}(a, b)$ para p , a distribuição a posteriori de p é dada por

$$\pi(p|x) \propto f(x|p) \pi(p), \quad 0 < p < 1$$

Então,

$$f(x|p) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x=0,1,\dots,n, \quad 0 < p < 1$$

$$\pi(p) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} p^{a-1} (1-p)^{b-1}, \quad 0 < p < 1, \quad a, b > 0$$

Assim,

$$\pi(p|x) \propto p^{x+a-1} (1-p)^{n+b-x-1}, \quad 0 < p < 1$$

Portanto, $p|x \sim \text{Beta}(x+a, n+b-x)$.

Logo, sob perda $L(p, d) = \frac{1}{p(1-p)} (d-p)^2$, $w(p) = \frac{1}{p(1-p)}$, o estimador de Bayes de p é

$$\delta_{\Delta}(x) = \frac{E[w(p)p|x=x]}{E[w(p)|x=x]} = \frac{E[\frac{1}{1-p}|x=x]}{E[\frac{1}{p(1-p)}|x=x]}$$

com $\Delta \equiv \text{Beta}(a, b)$

$$\begin{aligned} E\left[\frac{1}{1-p}|x=x\right] &= \int_0^1 \frac{1}{1-p} \pi(p|x) dp = \frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n+b-x)} \int_0^1 \frac{1}{1-p} p^{x+a-1} (1-p)^{n+b-x-1} dp \\ &= \frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n+b-x)} \int_0^1 p^{a-1} (1-p)^{b-1} dp; \quad a' = \underbrace{x+a}_{>0} \quad b' = \underbrace{n+b-x-1}_{>0} \\ &= \frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n+b-x)} \cdot \frac{\Gamma(a')\Gamma(b')}{\Gamma(a'+b')} \int_0^1 \frac{\Gamma(a'+b')}{\Gamma(a')\Gamma(b')} p^{a'-1} (1-p)^{b'-1} dp \end{aligned}$$

Então,

$$\begin{aligned} E\left[\frac{1}{1-p}|x=x\right] &= \frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n+b-x)} \frac{\Gamma(x+a)\Gamma(n+b-x-1)}{\Gamma(n+a+b-1)} = \frac{\Gamma(n+a+b)\Gamma(n+b-x-1)}{\Gamma(n+b-x)\Gamma(n+a+b-1)} \\ &= \frac{(n+a+b-1)\Gamma(n+a+b-1)\Gamma(n+b-x-1)}{(n+b-x-1)\Gamma(n+b-x-1)\Gamma(n+a+b-1)} = \frac{n+a+b-1}{n+b-x-1} \end{aligned}$$

Também,

$$\begin{aligned} E\left[\frac{1}{p(1-p)}|x=x\right] &= \frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n+b-x)} \int_0^1 \frac{1}{p(1-p)} p^{x+a-1} (1-p)^{n+b-x-1} dp \\ &= \frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n+b-x)} \int_0^1 p^{x+a-2} (1-p)^{n+b-x-2} dp \\ &= \frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n+b-x)} \cdot \frac{\Gamma(a')\Gamma(b')}{\Gamma(a'+b')} \int_0^1 \frac{\Gamma(a'+b')}{\Gamma(a')\Gamma(b')} p^{a'-1} (1-p)^{b'-1} dp \\ &\quad \text{Beta}(a', b') \end{aligned}$$

então $a' = x+a-1$ e $b' = n+b-x-1$, portanto

$$\begin{aligned} E\left[\frac{1}{p(1-p)}|x=x\right] &= \frac{\Gamma(n+a+b)}{\Gamma(x+a)\Gamma(n+b-x)} \frac{\Gamma(x+a-1)\Gamma(n+b-x-1)}{\Gamma(n+a+b-2)} \\ &= \frac{(n+a+b-1)\Gamma(n+a+b-1)\Gamma(x+a-1)\Gamma(n+b-x-1)}{(x+a-1)\Gamma(x+a-1)(n+b-x-1)\Gamma(n+b-x-1)\Gamma(n+a+b-2)} \\ &= \frac{(n+a+b-1)(n+a+b-2)\Gamma(n+a+b-2)}{(x+a-1)(n+b-x-1)\Gamma(n+a+b-2)} \\ &= \frac{(n+a+b-1)(n+a+b-2)}{(x+a-1)(n+b-x-1)} \end{aligned}$$

Assim,

$$\delta_{\Delta}(x) = \frac{n+a+b-1}{n+b-x-1} \cdot \frac{(x+a-1)(n+b-x-1)}{(n+a+b-1)(n+a+b-2)} = \frac{x+a-1}{n+a+b-2}$$

é o estimador de Bayes sob perda dada.

logD,

$$\begin{aligned} R(p, \delta_{\Delta}(x)) &= E[L(p, \delta_{\Delta}(x))] = E\left[\frac{1}{p(1-p)} (\delta_{\Delta}(x) - p)^2\right] \\ &= \frac{1}{p(1-p)} E[(\delta_{\Delta}(x) - p)^2] = \frac{1}{p(1-p)} \left[\text{Var}(\delta_{\Delta}(x) - p) + E^2(\delta_{\Delta}(x) - p) \right] \\ &= \frac{1}{p(1-p)} \left[\text{Var}(\delta_{\Delta}(x)) + E^2(\delta_{\Delta}(x) - p) \right] \end{aligned}$$

mas,

$$\text{Var}(\delta_{\Delta}(x)) = \frac{np(1-p)}{(n+a+b-2)^2} \quad \text{e} \quad E(\delta_{\Delta}(x)) = \frac{np+a-1}{n+a+b-2}$$

então

$$\begin{aligned} R(p, \delta_{\Delta}(x)) &= \frac{1}{p(1-p)} \left[\frac{np(1-p)}{(n+a+b-2)^2} + \left(\frac{np+a-1}{n+a+b-2} - p \right)^2 \right] \\ &= \frac{1}{p(1-p)} \left[np(1-p) + (np+a-1 - np - p(a+b-2))^2 \right] \frac{1}{(n+a+b-2)^2} \\ &= \frac{1}{(n+a+b-2)^2} \left[n + \frac{1}{p(1-p)} (a-1 - p(a+b-2))^2 \right] \end{aligned}$$

Logo, fazendo $a=b=1$,

$$R(p, \delta_{\Delta}(x)) = \frac{1}{n^2} \left[n + \frac{1}{p(1-p)} \cdot 0 \right] = \frac{1}{n}$$

Assim, se $a=b=1$ o risco é constante e

$$\delta_{\Delta}(x) = \frac{x}{n}$$

é o estimador minimax de p .

(13) Sejam X_1, \dots, X_m e Y_1, \dots, Y_n amostras aleatórias independentes das distribuições $N(\mu_x, \sigma_x^2)$ e $N(\mu_y, \sigma_y^2)$, respectivamente; aqui $\mu_x \in \mathbb{R}$, $\mu_y \in \mathbb{R}$, $\sigma_x^2 > 0$ e $\sigma_y^2 > 0$. Considere o problema de estimar $\Delta = \mu_y - \mu_x$ sob perda quadrática.

(a) Mostre que $\bar{Y} - \bar{X}$ é estimador minimax de Δ quando σ_x e σ_y são conhecidos; $\bar{x} = m^{-1} \sum_{i=1}^m X_i$ e $\bar{y} = n^{-1} \sum_{i=1}^n Y_i$.

Seja $\pi_{X,j} = N(0, j)$ e $\pi_{Y,j} = N(0, j)$, $j=1, 2, \dots$ uma sequência de distribuições a prioris de μ_x e μ_y . Então, o estimador de Bayes de μ_x e μ_y são respectivamente, (dado a sugestão)

$$\frac{m_j \bar{x}}{m_j + \sigma_x^2}$$

e

$$\frac{n_j \bar{y}}{n_j + \sigma_y^2}$$

Logo, o estimador de Bayes de $\Delta = \mu_y - \mu_x$ sob perda quadrática é

$$s_j = \frac{n_j \bar{y}}{n_j + \sigma_y^2} - \frac{m_j \bar{x}}{m_j + \sigma_x^2}$$

$$\begin{aligned} \frac{\frac{m_j \bar{x}}{\sigma_x^2} + \frac{0}{\sigma_y^2}}{\frac{n_j}{\sigma_x^2} + \frac{1}{\sigma_y^2}} &= \frac{\frac{m_j \bar{x}}{\sigma_x^2}}{\frac{n_j}{\sigma_x^2} + \frac{1}{\sigma_y^2}} \\ &= \frac{m_j \bar{x}}{m_j + \sigma_x^2} \end{aligned}$$

Logo,

$$\lim_{j \rightarrow \infty} R(\Delta, s_j) = \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m}$$

que não depende de (μ_x, μ_y) e é igual ao risco de $\bar{Y} - \bar{X}$,

$$\begin{aligned} E[(\bar{Y} - \bar{X} - \mu_y + \mu_x)^2] &= E[(\bar{Y} - \mu_y)^2] + E[(\bar{X} - \mu_x)^2] + 0 \\ &= \text{Var}(\bar{Y}) + \text{Var}(\bar{X}) \\ &= \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m} \end{aligned} \quad (*)$$

Portanto $\bar{Y} - \bar{X}$ é minimax.

(b) Mostre que $\bar{Y} - \bar{X}$ é estimador minimax de Δ quando $\sigma_x^2 \leq M_x$ e $\sigma_y^2 \leq M_y$, sendo $M_x > 0$ e $M_y > 0$ constantes conhecidas.

seja $\Theta = \{(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2) : \mu_x \in \mathbb{R}, \mu_y \in \mathbb{R}, \sigma_x^2 \in (0, M_x], \sigma_y^2 \in (0, M_y]\}$

$\Theta_0 = \{(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2) : \mu_x \in \mathbb{R}, \mu_y \in \mathbb{R}, \sigma_x^2 = M_x, \sigma_y^2 = M_y\}$

Então, por (a) $\bar{Y} - \bar{X}$ é minimax quando Θ_0 é considerado como o espaço paramétrico

seja $R_{\bar{Y}-\bar{X}}(\Theta)$ a função de risco de $\bar{Y} - \bar{X}$, então dado que

$$\sup_{\Theta \subset \Theta} R_{\bar{Y}-\bar{X}}(\Theta) = \frac{M_y}{n} + \frac{M_x}{m}$$

e

$$\sup_{\Theta \in \Theta_0} R_{\bar{Y}-\bar{X}}(\Theta) = \frac{M_y}{n} + \frac{M_x}{m}$$

dado que $R(\Delta, \bar{Y} - \bar{X}) = \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m}$ (dado *) e $\sigma_y^2 \in (0, M_y]$ e $\sigma_x^2 \in (0, M_x]$

então $\bar{Y} - \bar{X}$ é minimax.

com risco de Bayes,

$$\begin{aligned} R(\Delta, s_j) &= E \left[\left(\frac{n_j \bar{y}}{n_j + \sigma_y^2} - \frac{m_j \bar{x}}{m_j + \sigma_x^2} - \mu_y + \mu_x \right)^2 \right] \\ &= E \left[\left(\frac{n_j \bar{y}}{n_j + \sigma_y^2} - \mu_y \right)^2 + \left(\frac{m_j \bar{x}}{m_j + \sigma_x^2} - \mu_x \right)^2 - 2 \left(\frac{n_j \bar{y}}{n_j + \sigma_y^2} - \mu_y \right) \left(\frac{m_j \bar{x}}{m_j + \sigma_x^2} - \mu_x \right) \right] \\ &= \left(\frac{n_j}{n_j + \sigma_y^2} \right)^2 \text{Var}(\bar{Y}) + \mu_y \left(\frac{n_j}{n_j + \sigma_y^2} - 1 \right)^2 + \left(\frac{m_j}{m_j + \sigma_x^2} \right) \text{Var}(\bar{X}) + \mu_x \left(\frac{m_j}{m_j + \sigma_x^2} - 1 \right)^2 \\ &\quad - 2 \left(\frac{n_j}{n_j + \sigma_y^2} - 1 \right) \left(\frac{m_j}{m_j + \sigma_x^2} - 1 \right) \mu_y \mu_x \\ &= \left(\frac{1}{1 + \sigma_y^2/n_j} \right)^2 \frac{\sigma_y^2}{n} + \mu_y \left(\frac{1}{1 + \sigma_y^2/n_j} - 1 \right)^2 + \left(\frac{1}{1 + \sigma_x^2/m_j} \right) \frac{\sigma_x^2}{m} + \mu_x \left(\frac{1}{1 + \sigma_x^2/m_j} - 1 \right)^2 \\ &\quad - 2 \left(\frac{1}{1 + \sigma_y^2/n_j} - 1 \right) \left(\frac{1}{1 + \sigma_x^2/m_j} - 1 \right) \mu_y \mu_x \end{aligned}$$

9.6

ESTATÍSTICA AVANÇADA I - LISTA 4

Jaime Enrique Lincovil Curivil
Maicon Aparecido Pinheiro

Exercício 1. Por resultado visto em aula, sabemos que sob perda quadrática o estimador de Bayes é dado pela média a posteriori de θ . Portanto, para determiná-lo, vamos em um primeiro passo determinar a distribuição a posteriori de θ .

Supondo que, dado θ , X_1, \dots, X_n são variáveis aleatórias independentes e identicamente distribuídas com distribuição $U(\cdot, \theta)$, $\theta > 0$, segue que

$$f(x_1, \dots, x_n | \theta) = \prod_{i=1}^n \left[\frac{1}{\theta} I_{(0, \theta)}(x_i) \right] = \frac{1}{\theta^n} I_{(0, x_{(n)})}(x_{(1)}) I_{(0, \theta)}(x_{(n)}) = \frac{1}{\theta^n} I_{(0, x_{(n)})}(x_{(1)}) I_{(x_{(n)}, +\infty)}(\theta).$$

Ao considerar uma distribuição a priori Pareto(α, γ) para θ , isto é,

$$p(\theta) = \frac{\alpha \gamma^\alpha}{\theta^{\alpha+1}} I_{(\gamma, +\infty)}(\theta),$$

segue que a posteriori de θ é tal que

$$\begin{aligned} p(\theta | x_1, \dots, x_n) &\propto f(x_1, \dots, x_n | \theta) p(\theta) \propto \frac{1}{\theta^n} I_{(x_{(n)}, +\infty)}(\theta) \frac{1}{\theta^{\alpha+1}} I_{(\gamma, +\infty)}(\theta) \\ &\propto \frac{1}{\theta^{n+\alpha+1}} I_{(\max\{x_{(n)}, \gamma\}, +\infty)}(\theta). \end{aligned}$$

Logo, a distribuição a posteriori de θ é uma Pareto($n + \alpha, \max\{x_{(n)}, \gamma\}$). Assim, o estimador de Bayes para θ - vamos denotá-lo por δ_Λ , onde Λ representa a função distribuição de uma Pareto(α, γ) - é dado por

$$\delta_\Lambda(X_1, \dots, X_n) = \frac{(n + \alpha) \max\{X_{(n)}, \gamma\}}{n + \alpha - 1},$$

uma vez que

$$\begin{aligned} E[\theta | x_1, \dots, x_n] &= \int_{\max\{x_{(n)}, \gamma\}}^{+\infty} \theta \frac{(n + \alpha) \max\{x_{(n)}, \gamma\}^{n+\alpha}}{\theta^{n+\alpha+1}} d\theta \\ &= \frac{(n + \alpha) \max\{x_{(n)}, \gamma\}^{n+\alpha}}{(n + \alpha - 1) \theta^{n+\alpha-1}} \Big|_{\max\{x_{(n)}, \gamma\}}^{+\infty} \\ &= \frac{(n + \alpha) \max\{x_{(n)}, \gamma\}}{n + \alpha - 1}. \end{aligned}$$

Exercício 6.

- a. Do enunciado, sabemos que

$$f(x | \theta) = \frac{1}{\theta} I_{(0, \theta)}(x) = \frac{1}{\theta} I_{(x, +\infty)}(\theta),$$

e que

$$\pi(\theta) = \frac{1}{(1 + \theta)^2} I_{\mathbb{R}_+}(\theta).$$

Daí, segue que, para $x > 0$,

$$\begin{aligned} q(x) := f(x) &= \int_{\Omega} f(x|\theta)\pi(\theta)d\theta \\ &= \int_{\Omega} \frac{1}{\theta(1+\theta)^2} I_{\mathbb{R}_+}(\theta)I_{(x,+\infty)}(\theta)d\theta \\ &= \int_x^{+\infty} \frac{1}{\theta(1+\theta)^2}d\theta, \end{aligned}$$

onde Ω foi utilizado para representar o espaço paramétrico. Para resolver a integral acima, vamos utilizar o método das frações parciais, isto é, vamos encontrar os valores das constantes reais A , B e C tal que

$$\frac{1}{\theta(1+\theta)^2} = \frac{A}{\theta} + \frac{B}{1+\theta} + \frac{C}{(1+\theta)^2}.$$

Notando que

$$\begin{aligned} \frac{1}{\theta(1+\theta)^2} &= \frac{A}{\theta} + \frac{B}{1+\theta} + \frac{C}{(1+\theta)^2} \Leftrightarrow \\ \frac{1}{\theta(1+\theta)^2} &= \frac{A(1+\theta)^2 + B\theta(1+\theta) + C\theta}{\theta(1+\theta)^2} \Leftrightarrow \\ \frac{1}{\theta(1+\theta)^2} &= \frac{A(1+2\theta+\theta^2) + B(\theta+\theta^2) + C\theta}{\theta(1+\theta)^2} \Leftrightarrow \\ \frac{1}{\theta(1+\theta)^2} &= \frac{A + (2A+B+C)\theta + (B+A)\theta^2}{\theta(1+\theta)^2}, \end{aligned}$$

segue, igualando os polinômios dos numeradores, que $A = 1$, donde decorre que $B = -1$ e $C = -1$. Assim,

$$\begin{aligned} q(x) &= \int_x^{+\infty} \frac{1}{\theta} - \frac{1}{1+\theta} - \frac{1}{(1+\theta)^2}d\theta = \left[\ln \theta - \ln(1+\theta) + \frac{1}{1+\theta} \right]_x^{+\infty} \\ &= \left[\ln \left(\frac{\theta}{1+\theta} \right) + \frac{1}{1+\theta} \right]_x^{+\infty} = 0 + 0 - \ln \left(\frac{x}{1+x} \right) - \frac{1}{1+x} \\ &= \ln \left(\frac{1+x}{x} \right) - \frac{1}{1+x}, \quad \text{para } x > 0, \end{aligned}$$

como queríamos mostrar.

- b. De nota vista em aula, sabemos que o estimador de Bayes ($\delta(X)$) sob perda absoluta $L(\theta, d) = |d - \theta|$ é dado pela mediana a posteriori. Daí, denotando por $\pi(\theta|x)$ a posteriori de θ , segue que

$$\begin{aligned} \int_{\delta(x)}^{+\infty} \pi(\theta|x)d\theta &= \frac{1}{2} \Leftrightarrow \int_{\delta(x)}^{+\infty} \frac{\pi(\theta)f(x|\theta)}{q(x)}d\theta = \frac{1}{2} \Leftrightarrow \\ \int_{\delta(x)}^{+\infty} \pi(\theta)f(x|\theta)d\theta &= \frac{q(x)}{2} \Leftrightarrow \int_{\delta(x)}^{+\infty} \frac{1}{\theta(1+\theta)^2}d\theta = \frac{q(x)}{2} \Leftrightarrow \\ \left[\ln \left(\frac{\theta}{1+\theta} \right) + \frac{1}{1+\theta} \right]_{\delta(x)}^{+\infty} &= \frac{q(x)}{2} \Leftrightarrow -\ln \left(\frac{\delta(x)}{1+\delta(x)} \right) + \frac{1}{1+\delta(x)} = \frac{q(x)}{2} \Leftrightarrow \\ \ln \left(\frac{1+\delta(x)}{\delta(x)} \right) - \frac{1}{1+\delta(x)} &= \frac{q(x)}{2} \Leftrightarrow q(\delta(x)) = \frac{q(x)}{2}, \end{aligned}$$

onde a segunda e quarta equivalências decorrem de $q(x)$ ser constante em relação à θ e da resolução da integral exibida no item a., respectivamente. Logo $\delta(X)$ é solução de

$$q(\delta(X)) = \frac{q(X)}{2}.$$

Exercício 9.

a. Seja $\bar{\theta} = \hat{\theta} + c$. Logo, sob a perda quadrática temos que:

$$L(\theta, \bar{\theta}) = (\bar{\theta} - \theta)^2 = [(\hat{\theta} - \theta) + c]^2 = (\hat{\theta} - \theta)^2 + 2c(\hat{\theta} - \theta) + c^2.$$

Assim, o risco médio de $\bar{\theta}$ é dado por

$$\begin{aligned} R(\theta, \bar{\theta}) &= E_{\theta}[L(\theta, \bar{\theta})] = E_{\theta}[(\hat{\theta} - \theta)^2 + c^2] = Var_{\theta}(\hat{\theta}) + c^2 \\ &= R(\theta, \hat{\theta}) + c^2, \end{aligned}$$

uma vez que a perda é quadrática e $\hat{\theta}$ é não viciado. Agora, seja Δ a classe de todos os estimadores de θ e $\Delta^* \subset \Delta$ a classe dos estimadores não viciados. Logo,

$$\inf_{\delta \in \Delta} \sup_{\theta} \{R(\delta, \theta)\} \leq \inf_{\delta \in \Delta^*} \sup_{\theta} \{R(\delta, \theta)\} < \sup_{\theta} \{R(\bar{\theta}, \theta)\}.$$

Desde que $R(\theta, \bar{\theta}) > R(\theta, \hat{\theta})$, segue por definição que $\bar{\theta}$ não é estimador minimax. Por outro lado se

$$\sup_{\theta} \{R(\delta, \theta)\} = \infty \quad \forall \delta \in \Delta,$$

temos que

$$\inf_{\delta \in \Delta} \sup_{\theta} \{R(\delta, \theta)\} = \sup_{\theta} \{R(\bar{\theta}, \theta)\} = \infty.$$

Daí, por definição, $\bar{\theta}$ é estimador minimax.

b. Se considerarmos $\bar{\theta} = c\hat{\theta}$, sob a perda quadrática temos que

$$\begin{aligned} L(\theta, \bar{\theta}) &= (c\hat{\theta} - \theta)^2 = (c\hat{\theta} - c\theta + c\theta - \theta)^2 \\ &= (c\hat{\theta} - c\theta)^2 + 2(c\hat{\theta} - c\theta)(c\theta - \theta) + (c\theta - \theta)^2. \end{aligned}$$

onde decorre que

$$R(\theta, c\hat{\theta}) = (1 - c)^2 \theta^2 + c^2 Var_{\theta}(\hat{\theta}) = (1 - c)^2 \theta^2 + c^2 R(\theta, \hat{\theta}).$$

Ou seja, $R(\theta, \bar{\theta}) > R(\theta, \hat{\theta})$ e como no caso anterior,

$$\inf_{\delta \in \Delta} \sup_{\theta} \{R(\delta, \theta)\} \leq \inf_{\delta \in \Delta^*} \sup_{\theta} \{R(\delta, \theta)\} < \sup_{\theta} \{R(\bar{\theta}, \theta)\}.$$

$R(\theta, \hat{\theta})$, pois
 $0 < c < 1$.

Logo, por definição, $\bar{\theta}$ não é estimador minimax. Por outro lado se

$$\sup_{\theta} \{R(\delta, \theta)\} = \infty \quad \forall \delta \in \Delta,$$

temos que

$$\inf_{\delta \in \Delta} \sup_{\theta} \{R(\delta, \theta)\} = \sup_{\theta} \{R(\bar{\theta}, \theta)\} = \infty.$$

Neste caso, por definição, $\bar{\theta} = c\hat{\theta}$ é estimador minimax.

c. Sob a perda dada, o risco do estimador $c\hat{\theta}$ é dada por:

$$\begin{aligned} R(\theta, c\hat{\theta}) &= E_{\theta} \left[\frac{(\bar{\theta} - \theta)^2}{\theta^2} \right] = \frac{1}{\theta^2} E_{\theta} [(\bar{\theta} - \theta)^2] \\ &= \frac{1}{\theta^2} [c^2 E_{\theta} (\hat{\theta} - \theta)^2 + \theta^2 (c-1)^2] \\ &= c^2 E_{\theta} \left[\frac{(\hat{\theta} - \theta)^2}{\theta^2} \right] + (c-1)^2 = c^2 R(\theta, \hat{\theta}) + (c-1)^2. \end{aligned}$$

Considerando $\zeta = \sup_{\theta} R(\theta, \hat{\theta}) < \infty$ e $c = 1/(1+\zeta)$. Então,

$$\sup_{\theta} \bar{\theta} = (1-c)^2 + c^2 \zeta = \frac{\zeta^2}{(1+\zeta^2)^2} + \frac{\zeta}{(1+\zeta^2)^2} = \frac{\zeta}{1+\zeta} < \zeta$$

Portanto, $\hat{\theta}$ não é estimador minimax, a menos que $\sup_{\theta} R(\theta, \hat{\theta}) = \infty$ para todo estimador $\delta \in \Delta$ de θ .

Exercício 15. Por definição, \bar{X} será um estimado minimax para p se minimiza o risco máximo, ou seja,

$$\inf_{\delta} \sup_{p \in (0,1)} R(p, \delta) = \sup_{p \in (0,1)} R(\theta, \bar{X}).$$

No entanto, recordando que para um dado estimador $\delta(\mathbf{X})$ de p sob perda quadrática,

$$R(p, \delta(\mathbf{X})) = E_p (\delta(\mathbf{X}) - p)^2 = Var_p (\delta(\mathbf{X}) + (E(\delta(\mathbf{X})) - p)^2), \quad p \in (0, 1),$$

segue que

$$R(p, \bar{X}) = Var_p (\bar{X}) + (E_p (\bar{X}) - p)^2 = \frac{p(1-p)}{n} + \left(\frac{np}{n} - p \right)^2 = \frac{p(1-p)}{n}, \quad p \in (0, 1),$$

de modo que

$$\sup_{p \in (0,1)} R(\theta, \bar{X}) = \frac{1}{4n},$$

uma vez que a função $R(\theta, \bar{X})$ atinge o máximo em $p = 1/2$, $p \in (0, 1)$. Por outro lado, ao considerar o estimador

$$T(\mathbf{X}) = \begin{cases} \bar{X}, & \text{com probabilidade } \frac{n}{n+1}; \\ 1/2, & \text{com probabilidade } \frac{1}{n+1}, \end{cases}$$

temos que

$$\begin{aligned} R(p, T(\mathbf{X})) &= E_p (T(\mathbf{X}) - p)^2 = E_p (E_p ((T(\mathbf{X}) - p)^2 | T(\mathbf{X}))) \\ &= E_p (E_p ((T(\mathbf{X}) - p)^2 | T(\mathbf{X}) = \bar{X})) \mathbb{P}(T(\mathbf{X}) = \bar{X}) \\ &\quad + E_p (E_p ((T(\mathbf{X}) - p)^2 | T(\mathbf{X}) = 1/2)) \mathbb{P}(T(\mathbf{X}) = 1/2) \\ &= \frac{p(1-p)}{n} \frac{n}{n+1} + (1/2 - p)^2 \frac{n}{n+1} \\ &= \frac{p - p^2 + p^2 - p + 1/4}{n+1} \\ &= \frac{1}{4(n+1)}. \end{aligned}$$

Assim,

$$\sup_{p \in (0,1)} R(\theta, T(\mathbf{X})) = \frac{1}{4(n+1)}.$$

Uma vez que o risco máximo do estimador aleatorizado $T(\mathbf{X})$ é menor que o risco máximo do estimador \bar{X} , já podemos concluir que

$$\inf_{\delta} \sup_{p \in (0,1)} R(p, \delta) < \sup_{p \in (0,1)} R(\theta, \bar{X}),$$

onde decorre a conclusão de que \bar{X} não é um estimador minimax de p .

Exercício 16.

- a. Vamos propor as distribuições $N(a_1, b_1^2)$ e $N(a_2, b_2^2)$ como distribuições a priori para μ_x e μ_y , respectivamente. Temos que a distribuição à posteriori bivariada de (μ_x, μ_y) dado $(X, Y) = (x, y)$, é tal que

$$\begin{aligned}\pi(\mu_x, \mu_y | X, Y) &\propto f(X, Y | \mu_x, \mu_y) \pi(\mu_x, \mu_y) \\ &\propto f(X, Y | \mu_x, \mu_y) \pi(\mu_x) \pi(\mu_y) \\ &\propto f(X | \mu_x) \pi(\mu_x) f(Y | \mu_y) \pi(\mu_y).\end{aligned}$$

Como, dado (μ_x, μ_y) , X e Y são independentes, temos que

$$\mu_x | X \sim \text{Normal}\left(\frac{\frac{m\bar{x}}{\sigma_x^2} + \frac{a_1}{b_1^2}}{\frac{m}{\sigma_x^2} + \frac{1}{b_1^2}}, \left[\frac{m}{\sigma_x^2} + \frac{1}{b_1^2}\right]^{-1}\right)$$

$$\mu_y | Y \sim \text{Normal}\left(\frac{\frac{n\bar{y}}{\sigma_y^2} + \frac{a_2}{b_2^2}}{\frac{n}{\sigma_y^2} + \frac{1}{b_2^2}}, \left[\frac{n}{\sigma_y^2} + \frac{1}{b_2^2}\right]^{-1}\right)$$

Por outro lado, sob a perda quadrática o estimador de Bayes, $\delta_\Lambda(X, Y)$ de $\mu_y - \mu_x$, é dado por $\delta_\Lambda(X, Y) = E[g(\mu_x, \mu_y) | X, Y]$, onde $g(\mu_x, \mu_y) = \mu_y - \mu_x$. Ou seja,

$$\begin{aligned}\delta(X, Y) &= E[\mu_y - \mu_x | X, Y] = E[\mu_y | X, Y] - E[\mu_x | X, Y] = E[\mu_y | Y] - E[\mu_x | X] \\ &= \frac{\frac{n\bar{y}}{\sigma_y^2} + \frac{a_2}{b_2^2}}{\frac{n}{\sigma_y^2} + \frac{1}{b_2^2}} - \frac{\frac{m\bar{x}}{\sigma_x^2} + \frac{a_1}{b_1^2}}{\frac{m}{\sigma_x^2} + \frac{1}{b_1^2}}\end{aligned}$$

Para dar resposta ao problema acharemos uma sequência de distribuições a priori tais que a sequência de riscos de bayes converja a um risco igual ao supremo do risco médio de $\delta(X, Y)$ do estimador. Seja Λ_{1k} e Λ_{2k} duas sequências de distribuições a priori para X e Y da forma $\text{Normal}(0, b_{ik})$, $i = 1, 2$, tais que $b_{ik} \rightarrow \infty$ quando $k \rightarrow \infty$. Dado que $a_1 = a_2 = 0$, a sequência de estimadores de Bayes $\delta_k(X, Y)$ tem a forma

$$\delta_k(X, Y) = \frac{nb_{2k}\bar{y}}{nb_{2k} - \sigma_y^2} - \frac{mb_{1k}\bar{x}}{mb_{1k}\sigma_x^2}.$$

O risco médio do estimador pode ser reduzida à expressão

$$\begin{aligned}R(\mu_y - \mu_x, \delta_k(X, Y)) &= E_\theta \left[\left(\frac{nb_{2k}\bar{y}}{nb_{2k} - \sigma_y^2} - \frac{mb_{1k}\bar{x}}{mb_{1k}\sigma_x^2} - \mu_y + \mu_x \right)^2 \right] \\ &= \left(\frac{1}{1 + \sigma_y^2/nb_{2k}} \right)^2 \frac{\sigma_y^2}{n} + \mu_y \left(\frac{1}{1 + \sigma_y^2/nb_{2k}} - 1 \right)^2 \\ &\quad + \left(\frac{1}{1 + \sigma_x^2/mb_{1k}} \right)^2 \frac{\sigma_x^2}{m} + \mu_x \left(\frac{1}{1 + \sigma_x^2/mb_{1k}} - 1 \right)^2 \\ &\quad - 2\mu_x\mu_y \left(\frac{1}{1 + \sigma_y^2/nb_{2k}} - 1 \right) \left(\frac{1}{1 + \sigma_x^2/mb_{1k}} - 1 \right).\end{aligned}$$

Logo

$$r_k(\Lambda, \delta_k(X, Y)) = E_\Lambda[R(\mu_y - \mu_x, \delta_k(X, Y))] = \left(\frac{1}{1 + \sigma_y^2/nb_{2k}} \right)^2 \frac{\sigma_y^2}{n} + \left(\frac{1}{1 + \sigma_x^2/mb_{1k}} \right) \frac{\sigma_x^2}{m}.$$

Deste modo temos que

$$\lim_{k \rightarrow \infty} r_k(\Lambda, \delta_k(X, Y)) = \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m}.$$

Notemos que $\delta_k(X, Y) \rightarrow \bar{Y} - \bar{X}$ quando $k \rightarrow \infty$. Também temos que,

$$\begin{aligned} R(\mu_y - \mu_x, \bar{Y} - \bar{X}) &= E[((\bar{Y} - \bar{X}) - (\mu_y - \mu_x))^2] = E[((\bar{Y} - \mu_y) - (\bar{X} - \mu_x))^2] \\ &= Var(\bar{Y}) - Var(\bar{X}) = \frac{\sigma_y^2}{n} - \frac{\sigma_x^2}{m}. \end{aligned}$$

Logo,

$$\sup_{\theta} R(\mu_y - \mu_x, \bar{Y} - \bar{X}) = \frac{\sigma_y^2}{n} - \frac{\sigma_x^2}{m}.$$

Deste modo, $\bar{Y} - \bar{X}$ é estimador minimax de $\mu_y - \mu_x$.

- b. Seja $\Theta = (\mu_y, \mu_x, \sigma_y^2, \sigma_x^2)$, em que $\mu_x, \mu_y \in R$, $\sigma_y^2 \leq M_y$ e $\sigma_x^2 \leq M_x$, com M_x e M_y conhecidos e também $\Theta_0 = (\mu_y, \mu_x, \sigma_{0y}^2, \sigma_{0x}^2)$, em que $\mu_x, \mu_y \in R$, mas desta vez $\sigma_{0y}^2 = M_y$ e $\sigma_{0x}^2 = M_x$. Então, pelo exercício 19(a), $\bar{Y} - \bar{X}$ é o estimador de $\mu_y - \mu_x$ quando o espaço paramétrico é dado por Θ_0 .

Seja $R(\mu_y - \mu_x, \bar{Y} - \bar{X})$ é a função de risco médio quando é considerado o espaço Θ . Logo

$$\sup_{\theta \in \Theta} R(\mu_y - \mu_x, \delta(X, Y)) = \frac{M_y}{n} + \frac{M_x}{m}$$

e também

$$\sup_{\theta \in \Theta_0} R(\mu_y - \mu_x, \delta(X, Y)) = \frac{M_y}{n} + \frac{M_x}{m}$$

também, dado que $R(\mu_y - \mu_x, \bar{Y} - \bar{X}) = \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m}$ e

$$E_{\mu_y, \mu_x} [(\bar{Y} - \bar{X} - \mu_y + \mu_x)^2] = \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m},$$

e também que $\sigma_y^2 \in (0, M_x]$ e $\sigma_x^2 \in (0, M_y]$. Então $\bar{Y} - \bar{X}$ é minimax quando é considerado o espaço paramétrico Θ .

Exercício 17. Denotaremos por Δ o conjunto de todos os estimadores de parâmetro e δ_Λ (Λ é a distribuição a priori de $g(\theta)$) o estimador de Bayes que é ENVVUM, minimax e admissível. Logo supondo válidas as condições para a existência da distribuição a posterior dada por $g(\theta|X)$, temos que o estimador de Bayes de $a g(\theta) + b$ sob a perda quadrática é dado por:

$$E_\Lambda(a g(\theta) + b | X) = a \delta_\Lambda + b.$$

(i) ENVVUM.

Dado que δ_Λ é UNVVUM ele é não correlacionado com $U(X)$ que pertence à classe de estimadores não viciados de 0, ou seja $E(\delta_\Lambda U(X)) = 0$. Assim:

$$Cov_\theta(a\delta_\Lambda + b, U(x)) = E_\theta(U(x)[a\delta_\Lambda + b]) = aE_\theta(\delta_\Lambda U(X)) = 0.$$

Logo $a\delta_\Lambda + b$ é ENVVUM para estimar $ag(\theta) + b$.

(ii) Admissível. Por hipótese temos que δ_Λ é admissível, então:

$$R(g(\theta), \delta_\Lambda) \leq R(g(\theta), \delta), \forall \delta \in \Delta.$$

Agora, nos temos:

$$R(ag(\theta) + b, a\delta_\Lambda + b) = E[a^2(g(\theta) - \delta_\Lambda)] = a^2 R(g(\theta), \delta_\Lambda).$$

Supondo que $a\delta_\Lambda + b$, não é admissível, e existe um estimador $a\delta' + b$ tal que:

$$a^2 R(g(\theta), \delta_\Lambda) \geq a^2 R(g(\theta), \delta').$$

o qual implica que $R(g(\theta), \delta_\Lambda) \geq R(g(\theta), \delta')$ ou seja que δ_Λ é inadmissível, o que contradiz a hipótese inicial.

(iii) Minimax. Por hipótese temos que δ_Λ é minimax para $g(\theta)$, então:

$$\inf_{\delta \in \Delta} \sup_{\theta} \{R(g(\theta), \delta)\} = \sup_{\theta} \{R(g(\theta), \delta_\Lambda)\}.$$

Logo, multiplicando por a^2 em ambos lados da igualdade, pela parte 19(ii) temos que:

$$\inf_{\delta \in \Delta} \sup_{\theta} \{R(ag(\theta) + b, a\delta + b)\} = \sup_{\theta} \{R(ag(\theta) + b, a\delta_\Lambda + b)\}.$$

Então, $a\delta_\Lambda + b$ é minimax para estimar $ag(\theta) + b$.

Bayes?

9.8

Lista de Exercícios 5

MAE 5834 - ESTATÍSTICA AVANÇADA I

Prof. Silvia L.P. Ferrari

Hugo Alberto Brango García - 9176006

Mario José Pacheco López - 9034481

2º semestre, 2014

① Seja (x_1, \dots, x_n) uma amostra aleatória de variável aleatória com função densidade de probabilidade

$$f(x; \theta) = \theta^{-c} c x^{c-1} \exp\{-x/\theta\}^c, \quad x > 0; \quad \theta > 0, \quad c > 0;$$

em que c é conhecido.

(a) Obtenha um teste uniformemente mais poderoso de $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$ de nível α .

Sejam θ e θ' quaisquer, em que $\theta < \theta'$ e $\theta > 0$, então dado que

$$f(\underline{x}; \theta) = \theta^{-nc} c^n \left[\prod_{i=1}^n x_i^{c-1} \right] \exp\left\{ -\sum_{i=1}^n (x_i/\theta)^c \right\}, \quad x_i > 0, i=1, \dots, n; \quad \theta > 0, \quad c > 0$$

então $f(\underline{x}; \theta)$ e $f(\underline{x}; \theta')$ não distintas e a razão de verossimilhanças é dada por:

$$\frac{f(\underline{x}; \theta')}{f(\underline{x}; \theta)} = \left(\frac{\theta}{\theta'} \right)^{nc} \exp \left\{ \sum_{i=1}^n \left[\left(x_i / \theta \right)^c - \left(x_i / \theta' \right)^c \right] \right\}$$

$$= \underbrace{\left(\frac{\theta}{\theta'} \right)^{nc}}_{> 0} \exp \left\{ \underbrace{\left(\frac{1}{\theta'} - \frac{1}{\theta^c} \right)}_{> 0} \underbrace{\sum_{i=1}^n x_i^c}_{> 0} \right\}$$

Logo, dado que $\theta > 0$ e $\theta < \theta'$, $(\theta/\theta')^{nc} > 0$ e $1/\theta' - 1/\theta^c > 0$, portanto a razão de verossimilhanças, $f(\underline{x}; \theta')/f(\underline{x}; \theta)$ é uma função não decrescente de $T(\underline{x}) = \sum_{i=1}^n x_i^c$.

Assim, um teste UMP para $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$, de nível α , é dado por:

$$\phi(\underline{x}) = \begin{cases} 1, & \text{quando } T(\underline{x}) > d \\ 0, & \text{quando } T(\underline{x}) \leq d \end{cases}$$

Onde d é determinado por: $E_{\theta_0}\{\phi(\underline{x})\} = \alpha$ e portanto por a relação

$$P_{\theta_0}(T(\underline{x}) > d) = \alpha. \quad \text{Mas,}$$

$$x_i \sim \text{Weibull}(c, \theta) \Rightarrow x_i^c / \theta^c \sim \text{Exp}(1) \Rightarrow \sum_{i=1}^n x_i^c / \theta^c \sim \text{Gama}(n, 1)$$

$$\text{Logo, } P_{\theta_0}(T(\underline{x}) > d) = \alpha \Rightarrow 1 - P_{\theta_0}(T(\underline{x}) \leq d) = \alpha$$

$$\Rightarrow 1 - P_{\theta_0}\left(\frac{T(\underline{x})}{\theta_0^c} \leq \frac{d}{\theta_0^c}\right) = \alpha$$

$$\Rightarrow P\left(W \leq \frac{d}{\theta_0^c}\right) = 1 - \alpha$$

em que $W \sim \text{Gama}(n, 1)$. Portanto,

$$\frac{d}{\theta_0^c} = G_0^{-1}(1-\alpha) \Rightarrow d = \theta_0^c G_{n,1}^{-1}(1-\alpha)$$

em que $G_{n,1}^{-1}(1-\alpha)$ é o quantil $1-\alpha$ da distribuição Gama($n, 1$).

Assim, um teste UMP, de nível α , para $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$, rejeita H quando $\sum_{i=1}^n x_i^c > \theta_0^c G_{n,1}^{-1}(1-\alpha)$. Isto é,

$$\phi(\underline{x}) = \begin{cases} 1, & \text{quando } \sum_{i=1}^n x_i^c > \theta_0^c G_{n,1}^{-1}(1-\alpha) \\ 0, & \text{quando } \sum_{i=1}^n x_i^c \leq \theta_0^c G_{n,1}^{-1}(1-\alpha) \end{cases}$$

(b) Obtenha um limite superior de confiança uniformemente mais acurado para θ para θ com coeficiente de confiança $1-\alpha$.

Teve-se que a razão de verossimilhança é monótona crescente de $T(\underline{x})$ e $F_\theta(t) = G_{n,1}(t/\theta^c)$, portanto é contínua em cada variável t e θ quando a outra é fixada. Assim, existe um limite superior uniformemente mais acurado para θ com coeficiente de confiança $1-\alpha$.

Logo, seja \underline{x} a amostra aleatória observada e $t = T(\underline{x})$, então o limite superior é determinado por

$$F_\theta(t) = \alpha \Rightarrow G_{n,1}(t/\theta^c) = \alpha \Rightarrow \frac{t}{\theta^c} = G_{n,1}^{-1}(\alpha) \Rightarrow \bar{\theta} = \left(\frac{t}{G_{n,1}^{-1}(\alpha)} \right)^{1/c}$$

Assim, $\bar{\theta} = (t/G_{n,1}^{-1}(\alpha))^{1/c}$ é o limite superior de confiança uniformemente mais acurado para θ com coeficiente de confiança $1-\alpha$.

(c) Obtenha o teste da razão de verossimilhanças de $H: \theta = \theta_0$ contra $K: \theta \neq \theta_0$ de nível α .

Neste caso temos que $\mathcal{R}_H = \{\theta_0\}$ e $\mathcal{R} = \{\theta: \theta > 0\}$. Também,

$$L(\theta) = \prod_{i=1}^n \theta^{-c} c x_i^{c-1} \exp\left\{-\left(\frac{x_i}{\theta}\right)^c\right\} = \theta^{-nc} c^n \left[\prod_{i=1}^n x_i^{c-1}\right] \exp\left\{-\frac{1}{\theta^c} \sum_{i=1}^n x_i^c\right\}$$

$$\Rightarrow \ell(\theta) = -nc \log \theta + n \log c + (c-1) \sum_{i=1}^n \log x_i - \frac{1}{\theta^c} \sum_{i=1}^n x_i^c$$

$$\Rightarrow \frac{\partial \ell(\theta)}{\partial \theta} = -\frac{nc}{\theta} + \frac{c}{\theta^{c+1}} \sum_{i=1}^n x_i^c = \frac{c}{\theta} \left(\frac{1}{\theta^c} \sum_{i=1}^n x_i^c - n \right)$$

$$\text{Logo, se } \frac{\partial \ell(\theta)}{\partial \theta} = 0, \text{ então } \hat{\theta} = \left(\frac{1}{n} \sum_{i=1}^n x_i^c \right)^{1/c} = \sqrt[n]{T(\underline{x})} \text{ é o E.M.V.}$$

de θ , dado que

$$\frac{\partial^2 \ell(\theta)}{\partial \theta^2} = -\frac{c}{\theta^2} \left(\frac{1}{\theta^c} \sum_{i=1}^n x_i^c - n \right) - \frac{c^2}{\theta^{c+2}} \sum_{i=1}^n x_i^c = -\frac{c}{\theta^{c+2}} \sum_{i=1}^n x_i^c + \frac{cn}{\theta^2} - \frac{c^2}{\theta^c} \sum_{i=1}^n x_i^c$$

e quando $\theta = \hat{\theta}$, $\frac{\partial^2 \ell(\theta)}{\partial \theta^2} < 0$, dado que

$$\begin{aligned} -\frac{c \sum_{i=1}^n x_i^c}{\left(\frac{1}{n} \sum_{i=1}^n x_i^c\right)^{1+c}} + \frac{cn}{\left(\frac{1}{n} \sum_{i=1}^n x_i^c\right)^{2/c}} - \frac{c^2 \sum_{i=1}^n x_i^c}{\left(\frac{1}{n} \sum_{i=1}^n x_i^c\right)^{2/c}} &= -\frac{cn^{1+\frac{1}{c}}}{\left(\frac{1}{n} \sum_{i=1}^n x_i^c\right)^{2/c}} + \frac{cn^{1+\frac{1}{c}}}{\left(\frac{1}{n} \sum_{i=1}^n x_i^c\right)^{2/c}} - \frac{c^2 n}{\sum_{i=1}^n x_i^c} \\ &= -\frac{nc^2}{\sum_{i=1}^n x_i^c} < 0 \\ &\quad \xrightarrow{\sum_{i=1}^n x_i^c > 0} x_i > 0 \end{aligned}$$

Assim,

$$\lambda(\underline{x}) = \frac{\sup_{\theta \in \mathcal{R}_H} L(\theta)}{\sup_{\theta \in \mathcal{R}} L(\theta)} = \frac{\theta_0^{-nc} c^n \left[\prod_{i=1}^n x_i^{c-1}\right] \exp\left\{-\frac{1}{\theta_0^c} \sum_{i=1}^n x_i^c\right\}}{\hat{\theta}^{-nc} c^n \left[\prod_{i=1}^n x_i^{c-1}\right] \exp\left\{-\frac{1}{\hat{\theta}^c} \sum_{i=1}^n x_i^c\right\}}$$

$$= \left(\frac{\hat{\theta}}{\theta_0}\right)^{nc} \exp\left\{\left(\frac{1}{\hat{\theta}^c} - \frac{1}{\theta_0^c}\right) \sum_{i=1}^n x_i^c\right\}$$

$$= \left(\frac{T(\underline{x})}{(n\theta_0)^c}\right)^n \exp\left\{n - \frac{T(\underline{x})}{\theta_0^c}\right\}$$

Logo, rejeitamos $H_0: \theta = \theta_0$ se, e somente se $\lambda(\underline{x}) < C$, com $C \in (0,1)$, ou seja, rejeitamos H_0 se, e somente se

$$\left(\frac{T(\underline{x})}{(n\theta_0)^c}\right)^n \exp\left\{n - \frac{T(\underline{x})}{\theta_0^c}\right\} < C$$

$$\Rightarrow \left(\frac{T(\underline{x})}{\theta_0^c}\right)^n \exp\left\{-\frac{T(\underline{x})}{\theta_0^c}\right\} < n^n c e^{-n} = C_1$$

$$\Rightarrow \left(\frac{T(\underline{x})}{\theta_0^c}\right) n \left(\log T(\underline{x}) - \log \theta_0^c\right) < \log C_1 = C_2$$

$$\Rightarrow \frac{T(\underline{x})}{\theta_0^c} \left\{ \log \theta_0^c - \log T(\underline{x}) \right\} < \frac{1}{n} C_2 = C_3$$

Agora, seja $\lambda_1(\underline{x}) = \frac{T(\underline{x})}{\theta_0^c} \left\{ \log \theta_0^c - \log T(\underline{x}) \right\}$, então

$$\frac{\partial \lambda_1(\underline{x})}{\partial T(\underline{x})} = \frac{\log \theta_0^c}{\theta_0^c} - \frac{\log T(\underline{x})}{\theta_0^c} - \frac{1}{\theta_0^c}$$

Assim, se $\frac{\partial \lambda_1(\underline{x})}{\partial T(\underline{x})} = 0 \Rightarrow T(\underline{x}) = \exp\{\log \theta_0^c - 1\}$ é o valor que

maximiza $\lambda_1(\underline{x})$, pois $\frac{\partial^2 \lambda_1(\underline{x})}{\partial T^2(\underline{x})} = -\frac{1}{T(\underline{x})\theta_0^c} < 0 \quad \forall T(\underline{x})$

Logo, rejeita-se H_0 quando $\lambda_1(\underline{x}) < C_2$, o que equivale a rejeitar H_0 quando $T(\underline{x}) < a$ ou $T(\underline{x}) > b$, sendo a e b tais que $a < \exp\{\log \theta_0^c - 1\}$, $b > \exp\{\log \theta_0^c - 1\}$ e

$$E_{\theta_0} \{ \phi(\underline{x}) \} = P_{\theta_0} (T(\underline{x}) < a) + P_{\theta_0} (T(\underline{x}) > b) = \alpha$$

$$\Rightarrow P_{\theta_0} (T(\underline{x}) \leq b) - P_{\theta_0} (T(\underline{x}) < a) = 1 - \alpha$$

$$\Rightarrow P_{\theta_0} (a < T(\underline{x}) < b) = 1 - \alpha$$

$$\Rightarrow P_{\theta_0} \left(\frac{a}{\theta_0^c} < \frac{T(\underline{x})}{\theta_0^c} < \frac{b}{\theta_0^c} \right) = 1 - \alpha$$

$$\Rightarrow P_{\theta_0} \left(\frac{a}{\theta^c} < W < \frac{b}{\theta^c} \right) = 1 - \alpha$$

em que $W \sim \text{Gamma}(n, 1)$, portanto

$$\frac{a}{\theta^c} = G_{n,1}^{-1}(\alpha/2) \Rightarrow a = \theta^c G_{n,1}^{-1}(\alpha/2)$$

$$\frac{b}{\theta^c} = G_{n,1}^{-1}(1-\alpha/2) \Rightarrow b = \theta^c G_{n,1}^{-1}(1-\alpha/2)$$

Assim, o teste da razão de verossimilhanças de $H_0: \theta = \theta_0$ contra $H_1: \theta \neq \theta_0$ de nível α , rejeita H_0 quando $T(\underline{x}) < \theta_0^c G_{n,1}^{-1}(\alpha/2)$ ou $T(\underline{x}) > \theta_0^c G_{n,1}^{-1}(1-\alpha/2)$.

(d) Obtenha uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente minimal e determine um intervalo de confiança para θ com coeficiente de confiança $1 - \alpha$.

Temos que,

$$f(\underline{x}; \theta) = \theta^{-nc} \exp \left\{ -\frac{1}{\theta^c} \sum_{i=1}^n x_i^c \right\} c^n \prod_{i=1}^n x_i^{c-1} = g_\theta(T(\underline{x})) h(\underline{x})$$

e, pelo critério da fatoração, com $g_\theta(T(\underline{x})) = \theta^{-nc} \exp \left\{ -\frac{1}{\theta^c} \sum_{i=1}^n x_i^c \right\}$ e $h(\underline{x}) = c^n \prod_{i=1}^n x_i^{c-1}$ ($h(\underline{x}) > 0$), $T(\underline{x}) = \sum_{i=1}^n x_i^c$ é uma estatística suficiente.

Por outro lado,

$$\frac{f(\underline{y}; \theta)}{f(\underline{x}; \theta)} = \exp \left\{ \frac{1}{\theta^c} \left[\sum_{i=1}^n x_i^c - \sum_{i=1}^n y_i^c \right] \right\} h(\underline{x}, \underline{y}) ; \text{ em que } h(\underline{x}, \underline{y}) = \frac{h(\underline{y})}{h(\underline{x})}$$

é não negativa.

Logo, se $T(\underline{x}) = T(\underline{y}) \Rightarrow \sum_{i=1}^n x_i^c = \sum_{i=1}^n y_i^c$, então $f(\underline{y}; \theta) = f(\underline{x}; \theta) h(\underline{x}, \underline{y})$

e se $f(\underline{y}; \theta) = f(\underline{x}; \theta) h(\underline{x}, \underline{y})$ então $\exp \left\{ \frac{1}{\theta^c} \left[\sum_{i=1}^n x_i^c - \sum_{i=1}^n y_i^c \right] \right\} = 1$,

então $\sum_{i=1}^n x_i^c - \sum_{i=1}^n y_i^c = 0$, então $T(\underline{x}) = T(\underline{y})$.

Assim, dadas as condições do C.F., $T(\underline{x}) = T(\underline{y}) \Leftrightarrow \underline{y} \in D(\underline{x})$, em que $D(\underline{x}) = \{ \underline{y} \in \mathbb{R}^n : P_\theta(\underline{y}) = P_\theta(\underline{x}) h(\underline{x}, \underline{y}) \}$, se $\theta \in \Omega$ com h não negativa.

Então $T(\underline{x})$ é suficiente minimal.

Por outro lado, a distribuição de $T(\underline{x})/\theta^c \sim \text{Gamma}(n, 1)$, que não depende de θ , portanto $T(\underline{x})/\theta^c$ é uma quantidade pivotal.

Assim, um intervalo de confiança para θ sai da relação

$$P \left(g_{\frac{\alpha}{2}} < \frac{T(\underline{x})}{\theta^c} < g_{1-\frac{\alpha}{2}} \right) = 1 - \alpha , \text{ em que } g_\beta = G_{n,1}^{-1}(\beta), \beta \in [0, 1]$$

$$\Rightarrow \frac{1}{g_{1-\frac{\alpha}{2}}} < \frac{\theta^c}{T(\underline{x})} < \frac{\alpha}{g_{\frac{\alpha}{2}}} \Rightarrow \left[\frac{T(\underline{x})}{g_{1-\frac{\alpha}{2}}} \right]^{1/c} < \theta < \left[\frac{T(\underline{x})}{g_{\frac{\alpha}{2}}} \right]^{1/c}$$

Então, o intervalo $\left(\left[T(\underline{x})/g_{1-\frac{\alpha}{2}} \right]^{1/c}; \left[T(\underline{x})/g_{\frac{\alpha}{2}} \right]^{1/c} \right)$ é um intervalo de confiança de $100(1-\alpha)\%$ para θ .

8) Sejam x_1, \dots, x_n variáveis aleatórias independentes com distribuição $U(-\theta, \theta)$, $\theta > 0$.

(a) Considere o teste ϕ tal que $\phi(x_1, \dots, x_n) = 1$, se $\max(|x_1|, \dots, |x_n|) > \theta_0$ e $\phi(x_1, \dots, x_n) = \alpha$, caso contrário. Mostre que ϕ é uniformemente mais poderoso (UMP) de nível α para testar $H: \theta = \theta_0$ contra $K: \theta > \theta_0$. Este teste é UMP para testar $H^*: \theta \leq \theta_0$ contra $K: \theta > \theta_0$? Justifique.

Temos as v.a. x_1, \dots, x_n com distribuição $U(-\theta, \theta)$, $\theta > 0$, e vamos considerar as novas variáveis y_1, \dots, y_n , tais que $y_i = |x_i|$, $i=1, \dots, n$. Notar que, a distribuição de y_i é $U(0, \theta)$, $\theta > 0$, para $i=1, \dots, n$.

Considere agora o teste de $H: \theta = \theta_0$ contra $K: \theta > \theta_0$ ou equivalente mente $H: \theta = \theta_0$ contra $K: \theta = \theta_1$, $\theta_1 > \theta_0$.

Dado que

$$f(y|\theta_1) = \frac{1}{\theta_1^n} \prod_{i=1}^n I_{(0, \theta_1)}(y_i) = \frac{1}{\theta_1^n} I_{(0, \theta_1)}(y_{(n)}) ;$$

$$f(y|\theta_0) = \frac{1}{\theta_0^n} \prod_{i=1}^n I_{(0, \theta_0)}(y_i) = \frac{1}{\theta_0^n} I_{(0, \theta_0)}(y_{(n)})$$

em que $y_{(n)} = \max\{y_1, \dots, y_n\}$. Então, tomando $k = (\theta_0/\theta_1)^n$, temos que:

$$\begin{aligned} f(y|\theta_1) > k f(y|\theta_0) &\Leftrightarrow \frac{1}{\theta_1^n} I_{(0, \theta_1)}(y_{(n)}) > \frac{\theta_0^n}{\theta_1^n} \frac{1}{\theta_0^n} I_{(0, \theta_0)}(y_{(n)}) \\ &\Leftrightarrow I_{(0, \theta_1)}(y_{(n)}) > I_{(0, \theta_0)}(y_{(n)}) \\ &\Leftrightarrow y_{(n)} > \theta_0 \end{aligned}$$

e $\phi(x) = 0$, se e somente se

$$f(y|\theta_1) < k f(y|\theta_0) \Leftrightarrow I_{(0, \theta_1)}(y_{(n)}) < I_{(0, \theta_0)}(y_{(n)})$$

que nunca ocorre pois $\theta_1 > \theta_0$

O de cima, válido quando pelo menos um, $f(y|\theta_1)$ ou $f(y|\theta_0)$, é positivo; isto é, quando $y_{(n)} < \theta_1$ e $y_{(n)} > 0$.

Portanto, o teste UMP para testar $H: \theta = \theta_0$ contra $K: \theta = \theta_1$, $\theta_1 > \theta_0$, é dado por

$$\phi(y) = \begin{cases} 1, & y_{(n)} > \theta_0 \\ \alpha, & y_{(n)} \leq \theta_0 \end{cases}$$

em que α é determinado tal que $E_{\theta_0}\{\phi(y)\} = \alpha$; assim, dado que

$$\begin{aligned} E_{\theta_0}\{\phi(y)\} &= P_{\theta_0}(y_{(n)} > \theta_0) + \alpha P_{\theta_0}(y_{(n)} \leq \theta_0) \\ &= 0 + \alpha \cdot 1 = \alpha \end{aligned}$$

Então, $\alpha = \alpha$, e o teste UMP para testar $H: \theta = \theta_0$ contra $K: \theta = \theta_1$, $\theta_1 > \theta_0$ ou $H: \theta = \theta_0$ contra $K: \theta > \theta_0$, de nível α , é

$$\phi(y) = \begin{cases} 1, & y_{(n)} > \theta_0 \\ \alpha, & y_{(n)} \leq \theta_0 \end{cases} = \begin{cases} 1, & \max\{|x_1|, \dots, |x_n|\} > \theta_0 \\ \alpha, & \max\{|x_1|, \dots, |x_n|\} \leq \theta_0 \end{cases}$$

Notar que, o de acima é válido quando $H: \theta \leq \theta_0$, como se mostra a continuación.

Quando $y_{(n)} < \theta_0$ e $y_{(n)} > 0$, a razão $f(y|\theta_1)/f(y|\theta_0)$, com $\theta_0 < \theta_1$, é não decrescente^(*) de $y_{(n)}$, então a razão $f(y|\theta)$ tem razões de verossimilhanças monótonas, então para testar $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$, existe um teste UMP que é dado por

$$\phi(y) = \begin{cases} 1, & \text{se } y_{(n)} > c \\ \alpha, & \text{se } y_{(n)} = c \\ 0, & \text{se } y_{(n)} \leq c \end{cases} = \begin{cases} 1, & \text{se } y_{(n)} > c \\ 0, & \text{se } y_{(n)} \leq c \end{cases}$$

dado que $y_{(n)} = c$ tem probabilidade zero, e c é determinado por

$$E_{\theta_0}\{\phi(y)\} = \alpha . \text{ logo, dado que } f_{y_{(n)}}(x|\theta) = n\theta^{-n} x^{n-1} I_{(0, \theta)}(x), \theta > 0,$$

$$E_{\theta_0}\{\phi'(y)\} = P_{\theta_0}(y_{(n)} > c) = \int_c^{\theta_0} n\theta^{-n} x^{n-1} dx = \frac{x^n}{\theta_0^n} \Big|_c^{\theta_0} = 1 - \frac{c^n}{\theta_0^n}$$

$$\text{Portanto, } 1 - \frac{c^n}{\theta_0^n} = \alpha \Rightarrow c = \theta_0 (1-\alpha)^{\frac{1}{n}} .$$

(*) como em exemplo 6.8 de M.S. de shao.

Logo, o poder de $\phi'(\underline{y})$, para $\theta > \theta_0$, é

$$E_{\theta_0} \{ \phi'(\underline{y}) \} = P_{\theta_0} (Y_{(n)} > c) = 1 - \frac{c^n}{\theta_0^n} = 1 - (1-\alpha) \frac{\theta_0^n}{\theta_1^n}$$

e do item (b) o poder de $\phi(\underline{y})$ é também $1 - (1-\alpha) \frac{\theta_0^n}{\theta_1^n}$, para $\theta > \theta_0$.

Logo, dado que

$$\sup_{\theta \leq \theta_0} E_{\theta} \{ \phi(\underline{y}) \} = \sup_{\theta \leq \theta_0} \underbrace{\alpha}_{\text{rejeição}} P_{\theta} (Y_{(n)} \leq \theta_0) = \alpha P_{\theta_0} (Y_{(n)} \leq \theta_0) = \alpha$$

o teste $\phi(\underline{y})$ é um teste UMP de nível α , para testar $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$.

(b) Encontre a função de poder do teste ϕ .

Dado que, para $\theta > 0$

$$\begin{aligned} E_{\theta} (\phi(\underline{x})) &= P_{\theta} (Y_{(n)} > \theta_0) + \alpha P_{\theta} (Y_{(n)} \leq \theta_0) \\ &= 1 - P_{\theta} (Y_{(n)} \leq \theta_0) + \alpha P_{\theta} (Y_{(n)} \leq \theta_0) \\ &= 1 - (1-\alpha) P_{\theta} (Y_{(n)} \leq \theta_0) \\ &= \begin{cases} 1 - (1-\alpha), & \theta \leq \theta_0 \\ 1 - (1-\alpha) \int_0^{\theta_0} \frac{1}{\theta^n} x^{n-1} dx, & \theta > \theta_0 \end{cases} \\ &= \begin{cases} \alpha, & \theta \leq \theta_0 \\ 1 - (1-\alpha) \frac{\theta_0^n}{\theta^n}, & \theta > \theta_0 \end{cases} \end{aligned}$$

Assim, a função de poder é

$$\beta(\theta) = \begin{cases} \alpha, & \theta \leq \theta_0 \\ 1 - (1-\alpha) \frac{\theta_0^n}{\theta^n}, & \theta > \theta_0. \end{cases}$$

9) considere uma única observação de uma variável aleatória X .

(a) Use o Lema de Neyman-Pearson para construir o teste mais poderoso de nível α de $H_0: X \sim U(0,1)$ contra $H_1: X \sim \text{Beta}(1,b)$, sendo, $b > 1$ fixado. Se $\alpha = 0.05$ e se foi observado $x=0.1$, qual é sua decisão? Qual é o nível descriptivo (p-value) do teste?

Solução

$$\text{Se } X \sim \text{Beta}(a,b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} I_{(0,1)}(x)$$

Vamos provar $H_0: X \sim U(0,1)$ contra $H_1: X \sim \text{Beta}(1,b)$, $b > 1$ fixo

Pelo Lema de Neyman-Pearson existe um teste ϕ e uma constante

K tais que

$$\phi(x) = \begin{cases} 1 & \text{se } P_1(x) > K P_0(x) \\ 0 & \text{se } P_1(x) \leq K P_0(x) \end{cases}$$

e $E_0(\phi(x)) = \alpha$.

Sob $H_0: X \sim U(0,1) \Rightarrow P_0(x) = 1$

$$\begin{aligned} P_1(x) &= \frac{\Gamma(b+1)}{\Gamma(1)\Gamma(b)} (1-x)^{b-1} I_{(0,1)}(x) = \frac{\Gamma(b+1)}{\Gamma(b)} (1-x)^{b-1} I_{(0,1)}(x) \\ &= \frac{b\Gamma(b)}{\Gamma(b)} (1-x)^{b-1} I_{(0,1)}(x) = b(1-x)^{b-1} I_{(0,1)}(x) \end{aligned}$$

$$\begin{aligned} \Rightarrow P_1(x) > K P_0(x) &\Leftrightarrow b(1-x)^{b-1} > K P_0(x) \\ &\Leftrightarrow (1-x)^{b-1} > \frac{K}{b} \\ &\Leftrightarrow (1-x) > \left(\frac{K}{b}\right)^{\frac{1}{b-1}} \\ &\Leftrightarrow x < 1 - \left(\frac{K}{b}\right)^{\frac{1}{b-1}} = K' \end{aligned}$$

Então

$$\phi(x) = \begin{cases} 1 & \text{se } x < K' \\ 0 & \text{se } x \geq K' \end{cases}$$

Em que

$$E_0(\phi(x)) = \alpha \Leftrightarrow P_0(x < K') = \alpha$$

Sob $H_0: X \sim U(0,1) \Rightarrow K' = \alpha$

$$\begin{aligned} &\Leftrightarrow 1 - \left(\frac{K}{b}\right)^{\frac{1}{b-1}} = \alpha \Leftrightarrow \left(\frac{K}{b}\right)^{\frac{1}{b-1}} = 1 - \alpha \\ &\Leftrightarrow K = b(1-\alpha)^{b-1} \end{aligned}$$

pontualmente,

$$\phi(x) = \begin{cases} 1 & \text{se } b(1-x)^{b-1} > b(1-\alpha)^{b-1} \\ 0, \text{ c.c.} & \end{cases}$$

$$\Leftrightarrow \phi(x) = \begin{cases} 1 & \text{se } 1-x > 1-\alpha \\ 0, \text{ c.c.} & \end{cases} \Leftrightarrow \phi(x) = \begin{cases} 1 & \text{se } x < \alpha \\ 0, \text{ c.c.} & \end{cases}$$

Se $\alpha = 0.1$ e $\alpha = 0.05 \Rightarrow 0.1 > 0.05$ não rejeitamos H_0 .

$$\hat{P}(x) = P_0(x \geq x) = P_0(x \geq 0.1) = 1 - P_0(x \leq 0.1) = 1 - 0.1 = 0.9 \quad \times$$

$$\hat{P} = \inf \left\{ \alpha / \phi(x) = 1 \right\} = \inf \left\{ \alpha / x < \alpha \right\} = x \Rightarrow \text{se } x = 0.1 \rightarrow \hat{P} = 0.$$

(b) O teste obtido em (a) é uniformemente mais poderoso de $H: X \sim U(0,1)$ contra $K': X \sim \text{Beta}(1,b)$, $b > 1$? Justifique.

Solução

Considere $H: X \sim U(0,1)$ contra $K: X \sim \text{Beta}(1,b_0)$, $b_0 > 1$

pelo item (a) o teste UMP é dado por

$$\phi(x) = \begin{cases} 1, & x \leq x \\ 0, & \text{c.c.} \end{cases}$$

Considere $H: X \sim U(0,1)$ contra $K: X \sim \text{Beta}(1,b_1)$, $b_1 > b_0$

portanto o teste UMP é $\phi(x) = \begin{cases} 1, & x \leq x \\ 0, & \text{c.c.} \end{cases}$

Então, $\phi(x)$ é UMP para testar $H: X \sim U(0,1)$ contra $K: X \sim \text{Beta}(1,b)$, $b > 1$

(c) Existe teste uniformemente mais poderoso do $H: X \sim U(0,1)$ contra $K': X \sim \text{Beta}(1,b)$, $b \neq 1$? Justifique.

Solução

Se $H: X \sim U(0,1)$ contra $K: X \sim \text{Beta}(1,b)$, $b > 1$, então

$$\phi(x) = \begin{cases} 1, & x \leq x \\ 0, & \text{c.c.} \end{cases}$$

Se $H: X \sim U(0,1)$ contra $K: X \sim \text{Beta}(1,b)$, $b < 1$, então

$$\phi(x) = \begin{cases} 1, & x > x \\ 0, & \text{c.c.} \end{cases}$$

Portanto Não existe teste UMP para testar $H: X \sim U(0,1)$ contra $K': X \sim \text{Beta}(1,b)$, $b \neq 1$.

(d) Seja X distribuída de acordo com P_θ , $\theta \in \mathbb{R}$, e seja T uma estatística suficiente para θ . Mostre que, se $\phi(x)$ é qualquer teste de hipótese sobre θ , então $\psi(T)$ dado por $\psi(t) = E(\phi(x) | T=t)$ é um teste que depende apenas de T e sua função de poder é idêntica à de $\phi(x)$

Solução

Como T é uma estatística suficiente então $X | T=t$ não depende de parâmetros desconhecidos e portanto $\psi(T) = E(\phi(x) | T=t)$.

Seja $\theta \in \mathcal{R}_K$, assim

$$E_\theta(\psi(T)) = E_\theta[E(\phi(x) | T=t)] = E_\theta(\phi(x)) \quad \forall \theta \in \mathcal{R}_K.$$

Ou seja, o poder do teste $\psi(T)$ coincide com o poder do teste $\phi(x)$.

12 Sejam x_1, \dots, x_n e y_1, \dots, y_n amostras aleatórias de distribuições exponenciais de médias $\mu > 0$ e $\lambda > 0$ respectivamente. Obtenha o teste da razão de verossimilhanças de $H_0: \mu = \lambda$ versus $H_1: \mu \neq \lambda$ de nível α ($0 < \alpha < 1$).

Solução

Temos que

$$P_A(x) = \prod_{i=1}^n \frac{1}{\mu} e^{-\frac{x_i}{\mu}} = \left(\frac{1}{\mu}\right)^n e^{-\frac{1}{\mu} \sum_{i=1}^n x_i}$$

$$P_\lambda(y) = \prod_{i=1}^n \frac{1}{\lambda} e^{-\frac{y_i}{\lambda}} = \left(\frac{1}{\lambda}\right)^n e^{-\frac{1}{\lambda} \sum_{i=1}^n y_i}$$

Seja $\underline{\theta} = (\mu, \lambda)$, logo

$$L(x, y; \underline{\theta}) = \mu^n \lambda^n e^{-\frac{1}{\mu} \sum x_i - \frac{1}{\lambda} \sum y_i}$$

$$= \mu^n \lambda^n e^{-\frac{n\bar{x}}{\mu} - \frac{n\bar{y}}{\lambda}}$$

$$\Rightarrow l(x, y; \underline{\theta}) = -n \log \mu - n \log \lambda - \frac{n\bar{x}}{\mu} - \frac{n\bar{y}}{\lambda}$$

$$\Rightarrow \frac{\partial l(x, y; \underline{\theta})}{\partial \mu} = 0 \iff -\frac{n}{\mu} + \frac{n\bar{x}}{\mu^2} = 0 \iff \hat{\mu} = \bar{x}$$

$$\Rightarrow \frac{\partial l(x, y; \underline{\theta})}{\partial \lambda} = 0 \iff -\frac{n}{\lambda} + \frac{n\bar{y}}{\lambda^2} = 0 \iff \hat{\lambda} = \bar{y}$$

$$\Rightarrow \frac{\partial^2 l(x, y; \underline{\theta})}{\partial \mu^2} = \frac{n}{\mu^2} - \frac{2n\bar{x}}{\mu^3}; \quad \frac{\partial^2 l(x, y; \underline{\theta})}{\partial \lambda^2} = \frac{n}{\lambda^2} - \frac{2n\bar{y}}{\lambda^3} \quad \text{e}$$

$$\frac{\partial^2 l(x, y; \underline{\theta})}{\partial \mu \partial \lambda} = 0$$

$$\text{Seja } D(a, b) = \left[\frac{\partial^2 l(x, y; \underline{\theta})}{\partial \mu^2}(a, b) \right] \left[\frac{\partial^2 l(x, y; \underline{\theta})}{\partial \lambda^2}(a, b) \right] - \left[\frac{\partial^2 l(x, y; \underline{\theta})}{\partial \mu \partial \lambda}(a, b) \right]^2$$

$$\text{como } D(\bar{x}, \bar{y}) = \left[\frac{n}{\bar{x}^2} - \frac{2n\bar{x}}{\bar{x}^3} \right] \left[\frac{n}{\bar{y}^2} - \frac{2n\bar{y}}{\bar{y}^3} \right] - 0^2 = \frac{n^2}{\bar{x}^2 \bar{y}^2} > 0$$

$$\text{então, } \underline{\theta} = (\hat{\mu}, \hat{\lambda}) = (\bar{x}, \bar{y}) \text{ maximiza } l(x, y; \underline{\theta})$$

Temos que $\mathcal{N} = \{\underline{\theta} = (\mu, \lambda) / \mu > 0, \lambda > 0\}$

$$\mathcal{N}_H = \{\underline{\theta} = (\mu, \lambda) / \mu = \lambda\}$$

Se $\underline{\theta} \in \mathcal{N}_H$, então

$$l(x, y; \underline{\theta}) = -2n \log \mu - \frac{n}{\mu}(\bar{x} + \bar{y})$$

$$\Rightarrow \frac{\partial l(x, y; \underline{\theta})}{\partial \mu} = 0 \iff -\frac{2n}{\mu} + \frac{n}{\mu^2}(\bar{x} + \bar{y}) = 0$$

$$\iff \hat{\mu} = \frac{\bar{x} + \bar{y}}{2}$$

Note que $\hat{\lambda} = \frac{\bar{x} + \bar{y}}{2}$ maximiza $l(\bar{x}, \bar{y}; \lambda)$ sobre H_0 , pois

$$\begin{aligned} \frac{\partial^2 l(\bar{x}, \bar{y}; \lambda)}{\partial \lambda^2} \Big|_{\lambda = \frac{\bar{x} + \bar{y}}{2}} &= \frac{2n}{\lambda^2} - \frac{2n(\bar{x} + \bar{y})}{\lambda^3} \Big|_{\lambda = \frac{\bar{x} + \bar{y}}{2}} \\ &= \frac{8n}{(\bar{x} + \bar{y})^2} - \frac{16n(\bar{x} + \bar{y})}{(\bar{x} + \bar{y})^3} = -\frac{8n}{(\bar{x} + \bar{y})^2} < 0 \end{aligned}$$

Agora,

$$\lambda(\bar{x}, \bar{y}) = \frac{\sup_{\theta \in \Lambda} L(\bar{x}, \bar{y}; \theta)}{\sup_{\theta \in \Omega} L(\bar{x}, \bar{y}; \theta)}$$

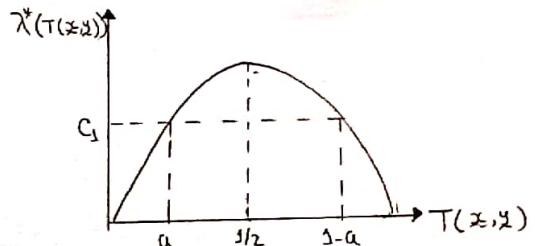
$$\Rightarrow \lambda(\bar{x}, \bar{y}) = \frac{\left(\frac{\bar{x} + \bar{y}}{2}\right)^{-n} \exp\left[-n\left(\frac{\bar{x}}{\bar{x} + \bar{y}}\right)(\bar{x} + \bar{y})\right]}{\bar{x}^{-n} \bar{y}^{-n} \exp\left[-\frac{n\bar{x}}{\bar{x}} - \frac{n\bar{y}}{\bar{y}}\right]} = \frac{4^n \bar{x}^n \bar{y}^n}{(\bar{x} + \bar{y})^{2n}}$$

$$\text{Logo, } \lambda(\bar{x}, \bar{y}) < c \iff \frac{\bar{x}\bar{y}}{(\bar{x} + \bar{y})^2} = \chi^*(\bar{x}, \bar{y}) < c, \text{ sendo } c = \frac{c_1}{4}.$$

Note que:

$$\frac{\bar{x}\bar{y}}{(\bar{x} + \bar{y})^2} = \frac{\bar{x}}{\bar{x} + \bar{y}} \cdot \frac{\bar{y}}{\bar{x} + \bar{y}} = \frac{\bar{x}}{\bar{x} + \bar{y}} \left(1 - \frac{\bar{x}}{\bar{x} + \bar{y}}\right)$$

$$\text{Chamemos } T(\bar{x}, \bar{y}) = \frac{\bar{x}}{\bar{x} + \bar{y}} \Rightarrow \chi = \chi^*(T(\bar{x}, \bar{y}))$$



$$\chi^*(T(\bar{x}, \bar{y})) < c_1 \iff T(\bar{x}, \bar{y}) < a \text{ ou } T(\bar{x}, \bar{y}) > 1-a$$

Sob $H_0: \lambda = \lambda$ temos que $x_1, \dots, x_n \in y_1, \dots, y_n$ são amostras aleatórias da distribuição $\text{Exp}(\lambda)$, logo $\sum_{i=1}^n x_i \sim \text{Gamma}(n, \lambda)$ e $\sum_{i=1}^n y_i \sim \text{Gamma}(n, \lambda)$ independentes.

$$\text{portanto } \frac{\bar{x}}{\bar{x} + \bar{y}} = \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n x_i + \sum_{i=1}^n y_i} \sim \text{Beta}(n, n)$$

Logo $P(T(\bar{x}, \bar{y}) < a) + P(T(\bar{x}, \bar{y}) > 1-a) = \alpha$, equivalente a ter

$$P(T(\bar{x}, \bar{y}) < a) = \frac{\alpha}{2}. \text{ Assim } a = q_{n, \alpha/2}, \text{ sendo } q_{n, \alpha/2} \circ \text{percentil } \alpha/2 \text{ da distribuição Beta}(n, n).$$

Assim, o teste de razão de verossimilhança de $H_0: \lambda = \lambda$ contra $H_1: \lambda \neq \lambda$ de nível α é dado por:

$$\phi(\bar{x}, \bar{y}) = \begin{cases} 1 & \text{se } T(\bar{x}, \bar{y}) < q_{n, \alpha/2} \text{ ou } T(\bar{x}, \bar{y}) > 1 - q_{n, \alpha/2} \\ 0 & \text{c.c.} \end{cases}$$

ESTATÍSTICA AVANÇADA I - LISTA 5

Jaime Enrique Lincovil Curivil
Maicon Aparecido Pinheiro

Exercício 2.

Sejam X_1, \dots, X_n uma amostra aleatória da densidade:

$$f(x|\theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0.$$

9.1

Item 2 (a): Obtenha um teste UMP de $H_0 : \theta \leq \theta_0$ ($\theta_0 > 0$) versus $H_1 : \theta > \theta_0$ de nível α . Começamos escrevendo a função de verossimilhança, para $x \in \mathcal{X}$:

$$L(\theta) = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} I_{\mathcal{X}}(x),$$

a qual pode ser expressada de forma equivalente por:

$$L(\theta) = \exp(\log(L(\theta))) = \exp\{n\log(\theta) + (\theta - 1) \sum_{i=1}^n \log(x_i)\} I_{\mathcal{X}}(x).$$

Agora, seja $\theta_0 < \theta'$, consideremos a seguinte razão de verossimilhanças :

$$\frac{p_{\theta'}(x)}{p_{\theta_0}(x)} = \exp\left\{n\log\left(\frac{\theta'}{\theta_0}\right) + (\theta' - \theta_0) \sum_{i=1}^n \log(x_i)\right\}.$$

De $\theta_0 < \theta'$, temos que $\log\left(\frac{\theta'}{\theta_0}\right) > 0$ e $(\theta' - \theta_0) > 0$. Esta razão é uma função da estatística $T(X) = \sum_{i=1}^n \log(X_i)$, a qual:

$$T : \mathcal{X} \rightarrow (-\infty, 0).$$

Como a razão depende da amostra através desta estatística, podemos considerarla como uma função $\psi_{\theta_0, \theta'}(T)$. Logo, como para dois valores de T , dados por t_1 e t_2 em que para $t_1 \leq t_2$ temos que $\psi_{\theta_0, \theta'}(t_1) \leq \psi_{\theta_0, \theta'}(t_2)$, ou seja a razão é uma função não decrescente de $T(X)$. Também, dada a distribuição contínua de $T(x)$, temos que $P(T = c) = 0, \forall c < 0$.

Pelo teorema correspondente, o teste UMP para as hipóteses consideradas é dado por:

$$\phi(x) = \begin{cases} 1, & \text{se } \sum_{i=1}^n \log(x_i) > c \\ 0, & \text{se } \sum_{i=1}^n \log(x_i) < c \end{cases}.$$

Para determinar a constante c associada com o nível de significância α . Precisaremos do seguinte resultado. Seja

$$Y = g(X) = -\log(X),$$

em que g é uma função estritamente monótona. Seja $g^{-1}(X) = e^{-Y}$ e $dg^{-1}(X)/dY = -e^{-Y}$. Deste modo a densidade de Y é dada por:

$$f_Y(y|\theta) = f_X(g^{-1}(y)|\theta) \left| \frac{dg^{-1}(y)}{dy} \right| = \theta e^{-\theta y} I_{R+}(y).$$

Portanto, $Y = -\log(X) \sim E(\theta)$. Logo, pelo teorema correspondente, a constante c para o teste ϕ , esta sujeita à condição $E_{\theta_0}(\phi(X)) = \alpha$, ou seja:

$$P_{\theta_0}(T > c) = P_{\theta_0}(-T < -c) = P_{\theta_0}\left(2\theta_0 \sum_{i=1}^n -\log(X_i) < -2\theta_0 c\right) = P_{\theta_0}(\chi_{2n}^2 < -2\theta_0 c) = \alpha.$$

$$\Leftrightarrow -2\theta_0 c = q_\alpha \Leftrightarrow c = \frac{-q_\alpha}{2\theta_0}.$$

Em que q_α é o percentil de ordem α da distribuição χ_{2n}^2 . Finalmente o teste $\phi(x)$ é dado por:

$$\phi(x) = \begin{cases} 1, & \text{se } \sum_{i=1}^n \log(x_i) > \frac{-q_\alpha}{2\theta_0} \\ 0, & \text{se } \sum_{i=1}^n \log(x_i) < \frac{-q_\alpha}{2\theta_0} \end{cases}$$

Item 2 (b): Obtenha um teste UMP de $H_0 : \theta \geq \theta_0$ ($\theta_0 > 0$) versus $H_1 : \theta < \theta_0$ de nível α .

Pelo teorema correspondente o teste UMP para estas hipóteses é dado por

$$\phi(x) = \begin{cases} 1, & \text{se } \sum_{i=1}^n \log(x_i) < c \\ 0, & \text{se } \sum_{i=1}^n \log(x_i) > c \end{cases}$$

Logo a constante c deve satisfazer:

$$P_{\theta_0}(T < c) = P_{\theta_0}(-T > -c) = P_{\theta_0}\left(2\theta_0 \sum_{i=1}^n -\log(X_i) > -2\theta_0 c\right) = P_{\theta_0}(\chi_{2n}^2 > -2\theta_0 c) = \alpha.$$

$$\Leftrightarrow -2\theta_0 c = q_{1-\alpha} \Leftrightarrow c = \frac{-q_{1-\alpha}}{2\theta_0}.$$

Em que $q_{1-\alpha}$ é o percentil de ordem $1 - \alpha$ da distribuição χ_{2n}^2 . Finalmente o teste $\phi(x)$ é dado por:

$$\phi(x) = \begin{cases} 1, & \text{se } \sum_{i=1}^n \log(x_i) < \frac{-q_{1-\alpha}}{2\theta_0} \\ 0, & \text{se } \sum_{i=1}^n \log(x_i) > \frac{-q_{1-\alpha}}{2\theta_0} \end{cases}$$

Item 2 (c): Neste exercício como resposta apresentamos um contra exemplo. A ideia principal do contra exemplo baseia-se no fato que necessariamente a região do teste não é fixa, para as hipóteses propostas.

Sob a hipótese alternativa é especificado o conjunto dado por $\Omega - \{\theta_0\} = (0, \theta_0) \cup (\theta_0, +\infty)$. Pelos exercícios 2(a) e 2(b) temos que se $\theta < \theta_0$ a região crítica é dada por $\sum_{i=1}^n \log(x_i) < \frac{-q_{1-\alpha}}{2\theta_0}$ e se $\theta > \theta_0$ a região critica é dado por $\sum_{i=1}^n \log(x_i) > \frac{-q_\alpha}{2\theta_0}$. Porem, para os testes de nível α o poder é maximizado pela seguinte função poder (sob o conjunto $(0, \theta_0) \cup (\theta_0, +\infty)$):

$$E_\theta[\phi(X)] = \begin{cases} P_\theta\left(\sum_{i=1}^n \log(X_i) < \frac{-q_{1-\alpha}}{2\theta}\right), & \text{se } \theta < \theta_0 \\ P_\theta\left(\sum_{i=1}^n \log(x_i) > \frac{-q_\alpha}{2\theta}\right), & \text{se } \theta > \theta_0 \end{cases}$$

Notamos que $E_\theta[\phi(X)]$ é crescente em θ se $\theta < \theta_0$ e decrescente se $\theta > \theta_0$. Neste caso a curva da função $E_\theta[\phi(X)] = \beta(\theta)$ é a máxima para os testes de nível α sobre a hipóteses alternativa. O ponto central é o seguinte: a região crítica deste teste de nível α vai depender dos possíveis valores de θ sob a alternativa a qual na prática é desconhecido.

Item 2 (d): Para começar, procuramos o EMV de θ . A função de log verossimilhança, para $x \in X$ é dada por:

$$l(\theta) = n\log(\theta) + (\theta - 1) \sum_{i=1}^n \log(x_i).$$

Também temos que

$$\frac{dl(\theta)}{d\theta} = \frac{n}{\theta} + \sum_{i=1}^n \log(x_i).$$

Fazendo $dl(\theta)/d\theta = 0$ e reemplazando $\hat{\theta} = \theta$ o EMV é dado por:

$$\hat{\theta} = \frac{n}{-\sum_{i=1}^n \log(X_i)}.$$

Também, como $d^2l(\theta)/d\theta^2 = -n/\theta^2 < 0, \forall \theta$, $l(\theta)$ tem um máximo em Ω .

Logo a razão de verossimilhança generalizada para as hipóteses propostas neste item é dada por:

$$\begin{aligned} \lambda(x) &= \frac{\theta_0^n \left(\prod_{i=1}^n x_i \right)^{\theta_0-1} I_X(x)}{\hat{\theta}^n \left(\prod_{i=1}^n x_i \right)^{\hat{\theta}-1} I_X(x)} = \left(\frac{\theta_0}{n} \right)^n T_1^n \left(\prod_{i=1}^n x_i \right)^{\theta_0 - \frac{n}{T_1}} < c \\ &\Leftrightarrow T_1^n \left(\exp \left\{ \log \prod_{i=1}^n x_i \right\} \right)^{\theta_0 - \frac{n}{T_1}} < c' \\ &\Leftrightarrow T_1^n \left(e^{-T_1} \right)^{\theta_0 - \frac{n}{T_1}} < c' \Leftrightarrow T_1^n e^{-\theta_0 T_1 + n} < c' \Leftrightarrow T_1^n e^{-\theta_0 T_1} < c'. \end{aligned}$$

Em que $T_1 = -\sum_{i=1}^n \log(X_i) \sim \text{Gama}(n, \theta_0)$. Ou seja, a razão de verossimilhança depende dos dados somente através de T_1 e também tem uma forma proporcional a uma densidade de uma Gama $(n+1, \theta_0)$, crescente até um determinado ponto para depois decrescer.

Por isso rejeitar H_0 quando $\lambda(x) < c'$ é equivalente a rejeitar quando $T_1 < c_1$ ou $T_1 > c_2$ para adequadas constantes c_1 e c_2 tais que o teste seja de nível α . Para nosso teste escolhemos as constantes tais que $P_{\theta_0}(T_1 < c_1) = \alpha/2$ e $P_{\theta_0}(T_1 > c_2) = \alpha/2$.

Nesta vez, por simplicidade podemos tomar

$$c_1 = v_{\alpha/2} \text{ e } c_2 = v_{1-\alpha/2},$$

Seria bom fazer um gráfico.

em que $v_{\alpha/2}$ e $v_{1-\alpha/2}$ são os percentis correspondentes da distribuição Gama (n, θ_0) . Logo, o teste da razão de verossimilhança é dado por:

$$\phi(x) = \begin{cases} 1, & \text{se } T_1 < v_{\alpha/2} \text{ ou } T_1 > v_{1-\alpha/2} \\ 0, & \text{caso contrário.} \end{cases}$$

Item 2 (e). Encontre um limite inferior de confiança mais acurado co coeficiente de confiança $1 - \alpha$. Seja $\underline{\theta}$ o limite inferior de confiança uniformemente mais acurado para θ correspondente. Pelo item 2(a), a família de densidades $p_\theta(x)$ tem RVM em a estatística $T = \sum_{i=1}^n \log(X_i)$, deste modo, $\underline{\theta}$ será a solução de:

$$P_\theta \left(\sum_{i=1}^n \log(X_i) < t \right) = P_\theta \left(-2\theta \sum_{i=1}^n \log(X_i) > -2\theta t \right) = P_\theta \left(\chi_{2n}^2 > -2\theta t \right) = 1 - \alpha,$$

ç? x?

do exercício anterior temos que $\underline{\theta} = -q_\alpha/2t$, em que $t = \sum_{i=1}^n \log(x_i)$.

Item 2 (f). Encontre um limite superior de confiança mais acurado co coeficiente de confiança $1 - \alpha$.

Do corolário utilizado no exercício anterior, temos que o limite superior $\bar{\theta}$ será a solução de :

$$P_\theta \left(\sum_{i=1}^n \log(X_i) > t \right) = P_\theta \left(-2\theta \sum_{i=1}^n \log(X_i) < -2\theta t \right) = P_\theta \left(\chi_{2n}^2 < -2\theta t \right) = 1 - \alpha,$$

do exercício 2(b) anterior temos que $\underline{\theta} = -q_{1-\alpha}/2t$, em que $t = \sum_{i=1}^n \log(x_i)$.

Item 2 (g). Determine uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente e minimal e encontre um intervalo de confiança para θ com coeficiente de confiança $1 - \alpha$.

$$\begin{aligned} p_\theta(x) &= \exp \{n \log(\theta) + -(\theta - 1) \sum_{i=1}^n -\log(X_i)\} I_X(x) = \exp \{n \log(\theta) + -(\theta - 1) T(x)\} I_X(x) \\ &= g_\theta(T(x)) h(x). \end{aligned}$$

Logo, pelo critério da fatoração, a estatística T é suficiente para a família de densidades $p_\theta(x)$. Definamos para dois pontos do espaço amostral x e y o seguinte conjunto

$$D(x) = \{y : p_\theta(y) = p_\theta(x)h(x, y), \forall \theta \in \Omega\}.$$

Considerando $h(x, y) = 1$, verifica-se que $T(x) = T(y) \Leftrightarrow y \in D(x)$, porém $T(x)$ é uma estatística suficiente e minimal para $p_\theta(x)$

Como foi visto anteriormente $-2\theta \sum_{i=1}^n \log(X_i) \sim \chi_{2n}^2$. Escolheremos constantes a e b tais que:

$$P_\theta(a \leq -2\theta \sum_{i=1}^n \log(X_i) \leq b) = 1 - \alpha.$$

decidimos por estas constantes tais que $a = v_{\alpha/2}$ e $b = v_{1-\alpha/2}$. Logo com probabilidade $1 - \alpha$ temos que $v_{\alpha/2} \leq -2\theta \sum_{i=1}^n \log(X_i) \leq v_{1-\alpha/2}$ e o intervalo de confiança respectivo é dado por:

$$\left[\frac{v_{\alpha/2}}{-2 \sum_{i=1}^n \log(x_i)}, \frac{v_{1-\alpha/2}}{-2 \sum_{i=1}^n \log(x_i)} \right]$$

desde que $-2 \sum_{i=1}^n \log(x_i) > 0$ e $v_{\alpha/2}$ e $v_{1-\alpha/2}$ são os respectivos percentis da distribuição χ_{2n}^2 .

Item 2 (h). Pelo teorema de Bayes temos que:

$$\begin{aligned} \pi(\theta|x) &\propto f(x|\theta)\pi(\theta) = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} \gamma e^{-\gamma\theta} I_{R_+}(\theta). \\ &\propto \theta^{(n+1)-1} \left(\exp \left\{ \log \prod_{i=1}^n x_i \right\} \right)^{\theta-1} \gamma e^{-\gamma\theta} I_{R_+}(\theta). \\ &= \theta^{(n+1)} e^{-(T+\gamma)\theta} I_{R_+}(\theta). \end{aligned}$$

Então $\theta|x \sim \text{Gama}(n+1, T(x) + \gamma)$ e sob a perda quadrática, temos que o estimador de Bayes é dado por:

$$d_\Lambda = E_\gamma(\theta|x) = \frac{n+1}{\sum_{i=1}^n \log(x_i) + \gamma}$$

? $T = -\log(x)$?

Exercício 3. Seja $g(x)$ uma densidade de probabilidade que não depende de θ , dada a condição

$$\frac{d^2}{dx^2} \log g(x) \leq 0, \forall x,$$

temos que a função $\tau(x) = \log g(x)$ tem um máximo relativo que denotaremos por x_0 . Logo, tanto para $x < x_1 < x_0$ como $x_0 > x_1 > x$ temos que $\tau(x) < \tau(x_1)$. Também isto implica que a $g(x)$ cresce até x_0 para depois decrescer, ou seja $g(x) \leq g(x_1)$.

$x < x_1$

Deste modo para $\theta < \theta'$, temos que $x - \theta' < x - \theta$ o qual implica que:

$$\begin{aligned} g(x - \theta') &\leq g(x - \theta) \\ \Leftrightarrow \log\left[\frac{g(x - \theta')}{g(x - \theta)}\right] &\leq 0 \end{aligned}$$

também pela primeira desigualdade temos que:

$$\frac{d}{dx} \log\left[\frac{g(x - \theta')}{g(x - \theta)}\right] = \frac{1}{g(x - \theta')} - \frac{1}{g(x - \theta)} \geq 0, \forall x.$$

Do ultimo resultado temos que $\log\left[\frac{g(x - \theta')}{g(x - \theta)}\right]$ é não decrescente em x e como a função $\log(\cdot)$ é crescente em seu argumento isto leva à implicância de que a razão $g(x - \theta')/g(x - \theta)$ é não decrescente em x .

Exercício 7.

a. Uma vez que $X_i \sim \text{Pareto}(\beta, \gamma)$, temos que

$$Y_i = 2\beta \log\left\{\frac{X_i}{\gamma}\right\} \sim \text{Exp}(1/2), i \in \{1, \dots, n\},$$

uma vez que

$$\mathbb{P}(Y_i \leq y) = \mathbb{P}\left(X_i \leq \gamma e^{y/2\beta}\right) = \int_{\gamma}^{\gamma e^{y/2\beta}} \frac{\beta \gamma^\beta}{x^{\beta+1}} dx = -\frac{\gamma^\beta}{x^\beta} \Big|_{\gamma}^{\gamma e^{y/2\beta}} = 1 - e^{-y/2}, y > 0.$$

Daí, segue que $2 \sum_{i=1}^n \beta \log\{X_i/\beta\} \sim \chi^2_{2n}$, uma vez que se $Y_i \sim \text{Exp}(1/2)$, então $Y_i \sim \sim \chi^2_2$ e a soma de chi-quadrados independentes é uma chi-quadrado com os graus de liberdades adicionados. Daí, segue que um intervalo de confinância de nível $1 - \alpha$ baseado em Q é dado por

$$\left[\frac{q_{\alpha/2}}{2 \sum_{i=1}^n \log\{X_i/\beta\}}, \frac{q_{1-\alpha/2}}{2 \sum_{i=1}^n \log\{X_i/\beta\}} \right], \quad \times$$

onde q_a é o quantil de ordem a de uma χ^2_{2n} .

b A função de densidade conjunta é dada por

$$f(x|\beta) = \beta^n \gamma^{n\beta} \left(\prod_{i=1}^n x_i\right)^{-(\beta+1)} I_{(\gamma, +\infty)}(x_{(1)}).$$

Para $\beta > \beta_0$, a razão é dada por

$$\begin{aligned} \frac{f(x|\beta_1)}{f(x|\beta_0)} &= \frac{\beta_1^n \gamma^{n\beta_1} (\prod_{i=1}^n x_i)^{-(\beta_1+1)} I_{(\gamma, +\infty)}(x_{(1)})}{\beta_0^n \gamma^{n\beta_0} (\prod_{i=1}^n x_i)^{-(\beta_0+1)} I_{(\gamma, +\infty)}(x_{(1)})} \\ &= (\beta_1/\beta_0)^n \gamma^{n\beta_1 - n\beta_0} \left(\frac{1}{\prod_{i=1}^n x_i}\right)^{\beta_1 - \beta_0}. \end{aligned}$$

Logo, $f(x|\beta)$ tem RVM em $\frac{1}{\prod_{i=1}^n x_i}$ e, portanto, também em $T = -\sum_{i=1}^n \log x_i$. Assim, $\bar{\beta}$ será a solução de $P_\beta(T < t) = 1 - \alpha$.

$$\bar{\beta} = ?$$

~~X~~ c Dado que $f(x|\beta)$ tem RVM em $T = -\sum_{i=1}^n \log x_i$,

$$\phi(X) = \begin{cases} 1, & -\sum_{i=1}^n \log X_i > c \\ 0, & -\sum_{i=1}^n \log X_i \leq c \end{cases}$$

$$\Rightarrow c = ?$$

d Quando β é conhecido e γ desconhecido, podemos reescrever

$$\cancel{X} f(x|\gamma) = \beta^n \gamma^{n\beta} \left(\prod_{i=1}^n x_i \right)^{-(\beta+1)} I_{(\gamma, +\infty)}(x_{(1)}).$$

Para o caso das hipóteses simples dadas por

$$H : \gamma = \gamma_0 \quad \text{vs} \quad K : \gamma = \gamma_1, \gamma_0 < \gamma_1,$$

pelo LNP, o teste UMP de nível α é da forma $\phi(X) = \begin{cases} 1, & \text{se } f(x|\gamma_1) > f(x|\gamma_0) \\ \gamma, & \text{se } f(x|\gamma_1) = f(x|\gamma_0) \\ 0, & \text{se } f(x|\gamma_1) < f(x|\gamma_0) \end{cases}$

$$\Rightarrow ?$$

Exercício 9.

Exercício 9 (a): Sejam X_1, \dots, X_n v.a i.i.d com distribuição $U(-\theta, \theta)$ em que $\theta > 0$. Em primeiro lugar apresentamos a densidade conjunta dada por:

$$f(x|\theta) = \left(\frac{1}{2\theta} \right)^n \prod_{i=1}^n I_{(-\theta, \theta)}(x_i)$$

Além disso, notemos que $x_i \in (-\theta, \theta) \Leftrightarrow |x_i| \in (0, \theta)$. Assim, considerando $y_1 = |x_1|$, temos que $\prod_{i=1}^n I_{(-\theta, \theta)}(x_i) = 1 \Leftrightarrow 0 < y_{(1)} < y_{(n)} < \theta$, em que $y_{(1)} = \min\{|x_1|, \dots, |x_n|\}$ e $y_{(n)} = \max\{|x_1|, \dots, |x_n|\}$. Logo podemos re-escrever a densidade conjunta :

$$f(x|\theta) = \left(\frac{1}{2\theta} \right)^n I_{(0, y_{(n)})}(y_{(1)}) I_{(0, \theta)}(y_{(n)}).$$

Consideremos as hipóteses $H_0 : \theta = \theta_0$ e $H_1 : \theta = \theta_1$ em que $\theta_0 < \theta_1$. Primeiro encontraremos o teste UMP segundo o LNP para estas hipóteses iniciais. Segundo o LNP o teste UMP é tal que $\phi(x) = 1$ se $f(x|\theta_1) > k f(x|\theta_0)$, $\phi(x) = \gamma$ se $f(x|\theta_1) = k f(x|\theta_0)$ e $\phi = 0$ se $f(x|\theta_1) < k f(x|\theta_0)$, para uma adequada constante k , tais que as condições [1] e [2] do Lema sejam satisfeitas, neste caso escolhemos $k = (\theta_1/\theta_0)^n$. Em este teste rejeitamos H_0 se

$$\begin{aligned} \left(\frac{1}{2\theta_1} \right)^n I_{(0, y_{(n)})}(y_{(1)}) I_{(0, \theta_1)}(y_{(n)}) &> k \left(\frac{1}{2\theta_0} \right)^n I_{(0, y_{(n)})}(y_{(1)}) I_{(0, \theta_0)}(y_{(n)}) \\ &\Leftrightarrow I_{(0, \theta_1)}(y_{(n)}) > I_{(0, \theta_0)}(y_{(n)}). \end{aligned}$$

Desde que sempre $y_{(1)} \leq y_{(n)}$ se $\theta_0 < \theta_1$, a ultima desigualdade é verdadeira somente no caso $1 > 0$ ou seja $\phi(x) = 1$ se $y_{(n)} > \theta_0$.

Agora $\phi(x) = \gamma$ se $I_{(0, \theta_1)}(y_{(n)}) = I_{(0, \theta_0)}(y_{(n)})$, ou seja quando $y_{(n)} < \theta_0$. Por outro lado, o conjunto dos x , tais que

$$I_{(0, \theta_1)}(y_{(n)}) < I_{(0, \theta_0)}(y_{(n)})$$

é vazio, desde que não existe um x , tais que isto acontece para $\theta_0 < \theta_1$.

Deste modo, o teste UMP aleatorizado é dado por:

$$\phi(x) = \begin{cases} 1, & \text{se } y_{(n)} > \theta_0 \\ \gamma, & \text{se } y_{(n)} < \theta_0 \end{cases}$$

Em que γ esta sujeito a

$$E_{\theta_0}[\phi(X)] = 1 \times P_{\theta_0}(Y_{(n)} > \theta_0) + \gamma \times P_{\theta_0}(Y_{(n)} < \theta_0) = 0 + \gamma = \alpha.$$

Porem o este UMP de nível α para as hipóteses simples consideradas é dado por:

$$\phi(x) = \begin{cases} 1, & \text{se } y_{(n)} > \theta_0 \\ \alpha, & \text{se } y_{(n)} < \theta_0 \end{cases}$$

Dado que este teste é valido para $\theta_0 < \theta_1$, também é um test UMP quando é considerado qualquer outro $\theta' > \theta_0$, ou seja o este é UMP para testar as hipóteses $H : \theta = \theta_0$ contra $K : \theta > \theta_0$.

Para as hipóteses $H^* : \theta \leq \theta_0$ countra $K : \theta > \theta_0$, temos que a densidade conjunta considerada tem RVM em a estatística $T(X) = \max\{|X_1|, \dots, |X_n|\}$, desde que:

$$\frac{f(x|\theta_1)}{f(x|\theta_0)} = \begin{cases} (\frac{\theta_0}{\theta_1})^n, & \text{se } y_{(n)} < \theta_0 \\ \infty, & \text{se } \theta_0 < y_{(n)} < \theta_1 \end{cases}$$

Dado que a distribuição de $Y_{(n)}$ é continua o teste UMP será dado por:

$$\phi_1(x) = \begin{cases} 1, & \text{se } y_{(n)} > c \\ 0, & \text{se } y_{(n)} < c. \end{cases}$$

Como foi visto em listas anteriores a função de densidade de $Y_{(n)}$ é dada por:

$$f_{Y_{(n)}}(y|\theta) = n\theta^{-n}y^{n-1}I_{(0,\theta)}(y).$$

A constante c tem que garantir que o teste é de nível α , ou seja:

$$E_{\theta_0}[\phi_1(X)] = P_{\theta_0}(Y_n > c) = \int_c^{\theta_0} n\theta^{-n}y^{n-1}dx = \frac{y^n}{\theta_0^n}|_{c}^{\theta_0} = 1 - \frac{c^n}{\theta_0^n}.$$

O qual implica que $c = \theta_0(1 - \alpha)^{1/n}$. Para finazar esta parte o teste é dado por:

$$\phi_1(x) = \begin{cases} 1, & \text{se } y_{(n)} > \theta_0(1 - \alpha)^{1/n} \\ 0, & \text{se } y_{(n)} < \theta_0(1 - \alpha)^{1/n}. \end{cases}$$

O poder do teste $\phi_1(x)$ para algum $\theta > \theta_0$ é dado por:

$$E_\theta[\phi_1(x)] = P_\theta(Y_{(n)} > \theta_0(1 - \alpha)^{1/n}) = 1 - (1 - \alpha)\left[\frac{\theta_0}{\theta}\right]^n.$$

Resumendo, o teste $\phi_1(x)$ é o teste UMP de nível α para testar as hipóteses $H^* : \theta \leq \theta_0$ contra $K : \theta > \theta_0$. Voltando ao teste inicial que foi denotado por $\phi(x)$ é posivel verificar que ele é de nível α para estas hipóteses, pois:

$$\sup_{\theta: \theta \leq \theta_0} \{E_\theta[\phi(x)]\} = \sup_{\theta: \theta \leq \theta_0} \{1P_\theta(Y_{(n)} > \theta_0) + \alpha P(Y_{(n)} < \theta_0)\} = \sup_{\theta: \theta \leq \theta_0} \{\alpha \times 1\} = \alpha.$$

Também, o poder do teste ϕ para as hipóteses consideradas é:

$$\begin{aligned} E_\theta[\phi(X)] &= P_\theta(Y_{(n)} > \theta_0) + \alpha P_\theta(Y_{(n)} < \theta_0) = \int_{\theta_0}^{\theta} n\theta^{-n} y^{n-1} dx + \alpha \int_0^{\theta_0} n\theta^{-n} y^{n-1} dx \\ 1 - \int_0^{\theta_0} n\theta^{-n} y^{n-1} dx + \alpha \int_0^{\theta_0} n\theta^{-n} y^{n-1} dx &= 1 - (1 - \alpha) \int_0^{\theta_0} n\theta^{-n} y^{n-1} dx \\ &= 1 - (1 - \alpha) \left[\frac{\theta_0}{\theta} \right]^n, \forall \theta > \theta_0. \end{aligned}$$

Desta forma $\phi(x)$ é de nível α é mesmo poder a $\phi_1(x)$, ou seja o teste $\phi(x)_1$ também é mais poderoso para testar as hipóteses.

Exercício 9 (b): Para $\theta > 0$, temos que:

$$\begin{aligned} \beta_\phi(\theta) &= E_\theta(\phi(X)) = P_\theta(Y_{(n)} > \theta_0) + \alpha P_\theta((Y_{(n)} < \theta_0)) \\ &= 1 - P_\theta(Y_{(n)} \leq \theta_0) + \alpha P_\theta((Y_{(n)} < \theta_0)) \\ &= 1 - (\alpha) P_\theta(Y_{(n)} \leq \theta_0) \\ &= \begin{cases} \alpha, & \text{se } \theta \leq \theta_0 \\ 1 - (1 - \alpha) \left[\frac{\theta_0}{\theta} \right]^n, & \text{se } \theta > \theta_0. \end{cases} \end{aligned}$$

Exercício 11. Nesta demonstração nos assumimos que o teste $\phi(x)$ será dado por

$$\phi(x) = \begin{cases} 1, & \text{se } x \in S_0 \\ \gamma, & \text{se } x \in S_1 \end{cases}$$

, em que S_0 e S_1 são as regiões de aceitação e rejeição respectivamente. Pela definição de esperança condicional temos que:

$$\psi(t) = E[\phi(X)|T = t] = 1 \times P_\theta(x \in S_0|T = t) = \begin{cases} P_\theta(x \in S_0|T = t) = P'_t(x), & \text{se } T(x) = t. \\ 0, & \text{se } T(x) \neq t \end{cases}$$

Em que para um x fixo, $P'_t(x)$ somente depende de t . Seja Ω_K o subconjunto de Ω determinado por K . O poder do teste $\psi(t)$ para $\forall \theta \in \Omega_K$ é dado por:

$$\beta_{\psi(t)}(\theta) = E_\theta[\psi(T)] = E_\theta \left[E(\phi(X)|T = t) \right] = E_\theta(\phi(X)) = \beta_{\phi(x)}(\theta).$$

Ou seja, o poder do teste $\psi(t)$ é o mesmo que o poder do teste ϕ para todo $\theta \in \Omega_K$.

Fazer

E1 Seja X uma única observação de uma distribuição geométrica com função de probabilidade

$$f(x|\theta) = \theta^x(1-\theta), \quad x=0,1,\dots; \quad \theta \in (0,1).$$

- (a) Encontre o estimador do método dos momentos de θ .
- (b) Existe estimador não viésado de θ ? Se sim, encontre o ENVVUM de θ .
- (c) Considere uma distribuição a priori $U(0,1)$ para θ . Encontre o estimador de Bayes de θ sob perda quadrática.

E2 Seja X uma única observação de uma variável aleatória com densidade $f(x;\theta) = 2x/\theta^2$, $0 < x < \theta$; $\theta > 0$. Considerar para θ uma distribuição uniforme no intervalo unitário.

- (a) Obtenha a função densidade de probabilidade a posteriori de θ .
- (b) Encontre o estimador de Bayes com respeito à perda $\theta^2(d-\theta)^2$.

E3 Sejam X e Y variáveis aleatórias independentes com distribuições P_ζ e Q_η respectivamente. Suponha que ζ e η são consideradas variáveis aleatórias independentes, reais, com distribuições Λ e Λ' respectivamente. Se, com perda quadrática, δ_Λ é o estimador de Bayes de ζ com base em X e $\delta_{\Lambda'}$ é o estimador de Bayes de η com base em Y ,

- (a) mostre que $\delta_{\Lambda'} - \delta_\Lambda$ é o estimador de Bayes de $\eta - \zeta$ com base em (X, Y) .
- (b) Se $\eta > 0$ e δ_Λ^* é o estimador de Bayes de $1/\eta$ com base em Y , mostre que $\delta_\Lambda - \delta_{\Lambda'}^*$ é o estimador de Bayes de ζ/η com base em (X, Y) .

E4 Seja X uma variável aleatória representando o tempo de vida de um sistema eletrônico, com função distribuição acumulada $F_\theta(x)$, $\theta \in \Omega$. Defina a confiabilidade do sistema por

$$R_\theta(\tau) = P_\theta(X > \tau) = 1 - F_\theta(\tau), \quad \tau > 0.$$

Considere n observações independentes X_1, \dots, X_n de X . Admita que, dado θ , X tem distribuição exponencial de parâmetro θ e função densidade de probabilidade

$$f(x;\theta) = \theta \exp(-\theta x), \quad x > 0; \quad \theta > 0.$$

- (a) Mostre que, neste caso, $R_\theta(\tau) = \exp(-\tau\theta)$.
- (b) Encontre o estimador de máxima verossimilhança de $R_\theta(\tau)$.
- (c) Encontre o ENVVUM de $R_\theta(\tau)$.

- (d) Mostre que o estimador de Bayes de $R_\theta(\tau)$ sob perda quadrática e função densidade a priori para θ

$$\pi(\theta) = \frac{1}{\gamma^\nu \Gamma(\nu)} \theta^{\nu-1} \exp(-\theta/\gamma), \quad \theta > 0,$$

é dado por

$$\left(1 + \frac{\tau}{\sum_{i=1}^n X_i + 1/\gamma}\right)^{-(\nu+1)}.$$

$$\text{fam: } \frac{\beta^\alpha}{\Gamma(\alpha)} x^{-\alpha-1} \exp(-\frac{\beta}{x}) \quad EX = \frac{\beta}{\alpha-1} \quad \text{Var } X = \frac{\beta^2}{(\alpha-1)^2 (\alpha-2)} \quad \text{Cov } X = \frac{\beta^3}{(\alpha-1)^3 (\alpha-2)}$$

$$\text{fam: } \frac{\alpha!}{(x-1)!} x^{x-1} \exp(-\alpha) \quad K(x) = \sqrt{\alpha x + \alpha}$$

Fazer

E5 Seja $X = (X_1, \dots, X_n)$ uma amostra aleatória de uma distribuição $N(\theta, \theta^2)$, $\theta > 0$. Considere a seguinte classe dos estimadores de θ :

$$\Delta = \{\delta(X) = a\bar{X}_n + bS_n, \quad -\infty < a < +\infty, \quad -\infty < b < +\infty\},$$

onde $\bar{X}_n = \sum_{i=1}^n X_i/n$. Aqui, $\bar{X}_n = \sum_{i=1}^n X_i/n$ e $S_n^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2/(n-1)$.

Encontre restrições para a e b de tal forma que os estimadores em Δ sejam não viésados para θ . Denote a classe de estimadores resultante por Δ^* . Obtenha o estimador $\delta^* \in \Delta^*$ que tem variância uniformemente mínima. Esse estimador coincide com \bar{X}_n ?

E6 Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes e identicamente distribuídas segundo uma distribuição $N(0, \sigma^2)$. Considere o problema de estimar σ^2 com a função de perda $L(\sigma^2, d) = (d/\sigma^2 - 1)^2 = (d - \sigma^2)^2/d^4$.

- (a) Considere uma distribuição a priori $Gama(a, b)$ para $\theta = 1/(2\sigma^2)$ com densidade

$$\pi(\theta) = \frac{1}{\Gamma(a)b^a} \theta^{a-1} \exp\{-\theta/b\}; \quad a > 0, \quad b > 0.$$

Encontre o estimador de Bayes de σ^2 .

- (b) Mostre que $\delta(X) = \sum_{i=1}^n X_i^2/(n+2)$ tem risco uniformemente menor ou igual aos de todos os estimadores da forma $c \sum_{i=1}^n X_i^2$. Mostre que o estimador de máxima verossimilhança é inadmissível.

- (c) Mostre que $\delta(X) = \sum_{i=1}^n X_i^2/(n+2)$ é um estimador minimax de σ^2 .

E7 Sejam X_1, \dots, X_n uma amostra aleatória da distribuição de binomial negativa $bn(p, m)$. Considere uma distribuição a priori Beta(α, β) para p . Encontre o estimador de Bayes de p sob perda quadrática.

E8 Suponha que X tenha distribuição binomial $b(\theta, n)$. Considere uma distribuição a priori Beta(α, β) com $\alpha = \beta = 0$ (priori imprópria) e a perda quadrática. Considere estimadores δ que satisfazem $\delta(0) = 0$ e $\delta(n) = 1$. Mostre que o risco a posteriori é minimizado em $\delta(x) = x/n$. [Ver Exemplo 2.8, p. 238-239, TPE].

E9 Suponha que, dados θ e σ^2 , X_1, \dots, X_n sejam variáveis aleatórias independentes com distribuição $N(\theta, \sigma^2)$. Admita que, a priori, $\tau = 1/(2\sigma^2)$ tem distribuição Gama($g, 1/\alpha$) e θ , independente de τ , tem distribuição uniforme (imprópria) na reta.

- (a) Mostre que a densidade conjunta a posteriori é proporcional a $\tau^{r+g-1} e^{-\tau[\alpha+z+n(\theta-\theta)^2]}$ onde $z = \sum(x_i - \bar{x})^2$ e $r = n/2$.

- (b) Mostre que distribuição a posteriori de τ é Gama($r+g-1/2, 1/(\alpha+z)$).

- (c) Mostre que se $\alpha = g = 0$, o estimador de Bayes (generalizado) de σ^2 é $Z/(n-3)$ para perda quadrática. Para a perda $(d - \sigma^2)^2/\sigma^4$, este estimador é $Z/(n+1)$.

- (d) Mostre que a densidade a posteriori de θ é simétrica em relação a \bar{X} e que o estimador de Bayes (generalizado) é \bar{X} .

E10 Suponha que, dado p , $X \sim b(n, p)$ e considere a densidade (imprópria) proporcional a $p^{-1}(1-p)^{-1}$ para p . Mostre que X/n é um estimador de Bayes (generalizado) para p sob perda quadrática.

E11 Suponha que X tem distribuição $b(p, n)$ e considere o problema de estimar p com perda $(d-p)^2/[(p(1-p))]$. Obtenha o estimador minimax.

$$\frac{(1-p)^2}{2p^2} \quad \sqrt{\frac{2p}{2p+1}} \quad \frac{2p}{2p+1}$$

Sejam X_1, \dots, X_m e Y_1, \dots, Y_n amostras aleatórias independentes das distribuições $N(\mu_x, \sigma_x^2)$ e $N(\mu_y, \sigma_y^2)$, respectivamente; aqui $\mu_x \in \mathbb{R}$, $\mu_y \in \mathbb{R}$, $\sigma_x^2 > 0$ e $\sigma_y^2 > 0$. Considere o problema de estimar $\Delta = \mu_y - \mu_x$ sob perda quadrática.

(a) Mostre que $\bar{Y} - \bar{X}$ é estimador minimax de Δ quando σ_x e σ_y são conhecidos; $\bar{X} = m^{-1} \sum_{i=1}^m X_i$ e $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$.

(b) Mostre que $\bar{Y} - \bar{X}$ é estimador minimax de Δ quando $\sigma_x^2 \leq M_x$ e $\sigma_y^2 \leq M_y$, sendo $M_x > 0$ e $M_y > 0$ constantes conhecidas.

Sugestão: Use o seguinte resultado: Se, dado ξ , Z_1, \dots, Z_n são independentes e têm distribuição $N(\xi, \sigma^2)$, e se a distribuição a priori para ξ é $N(\zeta, b^2)$, então a distribuição a posteriori de ξ , dado que $Z_1 = z_1, \dots, Z_n = z_n$, é normal de média $(n\bar{z}/\sigma^2 + (\zeta/b^2))/(n/\sigma^2 + 1/b^2)$ e variância $(n/\sigma^2 + 1/b^2)^{-1}$, onde $\bar{z} = \sum_{i=1}^n z_i/n$.

13. Prove ou dê contra-exemplo.

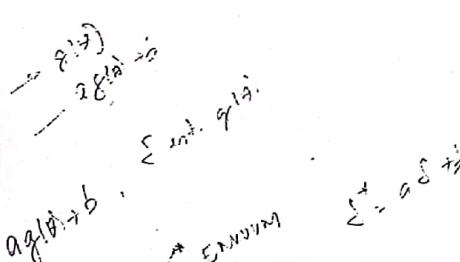
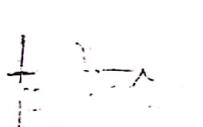
- (a) Se um estimador minimax é único, então ele é admissível.
- (b) Um estimador minimax não pode ser não viável.
- (c) Se um estimador tem risco constante e é admissível, ele é minimax.

14. Seja δ um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $g(\theta)$ sob perda quadrática. Então, $a\delta + b$ é um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $a g(\theta) + b$. Aqui, a e b são números reais.

15. Seja $\hat{\theta}$ um estimador não viável de um parâmetro $\theta \in \mathbb{R}$. Mostre que o estimador $\hat{\theta} + c$ não é minimax sob perda quadrática a menos que $\sup_{\theta \in \mathbb{R}} R(\theta, \hat{\theta}) = \infty$ para todo estimador $\hat{\theta}$. Aqui $c \neq 0$ é uma constante conhecida e $R(\theta, \hat{\theta})$ é o risco do estimador $\hat{\theta}$.

Contra-exemplo

Fazer



Alessandra Giovanna, 2ºano
19/02/2010

①

4º lista de Estatística Avançada I
03/1/2010

Portanto, δ é um estimador ENVIADO para θ é dado por:

$$\delta(x) = \bar{I}_{\frac{x}{\theta}}^{+}(x)$$

pois é não viável e função da estatística suficiente, completa $T(x) = x$.

④ Método dos Momentos:

$$\begin{aligned} E[X] = \sum_{k=0}^{\infty} k P(X=k) &= \sum_{k=1}^{\infty} k \theta(1-\theta)^{k-1} X_0 = \theta(1-\theta) \sum_{k=1}^{\infty} k \theta^{k-1} = \theta(1-\theta) \frac{\theta}{(1-\theta)^2} \\ &= \theta(1-\theta) \frac{d}{d\theta} \sum_{k=1}^{\infty} \theta^k = \theta(1-\theta) \frac{d}{d\theta} \left(\frac{\theta}{1-\theta} \right) = \frac{\theta}{1-\theta} \end{aligned}$$

Portanto, com auxílio da teorema 1, X é viável $\frac{\theta}{1-\theta}$ para qualquer θ momento. Logo, δ é um estimador de θ é dado por:

$$\hat{\theta} = \frac{\theta}{1-\theta} \Rightarrow \hat{\theta} = \frac{X}{1+X}$$

② $f(x|\theta) = \exp \left\{ x \log \theta + \log(1-\theta) \right\}, \quad x=0, 1, \dots, \theta \in (0, 1)$

Fazendo esperanca unidimensional, com $T(x) = X$, $\mathbb{E}[X] = \log \theta$ e $B(\theta) = \log(1-\theta)$. No intervalo paramétrico Θ podemos considerar

segundo da ulta $\Rightarrow X$ é completa e suficiente.
Siga $\delta(x)$ é um estimador incompleto, $\forall \theta \in (0, 1)$, utilizando o método:

$$\sum_{k=0}^{\infty} \delta(x) \theta^{k-1} = \theta \Leftrightarrow \sum_{k=0}^{\infty} \delta(x) \frac{\theta^k}{k!} = \frac{\theta}{k!} = \frac{1}{k!} \theta^k = 0 \times \theta^0 + \sum_{k=1}^{\infty} \frac{\theta^k}{k!} = 0 \times \theta^0 + \frac{\theta}{1+\theta}$$

Portanto, δ é um estimador ENVIADO para θ é dado por:

$$\delta(x) = \bar{I}_{\frac{x}{\theta}}^{+}(x)$$

pois é não viável e função da estatística suficiente, completa $T(x) = x$.

③ $T(\theta) \sim U(0, 1)$

sob perda quadrática, o estimador $\delta_\lambda(x)$ é dado por:

$$\delta_\lambda(x) = \mathbb{E}[\theta | X=x] = \int_0^1 \theta \cdot \pi(\theta|x) d\theta$$

Não $\pi(\theta|x) \propto \theta^{(1-\theta)} \cdot I_{(0,1)}(\theta)$

$$\pi(\theta|x) = \frac{1}{\beta(x+1)} \theta^x (1-\theta)^{1-x} \Rightarrow \theta|x \sim \text{Beta}(x+1, 2)$$

Portanto: $\delta_\lambda(x) = \frac{x+1}{x+3}$

$\alpha = x+1$

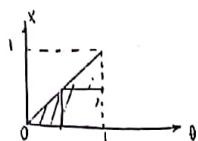
$$\beta(x+1) = \frac{\Gamma(x+1)}{\Gamma(x+2)} \frac{\Gamma(x+4)}{\Gamma(x+2)} = \frac{\Gamma(x+3)}{\Gamma(x+2)} = \frac{(x+2)!}{(x+1)!} = x+2$$

$\beta = 2$

2º Questão

$$f(x|\theta) = \frac{2x}{\theta^2}, \quad 0 < x < \theta < 0$$

$$\pi(\theta) = I_{(0,1)}(\theta)$$



$$\textcircled{1} \quad \pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{q(x)} = \frac{\frac{2x}{\theta^2} \cdot I_{(0,1)}(\theta) I_{(0,\theta)}(x)}{2(1-x)} = \frac{x}{\theta^2(1-x)} I_{[0,1]}(x)$$

$$\text{pois. } q(x) = \int_x^1 f(x|\theta) \cdot \pi(\theta) d\theta = \int_x^1 \frac{2x}{\theta^2} d\theta = 2x \theta^{-1} \Big|_{\theta=1}^x = 2 - 2x = 2(1-x), \quad 0 < x \leq \theta$$

$$\textcircled{2} \quad L(\theta, d) = \theta^2 [d - \theta]^2$$

$$\delta_\lambda(x) = \frac{\mathbb{E}[\theta^2 | X=x]}{\mathbb{E}[\theta^2 | X=x]} = \frac{\int_x^1 \theta^2 \frac{x}{\theta^2(1-x)} d\theta}{\int_x^1 \theta^2 \frac{x}{\theta^2(1-x)} d\theta} = \frac{\frac{x}{1-x} \cdot \frac{1-x^2}{2}}{\frac{x}{1-x} \cdot (1-x)} \Rightarrow$$

$$\Rightarrow \boxed{\delta_\lambda(x) = \frac{1+x}{2}}$$

6º Questão

(X_1, \dots, X_n) iid, $X_i \sim N(0, \sigma^2)$. Estimar σ^2 .

$$L = \left(\frac{1}{\sigma^2} \right) (d - \frac{x^2}{\sigma^2}) = L(\sigma^2, d)$$

$$\textcircled{4} \quad \theta = \frac{1}{2\sigma^2} \quad \text{e} \quad \pi(\theta) = \frac{1}{\Gamma(a)} \theta^{a-1} \exp\{-\theta/b\}, \quad a > 0, b > 0$$

$$\text{Suumary estimator } \hat{\sigma}^2 = \frac{1}{2\theta}$$

$$L(\theta, d) = 4\theta^2 \left(d - \frac{1}{2\theta}\right)^2 = w(\theta) (d - g(\theta))^2 \quad \textcircled{*}$$

$$\delta_\lambda(x) = \frac{\mathbb{E}[2\theta^2 | X=x]}{\mathbb{E}[4\theta^2 | X=x]} = \frac{2\mathbb{E}[\theta | X=x]}{\mathbb{E}[\theta^2 | X=x]} = \frac{\mathbb{E}[\theta | X=x]}{2\mathbb{E}[\theta^2 | X=x]}$$

$$f(x|\sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^n \exp\left\{ -\frac{\sum x_i^2}{2\sigma^2} \right\} \Rightarrow \left(\frac{1}{\pi} \right)^n \exp\left\{ -\theta \sum x_i^2 \right\} = f(x)$$

$$\pi(\theta|x) \propto f(x|\theta) \pi(\theta) \propto \theta^{a-1} \exp\left\{ -\theta \left(\frac{1}{b} + \frac{1}{2} \sum x_i^2 \right) \right\} = \theta^{\frac{n}{2}+a-1} \exp\left\{ -\theta \left(\frac{1}{b} + \frac{1}{2} \sum x_i^2 \right) \right\}$$

que é o risco de uma gama (α, β) , sendo:

$$\alpha = \frac{n}{2} + a$$

$$\beta = \frac{1}{\frac{1}{b} + \sum x_i^2} = \frac{b}{1 + b \sum x_i^2}$$

c.s.

$$\text{Portanto: } \delta_\lambda(x) = \frac{\lambda \beta}{2(\lambda \beta + \alpha \beta)} = \frac{1}{2\beta(1+\alpha)}$$

$$\boxed{\delta_\lambda(x) = \frac{1}{2 \frac{b}{1+b \sum x_i^2} (1 + \frac{n}{2} + a)}} = \frac{1 + b \sum x_i^2}{2b (1 + a + \frac{n}{2})}$$

$$\textcircled{5} \quad \delta(x) = \frac{\sum x_i^2}{n+2}$$

$$L = \left(\frac{d}{\sigma^2} - 1 \right)^2 \quad \text{e} \quad R = E_\theta[L(d, \sigma^2)]$$

$$\text{Mas } \frac{d}{\sigma^2} = \frac{v}{n+2} \quad ; \quad \text{ onde } v \sim \chi^2_n$$

$$\text{Portanto: } R = E_\theta \left(\frac{v-n-2}{n+2} \right)^2 = \frac{1}{(n+2)^2} E_\theta (v^2 - 2(n+2)v + (n+2)^2)$$

$$R = \frac{1}{(n+2)^2} (zn+n^2 - 2(n+2)v + (n+2)^2) = \frac{1}{(n+2)^2} ((n+2)^2 - n(n+2))$$

$$\boxed{R = 1 - \frac{n}{n+2} \quad \text{para } \delta(x) = \frac{\sum x_i^2}{n+2}}$$

$$\textcircled{6} \quad \text{Para } \delta^* = c \sum_{i=1}^n x_i^2, \quad c > 0, \quad \text{obter os seguintes resultados:}$$

$$R = E_\theta(cv-1)^2 = E_\theta(c^2v^2 - 2cv + 1) = c^2(zn+n^2) - 2cn + 1 \Rightarrow$$

$$\Rightarrow R = 1 + cn \left[c(n+2) - 2 \right] = 1 + \frac{c^2n(n+2) - 2nc}{\text{polinômio em } c}$$

$$\text{O polinômio em } c \text{ atinge o mínimo em } c = \frac{zn}{z(n+2)}, \text{ valor de } \frac{vn(v+2)}{(n+2)^2} - \frac{zn}{n+2} = -\frac{vn}{n+2} \Rightarrow 0 \text{ risco} \Leftrightarrow \text{mínimo, igual a:}$$

$$R = 1 - \frac{vn}{n+2}, \text{ que é o risco do estimador anterior.}$$

$$\textcircled{7} \quad \text{Finalmente, o EMV de } \hat{\sigma}^2 \text{ é } \hat{\sigma}^2 = \frac{\sum x_i^2}{n}, \text{ cujo risco é dado por:}$$

$$R = E_\theta \left(\frac{v}{n} - 1 \right)^2 = \frac{1}{n^2} E_\theta (v^2 - 2vn + n^2) = \frac{1}{n^2} (zn+n^2 - 2vn + n^2)$$

$$R = \frac{2}{n} > \frac{z}{n+2} = \frac{n+2-n}{n+2} = 1 - \frac{n}{n+2} \quad \text{que é o risco da}$$

$$\text{estimador } \frac{\sum x_i^2}{n} \Rightarrow 0 \text{ EMV de } \hat{\sigma}^2 \text{ é inadmissível.}$$

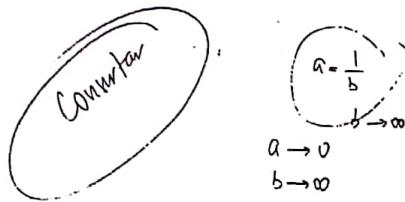
④ O estimador $\hat{s}(x) = \frac{\sum_{i=1}^n x_i^2}{n+2}$ corresponde a uma função Gamma tal que:

$$\begin{aligned} z \cdot b(1 + a + \frac{1}{n}) &= 1 \\ z \cdot (1 + a + \frac{n}{2}) &= n+2 \end{aligned} \Rightarrow \begin{cases} b = \frac{1}{n+2} \\ a = \frac{n}{2} - 1 - \frac{1}{n} = \frac{n}{2} - \frac{1}{n} \end{cases}$$

que virá a ser a priori uma função favorável.

O risco desse estimador é independente de x^2 , segundo item B \Rightarrow

$$\Rightarrow r(\theta, \hat{s}_\lambda) = \sup_{d^2} R(d^2, \hat{s}_\lambda)$$

$$\Rightarrow \hat{s}(x) \text{ é minimax}$$


⑤ Para usarmos o teorema, precisamos provar que para quase todo X , $\exists \delta_\lambda$ que minimiza $E\{L(\theta, f(x)) | X=x\}$

Da solução da questão vemos que $\theta|x \sim \text{Gamma}(\alpha, \beta)$ temos:

$$\begin{aligned} E\{L(\theta, f(x)) | X=x\} &= E\left\{4\hat{d}^2\left(\hat{d} - \frac{1}{2}\right)^2 | X=x\right\} = \\ &= E\{4\hat{d}^2 - 4\hat{d} + 1 | X=x\} = 4\hat{d}^2(\alpha^2 + \beta^2) - 4\alpha\beta d + 1 \end{aligned}$$

que é minimizado quando $d = \frac{\alpha\beta}{2(\alpha^2 + \beta^2)} = \frac{1}{2\beta(1+\alpha)} = \delta_\lambda$

o cujo risco é igual a

$$\begin{aligned} \frac{\alpha^2 + \beta^2}{4\beta^2(1+\alpha)^2} - \frac{2}{4\alpha\beta} \frac{1}{2\beta(1+\alpha)} + 1 &= \frac{\alpha(1+\alpha)}{(1+\alpha)^2} - \frac{2\alpha}{1+\alpha} + 1 = \\ &= 1 - \frac{\alpha}{1+\alpha} \quad \text{que é finito, pois } \alpha = a + \frac{1}{n} \end{aligned}$$

IIº Bloco

$X \sim b(p, n)$

Estimar p com função $L(d, p) = \frac{(d-p)^2}{p(1-p)}$

Utilizando a seguinte das Notas da folha, vamos utilizar para p a função $\pi(p) = I_{(0,1)}(p)$

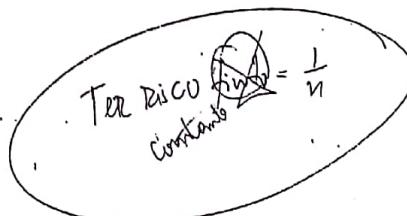
$\pi(p|x) \propto f(x|p)$. $\pi(p) = C_n^p p^x (1-p)^{n-x}$, $p \in (0,1) \Rightarrow p|x \sim \text{Beta}(x+1, n-x+1)$

O estimador de Bayes é dado por:

$$\delta_\lambda(x) = \frac{E\left[\frac{p}{p(1-p)} | X=x\right]}{E\left[\frac{1}{p(1-p)} | X=x\right]} = \frac{\int_0^1 p^x (1-p)^{n-x-1} dp}{\int_0^1 p^{x-1} (1-p)^{n-x-1} dp} = \frac{\beta(x+1, n-x)}{\beta(x, n-x)} =$$

$$= \frac{\beta(x+1, n-x)}{\beta(x+1, n-x+1)} \int_0^1 (d-p)^2 \frac{1}{p(x, n-x)} p^{x-1} (1-p)^{n-x-1} dp, \text{ que é}$$

minimizada quando $d = E(p|x) = \frac{x}{n-x+1} = \frac{x}{n}$:



Portanto, a função utilizada é a menor favorável e o estimador minimax é dado por $\frac{x}{n}$.

Para usarmos ⑤ é necessário mostrar que q.c. para todo X , conseguimos encontrar d que minimizar:

$$E\{L(d, p) | X=x\} = \int_0^1 (d-p)^2 \frac{1}{\pi(x, n-x)} p^{x-1} (1-p)^{n-x-1} dp =$$

12º Questão

X_1, \dots, X_m iid, $X_i \sim N(\mu_x, \sigma_x^2)$, $\mu_x \in \mathbb{R}$, $\sigma_x^2 > 0$

Y_1, \dots, Y_n iid, $Y_i \sim N(\mu_y, \sigma_y^2)$, $\mu_y \in \mathbb{R}$, $\sigma_y^2 > 0$

Estimar $\Delta = \mu_y - \mu_x$ sob perda quadrática

- (A) Supondo σ_x^2, σ_y^2 conhecidos, vamos utilizar a sugestão dada para os priors de μ_x e μ_y . Vamos usar as mesmas trinis para μ_x e μ_y , isto é, $N(0, b^2)$. Poderia ser de forma? $N(0, b^2)$ é de forma constante?

$$f(x, y | \mu_x, \mu_y) = \left(\frac{1}{\sqrt{2\pi\sigma_x^2}}\right)^m \left(\frac{1}{\sqrt{2\pi\sigma_y^2}}\right)^n \exp\left\{-\frac{\sum_{i=1}^m x_i^2 - 2\mu_x \sum_{i=1}^m x_i + m\mu_x^2}{2\sigma_x^2} - \frac{\sum_{j=1}^n y_j^2 - 2\mu_y \sum_{j=1}^n y_j + n\mu_y^2}{2\sigma_y^2}\right\}$$

e a estatística suficiente é $T = (\sum_{i=1}^m x_i, \sum_{j=1}^n y_j)$

Usando a priori acima e considerando que sob perda quadrática o estimador de Bayes de $\mu_y - \mu_x$ é a média a posterior, temos o seguinte estimador de Bayes:

$$\begin{aligned} \hat{\delta}_\lambda &= E(\hat{\mu}_y - \hat{\mu}_x | x = \bar{x}, y = \bar{y}) = E(\hat{\mu}_y | x = \bar{x}, y = \bar{y}) - \\ &- E(\hat{\mu}_x | x = \bar{x}, y = \bar{y}) \stackrel{\text{modo}}{=} E(\hat{\mu}_y | \bar{y}) - E(\hat{\mu}_x | \bar{x}) = \\ &= \frac{n\bar{y}}{\frac{n}{\sigma_y^2} + \frac{1}{b^2}} - \frac{m\bar{x}}{\frac{m}{\sigma_x^2} + \frac{1}{b^2}}. \text{ e seu risco será dado por:} \end{aligned}$$

07

$$r_\lambda = \text{Var}(\hat{\mu}_y - \hat{\mu}_x | x = \bar{x}, y = \bar{y}) \text{ pris as variâncias}$$

a posterior não dependem da constante.

Da independência entre x e y :

$$r_\lambda = \text{Var}(\hat{\mu}_y | \bar{y}) + \text{Var}(\hat{\mu}_x | \bar{x}) = \left(\frac{n}{\sigma_y^2} + \frac{1}{b^2}\right) + \left(\frac{m}{\sigma_x^2} + \frac{1}{b^2}\right)$$

Temos agora uma sequência de primis tais que $b^2 \rightarrow \infty$

Por exemplo, $b^2 = k^2$, k no intiro

$$\text{Assim, } \lim_{k \rightarrow \infty} r_{\lambda_k} = \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m}$$

$$\begin{aligned} \text{Mas } r &= \sup_{\theta} R(\theta, \bar{y} - \bar{x}), \text{ pris } R(\theta, \bar{y} - \bar{x}) = \text{Var}_{\theta}(\bar{y} - \bar{x}) = \\ &= \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m}, \text{ independente de } \theta = (\mu_x, \mu_y). \end{aligned}$$

Pertanto, $\bar{y} - \bar{x}$ é minimax e a sequência de primis acima construída

14º Questão

$\delta(x)$ estimador de Bayes (ENVVUM, minimizar, admissível) de $g(\theta)$.
Seja $\delta'(x)$ um estimador de $g(\theta) + b$, $a, b \in \mathbb{R}$, $a \neq 0$. (Se $a = 0$, temos o problema de estimar uma constante b , que não é mais um problema de estimacão).

Então podemos escrever $\delta'(x)$ como $\delta'(x) = a F(x) + b$ com $\delta'(x) = \frac{\delta(x) - b}{a}$.

Sob perda quadrática, o risco de $\delta'(x)$ é dado por:

$$R(g(\theta) + b, \delta') = E_\theta [(a g(\theta) + b) - (a \delta(x) + b)]^2 = a^2 R(g(\theta), \delta)$$

(A) Bayes

O estimador de Bayes minimiza o risco médio, que no caso é igual a $a^2 r(\cdot, \delta)$, que é minimizado quando $\delta = \delta^*(x)$

$$\text{Portanto: } \boxed{\delta'(x) = a \delta^*(x) + b}$$

(B) ENVVUM

$\delta'(x) = a \delta^*(x) + b$ é não viável para $g(\theta) + b$
mas $R(g(\theta) + b, \delta') = a^2 R(g(\theta), \delta)$ e como $R(g(\theta), \delta)$ é uniformemente mínima

quando $\delta = \delta^*$ $\Rightarrow \boxed{\delta'(x) = a \delta^*(x) + b}$

por hipótese

(C) Minimax

$$\text{Sabemos que } \inf_{\delta} \sup_{\theta} R(g(\theta), \delta) = \sup_{\theta} R(g(\theta), \delta^*)$$

$$\text{Mas } R(g(\theta) + b, \delta^*) = a^2 R(g(\theta), \delta)$$

$$\text{Portanto: } \inf_{\delta} \sup_{\theta} R(g(\theta) + b, \delta^*) = a^2 \sup_{\theta} R(g(\theta), \delta) = \sup_{\theta} R(g(\theta), \delta^*)$$

$$\text{Portanto: } \boxed{\delta'(x) = a \delta^*(x) + b}$$

(D) Admissível

$$\delta^*(x) \text{ é admissível para } g(\theta) \text{ se } R(g(\theta), \delta^*(x)) \leq R(g(\theta), \delta(x)) \forall \theta \in \Theta. \Leftrightarrow a^2 R(g(\theta), \delta^*(x)) \leq a^2 R(g(\theta), \delta(x))$$

$$\text{Assim, } \forall \theta \in \Theta, R(g(\theta) + b, a \delta^*(x) + b) \leq R(g(\theta) + b, a \delta(x) + b)$$

$$\text{Portanto, } a^2 R(g(\theta), \delta^*) \leq a^2 R(g(\theta), \delta)$$

$$\textcircled{9} \quad f(x_1 | \theta, \sigma^2) = N(\theta, \sigma^2), \quad x_1, \dots, x_n \text{ iid}$$

$$\tau = \frac{1}{\sigma^2}, \quad \tau \sim \text{Gamma}\left(\frac{1}{\sigma^2}, \frac{1}{\sigma^2}\right)$$

$\theta \sim \text{uniforme em } \mathbb{R}$ (independente)

$$\textcircled{10} \quad \pi(\theta, \tau) \propto \left(\frac{\tau}{\pi}\right)^{\frac{n}{2}} \exp\left\{-\tau \sum(x_i - \theta)^2\right\} \times \tau^{n-1} \exp\{-\alpha \tau\} \propto \tau^{\frac{n}{2}-1} \exp\left\{-\tau (\theta + \sum(x_i - \theta)^2)\right\}, \text{ levantando}$$

$$\text{que } \sum(x_i - \theta)^2 = \sum(x_i - \bar{x} + \bar{x} - \theta)^2 = \sum(x_i - \bar{x})^2 + n(\bar{x} - \theta)^2$$

$$\textcircled{11} \quad \int_{-\infty}^{+\infty} \text{conj. da} \propto \tau^{\frac{n}{2}-1} e^{-\tau} \tau^{n-1} e^{-\tau(\theta + \sum(x_i - \bar{x})^2)} \sim \text{Gamma}\left(\frac{n}{2} + r - \frac{1}{2}, \frac{1}{\alpha + \sum(x_i - \bar{x})^2}\right)$$

$$\textcircled{12} \quad \text{sob prud. qnt.} \quad \theta = \frac{1}{2\tau}, \quad \alpha = \frac{1}{2}, \quad \Rightarrow \tau \sim \text{Gamma}\left(r - \frac{1}{2}, \frac{1}{2}\right)$$

$$f = E\left(\frac{1}{2\tau} \mid x\right) = \int_0^\infty \frac{1}{2\tau} \cdot \frac{\tau^{\frac{n}{2}-\frac{1}{2}} \tau^{\frac{n}{2}-\frac{1}{2}}}{\Gamma(r-\frac{1}{2})} e^{-\tau} d\tau = \frac{1}{2} \cdot \frac{\Gamma(r-\frac{3}{2})}{\Gamma(r-\frac{1}{2})} \cdot \underbrace{\int_0^\infty \frac{\tau^{\frac{n}{2}-\frac{1}{2}} \tau^{\frac{n}{2}-\frac{1}{2}}}{\Gamma(r-\frac{3}{2})} e^{-\tau} d\tau}_{\text{Estimar } \frac{1}{2\tau} \text{ sob prud. } \left(\frac{d-1}{2\tau}\right)^2 \frac{1}{4\tau^2}}$$

$$= \frac{1}{2} \cdot \frac{\Gamma(r-\frac{3}{2})}{\Gamma(r-\frac{1}{2})} \cdot \underbrace{\int_0^\infty \frac{\tau^{\frac{n}{2}-\frac{1}{2}} \tau^{\frac{n}{2}-\frac{1}{2}}}{\Gamma(r-\frac{3}{2})} e^{-\tau} d\tau}_{\mathbb{E}(W(\theta)g(\theta) \mid x)} = \frac{1}{2} \cdot \frac{1}{\frac{n}{2}-\frac{3}{2}} = \frac{2}{n-3}$$

$$\text{Então } \frac{1}{2\tau} \text{ sob prud. } \left(\frac{d-1}{2\tau}\right)^2 \frac{1}{4\tau^2} = \frac{\mathbb{E}(W(\theta)g(\theta) \mid x)}{\mathbb{E}(z\tau) \mathbb{E}(z\tau)} = \frac{\mathbb{E}(z\tau) \mathbb{E}(x)}{\mathbb{E}(z\tau) \mathbb{E}(z\tau)} =$$

$$\overline{P(X_1 > \tau \mid \sum_{i=1}^n x_i)} \quad \text{Linha 4}$$

$$f(x_1 \mid \sum_{i=1}^n x_i) = \frac{f(x_1, \sum_{i=1}^n x_i)}{f(\sum_{i=1}^n x_i)} =$$

Gama(n, θ)

Cálculo de $f(x_1, \sum_{i=1}^n x_i)$

$$X = X_1 \sim \text{Exp}(\theta) \quad \rightarrow f(x_1, \theta) = \text{Exp}(\theta) \sim \text{Gamma}(n-1, \theta)$$

$$Y = \sum_{i=2}^n x_i \sim \text{Gamma}(n-1, \theta)$$

$$U = X_1 (-X_1) \quad \Rightarrow \begin{cases} X = U \\ Y = \theta - U \end{cases} \Rightarrow J = \begin{vmatrix} 1 & 0 \\ -1 & 1 \end{vmatrix} = 1$$

$$f(u, v) = f(x_1, \sum_{i=1}^n x_i) = \theta^{-\theta u} \frac{\theta^{n-1} (\theta - u)^{n-2}}{\Gamma(n-1)} e^{-\theta(\theta-u)}$$

Portanto:

$$f(x_1 \mid \sum_{i=1}^n x_i) = \frac{\theta^{-\theta x_1} \frac{\theta^{n-1} (\sum_{i=1}^n x_i)^{n-2}}{\Gamma(n-1)} e^{-\theta \sum_{i=1}^n x_i}}{\frac{\theta^{-\theta t} \frac{(n-1)!}{(t-1)!} \theta^t}{\Gamma(n)}} =$$

$$\frac{x_1^{n-2}}{t^{n-1}} = (n-1) \frac{(t-x_1)^{n-2}}{t^{n-1}}$$

$$(t) = P(X_1 > \tau \mid t) = \int_{\tau}^t (n-1) \frac{(t-x_1)^{n-2}}{t^{n-1}} dx_1 = \frac{1}{t^{n-1}} (t-x_1)^{n-1} \Big|_{\tau}^t = \frac{1}{t^{n-1}} (t-\tau)^{n-1}$$

$$\textcircled{12} \quad \int_0^\infty \text{conj. da} \propto (\alpha + \sum(x_i - \bar{x})^2)^{-\frac{g+1}{2}} \propto (\alpha + \sum(x_i - \bar{x})^2 + n(\theta - \bar{x})^2)^{-\frac{g+1}{2}} \propto (1 + K(\theta - \bar{x}))^{-\frac{g+1}{2}} \Rightarrow \text{mínimo da VM é quando } p/\bar{x}$$

$x_i \sim N(\theta, \sigma^2)$

$$E_\theta(f(x)) = a E_\theta(\bar{x}_n) + b E_\theta(s_n) = a\theta + bK\theta = \theta \Leftrightarrow \boxed{a+bK=1} \quad \textcircled{13}$$

$$\frac{(n-1)s_n^2}{\sigma^2} \sim \chi_{n-1}^2 \Rightarrow E_\theta(s_n) = K\sigma, \quad K = \dots$$

$$\text{Var}(a\bar{x}_n + b s_n) = a^2 \text{Var}(\bar{x}_n) + b^2 \text{Var}(s_n) = a^2 \frac{\sigma^2}{n} + b^2 \left(\frac{\sigma^2}{n} + K^2 \sigma^2\right) = b^2 \left[\frac{\sigma^2}{n} + (1+K^2)\right], \text{ que é mínimo quando } \frac{\sigma^2}{n} + (1+K^2) \text{ é mínimo}$$

$$\text{de } \textcircled{13} \quad a^2 = (1-bK)^2 = 1-2bK+b^2K^2$$

$$\text{Logo: } g(b) = \frac{1-2bK+b^2K^2}{n} + b^2(1+K^2) = \frac{[n+K^2(1+n)]b^2 - 2Kb + 1}{n}$$

$$\text{e quando } b = \frac{2K}{[n+K^2(1+n)]} \quad \text{e } a = 1 - \frac{K}{n+K^2(1+n)}$$

$$E(f(t)) = \int_0^\infty \frac{(t-\tau)^{n-1}}{\Gamma(n)} \cdot \frac{\theta^t t^{n-1}}{\Gamma(n)} e^{-\theta t} dt = \int_0^\infty \frac{u^{n-1} \theta^n}{\Gamma(n)} e^{-\theta(u+\tau)} du = e^{-\theta \tau}$$

$$\text{II}$$

$$= \frac{\frac{(n-1)!}{(n-1-n)!} \theta^n}{\frac{(n-1)!}{(n-n-n)!} \theta^n} = (n-n-n) f \cdot (n-n) f$$

$$T = \begin{vmatrix} 1 & 1 \\ 0 & 1 \end{vmatrix} = \{ \mathbb{F} \}$$

$$\begin{aligned} & \left. \begin{aligned} & n-a-b \\ & n-x \end{aligned} \right\} \left\{ \begin{aligned} & h+x=a \\ & x-h \end{aligned} \right\} \left\{ \begin{aligned} & h+x=a \\ & x-h \end{aligned} \right\} \left\{ \begin{aligned} & h+x=a \\ & x-h \end{aligned} \right\} \\ & \left. \begin{aligned} & \frac{(n-1)!}{(n-1-n)!} \\ & n! \end{aligned} \right\} = (n-n) f \quad \left. \begin{aligned} & \frac{(n-1)!}{(n-1-n)!} \\ & n! \end{aligned} \right\} = (n-n) f \end{aligned}$$

Alessandra, Giovana, Jayme

2º Questão

$$f(x|\theta) = \theta^x (1-\theta)^{1-x}, \quad x=0,1,2,\dots, \theta \in (0,1)$$

(A) Método dos Momentos.

$$\begin{aligned} E[X] &= \sum_{x=0}^{\infty} x P(X=x) = \sum_{x=1}^{\infty} x \theta^x (1-\theta)^{1-x} = \theta(1-\theta) \sum_{x=1}^{\infty} x \theta^{x-1} = \theta(1-\theta) \sum_{x=1}^{\infty} \frac{d}{d\theta} \theta^x \\ &= \theta(1-\theta) \frac{d}{d\theta} \sum_{x=1}^{\infty} \theta^x = \theta(1-\theta) \frac{d}{d\theta} \left(\frac{\theta}{1-\theta} \right) = \frac{\theta}{1-\theta} \end{aligned}$$

Portanto, com amarra de tamancos 1, X é estimador de θ pelo método dos momentos. Logo, o estimador de θ é dado por:

$$X = \frac{\theta}{1-\theta} \Rightarrow \hat{\theta} = \frac{X}{1+X}$$

$$(B) f(x|\theta) = \exp\{x \log \theta + \log(1-\theta)\}, \quad x=0,1,\dots, \theta \in (0,1)$$

Família exponencial unidimensional, com $T(x) = X$, $\eta(\theta) = \log \theta$ e $-B(\theta) = \log(1-\theta)$. No espaço paramétrico Θ podemos construir segmentos de reta $\Rightarrow X$ é completa e suficiente.

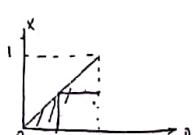
Siga $\delta(x)$ o estimador insuflado. $\forall \theta \in (0,1)$, utilizando o Método:

$$\sum_{x=0}^{\infty} \delta(x) \theta^x (1-\theta)^{1-x} = \theta \Leftrightarrow \sum_{x=0}^{\infty} \delta(x) \theta = \frac{\theta}{1-\theta} = \sum_{x=1}^{\infty} \theta^x = 0 \times \theta + \sum_{x=1}^{\infty} 1 \times \theta$$

2º Questão

$$f(x|\theta) = \frac{2x}{\theta^2}, \quad 0 < x < \theta < \theta > 0$$

$$\pi(\theta) = I_{(0,1)}(\theta)$$



$$(A) \pi(\theta|x) = \frac{f(x|\theta) \pi(\theta)}{f(x)} = \frac{\frac{2x}{\theta^2} \cdot I_{(0,1)}(\theta) I_{(0,\theta)}(x)}{\int_0^1 \frac{2\theta}{\theta^2} d\theta} = \frac{x}{\theta^2(1-x)} I_{[0,1]}(\theta)$$

$$\text{Mais } g(x) = \int_x^1 f(x|\theta) \pi(\theta) d\theta = \int_x^1 \frac{2\theta}{\theta^2} d\theta = 2x^{-1} \int_{\theta=1}^x = 2 - 2x - 2(1-x), \quad 0 < x < \theta$$

$$(B) L(\theta, d) = \theta^d [d - \theta]^2$$

$$\delta_\lambda(x) = \frac{\mathbb{E}[\theta^2 | X=x]}{\mathbb{E}[\theta^2 | X=x]} = \frac{\int_x^1 \theta \frac{x}{\theta^2(1-x)} d\theta}{\int_x^1 \frac{x}{\theta^2(1-x)} d\theta} = \frac{\frac{x}{1-x} \cdot \frac{1-x^2}{2}}{\frac{x}{1-x} \cdot (1-x)} \Rightarrow$$

$$\Rightarrow \boxed{\delta_\lambda(x) = \frac{1+x}{2}}$$

Portanto, o estimador ENNUM para θ é dado por:

$$\boxed{\delta(x) = I_{[0,1]}(x)} \quad \text{pois é uma variável e função da estatística suficiente, completa } T(x)=x.$$

$$(C) \pi(\theta) \sim U(0,1)$$

sub forma quadrática, o estimador $\delta_\lambda(x)$ é dado por:

$$\delta_\lambda(x) = \mathbb{E}[\theta | X=x] = \int_0^1 \theta \pi(\theta|x) d\theta$$

$$\text{Mas } \pi(\theta|x) \propto \theta^x (1-\theta)^{1-x} I_{(0,1)}(\theta)$$

$$\pi(\theta|x) = \frac{1}{B(x+1,2)} \theta^x (1-\theta)^{1-x} \Rightarrow \theta|x \sim \text{Beta}(x+1,2)$$

$$\text{Portanto: } \boxed{\delta_\lambda(x) = \frac{x+1}{x+3}}$$

6º Questão

(x_1, \dots, x_n) iid, $x_i \sim N(0, \sigma^2)$. Estimar σ^2 .

$$L = \left(\frac{1}{\sigma^2} \right) (d - \bar{x})^2 = L(\sigma^2, d)$$

$$(A) \theta = \frac{1}{2\sigma^2} \quad \text{e} \quad \pi(\theta) = \frac{1}{\Gamma(a) b^a} \theta^{a-1} \exp\{-\theta/b\}, \quad a>0, b>0$$

$$\text{Queremos estimar } \sigma^2 = \frac{1}{2\theta}$$

$$L(\theta, d) = 4\theta^2 \left(d - \frac{1}{2\theta} \right)^2 = w(\theta) (d - g(\theta))^2$$

$$\delta_\lambda(x) = \frac{\mathbb{E}\left[\frac{2\theta^2}{\theta^2} \mid X=x\right]}{\mathbb{E}[4\theta^2 \mid X=x]} = \frac{\mathbb{E}[\theta \mid X=x]}{\frac{1}{2} \mathbb{E}[\theta^2 \mid X=x]} = \frac{\mathbb{E}[\theta \mid X=x]}{2 \mathbb{E}[\theta^2 \mid X=x]}$$

$$f(x+\sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^n \exp\left\{ -\frac{x_i^2}{2\sigma^2} \right\} \Rightarrow \left(\sqrt{\frac{1}{\pi}} \right)^n \exp\left\{ -\theta \sum_{i=1}^n x_i^2 \right\} = f(x)$$

$$\pi(\theta|x) \propto f(x|\theta) \pi(\theta) \propto \theta^{a-1} \theta^{n/2} \exp\left\{ -\theta \left(\frac{1}{b} + \sum_{i=1}^n x_i^2 \right) \right\} =$$

$$= \theta^{\frac{n}{2}-a-1} \exp\left\{ -\theta \left(\frac{1}{b} + \sum_{i=1}^n x_i^2 \right) \right\},$$

que é o mdc de uma gamma (α, β) , sendo:

$$\alpha = \frac{n}{2} + a$$

$$\beta = \frac{1}{\frac{1}{b} + \sum_{i=1}^n x_i^2} = \frac{b}{1 + \frac{\sum_{i=1}^n x_i^2}{b}}$$

$$\text{Portanto: } f_\lambda(x) = \frac{\alpha\beta}{2(\alpha\beta + \alpha\beta)} = \frac{1}{2\beta(1+\alpha)}$$

$$f_\lambda(x) = \frac{1}{2 \frac{b}{1+b\sum x_i^2} (1+\frac{n}{2}+a)} = \frac{1+\frac{n}{2}\sum x_i^2}{2b(1+a+\frac{n}{2})} \quad (1)$$

$$(2) \quad f(x) = \frac{\sum x_i^2}{n+2}$$

$$L = \left(\frac{d}{v} - 1 \right)^2 \quad \text{e} \quad R = E_v[L(d, v)]$$

$$\text{Mas } \frac{d}{v^2} = \frac{v}{n+2} \quad ; \quad \text{onde } v \sim \chi_{n+2}^2$$

$$\text{Portanto: } R = E_v \left(\frac{v-n-2}{n+2} \right)^2 = \frac{1}{(n+2)^2} E_v(v^2 - 2(n+2)v + (n+2)^2)$$

$$R = \frac{1}{(n+2)^2} (v^2 - 2(n+2)v + (n+2)^2) = \frac{1}{(n+2)^2} ((n+2)^2 - n(n+2))$$

$$R = 1 - \frac{n}{n+2} \cdot \text{para } f(x) = \frac{\sum x_i^2}{n+2}$$

(*) Para $\delta^2 = C \sum_{i=1}^n x_i^2$, $C > 0$, calcular o risco formular.

$$R = E_v(Cv - 1)^2 = E_v(Cv^2 - 2Cv + 1) = C^2(v^2 - 2Cv + 1) \Rightarrow$$

$$\Rightarrow R = 1 + Cv [C(n+2) - 2] = 1 + \frac{C^2 n(n+2) - 2Cn}{\text{Polinômio em } C}$$

$$\text{O polinômio em } C \text{ atinge o mínimo em } C = \frac{zv}{z(n+2)}, \text{ valor}$$

$$\frac{v(n+2)}{(n+2)^2} - \frac{zn}{n+2} = -\frac{n}{n+2} \Rightarrow 0 \text{ risco } \epsilon, \text{ ou seja, igual a:}$$

$$R = 1 - \frac{n}{n+2}, \text{ que } \epsilon \text{ é o risco da estimadora anterior.}$$

(*) Finalmente, o ENR de δ^2 é $\delta^2 = \frac{\sum x_i^2}{n+2}$, cujo risco é dado por:

$$R = E_v \left(\frac{v}{n+2} - 1 \right)^2 = \frac{1}{n+2} E_v(v^2 - 2vn + n^2) = \frac{1}{n+2} (vn + \frac{v^2}{2} - 2vn + n^2)$$

$$R = \frac{2}{n+2} > \frac{2}{n+2} = \frac{n+2-n}{n+2} = 1 - \frac{n}{n+2} \text{ que } \epsilon \text{ é risco da}$$

$$\text{estimadora } \frac{\sum x_i^2}{n+2} \Rightarrow 0 \text{ ENR de } \delta^2 \text{ é inadmissível.}$$

∞

(*) Para usarmos o teorema, precisamos provar que para quase todo x , $\exists \delta_\lambda$ que minimiza $E \{ L(\theta, f(x)) | X=x \}$

Da solução da questão vimos que $\theta | X \sim \text{Gamma}(\alpha, \beta)$
Assim:

$$E \{ L(\theta, f(x)) | X=x \} = E \left\{ 4\theta^2 \left(d - \frac{1}{2\theta} \right)^2 | X=x \right\} =$$

$$= E \left\{ 4\theta^2 d^2 - 4\theta d + 1 | X=x \right\} = 4d^2 (\alpha\beta^2 + \alpha^2\beta^2) - 4\alpha\beta d + 1$$

$$\text{que é minimizada quando } d = \frac{4\alpha\beta}{4\alpha\beta^2 + \alpha^2\beta^2} = \frac{1}{2\beta(1+\alpha)} = \delta_\lambda$$

o cujo risco é igual a

$$\frac{\alpha\beta^2 + \alpha^2\beta^2}{4\beta^2(1+\alpha)^2} - 4\alpha\beta \frac{1}{2\beta(1+\alpha)} + 1 = \frac{\alpha(1+\alpha)}{(1+\alpha)^2} - \frac{2\alpha}{1+\alpha} + 1 =$$

$$= 1 - \frac{\alpha}{1+\alpha} \quad \text{que é finito, pois } \alpha = \alpha + \frac{1}{n}$$

c) Para a priori $\theta \sim \Gamma(a, b)$, obtivemos, em ①:

$$\hat{\delta}_\lambda = \frac{1}{2b(1+a+\frac{1}{\lambda})} + \frac{\sum_{i=1}^n x_i^2}{2(1+a+\frac{1}{\lambda})} = C_1 + C_2 \sum_{i=1}^n x_i^2$$

seu risco é dado por:

$$R = E_\theta \left(\left(\frac{C_1}{\theta^2} + C_2 v^2 - 1 \right)^2 \right), \quad v \sim X_n$$

$$\begin{aligned} R &= E_\theta \left(\left(\frac{C_1}{\theta^2} + C_2 v^2 + 1 + \frac{2C_1 C_2}{\theta^2} v - \frac{2C_1}{\theta^2} - 2C_2 v \right)^2 \right) = \\ &= \frac{C_1^2}{\theta^4} + C_2^2 (2n+1) + 1 + \frac{2C_1 C_2}{\theta^2} n - \frac{2C_1}{\theta^2} - 2C_2 n \end{aligned} \quad \textcircled{4}$$

Se formarmos uma seqüência de priors $\Gamma(\frac{1}{b}, b)$, $b > 0$ e fizermos $b \rightarrow \infty$, por exemplo, $b = k$, $k = 1, 2, 3, \dots$, e fizermos $k \rightarrow \infty$,

$$C_1 \xrightarrow{k \rightarrow \infty} 0 \quad \text{e} \quad C_2 \xrightarrow{k \rightarrow \infty} \frac{1}{2n+1}, \quad \text{de modo que de } \textcircled{4}$$

$$\begin{aligned} \lim_{k \rightarrow \infty} R_k &= 0 + \frac{1}{(2n+1)} (2n+1) + 1 + 0 - 0 - 2 \frac{1}{n+2} n \\ &= \frac{2}{n+2} = \text{Risco do estimador } \frac{\sum_{i=1}^n x_i^2}{n+2}. \end{aligned}$$

Concluindo o risco do estimador $\frac{\sum_{i=1}^n x_i^2}{n+2}$ independe do parâmetro,

ele é igual a $\sup_\theta R(\theta, \delta)$. Portanto, $\frac{\sum_{i=1}^n x_i^2}{n+2}$ é minimax e a sequência de priors exibida acima é muito favorável.

IIº Método

$$X \sim B(p, n)$$

$$\text{Estimar } p \text{ com função } L(d, p) = \frac{(d-p)^2}{p(1-p)}$$

Utilizando a suposição das Notas da Tela, vamos utilizar para p a priori $\pi(p) = I_{(0,1)}(p)$

$$\pi(p|x) \propto f(x|p) \pi(p) = C_n^p p^x (1-p)^{n-x}, \quad p \in (0,1) \Rightarrow p|x \sim \text{Beta}(x+1, n-x+1)$$

O estimador de Bayes é dado por:

$$\textcircled{5} \quad \delta_\lambda(x) = \frac{E\left[\frac{p}{p(1-p)} | X=x\right]}{E\left[\frac{1}{p(1-p)} | X=x\right]} = \frac{\int_0^1 \frac{x}{p} p^{x-1} (1-p)^{n-x} dp}{\int_0^1 \frac{1}{p} p^{x-1} (1-p)^{n-x} dp} = \frac{\beta(x+1, n-x)}{\beta(x, n-x)} =$$

$$= \frac{\frac{\Gamma(x+1)\Gamma(n-x)}{\Gamma(n+1)}}{\frac{\Gamma(x)\Gamma(n-x)}{\Gamma(n)}} = \frac{\frac{x!}{n!} \frac{\Gamma(n+1)}{\Gamma(x+1)}}{\frac{\Gamma(n)}{\Gamma(x)}} = \frac{x}{n} \quad \text{que é constante (independente de } p).$$

Portanto, a priori utilizada é a muito favorável e o estimador minimax é dado por $\frac{x}{n}$.

Para usarmos $\textcircled{5}$ é necessário encontrar que q.c para todo X , conseguimos encontrar de que minimizar:

$$E(L(d, p) | X=x) = \int \frac{(d-p)^2}{p(1-p)} \frac{1}{\Gamma(x+1) \Gamma(n-x)} \frac{x^{x-1} (1-p)^{n-x-1}}{\Gamma(x) \Gamma(n-x)} dp =$$

$$= \frac{\beta(x, n-x)}{\beta(x+1, n-x)} \int (d-p)^2 \frac{1}{p} \frac{x^{x-1} (1-p)^{n-x-1}}{\beta(x, n-x)} dp, \quad \text{que é}$$

$$\text{minimizada quando } d = E(p|x) = \frac{x}{n-x+x} = \frac{x}{n} = \delta(x).$$

Além disso, $\delta(x)$ possui risco finito, temos:

$$R(\theta, \delta) = E_p \left[\frac{(d-p)^2}{p(1-p)} \right] = \frac{1}{n^2 p(1-p)} E_p \left[\frac{X-np}{Var_p(X)} \right]^2 = \frac{n^2 p(1-p)}{n^2 p(1-p)} = \frac{1}{n}$$

que é finito.

Portanto, podemos usar o resultado $\textcircled{5}$.

12.9. Biestimador

X_1, \dots, X_n iid, $X_i \sim N(\mu_x, \sigma_x^2)$, $\mu_x \in \mathbb{R}, \sigma_x > 0$

Y_1, \dots, Y_n iid, $Y_i \sim N(\mu_y, \sigma_y^2)$, $\mu_y \in \mathbb{R}, \sigma_y > 0$

Estimador $\hat{\Delta} = \hat{\mu}_y - \hat{\mu}_x$ sob jarda quadrática.

- (A) Supondo σ_x^2 e σ_y^2 conhecidos, vamos utilizar a seguinte dada para as prioris de μ_x e μ_y . Vamos usar as mesmas formas para μ_x e μ_y , isto é, $N(0, b)$.

$$f(x, y | \mu_x, \mu_y) = \left(\frac{1}{\sqrt{2\pi\sigma_x^2}}\right)^n \left(\frac{1}{\sqrt{2\pi\sigma_y^2}}\right)^m \exp\left\{-\frac{\sum_{i=1}^n (x_i - \mu_x)^2}{2\sigma_x^2} - \frac{\sum_{j=1}^m (y_j - \mu_y)^2}{2\sigma_y^2}\right\}$$

E a estatística suficiente é $T = (\bar{x}, \bar{y})$.

- Usando a priori acima e considerando que sob jarda quadrática o estimador de Bayes de $\mu_y - \mu_x$ é a média a posterior, temos o seguinte estimador de Bayes:

$$\begin{aligned} \delta_\lambda &= E(\hat{\mu}_y - \hat{\mu}_x | \bar{x}, \bar{y}) = E(\hat{\mu}_y | \bar{x}, \bar{y}) - \\ &- E(\hat{\mu}_x | \bar{x}, \bar{y}) \stackrel{\text{def}}{=} E(\hat{\mu}_y | \bar{y}) - E(\hat{\mu}_x | \bar{y}) = \\ &= \frac{\bar{y}}{\frac{n}{\sigma_y^2}} - \frac{\bar{x}}{\frac{n}{\sigma_x^2}} \quad \text{e seu risco será dado por:} \end{aligned}$$

0

$$r_\lambda = \text{Var}(\hat{\mu}_y - \hat{\mu}_x | \bar{x}, \bar{y})$$

ou seja, é a variação da diferença.

Da independência entre \bar{x} e \bar{y} :

$$r_\lambda = \text{Var}(\hat{\mu}_y | \bar{y}) + \text{Var}(\hat{\mu}_x | \bar{x}) = \left(\frac{n}{\sigma_y^2} + \frac{1}{b}\right) + \left(\frac{n}{\sigma_x^2} + \frac{1}{b}\right)$$

Então, agora temos a seguinte de priori tais que $b \rightarrow \infty$.

Por exemplo, $b = k$, k é qualquer.

$$\text{Assim, } \lim_{b \rightarrow \infty} r_{\lambda,b} = \frac{\bar{y}^2}{n} + \frac{\bar{x}^2}{n}$$

$$\text{Mas } r = \sup_b r(\theta, \bar{y} - \bar{x}), \text{ pós } R(\theta, \bar{y} - \bar{x}) = \text{Var}_\theta(\bar{y} - \bar{x}) =$$

$$= \frac{\bar{y}^2}{n} + \frac{\bar{x}^2}{n}, \text{ independente de } \theta = (\mu_x, \mu_y).$$

Pertanto, $\bar{y} - \bar{x}$ é minimax e a sequência de prioris acima construída

c

- (B) Se σ_x^2 e σ_y^2 são desconhecidos, suas limitações superiores para μ_x e μ_y , entre $\bar{y} - \bar{x}$ formam o estimador minimax de $\mu_y - \mu_x$.

Para provarmos, basta considerarmos:

$$\Omega = \{(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2) \mid \mu_x \in \mathbb{R}, \mu_y \in \mathbb{R}, 0 < \sigma_x^2 < M_x, 0 < \sigma_y^2 < M_y\}$$

$$\Omega_0 = \{(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2) \mid \mu_x \in \mathbb{R}, \mu_y \in \mathbb{R}, \sigma_x^2 = M_x, \sigma_y^2 = M_y\}$$

$$\Omega_0 \subset \Omega$$

Em Ω_0 , o estimador minimax de $\mu_y - \mu_x$ é $\bar{y} - \bar{x} - \delta$,

$$\sup_{(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2) \in \Omega_0} (\theta, \bar{y} - \bar{x}) = \frac{\mu_y}{n} - \frac{\mu_x}{n} = \sup_{(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2) \in \Omega} (\theta, \bar{y} - \bar{x})$$

Portanto, demonstrado em sala, $\bar{y} - \bar{x}$ é minimax em Ω .

Exercícios

145 Punto

(a) Estimador de Bayes (ENVN, minimizar, admissível) de $g(\theta)$
 seja $\hat{\delta}(\cdot)$ um estimador de $a\hat{g}(\cdot) + b$, $a, b \in \mathbb{R}$, $a \neq 0$. (se $a=0$, temos o problema de estimar uma constante b , que não é mais um problema de estimacão).

Então temos, seccor $\hat{\delta}'(\cdot)$ com $\hat{\delta}'(\cdot) = a\hat{g}'(\cdot) + b$ com
 $\hat{\delta}'(\cdot) = \frac{\hat{\delta}(\cdot) - b}{a}$.

Sob tais condições, o risco de $\hat{\delta}(\cdot)$ é dado por:

$$R(a\hat{g}(\cdot) + b, \hat{\delta}') = E_{\theta} [(a\hat{g}(\cdot) + b) - (a\hat{g}'(\cdot) + b)]^2 = a^2 R(\hat{g}(\cdot), \hat{\delta}')$$

(1) Basta

O estimador de Bayes minimiza o risco médio, que nesse caso é igual a $a^2 R(\cdot, \hat{\delta}')$, que é minimizado quando $\hat{\delta} = \hat{\delta}^*(\cdot)$.

Portanto: $\hat{\delta}'(\cdot) = a\hat{\delta}^*(\cdot) + b$

(2) ENVN

$\hat{\delta}(\cdot) = a\hat{\delta}^*(\cdot) + b$ é não viável, pois, por hipótese, $E_{\theta}(\hat{\delta}(\cdot)) = g(\cdot)$.
 e $R(a\hat{g}(\cdot) + b, \hat{\delta}') = a^2 R(\cdot, \hat{\delta}')$ (com $R(\cdot, \hat{\delta}')$ é uniformemente mínimo quando $\hat{\delta} = \hat{\delta}^*$) $\Rightarrow \hat{\delta}(\cdot) = a\hat{\delta}^*(\cdot) + b$

(C) Minimar

$$\text{sabemos que } \inf_{\delta} \sup_{\theta} R(g(\theta), \delta) = \sup_{\theta} R(g(\theta), \delta^*)$$

$$\text{Mas } R(a\hat{g}(\cdot) + b, \delta') = a^2 R(\hat{g}(\cdot), \delta')$$

$$\text{Portanto: } \inf_{\delta} \sup_{\theta} R(a\hat{g}(\cdot) + b, \delta') = a^2 \sup_{\theta} R(\hat{g}(\cdot), \delta) = a^2 \sup_{\theta} R(g(\cdot), \delta^*)$$

$$\text{Portanto: } \hat{\delta}'(\cdot) = a\hat{\delta}^*(\cdot) + b$$

(D) Admissível

$$\hat{\delta}^*(\cdot) \text{ é admissível para } g(\cdot) \text{ se } R(g(\cdot), \hat{\delta}^*(\cdot)) \leq R(g(\cdot), \delta(\cdot)) \forall \theta \in \Theta. \Leftrightarrow a^2 R(\hat{g}(\cdot), \hat{\delta}^*(\cdot)) \leq a^2 R(\hat{g}(\cdot), \delta(\cdot))$$

$$\text{Assim, } \forall \theta \in \Theta, R(a\hat{g}(\cdot) + b, a\hat{\delta}^*(\cdot) + b) \leq R(a\hat{g}(\cdot) + b, a\hat{\delta}(\cdot) + b)$$

porque $a^2 R(\hat{g}(\cdot), \hat{\delta}^*) \leq a^2 R(\hat{g}(\cdot), \delta)$

$$(c) \text{ Para a prim } Q \sim P(a, b), \text{ obtemos, em A:}$$

$$\hat{d}_n = \frac{1}{2b(1+\frac{n}{2})} + \frac{\sum_{i=1}^n X_i^2}{2(1+a+\frac{n}{2})} = C_1 + C_2 \sum_{i=1}^n X_i^2$$

sua risca é dada por:

$$R = E_Q \left(\frac{C_1}{Q^2} + C_2 V^{-1} \right), \quad V \sim X_n^2$$

$$R = E_Q \left(\frac{C_1^2}{Q^4} + C_2^2 V^{-2} + 1 + \frac{2C_1 C_2}{Q^2} V - \frac{2C_1}{Q^2} - 2C_2 V \right) = \\ = \frac{C_1^2}{Q^4} + C_2^2 (2n+1) + 1 + \frac{2C_1 C_2}{Q^2} n - \frac{2C_1}{Q^2} - 2C_2 n \quad (4)$$

Se formarmos uma seqüência de primis $P(\frac{1}{b}, b)$, $b > 0$ e fizermos $b \rightarrow \infty$, por exemplo, $b = k$, $k = 1, 2, 3, \dots$, e fizermos $k \rightarrow \infty$,

$C_1 \xrightarrow{k \rightarrow \infty} 0$ e $C_2 \xrightarrow{k \rightarrow \infty} \frac{1}{2n+1}$, de modo que da (4)

$$\lim_{k \rightarrow \infty} R_k = 0 + \frac{1}{(2n+1)^2} + 1 + 0 - 0 - 2 \frac{1}{n+2} n$$

$$= \frac{2}{n+2} = \text{Risco do estimador } \frac{\sum_{i=1}^n X_i^2}{n+2}$$

Com o risco do estimador $\frac{\sum_{i=1}^n X_i^2}{n+2}$ independente dos parâmetros

ele é igual a $\sup_{\theta} R(0, \delta)$. Portanto, $\frac{\sum_{i=1}^n X_i^2}{n+2}$ é minimizar e

a seqüência de primis exibida acima é uma favorável.

$$\text{dada } f = a\bar{X}_n + bS_n, \quad a + b\frac{\sqrt{2}\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} = 1$$

$$\frac{S_n^2}{\theta^2} \sim \chi_{n-1}^2$$

$$\begin{aligned} \text{Var}(f) &= a^2 \text{Var}(\bar{X}_n) + b^2 \text{Var}(S_n) = a^2 \frac{\theta^2}{n} + b^2 [E S_n^2 - (E S_n)^2] = \\ &= a^2 \frac{\theta^2}{n} + b^2 \left[(n-1)\theta^2 - \left(\frac{\sqrt{2}\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} \theta \right)^2 \right] = \\ &= a^2 \frac{\theta^2}{n} + b^2 (n-1)\theta^2 - 2b^2 \left(\frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} \theta \right)^2 \end{aligned}$$

$$a = 1 - b\sqrt{2} \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})}$$

$$\left(1 - b\sqrt{2} \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} \right)^2 \frac{1}{n^2} + b^2 (n-1) - 2b^2 \left(\frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} \theta \right)^2 = 0$$

$$\frac{2}{n^2} \left(1 - b\sqrt{2} \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} \right) \sqrt{2} \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} + 2b(n-1) - 2b \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} = 0$$

$$\frac{\sqrt{2}}{n^2} \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} = \frac{b\sqrt{2}}{n^2} \cdot \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} \sqrt{2} \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} + b(n-1) - 2b \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} =$$

$$b \left[\frac{2}{n^2} \left(\frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} \right)^2 + n-1 - 2 \frac{\Gamma(n/2)}{\Gamma(\frac{n+1}{2})} \right]$$

OPTIMALIDADE DO RISCO MÉDIO

- $\lambda(\theta, \delta)$: função de perda
- $L(\theta, \delta)$ mede as consequências (perda, custo) de se estimar θ pelo valor $\delta = \delta(z)$: alternativa de $g(\theta)$ obtida da amostra $z \in \mathbb{R}^k$
- A grande média, segundo a distribuição de X^z
- dado pelo valor de θ :
- $R(\theta, \delta) = E_\theta \{ L(\theta, \delta(X)) \}, \theta \in \mathbb{R}$
- é chamado de risco do estimador δ
- $R(\theta, \delta) = \int L(\theta, \delta(x)) dP_\theta(x)$
- Estimador de Bayes: gerador e estimador que tem risco médio mínimo. O risco médio é obtido usando uma função de perda em (θ) .
- Risco médio: $r(\Delta, \delta) = \int R(\theta, \delta) d\Delta(\theta)$
- Vamos assumir que Δ é uma distribuição de probabilidade e que, portanto, $\int d\Delta(\theta) = 1$.
- $R(\Delta, \delta)$ é o risco de Bayes, depende do estimador δ e da distribuição de probabilidade Δ , não depende de θ . Um estimador δ^* que minimiza o risco de Bayes é chamado de estimador (ideia) de Bayes com respeito a Δ .

IDEIA:

EXPERIÊNCIA PREVIA	Dados	EXPERIÊNCIA ATUALIZADA
• Aprende (antes de obter dados) $X=z$	$X=z$ é observado	• Aprende (após obter dados) $X=z_1, z_2, \dots, z_n$
• (1) tem distribuição $f(x \theta)$: função de probabilidade Δ com domínio	$f(x \theta)$: função de verossimilhança	• distribuição $f(x \theta)$ condicional com domínio
• $\Pi(\theta)$ que pode depender de outros parâmetros (hiperparâmetros)	$\Pi(\theta z) = \frac{f(z \theta)}{f(z)}$	• $\Pi(\theta z_1, z_2, \dots, z_n) = \Pi(\theta z)$
• Tudo o que se conhece sobre θ , após $X=z$, tem sido ignorado na distribuição a posteriori	$q(z) = \int f(z \theta) d\theta$	• Tudo o que se conhece sobre θ , após $X=z$, tem sido ignorado na distribuição a posteriori

$$\begin{aligned} \text{Base } S \text{ tem que o risco a posteriori} \\ E \{ L(\theta, \delta(X)) | X=z \} \text{ seja mínimo} \\ r(\Delta, \delta) = E_\theta \{ R(\theta, \delta) \} = \int_\theta R(\theta, \delta) \Pi(\theta) d\theta = \text{Teorema Fubini} \\ = \int_\theta \int_S L(\theta, \delta(x)) \cdot f(x|\theta) dx \Pi(\theta) d\theta = \\ = \int_S \int_\theta L(\theta, \delta(x)) \cdot \frac{f(x|\theta)}{q(z)} d\theta \cdot q(z) dx = \\ = \int_S \int_\theta L(\theta, \delta(x)) \cdot \Pi(\theta|x) d\theta \cdot q(z) dx = \end{aligned}$$

- $= \int_S E_\theta \{ L(\theta, \delta(x)) | X=z \} q(z) dx$
- $r(\Delta, \delta)$ é minimizado minimizando o integrando
- $E_\theta \{ L(\theta, \delta(x)) | X=z \}$ para cada x . O estimador que minimiza $E_\theta \{ L(\theta, \delta(x)) | X=z \}$ é um estimador de Bayes.
- mas a posteriori é uma distribuição Δ , dado S , entendo: supondo que (1) tem uma distribuição P_θ . Supõe que $\Pi(\theta)$, supondo que X tem distribuição P_θ . Supõe que $\Pi(\theta)$, supondo que θ é um risco de perda $L(\theta, \delta)$, não negativo
- supõe que $\Pi(\theta)$ com função de perda $L(\theta, \delta)$, não negativa
- estima θ um estimador δ com risco finito
- a) para qualquer todo x (i.e. visto para
- b) para qualquer todo x (i.e. visto para

19/10/2010

Exercício 4

I. Seja X uma única observação de uma distribuição geométrica com função de probabilidade

$$f(x|\theta) = \theta^x (1-\theta), \quad x=0,1,\dots, \theta \in (0,1)$$

a) Encontre o estimador de método dos momentos de θ .

i) Momento amostral: $\hat{\mu}_1 = \frac{1}{n} \sum X_i = \bar{X}$

1

ii) Momento populacional: $\mu_1 = E(X) = \frac{1}{1-\theta}$

\Rightarrow

Pelo método dos momentos, tem-se que:

$$\frac{\hat{\mu}_1 - \mu_1}{\sigma_{\mu_1}} \rightarrow \frac{\bar{X} - \frac{1}{1-\theta}}{\sqrt{\frac{1}{(1-\theta)^2}}} \rightarrow \theta = \frac{1}{\bar{X} + 1} \quad \boxed{\hat{\theta} = \frac{1}{\bar{X} + 1}}$$

b) Existe estimador não viável de θ ? Né sim, encontre o ENNVM de θ .

A distribuição pertence à família exponencial de gama completa, pois

$f(x|\theta) = \exp[-\eta \log(\theta + \log(1-\theta))]$, $\eta = \log(\theta)$, a função constante em seu domínio retangular.

$\lambda = 1$ dimensione, portanto, a estatística $T = X$ é estatística suficiente e completa para $g(\theta)$.

Assim, pelo método 1, $E(g(t)) = \theta \Rightarrow \sum_{t=0}^{\infty} g(t) \cdot \theta^t (1-\theta) = \theta \Rightarrow$

$$\Rightarrow \sum_{t=0}^{\infty} g(t) \cdot \theta^t = \frac{\theta}{1-\theta} \rightarrow \sum_{t=0}^{\infty} E(t) \cdot \theta^t = \sum_{t=0}^{\infty} \theta^t = 0 \cdot \theta^0 + \sum_{t=1}^{\infty} t \cdot \theta^t$$

$$\left\{ \begin{array}{l} g(t) = 0 \quad \text{se } t=0 \\ g(t) = t \quad \text{se } t > 1 \end{array} \right. \Rightarrow \left\{ \begin{array}{l} E(t) = 1 \quad \text{se } t=1 \\ E(t) = 0 \quad \text{se } t > 1 \end{array} \right. \quad \text{função de estatística suficiente e} \quad \text{estatística } T(X) = X$$

$\therefore g(t) = t$ ENNUM para θ

$\therefore g(t) = t$ ENNUM para θ

* Cálculo do valor esperado:

$$E(X) = \sum_{x=0}^{+\infty} x \cdot \theta^x (1-\theta) = (1-\theta) \cdot \sum_{x=1}^{+\infty} x \cdot \theta^x$$

$$\therefore E(X) = (1-\theta) \cdot \sum_{x=1}^{+\infty} x \cdot \theta^{x-1} = (1-\theta) \cdot \sum_{x=1}^{+\infty} x \cdot \theta^x \cdot \frac{d}{d\theta} \theta^{-1} = (1-\theta) \cdot \frac{d}{d\theta} \sum_{x=1}^{+\infty} \theta^x =$$

$$E(X) = (1-\theta) \cdot \frac{d}{d\theta} \left(\frac{\theta}{1-\theta} \right) = \frac{\theta}{1-\theta}$$

$$E(X) = 1$$

$$\therefore \frac{E(X)}{\theta} = \frac{(1-\theta) \cdot 1}{\theta} = \frac{1}{\theta} - 1$$

$$\boxed{E(X) = \frac{\theta}{1-\theta}}$$

13

1 / 1

c) Considere uma distribuição a priori $U(0,1)$ para θ . Encontre o estimador de Bayes de θ sob risco quadrático

$$\theta \sim U(0,1) \Rightarrow \pi(\theta) = 1, \quad 0 < \theta < 1$$

$$f(x|\theta) = \theta^x (1-\theta), \quad x=0,1,\dots, \theta$$

$$\pi(\theta|x) \propto f(x|\theta) \cdot \pi(\theta) = \theta^x (1-\theta), \quad 0 < \theta < 1$$

$$\int_0^1 c \cdot \theta^x (1-\theta) d\theta = 1$$

$$c \int_0^1 \theta^x (1-\theta) d\theta = 1$$

$$= c \int_0^1 \theta^x - \theta^{x+1} d\theta = 1$$

$$c \left[\int_0^1 \theta^x d\theta - \int_0^1 \theta^{x+1} d\theta \right] = 1$$

$$c \left[\frac{\theta^{x+1}}{x+1} \Big|_0^1 - \frac{\theta^{x+2}}{x+2} \Big|_0^1 \right] = 1$$

$$c \left[\frac{1}{x+1} - \frac{1}{x+2} \right] = 1$$

$$c \left[\frac{x+2-x-1}{(x+1)(x+2)} \right] = 1$$

$$c = (x+1)(x+2)$$

Como a estimadora é sob risco quadrático, $w(\theta)=1$, então tem-se:

$$\delta_n(X) = E \left[g(\theta) | X=x \right] = E \left[\theta | X=x \right] = \int_0^1 \theta (x+1)(x+2) \theta^x (1-\theta) d\theta =$$

$$= (x+1)(x+2) \int_0^1 \theta^{x+1} (1-\theta) d\theta = (x+1)(x+2) \int_0^1 \theta^{x+2} - \theta^{x+3} d\theta =$$

$$= (x+1)(x+2) \left[\theta^{x+3} \Big|_0^1 - \theta^{x+4} \Big|_0^1 \right] = (x+1)(x+2) \left[\frac{1}{x+4} - \frac{1}{x+3} \right] = \frac{x+1}{x+3}$$

$$\boxed{\delta_n(X) = \frac{x+1}{x+3}}$$

$f(x|\theta)$

20/10/2010

2. seja X uma única observação de uma variável aleatória com densidade de $f(x|\theta) = 2x$, $0 < x < \theta$; $\theta > 0$. Considere, para θ uma distribuição uniforme no intervalo unitário.

a) Determina a função densidade de probabilidade a posteriori de θ .

b) Encontra o estimador de Bayes com respeito à priori $\theta^2(d-\theta)^2$.

a) $\theta \sim U(0,1)$ $\Pi(\theta) = 1$ $T(\theta) = I(\theta < 1)$

$$L(\theta|x) = \theta^2(d-\theta)^2$$

$$\begin{aligned} f(x|\theta) &= 2x \quad T(x) \\ 0 < x < \theta & \theta^2 \quad \text{if } x < \theta \\ \Pi(\theta|x) &= \frac{f(x|\theta) \cdot \Pi(\theta)}{\int_0^{+\infty} f(x|\theta) \cdot \Pi(\theta) dx} = \frac{2x \cdot \theta^2}{\int_0^{+\infty} 2x \cdot \theta^2 dx} = \frac{x}{\int_0^{+\infty} x \cdot \theta^2 dx} = \frac{x}{\frac{1}{3}\theta^3} = \frac{3x}{\theta^3} \end{aligned}$$

$$\begin{aligned} \int_0^{+\infty} f(x|\theta) \cdot \Pi(\theta) d\theta &= \int_0^{+\infty} 2x \cdot \theta^2 \cdot \frac{3x}{\theta^3} d\theta = 6x^2 \int_0^{+\infty} \frac{1}{\theta} d\theta = 6x^2 \cdot \left[-\frac{1}{\theta} \right]_0^{+\infty} = 6x^2 \cdot 1 = 6x^2 \\ &= 2x \int_x^{+\infty} \theta^{-2} d\theta = 2x \cdot \left[-\theta^{-1} \right]_x^{+\infty} = 2x \cdot \left[-\frac{1}{\theta} \right]_x^{+\infty} = 2x \left(\frac{1}{x} + 1 \right) = 2 + 2x \end{aligned}$$

b) $S_n(x) = E[w(\theta) \cdot g(\theta) | X=x]$
 $E[w(\theta) | X=x]$

$$E[w(\theta) \cdot g(\theta) | X=x] = E[\theta^2 \theta | X=x] = E[\theta^3 | X=x] =$$

$$w(\theta) = \theta^2$$

$$g(\theta) = \theta$$

$$\begin{aligned} &= \int_x^1 \theta^3 \cdot \frac{1}{2 + 2x} d\theta = \frac{1}{2 + 2x} \int_x^1 \theta^3 d\theta = \frac{x}{2 + 2x} \left[\frac{\theta^4}{4} \right]_x^1 = \\ &= \frac{x}{2 + 2x} \left[\frac{1 - x^4}{4} \right] = \frac{x}{2 + 2x} \frac{(1+x)(1-x)(1+x^2)}{2} = \frac{x(1+x)}{2 + 2x} \\ E[w(\theta) | X=x] &= E[\theta^2 | X=x] = \int_x^1 \theta^2 \cdot \frac{1}{2 + 2x} d\theta = \frac{x}{2 + 2x} \left[\frac{\theta^3}{3} \right]_x^1 = \frac{x(1-x^2)}{3(2+2x)} \end{aligned}$$

11

$$S_n(x) = E[w(\theta) \cdot g(\theta) | X=x] = \frac{\frac{x(1+x)}{2 + 2x}}{\frac{x}{2 + 2x}} = \frac{x(1+x)}{2}$$

$$S_n(x) = \frac{x+1}{2}$$

$$h_k(p) = (k-4p)^2 = k^2 - 8kp + 16p^2$$

11

$$\lambda(\theta, d) = w(\theta) \cdot [d - g(\theta)]^2$$

$$\begin{aligned} E[w(\theta) \cdot [g(x) - g(\theta)]^2 | X=x] &= E[w(\theta) \cdot [g^2(x) - 2g(x)g(\theta) + g^2(\theta)] | X=x] \\ &= E[w(\theta)g^2(x) - 2E[w(\theta)g(\theta)|X=x]g^2(\theta) | X=x] \\ &= g^2(x) \cdot E[w(\theta) | X=x] - 2g(x)E[w(\theta) \cdot g(\theta) | X=x] + E[w(\theta)g^2(\theta)] \end{aligned}$$

minimizando $g(x)$ temos que:

$$2g(x) \cdot E[w(\theta) | X=x] - 2E[w(\theta) \cdot g(\theta) | X=x] = 0$$

$$\hat{s}_n(x) = \frac{E[w(\theta) \cdot g(\theta) | X=x]}{E[w(\theta) | X=x]}$$

Estimador Minimax

o estimador de Bayes minimiza o risco médio: $r(\Delta, \delta) = \int R(\theta, \delta) \cdot d\Delta(\theta)$

\neq

o estimador minimax vai minimizar o risco máximo

Um estimador δ^M de θ que minimiza o risco máximo

$$\inf_{\delta} \sup_{\theta} R(\theta, \delta) = \sup_{\theta} R(\theta, \delta^M) \text{ é o estimador minimax}$$

Binomial

$X \sim b(p, n)$ grande quantidade
pode Beta(a, b)

Estimador de Bayes: $\hat{s}_{\Delta}(x) = a+n$

δ^{T_1} : est. de Bayes com priori Beta($1, 3$) $E(p) = \frac{1}{4}$

$$E(p) = \frac{a}{a+b}$$

δ^{T_2} : est. de Bayes com priori Beta($2, 2$) $E(p) = \frac{1}{2}$

δ^{T_3} : est. de Bayes com priori Beta($3, 1$) $E(p) = \frac{3}{4}$

$$R(p, s_n) = E_p \left[\frac{(a+x - p)^2}{a+b+n} \right] = Var_p \left[\frac{a+x}{a+b+n} \right] + E_p \left[\frac{a+x - p}{a+b+n} \right]^2$$

$$\begin{aligned} &= \frac{1}{(a+b+n)^2} Var_p(X) + \left[\frac{a + E_p(X) - p}{a+b+n} \right]^2 = \frac{1}{(a+b+n)^2} n \cdot p \cdot (1-p) + \left[\frac{a+n-p}{a+b+n} \right]^2 \\ &\quad \therefore \frac{1}{(a+b+n)^2} [np(1-p) + (n-(a+b)p)^2] \end{aligned}$$

$$h_1(p) = (1-4p)^2$$

$$h_1'(p) = 2(1-4p) \cdot -4 = -8(1-4p) = 0$$

$$1-4p=0 \Rightarrow p=\frac{1}{4}$$

$$h_1''(p) = -8 \cdot (-4) = 32 > 0$$

$$h_2(p) = (2-4p)^2$$

$$h_2'(p) = 2(2-4p) \cdot -4 = 0 \Rightarrow p=\frac{1}{2}$$

$$h_2''(p) = 2 \cdot (-4 \cdot (-4)) = 32 > 0$$

Três parabolas

crescente

decrescente

$$h_3(p) = (3-4p)^2$$

$$h_3'(p) = 2(3-4p) \cdot -4 = 0 \Rightarrow p=\frac{3}{4}$$

$$h_3''(p) = 2 \cdot (-4 \cdot (-4)) = 32 > 0$$

$$p=0 \quad h_1 = (1-4 \cdot 0)^2 = 1 \quad \text{em } p=1 \quad h_1 = (1-4 \cdot 1)^2 = 9 \quad \text{maior risco mínimo}$$

$$h_2 = (2-4 \cdot 0)^2 = 4 \quad h_2 = (2-4 \cdot 1)^2 = 4$$

$$h_3 = (3-4 \cdot 0)^2 = 9 \quad \text{(maior risco, menor risco)}$$

2. No intervalo de Δ a \perp , $h(\Delta)$ contém o menor

risco máximo dado quando $p=0$ ou $p=1$,

$$1-R(p, \delta^{T_2}) = 1/4$$

$$-1 + 1/4 = 1/4$$

$$1/4 > 1/9$$

3. Sejam X e y variáveis aleatórias independentes com distribuições $P_{\eta|g}$ e Q_{η} respectivamente. Suponha que $\tilde{g} \in \mathcal{G}$ são consideradas variáveis aleatórias independentes, reais, com distribuições Δ e Δ' , respectivamente. Se, com grande probabilidade, \hat{s}_{Δ} é o estimador de Bayes de \tilde{g} com base em X e $\hat{s}_{\Delta'}$ é o estimador de Bayes de η com base em y .

a) Mostre que $\hat{s}_{\Delta} - \hat{s}_{\Delta'}$ é o estimador de Bayes de $\eta - \tilde{g}$ com base em (X, y) .

$$X \perp\!\!\!\perp y \Rightarrow f_{\tilde{g}|y}(z, y) = f_{\tilde{g}}(z) f_y(y)$$

$$\tilde{g} \perp\!\!\!\perp \eta \Rightarrow f_{\tilde{g}|\eta}(g) = f_{\tilde{g}}(g) f_{\eta}(\eta)$$

Sob grande probabilidade, \hat{s}_{Δ} é estimador de Bayes de \tilde{g} com base em X

$\hat{s}_{\Delta'}$ é estimador de Bayes de η com base em y

$$\text{Então: } w(\theta) = 1 \text{ e } g_{\theta}(\theta) = \eta \quad \text{e} \quad g_{\theta'}(\theta) = \tilde{g}$$

$$\hat{s}_{\Delta}(x) = E(\tilde{g} | X=x)$$

$$\hat{s}_{\Delta'}(y) = E(\tilde{g} | Y=y)$$

Sob grande probabilidade, tem-se que: $w(\theta) = 1$ e $g(\tilde{g}, \eta) = \eta - \tilde{g}$, então:

$$\begin{aligned} \hat{s}_{\Delta}(x, y) &= E[\eta - \tilde{g} | (X, y) = (x, y)] = \iint_{\mathcal{G} \times \mathcal{Y}} (\eta - \tilde{g}) \cdot \pi(\eta, \tilde{g} | (X, y) = (x, y)) d\eta d\tilde{g} = \\ &= \iint_{\mathcal{G} \times \mathcal{Y}} \eta \cdot \pi(\eta, \tilde{g} | (X, y) = (x, y)) d\eta d\tilde{g} - \iint_{\mathcal{G} \times \mathcal{Y}} \tilde{g} \cdot \pi(\eta, \tilde{g} | (X, y) = (x, y)) d\eta d\tilde{g} = \\ &\stackrel{\text{Fazendo}}{=} \iint_{\mathcal{G} \times \mathcal{Y}} \eta \cdot \pi(\tilde{g} | X=x, \pi(\eta | y=y)) d\eta d\tilde{g} - \iint_{\mathcal{G} \times \mathcal{Y}} \tilde{g} \cdot \pi(\tilde{g} | X=x, \pi(\eta | y=y)) d\eta d\tilde{g} = \\ &\stackrel{\text{Fazendo}}{=} \iint_{\mathcal{G} \times \mathcal{Y}} \eta \cdot \pi(\tilde{g} | X=x) \pi(\eta | y=y) d\eta d\tilde{g} - \iint_{\mathcal{G} \times \mathcal{Y}} \tilde{g} \cdot \pi(\tilde{g} | X=x) \pi(\eta | y=y) d\eta d\tilde{g} = \\ &= \iint_{\mathcal{G}} \eta \cdot \pi(\eta | y=y) \left[\int_{\mathcal{G}} \pi(\tilde{g} | X=x) d\tilde{g} \right] d\eta - \iint_{\mathcal{G}} \tilde{g} \cdot \pi(\tilde{g} | X=x) \int_{\mathcal{G}} \pi(\eta | y=y) d\eta d\tilde{g} = \\ &= \int_{\mathcal{G}} \eta \cdot \pi(\eta | y=y) d\eta - \int_{\mathcal{G}} \tilde{g} \cdot \pi(\tilde{g} | X=x) d\tilde{g} = \\ &= E(\eta | y=y) - E(\tilde{g} | X=x) = \hat{s}_{\Delta}(x) - \hat{s}_{\Delta'}(y) = \hat{s}_{\Delta} - \hat{s}_{\Delta'} \end{aligned}$$

b) Seja $\eta > 0$ e \hat{s}_{Δ}^* o estimador de Bayes de \tilde{g} com base em y , mentre que $\hat{s}_{\Delta}, \hat{s}_{\Delta}'$, é o estimador de Bayes de \tilde{g} com η base em (X, y) .

Sob grande probabilidade, temos que $w(\theta) = 1$ e $g(\tilde{g}, \eta) = \frac{\tilde{g}}{\eta}$, então:

$$\hat{s}_{\Delta}^*(x, y) = E\left[\frac{\tilde{g}}{\eta} | (X, y) = (x, y)\right] = E\left[\frac{\tilde{g}}{\eta} | (X, y) = (x, y)\right] \stackrel{\tilde{g} \perp\!\!\!\perp \eta}{=} \frac{\tilde{g}}{\eta} \Rightarrow \hat{s}_{\Delta}^* = \frac{\hat{s}_{\Delta}}{\eta}$$

Propriedade: $E(XY) = E(X)E(Y)$

$$= E\left[\frac{\tilde{g}}{\eta} | X=x\right] - E\left[\frac{1}{\eta} | Y=y\right] = \hat{s}_{\Delta} - \hat{s}_{\Delta}'$$

4. Seja X uma variável aleatória representando o tempo de vida de um sistema elétrico, com função distribuição acumulada $F_\theta(x)$, $\theta \in \mathbb{R}$. Defina a confiabilidade do sistema, por:

$$R_\theta(t) = P_\theta(X > t) = 1 - F_\theta(t), t \geq 0.$$

Considere n observações independentes X_1, \dots, X_n de X . Admita que, dado θ , X tem distribuição exponencial de parâmetro θ e função densidade de probabilidade: $f(x; \theta) = \theta \cdot \exp(-\theta x)$, $x > 0$, $\theta > 0$.

a) Mostre que, nesse caso, $R_\theta(t) = \exp\{-t/\theta\}$

$$\begin{aligned} R_\theta(t) &= P_\theta(X > t) = 1 - F_\theta(t) = 1 - \int_0^t \theta \cdot e^{-\theta x} dx = \\ &= 1 - \theta \int_0^t e^{-\theta x} dx = 1 - \theta \cdot e^{-\theta x} \Big|_{0}^t = 1 - [e^{-\theta t} + e^{0 \cdot 0}] = 1 - e^{-\theta t} = e^{\theta t} \end{aligned}$$

$$\alpha = t/\theta$$

$$\begin{aligned} dx &= t/\theta \, d\alpha \quad \int e^{-\theta x} dx = \int e^{-t/\theta \alpha} d\alpha = -\frac{e^{-t/\theta \alpha}}{\theta} = -e^{-t/\theta} \\ d\alpha &= d\alpha \end{aligned}$$

$$R_\theta(t) = \exp\{-t/\theta\} \quad t > 0, \theta > 0$$

b) Encontre o estimador de máxima verossimilhança de $R_\theta(t)$

$$f(x; \theta) = \theta^n e^{-\sum x_i \theta} \cdot I(x > 0), I(\theta > 0)$$

$$f(x; \theta) = \exp\{-\sum x_i \theta + n \log \theta\}$$

$$I(x; \theta) = -\sum x_i \theta + n \log \theta$$

$$\frac{dI(x; \theta)}{d\theta} = -\sum x_i + n = 0 \Rightarrow -\theta \sum x_i = -n \Rightarrow \theta = n / \sum x_i = n / \bar{x}$$

$$\frac{d^2 I(x; \theta)}{d\theta^2} = -n < 0 \text{ (ponto mínimo)}$$

$$\theta = \bar{x}$$

Pela função da Inversão das EMV, tem-se que

$$R_\theta(t) = e^{-\bar{x} t / n}$$

\Rightarrow ENNUM de $R_\theta(t)$. Note que: $f(x; \theta) = \theta^n e^{-\theta \sum x_i} = \exp\{-\theta \sum x_i + n \log \theta\}$ é pertence à família exponencial uniparamétrica, e domínio da função $y = \theta$ rotângulo $\theta > 0$ dimensionado e, portanto, a família é de ponto completo ($T = \sum x_i$ é uma estatística suficiente e completa para θ).

Usando o método 2 de condicionamento para estimar θ : $g(\theta) = e^{-T\theta}$, temos que:

$$1 \quad x \quad X > t$$

$$0 \quad c.c.$$

$$(X) = 1 \cdot P(X > t) = e^{-T\theta}; \text{ o estimador } \hat{\theta}(X) \text{ é ENV para } g(\theta)$$

$$\star P(X > t | \sum x_i) = f(x_1 | \sum x_i) = f(x_1 | \sum \hat{x}_i) = \frac{f(\sum x_i)}{f(\sum \hat{x}_i)}$$

$$(X_1, \sum x_i)$$

$$\begin{aligned} X &\sim \exp(\theta) \quad X \sim \text{Gamma}(n-1, \theta) \\ f(x_1, y) &= \theta e^{-\theta x_1} \theta^{n-1} \frac{(n-1)!}{(y-1)!} e^{-\theta y} \\ Y &\sim \text{Gamma}(n-1, \theta) \end{aligned}$$

$$\begin{aligned} x_1 &= X \Rightarrow X = U \quad J = \begin{vmatrix} \frac{dx}{du} & \frac{du}{dv} \\ \frac{\partial}{\partial u} & \frac{\partial}{\partial v} \end{vmatrix} = 1 \\ \sum x_i &= \sum x_i \Rightarrow Y = V - X = V - u \end{aligned}$$

$$f(u, v) = f(Y | \sum x_i) = \theta \cdot e^{-\theta u} \theta^{n-1} \cdot (v-u)^{n-2} e^{-(v-u)\theta}$$

$$\frac{1}{r(n-1)} \cdot \frac{(\sum x_i)^{n-2}}{(\sum x_i)^{n-1}} \cdot e^{-\theta (\sum x_i)} = r(n-1) \left(\frac{\sum x_i}{r(n-1)} \right)^{n-2}$$

$$\frac{1}{r(n-1)} \cdot \frac{(\sum x_i)^{n-2}}{r(n-1) \cdot (\sum x_i)^{n-1}} = \frac{(n-1) r(n-1)}{r(n-1)} \cdot \left(\frac{\sum x_i}{r(n-1)} \right)^{n-2} =$$

$$\frac{1}{r(n-1)} \cdot \frac{(\sum x_i)^{n-2}}{n(n-1)} = \frac{1}{n(n-1)} \cdot \left(\frac{\sum x_i}{r(n-1)} \right)^{n-2} =$$

$$\frac{1}{n(n-1)} \cdot \frac{\sum x_i^{n-2}}{t^{n-2}} = \frac{1}{n(n-1)} \cdot \frac{\int_{t-x_i}^t (t-u)^{n-2} du}{t^{n-2}} = \frac{1}{n(n-1)} \cdot \frac{\int_{t-x_i}^t (t-u)^{n-2} du}{t^{n-2}} =$$

$$E(\hat{\theta}(X) | t) = P(X > t | t) = \int_{x_i=t}^{\infty} (n-1) \cdot \frac{(t-x_i)^{n-2}}{t^{n-2}} dx_i = (n-1) \int_{x_i=t}^{\infty} \frac{(t-x_i)^{n-2}}{t^{n-2}} dx_i =$$

$$\frac{1}{t^{n-1}} \cdot \frac{(t-x_i)^{n-1}}{t} = \frac{1}{t^{n-1}} \cdot \frac{(t-t)^{n-1}}{t} = \frac{1}{t^{n-1}} \cdot \frac{0^{n-1}}{t} = 0$$

$$\frac{1}{t^{n-1}} \cdot \frac{\theta^n \cdot t^{n-1} \cdot e^{-\theta t}}{r(n-1)} = \int_0^\infty \frac{\theta^n \cdot u^{n-1} \cdot e^{-\theta(u-t)}}{r(n-1)} du = e^{-\theta t}$$

$$\text{Gamma } \frac{1}{r(\alpha) T^\alpha} x^{\alpha-1} e^{-\frac{x}{T}} \cdot I_{(0,+\infty)}^{(x)}$$

$$E(X) = \alpha T$$

1 / 1

d) Mostre que o estimador de Bayes de $P_\theta(t)$ sob perda quadrática é função constante a menor preço θ

$$\Pi(\theta) = \frac{1}{T^\alpha r(\alpha)} \theta^{\alpha-1} \exp(-\theta/T), \theta > 0$$

índice por:

$$\left(\sum_{i=1}^n \frac{x_i + 1}{T} \right)^{-(n+r)}$$

$$\Pi(\theta) = \frac{1}{T^\alpha r(\alpha)} \theta^{\alpha-1} e^{-\frac{\theta}{T}}, \theta > 0$$

$$f(x|\theta) = \theta^n e^{-\theta \sum x_i}, x_i \geq 0, \theta > 0$$

A distribuição a posteriori é proporcional a:

$$\Pi(\theta|x) \propto f(x|\theta) \cdot \Pi(\theta) = \theta^n e^{-\theta \sum x_i} \cdot \frac{1}{T^\alpha r(\alpha)} \theta^{\alpha-1} e^{-\frac{\theta}{T}} \propto$$

$$\propto \theta^{n+r-1} e^{-\theta \sum x_i - \frac{\theta}{T}} = \theta^{n+r-1} e^{-\theta \left[\frac{\sum x_i + T}{T} \right]} =$$

$$= \theta^{n+r-1} e^{-\theta \left[\frac{n+r+1}{T} \right]} = \theta^{n+r-1} e^{-\frac{\theta(n+r+1)}{T}}$$

$$\Pi(\theta|x) \sim \text{Gamma} \left(n+r, \frac{T}{n+r+1} \right)$$

Sob perda quadrática temos que $(w(\theta)=1)$, então o preço do bala é estimado de Bayes para $P_\theta(t) = e^{-\theta t}$, de acordo:

$$\hat{\theta}_B(z) = E[\hat{\theta}(z)|X=z] = E[e^{-\theta z}|X=z] =$$

$$= \int_0^\infty \frac{e^{-\theta z}}{T(n+r)} \left[\frac{1}{T} \right]^{n+r} \theta^{n+r-1} e^{-\frac{\theta}{T} \left[\frac{z}{n+r+1} \right]} d\theta =$$

$$= \int_{T(n+r)}^\infty \frac{1}{T(n+r)} \left[\frac{1}{T} \right]^{n+r} \theta^{n+r-1} e^{-\theta \left[\frac{z}{n+r+1} \right] - \frac{\theta}{T}} d\theta =$$

$$= \int_{T(n+r)}^\infty \frac{1}{T(n+r)} \left[\frac{1}{T} \right]^{n+r} \theta^{n+r-1} e^{-\theta \left[\frac{z}{n+r+1} + \frac{1}{T} \right]} d\theta =$$

$$\frac{1}{\frac{T}{T(n+r)}} = \frac{T(n+r)}{T} = \frac{T(n+r+1)}{T(n+r+2)}$$

$$\frac{T(n+r+1)}{T(n+r+2)}$$

10

$$\int_0^\infty \frac{1}{T(n+r)} \left[\frac{1}{T} \right]^{n+r} \theta^{n+r-1} e^{-\theta \left[\frac{z}{n+r+1} + \frac{1}{T} \right]} d\theta =$$

$$\int_0^\infty \frac{1}{T(n+r)} \left[\frac{1}{T} \right]^{n+r} \theta^{n+r-1} e^{-\theta \left(\frac{T(n+r+1)}{T(n+r+2)} + \frac{1}{T} \right)} d\theta =$$

$$\int_0^\infty \frac{1}{T(n+r)} \left[\frac{1}{T} \right]^{n+r} \theta^{n+r-1} e^{-\theta \left(\frac{T(n+r+1)+T}{T(n+r+2)} \right)} d\theta =$$

$$\frac{1}{T(n+r)} \left[\frac{1}{T} \right]^{n+r} \theta^{n+r-1} e^{-\theta \left(\frac{T(n+r+1)+T}{T(n+r+2)} \right)} =$$

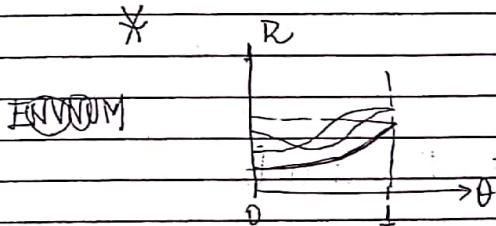
$$= \frac{T(n+r+1+T)}{T(n+r+1)} \left[\frac{1}{T} \right]^{n+r} = \frac{T(n+r+1+T)}{T(n+r+1) T(n+r+2)} \left[\frac{1}{T} \right]^{n+r} =$$

$$= \left[1 + \frac{T}{T(n+r+1)} \right]^{-(n+r)} = \left[1 + \frac{T}{T(n+r+1+T)} \right]^{-(n+r)} =$$

$$\delta(x) = \left[1 + \frac{T}{T(n+r+1+T)} \right]^{-(n+r)}$$

11

$$R = \int L(d, \theta) \cdot f(x|\theta) dx = R(\theta, d)$$



$$E_{\theta}(R(\theta, d)) = \int K(\theta, d) \pi(\theta) d\theta =$$

$$\pi(\theta) \rightarrow \text{Beta}(1, z)$$

$$g(x) =$$

$$E_{\theta}(R(\theta, d)) = \int \left[\int L(d, \theta) f(x|\theta) dx \right] \pi(\theta) d\theta$$

$$\int \left[\int L(d, \theta) \pi(\theta) d\theta \right] f(x|\theta) dx$$

$$(x|\theta) \cdot \pi(\theta) = f(x, \theta) \times \frac{\pi(x)}{\pi(x)} = \frac{f(x, \theta)}{\pi(x)} \cdot \pi(x) =$$

$$= \int f(x, \theta) d\theta = (\pi(\theta|x), g(x))$$

(*)

$$(4) g(x) dx \quad E_{\theta} = \int (w(\theta) \cdot (d - g(\theta))^2 \pi(\theta|x) d\theta =$$

$$(3) g(x) dx = \int (w(\theta) \cdot d^2 - 2w(\theta)g(\theta) + w(\theta)g^2(\theta)) \pi(\theta|x) d\theta$$

$$(2) (L(d, \theta) | X=x) \quad \int (w(\theta) \cdot d^2 - 2w(\theta)g(\theta) + w(\theta)g^2(\theta)) \pi(\theta|x) d\theta$$

$$= w(\theta) \cdot (d - g(\theta))^2$$

$$= E(w(\theta) \cdot g(\theta) | X=x) - \frac{d}{w}$$

$$= E(w(\theta) | X=x)$$

$$\delta_1 \quad \delta_2 \quad \delta_3 \longrightarrow S = \bar{x}$$

$$\begin{matrix} | & | & | \\ \downarrow & \downarrow & \downarrow \\ \lambda_1 & \lambda_2 & \lambda_3 \end{matrix}$$

$$b^2 \rightarrow 0$$

$$\theta \sim N(\mu, \sigma^2)$$

$$\textcircled{1} \quad \theta \sim N(\mu_1, 1) \rightarrow \delta_1$$

$$\textcircled{2} \quad \theta \sim N(\mu_2, 2) \rightarrow \delta_2$$

$$\textcircled{3} \quad \theta \sim N(\mu_3, 3) \rightarrow \delta_3$$

1 1

) Punkte Max

) -1

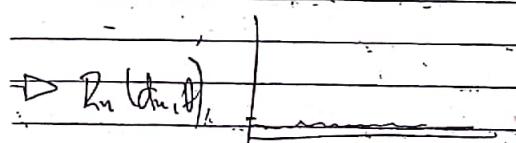
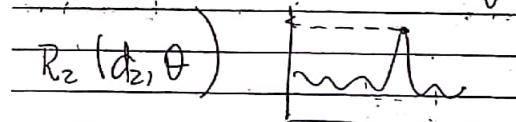
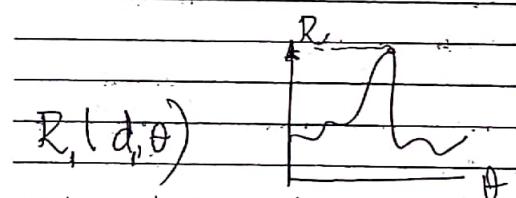
) -3 Minimiza

) -10 Punkte Max

) -0,5

) -3

P



$$\left\{ \begin{array}{l} E\left(\frac{S_n}{r_n}\right) = E\left[\left(\frac{\bar{X}_n}{r_n}\right)^{\frac{n}{2}}\right] = \frac{r\left[\left(\frac{n+r}{2}\right)\right]}{r\left(\frac{n}{2}\right)} 2^{\frac{n}{2}} \text{ para } n > n \\ \text{p.79} \\ \text{método de} \\ \text{aula} \end{array} \right.$$

21/30 bo10

5. seja $X = (X_1, \dots, X_n)$ um amostra aleatória de uma distribuição $N(\theta, \theta^2)$, $\theta > 0$. Considere a ^{meia} parte da estimadora de θ :

$$\Delta = \left\{ S(X) = a\bar{X}_n + bS_n, -\infty < a < +\infty, -\infty < b < +\infty \right\},$$

onde $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ e $S_n^2 = \sum_{i=1}^{n-1} (X_i - \bar{X})^2$

Encontre restrições para a, b de tal forma que o estimador em Δ seja não viável para θ . Denote a classe dos estimadores resultantes por Δ^* . Obtenha o estimador $\delta^* \in \Delta^*$ que tem variação uniformemente mínima. Este estimador coincide com \bar{X}_n ?

$$f(x|\theta) = \frac{1}{(2\pi\theta)^n} \exp\left[-\frac{1}{2\theta^2} \sum_{i=1}^n (x_i - \theta)^2\right]$$

Encontre restrições para a, b de modo que o estimador em Δ seja não viável para θ , ou seja:

$$\begin{aligned} E_\theta(\Delta) &= \theta \\ E_\theta(S(X)) &= \theta \\ E_\theta(a\bar{X}_n + bS_n) &= \theta \end{aligned}$$

$$\begin{aligned} E_\theta(a\bar{X}_n) + E_\theta(bS_n) &= \theta \\ aE_\theta(\bar{X}_n) + bE_\theta(S_n) &= \theta \\ a \cdot \frac{1}{\sqrt{n}} + b\sqrt{n}r\left(\frac{n-1}{2}\right) &= \theta \end{aligned}$$

$S_n^2 = \sum_{i=1}^{n-1} (X_i - \bar{X}_n)^2$

$$E\left(\frac{(S_n^2)^{\frac{1}{2}}}{\theta^2}\right) = \frac{\sqrt{2}r\left(\frac{n-1+1}{2}\right)}{r\left(\frac{n-1}{2}\right)} = \frac{\sqrt{2}r\left(\frac{n}{2}\right)}{r\left(\frac{n-1}{2}\right)}$$

$$\Delta^* = \left\{ S^*(X) = a\bar{X}_n + bS_n, a + b\sqrt{2}r\left(\frac{n}{2}\right) - 1, \begin{array}{l} -\infty < a < +\infty \\ -\infty < b < +\infty \end{array} \right\}$$

$$\begin{aligned} \text{Var}(\Delta^*) &= \text{Var}(S^*(X)) = \text{Var}(a\bar{X}_n + bS_n) \stackrel{\text{independentes}}{=} \text{Var}(a\bar{X}_n) + \text{Var}(bS_n) = \\ &= a^2 \text{Var}(\bar{X}_n) + b^2 \text{Var}(S_n) = a^2 \cdot \theta^2 + b^2 \left[E(S_n^2) - E(S_n) \right] = \\ &= \frac{a^2\theta^2}{n} + b^2 \left[\theta^2 + \left[\frac{\sqrt{2}r\left(\frac{n}{2}\right)}{r\left(\frac{n-1}{2}\right)} \right]^2 \right] \end{aligned}$$

$$\text{Condição: } a+b\frac{\sqrt{2}r\left(\frac{n}{2}\right)}{r\left(\frac{n-1}{2}\right)} = 1$$

$$2020 \quad a+b-c=1, c=\sqrt{2} \frac{r\left(\frac{n}{2}\right)}{r\left(\frac{n-1}{2}\right)}$$

$$a^2 + b^2 - b^2 2 \cdot \theta^2 \left[r\left(\frac{n}{2}\right) \right]^2 =$$

$$\frac{a^2 + b^2}{n} \left[1 - \frac{2\left[r\left(\frac{n}{2}\right)\right]^2}{\left[r\left(\frac{n-1}{2}\right)\right]^2} \right] \theta^2 = \frac{a^2 + b^2[1-c^2]}{n} \theta^2, \text{ onde } c = \sqrt{2} \frac{r\left(\frac{n}{2}\right)}{r\left(\frac{n-1}{2}\right)}$$

$$(a^2) = \left[\frac{a^2 + b^2 - b^2c^2}{n} \right] \theta^2 \quad \text{mas } a+b-c=1 \Rightarrow bc=1-a$$

$$(a^2) = \left[\frac{a^2 + b^2(1-c^2)}{n} \right] \theta^2 \quad \text{que é mínimo quando } a^2 + b^2(1-c^2) \text{ é}$$

a(b)

$$n \rightarrow \infty \text{ que } a+b-c=1 \Rightarrow a=1-bc \Rightarrow a^2 = (1-bc)^2 = 1-2bc+b^2c^2$$

$$q(b) = \frac{1-2bc+b^2c^2}{n} + b^2(1-c^2) = 1-2bc+b^2c^2 + \frac{b^2}{n} + \frac{b^2c^2}{n} =$$

$$2(1-n)b^2 - 2bc + 1$$

n

$$\text{mínimo para quando: } \begin{array}{|c|c|} \hline b & a = 1 - c^2 \\ \hline n+c^2(1-n) & n+c^2(1-n) \\ \hline \end{array}$$

$$I = a\bar{X}_n + bS_n = \left[1 - c^2 \right] \bar{X}_n + \frac{c}{n+c^2(1-n)} S_n =$$

$$\frac{c^2}{n+c^2(1-n)} \bar{X}_n + \frac{c}{n+c^2(1-n)} S_n \neq \bar{X}_n$$

6. Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes e identicamente distribuídas segundo uma distribuição $N(0, \sigma^2)$. Considere o problema de estimar σ^2 com a função de perda $L(\sigma^2, d) = \left(\frac{d-1}{\sigma^2}\right)^2 = \frac{(d-\sigma^2)^2}{\sigma^4}$

a) Considere uma distribuição a priori Gamma (a, b) para $\theta = \frac{1}{\sigma^2}$ com densidade:

$$\pi(\theta) = \frac{1}{\Gamma(a)} \frac{\theta^{a-1}}{b^a} \exp\left\{-\frac{\theta}{b}\right\}; \quad a > 0, b > 0.$$

Encontre o estimador de Bayes de σ^2 :

$$Y_i \sim N(0, \sigma^2) \quad f(z_i | \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(z_i - 0)^2}{2\sigma^2}\right\}$$

$$f(z | \sigma^2) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left\{-\frac{\sum z_i^2}{2\sigma^2}\right\} = \exp\left\{-\frac{\sum z_i^2}{2\sigma^2} - n \log \frac{1}{\sqrt{2\pi\sigma^2}}\right\}$$

$$\text{Como } \theta = \frac{1}{\sigma^2} \Rightarrow \sigma^2 = \frac{1}{\theta} \quad \text{e} \quad \frac{1}{\sigma^2} = \frac{1}{2\theta}.$$

$$f(z | \theta) = \exp\left\{-\frac{\theta \sum z_i^2 - n \log \frac{1}{\theta}}{2\theta}\right\}$$

$$\pi(\theta | X) \propto f(z | \theta) \cdot \pi(\theta) =$$

$$= \exp\left\{-\frac{\theta \sum z_i^2 - n \log \frac{1}{\theta}}{2\theta}\right\} \cdot \frac{1}{\Gamma(a)} \frac{\theta^{a-1}}{b^a} \exp\left\{-\frac{\theta}{b}\right\} \propto$$

$$\propto \theta^{a-1} \left(\frac{\theta}{b}\right)^{\frac{n}{2}} \exp\left\{-\frac{\theta \sum z_i^2 + \theta}{b}\right\} \propto \theta^{a+\frac{n}{2}-1} \exp\left\{-\theta\left(\sum z_i^2 + \frac{1}{b}\right)\right\}$$

$$\propto \theta^{(a+\frac{n}{2})-1} \exp\left\{-\frac{\theta}{b\sum z_i^2 + \frac{1}{b}}\right\}$$

$$\theta | X \sim \text{Gamma}\left(a + \frac{n}{2}, \frac{1}{b\sum z_i^2 + \frac{1}{b}}\right)$$

$$\text{Como } \theta = \frac{1}{\sigma^2} \text{, então } \sigma^2 = \frac{1}{\theta} \text{, e } \text{estimador de Bayes}$$

$$\text{é desejado. Mas, agora } g(\theta) = \frac{1}{\theta} \text{... fiquei maluco, tentei assim:}$$

$$L(\sigma^2, d) = \frac{(d-\sigma^2)^2}{\sigma^4}, \text{ então } w(\sigma^2) = \frac{1}{\sigma^4}, \text{ com } \sigma^2 = \frac{1}{2\theta} \text{ visto}$$

$$w(\theta) = 4\theta^2, \text{ ótimo visto.}$$

$$L(\sigma^2, d) = \frac{1}{\sigma^4} (d - \sigma^2)^2 \Rightarrow \sigma^2 = \frac{d}{2\theta}$$

$$L(\theta, d) = 4\theta^2 \left(\frac{d}{2\theta} - 1\right)^2$$

Deste modo, o estimador de Bayes para função $g(\theta) = \frac{1}{\theta}$ visto

$$E(\theta | X) = E\left[w(\theta) g(\theta) | X=x\right] = \frac{E[w(\theta)] g(\theta)}{E[w(\theta) | X=x]} = E[2(\theta) | X=x] = E[4\theta^2 | X=x]$$

$$\begin{aligned} E[2(\theta) | X=x] &= \int_0^{+\infty} 2\theta \cdot \frac{1}{\Gamma(a+\frac{n}{2})} \frac{\theta^{a+\frac{n}{2}-1}}{(b\sum z_i^2 + \frac{1}{b})^{\frac{a+n}{2}}} e^{-\frac{\theta}{b\sum z_i^2 + \frac{1}{b}}} d\theta = \\ &= 2 \cdot \frac{1}{\Gamma(a+\frac{n}{2})} \frac{1}{(b\sum z_i^2 + \frac{1}{b})^{\frac{a+n}{2}}} \theta^{\frac{a+n+1}{2}-1} e^{-\frac{\theta}{b\sum z_i^2 + \frac{1}{b}}} \\ &\quad \cancel{\Gamma(a+\frac{n}{2}) \left(\frac{b}{b\sum z_i^2 + \frac{1}{b}}\right)^{\frac{a+n}{2}}} \cdot \cancel{\left(\frac{b}{b\sum z_i^2 + \frac{1}{b}}\right)^{\frac{a+n+1}{2}}} \\ &= 2 \cdot \frac{\left(a+\frac{n}{2}\right)_n}{\Gamma(\frac{a+n}{2})} \cdot \frac{1}{\sum b z_i^2 + \frac{1}{b}} \underbrace{\Gamma\left(\frac{a+n+1}{2}\right)}_{\text{f.d.p de Gamma}} \left(\frac{a+\frac{n}{2}+1}{2}, \frac{b}{b\sum z_i^2 + \frac{1}{b}}\right) \end{aligned}$$

$$\begin{aligned} E[4\theta^2 | X=x] &= \int_0^{+\infty} 4\theta^2 \cdot \frac{1}{\Gamma(a+\frac{n}{2})} \frac{\theta^{a+\frac{n}{2}-1}}{(b\sum z_i^2 + \frac{1}{b})^{\frac{a+n}{2}}} e^{-\frac{\theta}{b\sum z_i^2 + \frac{1}{b}}} d\theta = \\ &= 4 \cdot \frac{1}{\Gamma(a+\frac{n}{2})} \frac{1}{(b\sum z_i^2 + \frac{1}{b})^{\frac{a+n}{2}}} \theta^{\frac{a+n+2}{2}-1} e^{-\frac{\theta}{b\sum z_i^2 + \frac{1}{b}}} \\ &\quad \cancel{\Gamma(a+\frac{n}{2}) \left(\frac{b}{b\sum z_i^2 + \frac{1}{b}}\right)^{\frac{a+n}{2}}} \cdot \cancel{\left(\frac{b}{b\sum z_i^2 + \frac{1}{b}}\right)^{\frac{a+n+2}{2}}} \\ &= 4 \cdot \frac{\left(a+\frac{n}{2}+1\right)_n}{\Gamma(\frac{a+n}{2})} \cdot \frac{1}{\sum b z_i^2 + \frac{1}{b}} \underbrace{\Gamma\left(\frac{a+n+2}{2}\right)}_{\text{f.d.p de Gamma}} \left(\frac{a+\frac{n}{2}+2}{2}, \frac{b}{b\sum z_i^2 + \frac{1}{b}}\right) \end{aligned}$$

$$\begin{aligned}
 & 4. \frac{1}{r(a+n)} \cdot \frac{(a+n+1)}{2} \cdot r \left(\frac{a+n+1}{2} \right) = 4. \frac{1}{r(a+n)} \cdot \frac{(a+n+1)}{2} \cdot \frac{r(a+n)}{2} \cdot \frac{(b\sum x_i^2 + 1)}{b} \\
 & = 4 \cdot \frac{(a+n+1)}{2} \cdot \frac{(a+n)}{2} \cdot \frac{b^2}{b\sum x_i^2 + 1} \\
 & S(X) = E(2\theta^2 | X=x) = \frac{\theta(a+n)}{2} \left(\frac{b}{b\sum x_i^2 + 1} \right)^2 \\
 & E(4\theta^2 | X=x) = \theta^2 \left(\frac{a+n+1}{2} \right) \left(\frac{a+n}{2} \right) \left(\frac{b}{b\sum x_i^2 + 1} \right)^2 \Rightarrow \\
 & S(X) = \frac{b\sum x_i^2 + 1}{2b(a+n+1)}
 \end{aligned}$$

Outro modo:

$$L(\theta, d) = 4\theta \left(\frac{d-1}{2\theta} \right)^2 = w(\theta) \cdot (d-g(\theta))^2$$

$$\begin{aligned}
 S_n(X) &= \frac{E[4\theta \cdot \frac{1}{\theta} | X=x]}{E[4\theta | X=x]} = \frac{E[\theta | X=x]}{E[\theta^2 | X=x]} = \\
 &= \frac{E[\theta | X=x]}{2E[\theta^2 | X=x]} \quad \text{mo } \theta \sim \text{Gamma} \left(\frac{n}{2} + a; \frac{b}{b\sum x_i^2 + 1} \right)
 \end{aligned}$$

Então, $X \sim \text{Gamma}(\alpha, \beta)$

$$E(X) = \alpha\beta$$

$$\text{Var}(X) = \alpha\beta^2$$

$$E[\theta | X=x] = \alpha\beta$$

$$2E[\theta^2 | X=x] = [E[\theta | X=x]]^2 = \frac{1}{2(\alpha\beta + \alpha^2\beta^2)} = \frac{1}{2\beta(1+\alpha)}$$

Então

$$S_n(X) = \frac{1}{b\sum x_i^2 + \frac{1}{2}}$$

$$S_n(X) = \frac{b\sum x_i^2 + 1}{2b\left(\frac{a+n+1}{2}\right)^2}$$

22/10/2010

b) Mostre que $S(X) = \sum_{i=1}^n \frac{x_i^2}{(n+2)}$ tem variação uniformemente

menor ou igual a zero de todos os estimadores da forma $c \sum_{i=1}^n x_i^2$.
Mostre que o estimador de momênto é variantilmente inadmissível

$$L(\theta, d) = 4\theta^2 \left(\frac{d-1}{2\theta} \right)^2$$

$$L(\theta, S(X)) = 4\theta^2 \left(\frac{\sum x_i^2 - 1}{2\theta} \right)^2$$

$$E(\theta, S(X)) = E(L(\theta, S(X))) = E \left(4\theta^2 \left(\frac{\sum x_i^2 - 1}{2\theta} \right)^2 \right) =$$

$$= 4\theta^2 E \left(\left(\frac{\sum x_i^2 - 1}{n+2} \right)^2 \right) = 4\theta^2 \underbrace{\left[\text{Var}_{\theta} \left(\frac{\sum x_i^2}{n+2} \right) + \left[E \left(\frac{\sum x_i^2}{n+2} \right) \right]^2 \right]}_{\text{variação}} =$$

$$= 4\theta^2 \left[\frac{1}{(n+2)^2} \text{Var}_{\theta} (\sum x_i^2) + \left[\frac{1}{n+2} E(\sum x_i^2) - \frac{1}{2} \right]^2 \right] =$$

$$= 4\theta^2 \left[\frac{1}{(n+2)^2} n \text{Var}(x_i^2) + \left[\frac{1}{n+2} n E(x_i^2) - 1 \right]^2 \right] \quad (*)$$

$X \sim N(0, \sigma^2)$

$$E[X^2] = \text{Var}X + (EX)^2 = \sigma^2 + 0^2 = \sigma^2 = 1$$

$$\text{Var}[X]^2 = EX^4 - [EX^2]^2$$

$$M_0(t) = e^{\frac{\sigma^2 t^2}{2}}$$

$$M_0'(t) = e^{\frac{\sigma^2 t^2}{2}} + \sigma^2 t$$

$$M_0''(t) = e^{\frac{\sigma^2 t^2}{2}} (E[X^2])^2 + e^{\frac{\sigma^2 t^2}{2}} \sigma^2$$

$$M_0'''(t) = e^{\frac{\sigma^2 t^2}{2}} (t^2)^3 + e^{\frac{\sigma^2 t^2}{2}} \cdot 2t\sigma^2 + e^{\frac{\sigma^2 t^2}{2}} \cdot \sigma^2 t\sigma^2$$

22/10/2010

$$M_{W^{(1)}}(t) = e^{\frac{t\sigma^2}{2}} \cdot (t\sigma^2)^4 + e^{\frac{t\sigma^2}{2}} \cdot 3(t\sigma^2)^2 \cdot \sigma^2 + 2\sigma^2 e^{\frac{t\sigma^2}{2}} (t\sigma^2)^2 + 2\sigma^2 e^{\frac{t\sigma^2}{2}} \cdot \sigma^2 + \\ + \sigma^2 e^{\frac{t\sigma^2}{2}} \cdot (t\sigma^2)^2 + \sigma^2 e^{\frac{t\sigma^2}{2}} \cdot \sigma^2$$

$$\left. M_{W^{(1)}}(t) \right|_{t=0} = E X^4 = 3 \sigma^4 + \sigma^4 = 3 \sigma^4$$

$$\text{Var } X_i^2 = 3\sigma^4 - (\sigma^2)^2 = 3\sigma^4 - \sigma^4 = 2\sigma^4 = \frac{2 \cdot 1}{(2\theta)^2} = \frac{2}{4\theta^2} = \frac{1}{2\theta^2}$$

Retomando (*)

$$R(\theta, \delta(x)) = 4\theta^2 \left\{ \frac{1}{(n+2)^2} \cdot \frac{n \cdot 1}{2\theta^2} + \left[\frac{1 \cdot n \cdot 1 - 1}{n+2 \cdot 2\theta \cdot 2\theta} \right]^2 \right\} = \\ = 4\theta^2 \left\{ \frac{1}{2\theta^2} \cdot \frac{n}{(n+2)^2} + \left[\frac{1}{2\theta} \left[\frac{n-1}{n+2} \right]^2 \right] \right\} = \\ = \frac{4\theta^2}{2\theta^2} \left\{ \frac{1}{(n+2)^2} \left[n + \left[1 \left(\frac{n-n-2}{n+2} \right)^2 \right] \right] - 2 \cdot \frac{1}{(n+2)^2} \left[n + \frac{1}{2} \frac{4}{(n+2)^2} \right] \right\} = \\ = \frac{2n+4}{(n+2)^2} = \frac{2(n+2)}{(n+2)^2} = \frac{2}{n+2}$$

$$R(\theta, \delta(x)) = 2 \quad \text{que é constante}$$

Considerando a cláusula de todo o estimador: $c \leq \bar{X}_i^2 \leq n+2$

$$L(\theta, \delta(x)) = 4\theta^2 \left(c \leq \bar{X}_i^2 - 1 \right)^2 \cdot \frac{1}{2\theta}$$

$$R(\theta, \delta^*(x)) = F(L(\theta, \delta^*(x))) = E \left(4\theta^2 \left(c \leq \bar{X}_i^2 - 1 \right)^2 \right) =$$

$$= \frac{4\theta^2}{2\theta} E \left[\left(c \leq \bar{X}_i^2 - 1 \right)^2 \right] = \frac{4\theta^2}{2\theta} \left[\text{Var}(c \leq \bar{X}_i^2) + \left[E(c \leq \bar{X}_i^2 - 1) \right]^2 \right] =$$

$$= \frac{4\theta^2}{2\theta} \left\{ \frac{c^2 \cdot n}{2\theta} + \left[\frac{c \cdot n \cdot 1 - 1}{2\theta} \right]^2 \right\} = \frac{4\theta^2}{2\theta} \left[\frac{c^2 n}{2\theta} + \frac{[cn - 1]^2}{2\theta} \right] =$$

$$= \frac{4\theta^2}{2\theta} \left[\frac{c^2 n + (cn-1)^2}{2\theta} \right] = 2 \left[\frac{c^2 n + (cn-1)^2}{2\theta^2} \right] \quad \text{menor verificar para} \\ \text{que } c, \text{ o risco nro. mínimo, pertençam ao intervalo } \left[\frac{2}{n+2}, R(\theta, \delta(x)) \right] = 0$$

$$2 \left[\frac{2cn + k(cn-1) \cdot n}{2\theta^2} \right] = 0 \quad \frac{\partial^2}{\partial c^2} = 2n + n^2 > 0$$

$$2cn + cn - 1 = 0 \Rightarrow cn(n+1) = 1 \Rightarrow c = \frac{1}{n+1} \quad \text{dominado}$$

(*)

o risco que, se $c = \frac{1}{n+2}$ é a constante que formou o

único para a cláusula do estimador da forma $c \leq \bar{X}_i^2$,

do, o estimador $\delta(x) = \frac{\sum \bar{X}_i^2}{n+2}$ tem um risco uniformemente

igual a todos os estimadores da forma $c \leq \bar{X}_i^2$.

ou que o estimador de máxima verossimilhança é inadmissível
do EMV:

$$f_x(x, \theta^2) = \frac{1}{(2\theta^2)^{\frac{n}{2}}} \exp \left\{ -\frac{\sum \bar{X}_i^2}{2\theta^2} \right\} = \exp \left\{ -\frac{\sum \bar{X}_i^2}{2\theta^2} - n \log 2\pi\theta^2 \right\}$$

$$\ell(\theta^2) = -\frac{\sum \bar{X}_i^2}{2\theta^2} - n \log 2\pi\theta^2$$

$$\frac{d\ell(\theta^2)}{d\theta^2} = \frac{\sum \bar{X}_i^2}{2\theta^4} - \frac{n}{2\theta^2} = 0$$

$$\frac{\sum \bar{X}_i^2}{2\theta^4} = \frac{n}{2\theta^2}$$

$$\sum \bar{X}_i^2 = \theta^2 n$$

$$\hat{\theta}^2 = \frac{\sum \bar{X}_i^2}{n}$$

$$(\hat{\theta}^2) = -\frac{\sum \bar{X}_i^2}{2\theta^2} + n < 0$$

$\hat{\theta}^2 = \frac{2\theta^2}{2\theta^2 - 2\theta^2 \theta^2} = \theta^2$ ponto máximo.

mas o EMV virá da forma $c \leq \bar{X}_i^2$, com $c = \frac{1}{n+2}$

do item anterior que o menor risco será

$c = \frac{1}{n+2}$, então o risco dele será maior do

que o risco dado pelo estimador $\frac{\sum \bar{X}_i^2}{n+2}$.

Pág 133 (Cotinuidade de risco médio)

Pág 160 (estimação M(Minimax))

22/10/10

portanto, $\hat{\theta}^2 = \frac{\sum X_i^2}{n}$ é um estimador insensível.

De fato: forma geral do risco para estimadores da forma $c\sum X_i^2$

$$R(\theta, \hat{\theta}^2) = 2 \cdot \left[\frac{c^2 n + (cn-1)^2}{2} \right] = 2 \left[\frac{1 \cdot n + (\frac{n(n-1)}{2})^2}{2} \right] =$$

$$= \frac{2n}{n+2} = R(\theta, \hat{s}(x)), \quad \hat{s}(x) = \frac{\sum X_i^2}{n+2}$$

a) Mostre que $\hat{s}(x) = \frac{\sum X_i^2}{n+2}$ é um estimador minimax de θ^2 .

Tomemos uma sequência de prioris dada por:

$$\text{prior } \left(\frac{1}{b_k}, b_k \right) \quad (N_{b_k}), \quad b_k \rightarrow +\infty$$

Então temos (a) uma estimador de Bayes para θ^2 de uma priori dada

$$\text{prior } a, b \text{ é dado por: } \hat{s}_a(x) = \frac{\sum X_i^2}{2a+n+2} + \frac{1}{b}$$

Então temos a) sequências de prioris dadas, devendo tratar a sequência de estimadores de Bayes. (Teorema pag. 69)

$$\hat{s}_{\Delta_{b_k}}(x) = \frac{\sum X_i^2}{2+n+2} + \frac{1}{b_k(2+n+2)}$$

As sequências de prioris devem ser prioris sob a priori dada é definida

$$P\left(L\left(\frac{1}{\theta^2}, \hat{s}_{\Delta_{b_k}}(x)\right)\right) = E\left(L\left(\frac{1}{\theta^2}, \hat{s}(x)\right)\right) = E\left(\left(\frac{\hat{s}(x)}{\theta^2} - 1\right)^2\right)$$

$$= E\left[\left(\frac{b_k^2 \sum X_i^2 + 1}{b_k^2 (2+n+2)} - 1\right)^2\right] = E\left[\left(\frac{b_k^2 \sum X_i^2 + 1}{b_k^2 (2+n+2)} - 1\right)^2\right]$$

$L(\frac{1}{\theta^2}, \hat{s}_{\Delta_{b_k}})$

$S(\frac{1}{\theta^2}, \hat{s}(x))$

25

25/10/2010

$$= E\left[\frac{(b_k^2 \sum X_i^2 + 1)^2}{b_k^4 (2+n+2)^2} - \frac{2(b_k^2 \sum X_i^2 + 1)}{b_k^2 (2+n+2)^2} + 1^2\right] =$$

$$= E\left[\frac{b_k^4 (\sum X_i^2)^2}{b_k^2 (2+n+2)^2} + \frac{2b_k^2 \sum X_i^2 + 1}{b_k^2 (2+n+2)^2} - \frac{2b_k^2 \sum X_i^2}{b_k^2 (2+n+2)^2} + \frac{b_k^2 (2+n+2)^2}{b_k^2 (2+n+2)^2}\right] =$$

$$= E\left[\frac{1}{b_k^2 (2+n+2)^2} \left(\sum X_i^2\right)^2 + \frac{2}{b_k^2 (2+n+2)^2} \left(\sum X_i^2\right) + \frac{1}{b_k^2 (2+n+2)^2} - \frac{2}{b_k^2 (2+n+2)^2} \left(\sum X_i^2\right) + \frac{b_k^2 (2+n+2)^2}{b_k^2 (2+n+2)^2}\right], \text{ mas } U = \sum X_i^2 \sim \chi_n^2, \quad E(U) = n, \quad \text{Var}(U) = 2n, \quad E(U^2) = 2n + n^2$$

Então:

$$= \frac{1}{b_k^2 (2+n+2)^2} (2n+n^2) + \frac{2}{b_k^2 (2+n+2)^2} n + 1 - \frac{2}{b_k^2 (2+n+2)^2} n -$$

$$= \frac{2}{b_k^2 (2+n+2)^2} + 1$$

$$n = \lim_{n \rightarrow +\infty} n/n = \frac{2n+n^2}{(n+2)^2} - \frac{2n}{n+2} + 1 = \frac{n(2+n)}{(n+2)^2} - \frac{2n}{n+2} + 1 =$$

$$= \frac{n(2+n+2)}{n+2} = \frac{2}{n+2} = n$$

$$\text{mas tem-se que } R\left(\frac{1}{\theta^2}, \hat{s}(x)\right) = \frac{2}{n+2} \text{ quando } \hat{s}(x) = \frac{\sum X_i^2}{n+2},$$

$$\text{caso é constante, mas } R\left(\frac{1}{\theta^2}, \hat{s}(x)\right) = \frac{2}{n+2} - n$$

$$\therefore \hat{s}(x) = \frac{\sum X_i^2}{n+2} \text{ é um estimador minimax de } \theta^2$$

$\beta(\alpha, \beta)$

26/10/2020

$$E(X) = \frac{\alpha}{\alpha+\beta}$$

Item (b) Referto de outra moda:

$$S(X) = \sum_{i=1}^n X_i^2$$

$n+2$

$$L\left(\frac{d-1}{n^2}\right)^2 + R = E_\theta [L(d, \theta)]$$

$$\text{Max } d = n, \text{ onde } n \sim \chi_n^2$$

$$\frac{\sum X_i^2}{n^2} \sim \chi_n^2$$

$d = \sum X_i^2$

$n-2$

$\frac{n+2}{1}$

$$\text{Portanto: } R = E_\theta \left(\frac{n-1}{n+2} \right)^2 = E_\theta \left[\frac{n-(n+2)}{n+2} \right]^2 = \frac{1}{(n+2)^2} E_\theta [n^2 - 2(n+2)n + (n+2)^2]$$

$$R = \frac{1}{(n+2)^2} [2n + n^2 - 2(n+2).n + (n+2)^2] = \frac{1}{(n+2)^2} [n(n+2) - 2(n+2).n + (n+2)^2]$$

$$= \frac{-n+n+2}{n+2} = \frac{2}{n+2} \quad \text{para } S(X) = \sum_{i=1}^n X_i^2$$

Para $S^* = c \sum_{i=1}^n X_i^2$, $c > 0$, calcula analogamente:

$$R = E_\theta (c\theta - 1)^2 = E_\theta (c\theta^2 - 2c\theta + 1) = c^2(2n + n^2) - 2cn + 1$$

Identifico em c que atinge o mínimo em $c = 1$. Dessa maneira, o valor mínimo é obtido para $R = 2$ que é o valor da estimadora anterior.

O EMV da $\hat{\theta}^2$ é $\hat{\theta}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$ cujo valor é dado por:

$$R = E_\theta \left(\frac{n-1}{n} \right)^2 = \frac{1}{n^2} E_\theta (n^2 - 2n + n^2) = \frac{1}{n^2} (2n + n^2 - 2\cancel{n^2} + \cancel{n^2}) = \frac{2}{n} > 2$$

que é maior do estimador $\frac{1}{n} \sum_{i=1}^n X_i^2 \rightarrow$ o EMV de $\hat{\theta}^2$ é inadmissível.

10)

X_1, \dots, X_n uma amostra aleatória da distribuição binomial $m(p, m)$. Considere uma distribuição a priori Beta (α, β) para o estimador de Bayes de p sob perda quadrática.

10)

$$f(z, p) = \prod_{i=1}^m (z_i - 1) p^m (1-p)^{z_i - m}, \quad z_i = m, m+1, \dots$$

$$f(z|p) = \prod_{i=1}^m \binom{z_i - 1}{m-1} p^{mz_i} (1-p)^{2z_i - m - m} \quad z_i = m, m+1, \dots$$

por Beta (α, β)

$$\pi(p) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} I_{(0,1)}(p)$$

$\pi(p|z) \propto f(z|p) \cdot \pi(p) =$

$$= \prod_{i=1}^m \binom{z_i - 1}{m-1} p^{mz_i} (1-p)^{2z_i - m - m} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} I_{(0,1)}(p)$$

$$\propto p^{(nm+\alpha)-1} (1-p)^{(2\sum z_i - m - n + \beta) - 1} I_{(0,1)}(p)$$

$p|z \sim \text{Beta} (\alpha + nm; \beta + n(\bar{z} - m))$

perda quadrática, tem-se que $w(\theta) = 1$ e então

$$\delta_A(x) = E_p [q(\hat{\theta}) | X=x] = \underbrace{E_p [p | X=x]}_{\text{média da posterior}} = \frac{\alpha + mn}{\alpha + mn + \beta + n(\bar{x} - m)}$$

$$\delta_A(x) = \alpha + mn$$

$$\alpha + \beta + n\bar{x}$$

8. Supõe-se que X tinha distribuição binomial $b(\theta, n)$. Considere uma distribuição a priori Beta (a, b) com $a=b=0$ (priori imprecisa) e a priori quadrática. Considere estimadores δ que satisfaçam $S(0)=0$ e $S(n)=1$. Mostre que o risco e posterior é minimizado em $\delta(x) = x$. [Ver Example 2.8, p. 238-239, TPE]

$$X \sim b(\theta, n) \quad f(x|\theta) = \binom{n}{x} \theta^x (1-\theta)^{n-x}, \quad x=0, 1, \dots, n$$

$$\theta \sim \text{Beta}(0,0) \quad \pi(\theta) = \theta^{-1} (1-\theta)^{-1} I(0) \quad (\text{priori imprecisa, prior})$$

$$\begin{aligned} \int_0^1 \theta^{-1} (1-\theta)^{-1} d\theta &= \int_0^1 \frac{1}{\theta(1-\theta)} d\theta = \int_{\theta=1}^2 \frac{1}{\theta-1} d\theta \\ &= \int_0^1 \frac{1}{\theta} d\theta + \int_0^1 \frac{1}{1-\theta} d\theta = \log \theta \Big|_0^1 + \log (1-\theta) \Big|_0^1 = \log \left(\frac{\theta}{1-\theta} \right) \Big|_0^1 = \infty \end{aligned}$$

$$\theta | X=x \quad f(x|\theta) = \binom{n}{x} \theta^x (1-\theta)^{n-x} \theta^{-1} (1-\theta)^{-1} I(0)$$

$$\theta | X=x \quad \theta^{2-1} (1-\theta)^{n-x-1} I(0)$$

Se $x=1, \dots, n-1$, era é "título" demolido a posteriori própria (Beta $(x, n-x)$)

Considerando $S(0)=0$ e $S(n)=1$, então a estimadora de Bayes era dada, sob priori quadrática, pelo valor esperado do demolido a posteriori:

$$S_n(x) = E_\theta [\theta | X=x] = \frac{x}{n} \quad \boxed{S_n(x) = \frac{x}{n}}$$

Mostre que de fato essa estimadora é a que minimiza o risco da posterior.

Por definição, o risco médio é dado por:

$$J(\Delta, \delta) = \int R(\theta, \delta) d\Delta(\theta)$$

$$J(\Delta, \delta) = E_\theta [R(\theta, \delta)] = E_\theta [E_\theta [L(\theta, \delta) | X=x]] =$$

$$= \int_0^1 \left[\int_{\mathbb{R}} L(\theta, \delta) f(x|\theta) dx \right] \pi(\theta) d\theta =$$

$$= \int_0^1 \left[\sum_{x=0}^n (S(x)-\theta)^2 \binom{n}{x} \theta^x (1-\theta)^{n-x} \right] \theta^{-1} (1-\theta)^{-1} d\theta$$

$$= \int_0^\infty \left[\int_0^1 (S(x)-\theta)^2 \cdot \pi(n) \theta^{n-1} (1-\theta)^{n-x-1} d\theta \right] q(x) dx,$$

Minimizando este integrando, estaremos minimizando tudo, visto que $E_\theta [(S(x)-\theta)^2 | X=x] =$

$$= E_\theta [S(x)^2 - 2S(x)\theta + \theta^2 | X=x] =$$

$$= S(x)^2 - 2S(x)E_\theta [\theta | X=x] + E_\theta [\theta^2 | X=x]$$

Para que $S(x)$ seja mínimo, deve-se ter:

$$2S(x) - 2E_\theta [\theta | X=x] = 0$$

$$S(x) - E_\theta [\theta | X=x] = x = x$$

Note que $\frac{\partial^2 E_\theta}{\partial S(x)^2} = 2 > 0$ ponto mínimo

$$\boxed{S(x) = \frac{x}{n}}$$

∴ O risco e posterior é seu mínimo quando $\boxed{S(x) = \frac{x}{n}}$

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\theta)^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{(x-\theta)^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = 1$$

22/10/2010

9. Supõe-se que, dados θ e σ^2 , X_1, \dots, X_n sejam variáveis aleatórias independentes com distribuição $N(\theta, \sigma^2)$. Admita que, a priori, $T = \bar{x}$ tem distribuição Gamma $(q, 1)$ e θ , independente de T , tem distribuição uniforme (impropera) na reta.

(a) Mostre que a densidade conjunta a posteriori é proporcional a:

$$e^{-T} e^{-\frac{1}{2}\sum(x_i - \bar{x})^2 + n(\bar{x} - \theta)^2}$$

x_1, \dots, x_n

$$\begin{aligned} f(x|\theta, \sigma^2) &= \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2\right\} \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \\ T = 1 &\quad f(x|\theta, T) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2\right\} \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \\ \sigma^2 &= 1 \\ &+ 2T \end{aligned}$$

$$\frac{T}{2\sigma^2} \sim \text{Gamma}\left(\frac{n}{2}, \frac{1}{\sigma^2}\right)$$

$$\pi(T) = \frac{1}{r(q)} \cdot T^{q-1} \cdot e^{-\frac{T}{\sigma^2}} \cdot I(T)$$

$$T \perp \theta \Rightarrow \pi(T|\theta) = \pi(T) \cdot \pi(\theta)$$

$\pi(\theta)$ uniforme na reta (impropera, não informativa)

$$\begin{aligned} \pi(\theta, T|x) &\propto f(x|\theta, T) \cdot \pi(\theta, T) = f(x|\theta, T) \cdot \pi(\theta) \cdot \pi(T) = \\ &= \frac{1}{r(q)} \cdot \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \cdot e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2} \cdot T^{q-1} \cdot e^{-\frac{T}{\sigma^2}} \cdot d\theta \cdot dT \\ &= \frac{(T)^{\frac{n}{2}-1}}{(T)^{\frac{n}{2}}} \cdot r(q) \cdot (1)^0 \end{aligned}$$

$$\begin{aligned} &\propto = T^{\frac{n}{2}-1} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2} \cdot T^{q-1} \cdot e^{-\frac{T}{\sigma^2}} = \\ &= T^{\frac{n}{2}+q-1} \cdot e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 - \frac{T}{\sigma^2}} = \star \end{aligned}$$

22/10/2010

$$\begin{aligned} \star &\quad \sum ((x_i - \bar{x}) + (\bar{x} - \theta))^2 = \sum [(x_i - \bar{x})^2 + 2(x_i - \bar{x})(\bar{x} - \theta) + (\bar{x} - \theta)^2] = \\ &= \sum (x_i - \bar{x})^2 + 2 \cdot \sum (x_i - \bar{x}) \cdot (\bar{x} - \theta) + n(\bar{x} - \theta)^2 = \sum (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2 \\ &\quad \sum (x_i - \bar{x}) = \sum (x_i - \bar{x}) \cdot \frac{\bar{x}}{\bar{x}} = 0 \end{aligned}$$

Voltando:

$$\begin{aligned} \star \pi(\theta, T|x) &\propto T^{\frac{n}{2}+q-1} e^{-T[\alpha + \sum (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2]} = \\ &= T^{\frac{n}{2}+q-1} e^{-T[\alpha + 2(x_i - \bar{x})^2 + n(\bar{x} - \theta)^2]} = \\ &= T^{\frac{n}{2}+q-1} e^{-T[\alpha + 2(x_i - \bar{x})^2 + n(\bar{x} - \theta)^2]} \end{aligned}$$

Segundo $\pi(\theta, T|x) \propto T^{\frac{n}{2}+q-1} e^{-T[\alpha + 2(x_i - \bar{x})^2 + n(\bar{x} - \theta)^2]}$

$$\boxed{\pi(\theta, T|x) \propto T^{\frac{n}{2}+q-1} e^{-T[\alpha + 2(x_i - \bar{x})^2 + n(\bar{x} - \theta)^2]}}$$

(b) Mostre que a distribuição a posteriori de T é:

$$\text{Gamma}\left(\frac{n+q-1}{2}, \frac{1}{\alpha+2}\right)$$

$$\begin{aligned} \pi(T|x) &= \int_0^{+\infty} \pi(\theta, T|x) d\theta = \int_{-\infty}^{+\infty} T^{\frac{n}{2}+q-1} e^{-T[\alpha + 2(x_i - \bar{x})^2 + n(\bar{x} - \theta)^2]} d\theta = \\ &= T^{\frac{n}{2}+q-1} e^{-T[\alpha+2]} \int_{-\infty}^{+\infty} e^{-T(n\bar{x}^2 + 2\bar{x}\theta + \theta^2)} d\theta = \\ &= T^{\frac{n}{2}+q-1} e^{-T[\alpha+2]} \cdot \sqrt{\pi} \frac{1}{\sqrt{n}} \int_{-\infty}^{+\infty} \frac{1}{e^{\frac{1}{2}T(n\bar{x}^2 + 2\bar{x}\theta + \theta^2)}} d\theta = \\ &= T^{\frac{n}{2}+q-1} e^{-T[\alpha+2]} \cdot \sqrt{\pi} \frac{1}{\sqrt{n}} \int_{-\infty}^{+\infty} \frac{1}{e^{\frac{1}{2}T(\theta - \bar{x})^2}} d\theta = \\ &\quad \text{fdp } \mathcal{N}(\bar{x}, \frac{1}{2T}) \end{aligned}$$

22/10/2010

$$= \tilde{t}^{n+q-1} \cdot e^{-\tilde{t}(\alpha+q)} \cdot (\tilde{t}/n)^{-\frac{1}{2}} = \tilde{t}^{(n+q-1)-1} \cdot e^{-\tilde{t}(\alpha+q)} \cdot \frac{1}{n^{-\frac{1}{2}}}$$

intas

$$\pi(\tau|x) \propto \tau^{(n+q-\frac{1}{2})-1} e^{-\tau(\alpha+q)}$$

$$|\tau|x \sim \text{Gamma}\left(\frac{n+q-1}{2}, \frac{1}{\alpha+q}\right)$$

(c) Mostre que se $\alpha = q = 0$, o estimador de Bayes (generalizado) de σ^2 é $\hat{\sigma}^2$ para média quadrática. Para a média $\frac{(d - \bar{x})^2}{5^4}$, este

estimador é $\hat{\sigma}^2$

$$f(x|\theta, \tau) = \frac{1}{\tau^{\frac{n}{2}}} e^{-\tau \sum (x_i - \theta)^2}$$

$$\tau \sim \text{Gamma}\left(q, \frac{1}{\alpha}\right) \Rightarrow \tau \sim \text{Gamma}\left(0, \frac{1}{\alpha}\right) \dots$$

$$\pi(\tau) \propto \tau^{-\frac{n}{2}} e^{-\frac{\tau}{\alpha}}$$

$\pi(\theta)$ $\theta \sim$ uniforme na reta, não informativo:

$$\pi(\theta, \tau|x) \propto f(x|\theta, \tau) \cdot \pi(\theta, \tau) = f(x|\theta, \tau) \cdot \pi(\theta) \cdot \pi(\tau)$$

$$\pi(\theta, \tau|x) \propto \tau^{\frac{n}{2}} e^{-\tau \sum (x_i - \theta)^2} \tau^{-\frac{n}{2}-1} = \tau^{\frac{n}{2}} e^{-\tau \sum (x_i - \theta)^2}$$

$$\begin{aligned} \pi(\sigma^2|x) &= \int_{-\infty}^{+\infty} \pi(\theta, \tau|x) d\theta = \int_{-\infty}^{+\infty} \tau^{\frac{n}{2}-1} e^{-\tau \sum (x_i - \theta)^2} d\theta \\ &= e^{-\tilde{t}^2} \tau^{\frac{n}{2}-1} \sqrt{2\pi} \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2} \frac{\theta^2}{\tilde{t}^2}} d\theta = e^{-\tilde{t}^2} \tau^{\frac{n}{2}-1} \end{aligned}$$

$$\sqrt{2\pi} \sim N(\tilde{t}, \frac{1}{\tilde{t}^2}) \quad \pi(\sigma^2|x) \sim \text{Gamma}\left(\frac{n}{2}, \frac{1}{\tilde{t}^2}\right)$$

Outro modo:

$$\text{Do item (b), } |\tau|x \sim \text{Gamma}\left(n+q-\frac{1}{2}, \frac{1}{\alpha+q}\right) \stackrel{q=0}{\Rightarrow} |\tau|x \sim \text{Gamma}\left(\frac{n-1}{2}, \frac{1}{\alpha}\right)$$

 $r(\alpha+1) = \alpha \cdot r(\alpha)$

22/10/2010

$$|\tau|x \sim \text{Gamma}\left(\frac{n-1}{2}, \frac{1}{\alpha}\right)$$

$$\tau = 1$$

$$\tau^2 = 1$$

Sob forma quadrática, $w(\tau) = \frac{1}{2} \tau^2$ e amin:

$$S_n(x) = E_\tau[g(\tau)|X=x] = \int_0^{+\infty} \frac{1}{2\tau} \cdot \frac{1}{r(n-1)} \frac{\tau^{\frac{n-1}{2}-1}}{\left(\frac{n-1}{2}\right)!} e^{-\tau} d\tau$$

$$= \frac{1}{2} \frac{1}{r(n-1)} \int_0^{+\infty} \tau^{-\frac{1}{2}} \frac{\tau^{\frac{n-1}{2}-1}}{\left(\frac{n-1}{2}\right)!} e^{-\tau} d\tau =$$

$$= \frac{1}{2} \frac{1}{r(n-1)} \int_0^{+\infty} \tau^{\frac{3-n}{2}} \frac{\tau^{\frac{n-1}{2}-1}}{\left(\frac{n-1}{2}\right)!} e^{-\tau} d\tau =$$

$$= \frac{1}{2} \frac{1}{r(n-1)} \frac{\tau^{\frac{n-1}{2}}}{\left(\frac{n-1}{2}\right)!} \int_0^{+\infty} \frac{1}{\tau} \tau^{\frac{n-1}{2}-1} e^{-\frac{\tau}{2}} d\tau$$

$$= \frac{1}{2} \frac{1}{r(n-1)} \frac{\tau^{\frac{n-1}{2}}}{\left(\frac{n-1}{2}\right)!} \underbrace{\int_0^{+\infty} \frac{1}{z} z^{\frac{n-1}{2}-1} e^{-\frac{z}{2}} dz}_{\text{sp}} = \text{Gamma}\left(\frac{n-1}{2}, \frac{1}{2}\right)$$

$$= \frac{1}{2} \frac{1}{r(n-1)} \frac{\tau^{\frac{n-1}{2}}}{\left(\frac{n-1}{2}\right)!} = \frac{1}{n-3}$$

$$S_n(x) = \frac{1}{n-3}$$

$X \sim \text{Gamma}(\alpha, \theta)$

$$\boxed{\begin{aligned} E(X) &= \alpha\theta \\ \text{Var}(X) &= \alpha\theta^2 \end{aligned}}$$

22/10/2010

Sob a pumba, $\lambda = \frac{(d-\theta)^2}{\theta^4}$ tem-se que:

$$\lambda(\bar{x}, d) = \frac{\left(\frac{d-1}{2\bar{x}}\right)^2}{\frac{1}{2\bar{x}}} = 4\bar{x}^2 \left(\frac{d-1}{2\bar{x}}\right)^2.$$

$w(\tau) = 4\bar{x}^2$ e $g(\tau) = \frac{1}{2\bar{x}}$, assim tem-se que:

$$s_n(x) = E_{\tau} [w(\tau) \cdot g(\tau) | X=x] = \frac{E_{\tau} \left[\frac{2\bar{x}^2}{2\bar{x}} \cdot \frac{1}{2\bar{x}} | X=x \right]}{E_{\tau} [w(\tau) | X=x]} = \frac{E_{\tau} [4\bar{x}^2 | X=x]}{E_{\tau} [\bar{x}^2 | X=x]}$$

$$= 2 E_{\tau} [\bar{x} | X=x] = \sqrt{2} \cdot E_{\tau} [\bar{x} | X=x]$$

$$4 E_{\tau} [\bar{x}^2 | X=x] = \sqrt{2} \cdot \left\{ \text{Var}_{\tau} [\bar{x} | X=x] + [E_{\tau} [\bar{x} | X=x]]^2 \right\} =$$

$$= \frac{(\frac{n-1}{2}) \cdot \frac{1}{2}}{\binom{n-1}{2}} = \frac{\frac{n-1}{2}}{2\binom{n-1}{2}} = \frac{1}{2(n-1)}$$

$$= \frac{1}{2(n-1)+n-1} = \frac{(n-1)}{(n-1)[2+(n-1)]} = \frac{1}{2(n+1)-n+1} = \frac{1}{n+1}$$

$$\boxed{s_n(x) = \frac{2}{n+1}}$$

m-1

SAO DOMINGOS

22/10/2010

(d) Mostre que a densidade a posteriori de θ é simétrica em relação a \bar{x} e que o estimador de Bayes (generalizado) é \bar{x} .

$$\pi(\theta | x) = \int_0^{+\infty} \pi(\theta, \bar{x} | x) d\bar{x} = \int_0^{+\infty} \bar{x}^{n+g-1} e^{-\bar{x}(\alpha+g+n(\bar{x}-\theta)^2)} d\bar{x}$$

$$= \frac{r(n+g)}{\left[\left(\alpha+g+n(\bar{x}-\theta)^2\right)^{n+g}\right]} \int_0^{+\infty} \frac{1}{r(n+g)} \cdot \frac{\bar{x}^{n+g-1}}{\left(\left(\alpha+g+n(\bar{x}-\theta)^2\right)^{-1}\right)^{n+g}} e^{-\bar{x}(\alpha+g+n(\bar{x}-\theta)^2)} d\bar{x}$$

$$\pi(\theta | x) \propto r(n+g) \cdot \frac{1}{\left[\alpha+g+n(\bar{x}-\theta)^2\right]^{n+g}}$$

$$\pi(\theta | x) \propto \left[1 + n(\bar{x}-\theta)^2 \right]^{-(n+g)} = \left[1 + \frac{(\bar{x}-\theta)^2}{\frac{\alpha+g}{n}} \right]^{-(n+g)}$$

que é o núcleo de uma t-student centrízada em \bar{x}
e então $E[\pi(\theta | x)] = \bar{x}$ e o estimador de Bayes
sob pumba quadrática é \bar{x} .

* t-student (\bar{x}, s^2, v) onde:

$$\frac{v+1}{2} = n+g \quad v = 2(n+g)-1 > 0$$

$$i) \quad v s^2 = \frac{\alpha+g}{n} \rightarrow s^2 = \frac{\alpha+g}{n v} = \frac{\alpha+g}{n [2(n+g)-1]} \rightarrow 0$$

$$ii) \quad \theta | x \sim t\left(\bar{x}, \frac{\alpha+g}{n}, \frac{2(n+g)-1}{n [2(n+g)-1]}\right)$$

medida em relação a \bar{x}

22/10/2010

10. Suponha que, dado p , $X \sim b(n, p)$ e considere a densidade (imprópria) proporcional a $p^{-1}(1-p)^{-1}$ para p . Mostre que X é um estimador de Bayes (generalizado) para p sob perda quadrática.

$$X \sim b(n, p)$$

$$f(x|p) = \binom{n}{x} p^x (1-p)^{n-x} \quad x=0, \dots, n$$

$$\Pi(p|x) \propto f(x|p) \Pi(p) \quad (\text{priori imprópria - não é uma densidade})$$

$$\propto \binom{n}{x} p^x (1-p)^{n-x} p^{-1}(1-p)^{-1}$$

$$\propto p^{x-1} (1-p)^{n-x-1}$$

Se $x=1, \dots, n-1$ isso é uma densidade a posteriori própria

$$p|X \sim \text{Beta}(x, n-x)$$

Se $x=0$, a densidade a posteriori é proporcional a:

$$(1-p)^{n-1} = 1 \sum_{k=0}^{n-1} \binom{n-1}{k} 1^k (-p)^{n-1-k} =$$

$$= 1 \sum_{k=0}^{n-1} \binom{n-1}{k} (-1)^{n-1-k} p^{n-1-k} =$$

$$= \sum_{k=0}^{n-1} \binom{n-1}{k} (-1)^{n-1-k} p^{n-1-k} \quad k=n-1$$

$$= \sum_{k=0}^{n-2} \binom{n-1}{k} (-1)^{n-1-k} p^{n-2+k} + \frac{1}{p}$$

A integral de cada parcela da somatória em $(0,1)$ é finita e a da parcela 1 é infinita.

$$\int_0^1 \frac{(1-p)^{n-1}}{p} dp = k + \int_0^1 \frac{1}{p} dp = k + \log p \Big|_0^1 = +\infty$$

onde k é um número real finito. Então $\Pi(p|x)$ não é densidade.

22/10/2010

Se $x=n$, a densidade a posteriori é dada por:

$$p^{\frac{n-1}{2}}, \text{ se tomarmos } 1-p=q \text{ e } p=1-q, \text{ tem-se que:}$$

$$(1-q)^{\frac{n-1}{2}}, \text{ o que análogamente ao caso anterior resultará}$$

$$\text{em: } \int_0^1 (1-q)^{\frac{n-1}{2}} dq = +\infty.$$

Então $\Pi(p|x)$ não é densidade.

Se $x=1, \dots, n-1$, tem-se que $p|X \sim \text{Gamma}(x, n-x)$

Sob perda quadrática, tem-se que $\delta(p)=1$ e então o estimador de Bayes será dado por:

$$\delta_n(x) = E_p[p|X=x] = \frac{x}{x+n-1} = \frac{x}{n}$$

$$\boxed{\delta_n(x) = \frac{x}{n}}$$

para os casos nos quais $x=0$ e $x=n$ é razoável tomar como estimador $\delta(0)=0$ e $\delta(n)=1$.

$\delta(0)=0 \Rightarrow$ não se observou nenhum sucesso, estima-se p por zero.

$\delta(n)=1 \Rightarrow$ tudo que observado é sucesso, estima-se p por 1.

Então, o estimador de Bayes para p , face dada por:

$$\delta(x) = \begin{cases} 0 & \text{se } x=0 \\ \frac{x}{n} & \text{se } x=1, \dots, n-1 \\ 1 & \text{se } x=n \end{cases}$$

~~Relação entre a função
de risco e a função
de perda~~

$$r(a+b) = a \cdot r(a)$$

Risco (r)

* Tentarmos: $\Pi(p) = \int_{0,1}^1 p^x (1-p)^{n-x} \text{Beta}(x+a, n-x+b) dp$ [22/10/2010]

(1) Suponha que X tem distribuição $b(p, n)$ e considere o problema de estimar p com perda $(d-p)^2$. Obterá o estimador minimax.

$$[p(1-p)]$$

$$X \sim b(p, n)$$

$$f(x|p) = \binom{n}{x} p^x (1-p)^{n-x}$$

Tentarmos uma função Δ Beta (a, b), tem-se que:

$$\Pi(p) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} p^{a-1} (1-p)^{b-1} \int_{0,1}^1$$

$$\Pi(p) \propto \{ |x| \cdot p \} \cdot \Pi(p)$$

$$\propto \binom{n}{x} p^x (1-p)^{n-x} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} p^{a-1} (1-p)^{b-1}$$

$$p^x (1-p)^{n-x} \cdot \text{Beta}(x+a, n-x+b)$$

$$L(p, d) = 1 - (d-p)^2, \text{ então } w(p) = \frac{1}{1 - (d-p)^2}, \quad g(p) = p, \text{ então tem-se}$$

$$w(p) = \frac{p}{1 - (d-p)^2}$$

que o estimador de Bayes será dado por:

$$\delta_D(x) = \frac{E_p[w(p) \cdot g(p) | X=x]}{E_p[w(p) | X=x]} = \frac{E_p[\frac{1}{1-(d-p)^2} p | X=x]}{E_p[\frac{1}{1-(d-p)^2} | X=x]} \quad \text{(*)}$$

$$E_p[w(p) | X=x] = E_p[\frac{1}{1-(d-p)^2} | X=x] \quad \text{(**)}$$

$$\begin{aligned} \text{(*)} \quad E_p\left[\frac{1}{1-p} | X=x\right] &= \int_0^1 \frac{1}{1-p} \frac{r(x+a+n-x+b)}{r(x+a) \cdot r(n-x+b)} p^{x+a-1} (1-p)^{n-x+b-1} dp \\ &= \int_0^1 \frac{\Gamma(a+b+n)}{\Gamma(x+a) \cdot \Gamma(n-x+b)} p^{x+a-1} (1-p)^{n-x+b-1} dp = \frac{\Gamma(a+b+n)}{\Gamma(x+a) \cdot \Gamma(n-x+b)} \\ &= \frac{(a+b+n-1)}{(n-x+b-1)} \int_0^1 \frac{r(a+b+n-1)}{r(x+a) \cdot r(n-x+b-1)} p^{x+a-1} (1-p)^{n-x+b-1} dp = a+b+n-1 \\ &= 1 \quad \text{f.d.p. Beta}(x+a, n-x+b-1) \end{aligned}$$

$$\begin{aligned} * \quad r(a+n+b) &= (a+n+b-1) \cdot r(a+n+b-1) = \\ &= (a+n+b-1) \cdot (a+n+b-2) \cdot r(a+n+b-2) \end{aligned}$$

22/10/2010

$$\begin{aligned} E_p\left[\frac{1}{1-p} | X=x\right] &= \int_0^1 \frac{1}{1-p} \frac{r(x+a+n-x+b)}{r(x+a) \cdot r(n-x+b)} p^{x+a-1} (1-p)^{n-x+b-1} dp = \\ &= \int_0^1 \frac{r(a+n+b)}{r(x+a) \cdot r(n-x+b)} p^{(x+a-1)-1} (1-p)^{(n-x+b-1)-1} dp \\ &= \frac{(a+n+b-1) \cdot (a+n+b-2)}{(x+a-1) \cdot (n-x+b-1)} \int_0^1 \frac{r(a+n+b-2)}{r(x+a-1) \cdot r(n-x+b-1)} p^{(x+a-1)-1} (1-p)^{(n-x+b-1)-1} dp \\ &= \frac{1}{(a+n+b-1) \cdot (a+n+b-2)} \frac{\Gamma(x+a-1) \cdot \Gamma(n-x+b-1)}{\Gamma(x+a-1) \cdot (n-x+b-1)} \end{aligned}$$

Voltando a (*) de (1), (2) temos que:

$$\delta_D(x) = \frac{E_p[w(p) \cdot g(p) | X=x]}{E_p[w(p) | X=x]} = \frac{\frac{a+b+n-1}{n-x+b-1}}{\frac{(a+n+b-1) \cdot (a+n+b-2)}{(x+a-1) \cdot (n-x+b-1)}} = \frac{x+a-1}{a+n+b-2}$$

$$\boxed{\delta_D(x) = \frac{x+a-1}{a+n+b-2}}$$

Estimador de Bayes para p .

Cálculo do Risco sob a perda: $L(p, \delta) = 1 - (d-p)^2$, tem-se que:

$$\begin{aligned} R(p, \delta(x)) &= E(L(p, \delta(x))) = E\left[\frac{1}{1-p} (1 - \frac{\delta(x)}{p})^2\right] = \\ &= \frac{1}{p(1-p)} E[(\delta(x) - p)^2] = \frac{1}{p(1-p)} \left[\text{Var}(\delta(x)) + [E(\delta(x)) - p]^2 \right] \end{aligned}$$

$$\text{Var}(\delta(x)) = \text{Var}\left(\frac{x+a-1}{a+n+b-2}\right) = \frac{n \cdot p \cdot (1-p)}{(a+n+b-2)^2}$$

22/10/2010

$$E(\delta(x)) = E\left[\frac{x+a-1}{a+n+b-2}\right] = \frac{np+a-1}{a+n+b-2}$$

Voltando ao cálculo do risco, tem-se que:

$$\begin{aligned} R(p, \delta(x)) &= 1 \left[\text{Var}(\delta(x)) + \mathbb{E}[(\delta(x) - p)^2] \right] = \\ &= \frac{1}{p(1-p)} \left[\frac{np(1-p)}{(a+n+b-2)^2} + \left[np+a-1 - p \right]^2 \right] = \\ &= \frac{1}{p(1-p)} \left[np(1-p) + \frac{(np+a-1-p)^2}{(a+n+b-2)^2} \right] = \\ &= \frac{1}{p(1-p)} \left[np(1-p) + \frac{[a-1-2p-n(a+b)]^2}{(a+n+b-2)^2} \right] = \\ &= \frac{1}{p(1-p)} \left[\frac{np(1-p) + [(a-1)-p(a+b-2)]^2}{(a+n+b-2)^2} \right] = \\ &= \frac{1}{(a+n+b-2)^2} \left[n+1 \cdot \frac{[(a-1)-p(a+b-2)]^2}{p(1-p)} \right] \end{aligned}$$

Para que o risco $R(p, \delta(x))$ seja constante, ou seja, não dependa de p , devemos ter:

$$a-1=0 \quad a+b-2=0$$

$$\boxed{a=1} \quad 1+b-2=0 \quad b-1=0 \Rightarrow \boxed{b=1}$$

Deste modo, se $a=b=1$, o risco será constante e o estimador de Bayes será dado por:

$$\delta_n(x) = \frac{x+\bar{x}-2}{n} \rightarrow \boxed{\delta_n(x) = \frac{x}{n}}$$

Portanto, se o estimador de Bayes tem risco constante, então é de risco mínimo. Então $\boxed{\delta(x) = \frac{x}{n}}$ é estimador mínimo de p .

23/10/2010

12. Sejam X_1, \dots, X_m e Y_1, \dots, Y_n amostras aleatórias independentes das distribuições $N(\mu_x, \sigma_x^2)$ e $N(\mu_y, \sigma_y^2)$, respectivamente, aqui $\mu_x \in \mathbb{R}$, $\mu_y \in \mathbb{R}$, $\sigma_x^2 > 0$ e $\sigma_y^2 > 0$. Considere o problema de estimar $\Delta = \mu_y - \mu_x$ sob medida quadrática.

(a) Mostre que $\bar{y} - \bar{x}$ é estimador mínimo de Δ quando σ_x^2 e σ_y^2 são conhecidos, $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$ e $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$.

(b) Mostre que $\bar{y} - \bar{x}$ é estimador mínimo de Δ quando $\sigma_x^2 \leq M_x$ e $\sigma_y^2 \leq M_y$, sendo $M_x > 0$ e $M_y > 0$ constantes conhecidas.

Resposta: Use o seguinte resultado: se, dada $\xi_1, \xi_2, \dots, \xi_n$ não independentes e com distribuição $N(\xi_j, \sigma^2)$ e se a distribuição a priori para $\xi_j \sim N(\xi_j, \sigma^2)$, então a distribuição a posteriori de ξ_j , dado que $\bar{\xi}_j = \xi_1, \dots, \bar{\xi}_n = \xi_n$, é normal de média $\left(\frac{n\bar{\xi}_j + \xi_j}{n+1} \right)$ e

$$\text{variancia } \left(\frac{n+1}{\sigma^2} \right)^{-1}, \text{ onde } \bar{\xi}_j = \frac{\sum_{i=1}^n \xi_i}{n}$$

$$\bar{\xi}_1, \dots, \bar{\xi}_n \sim N(\xi_j, \sigma^2)$$

$$f(\xi_j | \xi) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (\xi_i - \xi_j)^2 \right\} \prod_{i=1}^n I(\xi_i)$$

$$\Pi(\xi_j | \xi) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{2\sigma^2} (\xi_j - \bar{\xi})^2 \right\} I(\xi_j)$$

$$\Pi(\xi_j | \xi) \propto f(\xi_j | \xi) \cdot \Pi(\xi_j)$$

$$\Pi(\xi_j | \xi) \propto \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (\xi_i - \xi_j)^2 \right\} \cdot \frac{1}{(2\pi\sigma^2)^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2\sigma^2} (\xi_j - \bar{\xi})^2 \right\}$$

$$\Pi(\xi_j | \xi) \propto \exp \left\{ -\frac{1}{2\sigma^2} \left(\sum_{i=1}^n (\xi_i - \bar{\xi})^2 + (\xi_j - \bar{\xi})^2 \right) - \frac{1}{2\sigma^2} (\xi_j - \bar{\xi})^2 \right\}$$

$$\propto \exp \left\{ -\frac{1}{2\sigma^2} \left(\frac{n-1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi})^2 + \frac{1}{n} (\xi_j - \bar{\xi})^2 \right) \right\}$$

23/10/2010

$$\propto \exp \left\{ -\frac{1}{2} \sum_{i=1}^m \left(\frac{(x_i - \bar{x})^2}{b_i^2} + \frac{(y_i - \bar{y})^2}{b_j^2} \right) \right\}$$

$$E[z] \sim N \left\{ \left(\frac{\bar{x}}{b_x^2} + \frac{\bar{y}}{b_y^2} \right) / (m+1); \left(\frac{1}{b_x^2} + \frac{1}{b_y^2} \right)^{-1} \right\}, \quad \bar{z} = \frac{\sum z_i}{m}$$

Sijan $x_1, \dots, x_m, y_1, \dots, y_n$ amotis aleatorias independentes das distribucións $N(\mu_x, \sigma_x^2)$, $N(\mu_y, \sigma_y^2)$, respectivamente.

Problema: estimar $\mu_y - \mu_x$. nob pode quodarla.

A distribución conjunta das dous amotis serí dada por:

$x_i \sim N(\mu_x, \sigma_x^2)$, $y_i \sim N(\mu_y, \sigma_y^2)$, $\sigma_x^2 > 0$ e $\sigma_y^2 > 0$ combinar

$$f(x, y | (\mu_x, \mu_y)) = f(x | \mu_x) \cdot f(y | \mu_y) \text{ para } x \perp\!\!\!\perp y.$$

$$f(x, y | (\mu_x, \mu_y)) = \frac{1}{(\sqrt{2\pi\sigma_x^2})^m} \exp \left\{ -\frac{1}{2\sigma_x^2} \sum_{i=1}^m (x_i - \mu_x)^2 \right\} \cdot \frac{1}{(\sqrt{2\pi\sigma_y^2})^n} \exp \left\{ -\frac{1}{2\sigma_y^2} \sum_{i=1}^n (y_i - \mu_y)^2 \right\}$$

Suponse que μ_x é una princi $N(\bar{\mu}_x, b_x^2)$ e que μ_y é una princi $N(\bar{\mu}_y, b_y^2)$, donde $b_x^2 > 0$ e $b_y^2 > 0$ combinar

$$f(\mu_x | \mu_y) = \frac{1}{\sqrt{2\pi b_x^2}} \exp \left\{ -\frac{1}{2b_x^2} (\mu_x - \bar{\mu}_x)^2 \right\}$$

$$f(\mu_y | \mu_x) = \frac{1}{\sqrt{2\pi b_y^2}} \exp \left\{ -\frac{1}{2b_y^2} (\mu_y - \bar{\mu}_y)^2 \right\}$$

Como $x \perp\!\!\!\perp y$ entón $\mu_x \perp\!\!\!\perp \mu_y$ e daí, ten-se que:

$$\Pi((\mu_x, \mu_y) | (\bar{\mu}_x, \bar{\mu}_y)) = \Pi(\mu_x | \bar{\mu}_x) \cdot \Pi(\mu_y | \bar{\mu}_y)$$

$$\Pi((\mu_x, \mu_y) | (\bar{\mu}_x, \bar{\mu}_y)) = \frac{1}{\sqrt{2\pi b_x^2}} \exp \left\{ -\frac{1}{2b_x^2} (\mu_x - \bar{\mu}_x)^2 \right\} \cdot \frac{1}{\sqrt{2\pi b_y^2}} \exp \left\{ -\frac{1}{2b_y^2} (\mu_y - \bar{\mu}_y)^2 \right\}$$

Logo, a distribución conjunta de (μ_x, μ_y) non depende de $\bar{\mu}_x$.

$$\Pi((\mu_x, \mu_y) | (\bar{x}, \bar{y})) \propto f(\bar{x}, \bar{y}) \cdot \Pi((\mu_x, \mu_y) | (\bar{\mu}_x, \bar{\mu}_y))$$

$$\propto \exp \left\{ -\frac{1}{2b_x^2} \sum (x_i - \bar{x})^2 \right\} \cdot \exp \left\{ -\frac{1}{2b_y^2} \sum (y_i - \bar{y})^2 \right\} \exp \left\{ -\frac{1}{2b_x^2} \sum (y_i - \bar{\mu}_y)^2 \right\}$$

$$\propto \exp \left\{ -\frac{1}{2b_x^2} \sum (x_i - \bar{x})^2 \right\} \cdot \exp \left\{ -\frac{1}{2b_y^2} \sum (y_i - \bar{y})^2 \right\} \cdot \exp \left\{ -\frac{1}{2b_x^2} \sum (y_i - \bar{\mu}_y)^2 \right\}$$

23/10/2010

$$\propto \exp \left\{ -\frac{1}{2b_x^2} \sum_{i=1}^m ((x_i - \bar{x}) + (\bar{x} - \mu_x))^2 - \frac{1}{2b_y^2} \sum_{i=1}^n ((y_i - \bar{y}) + (\bar{y} - \mu_y))^2 \right\}$$

$$= \frac{1}{2b_x^2} (\mu_x - \bar{\mu}_x)^2 + \frac{1}{2b_y^2} (\mu_y - \bar{\mu}_y)^2$$

$$\propto \exp \left\{ -\frac{1}{2b_x^2} m (\bar{x} - \mu_x)^2 - \frac{1}{2b_y^2} n (\bar{y} - \mu_y)^2 - \frac{1}{2b_x^2} (\mu_x - \bar{\mu}_x)^2 - \frac{1}{2b_y^2} (\mu_y - \bar{\mu}_y)^2 \right\}$$

$$\propto \exp \left\{ -\frac{1}{2b_x^2} m (\bar{x}^2 - 2\bar{x}\mu_x + \mu_x^2) - \frac{1}{2b_y^2} n (\bar{y}^2 - 2\bar{y}\mu_y + \mu_y^2) - \frac{1}{2b_x^2} (\mu_x^2 - 2\bar{\mu}_x\mu_x + \bar{\mu}_x^2) - \frac{1}{2b_y^2} (\mu_y^2 - 2\bar{\mu}_y\mu_y + \bar{\mu}_y^2) \right\}$$

$$\propto \exp \left\{ \left(-m - 1 \right) \frac{\mu_x^2}{b_x^2} + \left(+m\bar{x} + \mu_x \right) \frac{\mu_x}{b_x^2} + \left(-n - 1 \right) \frac{\mu_y^2}{b_y^2} + \left(+n\bar{y} + \mu_y \right) \frac{\mu_y}{b_y^2} \right\}$$

$$\propto \exp \left\{ \left[-\frac{1}{2} \left(\frac{m}{b_x^2} + 1 \right) \right] \left[\mu_x^2 + \left(\frac{m\bar{x} + \mu_x}{b_x^2} \right) \mu_x \right] + \left[-\frac{1}{2} \left(n + 1 \right) \right] \left[\mu_y^2 + \left(\frac{n\bar{y} + \mu_y}{b_y^2} \right) \mu_y \right] - \frac{1}{2} \left(\frac{m+n}{b_x^2} + 1 \right) \right\} - \frac{1}{2} \left(\frac{m+n}{b_y^2} + 1 \right)$$

$$\propto \exp \left\{ \left[-\frac{1}{2} \left(\frac{m+1}{b_x^2} \right) \right] \left[\mu_x - \left(\frac{m\bar{x} + \mu_x}{b_x^2} \right) \right]^2 - \frac{m}{b_x^2} + \frac{1}{2} \right\}$$

$$\propto \exp \left\{ \left[-\frac{1}{2} \left(\frac{n+1}{b_y^2} \right) \right] \left[\mu_y - \left(\frac{n\bar{y} + \mu_y}{b_y^2} \right) \right]^2 - \frac{n}{b_y^2} + \frac{1}{2} \right\}$$

Ques é a muílo de suma normal bi-variedade

$$\mu_x | x = \bar{x} \sim N \left[\left(\frac{m\bar{x} + \mu_x}{b_x^2} \right) / \left(\frac{m+1}{b_x^2} \right); \left(\frac{m+1}{b_x^2} \right)^{-1} \right]$$

23/10.2010

$$\text{My} | y=y \sim N \left[\left(\frac{n\bar{x} + u_0}{\bar{t}_y^2 + b^2} \right) / \left(\frac{n+1}{\bar{t}_y^2 + b^2} \right); \left(\frac{n+1}{\bar{t}_y^2 + b^2} \right)^{-1} \right]$$

Sob grandeza quadrática $W(u_x, u_y) = 1$, é lim -x que $y(u_x, u_y) = u_y - u_x$ é
máx e otimizada de Bayes só dada por:

$$S_n(x) = E_{u_x, u_y} [g(u_x, u_y) | X=x, Y=y] = E(u_y - u_x | X=x, Y=y) =$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (u_y - u_x) \Pi((u_x, u_y) | t_{xy}) du_x du_y =$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} My \Pi((u_y, u_x) | (t_{xy})) du_x du_y = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} u_x \Pi(u_x, u_y | (t_{xy})) du_x du_y =$$

$$= E(u_y | y=y) - E(u_x | Y=y)$$

$$= \frac{\frac{n\bar{x}}{\bar{t}_y^2 + b^2} + \frac{u_0}{b^2}}{\bar{t}_y^2 + b^2} = \frac{\frac{n\bar{x}}{\bar{t}_y^2 + b^2} + \frac{u_1}{b^2}}{\bar{t}_y^2 + b^2}$$

$$= \frac{n+1}{\bar{t}_y^2 + b^2} = \frac{m+1}{\bar{t}_x^2 + b^2}$$

Para facilitar ainda mais o problema, supondo $\bar{t}_x = \bar{t}_y$
comum, menor ou não, menor que para u_x e u_y , $N(0, b^2)$

Análise

$$f(z_{xy} | u_x, u_y) = \left(\frac{1}{\sqrt{2\pi\bar{t}_x^2}} \right)^n \left(\frac{1}{\sqrt{2\pi\bar{t}_y^2}} \right)^m \exp \left(-\frac{\sum x_i^2 - 2u_x \sum x_i + m u_x^2}{2\bar{t}_x^2} - \frac{\sum y_i^2 - 2u_y \sum y_i + n u_y^2}{2\bar{t}_y^2} \right)$$

Usando este prior, considerando grandeza quadrática, a otimizada de Bayes de $u_y - u_x$ é a média a posterior, então

$$S_n(x) = E(\hat{u}_y - \hat{u}_x | X=x, Y=y) = E(u_y | X=x, Y=y) - E(u_x | X=x, Y=y) =$$

$$= E(u_y | Y=y) - E(u_x | X=x) = \frac{\frac{n\bar{x}}{\bar{t}_y^2 + b^2} + \frac{u_1}{b^2}}{\bar{t}_y^2 + b^2} -$$

$$= \frac{n+1}{\bar{t}_y^2 + b^2} = \frac{m+1}{\bar{t}_x^2 + b^2}$$

(Nota: a verossimilhança a posteriori não depende da amostra lim-nula, ou dominante)

a)

$$(u_y - \hat{u}_x | X=x, Y=y)$$

independente entre X e Y ; tem-se:

$$\hat{u}_y - \hat{u}_x | X=x, Y=y = \text{Var}(u_y | Y=y) + \text{Var}(u_x | X=x) =$$

$$+ \frac{1}{b^2} + \left(\frac{n+1}{\bar{t}_y^2 + b^2} \right)^{-1}$$

segue uma sequência de priors tais que $b^2 \rightarrow \infty$.

então, $b^2 = \bar{t}_x^2$, é ótimo

$$\lim_{K \rightarrow \infty} \hat{u}_{xK} = \frac{\bar{t}_y^2 + \bar{t}_x^2}{m}$$

$$= \sup_{\theta} R(\theta, \bar{y} - \bar{x}), \text{ para } R(\theta, \bar{y} - \bar{x}) = \text{Var}_{\theta}(\bar{y} - \bar{x}) = \frac{\bar{t}_y^2}{m} + \frac{\bar{t}_x^2}{m},$$

onde $\theta = (u_x, u_y)$

tanto, $\bar{y} - \bar{x}$ é minimax.

23/10/2010

Dúctio mede.

Considerar os gráficos:

$$u_x \sim N(\mu_x; b_x^2) \quad (\Delta b_{1x}) \quad \text{com } b_{1x} \xrightarrow[k \rightarrow +\infty]{} +\infty$$

$$u_y \sim N(\mu_y; b_y^2) \quad (\Delta b_{2x}) \quad \text{com } b_{2x} \xrightarrow[k \rightarrow +\infty]{} +\infty$$

- independentes

Vamos obter a distribuição a posteriori de:

$$\theta = (u_x, u_y) \quad z = (x, y) = (z_1, \dots, z_m, y_1, \dots, y_n)$$

$$\pi(\theta|z) \propto f(z|\theta) \cdot \pi(\theta)$$

$$\propto \sup \left\{ -\frac{1}{2b_x^2} \sum_{i=1}^m (z_i - \mu_x)^2 - \frac{1}{2b_y^2} \sum_{j=1}^n (y_j - \mu_y)^2 - \frac{1}{2b_{1x}^2} (u_x - \mu_x)^2 - \frac{1}{2b_{2x}^2} (u_y - \mu_y)^2 \right\}$$

(mesmo procedimento para outras variáveis)

Então $\theta|z$ é uma nova variável

$$u_x|z \sim N \left(\frac{m\bar{z}/b_x^2 + \mu_x/b_x^2}{m/b_x^2 + 1/b_x^2}; \frac{1}{m/b_x^2 + 1/b_x^2} \right)$$

$$u_y|y \sim N \left(\frac{m\bar{y}/b_y^2 + \mu_y/b_y^2}{m/b_y^2 + 1/b_y^2}; \frac{1}{m/b_y^2 + 1/b_y^2} \right) \quad \text{vêm independentes}$$

O estimador de Bayes de $\Lambda = \mu_y - \mu_x = g(\theta)$ com $\theta = (u_x, u_y)$ para grande quantidade é:

$$\begin{aligned} S_{\Delta b_{1x}, \Delta b_{2x}}(z) &= E(g(\theta)|z) = \int g(\theta) \pi(\theta|z) d\theta = \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (\mu_y - \mu_x) \pi(u_x, u_y | z) du_x du_y = \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \mu_y \pi(u_x|z) \cdot \pi(u_y|y) du_x du_y - \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \mu_x \pi(u_x|z) \cdot \pi(u_y|y) du_x du_y \\ &= E(\mu_y|y) - E(\mu_x|z) = \frac{n\bar{y}/b_y^2 + \mu_x/b_x^2}{n/b_y^2 + 1/b_x^2} - \frac{m\bar{x}/b_x^2 + \mu_x/b_x^2}{m/b_x^2 + 1/b_x^2} \end{aligned}$$

23/10/2010

O risco de Bayes de $\delta_{\Delta b_{1x}, \Delta b_{2x}}$ é a variação a posteriori de $g(\theta)$ entre

$$\begin{aligned} r_{\Delta b_{1x}, \Delta b_{2x}} &= \text{Var}(\bar{u}_x - \bar{u}_y|z) = \\ &= \text{Var}(\bar{u}_x|z) + \text{Var}(\bar{u}_y|z) = \frac{1}{m+1} + \frac{1}{n+1} \\ &\quad \frac{\bar{u}_x^2}{b_x^2} \cdot \frac{\bar{u}_y^2}{b_y^2} \end{aligned}$$

Portanto temos que

$$r_{\Delta b_{1x}, \Delta b_{2x}} \xrightarrow[b_{1x}, b_{2x} \rightarrow +\infty]{} \frac{\bar{u}_x^2}{m} + \frac{\bar{u}_y^2}{n}$$

Calculando o risco de $\bar{y} - \bar{x}$ para $\Lambda = \mu_y - \mu_x$

$$R(\Delta, \bar{y} - \bar{x}) = E[(\bar{y} - \bar{x} - \Lambda)^2] =$$

$$= E[(\bar{y} - \mu_y - (\bar{x} - \mu_x))^2] = E[(\bar{y} - \mu_y - (\bar{x} - \mu_x))^2] =$$

$$= E[(\bar{y} - \mu_y)^2] - 2E[(\bar{y} - \mu_y)(\bar{x} - \mu_x)] + E[(\bar{x} - \mu_x)^2] =$$

$$= E[(\bar{y} - \mu_y)^2] - 2E[(\bar{y} - \mu_y)(\bar{x} - \mu_x)] + E[(\bar{x} - \mu_x)^2] = 0$$

$$= \text{Var}(\bar{y}) - 2E[(\bar{y} - \mu_y) \cdot E(\bar{x} - \mu_x)] + \text{Var}(\bar{x}) = \frac{\bar{u}_y^2}{n} + \frac{\bar{u}_x^2}{m}$$

Então \bar{u}_y
independente \bar{u}_x é independente
de $\Lambda = \mu_y - \mu_x$

$$\text{Portanto } R(\Delta, \bar{y} - \bar{x}) = \frac{\bar{u}_y^2}{n} + \frac{\bar{u}_x^2}{m}$$

Tudo c:

Para a variação de distribuições a priori
 $\{\Delta_{b_{1x}}, \Delta_{b_{2x}}\}$ com riscos de Bayes.

23/10/2010

$$r_{\Delta_{B2R}, \Delta_{B2R}} = \frac{1}{\sqrt{x^2} + \frac{1}{b_{xR}^2}} + \frac{1}{\sqrt{y^2} + \frac{1}{b_{yR}^2}}$$

$$\lim_{\substack{b_{xR} \rightarrow +\infty \\ b_{yR} \rightarrow +\infty}} r_{\Delta_{B2R}, \Delta_{B2R}} = \frac{\sqrt{x^2}}{m} + \frac{\sqrt{y^2}}{n}$$

E para $\delta = \bar{y} - \bar{x}$ estimador de $\Lambda = My - ux$ temos que

$$\sup_{\Delta} R(\Delta, \delta) = \frac{\bar{y}^2}{m} + \frac{\bar{x}^2}{n}$$

então $\delta = \bar{y} - \bar{x}$ é minimax.

10)

que $\bar{y} - \bar{x}$ é estimador minimax de Λ quando $\bar{x}_j^2 \leq M_{y_j}$, sendo $M_x > 0$ e $M_y > 0$ constantes conhecidas.

se:

$$= (u_x, u_y, \bar{x}_x^2, \bar{y}_y^2), u_x \in \mathbb{R}, u_y \in \mathbb{R}, 0 \leq \bar{x}_x^2 \leq M_x, 0 \leq \bar{y}_y^2 \leq M_y,$$

$M_x > 0$ e $M_y > 0$ constantes conhecidas

$\bar{y} - \bar{x}$ é um estimador minimax de $\Lambda = My - ux$

\bar{x}_x^2 e \bar{y}_y^2 são constantes positivas fixadas ou seja, quando o parâmetro é de forma:

$$\theta = (u_x, u_y, \bar{x}_x^2, \bar{y}_y^2), u_x \in \mathbb{R}, u_y \in \mathbb{R}, \bar{x}_x^2 = M_x \text{ e } \bar{y}_y^2 = M_y,$$

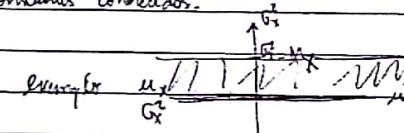
M_x e M_y constantes positivas conhecidas }

nota-se que $\Lambda \in G\Lambda$ e ainda:

$$\sup_{\theta \in G\Lambda} R(\theta, \delta) = \frac{\bar{y}^2}{m} + \frac{\bar{x}^2}{n} = \frac{M_y}{m} + \frac{M_x}{n} = \sup_{\theta \in G\Lambda} R(\theta, \delta) \quad (\text{lema p-133})$$

notas de aula)

de modo, $\delta = \bar{y} - \bar{x}$ é também minimax quando θ varia em $G\Lambda$, será também minimax para $\bar{x}_x^2 \leq M_x$ e $\bar{y}_y^2 \leq M_y$, de $M_y > 0$ constantes conhecidas.

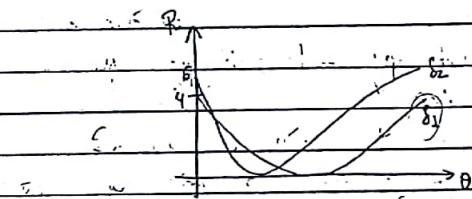


23/10/2010

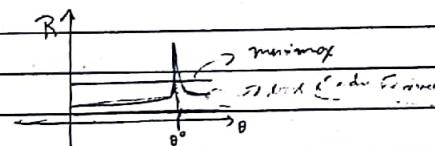
13. Prove ou dé contra-exemplo.

(a) Se um estimador minimax é único, então ele é admissível.

Contra exemplo:



No exemplo, o estimador minimax seria dado por $\hat{\theta}_1$, por ser aquele que apresenta o menor risco máximo e, além disso, ele é único, porém, nota-se que ele não é admissível para todo θ , existem valores de θ_2 onde o risco é menor do risco de $\hat{\theta}_1$, então $\hat{\theta}_1$ não é admissível.



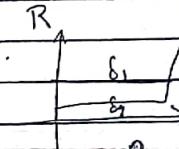
$\hat{\theta}_2$ não é admissível

$$R(\theta, \hat{\theta}_1) \leq R(\theta, \hat{\theta}_2)$$

$$R(\theta^*, \hat{\theta}_1) < R(\theta^*, \hat{\theta}_2)$$

$$R(\hat{\theta}_1, \theta) \leq R(\hat{\theta}_2, \theta)$$

Existe θ^* tal que $R(\hat{\theta}_1, \theta^*) < R(\hat{\theta}_2, \theta^*)$



SÁO DOMINGOS

23/10/2010

(b) Um estimador minimax não pode ser não viável.

Contra exemplo: notas de aula p. 164 estimador minimax

Binomial com priori Beta.

O estimador minimax é dado por:

$$\hat{\theta} = \frac{X + \frac{1}{2}}{n + 1} = \frac{X}{n + 1} + \frac{1}{2}$$

Vizinho de $\hat{\theta}$:

viável não viável
↓
um vício vício = $\hat{\theta}$

$$E_p(\hat{\theta}) - p = \frac{p\sqrt{n}}{n+1} + \frac{1}{2} - p \xrightarrow{n \rightarrow \infty} 0$$

viciado!

$$= \frac{1}{2} \frac{1}{1+\sqrt{n}} + \left(\frac{\sqrt{n}}{1+\sqrt{n}} - 1 \right) p$$

vício

Observação:

O estimador para os minimos devem ser não viáveis no caso de vício independente do parâmetro (exercício 15)

25/10/2020

(2) Se um estimador tem risco constante e é admissível, ele é minimax.

Se um estimador tem risco constante, então:

$$R(\theta, \delta) = \sup_{\theta} R(\theta, \delta) \quad (1)$$

Se δ é admissível, isso significa que o risco dele é menor do que o risco de qualquer outro estimador, ou ainda que o risco de δ é estatisticamente menor que o risco de algum outro estimador, em outras palavras, se é aquele que fornece o menor risco.

No con, se δ é com dada em (1), se δ for admissível, ele será aquele que minimizará o maior dos riscos, ou seja,

$$\inf_{\delta} \sup_{\theta} R(\theta, \delta) = \sup_{\theta} R(\theta, \delta^M);$$

Então δ^M não é minimax.

23/10/2020

Se δ é um estimador de Bayes (respectivamente NIVUM, minimax, admissível) de $g(\theta)$ sob forma quadrática. Então, $a\delta+b$ é um estimador de Bayes (respectivamente NIVUM, minimax, admissível) de $a g(\theta)+b$. Aqui, a e b são números reais.

Bayes

O estimador de Bayes é aquela que minimiza o risco médio, dado por:

$$E_{\theta} (R(g(\theta), \delta)) = \int \underbrace{R(g(\theta), \delta)}_{(1)} \pi(\theta) d\theta$$

Para o problema em questão, tem-se que:

$$R(a g(\theta) + b, a\delta + b) - E \left(L(a g(\theta) + b, a\delta + b) \right) = \text{fundo quadrático}$$

$$= E \left[a\delta + b - (a g(\theta) + b) \right]^2 = E \left[(a\delta + b - a g(\theta) - b)^2 \right] =$$

$$= E \left[a \cdot \left(\delta - g(\theta) \right)^2 \right] = E \left(a^2 \cdot (\delta - g(\theta))^2 \right) = a^2 E (\delta - g(\theta))^2 =$$

$$= a^2 \cdot E (L(g(\theta), \delta)) = a^2 \cdot R(g(\theta), \delta)$$

\hookrightarrow estimador de Bayes

NIVUM

$$\begin{aligned} \text{Var}(a\delta + b) &= \text{Var}(a\delta) = a^2 \text{Var}(\delta) \stackrel{\text{NIVUM}}{\leq} a^2 \text{Var}(\delta'), \quad \forall \delta' \text{ não viável para } g(\theta) \\ &= \text{Var}(a\delta' + b), \quad \forall \delta' \text{ não viável para } g(\theta) \\ &= a^2 \text{Var}(\delta') + a^2 b^2 = a^2 \cdot \text{NIVUM para } a g(\theta) + b \end{aligned}$$

Minimax

$$R(a g(\theta) + b, a\delta + b) - a^2 R(g(\theta), \delta)$$

$$\sup_{\theta} R(a g(\theta) + b, a\delta + b) = \sup_{\theta} a^2 R(g(\theta) + \delta) \stackrel{\text{le minimax}}{=} \sup_{\theta} a^2 R(g(\theta), \delta')$$

$$\leq \sup_{\theta} a^2 R(g(\theta), \delta') = \sup_{\theta} R(a g(\theta) + b, a\delta' + b)$$

$a\delta + b$ é minimax para $a g(\theta) + b$.

• Admíssivel

$$\begin{aligned} R(a g(\theta) + b, a \delta + b) &= a^2 R(g(\theta), \delta) \stackrel{\delta \text{ é admíssivel}}{\leq} a^2 R(g(\theta), \delta'), \forall \delta' \\ &\leq a^2 R(g(\theta), \delta'), \text{ algum } \delta' \\ &\leq R(g(\theta) + b, a \delta' + b) \end{aligned}$$

$a \delta + b$ é admíssivel para $a g(\theta) + b$

Outro modo: $\delta^*(x)$ é estimador de Bayes (ENVVUM, minimax, admíssivel) de $g(\theta)$. Isto é, $\delta^*(x)$ é um estimador de $a g(\theta) + b$, $a, b \in \mathbb{R}$, contínuo, $a \neq 0$ ($a=0$ tem o problema de estimar uma constante b , que não é mais um problema de estimação). Então podemos escrever $\delta^*(x)$ como $\delta^*(x) = a \delta(x) + b$, com $\delta(x) = \delta^*(x) - b$. Sob prenda quadrática, o risco de $\delta^*(x)$ é dado por $R(g(\theta) + b, \delta^*) = E[(a g(\theta) + b) - (a \delta(x) + b)]^2 = a^2 R(g(\theta), \delta)$

(A) Bayes O estimador de Bayes minimiza o risco médio, que no caso é igual a $a^2 R(g(\theta), \delta)$, que é minimizado por hipótese, quando $\delta = \delta^*(x)$. Isto é, $\delta^*(x) = a \delta^*(x) + b$.

(B) ENVVUM $\delta^*(x) = a \delta^*(x) + b$ é não ruim para $a g(\theta) + b$, pois, por hipótese, $E[\delta^*(x)] = 0$. Como $R(a g(\theta) + b, \delta^*) = a^2 R(g(\theta), \delta)$ e como $R(g(\theta), \delta)$ é uniformemente mínimo, por hipótese, quando $\delta = \delta^*$ $\Rightarrow \delta^*(x) = a \delta^*(x) + b$.

(C) Mínimos Sabe-se que $\inf_{\delta} \sup_{\theta} R(g(\theta), \delta) = \sup_{\theta} R(g(\theta), \delta^*)$

$$\text{Mas } R(a g(\theta) + b, \delta^*) = a^2 R(g(\theta), \delta)$$

$$\text{Portanto: } \inf_{\delta} \sup_{\theta} R(a g(\theta) + b, \delta^*) = a^2 \sup_{\theta} R(g(\theta), \delta) = a^2 \sup_{\theta} R(g(\theta), \delta^*)$$

$$\text{Portanto, } \boxed{\delta^*(x) = a \delta^*(x) + b}$$

① Admíssivel

$\delta^*(x)$ é admíssivel para $g(\theta)$ se e somente se $R(g(\theta), \delta^*(x)) \leq R(g(\theta), \delta(x)) \quad \forall \theta \in \mathbb{H}$

$$\Leftrightarrow a^2 R(g(\theta), \delta^*(x)) \leq a^2 R(g(\theta), \delta(x))$$

Assim, $\forall \theta \in \mathbb{H}$, $R(a g(\theta) + b, a \delta^*(x) + b) \leq R(a g(\theta) + b, a \delta(x) + b)$

porque, por hipótese, $a^2 R(g(\theta), \delta^*(x)) \leq a^2 R(g(\theta), \delta(x))$.

$\hat{\theta}$ é um estimador não ruim de um parâmetro $\theta \in \mathbb{R}$.

se o estimador $\hat{\theta} + c$ não é minimax sob prenda quadrática, que $\sup_{\theta \in \mathbb{R}} R(\theta, \hat{\theta}) = \infty$ para todo estimador $\hat{\theta}$.

O é uma constante conhecida e $R(\theta, \hat{\theta})$ é o risco do estimador $\hat{\theta} + c$ é minimax sob prenda quadrática $\Rightarrow \sup_{\theta \in \mathbb{R}} R(\theta, \hat{\theta} + c) = \infty$

$$\hat{\theta} = \theta \quad \theta \in \mathbb{R}$$

$$\hat{\theta} + c = E(\theta) + E(c) = \theta + c \quad \text{Viz. } (\hat{\theta} + c) = E(\hat{\theta} + c) - \theta = c$$

$$= (\hat{\theta} + c - \theta)^2$$

$$\therefore c = E((\hat{\theta} + c - \theta)^2) = E((\hat{\theta} + c - \theta)^2) =$$

$$(\hat{\theta} - \theta + c)^2 = -R(\theta, \hat{\theta}) + c^2.$$

$\hat{\theta} + c$ é minimax sob prenda quadrática $\Rightarrow \sup_{\theta \in \mathbb{R}} R(\theta, \hat{\theta} + c) = \infty$

c é minimax sob prenda quadrática, então:

$$\inf_{\theta} \sup_{\theta \in \mathbb{R}} R(\theta, \hat{\theta}) = \sup_{\theta \in \mathbb{R}} R(\theta, \hat{\theta} + c)$$

então

$$\begin{aligned} R(\theta, \hat{\theta} + c) &= R(\theta, \hat{\theta}) + c^2 < \infty \\ &= \infty \end{aligned}$$

$R(\theta, \hat{\theta} + c) < \infty \Rightarrow \hat{\theta} + c$ não é minimax, pode existir um outro que tenha risco menor

$$R(\theta, \hat{\theta} + c) = \infty \Rightarrow \hat{\theta} + c$$
 não é minimax, pois ele só maximiza o risco máximo

23/10/2010

$\left(\Leftarrow\right) \sup_{\theta \in \mathbb{R}} R(\theta, \tilde{\theta}) = \infty \Rightarrow \hat{\theta} + c \text{ é minimax}$
sob judeo quocetim

Se $\sup_{\theta \in \mathbb{R}} R(\theta, \tilde{\theta}) = \infty \forall \tilde{\theta}$, então o $\tilde{\theta}$ pode ser

um particular $\hat{\theta} + c$, portanto, $\hat{\theta} + c$ é minimax.

Outra forma:

Siga $\hat{\theta}$ estimador não viésado de $\theta \Rightarrow E(\hat{\theta}) = \theta$.

$\sup_{\theta} R(\theta, \tilde{\theta}) = \infty \forall \tilde{\theta}$ estimador $\Leftrightarrow \hat{\theta} + c$ é minimax

Definição: \hat{s} estimador é minimax $\Rightarrow \inf_{\tilde{\theta}} \sup_{\theta} R(\theta, \tilde{\theta}) = \sup_{\theta} R(\hat{s}, \theta)$

\Rightarrow Pela hipótese $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty \forall \tilde{\theta} \Rightarrow \inf_{\tilde{\theta}} \sup_{\theta} R(\theta, \tilde{\theta}) = \infty$.

Se $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty$ para todo $\tilde{\theta}$ então um particular para

$\hat{\theta} + c \in \sup_{\theta} R(\theta, \hat{\theta} + c) = \infty$ que é igual ao $\inf_{\tilde{\theta}} \sup_{\theta} R(\theta, \tilde{\theta})$

então $\hat{\theta} + c$ é minimax.

$\left(\Leftarrow\right) [\hat{\theta} + c \text{ é minimax} \Rightarrow \sup_{\theta} R(\theta, \tilde{\theta}) = \infty \forall \tilde{\theta}] \Leftrightarrow$

\Leftrightarrow [Se $\sup_{\theta} R(\theta, \tilde{\theta}) < \infty$ para algum $\tilde{\theta} \Rightarrow \hat{\theta} + c$ não
é minimax]

Temos que:

$$\begin{aligned} R(\theta, \hat{\theta} + c) &= E[(\hat{\theta} + c - \theta)^2] = \\ &= E[(\hat{\theta} - \theta)^2 + 2(\hat{\theta} - \theta)c + c^2] \\ &= R(\theta, \hat{\theta}) + 2E(\hat{\theta} - \theta)c + c^2 \\ &= R(\theta, \hat{\theta}) + c^2 > R(\theta, \hat{\theta}) \quad (\mu R(\theta, \hat{\theta}) < \infty) \\ \therefore \text{intão } \sup_{\theta} R(\theta, \hat{\theta} + c) &> \sup_{\theta} R(\theta, \hat{\theta}) \quad (i) \end{aligned}$$

$\sup_{\theta} R(\theta, \hat{\theta} + c) = \infty$ então não é minimax pois, por

existir $\tilde{\theta}$ tal que $\sup_{\theta} R(\theta, \tilde{\theta}) < \infty$. logo $\hat{\theta} + c$ não
é risco máximo.

$\sup_{\theta} R(\theta, \hat{\theta} + c) < \infty$ então não é minimax pois,

$\sup_{\theta} R(\theta, \hat{\theta} + c) > \sup_{\theta} R(\theta, \tilde{\theta})$, logo

$\hat{\theta} + c$ não minimiza o risco máximo

Central do teorema:

$$s_1 = \hat{\theta} \quad s_2 = \hat{\theta} + c$$

$$s_1^2 = \text{Var}(\hat{\theta}) + c^2 = \text{Risco}(\hat{\theta} + c)$$

$$s_2^2 = \text{Var}(\hat{\theta}) = \text{Risco}(\hat{\theta})$$

$$s_1^2 > s_2^2$$

$$c^2 > 0$$

$$\sup_{\theta} R(s_2, \theta) = \sup_{\theta} R(s_1, \theta) + c^2$$

o risco de s_2 é sempre maior

que o de s_1 , então ele não

é minimax armenos que-

$$\sup_{\theta} R(s_2, \theta) = \sup_{\theta} R(s_1, \theta) + c^2$$

25/10/2010

11. Suponha que X tem distribuição $b(p, n)$ e considere o problema de estimar p com perda $(d-p)^2$. Obtenha o estimador minimox.

$$p(1-p)$$

$$X \sim b(n, p)$$

$$f(x|p) = \binom{n}{x} p^x (1-p)^{n-x} \quad x=0, 1, \dots, n$$

Tentarmos a priori: $U(0, 1)$

$$\pi(p) = 1 \cdot I_{(0,1)}(p)$$

Então, a distribuição à posteriori será dada por:

$$\begin{aligned} \pi(p|x) &\propto f(x|p) \cdot \pi(p) \\ &\propto \binom{n}{x} p^x (1-p)^{n-x} I_{(0,1)}(p) \end{aligned}$$

$$\propto p^x (1-p)^{n-x} I_{(0,1)}(p) \propto p^{(x+1)-1} (1-p)^{n-x+(1-1)}$$

$$p|x \sim \text{Beta}(x+1, n-x+1)$$

Desse modo, sob a perda $(d-p)^2$; tem-se que $w(p) = 1$ e $g(p) = p$ e então o estimador de Bayes é $\hat{p}(1-p)$ (um dado p):

$$\begin{aligned} * S_n(x) - E_p[w(p) \cdot g(p) | X=x] &= E_p \left[\frac{1}{g(p)} \cdot p | X=x \right] \\ &= E_p \left[\frac{1}{p} | X=x \right] = E_p \left[\frac{1}{p} \mid X=x \right] \\ &= \frac{1}{1-p} \int_0^1 \frac{1}{p} \cdot \frac{1}{r(x+1) \cdot r(n-x+1)} \cdot p^{(x+1)-1} (1-p)^{n-x+(1-1)} dp \\ &= E_p \left[\frac{1}{p} | X=x \right] = \int_0^1 \frac{1}{p} \cdot \frac{1}{r(x+1+n-1)} \cdot p^{(x+1)-1} (1-p)^{n-x+(1-1)} dp \\ &= \int_0^1 p^2 (1-p)^{n-x-1} dp \\ &= \int_0^1 p^{x-1} (1-p)^{n-x-1} dp \end{aligned}$$

$$\begin{aligned} &= \int_0^1 p^{x-1} (1-p)^{n-x-1} dp \\ &= \frac{1}{r(x+1) \cdot r(n-x+1)} \int_0^1 p^{x-1} (1-p)^{n-x-1} dp \\ &= \frac{1}{r(n)} \int_0^1 p^{x-1} (1-p)^{n-x-1} dp \\ &= \frac{1}{r(x)} \int_0^1 p^{x-1} (1-p)^{n-x-1} dp \\ &= \frac{1}{r(n)} = \frac{x \cdot r(x+1) \cdot r(n-x)}{n} = x \\ &= \frac{1}{n} \int_0^1 p^{x-1} (1-p)^{n-x-1} dp \\ &= \frac{1}{n} S_n(x) = \frac{X}{n} \end{aligned}$$

$$E_p(S_n(x)) = E_p \left(\frac{1}{n} (S_n(x) - p)^2 \right) =$$

$$E_p((S_n(x) - p)^2) = \frac{1}{n^2} [\text{Var}_p(S_n(x)) + \text{Var}_{\pi(p)}(S_n(x))] =$$

$$[\text{Var}_p(X) + [E_p(X) - p]^2] =$$

$$\left[\frac{1}{n^2} \text{Var}_p(X) + \left[\frac{1}{n} E_p(X) - p \right]^2 \right] = \frac{1}{n^2} \cdot \left[\frac{1}{n} \sum p_i (1-p_i) + \right]$$

$$\left[\frac{1}{n} \cdot \frac{\sum p_i}{n} \right]^2 = \frac{1}{n^2} \cdot \frac{\sum p_i (1-p_i)}{n} = \frac{1}{n} \quad \text{que independe de } p \quad (\text{o ruído é fixo})$$

$$S_n(x) = \frac{X}{n} \quad \text{é um estimador minimox}$$

corolário: Se a solução de Bayes S_n tem ruído constante, minimox)

Obs: Para numero (k) é necessário mostrar que a probabilidade χ ,
correspondente à soma de k eventos, é menor que

$$E\left[\chi(d,p) | \chi=k\right] = \int_0^1 (d-p)^k \frac{1}{p} p^{n-k} (1-p)^{m-k} dp <$$

$\frac{p(n,m)}{p(n,k,n-k)} \int_0^1 (d-p)^k \frac{1}{p} p^{n-k} (1-p)^{m-k} dp$, que é
menor que 1 quando $d E(p|X) = \frac{k}{m+k} < \frac{k}{m}$.

(/ /)
Definição: Ora definindo P -valor

Operador: Operador S (Null-Hip), Operador T (Alternative)

Contingência: Teste de contingência que depende sobre H_0 ou H_1

Fatores: { Nossa hipótese hipótese H_0
necessariamente para a hipótese H_1

Regras: Regra de decisão entre duas hipóteses H_0 e H_1 .
Ésta regra: I. II.
Poder do teste.

O objetivo é obter a hipótese que defina o teste de menor risco de tipo I.
Definir risco de tipo I

(1) a probabilidade é dada a hipótese verdade de obter os dados em virtude da distribuição

(2) O menor risco de hipóteses é dada a hipótese verdadeira que os resultados observados nos dados de amostra

Validação e profunidade do teste p . (estatística de Fisher)

Seja X uma variável de teste estatístico, a qual se distribuiu dependendo de um risco α (α é o risco). Um risco é a probabilidade de rejeitar a hipótese H_0 quando esta é verdadeira. Se a hipótese H_0 é verdadeira, a probabilidade de obter resultados que contradizem a hipótese é dada por p . A correspondente probabilidade de obter resultados que contradizem a hipótese é dada por $1 - p$. A menor probabilidade é dada por p .

Consideremos o problema de teste. H: H_0 e H_1

Fisher define riscos como hipóteses nulas de uma probabilidade de risco. O conceito de risco p não define de forma precisa hipóteses que consideram probabilidades contínuas, e é dado por

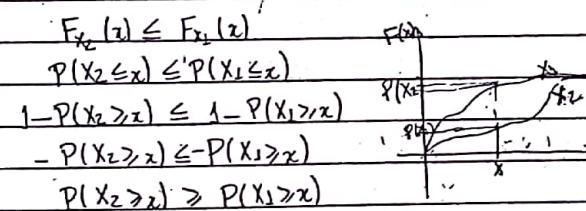
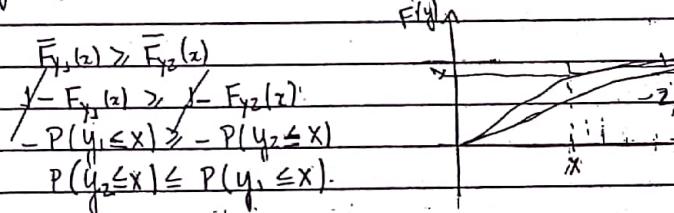
$$P(t) = \sup_{\theta \in \Theta_0} [1 - P_\theta(T < t)] = \sup_{\theta \in \Theta_0} P_\theta(T > t)$$

Em que T é uma estatística $\Rightarrow t$ o valor observado da estatística a partir da amostra

Para a parametrização a ser feita sobre valor P , devemos definir a idéia de "ordenação" estatística de variáveis aleatórias

Dada F_Y denotando a função de distribuição de uma variável aleatória Y e $\bar{F}_Y = 1 - F_Y$.

Definição. Uma variável aleatória Y_2 é dita "estatisticamente maior do que" Y_1 ($Y_1 > Y_2$) se $\bar{F}_{Y_1}(z) \geq \bar{F}_{Y_2}(z)$, $\forall z \in \mathbb{R}$



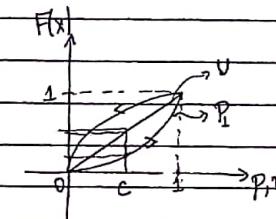
No contexto de valor P , vamos considerar o caso em que X é uma variável aleatória absolutamente contínua, parametrizando pelo parâmetro θ , a função de distribuição $F(x|\theta)$ com a correspondente função de densidade dada por $f(x|\theta)$. Representamos por $X \sim f(\cdot|\theta)$.

II

Um valor y para teste. No seu momento $P = x \rightarrow [0,1]$ um valor x é:

$$P > U \text{ para } \theta \in \Theta_0$$

$$P \leq U \text{ para } \theta \in \Theta_1$$



$$P > U \Rightarrow F_p(c) \leq F_U(c)$$

$$\text{para } \theta \in \Theta_0$$

$$1 - P(P > c) \leq 1 - P(U > c)$$

$$-P(P > c) \leq -P(U > c)$$

$P(P > c) \geq P(U > c)$ P é estatisticamente maior que U .

$$P \leq U \Rightarrow F_p(c) > F_U(c)$$

$$\text{para } \theta \in \Theta_1$$

$$1 - P(P > c) \geq 1 - P(U > c)$$

$$-P(P > c) \geq -P(U > c)$$

$$P(P > c) \leq P(U > c)$$

$$P(X > c) \geq P(Y > c)$$

$X > Y$



$$P(X < c) \geq P(Y < c)$$

$X \leq Y$

$$X \text{ é estatisticamente maior que } Y \quad P(X < 5) > P(Y < 5)$$

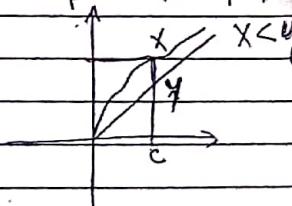
maior que y

50%

10%

aprox.

X é mais provável de acontecer do que y



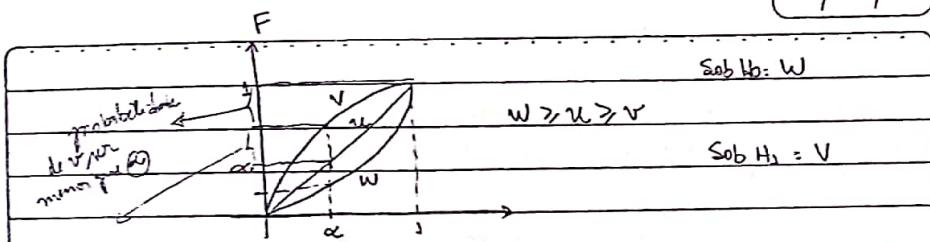
$X < y$

3815-1098

correr para grande
espera de retorno da

II

II

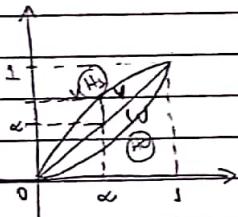


$$P(W < \alpha) < P(U < \alpha)$$

$$U < W$$

lede do teste Teorema 2.

$$P_{\theta_0} E_{\theta_0} (\phi P(X)) = P_{\theta_0} (P(X) < \alpha) \geq \alpha$$



$P(\text{Erro I}) \leq \alpha$, no tipo I - Rejeita H_0 falso

$$E_{\theta_0} (\phi P(X)) \leq \alpha$$

$$P_{\theta_0} (P(X) < \alpha) \leq \alpha$$

$$P_{\theta_0} (P(X) < \alpha) \geq \alpha \quad (\text{no tipo II})$$

MAE 5834 - Estatística Avançada I

Lista de Exercícios 4 - 2º semestre de 2005 - Prof. Silvia L.P. Ferrari

1

NÃO ENTRAR

- 1) Seja X uma variável aleatória com distribuição binomial de parâmetros n e p . Considere uma distribuição a priori beta de parâmetros α e β para p .

(a) Encontre o estimador de Bayes δ de $p(1-p)$ sob perda quadrática.

(b) Encontre o ENVVUM de $p(1-p)$ e compare os estimadores δ e δ' .

(c) Mostre que a distribuição marginal de X é beta-binomial com função de probabilidade

$$\binom{n}{x} \frac{\Gamma(\alpha+b)}{\Gamma(\alpha)\Gamma(b)} \frac{\Gamma(x+\alpha)\Gamma(n-x+b)}{\Gamma(n+\alpha+b)}.$$

(d) Mostre que a média e a variância da distribuição beta-binomial são

$$E(X) = \frac{na}{a+b} \quad \text{e} \quad \text{var}(X) = n \frac{a}{a+b} \frac{b}{a+b} \frac{a+b+n}{a+b+1}.$$

Sugestão: Use o fato de que $E(X) = E(E(X|p))$ e $\text{var}(X) = \text{var}(E(X|p)) + E(\text{var}(X|p))$.

- 2) Seja X uma variável aleatória representando o tempo de vida de um sistema eletrônico, com função distribuição acumulada $F_\theta(x)$, $\theta \in \mathbb{R}$. Defina a confiabilidade do sistema por

$$R_\theta(\tau) = P_\theta(X > \tau) = 1 - F_\theta(\tau), \quad \tau > 0.$$

Considere n observações independentes X_1, \dots, X_n de X . Admita que, dado θ , X tem distribuição exponencial de parâmetro θ e função densidade de probabilidade

$$f(x|\theta) = \theta \exp(-\theta x), \quad x > 0; \quad \theta > 0.$$

Mostre que o estimador de Bayes de $R_\theta(\tau)$ sob perda quadrática e função densidade a priori para θ

$$\pi(\theta) = \frac{1}{\gamma^\nu \Gamma(\nu)} \theta^{\nu-1} \exp(-\theta/\gamma), \quad \theta > 0,$$

é dado por

$$\left(1 + \frac{\tau}{\sum_{i=1}^n X_i + 1/\gamma}\right)^{-(\nu+1)}.$$

- 3) Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes e identicamente distribuídas segundo uma distribuição $N(0, \sigma^2)$. Considere a função de perda $L(\sigma^2, d) = (d/\sigma^2 - 1)^2 = (d - \sigma^2)^2/\sigma^4$.

(a) Considere uma distribuição a priori $\text{Gama}(\alpha, b)$ para $\theta = 1/(2\sigma^2)$ com densidade

$$\pi(\theta) = \frac{1}{\Gamma(a)b^a} \theta^{a-1} \exp\{-\theta/b\}; \quad a > 0, \quad b > 0.$$

Encontre o estimador de Bayes de σ^2 .

(b) Mostre que $\delta(X) = \sum_{i=1}^n X_i^2/(n+2)$ é um estimador minimax de σ^2 .

Folha

(c) Mostre que $\delta(X)$ tem risco uniformemente menor ou igual aos de todos os estimadores da forma $c \sum_{i=1}^n X_i^2$.

(d) Mostre que o estimador de máxima verossimilhança é inadmissível.

Sejam X_1, \dots, X_n uma amostra aleatória da distribuição de Poisson de média λ . Considere uma distribuição a priori $\Gamma(\alpha, \beta)$ (ver Tabela 5.1, p.25, TPE) para λ .

(a) Encontre o estimador de Bayes $\delta_{\alpha, \beta}$ de λ sob perda quadrática.

(b) O que ocorre com $\delta_{\alpha, \beta}$ quando (i) $n \rightarrow \infty$, (ii) $\alpha \rightarrow 0$, $\beta \rightarrow \infty$, ou ambos?

(c) Encontre o viés e o viés máximo do estimador $\delta_{\alpha, \beta}$.

- 4) Sejam X_1, \dots, X_n uma amostra aleatória da distribuição de binomial negativa $bn(p, m)$. Considere uma distribuição a priori Beta(α, β) para p .

(a) Encontre o estimador de Bayes $\delta_{\alpha, \beta}$ de p sob perda quadrática.

(b) Encontre o viés e o viés máximo do estimador $\delta_{\alpha, \beta}$.

- 5) Sejam X e Y variáveis aleatórias independentes com distribuições P_ζ e Q_η , respectivamente. Suponha que ζ e η são consideradas variáveis aleatórias independentes, reais, com distribuições Λ e Λ' respectivamente. Se, com perda quadrática, δ_Λ é o estimador de Bayes de ζ com base em X e $\delta_{\Lambda'}$ é o estimador de Bayes de η com base em Y ,

(a) mostre que $\delta_{\Lambda'} - \delta_\Lambda$ é o estimador de Bayes de $\eta - \zeta$ com base em (X, Y) .

(b) Se $\eta > 0$ e δ_Λ é o estimador de Bayes de $1/\eta$ com base em Y , mostre que $\delta_\Lambda - \delta_{\Lambda'}$ é o estimador de Bayes de ζ/η com base em (X, Y) .

- 6) Suponha que X tenha distribuição binomial $b(\theta, n)$. Considere uma distribuição a priori Beta(α, β) com $a = b = 0$ (priori imprópria) e a perda quadrática. Considere estimadores δ que satisfazem $\delta(0) = 0$ e $\delta(n) = 1$. Mostre que o risco a posteriori é minimizado em $\delta(x) = x/n$. [Ver Exemplo 2.8, p. 238-239, TPE].

- 7) Suponha que, dado $\Theta = \theta$, X_1, \dots, X_n sejam variáveis aleatórias independentes com distribuição uniforme no intervalo $(0, \theta)$. Admita que $1/\theta$ tem distribuição Gama(a, b) (a e b conhecidos).

(a) Verifique que o estimador de Bayes só depende dos dados através de $Y = \max_i X_i$.

(b) Mostre que

$$E(\Theta|y, a, b) = \frac{1}{b(n+a-1)} \frac{P(X_{2(n+a-1)}^2 < 2/by)}{P(X_{2(n+a)}^2 < 2/by)}.$$

- 8) Suponha que, dados θ e σ^2 , X_1, \dots, X_n sejam variáveis aleatórias independentes com distribuição $N(\theta, \sigma^2)$. Admita que, a priori, $\tau = 1/(2\sigma^2)$ tem distribuição Gama($g, 1/\alpha$) e θ , independente de τ , tem distribuição uniforme (imprópria) na reta.

(a) Mostre que a densidade conjunta a posteriori é proporcional a $\tau^{r+g-1} e^{-\tau[\alpha+z+n(z-\theta)^2]}$ onde $z = \sum (x_i - \bar{x})^2$ e $r = n/2$.

(b) Mostre que distribuição a posteriori de τ é Gama($r+g-1/2, 1/(\alpha+z)$).

(c) Mostre que se $\alpha = g = 0$, o estimador de Bayes (generalizado) de σ^2 é $Z/(n-3)$ para perda quadrática. Para a perda $(d - \sigma^2)^2/\sigma^4$, este estimador é $Z/(n+1)$.

- (d) Mostre que a densidade a posteriori de θ é simétrica em relação a \bar{X} e que o estimador de Bayes (generalizado) é \bar{X} .
18. Seja X uma única observação de uma variável aleatória com densidade $f(x; \theta) = 2x/\theta^2$, $0 < x < \theta$; $\theta > 0$. Considere para θ uma distribuição uniforme no intervalo unitário. Encontre o estimador de Bayes com respeito à perda $\theta^2(d - \theta)^2$.
19. Suponha que, dado p , $X \sim b(n, p)$ e considere a densidade (imprópria) proporcional a $p^{-1}(1-p)^{-1}$ para p . Mostre que X/n é um estimador de Bayes (generalizado) para p sob perda quadrática.
20. Suponha que X tem distribuição $b(p, n)$ e considere o problema de estimar p com perda quadrática. Encontre o vício do estimador minimax e discuta sua direção. (ver Exemplo 1.7, p. 311, TPE).
21. No contexto da questão acima, compare o risco do estimador minimax com o de X/n .
22. Suponha que X tem distribuição $b(p, n)$ e considere o problema de estimar p com perda $(d - p)^2/(p(1-p))$. Obtenha o estimador minimax.
23. Sejam X_1, \dots, X_n variáveis aleatórias iid com $E(X_i^2) < \infty$. Considere o problema de estimar $\mu = E(X_1)$ com perda quadrática.
- (a) Mostre que qualquer estimador da forma $a\bar{X} + b$ é inadmissível, onde $a > 1$ e b são constantes.
- (b) Mostre que qualquer estimador da forma $\bar{X} + b$ é inadmissível, onde $b \neq 0$ é uma constante.
24. Prove ou dê contra-exemplo.
- (a) Se um estimador minimax é único, então ele é admissível.
- (b) Um estimador minimax não pode ser não viciado.
- (c) Se um estimador tem risco constante e é admissível, ele é minimax.
25. Sejam X_1, \dots, X_n e Y_1, \dots, Y_n variáveis aleatórias independentes tais que $X_i \sim N(\mu, \sigma^2)$ e $Y_i \sim N(\mu, \rho\sigma^2)$, $i = 1, \dots, n$. As duas distribuições têm média comum $-\infty < \mu < \infty$ desconhecida; $\sigma^2 > 0$ é desconhecida e $0 < \rho < \infty$.
- (a) Encontre o estimador não viciado de variância uniformemente mínima de μ se ρ é conhecido.
- (b) Admita agora que ρ é desconhecido. Considere o problema de estimar μ sob perda $L(\mu, \hat{\mu}) = (\mu - \hat{\mu})^2 / (\sigma^2 \max(1, \rho))$.
- Mostre que $(\bar{X} + \bar{Y})/2$ é estimador minimax de μ . Aqui $\bar{X} = \sum_{i=1}^n X_i/n$ e $\bar{Y} = \sum_{i=1}^n Y_i/n$.
- Sugestão para (b): Considere a seqüência de estimadores de Bayes sob distribuições a priori Λ_k que atribuem probabilidade 1 a $(\sigma^2, \rho) = (1, 1)$, independentemente de μ e a μ uma distribuição $N(0, k^2)$. Encontre o estimador de Bayes de μ correspondente a Λ_k . Você pode usar, sem provar, o seguinte resultado: Se, dado ξ , Z_1, \dots, Z_n são independentes e têm distribuição $N(\xi, \sigma^2)$, e se a distribuição a priori para $\xi \in N(\zeta, b^2)$, então a distribuição a posteriori de ξ , $N(\bar{Z} + \zeta, \sigma^2)$, é normal de média $(n\bar{Z}/\sigma^2 + \zeta/b^2)/(n/\sigma^2 + 1/b^2)$ e variância $(n/\sigma^2 + 1/b^2)^{-1}$, onde $\bar{Z} = \sum_{i=1}^n Z_i/n$.

Fazendo

26. Suponha que Θ tem uma distribuição Λ , e seja P_θ a distribuição condicional de X dado θ . Considere a estimativa de $g(\theta)$ quando a função de perda é quadrática. Mostre que nenhum estimador não viciado $\delta(X)$ pode ser uma solução de Bayes a menos que

$$E[(\delta(X) - g(\theta))^2] = 0,$$

onde a esperança é tomada com respeito à variação em ambos X e Θ .

27. Seja δ um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $g(\theta)$ sob perda quadrática. Então, $a\delta + b$ é um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $ag(\theta) + b$. Aqui, a e b são números reais.

28. Seja $\hat{\theta}_\Lambda$ um estimador de Bayes com respeito a uma distribuição a priori Λ , isto é,

$$r(\Lambda, \hat{\theta}_\Lambda) = \inf_{\delta} r(\Lambda, \delta),$$

onde $r(\Lambda, \delta)$ é o risco de Bayes do estimador δ com respeito à distribuição a priori Λ . Suponha que $R(\theta, \hat{\theta}_\Lambda) \leq r(\Lambda, \hat{\theta}_\Lambda)$, para todo θ , onde $R(\theta, \delta)$ é o risco do estimador δ . Mostre que $\hat{\theta}_\Lambda$ é um estimador minimax.

$$E_\theta [E_{\delta(x)} [\delta(x) - g(\theta)]^2] = E_{\delta(x)} [E_\theta [g(\theta | x=x)]]$$

$$\begin{aligned} E_\theta (R(\theta, \delta)) &= \int_{\Theta} \left[\int_x L(\theta, \delta(x)) f(x|\theta) dx \right] \pi(\theta) d\theta = \\ &= \int_{\Theta} \left[\int_x (\delta(x) - g(\theta))^2 \pi(\theta|x) d\theta \right] q(x) dx = \\ &= E_\theta \left[L(\theta, \delta(x)) \Big| x=x \right]. \end{aligned}$$

$$\begin{aligned} E_{SM} ((\delta(x) - g(\theta))^2) &= 0 \\ E ((\delta(x))^2) - 2g(\theta) E(\delta(x)) + g^2(\theta) &= 0 \\ g(\theta) &= E(\delta(x)) \end{aligned}$$

$$\begin{aligned} E_\theta ((\delta(x) - g(\theta))^2) &= 0 \\ E^2(\delta(x)) - 2g(\theta) E(g(\theta)) + E(g^2(\theta)) &= 0 \\ g(x) &= E(g(\theta)) \end{aligned}$$

$$F_\Lambda = E_x (E_{\delta(x)} [E_\theta f(\theta) | x=x])$$

1) Seja X uma variável aleatória com distribuição binomial de parâmetros n e p . Considere uma distribuição a priori beta de parâmetros a e b para p .

(a) Encontre o estimador de Bayes δ de $p(1-p)$ sob perda quadrática:

Temos que $X/p \sim \text{Bin}(n, p) \Rightarrow p \sim \text{Beta}(a+b)$.

Logo

$$f(x|p) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x=0,1,\dots,n$$

$$\pi(p) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} p^{a-1} (1-p)^{b-1}, \quad 0 < p < 1$$

daí a posteriori π

$$\pi(p|x) \propto p^{(a+z)-1} (1-p)^{(n+b-x)-1} \quad (*)$$

Para que $\pi(p|x)$ seja uma f.d.p. temos que multiplicar $(*)$ pela constante

$$C = \frac{\Gamma(a+b+n)}{\Gamma(a+z)\Gamma(n+b-x)}$$

Daí temos que

$$\pi(p|x) \sim \text{Beta}(a+z, n+b-x) \quad 0 < p < 1$$

Usando o constante C temos

$$g(p) = p(1-p)$$

Logo, o estimador de Bayes de $g(p)$ será

$$\delta(x) = E[g(p) | X=x]$$

$$= \int_0^1 g(p) \pi(p|x) dp$$

$$= \int_0^1 p(1-p) \frac{\Gamma(a+b+n)}{\Gamma(a+z)\Gamma(n+b-x)} p^{(a+z)-1} (1-p)^{(n+b-x)-1} dp$$

$$\delta(x) = \frac{\Gamma(a+b+n)}{\Gamma(a+z)\Gamma(n+b-x)} \int_0^1 p^{a+z} (1-p)^{n+b-x} dp$$

$$\delta(x) = \frac{\Gamma(a+b+n)}{\Gamma(a+z)\Gamma(n+b-x)} \int_0^1 p^{(a+z+1)-1} (1-p)^{(n+b-x+1)-1} dp$$

$$= \frac{\Gamma(a+b+n)}{\Gamma(a+z)\Gamma(n+b-x)} \frac{\Gamma(a+z+1)\Gamma(n+b-x+1)}{\Gamma(a+b+n+2)} \int_0^1 \frac{\Gamma(a+b+n+2)}{\Gamma(a+z+1)\Gamma(n+b-x+1)} p^{(a+z+1)-1} (1-p)^{(n+b-x+1)-1} dp$$

↑ pais x + dp de
uma beta $(a+z+1, n+b-x+1)$

Logo

$$\delta(x) = \frac{\Gamma(a+b+n)}{\Gamma(a+z)\Gamma(n+b-x)} \frac{\Gamma(a+z+1)\Gamma(n+b-x+1)}{\Gamma(a+b+n+2)}$$

$$= \frac{(a+b+n-1)! (a+z)! (n+b-x)!}{(a+z-1)! (n+b-x-1)! (a+b+n+1)!}$$

$$= \frac{(a+b+n-1)! (a+z)(a+z-1)!(n+b-x)(n+b-x-1)!}{(a+z-1)!(n+b-x-1)!(a+b+n+1)(a+b+n)!}$$

$$= \frac{(a+b+n-1)! (a+z)(n+b-x)}{(a+b+n+1)(a+b+n)(a+b+n-1)!}$$

Portanto

$$\delta(x) = \frac{(a+z)(n+b-x)}{(a+b+n+1)(a+b+n)}$$

O estimador de Bayes de $g(p) = p(1-p)$ sob perda quadrática

(b) Encontre o ENVVUM de $p(1-p)$ e compare os estimadores δ e δ'

Como $X \sim \text{bin}(n, p)$ então

$$E\left[\frac{X}{n}\right] = \frac{1}{n} E(X) = \frac{np}{n} = p$$

Logo $\frac{X}{n}$ é estimador não viésado de p e $1 - \frac{X}{n}$ é estimador não viésado de $1-p$. Considere o estimador

$$\frac{X}{n} (1 - \frac{X}{n}) \text{ de } p(1-p)$$

Logo

$$\begin{aligned} E\left\{\frac{X}{n} \left(1 - \frac{X}{n}\right)\right\} &= \frac{1}{n^2} \left\{ nE(X) - E(X^2) \right\} \\ &= \frac{1}{n^2} \left\{ np - \text{var}(X) - (E(X))^2 \right\} \\ &= \frac{1}{n^2} \left\{ np - np(1-p) - np^2 \right\} \\ &= \frac{1}{n} \left\{ np - p(1-p) - np^2 \right\} \\ &= \frac{1}{n} \left\{ p(1-p) \left[\frac{n-p}{1-p} - 1 \right] \right\} \\ &= \frac{1}{n} \left\{ p(1-p) \left[\frac{n-p}{1-p} - 1 \right] \right\} \\ &= \frac{1}{n} \left\{ p(1-p) \left[n \left[\frac{1-p}{1-p} \right] - 1 \right] \right\} \\ &= \frac{1}{n} p(1-p) (n-1) = p(1-p) \cdot \frac{(n-1)}{n} \end{aligned}$$

Logo $\frac{X}{n} (1 - \frac{X}{n})$ é estimador viésado de $p(1-p)$

$$\frac{X}{n-1} \frac{X}{n} (1 - \frac{X}{n})$$

$$\text{Qua. sup. } \delta'(X) = \frac{X(n-X)}{n(n-1)} \text{ é ENVVUM de } p(1-p)$$

→ Compare os estimadores $\delta(X)$ e $\delta'(X)$

Termos visto item a)

$$\delta(X) = \frac{(a+x)(n+b-x)}{(a+b+n+1)(a+b+n)}$$

a) estatística

$$\delta'(X) = \frac{x(n-X)}{n(n-1)}$$

b) calcular o viés de $\delta(X)$:

$$\begin{aligned} E(q(p), \delta(X)) &= E\{(\delta(X) - q(p))^2\} \\ &= \text{Var}(\delta(X) - q(p)) + \{E[\delta(X) - q(p)]\}^2 \\ &= \text{Var}(\delta(X)) + \{E[\delta(X)] - q(p)\}^2 \end{aligned}$$

outra

$$\begin{aligned} \text{Var}(\delta(X)) &= \frac{1}{(a+b+n+1)^2(a+b+n)^2} \text{Var}[(a+x)(n+b-x)] \quad \text{foco } A = \frac{1}{(a+b+n+1)^2(a+b+n)^2} \\ &= \frac{1}{A} \text{Var}[an+ab-ax+nx+bx-x^2] = \frac{1}{A} \text{Var}[(b+n-a)x-x^2] \\ &= \frac{1}{A} \left\{ E\left[[(b+n-a)x-x^2]^2 \right] - [(b+n-a)E(X)-E(X^2)]^2 \right\} \\ &= \frac{1}{A} \left\{ E\left[(b+n-a)^2x^2 - 2(b+n-a)x^3 + x^4 \right] - (b+n-a)^2E^2(X) - 2(b+n-a)E(X) \right. \\ &\quad \left. \times E(X^2) + E^2(X^2) \right\} \\ &= \frac{1}{A} \left\{ (n+b-a)^2 E(X^2) - 2(n+b-a) E(X^3) + E(X^4) - (b+n-a)^2 E^2(X) - \right. \\ &\quad \left. - 2(b+n-a) E(X^2) + E^2(X^2) \right\} \\ &= \frac{1}{A} \left\{ (nfb-a)^2 \text{Var}(X) - 2(n+b-a) E(X^3) + E(X^4) - 2(b+n-a) [\text{Var}(X) + E^2(X)] \right. \\ &\quad \left. + [\text{Var}(X) + E^2(X)]^2 \right\} \end{aligned}$$

$$\text{mas } E(X) = np \quad \text{e} \quad \text{Var}(X) = np(1-p) \quad \text{Logo}$$

$$\text{Var}(S(x)) := \frac{1}{A} \left\{ (n+b-a)^2 np(1-p) - 2(n+b-a) E(X^2) + E(X^4) - 2(n+b-a)$$

$$\times [np(1-p) + n^2 p^2] + [np(1-p) + n^2 p^2]^2 \right\}$$

$$= \frac{1}{A} \left\{ (n+b-a)^2 np(1-p) - 2(n+b-a) E(X^2) + E(X^4) - 2 np(n+b-a) \times \right.$$

$$\times [1-p+np] + n^2 p^2 [1-p+np]^2 \right\}$$

Dá muita conta, a professora disse que pode somar
somente em termos de rizos

$$E[S(x)] = \frac{1}{(a+b+n)} E[(ax)(n+b-x)]$$

$$= \frac{1}{(a+b+n+1)(a+b+n)} \{ E[an+ab-ax+nx+bx-x^2] \}$$

$$= \frac{1}{(a+b+n+1)(a+b+n)} \{ an+ab - aE(x) + nE(x) + bE(x) - E(x^2) \}$$

$$= \frac{1}{(a+b+n+1)(a+b+n)} [an+ab - anp + n^2 p + bnp - np^2 - \frac{n^2 p^2}{2}]$$

$$= \frac{a(b+n) + np(-a+b+n+b) - \frac{n^2 p}{2}}{(a+b+n+1)(a+b+n)} \quad \begin{matrix} n^2 p \\ \parallel \\ n^2 p \cdot q \end{matrix}$$

$$= \frac{(n+q)(a+q) - np(a+q+2)}{(a+b+n+1)(a+b+n)}$$

$$\begin{aligned} & \frac{(b+n)(a+1) - anp - np}{(a+b+n+1)(a+b+n)} \quad \begin{matrix} np \\ \parallel \\ (a+b+n)(a+b+n) \end{matrix} \\ & (an+ab - anp + bnp) \end{aligned}$$

(c) Mostre que a distribuição marginal de X é beta-binomial com função de probabilidade

$$\binom{n}{x} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \frac{\Gamma(x+a)\Gamma(n-x+b)}{\Gamma(a+b+n)}$$

Sabemos que

$$f(z|p) = \binom{n}{z} p^z (1-p)^{n-z} \quad z = 0, 1, \dots, n, 0 < p < 1$$

$$\pi(p) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} p^{a-1} (1-p)^{b-1}, 0 < p < 1, a > 0, b > 0$$

Sabemos que

$$f(z) = \int_0^1 f(z|p) \pi(p) dp$$

$$= \binom{n}{z} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \int_0^1 p^{(a+z)-1} (1-p)^{(n+b-z)-1} dp$$

$$= \binom{n}{z} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \cdot \frac{\Gamma(z+a)\Gamma(n-z+b)}{\Gamma(a+b+n)} \int_0^1 \frac{\Gamma(a+b+n)}{\Gamma(z+a)\Gamma(n-z+b)} p^{(a+z)-1} (1-p)^{(n+b-z)-1} dp$$

I passo $\leftarrow f(p) dp$ de uma Beta($a+z, n+b-z$)

Logo

$$f(z) = \binom{n}{z} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \frac{\Gamma(z+a)\Gamma(n-z+b)}{\Gamma(a+b+n)}$$

(d) mostre que a média e a variância da distribuição são

nominal, são

$$E(X) = \frac{na}{a+b} \quad \text{e} \quad \text{Var}(X) = n \frac{a}{a+b} \frac{b}{a+b} \frac{ab+n}{a+b+1}$$

Sabemos que

$$E(X) = E\{E(X|P)\}$$

mas éramos育人假定 que

$$X|P \sim \text{bin}(p, n)$$

Logo $E(X|P) = np \quad \text{e} \quad \text{Var}(X|P) = np(1-p) \quad (*)$

Daí

$$\begin{aligned} E(X) &= E[E(X|P)] = E[np] \\ &= nE(p) \end{aligned}$$

$$\text{mas } p \sim \text{Beta}(a, b) \Rightarrow E(p) = \frac{a}{a+b} \quad \text{Logo}$$

$$E(X) = n \left(\frac{a}{a+b} \right)$$

$$\text{Temos ainda que } \text{Var}(p) = \frac{ab}{(a+b+1)(a+b)^2} \text{ ja que } p \sim \text{Beta}(a, b)$$

Sabemos também que

$$\text{Var}(X) = \text{Var}(E(X|P)) + E(\text{Var}(X|P))$$

$$\begin{aligned} &= \text{Var}[np] + E[np(1-p)] \\ &\hookrightarrow \text{de } (*) \end{aligned}$$

$$= n^2 \text{Var}(p) + nE[p - p^2]$$

$$= n^2 \left(\frac{ab}{(a+b+1)(a+b)^2} \right) + n [E(p) - E(p^2)]$$

$$\text{Var}(X) = \frac{n^2 ab}{(a+b+1)(a+b)^2} + \frac{na}{a+b} - n [Var(p) + E(p^2)]$$

$$= \frac{n^2 ab}{(a+b+1)(a+b)^2} + \frac{na}{a+b} - \frac{ab}{(a+b+1)(a+b)^2} - \frac{na^2}{(a+b)^2}$$

$$= \frac{na}{(a+b+1)(a+b)^2} (n-1) + \frac{na(a+b) - na^2}{(a+b)^2}$$

$$= \frac{n(n-1)ab + na(a+b)(a+b+1) - na^2(a+b+1)}{(a+b+1)(a+b)^2}$$

$$= \frac{nab - ab + a(a+b)(a+b+1) - a^2(a+b+1)}{(a+b+1)(a+b)^2} \times n$$

$$= \frac{n}{(a+b+1)(a+b)^2} \{ nab - ab + a^2 + ab^2 + 2a^2b + ab^2 + ab - a^2b - a^2 \}$$

$$= \frac{n}{(a+b+1)(a+b)^2} \{ nab + a^2b^2 + a^2b \} = \frac{nab}{(a+b+1)(a+b)^2} [n+b+a]$$

$$= n \frac{a}{a+b} \frac{b}{a+b} \frac{n+b+a}{a+b+1}$$

2) Seja X uma v.a. representando o tempo de vida de um sistema eletrônico, com função distribuição acumulada $F_0(x)$, $\theta \in \mathbb{R}$. Defina a confiabilidade do sistema por

$$R_0(x) = P_0(X > x) = 1 - F_0(x), x > 0.$$

Considere n observações independentes x_1, \dots, x_n de X . Admita que, dado θ , X tem distribuição exponencial de parâmetro θ e função de densidade de probabilidade

$$f(x|\theta) = \theta e^{-\theta x}, x > 0; \theta > 0$$

Mostre que o estimador de Bayes de $R_0(x)$ sob perda quadrática é função densidade a priori para θ

$$\pi(\theta) = \frac{1}{\theta^n \Gamma(n)} \theta^{n-1} e^{-\theta n}, \theta > 0, \quad \text{Gama}(n, \theta)$$

e dado por

$$\left(1 + \frac{x}{n\bar{x} + 1/x} \right)^{-(n+1)}$$

Termos que

$$R_0(x) = P_0(X > x) = 1 - P(X \leq x) = 1 - \int_0^x e^{-\theta z} dz = 1 - \theta \int_0^x e^{-\theta z} dz$$

$$= 1 - \theta \left[-\frac{1}{\theta} e^{-\theta z} \Big|_0^x \right] = 1 + e^{-\theta x} - 1 = e^{-\theta x} \quad \text{com } \theta, x > 0$$

A razão marginal é dada por

$$f(x|\theta) = \theta^n e^{-\theta \sum x_i}, x_i > 0; \theta > 0$$

$$\pi(\theta) = \frac{1}{\theta^n \Gamma(n)} \theta^{n-1} e^{-\theta n}, \theta > 0$$

Então, a posteriori é proporcional a

$$\pi(\theta|x) \propto e^{(n+1)-1} \exp \left\{ -\theta \left[n\bar{x} + \frac{1}{\bar{x}} \right] \right\}$$

$$= e^{(n+1)-1} \exp \left\{ -\theta \left[\frac{1}{n\bar{x} + 1} \right] \right\} \sim \text{Gama}[n+1, (n\bar{x} + 1)^{-1}]$$

$$\text{Logo, } \delta \sim \text{Goma} \left[\left(n\bar{x} + 1 \right)^{-1}, n+1 \right]$$

Como a perda quadrática podemos considerar, $W(\delta) = \delta$, o custo da dívida estimador de Bayes para $R_0(x) = e^{-\theta x}$

$$\delta(x) = E[R_0(x) | X=x]$$

$$= E[\exp(-\theta x) | X=x]$$

$$= \int_0^\infty e^{-\theta x} \frac{1}{\left[\frac{n}{n\bar{x} + 1} \right]^{n+1} \Gamma(n+1)} \exp \left[-\theta \left(n\bar{x} + \frac{1}{\bar{x}} \right) \right] dx$$

$$= \left[\frac{\partial}{\partial \theta} \right]_{\theta=0}^{-(n+1)} \left[\frac{e^{(n+1)\theta}}{\Gamma(n+1)} \right] \int_0^\infty e^{(n+1)\theta} \exp \left[-\theta \left(n\bar{x} + \frac{1}{\bar{x}} + \theta \right) \right] dx$$

$$= \left(\frac{n}{n\bar{x} + 1} \right)^{-(n+1)} \left[\Gamma(n+1) \right]^{-1} \int_0^\infty e^{(n+1)\theta} \exp \left[-\theta \left(\frac{1}{n\bar{x} + 1 + \theta \bar{x}} \right) \right] d\theta$$

$$= \left(\frac{n}{n\bar{x} + 1} \right)^{-(n+1)} \left[\Gamma(n+1) \right]^{-1} \left(\frac{n}{n\bar{x} + 1 + \theta \bar{x}} \right)^{n+1} \left[\Gamma(n+1) \right]^{-1} \times \\ \underbrace{e^{(n+1)\theta} \exp \left[-\theta \left(\frac{n}{n\bar{x} + 1 + \theta \bar{x}} \right)^{-1} \right] d\theta}_{\text{é a fdp da Gama} \left(\frac{n}{n\bar{x} + 1 + \theta \bar{x}}, n+1 \right)}$$

$$\text{Logo, } \delta = \left[\frac{\frac{n}{n\bar{x} + 1 + \theta \bar{x}}}{n\bar{x} + 1 + \theta \bar{x}} \right]^{n+1} = \left(\frac{n\bar{x} + 1 + \theta \bar{x}}{n\bar{x} + 1 + \theta \bar{x}} \right)^{n+1} = \left[\frac{n\bar{x} + 1 + \theta \bar{x}}{n\bar{x} + 1} \right]^{-(n+1)}$$

$$= \left[\frac{n\bar{x} + 1}{n\bar{x} + 1} + \frac{\theta \bar{x}}{n\bar{x} + 1} \right]^{-(n+1)} = \left[1 + \frac{\theta \bar{x}}{n\bar{x} + 1} \right]^{-(n+1)}$$

$$\text{Portanto, } \delta = \left[1 + \frac{x}{n\bar{x} + 1/x} \right]^{-(n+1)} \quad \text{onde } \bar{x} = \frac{1}{n} \sum x_i$$

3) seja $x = (x_1, \dots, x_n)$ um vetor de n variáveis aleatórias independentes e identicamente distribuídas segundo uma distribuição $N(\theta, \sigma^2)$.

Considere a função perda

$$L(\sigma^2, d) = \left[\frac{d}{\sigma^2} - 1 \right]^2 = \frac{(d - \sigma^2)^2}{\sigma^4}$$

(a) considere uma distribuição a priori Gamma(a,b) para $\theta = \frac{1}{\sigma^2}$ com densidade

$$\pi(\theta) = \frac{1}{r(a)b^a} \theta^{a-1} \exp\left\{-\frac{\theta}{b}\right\}; a > 0, b > 0$$

encontra o estimador de Bayes de σ^2 .

Temos que a verossimilhança é dada por

$$\pi(x|\theta^2) = \left(\frac{1}{\sqrt{2\pi\theta^2}} \right)^n \exp\left\{-\frac{1}{2\theta^2} \sum x_i^2\right\}$$

e temos ainda

$$\pi(\theta) = \frac{1}{r(a)b^a} \theta^{a-1} \exp\left\{-\frac{\theta}{b}\right\}$$

Logo a posteriori é dada por

$$\pi(\theta|x) \propto \frac{(2\pi\theta^2)^{-n/2}}{r(a)b^a} \theta^{a-1} \exp\left\{-\frac{\theta}{b} - \frac{\sum x_i^2}{2\theta^2}\right\}$$

$$= (\pi)^{-n/2} \left(\frac{1}{2\theta^2} \right)^{n/2} \frac{1}{r(a)b^a} \theta^{a-1} \exp\left\{-\frac{\theta}{b} - \frac{\sum x_i^2}{2\theta^2}\right\}, \text{ pois } \frac{1}{2\theta^2} = \theta$$

$$\propto \theta^{a+n/2-1} \frac{1}{r(a)b^a} \theta^{a-1} \exp\left\{-\theta \left(\frac{1}{b} + \frac{\sum x_i^2}{2\theta^2} \right)\right\}$$

$$\propto \theta^{(a+n/2)-1} \exp\left\{-\theta \left[\frac{b}{b+2\sum x_i^2} \right]^{-1}\right\}$$

que é o núcleo da urna Gamma $\left(a + \frac{n}{2}, \frac{b}{b+2\sum x_i^2}\right)$. Logo

$$\theta | x \sim \text{Gamma}\left(a + \frac{n}{2}, \frac{b}{b+2\sum x_i^2}\right)$$

Logo $\theta = \frac{1}{\sigma^2} \rightarrow \sigma^2 \theta = 1 \Rightarrow \sigma^2 = \frac{1}{\theta}$ então devo anotar

o estimador de Bayes de $g(\theta) = \frac{1}{\theta}$

Pelo corolário 2 temos que estimador de Bayes para $g(\theta)$

$$E[w(\theta)g(\theta) | x=x]$$

$$E[w(\theta) | x=x]$$

onde a perda é $L(\theta, d) = w(\theta) [d - g(\theta)]^2; w(\theta) > 0$.

No nosso caso

$$L(\theta^2, d) = \left(\frac{d}{\theta^2} - 1 \right)^2 = \left(\frac{d - \theta^2}{\theta^2} \right)^2 = \frac{(d - \theta^2)^2}{\theta^4}$$

$$\text{mas } \theta^2 = \frac{1}{\sigma^2} \Rightarrow L(\theta, d) = \frac{1}{\theta^4} \left[d - \frac{1}{\theta^2} \right]^2 = 4\theta^2 \left[d - \frac{1}{4\theta^2} \right]^2$$

então $w(\theta) = 4\theta^2$ logo o estimador de Bayes para $g(\theta)$ é

$$S = \frac{E[4\theta^2 \frac{1}{2\theta} | x=x]}{E[4\theta^2 | x=x]} = \frac{E[2\theta | x=x]}{E[4\theta^2 | x=x]}$$

mas

$$E[2\theta | x=x] = \int 2\theta \pi(\theta|x) d\theta = 2 \int \theta \pi(\theta|x) d\theta$$

$$\text{mas } \pi(\theta|x) = [r(a+n/2)]^{-1} \left(\frac{b}{b+2\sum x_i^2} \right)^{-(a+n/2)} \theta^{(a+n/2)-1} \exp\left\{-\theta \left(\frac{b+2\sum x_i^2}{b} \right)\right\}$$

$$E[2\theta | x=x] = 2A \int \theta^{a+n/2-1} \exp\left\{-\theta \left(\frac{b+2\sum x_i^2}{b} \right)\right\} d\theta = 2AB$$

$$\text{onde } A = \frac{1}{r(a+n/2)} \left(\frac{b}{b+2\sum x_i^2} \right)^{-(a+n/2)} \text{ e } B = \int \theta^{a+n/2-1} \exp\left\{-\theta \left(\frac{b+2\sum x_i^2}{b} \right)\right\} d\theta$$

mas D é o núcleo da fdp de uma urna Gamma $\left(a + \frac{n}{2} + 1, \frac{b}{b+2\sum x_i^2}\right)$

$$\text{então } B = r(a+n/2+1) \left(\frac{b}{b+2\sum x_i^2} \right)^{+(1+a+n/2)}$$

$$\text{Logo } E[2\theta | x=x] = 2 \frac{r(a+n/2+1)}{r(a+n/2)} \left(\frac{b}{b+2\sum x_i^2} \right) = \frac{2(a+n/2+1)}{(a+n/2+1)!} \frac{b}{b+2\sum x_i^2}$$

$$E[2\theta|X=x] = \frac{2b}{b\sum i^2+1} (a+n_2)$$

$$\begin{aligned} E[4\theta^2|X=x] &= 4 \int_0^\infty \theta^2 A^{-\theta(a+n_2)-1} u \exp \left\{ -\theta \left(\frac{b}{b\sum i^2+1} \right)^{-1} \right\} du \\ &= 4A \int_0^\infty \theta^{(a+n_2+2)-1} u \exp \left\{ -\theta \left(\frac{b}{b\sum i^2+1} \right)^{-1} \right\} du \\ &= 4AC \end{aligned}$$

onde $C = \int_0^\infty \theta^{(a+n_2+2)-1} u \exp \left\{ -\theta \left(\frac{b}{b\sum i^2+1} \right)^{-1} \right\} du$

mas E é o núcleo de uma Gama $\left(\frac{a+n_2+2}{2}, \frac{b}{b\sum i^2+1} \right)$ logo

$$C = \Gamma(a+n_2+2) \left(\frac{b}{b\sum i^2+1} \right)^{(a+n_2+2)}$$

Dai:

$$\begin{aligned} E[4\theta^2|X=x] &= 4 \frac{\Gamma(a+n_2+2)}{\Gamma(a+n_2)} \left(\frac{b}{b\sum i^2+1} \right)^2 \\ &= \frac{4(a+n_2+1)!}{(a+n_2-1)!} \left(\frac{b}{b\sum i^2+1} \right)^2 \\ &= \frac{4(a+n_2)(a+n_2-1)!(a+n_2+1)}{(a+n_2-1)!} \left(\frac{b}{b\sum i^2+1} \right)^2 \\ &= 4(a+n_2)(a+n_2+1) \left(\frac{b}{b\sum i^2+1} \right)^2 \end{aligned}$$

Logo

$$\delta = \frac{\cancel{ab}}{\cancel{n_2}b+1} \frac{(a+n_2)}{(a+n_2)(a+n_2+1)} = \frac{1}{\frac{2b}{b\sum i^2+1}(a+n_2+1)}$$

$$\frac{b\sum i^2+1}{2b(a+n_2+1)}$$

loop o estimador de Bayes para θ é $\frac{1}{2b}$ ou seja

estimador de Bayes para θ^2 é

$$\frac{b\sum i^2+1}{2b(a+n_2+1)}$$

b) Mostre que $\delta^*(x) = \frac{\sum x_i^2}{n+2}$ é um estimador mínimo de σ^2 .
Vamos calcular o variancia do estimador $\delta^*(x) = \frac{\sum x_i^2}{n+2}$.

$$P(g(0), \delta^*(x)) = E\{L(0, \delta^*(x))\}$$

$$= E\left\{10^2 \left(\delta^*(x) - \frac{1}{20}\right)^2\right\}$$

$$= 10^2 \left\{ \text{Var}\left(\delta^*(x) - \frac{1}{20}\right) + \left[E(\delta^*(x)) - \frac{1}{20}\right]^2 \right\}$$

$$= 10^2 \left\{ \text{Var}[\delta^*(x)] + \left[\frac{1}{n+2} \sum E(x_i^2) - \frac{1}{20}\right]^2 \right\}$$

mas

$$E(x_i^2) = \text{Var}(x_i) + (E(x_i))^2 = \sigma^2 = \frac{1}{20}$$

$$\text{Var}[\delta^*(x)] = \frac{1}{(n+2)^2} \sum_{i=1}^n \text{Var}(x_i^2) = \frac{1}{(n+2)^2} \sum_{i=1}^n [E(x_i^4) - E^2(x_i^2)]$$

$$= \frac{1}{(n+2)^2} \sum_{i=1}^n [E(x_i^4) - 1/(40^2)]$$

$$= \frac{1}{(n+2)^2} \left\{ \sum_{i=1}^n E(x_i^4) - \frac{n}{40^2} \right\}$$

mas

$$E(x_i^4) = \frac{\partial^4 H_{X_1}(t)}{\partial t^4} \Big|_{t=0}$$

$$H_{X_1}(t) = \exp\{st^2/2\} \Rightarrow \frac{\partial H_{X_1}(t)}{\partial t} = \exp\left\{\frac{s^2 t^2}{2}\right\} \frac{st^2 \sigma^2}{2}$$

$$\frac{\partial^2 H_{X_1}(t)}{\partial t^2} = \exp\left\{\frac{s^2 t^2}{2}\right\} s^2 t^2 + t^2 \sigma^2 + \exp\left\{\frac{s^2 t^2}{2}\right\} \sigma^2$$

$$\frac{\partial^3 H_{X_1}(t)}{\partial t^3} = \exp\left\{\frac{s^2 t^2}{2}\right\} t^2 \sigma^2 + t^2 \sigma^4 + \exp\left\{\frac{s^2 t^2}{2}\right\} 2st^2 + \exp\left\{\frac{s^2 t^2}{2}\right\} t^2 \sigma^2$$

$$\begin{aligned} \frac{\partial^4 H_{X_1}(t)}{\partial t^4} &= \exp\left\{\frac{s^2 t^2}{2}\right\} t^2 \sigma^2 t^3 \sigma^6 + \exp\left\{\frac{s^2 t^2}{2}\right\} 2s^2 \sigma^4 + \exp\left\{\frac{s^2 t^2}{2}\right\} t^2 \sigma^2 t^2 \sigma^4 \\ &= \exp\left\{\frac{s^2 t^2}{2}\right\} 2st^2 t^3 \sigma^6 + \exp\left\{\frac{s^2 t^2}{2}\right\} 2s^2 \sigma^4 + \exp\left\{\frac{s^2 t^2}{2}\right\} t^2 \sigma^2 t^2 \sigma^4 \end{aligned}$$

Logo

$$E(x_i^4) = 204 \exp\{0\} + 0^4 \exp 0 = 204 + 0^4 = 204 = 3(\sigma^2)^2 = 3\left(\frac{1}{20}\right)^2 = \frac{3}{40^2}$$

Logo,

$$\text{Var}(\delta^*(x)) = \frac{1}{(n+2)^2} \left\{ \frac{2n}{10^2} - \frac{n}{40^2} \right\} = \frac{2n}{40^2(n+2)^2}$$

então

$$P(g(0), \delta^*(x)) = 10^2 \left\{ \frac{2n}{40^2(n+2)^2} + \left[\frac{1}{n+2} \frac{n}{20} - \frac{1}{20} \right]^2 \right\}$$

$$= \frac{2n}{(n+2)^2} + \frac{10^2}{40^2} \left[\frac{n-1-2}{20(n+2)} \right]^2$$

$$= \frac{2n}{(n+2)^3} + \frac{40^2}{(n+2)^2} = \frac{2n+4}{(n+2)^2}$$

$$\therefore P(g(0), \delta^*(x)) = \frac{2n+4}{(n+2)^2} \text{ é constante}$$

Portanto, no item (a) temos que o estimador de Bayes sob a priori Gamma(a_0, b_0) é dado por

$$\delta_2(x) = \frac{b_0 \sum x_i^2 + 1}{2b_0(n+a_0+2)} = \frac{\sum x_i^2 + 1/b_0}{2(b_0 + \frac{2a_0 + n+2}{2})}$$

$$= \frac{\sum x_i^2 + 1/b_0}{2a_0 + n+2}$$

calcular o variancia do estimador de Bayes $\delta_2(x)$

$$R(g(\theta), \delta_2(x)) = 4\theta^2 \left\{ \text{Var}(\delta_2(x)) + \left[\frac{1}{n+2} \sum_{i=1}^{n+2} E(x_i^2) - \frac{1}{20} \right]^2 \right\}$$

$$\text{mas } E(x_i^2) = \frac{1}{20} - x$$

$$\text{Var}[\delta_2(x)] = \frac{1}{(2an+n+2)^2} \sum \text{Var}(x_i^2) = \frac{1}{(2an+n+2)^2} \left[\frac{2n}{4\theta^2} \right] \quad (A-x)$$

dai,

$$R(g(\theta), \delta_2(x)) = 4\theta^2 \left\{ \frac{2n}{4\theta^2(2an+n+2)^2} + \left[\frac{1}{n+2} \frac{n}{20} - \frac{1}{20} \right]^2 \right\}$$

$$= \frac{4\theta^2}{(2an+n+2)^2} \left\{ \frac{2n}{4\theta^2(2an+n+2)} + \frac{1}{4\theta^2} \left[\frac{x - x^2}{n+2} \right]^2 \right\}$$

$$= \frac{2n}{(2an+n+2)^2} + \frac{4}{(n+2)^2} = \frac{2n}{4an^2 + 2an(n+2) + (n+2)^2} + \frac{4}{(n+2)^2}$$

dai

ERRO: Deve-se fazer $\lim_{an \rightarrow 0} R(g(\theta), \delta_2(x))$

$$\lim_{an \rightarrow 0} R(g(\theta), \delta_2(x)) = \lim_{an \rightarrow 0} \frac{2n}{4an^2 + 2an(n+2) + (n+2)^2} + \frac{4}{(n+2)^2}$$

$$= \frac{2n}{(n+2)^2} + \frac{4}{(n+2)^2} \quad \lim_{an \rightarrow 0}$$

$$= \frac{2n+4}{(n+2)^2} = \sup_{\theta} R(g(\theta), \delta^*(x))$$

Logo

$$\lim_{an \rightarrow 0} R(g(\theta), \delta_2(x)) = \sup_{\theta} R(g(\theta), \delta^*(x))$$

Portanto pelo item (a) da pág. 169 do texto temos que

$\delta_2(x)$ é minimax.

(c) mostre que $\delta_1(x)$ tem risco uniformemente menor ou igual ao de todos os estimadores da forma $c \sum_{i=1}^n x_i^2$.

Suponha $\delta_1(x) = c \sum_{i=1}^n x_i^2$. Vamos encontrar o risco de $\delta_1(x)$.

$$\begin{aligned} R(g(\theta), \delta_1(x)) &= E\{L(\theta, \delta_1(x))\} \\ &= E\left\{4\theta^2 \left(\delta_1(x) - \frac{1}{2\theta}\right)^2\right\} \\ &= 4\theta^2 \left\{Var\left(\delta_1(x) - \frac{1}{2\theta}\right) + \left[E(\delta_1(x)) - \frac{1}{2\theta}\right]^2\right\} \\ &= 4\theta^2 \left\{Var(\delta_1(x)) + \left[c \sum E(x_i^2) - \frac{1}{2\theta}\right]^2\right\} \end{aligned}$$

$$\text{mas } E(x_i^2) = Var(x_i) + E^2(x_i) = \sigma^2 = \frac{1}{2\theta}$$

$$Var[\delta_1(x)] = c^2 \sum Var(x_i^2) = c^2 \left\{ \sum_{i=1}^n E(x_i^4) - n/4\theta^2 \right\}$$

$$\text{pela letra b)} \quad E(x_i^4) = \frac{3}{4\theta^2}$$

$$\begin{aligned} \text{Logo } R(g(\theta), \delta_1(x)) &= 4\theta^2 \left\{ c^2 \left[\frac{3n}{4\theta^2} - \frac{n}{4\theta^2} \right] + \left[c \frac{n}{2\theta} - \frac{1}{2\theta} \right]^2 \right\} \\ &= 4\theta^2 \left\{ \frac{c^2}{4\theta^2} 2n + \frac{1}{4\theta^2} (nc-1)^2 \right\} \\ &= 2nc^2 + (nc-1)^2 \\ &= 2nc^2 + n^2c^2 - 2nc + 1 \end{aligned}$$

$$\text{Logo } R(g(\theta), \delta_1(x)) = 2nc^2 + n^2c^2 - 2nc + 1 \quad \text{pela letra b) temos}$$

$$\text{que } R(g(\theta), \delta^*(x)) = \frac{1}{(n+2)^2} (2n+4) \cdot \text{Daí}$$

$$\begin{aligned} \frac{R(g(\theta), \delta^*(x))}{R(g(\theta), \delta_1(x))} &= \frac{\frac{1}{(n+2)^2} (2n+4)}{2nc^2 + n^2c^2 - 2nc + 1} = \frac{2n+4}{(n+2)^2 (2nc^2 + n^2c^2 - 2nc + 1)} \\ &= \frac{2n[1 + 2/n]}{3n(n+2)^2 \left(c^2 + \frac{nc^2}{2} - c - \frac{1}{2n}\right)} \end{aligned}$$

$$\begin{aligned} \frac{R(g(\theta), \delta^*(x))}{R(g(\theta), \delta_1(x))} &= \frac{1}{(n+2)^2 \left(c^2 + \frac{nc^2}{2} - c - \frac{1}{2n}\right)} + \frac{n(n+2)^2 \left(c^2 + \frac{nc^2}{2} - c - \frac{1}{2n}\right)}{(n+2)^2 (c^2 + \frac{nc^2}{2} - c - \frac{1}{2n})} \\ &\leq 1 \leq 1 \leq 1 \quad \forall \theta \end{aligned}$$

Logo

$$R[g(\theta), \delta^*(x)] \leq R[g(\theta), \delta_1(x)]$$

Outra forma (acho que está mais curta).

Pelo item anterior

$$R(\sigma^2, \delta^*(x)) = \frac{2n+4}{(n+2)^2}$$

$$\text{onde } \delta^*(x) = \frac{\sum x_i^2}{n+2}$$

→ calcular o valor de c que minimiza o risco de $\delta_1 = c \sum x_i^2$

Temos a perda

$$L(\sigma^2, \delta_1(x)) = L(\sigma^2, c \sum x_i^2) = \left[\frac{c \sum x_i^2 - \sigma^2}{\sigma^2} \right]^2 = \left[\frac{c \sum x_i^2}{\sigma^2} - 1 \right]^2$$

Então o risco $R(\sigma^2, \delta_1(x))$ é da forma

$$\begin{aligned} R(\sigma^2, \delta_1(x)) &= E[L(\sigma^2, \delta_1(x))] = E\left[\left(c \sum_{i=1}^n \left(\frac{x_i}{\sigma}\right)^2 - 1\right)^2\right] \\ &= \text{Var}\left[c \sum_{i=1}^n \left(\frac{x_i}{\sigma}\right)^2 - 1\right] + E^2\left[c \sum \left(\frac{x_i}{\sigma}\right)^2 - 1\right] \end{aligned}$$

$$\text{mas } \sum_{i=1}^n \left(\frac{x_i}{\sigma}\right)^2 \sim \chi_n^2 \Rightarrow \text{Var}\left(\sum \left(\frac{x_i}{\sigma}\right)^2\right) = 2n + E\left(\sum \left(\frac{x_i}{\sigma}\right)^2\right) = n$$

$$R(\sigma^2, \delta_1(x)) = c^2 2n + [nc-1]^2 = 2nc^2 + n^2c^2 - 2nc + 1$$

$$\text{Daí, } \underline{QR(\sigma^2, \delta_1(x))} = 4nc + 2n^2c - 2n$$

Q.C.

Então

$$4nc + 2n^2c - 2n = 0 \iff 4c + 2nc - 2 = 0$$

$$\iff c(2n+4) = 2 \iff c = \frac{2}{2n+4} \iff c = \frac{1}{n+2}$$

$$\frac{\partial^2 R(\sigma^2, s_1(x))}{\partial c^2} = 4n + 2n^2 > 0$$

Logo o ponto c que minimiza o risco de $s_1 = c \sum x_i^2$ é

$$c = \frac{1}{n+2}$$

Dai $s^*(x) = \frac{\sum x_i^2}{n+2}$ tem risco uniformemente menor ou igual aos de todos os estimadores da forma $c \sum_{i=1}^n x_i^2$.

(d) Mostre que o estimador de máxima verossimilhança é unbiased e temos a verossimilhança

$$\begin{aligned} L(x, \theta^2) &= \left(\frac{1}{\sqrt{2\pi\theta^2}}\right)^n \exp\left\{-\frac{1}{2\theta^2} \sum x_i^2\right\} \\ &= \left(\frac{1}{\sqrt{\pi}}\right)^n \left(\frac{1}{\sqrt{2\theta^2}}\right)^n \exp\left\{-\theta \sum x_i^2\right\} \\ &= \pi^{-n/2} \theta^{n/2} \exp\left\{-\theta \sum x_i^2\right\} \end{aligned}$$

a log-verossimilhança

$$L(x, \theta) = -\frac{n}{2} \log \pi + \frac{n}{2} \log \theta - \theta \sum x_i^2$$

$$\frac{\partial L(x, \theta)}{\partial \theta} = \frac{n}{2\theta} - \sum x_i^2 = U(\theta)$$

Fazendo $U(\theta) = 0$ temos

$$\frac{n}{2\theta} - \sum x_i^2 = 0 \Rightarrow \frac{n}{2\theta} = \sum x_i^2$$

$$\Rightarrow \frac{n}{\sum x_i^2} = 2\theta \Rightarrow \theta = \frac{n}{2 \sum x_i^2}$$

$$\frac{\partial^2 L(x, \theta)}{\partial \theta^2} = \frac{-n}{4\theta^2} = -\frac{1}{2\theta^2} < 0 \quad \text{Logo o EMV de } \theta \text{ é}$$

$$\boxed{\hat{\theta} = \frac{n}{2 \sum x_i^2}}$$

Logo EMV de θ^2 é $\frac{1}{2\hat{\theta}}$ ou seja,

$$\hat{\theta}^2 = \frac{1}{\frac{\sum n}{2 \sum x_i^2}} = \frac{2 \sum x_i^2}{\sum n} = \frac{\sum x_i^2}{n}$$

Portanto

$$\boxed{\hat{\theta}^2 = \frac{\sum x_i^2}{n}}$$

Vamos calcular o risco

$$\begin{aligned} R(\theta^2, \hat{\theta}^2) &= E\{L(\theta^2, \hat{\theta}^2)\} \\ &= E\left\{\frac{1}{\theta^4} (\hat{\theta}^2 - \theta^2)^2\right\} \\ &= \frac{1}{\theta^4} E[(\hat{\theta}^2)^2 - 2\theta^2 \hat{\theta}^2 + \theta^4] \\ &= \frac{1}{\theta^4} \{E[(\hat{\theta}^2)^2] - 2\theta^2 E(\hat{\theta}^2) + \theta^4\} \end{aligned}$$

mas

$$E(\hat{\theta}^2) = \frac{1}{n} \sum E(x_i^2) = \frac{1}{n} n \theta^2 = \theta^2$$

$$E[(\hat{\theta}^2)^2] = E\left\{\left(\frac{\sum x_i^2}{n}\right)^2\right\} = \text{Var}\left\{\frac{\sum x_i^2}{n}\right\} + [E\left(\frac{\sum x_i^2}{n}\right)]^2$$

$$= \frac{1}{n^2} \sum \text{Var}(x_i^2) + \theta^4$$

$$= \frac{1}{n^2} \frac{2n}{4\theta^2} + \theta^4 = \frac{1}{2n\theta^2} + \theta^4, \quad ; \theta = \frac{1}{2\theta^2}$$

$$= \frac{1}{\frac{1}{2n\theta^2} + \theta^4} + \theta^4 = \frac{1}{\frac{n}{2\theta^4}} + \theta^4 = \frac{2\theta^4}{n} + \theta^4$$

Logo

$$R(\theta^2, \hat{\theta}^2) = \frac{1}{\theta^4} \left\{ \frac{2\theta^4}{n} + \theta^4 - 2\theta^2 \theta^2 + \theta^4 \right\}$$

$$= \frac{1}{\theta^4} \left\{ \theta^4 \left[\frac{2}{n} + 1 - 2 + 1 \right] \right\} = \frac{2}{n}$$

$$\text{Portanto } R(\theta^2, \hat{\theta}^2) = \frac{2}{n}$$

Notemos que $R(\theta^2, \hat{\theta}^2)$ é uma função estritamente decrescente em n . Assim, se $n > 2$ podemos sempre pegar um n' com $1 \leq n' \leq n$ que fará um risco menor. Então $\hat{\theta}^2$ é inadmissível.

complemento:

Temos que $\hat{\sigma}^2 = \frac{\sum x_i^2}{n}$ é o EMV de σ^2 , mas podemos observar

que $\hat{\sigma}^2$ é um estimador da forma $c \sum x_i^2$ pelo item @

$R(\sigma^2, s^*(x)) \leq R(\sigma^2, c \sum x_i^2)$ com desigualdade estrita para
toda algum σ^2 . Logo

$$R(\sigma^2, s(x)) < R(\sigma^2, \sum x_i^2/n)$$

todas $\frac{\sum x_i^2}{n}$ é irracional

4) Sejam x_1, \dots, x_n uma amostra aleatória da distribuição de Poisson de média λ . Considere uma distribuição a priori $\pi(\alpha, \beta)$ para λ .

(a) Encontre o estimador de Bayes $\delta_{\alpha, \beta}$ de λ sob perda quadrática.

A verossimilhança é dada por

$$f(x|\lambda) = \frac{\lambda^{\sum x_i} e^{-n\lambda}}{x_i!} \quad x_i = 0, 1, \dots$$

$$\pi(\lambda) = \frac{1}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\lambda/\beta} I_{(0, \infty)}(\lambda)$$

Logo a posteriori λ

$$\begin{aligned} \pi(\lambda | x) &= \frac{1}{C} \frac{1}{x_i! \Gamma(\alpha)} \lambda^{\alpha + \sum x_i - 1} \exp \left\{ -\lambda \left(n + \frac{1}{\beta} \right) \right\} \\ &\propto \lambda^{\alpha + n\bar{x} - 1} \exp \left\{ -\lambda \left(\frac{1}{n\beta + 1} \right)^{-1} \right\} \end{aligned}$$

que é o núcleo de uma Gamma $\left[\alpha + n\bar{x}, \frac{\beta}{n\beta + 1} \right]$. Logo

$$\lambda | x \sim \text{Gamma} \left(\alpha + n\bar{x}, \frac{\beta}{n\beta + 1} \right)$$

sob perda quadrática temos pelo cálculo que

$$\delta_{\alpha, \beta} = E[\lambda | x = x]$$

$$= (\alpha + n\bar{x}) \left(\frac{\beta}{n\beta + 1} \right)$$

Portanto o estimador de Bayes de λ sob perda quadrática é

$$\frac{\beta(\alpha + n\bar{x})}{n\beta + 1}$$

(b) O que ocorre com $\delta_{\alpha, \beta}$ quando

(i) $n \rightarrow \infty$:

Sabemos pelo item a) que

$$\delta_{\alpha, \beta} = \frac{\beta(\alpha + n\bar{x})}{n\beta + 1}$$

$$= \frac{1}{n\beta + 1} [\beta\alpha + n\beta\bar{x}] \quad \text{divide por } n\beta \text{ em cima e embaixo}$$

$$= \frac{1}{1 + \frac{1}{n\beta}} [\beta\alpha/n\beta + \bar{x}]$$

$$= \frac{\frac{\alpha}{\beta} + \bar{x}}{1 + \frac{1}{n\beta}}$$

Logo

$$\lim_{n \rightarrow \infty} \delta_{\alpha, \beta} = \bar{x}$$

Quando $n \rightarrow \infty$ então $\delta_{\alpha, \beta}$ tende para \bar{x} .

(ii) $\alpha \rightarrow 0, \beta \rightarrow \infty$

$$\lim_{\substack{\alpha \rightarrow 0 \\ \beta \rightarrow \infty}} \delta_{\alpha, \beta} = \lim_{\substack{\alpha \rightarrow 0 \\ \beta \rightarrow \infty}} \frac{\frac{\alpha}{\beta} + \bar{x}}{1 + \frac{1}{n\beta}} = \bar{x}$$

(iii) $\alpha \rightarrow 0, \beta \rightarrow \infty, n \rightarrow \infty$

$$\lim_{\substack{\alpha \rightarrow 0 \\ \beta \rightarrow \infty \\ n \rightarrow \infty}} \delta_{\alpha, \beta} = \lim_{\substack{\alpha \rightarrow 0 \\ \beta \rightarrow \infty \\ n \beta \rightarrow \infty}} \frac{\frac{\alpha}{\beta} + \bar{x}}{1 + \frac{1}{n\beta}} = \bar{x}$$

(c) Encontre o viés e o viés mínimo do estimador δ_{4p} .

Temos pela letra (a)

$$\delta_{4p} = \frac{\beta(\omega + n\bar{x})}{n\beta + 1}$$

Daí,

$$E(\delta_{4p}(x)) = \frac{1}{n\beta + 1} \beta[\omega + nE(\bar{x})]$$

Temos que

$$E(\bar{x}) = \frac{1}{n} \sum E(x_i) = \frac{1}{n} n\lambda = \lambda, \text{ logo}$$

$$E[\delta_{4p}(x)] = \frac{1}{n\beta + 1} \beta[\omega + n\lambda]$$

$$\text{Víés } (\delta_{4p}(x)) = E[\delta_{4p}(x)] - \lambda$$

$$= \frac{\beta}{n\beta + 1} (\omega + n\lambda) - \lambda$$

$$= \frac{\omega\beta}{n\beta + 1} + \lambda \left(\frac{n\beta}{n\beta + 1} - 1 \right)$$

$$= \frac{\omega\beta}{n\beta + 1} + \lambda \left(\frac{-1}{n\beta + 1} \right)$$

$$= \frac{\omega}{n + 1/p} - \frac{\lambda}{n\beta + 1}$$

$$= \frac{\omega\beta - \lambda}{n\beta + 1} = \frac{\omega - \frac{\lambda}{\beta}}{n + \frac{1}{p}}$$

O viés de δ_{4p} aumenta quando $\omega\beta$ estiver mais distante de λ .

Depois considerando picas próprias ($\omega > 0, \beta > 0$), o viés é máximo

quando $\omega \rightarrow \infty$ e $\beta \rightarrow 0$

5) Suponha que x_1, \dots, x_n é uma amostra simples da distribuição binomial negativa $B(n, p)$. Considere uma distribuição prior Beta (α, β) para p .

(a) Encontre o estimador de Bayes $s_{\text{ap}}(x)$ de p usos perda quadrática.

A verossimilhança π dada por:

$$\pi(x|p) = \prod_{i=1}^n \frac{(x_i-1)}{m-1} \cdot p^{mn} (1-p)^{m-n} \quad x = m + n - \sum x_i$$

$$\propto p^{mn} (1-p)^{m-n}$$

$$\pi(p) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} I_{(0,1)}(p)$$

$$\propto p^{\alpha-1} (1-p)^{\beta-1}$$

Onde a posterior π dada por

$$\pi(p|x) \propto p^{(mn+\alpha)-1} (1-p)^{(m\bar{x}+\beta-mn)-1}$$

que é núcleo de uma Beta $(mn+\alpha, m\bar{x}+\beta-mn)$.

Logo

$$p|x \sim \text{Beta}(mn+\alpha, m\bar{x}+\beta-mn)$$

Como a perda é quadrática, pelo corolário 2.2.2 temos que o estimador de Bayes de p é

$$s_{\text{ap}}(x) = E[p|x=x]$$

$$= \frac{mn+\alpha}{m\bar{x}+\alpha+\beta}$$

(b) Escrever o risco e o risco máximo do estimador.

Temos pelo item (a) que

$$\delta_{\alpha, \beta}(x) = \frac{mn + \alpha}{mn + n\bar{x} + \alpha + \beta}$$

dai,

$$E[\delta_{\alpha, \beta}(x)] = E\left[\frac{mn + \alpha}{mn + n\bar{x} + \alpha + \beta}\right] = E\left[\frac{mn + \alpha}{\sum_{i=1}^n x_i + \alpha + \beta}\right]$$

Se $x_i | p \sim b(n, m, p) \Rightarrow \sum x_i | p \sim b(n, mn, p)$ logo

$$E\left[\frac{mn + \alpha}{\sum_{i=1}^n x_i + \alpha + \beta}\right] = \sum_{t=0}^{\infty} \frac{mn + \alpha}{t + \alpha + \beta} \binom{mn+t-1}{mn-1} p^{mn} (1-p)^t \\ = \sum_{t=0}^{\infty} \frac{1}{t + \alpha + \beta}$$

(06) suponha x e y variáveis aleatórias independentes com distribuições η e ξ , respectivamente. Suponha que $\xi + \eta$ são considerados variáveis aleatórias independentes, reais, com distribuições Δ e Λ respectivamente. Se, com perda quadrática, $s_\Delta =$ o estimador de Bayes de ξ com base em x e $s_\Lambda =$ o estimador de Bayes de η com base em y .

(a) mostre $s_{\Delta\Lambda} = s_\Delta - s_\Lambda =$ o estimador de Bayes de $\eta - \xi$ com base em (x, y) .

lema $s_\Delta + s_\Lambda$ são estimadores de Bayes de $\xi + \eta$ sob perda quadrática; respectivamente então

$$s_\Delta = E[\xi | x=x] = \int \xi d\Delta(\xi|x)$$

$$+ s_\Lambda = E[\eta | y=y] = \int \eta d\Lambda(\eta|y)$$

logo pelo corolário 2, sob perda quadrática

$$\begin{aligned} s_{\Delta\Lambda} &= E[\eta - \xi | (x,y) = (x,y)] \\ &= E[\eta | y=y] - E[\xi | x=x] \\ &= s_\Lambda - s_\Delta \end{aligned}$$

pois x e y são cond. dado $\xi + \eta =$
e ξ é func. da cond. η é cond.
de $x + \xi$ é cond. de y .

então $s_\Lambda - s_\Delta =$ o estimador de Bayes de $\eta - \xi$.

(b) se $\eta > 0$ e $s_{\Delta\Lambda}^*$ é o estimador de Bayes de ξ/η com base em y , mostre que $s_\Delta s_\Lambda^*$ é o estimador de Bayes de ξ/η com base em (x, y) .

lema $s_{\Delta\Lambda}^*$ é estimador de Bayes de $\frac{1}{\eta}$ intérvalo pelo corolário 2

$$s_{\Delta\Lambda}^* = E\left[\frac{1}{\eta} \mid y=y\right] = \int \frac{1}{\eta} d\Delta(\eta|y)$$

também pelo corolário 2 temos que

$$\begin{aligned} s_{\Delta\Lambda}^* &= E\left[\frac{\xi}{\eta} \mid (x,y) = (x,y)\right] \\ &= E[\xi | x=x] E[\eta | y=y] \\ &\quad \text{pois } x \text{ e } y \text{ não cond.} \\ &\quad \xi \text{ e } \eta \text{ " } \\ &= s_\Delta s_\Lambda^* \end{aligned}$$

} x e y cond. e $\xi + \eta$ cond.

então $s_\Delta s_\Lambda^*$ é estimador de Bayes de ξ/η .

07) Suponha que X tem distribuição binomial $b(\theta, n)$. Considere uma distribuição a priori Beta (α, β) , com $\alpha = \beta = 0$ (priori imprópria) e a perda quadrática. Considere estimador δ que satisfazem $\delta(0) = 0$ e $\delta(n) = 1$. mostre que o risco a posteriori é minimizado quando $\delta(x) = \frac{x}{n}$.

Temos que a verossimilhança:

$$L(\theta; x) \propto \theta^x (1-\theta)^{n-x}$$

e a priori

$$\pi(\theta) \propto \theta^{-1} (1-\theta)^{-1}$$

Então, temos a posteriori é proporcional:

$$\pi(\theta|x) \propto L(\theta|x) \pi(\theta)$$

$$\propto \theta^x (1-\theta)^{n-x-1}$$

que é núcleo de uma beta $(x, n-x)$. logo a posteriori tem distribuição

$$\theta|x \sim \text{Beta}(x, n-x)$$

seja $\delta(x)$ tal que

$$\delta(x) = \begin{cases} 0 & \text{se } x=0 \\ 1 & \text{se } x=n \end{cases}$$

Então

$$\begin{aligned} R(\theta, \delta(x)) &= E_{\theta} \{ [\delta(x) - \theta]^2 | X=x \} \\ &= E_{\theta} \{ (\delta(x)^2 - 2\theta\delta(x) + \theta^2) | X=x \} \\ &= \delta(x)^2 - 2\delta(x) E_{\theta} (\theta | X=x) + E_{\theta} (\theta^2 | X=x) \\ &= \delta(x)^2 - 2\delta(x) \frac{x}{n} + E_{\theta} (\theta^2 | X=x) \end{aligned}$$

Então

$$\frac{\partial R(\theta, \delta)}{\partial \delta} = 2\delta(x) - \frac{2x}{n}$$

08

então

$$2\delta(x) - \frac{2x}{n} = 0 \iff \delta(x) = \frac{2x}{2n} = \frac{x}{n}$$

$$\frac{\partial^2 R(\theta, \delta)}{\partial \delta^2} = 2 > 0$$

Logo $\delta(x) = \frac{x}{n}$ é o ponto que minimiza o risco a posteriori.

08) Suponha que, dado $\Theta = \theta$, x_1, \dots, x_n sejam variáveis aleatórias independentes com distribuição uniforme no intervalo $(0, \theta)$. Admita que Θ tem distribuição Gama (a, b) (a, b conhecidos).

(a) Verifique que o estimador de Bayes não depende dos dados através de $Y = \max_i x_i$.

Temos que $x_i | \Theta = \theta \sim U(0, \theta)$

$$f(x_i | \theta) = \theta^{-n} \prod_{i=1}^n I_{(0,\theta)}(x_i)$$

Então

$$\begin{aligned} \prod_{i=1}^n I_{(0,\theta)}(x_i) &= \begin{cases} 1 & \text{se } x_i \in (0, \theta) \text{ para } i = 1, \dots, n \\ 0 & \text{caso contrário} \end{cases} \\ &= \begin{cases} 1 & \text{se } x_{(n)} > 0 \text{ e } x_{(n)} < \theta \\ 0 & \text{caso contrário} \end{cases} \\ &= I_{(0, x_{(n)})} I_{(x_{(n)}, \theta)} \\ &= I_{(0, x_{(n)})} I_{(\theta, \infty)} = I_{(x_{(n)}, \infty)} \end{aligned}$$

Logo

$$f(\theta | x) = \theta^{-n} I_{(x_{(n)}, \infty)}$$

Temos ainda que

$$\frac{1}{\theta} \sim \text{Gama}(a, b) \Rightarrow \Theta \sim GI(a, b)$$

$$\pi(\theta) = \frac{1}{\Gamma(a)b^a} \left(\frac{1}{\theta}\right)^{a-1} e^{-\frac{1}{b\theta}}$$

Então a posteriori é

$$\begin{aligned} \pi(\theta | x) &\propto f(x | \theta) \pi(\theta) \\ &\propto \theta^{-n} I_{(x_{(n)}, \infty)} \frac{1}{\Gamma(a)b^a} \left(\frac{1}{\theta}\right)^{a-1} e^{-\frac{1}{b\theta}} \\ &\propto e^{-\frac{n}{b\theta}} I_{(x_{(n)}, \infty)} \end{aligned}$$

Ou ainda

$$\begin{aligned} \pi(\theta | x) &= \frac{f(x | \theta) \pi(\theta)}{g(x)} = \frac{\theta^{-n} I_{(x_{(n)}, \infty)} \pi(\theta)}{\int_{x_{(n)}}^{\infty} \theta^{-n} I_{(x_{(n)}, \infty)} \pi(\theta) d\theta} \\ &= \frac{\theta^{-(n+a-1)} e^{-\frac{n}{b\theta}} I_{(x_{(n)}, \infty)}}{\int_{x_{(n)}}^{\infty} \theta^{-(n+a-1)} e^{-\frac{n}{b\theta}} d\theta} \end{aligned}$$

Pelo corolário 2, sob hipótese quadrática, o estimador de Bayes de Θ é dado por

$$\begin{aligned} \delta(z) &= E[g(\Theta) | x = z] \quad \text{onde } g(\Theta) = \Theta \\ &= E[\Theta | x = z] \\ &= \int_{x_{(n)}}^{\infty} \theta \pi(\theta | z) d\theta \end{aligned}$$

Como $\pi(\theta | z)$ depende dos dados apenas através de $Y = x_{(n)}$, consequentemente $\delta(z)$ também vai depender dos dados através de $Y = x_{(n)}$.

→ sob uma perda qualquer:

O vínculo a posteriori é dado por

$$E[L(\Theta, \delta(z)) | x = z] = E[L(\Theta, \delta(z)) | Y = x_{(n)}] \quad (1)$$

Como $L(\Theta, \delta(z)) | x = z$ depende dos dados apenas através de $Y = x_{(n)}$ então $\delta(z)$ que minimiza (1) depende dos dados através de $Y = x_{(n)}$ (estatística suficiente pelo C.F.).

b) mostre que

$$E[\Phi | y, a, b] = \frac{1}{b(n+a-1)} \frac{P[X_{2(n+a-1)}^2 < 2/by]}{P[X_{2(n+a)}^2 < 2/by]}$$

$y = X_{2n}$.

$$\begin{aligned} E[\Phi | y, a, b] &= \int_y^\infty \theta \Gamma(\theta) d\theta \\ &= \frac{\int_y^\infty \theta \theta^{-(n+a+1)} e^{-1/b\theta} d\theta}{\int_0^\infty \theta^{-(n+a+1)} e^{-1/b\theta} d\theta} \\ &= \frac{\int_y^\infty \theta^{-(n+a)} e^{-1/b\theta} d\theta}{\frac{n(n+a)b^{n+a}}{\Gamma(n+a)} \int_0^\infty \frac{1}{\Gamma(n+a)} \theta^{-(n+a)} e^{-1/b\theta} d\theta} \\ &= \frac{\frac{n(n+a-1)b^{n+a-1}}{\Gamma(n+a-1)b^{n+a-1}} \int_y^\infty \frac{1}{\Gamma(n+a-1)} \theta^{-(n+a)} e^{-1/b\theta} d\theta}{\frac{n(n+a)b^{n+a}}{\Gamma(n+a)} \int_0^\infty \frac{1}{\Gamma(n+a)} \theta^{-(n+a)} e^{-1/b\theta} d\theta} \end{aligned}$$

mas $\Gamma(n+a) = (n+a-1)! = (n+a-1)(n+a-2)! = (n+a-1)\Gamma(n+a-1)$

$$\begin{aligned} E[\Phi | y, a, b] &= \frac{1}{b(n+a-1)} \times \frac{\int_y^\infty \frac{1}{\Gamma(n+a-1)} b^{n+a-1} \theta^{-(n+a)} e^{-1/b\theta} d\theta}{\int_0^\infty \frac{1}{\Gamma(n+a)} b^{n+a} \theta^{-(n+a)} e^{-1/b\theta} d\theta} \\ &= \frac{1}{b(n+a-1)} \frac{P[GI(n+a-1, b) > y]}{P[GI(n+a, b) > y]} \\ &= \frac{1}{b(n+a-1)} \frac{P[1/Gamma(n+a-1, b) > y]}{P[1/Gamma(n+a, b) > y]} \\ &= \frac{1}{b(n+a-1)} \frac{P[Gama(n+a-1, b) < 1/y]}{P[Gama(n+a, b) < 1/y]} \end{aligned}$$

Sabemos que

$$\text{b) Goma}(n+a-1, b) = \frac{\chi_{2(n+a-1)}^2}{\chi_{2(n+a-1)}^2}$$

↳ Se a fdp da Goma(a,b) for $\frac{1}{\Gamma(a)b^a} \theta^{a-1} e^{-\theta/b}$, $\theta > 0$

$$\Rightarrow \text{Goma}(n+a-1, b) = \frac{b}{2} \chi_{2(n+a-1)}^2 \text{ . Daí.}$$

$$\begin{aligned} E[\Phi | y, a, b] &= \frac{1}{b(n+a-1)} \frac{P[\frac{b}{2} \chi_{2(n+a-1)}^2 < 1/y]}{P[\frac{b}{2} \chi_{2(n+a)}^2 < 1/y]} \\ &= \frac{1}{b(n+a-1)} \frac{P[\chi_{2(n+a-1)}^2 < 2/by]}{P[\chi_{2(n+a)}^2 < 2/by]} \end{aligned}$$

Portanto:

$$E[\Phi | y, a, b] = \frac{1}{b(n+a-1)} \frac{P[\chi_{2(n+a-1)}^2 < 2/by]}{P[\chi_{2(n+a)}^2 < 2/by]}$$

09) Suponha que, dado $\theta + \sigma^2$, x_1, \dots, x_n seguem o.a. independentes com distribuições $N(\theta, \sigma^2)$. Admita que, a priori, $\theta = U(20^2)$ tem distribuição Gama ($g, 1/4$) e σ , independente de θ , tem distribuição uniforme (impropria) na reta.

(a) Mostre que a densidade conjunta a posteriori é proporcional a $v^{r+g+1} e^{-v[\alpha+\beta+n(\bar{x}-\theta)^2]}$ onde $\beta = \sum_{i=1}^n (x_i - \bar{x})^2$, $r = n/2$.

Temos que

$$\theta = \frac{1}{2\sigma^2} \sim \text{Gama}(g, 1/\sigma^2)$$

$$\Rightarrow \pi(\theta) = \frac{1}{I(g)(1/\sigma^2)^g} v^{g-1} e^{-v/2\sigma^2}, \quad v > 0$$

$$= \frac{1}{I(g)} v^g v^{g-1} e^{-v/2}, \quad v > 0$$

como $\theta \sim U(-\infty, \infty)$ então

$$\pi(\theta) = \frac{1}{b-a} I(g), \quad \text{onde } a = -\infty \text{ e } b = \infty$$

Temos ainda que

$$x_i | \theta, \sigma^2 \sim N(\theta, \sigma^2)$$

Já que a verossimilhança é dada por

$$\begin{aligned} f(z | \theta, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x_i - \theta)^2\right\} \\ &= (\pi)^{-n/2} \left(\frac{1}{2\sigma^2}\right)^n \exp\left\{-\frac{n}{2\sigma^2} \sum (x_i - \theta)^2\right\} \\ &= \frac{v^{n/2}}{\pi^{n/2}} \exp\left\{-\frac{n}{2} \sum_{i=1}^n (x_i - \theta + z - \bar{x})^2\right\} \\ &= \frac{v^{n/2}}{\pi^{n/2}} \exp\left\{-\frac{n}{2} \sum_{i=1}^n [(x_i - \bar{x})^2 + 2(x_i - \bar{x})(\bar{x} - z) + (\bar{x} - z)^2]\right\} \\ &= \frac{v^{n/2}}{\pi^{n/2}} \exp\left\{-\frac{n}{2} \left[\sum_{i=1}^n (x_i - \bar{x})^2 + 2(\bar{x} - z) \sum_{i=1}^n (x_i - \bar{x}) + n(\bar{x} - z)^2 \right]\right\} \\ &= \frac{v^{n/2}}{\pi^{n/2}} \exp\left\{-\frac{n}{2} \left[\sum_{i=1}^n (x_i - \bar{x})^2 + 2(\bar{x} - z) \cancel{\left[\sum_{i=1}^n (x_i - \bar{x}) \right]} + n(\bar{x} - z)^2 \right]\right\} \end{aligned}$$

$$(z | \theta, \sigma^2) = \frac{v^n}{\pi^n} \exp\left\{-\frac{n}{2} [z + n(\bar{x} - z)^2]\right\}$$

onde $\beta = \sum_{i=1}^n (x_i - \bar{x})^2$ e $n = n/2$

Então θ e σ não são independentes entre si.

$$\pi(\theta, \sigma^2) = \pi(\theta) \pi(\sigma^2)$$

$$= \frac{1}{b-a} I(g) \frac{1}{\pi^n} v^g v^{g-1} e^{-v/2}, \quad v > 0, a = -\infty \text{ e } b = \infty$$

Sabemos que

$$\pi(\theta, \sigma^2 | z) \propto f(z | \theta, \sigma^2) \pi(\theta, \sigma^2)$$

Logo

$$\pi(\theta, \sigma^2 | z) \propto \frac{v^n}{\pi^n} e^{-v[\beta + n(\bar{x} - z)^2]} \frac{1}{b-a} I(g) \frac{1}{\pi^n} v^g v^{g-1} e^{-v/2}$$

onde $v > 0$, $a = -\infty$ e $b = \infty$. Daí

$$\pi(\theta, \sigma^2 | z) \propto v^{n+g-1} e^{-v[\alpha + \beta + n(\bar{x} - z)^2]}$$

$$\text{onde } \beta = \sum_{i=1}^n (x_i - \bar{x})^2 \text{ e } n = n/2$$

b) mostre que distribuição a posteriori de \bar{x} é Gama ($\bar{x} + g/2, n/2$)

sabemos que

$$\pi(\theta, \bar{x} | z) = \pi(\bar{x} | z) \pi(\theta | \bar{x}, z) \quad (*)$$

mos pelo item a)

$$\begin{aligned}\pi(\theta, \bar{x} | z) &\propto \bar{x}^{n+g-1} e^{-\bar{x}[\bar{x}+g+n(\bar{x}-\theta)^2]} \\ &= \bar{x}^{n+g-\frac{1}{2}-1} e^{-\bar{x}(\bar{x}+g)} \bar{x}^{\frac{n}{2}} e^{-\bar{x}n(\bar{x}-\theta)^2} \\ &\propto \pi(\bar{x} | z) \pi(\theta | \bar{x}, z) \text{ por } (*)\end{aligned}$$

Logo

$$\begin{aligned}\pi(\theta | \bar{x}, z) &\propto \bar{x}^{\frac{n}{2}} e^{-\bar{x}n(\bar{x}-\theta)^2} \\ &= \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{(\bar{x}-\theta)^2}{2\bar{x}n}\right\} \quad (\dagger)\end{aligned}$$

que é núcleo de uma $N(\bar{x}, 1/2\bar{x}n)$ logo

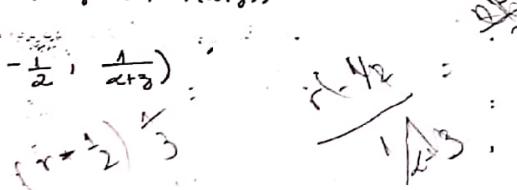
$$\theta | \bar{x} = z \sim N\left(\bar{x}, \frac{1}{2\bar{x}n}\right)$$

Temos ainda

$$\pi(z | \bar{x}) \propto \bar{x}^{n+g-\frac{1}{2}-1} e^{-\bar{x}(\bar{x}+g)}$$

que é núcleo de uma Gama ($\bar{x}+g-\frac{1}{2}, 1/(2\bar{x}n)$) logo

$$z | \bar{x} = z \sim \text{Gama}\left(\bar{x}+g-\frac{1}{2}, \frac{1}{2\bar{x}n}\right)$$



Obs: Outra forma é integrar $\pi(\theta, z | \bar{x})$ com respeito a θ .

(c) Mostre que se $\alpha = g = 0$, o estimador de Bayes (generalizado) de σ^2 é $\bar{z}/(n-3)$ para pista quadrática. Para pista $(d-\sigma)^2/\sigma^2$ este estimador é $\bar{z}/(n+1)$

$$\text{sabemos que } \bar{z} = \frac{1}{2\bar{x}^2} \Rightarrow \sigma^2 = \frac{1}{2\bar{x}^2} = g(\bar{x})$$

Logo corolário é, temos que o estimador de Bayes web pista quadrática é dado por

$$\delta(x) = E[g(\bar{x}) | \bar{x} = x]$$

$$= \int_0^\infty g(\bar{x}) \pi(\bar{x} | x = x) d\bar{x}$$

$$= \int_0^\infty \frac{1}{2x} \frac{1}{\Gamma(n+g-1/2)} (\bar{x}+g)^{n+g-1/2} \bar{x}^{n+g-1/2-1} e^{-(\bar{x}+g)x} d\bar{x}$$

Logo $\alpha = g = 0$ então

$$\delta(x) = \int_0^\infty \frac{1}{2x} \frac{1}{\Gamma(n+1)} \bar{x}^{n-1/2} \bar{x}^{n-1/2-1} e^{-\bar{x}x} d\bar{x}$$

mas, $\bar{x} = x/2$ dai,

$$\delta(x) = \int_0^\infty \frac{1}{2} \frac{1}{\Gamma(\frac{n+1}{2})} \bar{x}^{\frac{n-1}{2}-1} e^{-\bar{x}^2} d\bar{x}$$

$$= \frac{1}{2} \int_0^\infty \frac{1}{(\frac{n-1}{2}-1) \Gamma(\frac{n+1}{2}-1)} \bar{x}^{\frac{n-1}{2}-1+1} \bar{x}^{\frac{n-1}{2}-1-1} e^{-\bar{x}^2} d\bar{x}$$

$$= \frac{1}{2} \frac{3}{(\frac{n-1}{2}-1)} \int_0^\infty \frac{1}{\Gamma(\frac{n-1}{2})} \bar{x}^{\frac{n-1}{2}-1} \bar{x}^{\frac{n-1}{2}-1-1} e^{-\bar{x}^2} d\bar{x}$$

L, pois é fdp de uma Gama ($\frac{n-1}{2} - 1, \frac{1}{3}$)

$$= \frac{1}{2} \frac{3}{(\frac{n-1}{2}-1)} = \frac{1}{2x} \frac{3}{\frac{n-1-2}{x}}$$

Portanto

$$\boxed{\delta(x) = \frac{3}{n-3}}$$

$$\Rightarrow \delta(x) = \frac{3}{n-3}$$

→ considerar agora a perda $\frac{1}{\alpha^4} (d-\alpha)^2$

Temos que (pelo corolário 2) o estimador de Bayes para $g(x) = \frac{1}{x^2}$ é dado por

$$\delta^*(x) = \frac{E[w(x)g(x) | x=x]}{E[w(x) | x=x]} \quad \text{onde } w(x) = \frac{1}{\alpha^4} = 4x^2$$

mas

$$\begin{aligned} E[w(x)g(x) | x=x] &= E[2x | x=x] \\ &= 2E[x | x=x] \\ &= 2\left(n + g - \frac{1}{2}\right)\left(\frac{1}{n+g}\right) \end{aligned}$$

ficou $x = g = 0$ então

$$E[w(x)g(x) | x=x] = 2\left(n - \frac{1}{2}\right)\frac{1}{3} = 2\left(\frac{n}{2} - \frac{1}{2}\right)\frac{1}{3} = \frac{n-1}{3}$$

Temos ainda

$$\begin{aligned} E[w(x) | x=x] &= E[4x^2 | x=x] \\ &= 4E[x^2 | x=x] \\ &= 4\{\text{Var}(x | x=x) + E^2(x | x=x)\} \\ &= 4\left\{(n+g - \frac{1}{2})\left(\frac{1}{n+g}\right)^2 + (n+g - \frac{1}{2})^2\left(\frac{1}{n+g}\right)^2\right\} \end{aligned}$$

Colocando $x = g = 0$ temos

$$E(w(x) | x=x) = 4\left\{(n - \frac{1}{2})\frac{1}{3^2} + (n - \frac{1}{2})^2\frac{1}{3^2}\right\}$$

$$= \frac{4}{3^2} \left\{ \frac{n-1}{2} + \left(\frac{n-1}{2}\right)^2 \right\}$$

$$E[w(x) | x=x] = \frac{4}{3^2} \left\{ \frac{n-1}{2} + n^2 - 2n + 1 \right\}$$

$$= \frac{1}{3^2} \left\{ 2n - 2 + n^2 - 2n + 1 \right\}$$

$$= \frac{n^2 - 1}{3^2} = \frac{(n-1)(n+1)}{3^2}$$

Logo $\delta^*(x) = \frac{n-1}{3} \frac{3^2}{(n-1)(n+1)} = \frac{3}{n+1}$

Portanto

$$\delta^*(x) = \frac{2}{n+1}$$

(d) mostre que a densidade a posteriori de θ é simétrica em relação a \bar{x} e que o estimador de Bayes (generalizado) é \bar{x} .

Pelo item a) temos que

$$\pi(\theta, \alpha | z) \propto \alpha^{n+g-1} \exp\{-\alpha(\alpha + g + n(\bar{x} - \alpha)^2)\}$$

Daí temos

$$\pi(\theta | z) = \int_0^\infty \pi(\theta, \alpha | z) d\alpha$$

$$\propto \int_0^\infty \alpha^{n+g-1} \exp\{-\alpha(\alpha + g + n(\bar{x} - \alpha)^2)\} d\alpha$$

mas $\alpha^{n+g-1} \exp\{-\alpha(\alpha + g + n(\bar{x} - \alpha)^2)\}$ é o núcleo de uma

Gama $(n+g-1, 1/(2\bar{x}-\alpha))$ untao

$$\int_0^\infty \alpha^{n+g-1} \exp\{-\alpha(\alpha + g + n(\bar{x} - \alpha)^2)\} d\alpha = \frac{r(n+g)}{(\alpha + g + n(\bar{x} - \alpha)^2)^{(n+g)}}$$

que é proporcional a $[(\alpha + g + n(\bar{x} - \alpha)^2)^{(n+g)}]$ untao

$$\begin{aligned}\pi(\theta | z) &\propto [(\alpha + g + n(\bar{x} - \alpha)^2)^{(n+g)}] \\ &= \left[(\alpha + g) \left(1 + \frac{n(\bar{x} - \alpha)^2}{\alpha + g} \right) \right]^{-(n+g)} \\ &\propto \left(1 + \frac{n(\bar{x} - \alpha)^2}{\alpha + g} \right)^{-(n+g)}\end{aligned}$$

que é o núcleo de uma t-student ($\bar{x}; s^2, v$), onde

$$\begin{aligned}\frac{\alpha+g}{2} = n+g \Rightarrow v = 2(n+g) = 1 > 0 \quad \perp \quad v s^2 = \frac{\alpha+g}{n} \Rightarrow s^2 = \frac{\alpha+g}{nv} \\ \Rightarrow s^2 = \frac{(\alpha+g)/n}{(n+g-1)} > 0\end{aligned}$$

Portanto

$$\theta | z \sim t\left(\bar{x}; \frac{\alpha+g}{2(n+g-1)}, \frac{v s^2}{2(n+g-1)}\right)$$

Portanto $\theta | z$ é simétrica em relação a \bar{x} .

Sob Perda quadrática temos que

$$\begin{aligned}s^2(z) &= E[\theta | z] \\ &= \bar{x}.\end{aligned}$$

Portanto o estimador de Bayes é \bar{x} .

10) Seja x uma única observação de uma variável aleatória com densidade $f(x|\theta) = 2x/\theta^2$, $0 < x < \theta$; $\theta > 0$. Considerar para θ uma distribuição uniforme no intervalo unitário - encontre o estimador de Bayes com perda a pena $\theta^2(d-\theta)^2$

Temos que

$$f(x|\theta) = \frac{2x}{\theta^2} I_{(0,\theta)}(x) = \frac{2x}{\theta^2} I_{(0,\infty)}(\theta)$$

$$\pi(\theta) = I_{(0,1)}$$

Logo a posteriori é

$$\pi(\theta|x) = \frac{1}{q(x)} f(x|\theta) \pi(\theta) = \frac{1}{q(x)} \frac{2x}{\theta^2} I_{(x,0)}(\theta) I_{(0,1)}(\theta) = \frac{1}{q(x)} \frac{2x}{\theta^2} I_{(0,1)}(\theta)$$

onde

$$q(x) = \int_x^1 f(z|\theta) \pi(z) dz$$

$$= \int_x^1 \frac{2z}{\theta^2} dz = 2x \int_x^1 \theta^{-2} dz =$$

$$= 2x \left[-\theta^{-1} \right]_x^1 = 2x (-1 + x^{-1})$$

$$= -2x + 2 = x(2-x), \quad 0 < x < 1$$

Logo

$$\pi(\theta|x) = \frac{1}{x(2-x)} \frac{2x}{\theta^2} I_{(x,1)}(\theta) \quad 0 < x < 1$$

$$= \frac{x}{\theta^2(1-x)} I_{(x,1)}(\theta) I_{(0,1)}(\theta)$$

Rito constante 2. Temos que o estimador de Bayes de $g(\theta) = \theta$ é

dado por

$$S(x) = \frac{E[\omega(\theta) g(\theta) | x=x]}{E[\omega(\theta) | x=x]} \quad \text{onde } \omega(\theta) = \theta^2$$

Logo

$$S(x) = \frac{E[\theta^3 | x=x]}{E[\theta^2 | x=x]}$$

Daí

$$E[\theta^3 | x=x] = \int_x^1 \theta^3 \pi(\theta | x) d\theta$$

$$= \int_x^1 \theta^3 \frac{x}{\theta^2(1-x)} d\theta$$

$$= \frac{x}{(1-x)} \int_x^1 \theta d\theta$$

$$= \frac{x}{1-x} \frac{\theta^2}{2} \Big|_x^1 = \frac{x}{1-x} \left(\frac{1}{2} - \frac{x^2}{2} \right) = \frac{x(x-1)}{2(1-x)}$$

$$= \frac{x(x+1)(1-x)}{2(1-x)} = \frac{x(x+1)}{2}$$

$$E[\theta^2 | x=x] = \int_x^1 \theta^2 \frac{x}{\theta^2(1-x)} d\theta$$

$$= \frac{x}{1-x} \int_x^1 d\theta$$

$$= \frac{x(1-x)}{1-x} = x$$

Logo

$$S(x) = \frac{x(x+1)}{2} \frac{1}{x}$$

Portanto o estimador de Bayes de θ sob a pena $\theta^2(d-\theta)^2$ é

dado por

$$S(x) = \frac{x+1}{2}$$

II) Suponha que, dado p , $X \sim b(n, p)$ e considere a densidade (imposta) proporcional a $p^x(1-p)^{n-x}$ para p . Mostre que \bar{x}/n é um estimador de Bayes (generalizado) para p sob perda quadrática.

Temos que

$$X|p \sim b(n, p)$$

então

$$\pi(x|p) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x=0, 1, \dots, n \quad 0 < p < 1$$

$$\pi(p) \propto \frac{1}{p(1-p)}, \quad 0 < p < 1$$

Logo o posterior é proporcional:

$$\begin{aligned} \pi(p|x) &\propto p^x (1-p)^{n-x} \frac{1}{p(1-p)} \\ &= p^{x-1} (1-p)^{(n-x)-1} \end{aligned}$$

que é o mêsco de uma Beta($x, n-x$). Logo

$$p|x=x \sim \text{Beta}(x, n-x)$$

1º caso) se $x=1, \dots, n-1$

Temos que (pelo corolário 2) sob perda quadrática o estimador de Bayes para p é

$$\delta(x) = E[p|x=x] = \frac{x}{n-x} = \frac{x}{n}$$

Portanto

$$\delta(x) = \frac{x}{n}$$

2º caso) se $x=0$

$$\pi(p|x) \underset{\text{Binomial}}{\propto} \frac{(1-p)^{n-1}}{p} = \frac{1}{p} \sum_{k=0}^{n-1} \binom{n-1}{k} 1^k (-p)^{n-1-k}$$

$$= \frac{1}{p} \sum_{k=0}^{n-1} \binom{n-1}{k} (-1)^{n-1-k} p^{n-1-k}$$

$$= \frac{1}{p} + \sum_{k=0}^{n-2} \binom{n-1}{k} (-1)^{n-1-k} p^{n-1-k} \quad (*)$$

Uma integral da cada parcela no denominador em $(*)$ é finito e da parcela $\frac{1}{p}$ se $p \rightarrow \infty$, logo

$$\int_0^1 \frac{(1-p)^{n-1}}{p} dp = k + \int_0^k \frac{1}{p} dp$$

↓ integral da mesma em $(*)$

$$= k + \log \int_0^k = \infty \quad \text{onde } k \text{ é um } n \text{ real fixo.}$$

Neste caso $\pi(p|x)$ não é densidade.

3º caso) se $x=n$

$$\pi(p|x) \propto \frac{p^{n-1}}{(1-p)} = \frac{(1-q)^{n-1}}{q}$$

Segundo a mesma ideia do caso $x=0$ temos que $\int_0^1 \frac{(1-q)^{n-1}}{q} dp = \infty$

neste $\pi(p|x)$ não é densidade.

Então definimos o estimador de Bayes para p , por

$$\delta(x) = \begin{cases} 0 & \text{se } x=0 \\ \frac{x}{n} & \text{se } x=1, \dots, n-1 \\ 1 & \text{se } x=n. \end{cases}$$

12) Suponha que x tem distribuição $b(p, n)$ e considere o problema de estimar p com perda quadrática. Encontre o risco do estimador minimax e discuta sua direção (ver exemplo 1.7, p. 344, TPE).

Suponha que p é da forma $(a+b)$, $a \geq 0$, $b \geq 0$ então

$$\pi(p) = \frac{M(a+b)}{n(a)n(b)} + a^{-1}(1-p)^{b-1}, \quad a \geq 0, b \geq 0, 0 < p < 1$$

Sabemos que para $x=0, 1, \dots, n$

$$f(x|p) = \binom{n}{x} p^x (1-p)^{n-x}$$

Logo temos a posteriori

$$\pi(p|x) \propto p^{a+x-1} (1-p)^{n-x+b-1}$$

que é o núcleo de uma beta $(a+x, n+b-x)$ logo

$$p|x=x \sim \text{Beta}(a+x, n+b-x)$$

Pelo contrário 2, sob perda quadrática temos que o estimador de Bayes para p é

$$\delta(x) = E(p|x=x)$$

$$= \frac{a+x}{a+x+n+b-x}$$

Portanto o estimador de Bayes para p sob perda quadrática é

$$\delta(x) = \frac{a+x}{a+b+n}$$

Agora vamos encontrar o risco de Bayes sob a perda quadrática:

$$l(p, \delta(x)) = E_p \left[\left(\frac{a+x}{a+b+n} - p \right)^2 \right] = \text{Var}_p \left[\frac{x+a}{a+b+n} - p \right] + E^2 \left[\frac{x+a}{a+b+n} - p \right]$$

$$= \frac{\text{Var}(x)}{(a+b+n)^2} + \left[\frac{E(x) + a}{a+b+n} - p \right]^2$$

$$R(p, \delta(x)) = \frac{np(1-p)}{(a+b+n)^2} + \left[\frac{np+a}{a+b+n} - p \right]^2$$

$$\text{risco de Bayes} = \frac{np(1-p)}{(a+b+n)^2} + \frac{(np+a - np-ap-bp)^2}{(a+b+n)^2}$$

$$= \frac{1}{(a+b+n)^2} [np(1-p) + [a-(a+b)p]^2]$$

Agora devemos encontrar $(a+b)$ tal que $R(p, \delta(x))$ seja constante em p

$$\begin{aligned} np(1-p) + [a-(a+b)p]^2 &= np - np^2 + a^2 - 2a(a+b)p + (a+b)^2 p^2 \\ &= p(n - 2a(a+b)) + p^2(-n + (a+b)^2) + a^2 \end{aligned}$$

é constante. Um \Rightarrow que

$$n - 2a(a+b) = 0 \quad \text{e} \quad -n + (a+b)^2 = 0$$

$$\Leftrightarrow n = 2a(a+b) \quad \text{e} \quad n = (a+b)^2 \quad (1)$$

Como $a, b > 0$ então de (1) temos

$$a+b = \sqrt{n} \quad \text{e} \quad \frac{n}{2} = a^2 + ab$$

Daí, temos que $a = b = \frac{\sqrt{n}}{2}$

Logo o estimador minimax para p é dado por

$$\delta(x) = \frac{x + \sqrt{n}/2}{\sqrt{n} + n}$$

Sob perda quadrática.

→ Encontrar o risco de $s(x)$

$$\text{risco} = b(p) = p - E(s(x))$$

$$= p - E\left[\frac{x + \sqrt{n}/2}{n + \sqrt{n}}\right]$$

$$= p - \frac{np + \sqrt{n}/2}{n + \sqrt{n}}$$

$$= \frac{np + \sqrt{n} - np - \sqrt{n}/2}{n + \sqrt{n}}$$

$$= \frac{\sqrt{n}(p + 1/2)}{\sqrt{n}(\sqrt{n} + 1)} = \frac{p - 1/2}{\sqrt{n} + 1}$$

Portanto o risco de $s(x)$ é

$$b(p) = \frac{p - 1/2}{\sqrt{n} + 1}$$

Temos que

$$\lim_{n \rightarrow \infty} b(p) = \lim_{n \rightarrow \infty} \frac{p - 1/2}{\sqrt{n} + 1} = 0$$

para p fixo

Portanto, o risco $b(p)$ é decrescente em n .

13) No contexto da questão anterior, compare o risco do estimador minimax com o de $\frac{X}{n}$

O risco do estimador minimax é dado por

$$R(p, \delta(x)) = \frac{1}{(n+\sqrt{n})^2} [np(1-p) + (\sqrt{n}/2 - \sqrt{n}p)^2]$$

e o risco de $S^*(x) = \frac{X}{n}$ é dado por

$$\begin{aligned} R(p, S^*(x)) &= E_p[(p - S^*(x))^2] & V(A) &= E(A^2) - E^2(A) \\ &= \text{Var}_p(S^*(x) - p) + \{E_p(S^*(x) - p)\}^2 & E(A^2) &= V(A) + E^2(A) \\ &= \text{Var}_p\left(\frac{X}{n}\right) + [E_p(S^*(x)) - p]^2 & \\ &= \text{Var}_p\left(\frac{X}{n}\right) + \left[\frac{1}{n}E(X) - p\right]^2 & \\ &= \frac{n}{n^2}p(1-p) + \left[\frac{np}{n} - p\right]^2 & \\ &= \frac{p(1-p)}{n} \end{aligned}$$

Notemos que $R(p, S^*(x))$ é constante pois

$$\begin{aligned} R(p, S^*(x)) &= \frac{1}{(n+\sqrt{n})^2} \left[np - np^2 + \frac{n}{4} - 2\frac{\sqrt{n}}{2} \sqrt{n}p + np^2 \right] \\ &= \frac{1}{(n+\sqrt{n})^2} [np + n/4 - np] = \frac{n/4}{(n+\sqrt{n})^2} \\ &= \frac{n/4}{n^2 + 2n\sqrt{n} + n} = \frac{n/4}{n(n+2\sqrt{n}+1)} = \frac{1}{4(n+2\sqrt{n}+1)} \\ &= \frac{1}{4n+8\sqrt{n}+4} \end{aligned}$$

Sabemos que

$$p(1-p) \leq \frac{1}{4} \quad \forall 0 < p < 1$$

então

$$\frac{p(1-p)}{n} \leq \frac{1}{4n}$$

$$\text{Risco de } \frac{X}{n} > \text{Risco de } S^*\text{ minimax}$$

$$\frac{1}{4n} > \frac{1}{4(1+\sqrt{n})^2} = \frac{1}{4n+8\sqrt{n}+4}$$

$$n=1, \quad \frac{1}{4}$$

$$n=2, \quad \frac{1}{8}$$

$$\frac{1}{8} \quad 23.2$$

- 14) Suponha que X tem distribuição $B(p, n)$ e considere o problema de estimar p com perda $(d-p)^2 / [(p(1-p))]$. Obtenha o estimador mínimo.

Suponha que $p \sim \text{Beta}(a, b)$, $a > 0, b > 0$ então

$$\pi(p) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} p^{a-1} (1-p)^{b-1}, \quad a > 0, b > 0, 0 < p < 1$$

Sabemos que para $x=0, 1, \dots, n$

$$f(x|p) = \binom{n}{x} p^x (1-p)^{n-x}$$

Logo Juros a posteriori

$$\pi(p|x) \propto p^{(a+x)-1} (1-p)^{(n-x+b)-1}$$

que é o núcleo de uma Beta $(a+x, n+b-x)$ logo

$$p|x=x \sim \text{Beta}(a+x, n+b-x)$$

Pelo corolário 2, visto à perda $\frac{1}{p(1-p)}$ o estimador de Bayes de $g(p) = p^{-x}$

$$g(x) = \frac{E[\omega(p)g(p)|x=x]}{E[\omega(p)|x=x]}, \quad \text{onde } \omega(p) = \frac{1}{p(1-p)}.$$

mas,

$$E[\omega(p)g(p)|x=x] = E[(1-p)^{-x}|x=x]$$

$$= \int_0^1 (1-p)^{-x} \pi(p|x) dp$$

$$= \int_0^1 (1-p)^{-x} \frac{\Gamma(a+b+n)}{\Gamma(a+x)\Gamma(n+x+b)} p^{a+x-1} (1-p)^{n+b-x-1} dp$$

$$= \frac{\Gamma(a+b+n)}{\Gamma(a+x)\Gamma(n+b-x)} \int_0^1 p^{(a+x)-1} (1-p)^{(n+b-x)-1} dp$$

→ Vira

$$E[\omega(p)g(p)|x=x] = \frac{\Gamma(a+n+b)}{\Gamma(a+x)\Gamma(n+x+b)} \frac{\Gamma(a+x)\Gamma(n-x+b-1)}{\Gamma(a+b+n-1)} \int_0^1 \frac{p^{(a+b+n-1)}}{\Gamma(a+b+n-1)} p^{(n-x+b-1)} (1-p)^{n+b-x-1} dp$$

1 é fdp da
Beta $(a+x, n-x+b-1)$

$$= \frac{\Gamma(a+n+b) \Gamma(n-x+b-1)}{\Gamma(n-x+b) \Gamma(a+b+n-1)}$$

$$= \frac{(a+b+n-1)! (n-x+b-1)!}{(n-x+b-1)! (a+b+n-2)!}$$

$$= \frac{(a+b+n-1) (a+b+n-2)! (n-x+b-2)!}{(n-x+b-1) (n-x+b-2)! (a+b+n-2)!}$$

$$= \frac{a+b+n-1}{n+b-x-1}$$

$$E[\omega(p)|x=x] = \int_0^1 p^{-x} \frac{\Gamma(a+b+n)}{\Gamma(a+x)\Gamma(n+x+b)} p^{a+x-1} (1-p)^{n+b-x-1} dp$$

$$= \frac{\Gamma(a+b+n)}{\Gamma(a+x)\Gamma(n+x+b)} \frac{\Gamma(a+x-1)\Gamma(n-x+b-1)}{\Gamma(a+b+n-2)} \int_0^1 \frac{\Gamma(n+a+b-2)}{\Gamma(x+a-1)\Gamma(n+x+b-1)} p^{(a+x-1)-1} (1-p)^{(n+b-x-1)-1} dp$$

1 é fdp da
Beta $(a+x-1, n+b-x-1)$

Logo

$$E[\omega(p)|x=x] = \frac{(a+b+n-1)! (a+x-2)! (n-x+b-2)!}{(a+x-1)! (n-x+b-1)! (a+b+n-3)!}$$

$$= \frac{(a+b+n-1) (a+b+n-2) (a+b+n-3)! (a+x-2)! (n-x+b-2)!}{(a+x-1) (a+x-2)! (n-x+b-1)! (n-x+b-2)! (a+b+n-3)!}$$

$$= \frac{(a+b+n-1) (a+b+n-2)}{(a+x-1) (n-x+b-1)}$$

Logo

$$\delta(x) = \frac{(a+b+n-1)}{(b+n-x-1)} \cdot \frac{(a+x-1)(b+n-x-1)}{(a+b+n-1)(a+b+n-2)}$$

Pertanto

$$S(x) = \frac{a+x-1}{a+b+n-2}$$

Agora vamos calcular o viés de $\delta(x)$

$$R(p, \delta(x)) = E_p \{ L(p, \delta(x)) \}$$

$$= E_p \left\{ \frac{1}{p(1-p)} (\delta(x) - p)^2 \right\}$$

$$= \frac{1}{p(1-p)} E [(\delta(x) - p)^2]$$

$$= \frac{1}{p(1-p)} \left\{ \text{Var} [\delta(x) - p] + E^2 [\delta(x) - p] \right\}$$

$$= \frac{1}{p(1-p)} \left\{ \text{Var} (\delta(x)) + [E(\delta(x)) - p]^2 \right\}$$

mas

$$\text{Var} (\delta(x)) = \frac{1}{(a+b+n-2)^2} \text{Var}(x) = \frac{np(1-p)}{(a+b+n-2)^2}$$

$$E(\delta(x)) = \frac{a+np-1}{(a+b+n-2)}$$

Logo

$$R(p, \delta(x)) = \frac{1}{p(1-p)} \left\{ \frac{np(1-p)}{(a+b+n-2)^2} + \left[\frac{(a+np-1)}{(a+b+n-2)} - p \right]^2 \right\}$$

$$\begin{aligned} R(p, \delta(x)) &= \frac{1}{p(1-p)} \left\{ \frac{np(1-p)}{(a+b+n-2)^2} + \frac{1}{(a+b+n-2)^2} \left[(a+np-1 - p(a+b+n-2))^2 \right] \right\} \\ &= \frac{1}{(a+b+n-2)^2} \left\{ n + \frac{1}{p(1-p)} [(a-1) - p(a+b+n-2-x)]^2 \right\} \\ &= \frac{1}{(a+b+n-2)^2} \left\{ n + \frac{1}{p(1-p)} [(a-1) - p(a+b-2)]^2 \right\} \end{aligned}$$

Para que $R(p, \delta(x))$ seja constante, ou seja, não dependa de p , precisamos que:

$$a-1 = 0 \Rightarrow a = 1$$

$$a+b-2 = 0 \Rightarrow b = 2-a = 2-1 \Rightarrow b = 1$$

Pertanto se $a = b = 1$ então o viés é constante. Ou seja,

$$R(p, \delta(x)) = \frac{x}{n}$$

Por um corolário vemos que se o estimador de Bayes $\delta(x)$ tiver viés constante então ele é minimox.

Tentando

$$\delta(x) = \frac{x+a-1}{n+a+b-2} = \frac{x+1-1}{n+2-2} = \frac{x}{n}$$

Pertanto $\delta(x) = \frac{x}{n}$ é estimador minimox de p .

LISTA DE EXERCÍCIOS 4
Estatística Avançada I

12. Seja X uma única observação de uma distribuição geométrica com função de probabilidade

$$f(x|\theta) = \theta^x(1-\theta), \quad x=0,1,\dots; \quad \theta \in (0,1)$$

a) Encontre o estimador do método dos momentos de θ .

Temos que se $X \sim \text{Geometria}(\theta)$ então

$$E(X) = \frac{\theta}{1-\theta}$$

Então, o estimador do método dos momentos de θ é a solução à equação.

$$X = \frac{\hat{\theta}_{MM}}{1-\hat{\theta}_{MM}} \Rightarrow (1-\hat{\theta}_{MM})X = \hat{\theta}_{MM}$$

Daí, temos que:

$$\hat{\theta}_{MM} = \frac{X}{1+X}$$

b) Existe estimador não viésado de θ ? Se sim, encontre o ENVVUM de θ .

Seja $\delta(x)$ um estimador tal que $E(\delta(x)) = \theta$, ou seja,

$$\sum_{x=0}^{\infty} \delta(x) \theta^x (1-\theta) = \theta$$

$$\sum_{x=0}^{\infty} \delta(x) \theta^x = \frac{\theta}{1-\theta} = \theta \sum_{i=0}^{\infty} \theta^i, \quad \text{pois} \quad \sum_{i=0}^{\infty} \theta^i = \frac{1}{1-\theta}, \quad |\theta| < 1$$

$$\Rightarrow \sum_{x=0}^{\infty} \delta(x) \theta^x = \sum_{i=0}^{\infty} \theta^{i+1}$$

Então,
 $\delta(x) = \begin{cases} 0 & \text{se } x=0 \\ 1 & \text{se } x>0 \end{cases}$ é um estimador não viésado de θ .

Temos que $f(x|\theta)$ pertence à família exponencial uniparamétrica (posto completo) então $T(X)=X$ é uma estatística suficiente e completa para θ . Então, $\delta(x)$ é ENVVUM pois ele é função de uma estatística suficiente e completa.

c) Considere uma distribuição a priori $U(0,1)$ para θ . Encontre o estimador de Bayes de θ sob perda quadrática.

Temos que $\theta \sim U(0,1)$ e $f(x|\theta) = \theta^x(1-\theta) I_{\{0,1,\dots\}}(x)$

Então a densidade a posteriori de θ está dada por:

$$f(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{f(x)}$$

$$\text{com } f(x) = \int_0^1 f(x|\theta) \pi(\theta) d\theta = \int_0^1 \theta^x(1-\theta) d\theta = \int_0^1 (\theta^x - \theta^{x+1}) d\theta \\ = \left[\frac{\theta^{x+1}}{x+1} - \frac{\theta^{x+2}}{x+2} \right] \Big|_0^1 = \frac{1}{x+1} - \frac{1}{x+2} = \frac{1}{(x+1)(x+2)}$$

Então

$$f(\theta|x) = \theta^x(1-\theta)(x+1)(x+2), \quad \theta \in (0,1)$$

Daí

$$\theta|x \sim \text{Beta}(x+1, 2)$$

Então o estimador de Bayes de θ sob perda quadrática é:

$$\hat{\theta}_B = \frac{x+1}{x+3} = E[\theta|x=x]$$

3. Suponha que, dado θ , x tem distribuição $P_\theta : P_\theta \in \mathcal{P} = \{\theta \in \Omega\}$. Seja Γ uma classe específica de distribuições a priori para θ e seja $r(\Delta, \delta)$ o risco de Bayes do estimador δ sob a distribuição a priori Δ .

Definição 1. Um estimador δ^* é gama-minimax (ou Γ -minimax) se

$$\inf_{\delta} \sup_{\Delta \in \Gamma} r(\Delta, \delta) = \sup_{\Delta \in \Gamma} r(\Delta, \delta^*)$$

Definição 2: Um estimador δ^* é gama-admissível (ou Γ -admissível) se não existe nenhum outro estimador δ tal que $r(\Delta, \delta) \leq r(\Delta, \delta^*)$, para todo $\Delta \in \Gamma$, com desigualdade estrita para pelo menos um membro de Γ .

a) Mostre que se $\Gamma = \{\Delta_0\}$, ou seja, Γ consiste de apenas uma distribuição a priori então o estimador de Bayes é Γ -minimax.

Como Γ consiste de apenas uma distribuição então:

$$\sup_{\Delta \in \Gamma} r(\Delta, \delta) = r(\Delta_0, \delta_{\Delta_0})$$

Daí, $\inf_{\delta} \sup_{\Delta \in \Gamma} r(\Delta, \delta) = \inf_{\delta} r(\Delta_0, \delta_{\Delta_0}) = r(\Delta_0, \delta_{\Delta_0})$, em que δ_{Δ_0} é o Est. Bayes

Então δ_{Δ_0} é Γ -minimax. (pela definição 1.)

b) Mostre que se $\Gamma = \{\text{Todos os distribuições a priori sobre } \Omega\}$, então o estimador minimax é Γ -minimax.

Seja δ^* o estimador minimax, então

$$\inf_{\delta} \sup_{\theta} R(\theta, \delta) = \sup_{\theta} R(\theta, \delta^*)$$

Isto quer dizer que δ^* minimiza o risco máximo, enquanto que, o estimador de Bayes minimiza o risco médio segundo $R(\theta)$.

$$\text{Então } \sup_{\theta} R(\theta, \delta) \geq \int R(\theta, \delta) d\Delta(\theta) = r(\Delta, \delta) \neq \delta \quad (*)$$

ou seja, o risco máximo de δ é maior do que seu risco médio segundo $\Delta(\theta)$. Com igualdade quando o risco $R(\theta, \delta)$ for constante em θ ou quando o conjunto $\{\theta \in \Omega : R(\theta, \delta) = \sup_{\theta} R(\theta, \delta)\}$ tem medida 1 segundo $\Delta(\theta)$.

$$\text{Então } \sup_{\Delta \in \Gamma} \int R(\theta, \delta) d\Delta(\theta) = \sup_{\Delta \in \Gamma} r(\Delta, \delta) = \sup_{\theta} R(\theta, \delta) \neq \delta \quad ?$$

ou seja, o $\sup_{\Delta \in \Gamma} r(\Delta, \delta)$ é o limite superior de $r(\Delta, \delta)$ segundo (*), pois Γ considera todos as distribuições a priori sobre Ω .

$$\text{Então } \inf_{\delta} \sup_{\theta} R(\theta, \delta) = \inf_{\delta} \sup_{\Delta \in \Gamma} r(\Delta, \delta)$$

$$\delta^* = \bar{\delta},$$

tal que $\bar{\delta}$ é Γ -minimax segundo a definição 1.

Então δ^* é Γ -minimax.

$$(*) \quad r(\bar{\delta}, \bar{\delta}) \leq r(\delta^*, \bar{\delta}), \forall \delta$$

c) Mostre que se δ_{Δ^*} é o único estimador de Bayes para $\Delta^* \in \Gamma$, então δ_{Δ^*} é Γ -admissível.

Provo pela contradição.

Supomos que existe $\bar{\delta}$, $\bar{\delta} \neq \delta_{\Delta^*}$, tal que δ_{Δ^*} é Γ -admissível, ou seja,

$$r(\Delta, \bar{\delta}) \leq r(\Delta, \delta_{\Delta^*}) \quad \forall \Delta \in \Gamma \quad (*)$$

Com desigualdade estrita para pelo menos um membro de Γ , mas $\bar{\delta} \neq \delta_{\Delta^*}$, e δ_{Δ^*} é o único estimador de Bayes para todo $\Delta^* \in \Gamma$, ou seja, δ_{Δ^*} minimiza o risco médio, e isto contradiz (*) e é o suporte de unicidade. $(*) \quad r(\bar{\delta}, \bar{\delta}) \leq r(\delta^*, \bar{\delta})$ mas por (*) e $(*)$ temos que $\bar{\delta} = \delta^*$

7. Seja X uma variável aleatória representando o tempo de vida de um sistema eletrônico, com função distribuição acumulada $F_0(x)$, $\theta \in \Omega$.

Defina a confiabilidade do sistema por

$$R_0(\tau) = P_0(X > \tau) = 1 - F_0(\tau), \quad \tau > 0$$

Considere n observações independentes x_1, \dots, x_n de X . Admita que, dado θ , X tem distribuição exponencial de parâmetro θ e f.d.p.

$$f(x; \theta) = \theta \exp(-\theta x), \quad x > 0; \theta > 0$$

a) Mostre que, neste caso $R_0(\tau) = \exp\{-\tau\theta\}$.

Temos que

$$R_0(\tau) = 1 - F_0(\tau) = 1 - \int_0^\tau \theta \exp(-\theta x) dx$$

$$= 1 - [\theta \exp(-\theta x)/\theta]_0^\tau = 1 - [-\exp(-\theta\tau) + 1]$$

$$= \exp\{-\theta\tau\}$$

b) Encontre o estimador de máxima verossimilhança de $R_0(\tau)$.

Temos que

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n \{\theta \exp(-\theta x_i)\} = \theta^n \exp\{-\theta n \bar{x}\}$$

$$L(\theta) = \log(f(x_1, \dots, x_n; \theta)) = n \log \theta - n \theta \bar{x}$$

Então

$$U_{\theta} = \frac{\partial L(\theta)}{\partial \theta} = \frac{n}{\theta} - n \bar{x} \Rightarrow U_{\hat{\theta}} = \frac{n}{\hat{\theta}} - n \bar{x} = 0$$

$$\frac{\partial U_{\theta}}{\partial \theta} = -\frac{n}{\theta^2} < 0 \quad \hat{\theta} = \frac{1}{\bar{x}}$$

Então o EMV de θ é $\hat{\theta} = \frac{1}{\bar{x}}$

Daí, temos que o EMV de $R_0(\tau)$ é

$$\widehat{R_0}(\tau) = \exp\{-\tau/\bar{x}\}$$

c) Encontre o ENVVUM de $R_0(\tau)$.

Temos que

$$f(x_1, \dots, x_n; \theta) = \exp\{-\theta n \bar{x} + n \log \theta\}$$

$$= \exp\{T(\bar{x})\eta - A(\eta)\} h(\bar{x}),$$

com $T(\bar{x}) = \bar{x}$, $\eta = -\theta n$, $A(\eta) = -n \log(-\eta/n)$ e $h(\bar{x}) = 1$

Então $f(x_1, \dots, x_n; \theta)$ pertence à família exponencial unidimensional, então $T(\bar{x}) = \bar{x}$ é uma estatística suficiente e completa para θ .

Seja $s(\bar{x})$ o estimador definido como:

$$s(\bar{x}) = \begin{cases} 1 & \text{se } x_1 > \tau \\ 0 & \text{se } x_1 \leq \tau \end{cases}$$

$$\text{Então } E(s(\bar{x})) = P(x_1 > \tau) = R_0(\tau)$$

Daí, temos que $s^*(\bar{x}) = E[s(\bar{x})/\bar{x}]$ é o ENVVUM de $R_0(\tau)$, pois \bar{x} é uma estatística suficiente e completa.

Sabemos que $n\bar{x} \sim \text{Gamma}(n, \theta)$, então, $(n\bar{x} - x_1) \sim \text{Gamma}(n-1, \theta)$

$$\text{Dai, } f(x_1 | \bar{x} = \bar{x}) = \frac{f(x_1, \bar{x})}{f(\bar{x})} = \frac{\theta \exp\{-\theta x_1\} \cdot \frac{\theta^{n-1}}{\Gamma(n-1)} (n\bar{x} - x_1)^{n-2} \exp\{-\theta(n\bar{x} - x_1)\} I_{(0, n\bar{x})}(x_1)}{\frac{\theta^n}{\Gamma(n)} (n\bar{x})^{n-1} \exp\{-\theta(n\bar{x})\}}$$

$$= \frac{\theta^n}{\Gamma(n)} \frac{(n\bar{x} - x_1)^{n-2}}{(n\bar{x})^{n-1}} I_{(0, n\bar{x})}(x_1)$$

$$= \frac{(n-1)}{n\bar{x}} \left(\frac{n\bar{x} - x_1}{n\bar{x}}\right)^{n-2} I_{(0, n\bar{x})}(x_1) = \frac{(n-1)}{n\bar{x}} \left(1 - \frac{x_1}{n\bar{x}}\right)^{n-2} I_{(0, n\bar{x})}(x_1)$$

Então, o ENVVUM de $R_0(\tau)$, $\delta^*(\bar{x})$, é o seguinte:

$$\delta^*(\bar{x}) = \begin{cases} a(\tau, \bar{x}) & \text{se } n\bar{x} > \tau \\ 0 & \text{cc} \end{cases}$$

onde

$$\begin{aligned} a(\tau, \bar{x}) &= P(X_i > \tau | \bar{x}) = \int_{\tau}^{n\bar{x}} \frac{(n-1)}{n\bar{x}} \left(1 - \frac{x_i}{n\bar{x}}\right)^{n-2} dx_i, \quad n\bar{x} > \tau \\ &= \frac{(n-1)}{(n\bar{x})^{n-1}} \int_{\tau}^{n\bar{x}} (n\bar{x} - x_i)^{n-2} dx_i = \frac{(n-1)}{(n\bar{x})^{n-1}} \left[-\frac{(n\bar{x} - x_i)^{n-1}}{n-1} \right] \Big|_{\tau}^{n\bar{x}} \\ &= \frac{(n-1)}{(n\bar{x})^{n-1}} \frac{(n\bar{x} - \tau)^{n-1}}{(n-1)} = \left(\frac{n\bar{x} - \tau}{n\bar{x}} \right)^{n-1} \\ &= \left(1 - \frac{\tau}{n\bar{x}} \right)^{n-1} \end{aligned}$$

$$\Rightarrow a(\tau, \bar{x}) = \left(1 - \frac{\tau}{n\bar{x}} \right)^{n-1}$$

Então $\delta^*(\bar{x})$ fica dada por:

$$\delta^*(\bar{x}) = \begin{cases} \left(1 - \frac{\tau}{n\bar{x}} \right)^{n-1} & \text{se } n\bar{x} > \tau \\ 0 & \text{cc} \end{cases}$$

d) Mostre que o estimador de Bayes de $R_0(\tau)$ sob perda quadrática é função de densidade a priori para θ

$$\Pi(\theta) = \frac{1}{\gamma^n \Gamma(n)} \theta^{n-1} \exp(-\theta/\gamma), \quad \theta > 0$$

é dado por

$$\left(1 + \frac{\tau}{\sum x_i + 1/\gamma} \right)^{-n+\gamma}$$

Temos que $\Pi(\theta) \sim \text{Gama}(\gamma, 1/\gamma)$ e $f(x|\theta) = \theta \exp\{-\theta x\}$.

Então a densidade a posteriori de θ está dada por:

$$f(\theta|x) = \frac{f(x|\theta) \cdot \Pi(\theta)}{f(x)}$$

$$\begin{aligned} \text{com } f(x) &= \int_0^\infty \frac{\theta^n}{\gamma^n \Gamma(n)} \theta^{n-1} \exp\{-\theta(n\bar{x} + 1/\gamma)\} d\theta \\ &= \frac{\gamma^{n+\gamma}}{(n\bar{x} + 1/\gamma)^{n+\gamma} \gamma^n \Gamma(n)} \underbrace{\int_0^\infty \theta^{n+\gamma-1} \exp\{-\theta(n\bar{x} + 1/\gamma)\} (n\bar{x} + 1/\gamma)^{n+\gamma} d\theta}_{\text{II}} \\ &= \frac{\gamma^{n+\gamma}}{(n\bar{x} + 1/\gamma)^{n+\gamma} \gamma^n \Gamma(n)} , \quad x \in \mathbb{R}^{n+1} \end{aligned}$$

Daí, temos que

$$f(x|0) = \frac{(n\bar{x} + 1/\gamma)^{n+\gamma}}{\Gamma(n+\gamma)} \theta^{n+\gamma-1} \exp\{-\theta(n\bar{x} + 1/\gamma)\}$$

Então $\theta|x \sim \text{Gama}(n+\gamma, (n\bar{x} + 1/\gamma))$

Daí, o estimador de Bayes de $R_0(\tau)$ sob perda quadrática é dado por:

$$\begin{aligned} E_{\theta|x}(\exp\{-\theta\tau\}) &= \int_0^\infty \frac{(n\bar{x} + 1/\gamma)^{n+\gamma}}{\Gamma(n+\gamma)} \theta^{n+\gamma-1} \exp\{-\theta(n\bar{x} + 1/\gamma + \tau)\} d\theta \\ &= \frac{(n\bar{x} + 1/\gamma)^{n+\gamma}}{(n\bar{x} + 1/\gamma + \tau)^{n+\gamma}} \underbrace{\int_0^\infty \frac{(n\bar{x} + 1/\gamma + \tau)^{n+\gamma}}{\Gamma(n+\gamma)} \theta^{n+\gamma-1} \exp\{-\theta(n\bar{x} + 1/\gamma + \tau)\} d\theta}_{\text{I}} \\ &= \left(\frac{n\bar{x} + 1/\gamma}{n\bar{x} + 1/\gamma + \tau} \right)^{n+\gamma} = \frac{1}{\left(1 + \frac{\tau}{n\bar{x} + 1/\gamma} \right)^{n+\gamma}} \\ &= \left(1 + \frac{\tau}{n\bar{x} + 1/\gamma} \right)^{-(n+\gamma)} \end{aligned}$$

II. Suponha que X tem distribuição Bin(p,n) e considere o problema de estimar p com perda $\frac{(d-p)^2}{[p(1-p)]}$. Obtenha o estimador minimax.

Corolário: Se a solução de Bayes \hat{s}_n tem risco constante ela é minimax. (pág. 165, Notas de aula).

Temos que $f(x|p) \sim \text{Bin}(n,p)$ e usando o priori para $p \sim U(0,1)$

Então a densidade a posteriori de p está dada por:

$$f(p|x) = \frac{f(x|p) \Pi(p)}{f(x)}$$

$$\text{com } f(x) = \int_0^1 \binom{n}{x} p^x (1-p)^{n-x} dp$$

$$= \binom{n}{x} B(x+1, n-x+1) \underbrace{\int_0^1 \frac{1}{B(x+1, n-x+1)} p^x (1-p)^{n-x} dp}_{\text{I}}$$

$$= \binom{n}{x} B(x+1, n-x+1), \quad \text{onde } B(\cdot, \cdot) \text{ é a função Beta}$$

Daí, temos que

$$f(x|p) = \frac{\binom{n}{x} p^x (1-p)^{n-x}}{\binom{n}{x} B(x+1, n-x+1)} = \frac{1}{B(x+1, n-x+1)} p^x (1-p)^{n-x}$$

Então $p|x \sim \text{Beta}(x+1, n-x+1)$

risco a posteriori
Então o risco de Bayes para d sob perda $\frac{(d-p)^2}{[P(1-P)]}$ é:

$$\begin{aligned} E_{\pi(x)} \left\{ \frac{(d-p)^2}{P(1-P)} \right\} &= \int_0^1 \frac{p^x (1-p)^{n-x}}{B(x+1, n-x+1)} \frac{(d-p)^2}{P(1-P)} dp \\ &= \frac{B(x, n-x)}{B(x+1, n-x+1)} \int_0^1 \frac{p^{x-1} (1-p)^{n-x-1}}{B(x, n-x)} (d^2 - 2dp + p^2) dp \\ &= \frac{B(x, n-x)}{B(x+1, n-x+1)} \left\{ d^2 - 2d \left(\frac{x}{n}\right) + \frac{x(n-x)}{(n+1)n^2} \right\} = R(\Delta, \delta) \end{aligned}$$

Então, o estimador que minimiza $R(\Delta, \delta)$ é

$$\hat{\delta}_B = \frac{x}{n} = E(P|x)$$

Por outro lado, o risco para $\hat{\delta}_B$ é dado por:

$$\begin{aligned} R(p, \hat{\delta}_B) &= \frac{1}{P(1-P)} E[(\hat{\delta}_B - P)^2] \\ &= \frac{1}{P(1-P)} E \left\{ \hat{\delta}_B^2 - 2\hat{\delta}_B P + P^2 \right\} \\ &= \frac{1}{P(1-P)} \{ E[\hat{\delta}_B^2] - 2P E[\hat{\delta}_B] + P^2 \} \\ &= \frac{1}{P(1-P)} \left\{ E \left(\frac{x^2}{n^2} \right) - 2P E \left(\frac{x}{n} \right) + P^2 \right\} \\ &= \frac{1}{P(1-P)} \left\{ \frac{np(1-p) + n^2 p^2 - 2P^2 + P^2}{n^2} \right\} \end{aligned}$$

$$R(p, \hat{\delta}_B) = \frac{1}{n}$$

Então usando o corolário 1 acima $\hat{\delta}_B$ é minimax sob perda $\left[\frac{(d-p)^2}{P(1-P)} \right]$, ou seja, $\hat{\delta}_B$ é o estimador minimax para P . \checkmark

12. Sejam X_1, \dots, X_n e Y_1, \dots, Y_n r.v.'s independentes tais que $X_i \sim N(\mu, \sigma_1^2)$ e $Y_i \sim N(\mu, \sigma_2^2)$, sendo $0 < \sigma_2^2 \leq M$, $0 < \sigma_1^2 \leq M$ e $-\infty < \mu < \infty$ parâmetros desconhecidos a priori conhecidos. Considere o problema de estimar μ sob perda quadrática. Mostre que $(\bar{X} + \bar{Y})/2$ é estimador minimax de μ .

Resultados: Se, dados $\bar{z}_1, Z_1, \dots, Z_n$ são independentes e têm distribuição $N(\bar{z}, \sigma^2)$, e se a distribuição a priori para \bar{z} é $N(\bar{z}, b^2)$, então a distribuição a posteriori de \bar{z} , dado que $Z_1 = z_1, \dots, Z_n = z_n$ é normal de

Qualidade do modelo: Curve ROC
O melhor é ter \rightarrow sensibilidade < especificidade
obtidas de matriz de confusão.

Métricas: Métodos computacionais para inferências com aplicações em R

Referência Bayall (1997) (Paradigmas Frequentista, vassourilhange, Bayesiano)

Quais representam um IC em termos de máxima vassourilha? $R_f: 15 \approx -0.942$

Formas alternativas

- Veross.
 - Ver. relativa
 - da ver.
 - Divergência
- $\chi^2 + \% X \rightarrow$ exponencial
- do sol. → chamado de função

loops → apply (lataçãao supply)

- Veross profunda

Códigos R: [link](#)

- mle (stata) e mle2 (lme4)
- profile e .confint

LEG: fab. de estatístico - e - Estatística
Universidade de Paraná

Daí $R(\theta^*, \delta) < \sup_{\theta} R(\theta, \delta^*)$

Então, $\sup_{\theta} R(\theta, \delta) < \sup_{\theta} R(\theta, \delta^*)$, o qual contradiz (*),
ou seja, contradiz que δ^* é minimax.
Então δ^* além de ser minimax é admissível.

b) Um estimador minimax não pode ser não viésado.

→ Contrato-exemplo:

Exercício 11 desto lista. Neste caso:

$$\delta_B = \frac{X}{n} \text{ um estimador minimax para } p$$

Temos que $E(\delta_B) = E\left(\frac{X}{n}\right) = p$, então δ_B é um estimador não viésado para p , o qual contradiz que um estimador minimax não pode ser não viésado.

c) Se um estimador tem risco constante e é admissível, ele é minimax.

i) δ^* tem risco constante

Então $R(\theta, \delta^*) = r$, ou seja, não depende de θ

$$\Rightarrow \sup_{\theta} R(\theta, \delta^*) = r$$

ii) δ^* é admissível

Então $R(\theta, \delta^*) \leq R(\theta, \delta) \quad \forall \theta \in \Omega \text{ e todo } \delta \in X$

$$\text{Daí } r = \sup_{\theta} R(\theta, \delta^*) \leq \sup_{\theta} R(\theta, \delta) \quad \forall \delta$$

Então $\inf_{\delta} \sup_{\theta} R(\theta, \delta) = r$, ou seja, δ^* é minimax. ✓

15 Seja δ um estimador de Bayes (respectivamente NWUM, minimax e admissível) de $g(\theta)$ sob perda quadrática. Então $a\delta+b$ é um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $ag(\theta)+b$. Aqui, a e b são números reais.

Temos que sob perda quadrática o risco apresenta a seguinte propriedade

$$R(ag(\theta)+b, a\delta+b) = a^2 R(g(\theta), \delta) \quad (*)$$

onde $a \neq 0$, $b \in \mathbb{R}$ e $R(g(\theta), \delta) < \infty$.

i) Estimador admissível.

Se δ é um estimador admissível de $g(\theta)$ então

$$R(g(\theta), \delta) < R(g(\theta), \delta^*) \quad \forall \delta^* \quad \times$$

$$\Rightarrow a^2 R(g(\theta), \delta) < a^2 R(g(\theta), \delta^*) \quad \forall \delta^*, a \neq 0$$

$$\Rightarrow R(ag(\theta)+b, a\delta+b) < R(ag(\theta)+b, a\delta^*+b) \quad \forall \delta^*, a \neq 0, b \in \mathbb{R}, \text{ por } (*)$$

Então $a\delta+b$ é admissível para $ag(\theta)+b$, $a \neq 0$ e $b \in \mathbb{R}$.

ii) Estimador de Bayes

Se δ é um estimador de Bayes de $g(\theta)$ sob a priori Δ , então

$$r(\Delta, \delta) \leq r(\Delta, \delta^*) \quad \forall \delta^*$$

$$\Rightarrow \int R(g(\theta), \delta) d\Delta(\theta) \leq \int R(g(\theta), \delta^*) d\Delta(\theta) \quad \forall \delta^*$$

$$\Rightarrow \int a^2 R(g(\theta), \delta) d\Delta(\theta) \leq \int a^2 R(g(\theta), \delta^*) d\Delta(\theta) \quad \forall \delta^*, a \neq 0$$

$$\Rightarrow \int R(ag(\theta)+b, a\delta+b) d\Delta(\theta) \leq \int R(ag(\theta)+b, a\delta^*+b) d\Delta(\theta), \text{ por } (*)$$

$$r(\Delta, a\delta+b) \leq r(\Delta, a\delta^*+b) \quad \forall \delta^*, a \neq 0 \text{ e } b \in \mathbb{R}$$

Então $a\delta+b$ é o estimador de Bayes de $ag(\theta)+b$ sob priori Δ . ✓

iii) Estimador minimax

Se δ é um estimador minimax de $g(\theta)$ então

$$\inf_{\delta^*} \sup_{\theta} R(g(\theta), \delta^*) = \sup_{\theta} R(g(\theta), \delta)$$

$$\inf_{\delta^*} \sup_{\theta} a^2 R(g(\theta), \delta^*) = \sup_{\theta} a^2 R(g(\theta), \delta), \quad a \neq 0$$

$$\inf_{\delta^*} \sup_{\theta} R(ag(\theta)+b, a\delta^*+b) = \sup_{\theta} R(ag(\theta)+b, a\delta+b), \text{ por } (*)$$

Então $a\delta+b$ é o estimador minimax de $ag(\theta)+b$, $a \neq 0, b \in \mathbb{R}$. ✓

iv) ENVVUM

Se δ é ENVVUM de $g(\theta)$ então $E(\delta) = g(\theta)$.

$\Rightarrow E(a\delta+b) = aE(\delta)+b = ag(\theta)+b \Rightarrow a\delta+b$ é não viésado para $ag(\theta)+b$, $a \neq 0$ e $b \in \mathbb{R}$.

Além disso,

$$\text{Var}(\delta) < \text{Var}(\delta^*), \quad \forall \delta^* \text{ não viésado para } g(\theta) \text{ e } \forall \text{ toda } \theta$$

$$a^2 \text{Var}(\delta) < a^2 \text{Var}(\delta^*), \quad \forall \delta^*, a \neq 0$$

$$\text{Var}(a\delta+b) \leq \text{Var}(a\delta^*+b), \quad \forall \delta^*, a \neq 0, b \in \mathbb{R}$$

Então $a\delta+b$ é ENVVUM de $ag(\theta)+b$, pois $E(a\delta+b) = ag(\theta)+b$. ✓

MAE 5834 - Estatística Avançada I

Lista de Exercícios 5 – 2º semestre de 2010 – Prof. Sílvia Ferrari

1. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$.

(a) Se $\sigma = \sigma_0$ (conhecido), encontre um teste UMP de nível α para testar $H : \mu \leq \mu_0$ contra $K : \mu > \mu_0$.

(b) Se $\mu = \mu_0$ (conhecido), encontre um teste UMP de nível α para testar $H : \sigma \leq \sigma_0$ contra $K : \sigma > \sigma_0$.

2. Quantidade Pivotal

Considere a variável aleatória X com distribuição na família $\mathcal{P} = \{P_\theta, \theta \in \Omega\}$. Uma função $h(X, \theta)$ a valores reais cuja distribuição não depende de θ é chamada de quantidade pivotal. Seja $F_h(y)$ a função distribuição acumulada de $h(X, \theta)$, estritamente crescente e contínua. Mostre que

$$S(x) = \{\theta \in \Omega : h(x, \theta) \leq F_h^{-1}(1 - \alpha)\}$$

é uma região de confiança para θ com coeficiente de confiança $1 - \alpha$.

3. Seja (X_1, \dots, X_n) uma amostra aleatória de variável aleatória com função densidade de probabilidade

$$f(x, \theta) = (2\theta)^{-1} \exp(-|x|/\theta), x \in \mathbb{R}; \theta > 0.$$

(a) Obtenha o teste uniformemente mais poderoso de $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$ de nível α .

(b) Obtenha um limite superior de confiança para θ com coeficiente de confiança $1 - \alpha$.

(c) Obtenha o teste da razão de verossimilhanças de $H : \theta = \theta_0$ contra $K' : \theta \neq \theta_0$ de nível α .

(d) Obtenha uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente minimal e determine um intervalo de confiança para θ com coeficiente de confiança $1 - \alpha$.

4. Sejam X_i variáveis aleatórias independentes com distribuição $N(d_i \theta, 1)$, $d_i \neq 0$, $i = 1, \dots, n$. Encontre um teste UMP de $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$ de nível α .

5. Sejam X_1, \dots, X_n uma amostra aleatória da distribuição exponencial de média θ , $\theta > 0$:

(a) Encontre um teste uniformemente mais poderoso (UMP) de $H_0 : \theta = \theta_0$ versus $H_1 : \theta > \theta_0$ de nível α ($0 < \alpha < 1$).

(b) Se a amostra observada foi $(2.0, 0.2, 1.0, 0.9, 1.0, 0.1, 0.3, 1.3, 1.4, 0.8)$ e $\theta_0 = 1$, qual é sua conclusão ao nível de 5%? Qual é o nível descritivo do teste?

6. Sejam X_1, \dots, X_n variáveis aleatórias independentes, cada qual com distribuição $\Gamma(g, b)$. Mostre que existe um teste UMP para testar:

(a) $H : b \leq b_0$ contra $K : b > b_0$, quando g é conhecido;

(b) $H : g \leq g_0$ contra $K : g > g_0$, quando b é conhecido.

7. Sejam X_1, \dots, X_n variáveis aleatórias independentes, cada qual com distribuição Gaussiana inversa $GI(\mu, \tau)$ e densidade

$$\sqrt{\frac{\tau}{2\pi}} \exp[(\tau\mu)^{1/2}] x^{-3/2} \exp\left[-\frac{1}{2}\left(\frac{\tau}{x} + \mu x\right)\right], x > 0, \tau > 0, \mu > 0.$$

Mostre que existe um teste UMP para testar:

fato UMP → limite de confiança = limite de confiança mais afunilado.

falta distinguir

8. H : $\mu \leq \mu_0$ contra K : $\mu > \mu_0$, quando τ é conhecido;

9. H : $\tau \leq \tau_0$ contra K : $\tau > \tau_0$, quando μ é conhecido.

Em cada caso, dê a forma da região crítica.

Lista 2013 8. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $U(\theta, \theta)$.

(a) Mostre que, para testar $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$, qualquer teste para o qual $E_\theta(\phi(X)) = \alpha$, $E_\theta(\phi(X)) \leq \alpha$, para $\theta \leq \theta_0$, e $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$, é UMP de nível α . Sugestão: Use o Lema de Neyman-Pearson, com $k = (\theta_0/\theta_1)^n$.

(b) Mostre que, para testar $H : \theta = \theta_0$ contra $K : \theta \neq \theta_0$, o teste $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$ ou $\max(x_1, \dots, x_n) \leq \theta_0 \alpha^{1/n}$ e $\phi(x) = 0$, caso contrário, é UMP. Sugestão: Considere separadamente 3 situações: (i) $H : \theta = \theta_0$ contra $K_1 : \theta = \theta_1 > \theta_0$; (ii) $H : \theta = \theta_0$ contra $K_2 : \theta = \theta_1, \theta_0 \alpha^{1/n} < \theta_1 < \theta_0$; (iii) $H : \theta = \theta_0$ contra $K_3 : \theta = \theta_1 \leq \theta_0 \alpha^{1/n}$.

Lista 2013 9. Considere uma única observação de uma variável aleatória X .

(a) Use o Lema de Neyman-Pearson para encontrar o teste mais poderoso de nível α de $H : X \sim U(0, 1)$ contra $K : X \sim Beta(1, b)$, sendo $b > 1$ fixado. Se $\alpha = 0,05$ e se foi observado $x = 0,1$, qual é sua decisão? Qual é o nível descritivo (p-value) do teste?

(b) O teste obtido em (a) é uniformemente mais poderoso de $H : X \sim U(0, 1)$ contra $K' : X \sim Beta(1, b)$, $b > 1$? Justifique.

(c) Existe teste uniformemente mais poderoso de $H : X \sim U(0, 1)$, contra $K'' : X \sim Beta(1, b)$, $b \neq 1$? Justifique.

10. Admita que a densidade $p_\theta(x)$ de X tem razão de verossimilhança monótona em $T(x)$ e considere o problema de testar $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$. Se a distribuição de T é contínua, mostre que o nível descritivo (valor p) do teste UMP é dado por $\hat{\alpha} = P_{\theta_0}(T \geq t)$ onde t é o valor observado de T . Mostre que este resultado também vale sem a suposição de continuidade se, para testes aleatorizados, $\hat{\alpha}$ é definido como o menor nível de significância para o qual a hipótese H é rejeitada com probabilidade 1.

11. Sejam X_1, \dots, X_n uma amostra aleatória da distribuição exponencial deslocada com função densidade de probabilidade

$$f(x; \theta, \gamma) = \frac{1}{\gamma} \exp\left(-\frac{x-\theta}{\gamma}\right) I_{(\theta, +\infty)}(x); -\infty < \theta < \infty, \gamma > 0.$$

(a) Admita que θ é conhecido. Encontre um teste UMP de $H : \gamma \leq \gamma_0$ contra $K : \gamma > \gamma_0$ de nível $\alpha \in (0, 1)$.

(b) Admita que θ é conhecido. Encontre um limite inferior de confiança uniformemente mais acurado para γ com coeficiente de confiança $1 - \alpha$, $\alpha \in (0, 1)$.

(c) Admita que γ é conhecido. Obtenha uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente minimal e obtenha um intervalo de confiança para θ com coeficiente de confiança $1 - \alpha$, $\alpha \in (0, 1)$.

(d) Admita que γ é conhecido. Encontre um teste MP de $H : \theta = \theta_0$ contra $K : \theta = \theta_1$ ($\theta_1 > \theta_0$) de nível $\alpha \in (0, 1)$.

12. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$. Encontre quantidades pivotais adequadas e obtenha intervalos de confiança com coeficiente de confiança $1 - \alpha$ para μ e para σ^2 . [Veja Exemplo 4, p. 215 e Exemplo 5, p. 217, TSH].

Teorema. Seja X uma variável ou vetor aleatório cuja distribuição depende de um parâmetro θ desconhecido. Seja $T(X)$ uma estatística a valores reais e seja $U(X)$ uma estatística a valores reais positivos. Suponha que $(T - \theta)/U$ seja uma quantidade pivotal tendo densidade f com respeito à medida de Lebesgue, que é unimodal em $y_0 \in \mathbb{R}$ no sentido de que $f(y)$ é não decrescente para $y \leq y_0$ e não crescente para $y \geq y_0$. Considere a seguinte classe de intervalos de confiança para θ :

$$\mathcal{C} = \left\{ [T - bU, T - aU] : a \in \mathbb{R}, b \in \mathbb{R}, \int_a^b f(y) dy = 1 - \alpha \right\}.$$

Se $[T - bU, T - aU] \in \mathcal{C}$, $f(a_*) = f(b_*) > 0$, e $a_* \leq y_0 \leq b_*$, então o intervalo $[T - bU, T - aU]$ tem comprimento mínimo entre todos os intervalos em \mathcal{C} .

Sejam X_1, \dots, X_n observações independentes da distribuição $N(\mu, \sigma^2)$ com μ e σ^2 desconhecidos. Considere a seguinte quantidade pivotal: $\sqrt{n}(\bar{X} - \mu)/S$ onde $\bar{X} = \sum_i^n X_i/n$ e $S^2 = \sum_i^n (X_i - \bar{X})^2/(n-1)$. Identifique a classe \mathcal{C} para esse caso. Encontre um intervalo de confiança para μ com coeficiente de confiança $1 - \alpha$ em \mathcal{C} com comprimento mínimo.

14. Sejam f e g duas densidades de probabilidade com respeito a μ . Para testar a hipótese $H_0 : \theta \leq \theta_0$ ou $\theta \geq \theta_1$, ($0 < \theta_0 < \theta_1 < 1$) contra alternativas $\theta_0 < \theta < \theta_1$ na família $\mathcal{P} = \{\theta f(x) + (1-\theta)g(x), 0 \leq \theta \leq 1\}$, o teste $\phi(x) = \alpha$, para todo x , é UMP de nível α .

15. Sejam X_{i1}, \dots, X_{in_i} observações independentes de distribuições normais de média μ_i e variância σ_i^2 para $i = 1, 2$; $\mu_1, \mu_2 \in \mathbb{R}$, $\sigma_1^2, \sigma_2^2 > 0$.

(a) Obtenha o teste da razão de verossimilhanças de $H_0 : \mu_1 = \mu_2$ versus $H_1 : \mu_1 \neq \mu_2$ de nível α ($0 < \alpha < 1$) supondo que σ_1^2 e σ_2^2 são conhecidos.

(b) Obtenha o teste da razão de verossimilhanças de $H_0 : \sigma_1^2 = \sigma_2^2$ versus $H_1 : \sigma_1^2 \neq \sigma_2^2$ de nível α .

(c) Suponha agora que as variâncias são desconhecidas mas iguais (isto é, $\sigma_1^2 = \sigma_2^2 = \sigma^2$) e refaça a parte (a).

16. Sejam X_1, \dots, X_n e Y_1, \dots, Y_n amostras aleatórias de distribuições exponenciais de médias $\mu > 0$ e $\lambda > 0$ respectivamente. Obtenha o teste da razão de verossimilhanças de $H_0 : \mu = \lambda$ versus $H_1 : \mu \neq \lambda$ de nível α ($0 < \alpha < 1$).

$$\theta f(x) + (1-\theta) g(x)$$

$$\exp \left\{ \log(\theta) + \log f(x) + \log(1-\theta) + \log(g(x)) \right\}$$

$$\exp \left\{ \log(\theta \cdot f(x)) \right\}$$

MAE 5834 - Estatística Avançada I

Prova 1 - 2º semestre de 2010 – Prof. Silvia L.P. Ferrari

1. (2 pontos) Suponha que X_1, \dots, X_m e Y_1, \dots, Y_n sejam v.a's independentes tais que $X_i \sim N(\zeta, \sigma^2)$, para $i = 1, \dots, m$, e $Y_j \sim N(\eta, \sigma^2)$, para $j = 1, \dots, n$; $m \geq 2$, $n \geq 2$. Encontre o ENVVUM de $(\eta - \zeta)/\sigma$.
Nota: Se $V \sim \chi^2_n$, então $E(V^{r/2}) = 2^{r/2} \Gamma((n+r)/2)/\Gamma(n/2)$, para $n > -r$.

2. Dizemos que X tem distribuição exponencial de parâmetros a e b ($a \in \mathbb{R}$, $b > 0$), e escrevemos $X \sim E(a, b)$, se sua função densidade de probabilidade é

$$f(x; a, b) = \frac{1}{b} \exp \left\{ -\frac{x-a}{b} \right\} I_{[a, \infty)}(x).$$

Seja $\mathbf{X} = (X_1, \dots, X_n)$ uma amostra aleatória de $X \sim E(\theta, \theta)$ em que $\theta > 0$ é desconhecido.

(a) (0,5 ponto) Mostre que a classe de distribuições $\mathcal{P} = \{E(\theta, \theta), \theta > 0\}$ é uma família de escala.

(b) (1 ponto) Mostre que $(\bar{X}, X_{(1)})$, onde $\bar{X} = \sum_{i=1}^n X_i/n$ e $X_{(1)} = \min(X_1, \dots, X_n)$, é estatística suficiente minimal mas não é completa.

(c) (1,5 ponto) Esboce a função de verossimilhança. Encontre o estimador de máxima verossimilhança de θ . Este estimador é admissível sob perda quadrática?

3. Seja $\mathbf{X} = (X_1, \dots, X_n)$ com função densidade de probabilidade conjunta

$$f_{\mathbf{X}}(\mathbf{x}; \tau) = \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n; \quad \tau > 0,$$

em que f é conhecida e τ é um parâmetro de escala desconhecido. Considere o problema de estimar τ^r , $r \geq 1$, inteiro. Dizemos que um estimador $\delta(\mathbf{X})$ é equivariante por escala se $\delta(b\mathbf{X}) = b^r \delta(\mathbf{X})$, para todo $b > 0$. Pode-se mostrar que o estimador de Pitman de τ^r , dado por $\delta^*(\mathbf{X})$ sendo

$$\delta^*(\mathbf{x}) = \frac{\int_0^\infty v^{n+r-1} f(vx_1, \dots, vx_n) dv}{\int_0^\infty v^{n+2r-1} f(vx_1, \dots, vx_n) dv},$$

é um estimador equivariante por escala de risco mínimo sob perda $[(d - \tau^r)/\tau^r]^2$.

(a) (1 ponto) Mostre que, de fato, o estimador $\delta^*(\mathbf{X})$ é equivariante por escala.

(b) (1,5 ponto) Obtenha o estimador $\delta^*(\mathbf{X})$ de τ^r para a situação em que \mathbf{X} é uma amostra aleatória da distribuição uniforme no intervalo $(0, \tau)$, $\tau > 0$.

4. Seja $\mathbf{X} = (X_1, \dots, X_n)$ amostra aleatória da variável aleatória X que tem função densidade de probabilidade

$$f(x; a, \theta) = \theta a^{\theta} x^{-(\theta+1)} I_{(0, \infty)}(x),$$

em que $a \in (0, 1)$ e $\theta > 0$.

(a) (1 ponto) Supondo a conhecido, encontre a informação de Fisher para θ .

(b) (1,5 ponto) Mostre que o estimador não viésado de variância uniformemente mínima de θ , quando θ é conhecido, é

$$\hat{\theta} = I_{(1, \infty)}(X_{(1)}) + \left(1 - \frac{1}{n\theta}\right) X_{(1)} I_{(0, 1)}(X_{(1)}),$$

em que $X_{(1)} = \min(X_1, \dots, X_n)$.

Sugestão: Mostre que $X_{(1)}$ é uma estatística suficiente e caracterize a classe de estimadores não viésados do zero, que sejam funções de $X_{(1)}$.

Exercício extra

5. Seja X uma variável ou vetor aleatório com distribuição pertencente à família $\mathcal{P} = \{P_\theta, \theta \in \Omega\}$. Seja T uma estatística suficiente completa e S uma estatística suficiente minimal.

(a) (0,5 ponto) Mostre que T é uma estatística suficiente minimal. Sugestão: considere $T - E[T|S]$.

(b) (0,5 ponto) Mostre que S é uma estatística suficiente completa.

$$\begin{aligned} E(T - E[T|S]) &= E(T) - E(E[T|S]) = 0 \\ T - E(T|S) &= 0 \Rightarrow T = E(T|S) \end{aligned}$$

16/11/2020

5º lista de Exercícios

1. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$.

(a) se $\sigma = \sigma_0$ (conhecido), encontre um teste UMP de nível α para testar $H: \mu \leq \mu_0$ contra $K: \mu > \mu_0$.

$$p(x) = f(x, \mu) = \frac{1}{(\sqrt{2\pi\sigma_0^2})^n} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum (x_i - \mu)^2 \right\} T(x), \quad \sigma = \sigma_0 \text{ conhecido}$$

Nota: $\mu_1 > \mu_0$, então

$$p_1(x) = \frac{1}{(\sqrt{2\pi\sigma_0^2})^n} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum (x_i - \mu_1)^2 \right\}$$

$$p_0(x) = \frac{1}{(\sqrt{2\pi\sigma_0^2})^n} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum (x_i - \mu_0)^2 \right\}$$

$$= \exp \left\{ -\frac{1}{2\sigma_0^2} \sum (x_i - \mu_1)^2 + \frac{1}{2\sigma_0^2} \sum (x_i - \mu_0)^2 \right\} -$$

$$= \exp \left\{ -\frac{1}{2\sigma_0^2} \sum (x_i^2 - 2x_i\mu_1 + \mu_1^2) + \frac{1}{2\sigma_0^2} \sum (x_i^2 - 2x_i\mu_0 + \mu_0^2) \right\} -$$

$$= \exp \left\{ -\frac{\sum x_i\mu_1 - n\mu_1^2}{2\sigma_0^2} - \frac{\sum x_i\mu_0 - n\mu_0^2}{2\sigma_0^2} \right\} =$$

$$= \exp \left\{ \bar{x} \cdot \left[\frac{n\mu_1 - n\mu_0}{\sigma_0^2} \right] - \frac{n\mu_1^2 + n\mu_0^2}{2\sigma_0^2} \right\}$$

como $\mu_1 > \mu_0$, então é função crescente em \bar{x}

O conjunto dos pontos x tal que $p_1(x) > K$ é equivalente ao dos pontos x tal que $\bar{x} > K'$ ($K' = p_0(x)$)

para determinar K' fixar α

$$P_0(\bar{X} > K') = \alpha$$

$$\text{Se } \mu_1 = \mu_0, \quad \bar{X} \sim N(\mu_0, \frac{\sigma_0^2}{n})$$

$$\text{Assim: } P_0(\bar{X} > K') = P_0\left(\bar{X} - \mu_0 > \frac{K' - \mu_0}{\sqrt{\frac{\sigma_0^2}{n}}}\right) = P\left(Z > \frac{K' - \mu_0}{\sqrt{\frac{\sigma_0^2}{n}}}\right) = \alpha$$

família
exponencial

crescente	$X > \mu$
decrecente	$X < \mu$

$$R^* = \bar{x}_{(k)}$$

\bar{G}

\bar{G}_n

$$R^* = \frac{\bar{G}_n}{\sqrt{n}} z_{\alpha} + \mu_0$$

$$R^* = \mu_0 + \frac{\bar{G}_n}{\sqrt{n}} z_{\alpha}, \text{ em que } z_{\alpha} \text{ é o quantil de ordem } 1-\alpha \text{ da dist. } N(0,1).$$

Como $p_1(x)$ é uma função não decrescente de $T(x) = \bar{X}$, então:

sele interior da região de rejeição de hipótese monótona (RHM), tem-se que para todo $H: \mu \leq \mu_0$ contra $K: \mu > \mu_0$, existe um teste UMP que é dado por:

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) = \bar{X} > R^* \\ 0 & \text{se } T(x) < R^* \end{cases}$$

$$\therefore E_{\mu_0}(\phi(x)) = \alpha.$$

Deste modo, um teste UMP de nível α para teste $H: \mu \leq \mu_0$ contra $K: \mu > \mu_0$ é dado por:

$$\phi(x) = \begin{cases} 1 & \text{se } \bar{X} > \mu_0 + \frac{\bar{G}_n z_{\alpha}}{\sqrt{n}} \\ 0 & \text{a.c.} \end{cases}$$

$$\therefore E_{\mu_0}(\phi(x)) = \alpha.$$

16/11/2010

16/11/2010

(b) se $\mu = \mu_0$ (conhecido), encontre um teste UMP de nível α para todo $H: \bar{G} \leq \bar{G}_0$ contra $K: \bar{G} > \bar{G}_0$.

Para $\bar{G}_0 > \bar{G}_0$, então

$$p_1(x) = \frac{1}{(\sqrt{2\pi\bar{G}_0^2})^n} \cdot \exp \left\{ -\frac{1}{2\bar{G}_0^2} \sum (x - \mu_0)^2 \right\} =$$

$$p_0(x) = \frac{1}{(\sqrt{2\pi\bar{G}_0^2})^n} \cdot \exp \left\{ -\frac{1}{2\bar{G}_0^2} \sum (x - \mu_0)^2 \right\} =$$

$$= \frac{\left(2\pi\bar{G}_0^2\right)^{\frac{n}{2}}}{2^n \pi^{\frac{n}{2}}} \cdot \exp \left\{ -\frac{1}{2\bar{G}_0^2} \sum (x - \mu_0)^2 + \frac{1}{2\bar{G}_0^2} \sum (x - \mu_0)^2 \right\} =$$

$$= \left(\frac{\bar{G}_0^2}{\bar{G}_1^2}\right)^{\frac{n}{2}} \cdot \exp \left\{ \sum (x - \mu_0)^2 \left[\frac{-1}{2\bar{G}_0^2} + \frac{1}{2\bar{G}_1^2} \right] \right\}$$

Nota-se que $p_0(x)$ é uma função não decrescente em x .

$T(X) = \sum_{i=1}^n (X_i - \mu_0)^2$. Deste modo, novamente a família de distribuições p_0 tem região de rejeição de hipótese monótona e, então, novamente, existe um teste UMP para teste $H: \bar{G} \leq \bar{G}_0$ contra $K: \bar{G} > \bar{G}_0$ que é dado por:

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > R \\ 0 & \text{a.c.} \end{cases}$$

e R é determinado por $E_{\mu_0}(\phi(x)) = \alpha$.

Agora, deixe-nos explicar quem é R , da seguinte forma:

$$P_{\mu_0}(\sum (X_i - \mu_0)^2 > R) = \alpha$$

$$X \sim N(\mu_0, \bar{G}_0^2)$$

$$X - \mu_0 \sim N(0, \bar{G}_0^2)$$

$$X - \mu_0 \sim N(0, 1)$$

CB

16/11/2020

Então

$$\alpha = P_{\theta_0} \left[\sum_{i=1}^n (X_i - \mu_0)^2 \geq k_n \right] = P \left[\sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2} \geq \frac{k_n}{\sigma^2} \right]$$

Sob H_0 : $\sum_{i=1}^n (X_i - \mu)^2 \sim \chi_n^2$

Então, seja k_n o quantil de χ_n^2

$$k_n = \chi_{n,1-\alpha}$$

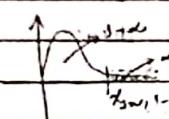
$$\therefore k_n = \chi_{n,1-\alpha}^2$$

Então, é todo μ dado por:

$$\phi(x) = \begin{cases} 1 & \text{se } T(X) > \chi_{n,1-\alpha}^2 \\ 0 & \text{c.c.} \end{cases}, \quad \text{é o quantil desse distribuição}$$

$$\text{com } E_{\mu_0}(\phi(x)) = \alpha.$$

* Podem ter mais de uma região rejeição (vamos adiantar desse ponto)



11

2 Quantidade Portada

Considerare a variável aleatória X com distribuição na família $P = \{\Pr_{\theta}, \theta \in \Omega\}$. Uma função $h(X, \theta)$ a valor real cuja distribuição não depende de θ é chamada de quantidade portada. Seja $F_h(y)$ a função distribuição acumulada de $h(X, \theta)$, estritamente crescente e contínua. Nota: que:

\hookrightarrow para ver qual é a sua função inversa.

$$S(x) = \{\theta \in \Omega : h(x, \theta) \leq F_h^{-1}(1-\alpha)\}$$

é uma região de confiança para θ com coeficiente de confiança $1-\alpha$.

Uma família de subconjuntos $S(x)$ de espaço paramétrico Ω é dita constituir uma família de regiões (conjuntos) de confiança com coeficiente de confiança $1-\alpha$ se:

$$P_{\theta}(\theta \in S(x)) \geq 1-\alpha \quad \text{para todo } \theta \in \Omega.$$

Tomemos que:

$$1-\alpha = F_h(F_h^{-1}(1-\alpha)) = P_{\theta}(h(x, \theta) \leq F_h^{-1}(1-\alpha)) = P_{\theta}(\theta \in S(x))$$

Demonstração: Se $\theta \in S(x) \iff h(x, \theta) \leq F_h^{-1}(1-\alpha)$

* θ , função que nos devolve para poder se falar a inversa.

$$P(\theta \in S(x)) = P(h(x, \theta) \leq F_h^{-1}(1-\alpha)) =$$

$$F_h(y) = P(h(x, \theta) \leq y)$$

$$\downarrow = F_h(F_h^{-1}(1-\alpha)) = 1-\alpha \quad \forall \theta$$

\rightarrow segue da noção de inversa

$$\therefore P(\theta \in S(x)) = 1-\alpha \quad \forall \theta \in \Omega$$

Então $S(x)$ é uma região de confiança para θ com coeficiente de confiança $1-\alpha$.

$$P(\theta \in S(x)) \geq 1-\alpha.$$

Para que $S(x)$ seja uma região de confiança para θ , devemos ter:

$$\theta \in S(x) \Leftrightarrow h(x; \theta) \leq F_h^{-1}(1-\alpha)$$

Se dois eventos não equivalentes, inteiros suas probabilidades também o são e então, tem-se que:

$$P(\theta \in S(x)) = P(h(x; \theta) \leq F_h^{-1}(1-\alpha)) \quad \text{①}$$

① é a f.d.a. de $h(x; \theta)$, que por hipótese é dada por:

$$P(h(x; \theta) \leq y) = F_h(y), \text{ então segue que:}$$

$$F_h(F_h^{-1}(1-\alpha)) = 1-\alpha$$

composição
de função

$$\text{Portanto, } P(\theta \in S(x)) = 1-\alpha$$

E desse modo, $S(x)$ é uma região de confiança $1-\alpha$ para o parâmetro θ .

* Quantidade final \Rightarrow usada para construir regiões de confiança

16/11/2010

$$\left\{ \begin{array}{l} X \sim E(\theta) \Rightarrow E(X) = \theta \\ \sum X \Rightarrow E(\sum X) = n\theta \\ 2\sum X \Rightarrow E(2\sum X) = 2n\theta \\ \frac{\sum X}{\theta} \xrightarrow{\text{amostra}} E\left(\frac{\sum X}{\theta}\right) = \bar{x} \end{array} \right.$$

$$\frac{1}{\theta} e^{-\frac{x}{\theta}}$$

$$Y \sim X_{2n}^2 \Rightarrow E(Y) = 2n$$

3. Seja (X_1, \dots, X_n) uma amostra aleatória de variável discrete com função densidade de probabilidade

$$f(x; \theta) = (\theta)^{-n} \exp\left(-\frac{\sum |x_i|}{\theta}\right), \quad x \in \mathbb{R}; \theta > 0.$$

(a) Obtenha o teste uniformemente mais poderoso de $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$ de nível α .

$$\begin{aligned} p_\theta(x) &= \frac{(\theta_1)^{-n}}{(\theta_0)^{-n}} \cdot \exp\left(-\frac{\sum |x_i|}{\theta_1}\right) \cdot I(\theta_1 > 0) \\ p_\theta(x) &= \frac{(\theta_1)^{-n}}{(\theta_0)^{-n}} \exp\left(-\frac{\sum |x_i|}{\theta_1}\right) \cdot I(\theta_1 > 0) \\ &= \left(\frac{\theta_1}{\theta_0}\right)^{-n} \exp\left(-\frac{\sum |x_i|}{\theta_1} \cdot \left(\frac{\theta_1 - \theta_0}{\theta_0}\right)\right) \cdot I(\theta_1 > 0) \cdot I(\theta_0 > 0) \end{aligned}$$

$$p_\theta(x) \geq K \text{ é não decrescente em } T(X) = \sum_{i=1}^n |x_i|,$$

e portanto, se cumpre a propriedade da razão de verossimilhanças monótona e então, temos um teste UMP de nível α para testar $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$, que será dado por:

$$F_{\theta_0}(T(X)) = \alpha$$

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > K \\ 0 & \text{c.c.} \end{cases}$$

Para determinar a probabilidade correta a distribuição de $T(X)$, que no caso é dada por: $T(X) = \sum_{i=1}^n |x_i|$

$$y = |X| \quad y = \begin{cases} x & \text{se } x > 0 \\ -x & \text{se } x < 0 \end{cases}$$

$$f(y) = (\theta)^{-1} \exp\left(-\frac{|y|}{\theta}\right) \cdot 1_{|y|} + (\theta)^{-1} \exp\left(-\frac{(-y)}{\theta}\right) \cdot 1_{-|y|}$$

$$f(y) = \theta^{-1} \exp\left(-\frac{y}{\theta}\right) \cdot I_{(0, \infty)}(y) = \theta^{-1} \exp\left(-\frac{y}{\theta}\right) \cdot I_{(0, \infty)}(y) \cdot E\left(\frac{1}{\theta}\right)$$

$$r(\alpha, \theta) \text{ Gamma } \frac{1}{r(\alpha) \theta^\alpha} x^{\alpha-1} e^{-\frac{x}{\theta}}$$

16/11/2011

$$T(X) = \sum |X_i| \Rightarrow T(Y) = \sum Y_i \sim \text{Gamma}(n, \theta)$$

$$\sum Y_i = Z \sim \text{Gamma}(n, \theta)$$

$Z \sim \text{Gamma}(n, \theta)$

$$f_Z(z) = \frac{1}{r(n) \theta^n} z^{n-1} e^{-\frac{z}{\theta}} \cdot \frac{T(z)}{(n-1)!}$$

Suje $W = \frac{Z}{\theta}$; então

$$Z = W\theta$$

$$Y \sim \chi_{2n}^2 \quad E(Y) = 2n$$

$$\mathbb{E}[E(\theta)] \quad E(\sum Z) = n\theta \text{ (Gamma)}$$

$$\frac{Z}{\theta} = 2n$$

$$f_W(w) = \frac{1}{r(n) \theta^n} \left(\frac{w\theta}{2} \right)^{n-1} e^{-\frac{w\theta}{2}} \cdot \frac{I(w)}{(n-1)!}$$

$$= \frac{1}{r(n) \theta^n} \cdot \frac{w^{n-1} \theta^{n-1}}{2^{n-1}} e^{-\frac{w\theta}{2}} \cdot \frac{1}{2} =$$

$$= \frac{1}{r(n)} \frac{w^{n-1} e^{-2w}}{2^n} \cdot \frac{I(w)}{(n-1)!} \sim \text{Gamma}(n, 2) \sim \chi_{2n}^2$$

$$W \sim \chi_{2n}^2$$

Então, sob H_0

$$P_{H_0}(T(X) > k) = \alpha$$

$$P_{H_0}\left(\frac{2 \sum |X_i|}{\theta_0} > 2k\right) = \alpha$$

$$\therefore P(X) = \int_{0}^{\infty} x \sum_{i=1}^n |X_i| > \frac{2k\theta_0}{2} \text{ c.c.}$$

$$2k = q_{1-\alpha} \theta_0$$

$$q_{1-\alpha} \text{ quantile } \chi_{2n}^2$$

$$k = \frac{q_{1-\alpha} \theta_0}{2}$$

$$\therefore P(X) = \int_{0}^{\infty} x \sum_{i=1}^n |X_i| > \frac{q_{1-\alpha} \theta_0}{2}$$

$$q_{1-\alpha} \text{ quantile } \chi_{2n}^2$$

$$\text{quantile da } \chi_{2n}^2$$

16/11/2011

(b) Obtendo um limite superior de confiança para θ com coeficiente de confiança $1-\alpha$. p. 54

Um limite superior de confiança para θ com coeficiente de confiança $1-\alpha$ não dado por:

$$P_\theta(T \geq t) = 1 - \alpha$$

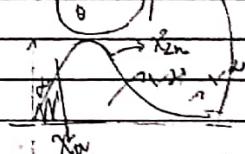
$$P_\theta(\sum |X_i| \geq t) = 1 - \alpha$$

$$t = 2 \cdot S |X_i|$$

$$\therefore P_\theta(\sum |X_i| < t) = \alpha$$

$$F_\theta(t) = \alpha$$

$$P_\theta(\sum |X_i| < t) = \alpha$$



$$2 \cdot S |X_i| \sim \chi_{2n}^2$$

$$P_\theta\left(\frac{2 \sum |X_i|}{\theta} < 2t\right) = \alpha$$

$$\therefore 2 \sum |X_i| = \chi_{2n}^2$$

$$P_\theta\left(\chi_{2n}^2 < 2t\right) = \alpha$$

$$\theta = 2 \leq |X_i|$$

$$\frac{2t}{\theta} = q_{1-\alpha} \quad \chi_{2n}^2$$

$$\theta = 2t$$

$$q_{1-\alpha}$$

$$\bar{\theta}(T) = q_{1-\alpha}$$

$$\text{O } \bar{\theta} \text{ é o valor da } \theta \text{ que}$$

$$\text{H. } \theta > \theta_0$$

$$P(X = 1 \mid \theta > \theta_0) = \alpha$$

$$P(X = 1 \mid \theta > \theta_0) = K \cdot T(X)$$

16/11/2010

(c) Obtenha o teste de rejeição da verosimilhança de $H: \theta = \theta_0$ contra $K': \theta \neq \theta_0$ de nível α .

Um teste de rejeição da verosimilhança é qualquer teste que rejeita H se e somente se:

$$\lambda(x) = \sup_{\theta \in K'} L(\theta) < c, \quad c \in (0,1)$$

$X_i = L(\hat{\theta})$ em que $\hat{\theta}$ é um EMV de θ , $\tilde{\theta}$ é um EMV de $L(\hat{\theta})$ e rejeito a que $\theta \in K'$.

No caso,

$$H: \theta = \theta_0 \quad \text{vs} \quad K': \theta \neq \theta_0$$

$$J = \{ \theta \geq 0 \} \quad \text{Sob } K: \theta = \theta_0$$

$$f(x, \theta) = (2\theta)^{-1} \exp(-\frac{x}{\theta})$$

$$p(\theta) = (2\theta)^{-n} \exp\left(-\frac{\sum |x_i|}{\theta}\right)$$

$$L(\theta) = -\frac{\sum |x_i|}{\theta} - n \log 2\theta$$

$$\frac{dL(\theta)}{d\theta} = +\frac{\sum |x_i|}{\theta^2} - n \cdot \frac{1}{\theta} = 0 \Rightarrow \hat{\theta} = \frac{\sum |x_i|}{n}$$

$$\frac{d^2 L(\theta)}{d\theta^2} = -\frac{2\sum |x_i|}{\theta^3} + n \quad \text{p.t.o}$$

$$\frac{d^2 L(\theta)}{d\theta^2} \Big|_{\theta=\hat{\theta}} = \frac{2\hat{\theta}^3}{\hat{\theta}^3} - n \quad \text{máximo}$$

$$\text{Sob } H: \theta = \theta_0 \Rightarrow \tilde{\theta} = \theta_0$$

Então:

$$\lambda(x) = L(\tilde{\theta}) = (2\theta_0)^{-n} \exp\left\{-\frac{\sum |x_i|}{\theta_0}\right\} =$$

$$L(\hat{\theta}) = (2\hat{\theta})^{-n} \exp\left\{-\frac{\sum |x_i|}{\hat{\theta}}\right\}$$

$$= \left(\frac{\theta_0}{\hat{\theta}}\right)^{-n} \exp\left\{\frac{\sum |x_i|}{\theta_0} \left(-1 + \frac{1}{\hat{\theta}}\right)\right\} =$$

$$= \left(\frac{\theta_0}{\sum |x_i| / n}\right)^{-n} \exp\left\{\frac{n}{\theta_0} \left(-1 + \frac{n}{\sum |x_i|}\right)\right\} =$$

$$\lambda(t) = \frac{\sup_{\theta \in K'} p(\theta)}{\sup_{\theta \in J} p(\theta)} \leq 1 \quad \text{se } H_0 \Rightarrow \lambda(x) \approx 1 \quad \frac{c}{\sum |x_i| / n} \approx 1$$

16/11/2010

$$= \left(\frac{n\theta_0}{\sum |x_i|}\right)^{-n} \sup_{\theta \in K'} \left\{ -\frac{\sum |x_i|}{\theta} + n \right\} =$$

$$= \left(\frac{\sum |x_i|}{n\theta_0}\right)^n \sup_{\theta \in K'} \left\{ -\frac{\sum |x_i|}{\theta} + n \right\} \leq c.$$

$$\text{Seja, } T = \frac{\sum |x_i|}{\theta_0}$$

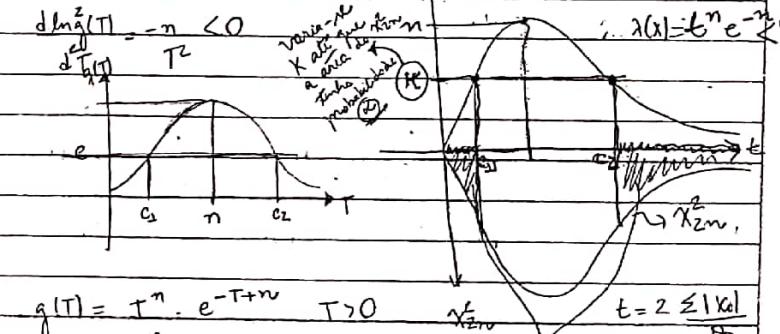
$$X|T \sim C$$

$$g(T) = \frac{T^n \cdot e^{-T+n}}{n^n} = R \cdot T^n e^{-T}$$

$$\ln g(T) = \frac{\log T^n - T + n}{n^n} = n \log T - n \log n - T + n$$

$$\frac{d \ln g(T)}{dT} = \frac{n-1}{T} = 0 \Rightarrow n-T=0 \Rightarrow T=n$$

$$(1) \quad \lambda(x) = \frac{t^n e^{-n}}{n^n} \quad \text{p.(}\lambda(x) < c\text{)}$$



$$g(T) = \frac{T^n \cdot e^{-T+n}}{n^n} \quad T > 0$$

A função crescente $\log g(T)$ também é crescente para $T < n$, atingindo o ponto de máximo em $T=n$ e é decrescente para $T > n$, logo $g(T) < c$ se e somente se $T < c_1$ ou $T > c_2$ com $g(c_1) = g(c_2)$. Portanto, TRV é equivalente a rejeitar H_0 quando

$$\sum |x_i| < c_1 \quad \text{ou} \quad \sum |x_i| > c_2$$

$$\text{Sob } H_0: 2 \sum |x_i| \sim \chi^2_{2n}$$

$$P(X) = \int_0^{\infty} x e^{-x} dx$$

$$\alpha - \ln(\Phi(x)) = \Gamma(2, x)$$

$$2\pi \text{e}^{i\theta}$$

Dónde θ es igual a ωt

$$f_{\theta}(x) = \frac{1}{2\pi} e^{-\frac{x^2}{2}}$$

18/10/2020

- (d) Obtén una probabilidad que dependa de los datos que tienen la misma relación que tiene en la teoría un intervalo de confianza para θ con respecto de confianza $1-\alpha$.

$$f(x, \theta) = (2\pi)^{-1} \exp\left(-\frac{|x|}{2}\right), x \in \mathbb{R}, \theta \in \mathbb{R}$$

$$\hat{\theta}(x) = (2\pi)^{-1} \exp\left(-\frac{|x|}{2}\right) = \frac{1}{2\pi} e^{-\frac{|x|}{2}}$$

El otro de interés, $T(X) = \frac{1}{2}|x_1| + \dots + \frac{1}{2}|x_n|$ es statisticamente independiente de $\hat{\theta}(x)$.

$$\hat{\theta}(x) = (2\pi)^{-1} \exp\left(-\frac{|x_1|}{2}\right) = (2\pi)^{-1} \exp\left(-\frac{|x_1|}{2}\right) \exp\left(-\frac{|x_2|}{2}\right) \dots \exp\left(-\frac{|x_n|}{2}\right)$$

= probabilidad

$$\hat{\theta}(x) = (2\pi)^{-1} \exp\left(-\frac{|x_1|}{2}\right) \dots \exp\left(-\frac{|x_n|}{2}\right) = \boxed{\exp\left(-\frac{T(X)}{2}\right)}$$

$T(X) = \frac{1}{2}|x_1| + \dots + \frac{1}{2}|x_n|$ es statisticamente independiente de $\hat{\theta}(x)$

Entonces, de dar α , queremos que $2\exp\left(-\frac{T(X)}{2}\right) < \alpha$, que es una

probabilidad que θ está en un intervalo de confianza para θ

con confianza $1-\alpha$ que deseamos.

$$P\left(\frac{1}{2} \leq \frac{|x_1|}{2} \leq \frac{1}{2} \right) = 1-\alpha$$

$$P\left(\frac{1}{2} \leq \frac{|x_1|}{2} \leq \frac{1}{2} \right) = 1-\alpha$$

$$P\left(\frac{1}{2} \leq \frac{|x_1|}{2} \leq \frac{1}{2} \right) = 1-\alpha$$

18/10/2020

Si queremos obtener el intervalo con confianza $1-\alpha$ de θ , entonces basta con que $T(X) = \frac{1}{2}|x_1| + \dots + \frac{1}{2}|x_n|$ sea menor que $\hat{\theta}(x)$.

$$\hat{\theta}(x) = \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right)$$

$$\hat{\theta}(x) = \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right)$$

$$\begin{aligned} \text{Prob } \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right) &< \hat{\theta}(x) \\ \text{Prob } \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right) &< \hat{\theta}(x) \\ \text{Prob } \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right) &< \hat{\theta}(x) \end{aligned}$$

$$\begin{aligned} &\Rightarrow \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right) < \hat{\theta}(x) \\ &\Rightarrow \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right) < \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right) \\ &\Rightarrow \exp\left(-\frac{T(X)}{2}\right) < \exp\left(-\frac{T(X)}{2}\right) \\ &\Rightarrow T(X) < \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right) \end{aligned}$$

Probabilidad de que $T(X)$ sea menor que $\hat{\theta}(x)$

Probabilidad que $T(X) < \hat{\theta}(x)$

Probabilidad que $T(X) < \hat{\theta}(x)$

$\hat{\theta}(x) = \frac{1}{2} \exp\left(-\frac{T(X)}{2}\right)$

Probabilidad que $T(X) < \hat{\theta}(x)$

$$Q(T) = \begin{cases} 1 & \text{si } T(X) < \hat{\theta}(x) \\ 0 & \text{de lo contrario} \end{cases}$$

que es igual a la probabilidad de que $T(X) < \hat{\theta}(x)$

que es menor que $\hat{\theta}(x)$

16/11/2010

$$E_{\theta_0}(\phi(x)) = P_{\theta_0}(\sum d_i x_i > c) = \alpha$$

$$X_i \sim N(d_i \theta, 1)$$

$$d_i X_i \sim N(d_i \theta, d_i^2)$$

$$\sum d_i X_i \sim N(\theta \sum d_i^2; \sum d_i^2)$$

$$E(d_i X_i) = d_i E(X_i) = d_i \cdot d_i \cdot \theta = d_i^2 \theta$$

$$E(\sum d_i X_i) = \sum E(d_i X_i) = \sum d_i \cdot E(X_i) = \sum d_i^2 \theta$$

$$\text{Var}(\sum d_i X_i) = d_i^2 \text{Var}(X_i) = d_i^2 \cdot 1 = d_i^2$$

$$\text{Var}(\sum d_i X_i) = \sum d_i^2 \text{Var}(X_i) = \sum d_i^2 \cdot 1 = \sum d_i^2 \cdot 1.$$

Então, tem-se que:

$$\sum d_i X_i - \theta \sum d_i^2 \sim N(0, 1)$$

$$\sqrt{\sum d_i^2}$$

Então:

$$P_{\theta_0}(\sum d_i X_i > c) = \alpha \Leftrightarrow P_{\theta_0}\left(\frac{\sum d_i X_i - \theta_0 \sum d_i^2}{\sqrt{\sum d_i^2}} > \frac{c - \theta_0 \sum d_i^2}{\sqrt{\sum d_i^2}}\right) = \alpha$$

$$c - \theta_0 \sum d_i^2 = z_{1-\alpha}; \quad z_{1-\alpha} \text{ é quantil de ordem } 1-\alpha \text{ de } N(0, 1)$$

$$c = \theta_0 \sum d_i^2 + \sqrt{\sum d_i^2} z_{1-\alpha}$$

Então, o teste mais simples é:

$$\phi(x) = \begin{cases} 1 & \text{se } \sum d_i X_i > \theta_0 \sum d_i^2 + z_{1-\alpha} \sqrt{\sum d_i^2} \\ 0 & \text{c.c.} \end{cases}$$

Outro modo, resumindo: H_0 se rejeita se:

$$T(X) = \sum d_i X_i > \theta_0 \sum d_i^2 + z_{1-\alpha} \sqrt{\sum d_i^2}$$

17/11/2010

5. Sejam X_1, X_n uma amostra aleatória da distribuição exponencial de média $\theta, \theta > 0$.

(a) Encontre um teste uniformemente mais preciso (UMP) de $H_0: \theta = \theta_0$ vs $H_1: \theta > \theta_0$ de nível α ($0 < \alpha < 1$)

$$\theta_1 > \theta_0, \quad p_{\theta_1}(x) = \frac{1}{\theta_1^n} e^{-\frac{\sum x_i}{\theta_1}} \prod_{i=1}^n \frac{I(x_i)}{(\theta_1 + \infty)} = \frac{1}{\theta_1^n} e^{-\frac{\sum x_i}{\theta_1}} I(x_n) \prod_{i=1}^n \frac{I(x_i)}{(\theta_1 + \infty)}$$

$$\frac{p_{\theta_1}(x)}{p_{\theta_0}(x)} = \frac{\left(\frac{1}{\theta_1}\right)^n e^{-\frac{\sum x_i}{\theta_1}} I(x_n)}{\left(\frac{1}{\theta_0}\right)^n e^{-\frac{\sum x_i}{\theta_0}} I(x_n)} = \left(\frac{\theta_0}{\theta_1}\right)^n \exp\left\{-\frac{\sum x_i}{\theta_1} \left(-1 + 1\right)\right\} \frac{I(x_n)}{\prod_{i=1}^n \frac{I(x_i)}{(\theta_1 + \infty)}}$$

í removendo $\sum x_i$

$$\text{Siga: } T = \sum X_i$$

$p_{\theta_1}(x)$ é RVU em $T = \sum X_i$

Então, um teste UMP para todos $H_0: \theta = \theta_0$ vs $H_1: \theta > \theta_0$

mais simples é:

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > c \\ 0 & \text{se } T(x) \leq c \end{cases}$$

$$\therefore E_{\theta_0}(\phi(x)) = \alpha$$

Vamos determinar c

Sub H_0 :

$$E_{\theta_0}(\phi(x)) = \alpha$$

$$\therefore P_{\theta_0}(\phi(x) = 1) = \alpha$$

$$P_{\theta_0}(T(x) > c) = \alpha$$

$$P_{\theta_0}(\sum X_i > c) = \alpha$$

$$X_i \sim \text{Exp}(\theta)$$

$$X_i \sim \text{Gamma}(n, \theta)$$

$$\therefore \sum X_i \sim \text{Gamma}(n, n\theta) \sim \chi_{2n}^2$$

17/11/2010

Então

$$P_{\theta_0}(\sum X_i > c) = \alpha$$

$$P_{\theta_0} \left(\frac{2}{\theta} \sum X_i > 2c \right) = \alpha \Rightarrow P \left(\frac{\chi^2_{2n}}{\theta_0} < \frac{2c}{\theta_0} \right) = \alpha.$$

$$\frac{2c}{\theta_0} = q_{1-\alpha} \text{ e } q \text{ é o quartil de } \chi^2_{2n}$$

$$c = \theta_0 q_{1-\alpha}$$

ou

Então, o teste UMP para a tese $H_0: \theta = \theta_0$ vs $H_1: \theta > \theta_0$ rejeita H_0

Não rejeita se:

$$\Phi(z) = \begin{cases} 1 & \text{se } \sum X_i > \theta_0 q_{1-\alpha} \\ 0 & \text{c.c.} \end{cases}$$

ou seja, se $\sum X_i > \frac{\theta_0 q_{1-\alpha}}{2}$, em que $q_{1-\alpha}$ é o quartil de ordem $1-\alpha$ de uma distribuição χ^2_{2n} .

* Alternativamente:

$$p_{\theta}(x) = \left(\frac{1}{\theta}\right)^n e^{-\frac{\sum x_i}{\theta}} = \frac{1}{\theta^n} \left\{ -\sum x_i - n \log \theta \right\}$$

$$\eta(\theta) = -\frac{1}{\theta} \quad T(X) = \sum X_i \quad B(\theta) = n \log \theta \text{ pertence à família exponencial paramétrica}$$

$$\eta'(\theta) = \frac{1}{\theta^2} \quad \eta''(\theta) = -\frac{1}{\theta^3} > 0 \quad \therefore \eta(\theta) \text{ é monótona e crescente}$$

9,08

1

3,84

17/11/2010

(b) N. a amostra observada foi $(2,0; 0,2; 1,0; 0,9; 1,0; 0,7; 0,3; 1,3; 1,4; 0,8)$ e $\theta_0 = 1$, qual é sua conclusão ao nível de 5%? Qual é o nível desritivo do teste?

A regras de decisão do teste é dada por:

$$\sum X_i > \theta_0 q_{1-\alpha} \text{ rejeita-se } H_0$$

$$q_{1-\alpha} \text{ é o quartil } \chi^2_{2n}$$

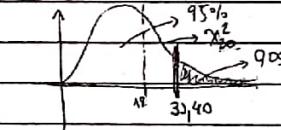
$$\text{e C.C. aceita-se } H_0.$$

$$\sum x_i = 2,0 + 0,2 + 1,0 + 0,9 + 1,0 + 0,7 + 0,3 + 1,3 + 1,4 + 0,8 = 9$$

$$\theta_0 = 1$$

$$q_{1-\alpha} = 31,41 \quad \chi^2_{2,10} = \chi^2_{30}$$

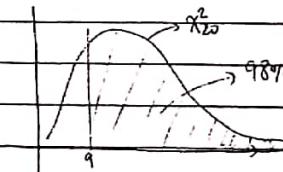
$$\frac{\theta_0 q_{1-\alpha}}{2} = \frac{31,41}{2} = 15,70$$



$$\text{Como } \sum X_i = 9 < 15,70 = \frac{\theta_0 q_{1-\alpha}}{2} \text{ não rejeita-se } H_0.$$

E o p-valor será dado por:

$$P_{\theta_0}(\sum X_i > \sum x_i) = P_{\theta_0}(\sum X_i > 9) = 0,9829$$



17/11/2010

6. Sejam X_1, X_m variáveis aleatórias independentes, cada qual com distribuição $r(g, b)$. Mostre que existe um teste UMP para testar

(a) $H: b \leq b_0$ contra $K: b > b_0$, quando g é conhecido.

$$\text{Gama} \quad 1 \quad x_i^{g-1} e^{-\frac{x_i}{b}} I_{(0,+\infty)}(x_i)$$

$$r(g, b) = \frac{1}{(gb)^n} \cdot b^{\frac{n}{g}}$$

g conhecido.

$$\frac{p_{b_0}(x)}{p_b(x)} = \frac{\left(\frac{1}{(gb_0)^n} \cdot b_0^{\frac{n}{g}}\right)^m \cdot e^{-\sum x_i}}{\left(\frac{1}{(gb)^n} \cdot b^{\frac{n}{g}}\right)^m \cdot e^{-\sum x_i}} = \left(\frac{b_0}{b}\right)^m \cdot \exp\left(-\sum x_i \left(\frac{1}{b_0} - \frac{1}{b}\right)\right) > 0$$

$p_{b_0}(x) = p_b(x)$ é não decrescente para $T = \sum x_i$

$$p_{b_0}(x)$$

Então $p_{b_0}(x)$ é RVM para $T = \sum x_i$.

Daí, existe um teste UMP de nível α para testar $H: b \leq b_0$

vs $K: b > b_0$ e é dado por:

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) \geq c \\ 0 & \text{c.c.} \end{cases} \quad (1)$$

$$\text{e } E_\alpha(\phi(x)) = \alpha \quad (2)$$

Para determinar c usando (2).

$$E_\alpha(\phi(x)) = \alpha$$

$$P_{b_0}(T(x) \geq c) = \alpha$$

$$P_{b_0}(\sum x_i \geq c) = \alpha$$

$$X_i \sim r(g, b)$$

$$\sum x_i \sim r(ng, b)$$

$$2 \sum x_i \sim r(2ng, 2b) \sim \chi^2_{2ng}$$

$$\text{e } 2 \sum x_i \sim \chi^2_{2ng}$$

$$\text{e } 2 \sum x_i \sim \chi^2_{2ng}$$

$$\text{e } 2 \sum x_i \sim \chi^2_{2ng}$$

$$E(y) = ngb$$

tabelado

$$2 \sum x_i \sim \chi^2_{2ng, 2b} \text{ ou } 2 \sum x_i \sim \chi^2_{2ng}$$

$$ng$$

$$\dots P_{b_0} \left(\frac{2 \sum x_i}{gb} > c \right) = \alpha$$

para determinar

17/11/2010

$$P\left(\frac{\chi^2_{2ng}}{gb} > c\right) = \alpha$$

χ^2_{2ng} é uma variável aleatória com dist. χ^2_{2ng}

E então:

$$c = g \cdot q_{1-\alpha}, \text{ } q_{1-\alpha} \text{ é o quantil de uma } \chi^2_{2ng}$$

$$c = \frac{gb \cdot q_{1-\alpha}}{2}$$

Então o teste rejeita H_0 se e somente se:

$$\sum x_i > g \cdot q_{1-\alpha}, \text{ em que } q_{1-\alpha} \text{ é o quantil}$$

de uma distribuição qui-quadrado com $2ng$ graus de liberdade

$$\chi^2_{2ng} \sim \chi^2_{2ng}$$

$$\text{Alternativamente: } f(x, b) = \frac{1}{(gb)^n} \cdot \left(\frac{x_i}{b}\right)^{g-1} e^{-\frac{x_i}{b}} = r(g, b)$$

de modo que

é exponencial

e monótona

e crescente

e unimodal

$$f(b) = \frac{1}{b} \eta'(b) = \frac{1}{b^2} \eta(b), \text{ } \eta(b) \text{ é monótona e crescente, então}$$

existe teste UMP para testar $H: b \leq b_0$ contra $K: b > b_0$ dado por

$$\phi(x) = \begin{cases} 1 & \text{se } \sum x_i > c \\ 0 & \text{c.c.} \end{cases}$$

$$\alpha = P_{b_0}(\sum x_i > c)$$

$$X_i \sim r(g, b)$$

$$\sum x_i \sim r(ng, b)$$

$$2 \sum x_i \sim r(2ng, 2b)$$

$$2 \sum x_i \sim \chi^2_{2ng}$$

$$2 \sum x_i \sim \chi^2_{2ng}$$

$$E(x) = ngb$$

$$E(x) = ngb$$

$$E(x) = ngb$$

$$E(x) = ngb$$

17/11/2010

(b) $H: g \leq g_0$ contra $K: g > g_0$, quando b é conhecido.

$r(g, b)$

$$f(x) = \frac{1}{r(g, b)^n} x^{g-1} e^{-\frac{x}{b}} T(x)_{(0,+\infty)}$$

Sendo $g_1 > g_0$:

$$\frac{p_g(x)}{p_{g_1}(x)} = \frac{\left(\frac{1}{r(g_1, b)^n} x^{g_1-1} e^{-\frac{x}{b}}\right)}{\left(\frac{1}{r(g_0, b)^n} x^{g_0-1} e^{-\frac{x}{b}}\right)} =$$

$$= \left(\frac{1}{r(g_0, b)^n}\right)_{i=1}^n \frac{x^{g_1-g_0}}{e^{-\frac{nx}{b}}} =$$

$$= \left[\frac{r(g_0, b)^n}{r(g_1, b)^n}\right]^n \cdot \left(\prod_{i=1}^n x_i^{g_1-g_0}\right)$$

$p_{g_1}(x)$ é menor que $p_g(x)$

Então $p_g(x)$ é RVM em $T = \prod_{i=1}^n x_i$,

e então érvem um teste UMP para testar $H: g \leq g_0$ vs $K: g > g_0$ que não dada por:

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) = \prod_{i=1}^n x_i > c \\ 0 & \text{c.c.} \end{cases} \quad E_{g_0}(\phi(x)) = \alpha$$

Mas se $\prod x_i > c$,

$\log \prod x_i > c$, função crescente crescente

$\left[\log x_i > c \right]$

é uma regra de decisão $\log x_i > c$.

Vamos determinar c :

$x_i \sim r(g, b)$

$\log x_i \sim ?$

$z = \log x_i$

$x = e^z$

$dx = e^z dz$

dy

$$f_z(z) = \frac{1}{r(g, b)^n} (e^z)^{g-1} e^{-\frac{e^z}{b}} e^z I(z)_{(1, +\infty)}$$

$$f_z(z) = \frac{1}{r(g, b)^n} e^{3z} e^{-\frac{e^z}{b}} T(z)_{(1, +\infty)}$$

não tem sujeira de conhecido.

1/1

$$H: g \leq g_0 \text{ contra } K: g > g_0 \quad b = b \text{ conhecido}$$

$$r(g, b) = \frac{1}{\left(r(g) b\right)^n} e^{-\frac{nx}{b}} =$$

$$= n p f(g-1) \log \prod x_i - \sum x_i - n \log r(g) b \frac{1}{b}$$

$$\eta'(g) = g-1 \quad T(X) = \log \prod X_i = \sum \log X_i$$

$$\eta'(g) = 1 \quad B(g) = n \log r(g) b \frac{1}{b}$$

$$h(u) = \exp\left(-\frac{\sum x_i}{b}\right)$$

Pertence à família exponencial e

$\eta'(g) = g-1$ é monotone crescente, então existe teste UMP.

dado por

$$\phi(x) = \begin{cases} 1 & \text{se } \sum \log x_i > R \\ 0 & \text{c.c.} \end{cases}$$

$$\alpha = E_{g_0}(\phi(x))$$

T sejam X_1, \dots, X_n variáveis aleatórias independentes, cada qual com distribuição Gaussiana inversa $GI(\mu, T)$ e densidade

$$\frac{\sqrt{T}}{2\pi} \exp\left[-(Tu)^{\frac{1}{2}}\right] x^{-\frac{3}{2}} \exp\left[-\frac{1}{2}\left(\frac{T}{x} + \mu x\right)\right], x > 0,$$

mostrou que existe um teste UMP para $H_0: \mu = \mu_0$

(a) $H_0: \mu \leq \mu_0$ contra $H_1: \mu > \mu_0$, quando T é conhecido tem dado constante

(b) $H_0: T \leq T_0$ contra $H_1: T > T_0$, quando μ é conhecido. forma da região crítica

(a) T é conhecido

$$\begin{aligned} p_{H_0}(x) &= \left(\frac{\sqrt{T}}{2\pi}\right)^n \exp\left[n - (Tu)^{\frac{1}{2}}\right] \cdot \frac{n-2}{2} \exp\left[-\frac{1}{2} \sum_i \left(\frac{T}{x_i} + \mu x_i\right)\right] \\ p_{H_1}(x) &= \left(\frac{\sqrt{T}}{2\pi}\right)^n \exp\left[n - (Tu)^{\frac{1}{2}}\right] \cdot \frac{n-2}{2} \exp\left[-\frac{1}{2} \sum_i \left(\frac{T}{x_i} + (\mu_0 + \epsilon)x_i\right)\right] \\ &= \exp\left[n \left[(Tu)^{\frac{1}{2}} - (\mu_0 + \epsilon)^{\frac{1}{2}}\right] - \frac{1}{2} \sum_i (\mu_0 + \epsilon)x_i\right] \\ &\quad \text{Existe } p_{H_1}(x) \downarrow \\ &\quad < 0 \quad \text{relação decrescente.} \end{aligned}$$

Então, $p_{H_1}(x)$ possui RVM em $T = -\sum x_i$ (não decrescente)

Então, um teste UMP para testar $H_0: \mu \leq \mu_0$ contra $H_1: \mu > \mu_0$, quando T é conhecido, será dado por:

$$\phi(x) = \begin{cases} 1 & \text{se } -\sum x_i > c \\ 0 & \text{c.c.} \end{cases} \Leftrightarrow \phi(x) = \begin{cases} 1 & \text{se } \sum x_i < c \\ 0 & \text{c.c.} \end{cases}$$

Alternativamente

$p_{H_1}(x)$ possui RVM mais decrescente em $T = \frac{1}{\sum x_i}$

E então, a região crítica será dada por

$$\phi(x) = \begin{cases} 1 & \text{se } \frac{1}{\sum x_i} > c \\ 0 & \text{c.c.} \end{cases} \Leftrightarrow \phi(x) = \begin{cases} 1 & \text{se } \sum x_i < \frac{1}{c} \\ 0 & \text{c.c.} \end{cases}$$

* $T(X) \sim$ Gaussiana Inversa

Alternativamente:

$$f(x, \mu, T) = \sqrt{\frac{T}{2\pi}} \exp\left[-(Tu)^{\frac{1}{2}}\right] x^{-\frac{3}{2}} \exp\left[-\frac{1}{2}\left(\frac{T}{x} + \mu x\right)\right]$$

$\rightarrow T$ conhecido

$$p(\mu) = \left(\frac{\sqrt{T}}{2\pi}\right)^{\frac{n}{2}} \exp\left[n - (Tu)^{\frac{1}{2}}\right] \left(\frac{\sqrt{T}}{2\pi}\right)^{\frac{n}{2}} \exp\left[-\frac{1}{2} \sum_i \left(\frac{T}{x_i} + \mu x_i\right)\right]$$

$$= \sup_{\mu} \left\{ -T \sum_i x_i - \mu \sum_i x_i + (Tu)^{\frac{1}{2}} - \frac{3}{2} \log(T/x_i) + n \log \frac{T}{2\pi} \right\}$$

$$\eta(\mu) = -\frac{\mu}{2} \quad T(X) = \sum x_i$$

A dist. pertence a família exponencial semi-paramétrica

$$\eta'(A) = -1 < 0 \quad \text{decrescente}$$

Como $\eta(\mu) = -\frac{\mu}{2}$ é uma função monótona decrescente, então um teste UMP para testar $H_0: \mu \leq \mu_0$ contra $H_1: \mu > \mu_0$ é dado por

$$\phi(x) = \begin{cases} 1 & \text{se } \sum x_i > k \\ 0 & \text{c.c.} \end{cases}$$

$$k = P_{\mu_0}(\sum x_i > k)$$

IBAumann.

17/11/2010

b) $H: T \leq T_0$ contra $K: T > T_0$, quando μ é conhecida.

$$\text{Sendo } \mu \text{ conhecida, } T_1 \geq T_0$$

$$p_T(x) = \frac{\left(\frac{x_i}{\theta}\right)^n \exp\left[n\left(T_0\mu\right)^2\right]}{\prod_{i=1}^n x_i^{1/2} \exp\left[-\frac{1}{2\theta^2} \left(\frac{x_i}{\theta} + \mu x_i\right)^2\right]} =$$

$$p_{T_0}(x) = \left(\frac{x_i}{\theta}\right)^n \exp\left[n\left(T_0\mu\right)^2\right] \prod_{i=1}^n x_i^{1/2} \exp\left[-\frac{1}{2\theta^2} \left(\frac{x_i}{\theta} + \mu x_i\right)^2\right]$$

$$= \left(\frac{T_0}{\theta}\right)^n \exp\left[n\mu^2\left(\frac{T_0}{\theta} - \frac{1}{\theta}\sum_{i=1}^n \frac{1}{x_i}\right)\right]$$

$$\left(\sum_{i=1}^n \frac{1}{x_i} \right) \quad 1 \quad 1$$

$$p_T(x) \text{ parece RVM com } T(x) = \sum_{i=1}^n \frac{1}{x_i} \quad (\text{mto - decrescente})$$

Então, um teste UMP para tétula $H: T \leq T_0$ contra $K: T > T_0$, quando μ é conhecida, será da forma:

$$\phi(x) = \begin{cases} 1 & \text{se } \sum_{i=1}^n \frac{1}{x_i} > c, \\ 0 & \text{c.c.} \end{cases} \rightarrow \sum_{i=1}^n \frac{1}{x_i} < c.$$

$$\text{e } F_{H_0}(\phi(x)) = \alpha$$

$$\text{Região crítica: } S = \{x \mid \sum_{i=1}^n \frac{1}{x_i} > c \text{ com } c \text{ tal que}$$

$$\alpha = P_{H_0}\left(\sum_{i=1}^n \frac{1}{x_i} > c\right)\}$$

$$\text{Alternativamente } p_T(x) = \sup_{\mu \text{ conhecido}} \left[-\frac{T}{2} - \mu \sum_{i=1}^n \frac{1}{x_i} + \frac{(\mu)^2}{2} - \frac{3}{2} \log \prod_{i=1}^n x_i + \frac{1}{2} \log T \right]$$

pertence a classe de funções monônomial crescentes

$$\eta(T) = -\frac{T}{2}, \quad \eta'(T) = -\frac{1}{2} < 0 \quad \text{decrecente e monônomia, então}$$

é um teste UMP para tétula

$H: T \leq T_0$ vs $K: T > T_0$ dado por

$$\phi(x) = \begin{cases} 1 & \text{se } \sum_{i=1}^n \frac{1}{x_i} < \theta_0 \\ 0 & \text{c.c.} \end{cases}$$

$$\alpha = P_{H_0}\left(\sum_{i=1}^n \frac{1}{x_i} < \theta_0\right)$$

17/11/2010

Se pegarmos X_1, \dots, X_m uma amostra aleatória de uma distribuição $U(0, \theta)$.

(a) Mostre que, para tétula $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$, qualquer teste para o qual $F_{H_0}(\phi(x)) = \alpha$, $F_{H_0}(\phi(x)) \leq \alpha$, para $\theta \leq \theta_0$, e $\phi(x) = 1$ quando $\max(x_1, \dots, x_m) > \theta_0$, é UMP de nível α . Sugestão: Use a

lema de Neyman-Pearson, com $K = \left(\frac{\theta_0}{\theta_1}\right)^n$

$$p_\theta(x) = \frac{1}{\theta^n} I(x) = \frac{1}{\theta_0^n} I(x_m) \quad \text{se } x_m > \theta_0, x_i < \theta_0$$

Segundo lema de Neyman-Pearson, um teste MP para tétula

$\theta = \theta_0$ vs $\theta = \theta_1$, é dado por:

$$\phi(x) = \begin{cases} 1 & \text{se } p_\theta(x) > K p_{\theta_0}(x) \\ 0 & \text{se } p_\theta(x) \leq K p_{\theta_0}(x) \end{cases}$$

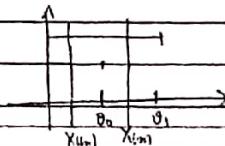
e $F_{H_0}(\phi(x)) = \alpha$

para $\theta_1 > \theta_0$, então

$$p_\theta(x) > K p_{\theta_0}(x) \quad \frac{1}{\theta} I(x_m) > K \frac{1}{\theta_0} I(x_m)$$

$$\frac{I(x_m)}{I(x_m)} > K \frac{\theta_0}{\theta}$$

Se $K = \left(\frac{\theta_0}{\theta_1}\right)^n$ tem-se que:



$$I(x_m) > I(x_m)$$

$$(0, \theta_0) \quad (0, \theta_0)$$

$$x_m \quad x_m$$

$$\phi'(x) = \begin{cases} 1 & \text{se } I(x_m < \theta_1) > I(x_m < \theta_0) \\ 0 & \text{se } I(x_m < \theta_1) \leq I(x_m < \theta_0) \end{cases}$$

$$\boxed{0 & \text{se } I(x_m < \theta_1) \leq I(x_m < \theta_0)}$$

17/11/2010

$$\alpha = \inf_{\theta_0} P(\theta_0 < X_m < \theta_0) + P_{\theta_0} P(X_m \leq \theta_0)$$

0

que é
1

K

$\alpha = P$

$$\text{dado } \phi(x) = \begin{cases} 1 & \text{se } x_m > \theta_0 \\ 0 & \text{caso contrário} \end{cases}$$

$$(i) \quad \max(x_1, \dots, x_n) > \theta_0 \Leftrightarrow x_m > \theta_0$$

$$(ii) \quad \max(x_1, \dots, x_n) \leq \theta_0 \Leftrightarrow x_m \leq \theta_0$$

que

~~17/11/2010~~

~~desconhecida~~

~~ver 23/11~~

(b) Mostre que, para teste $H: \theta = \theta_0$ contra $K: \theta \neq \theta_0$, se tem $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$ ou $\max(x_1, \dots, x_n) \leq \theta_0 \wedge x_m > \theta_0$, e $\phi(x) = 0$, caso contrário, é UMP.

Sugestão: Considere separadamente 3 situações: (i) $H: \theta = \theta_0$ contra $K_1: \theta = \theta_0 \vee \theta_0$; (ii) $H: \theta = \theta_0$ contra $K_2: \theta = \theta_1, \theta_0 < \theta_1 < \theta_0$; (iii) $H: \theta = \theta_0$ contra $K_3: \theta = \theta_1 \leq \theta_0 \wedge x_m > \theta_1$.

Mostre que: $H: \theta = \theta_0 \quad \text{vs} \quad K: \theta \neq \theta_0$

$$\phi(x) = \begin{cases} 1 & \text{se } \max(x_1, \dots, x_n) > \theta_0 \text{ ou} \\ & \max(x_1, \dots, x_n) \leq \theta_0 \wedge x_m > \theta_0 \\ 0 & \text{caso contrário} \end{cases}$$

Sugestão: 1) $H: \theta = \theta_0 \quad \text{vs} \quad K_1: \theta = \theta_1 \vee \theta_0$

2) $H: \theta = \theta_0 \quad \text{vs} \quad K_2: \theta = \theta_1, \theta_0 < \theta_1 < \theta_0$

3) $H: \theta = \theta_0 \quad \text{vs} \quad K_3: \theta = \theta_1 \leq \theta_0 \wedge x_m > \theta_1$

Segundo a sugestão, temos que:

Pelo item 1) um teste UMP para teste 1) é dado por $\phi(x) = 1$ se $\max(x_1, \dots, x_n) > \theta_0$. Então basta provar que atende com as regras 2) e 3).

Considerando 2) $H: \theta = \theta_0 \quad \text{vs} \quad K_2: \theta = \theta_1, \theta_0 < \theta_1 < \theta_0 \wedge x_m > \theta_1$

Pelo teste de NP item 1) que

$$p_{\theta_1}(x) > K \cdot p_{\theta_0}(x)$$

$$\frac{I(x_m)}{\binom{\theta_1}{n}} > K \cdot \frac{I(x_m)}{\binom{\theta_0}{n}}$$

$$\text{Fazendo } K = \frac{\binom{\theta_0}{n}}{\binom{\theta_1}{n}}, \text{ tem-se}$$

$$\frac{I(x_m)}{\binom{\theta_0}{n}} > \frac{I(x_m)}{\binom{\theta_1}{n}} \iff$$

$$\frac{I(x_m)}{\binom{\theta_0}{n}} = 1 \quad \text{e} \quad \frac{I(x_m)}{\binom{\theta_1}{n}} = 0 \iff$$

17/11/2010

$$T(x_m) = 1 \iff 0 < x_m < \theta_0 \quad \text{①}$$

$$\begin{aligned} I(x_m) = 0 &\iff x_m < 0 \text{ ou } x_m > \theta_0 \quad \text{②} \\ \text{①} \wedge \text{②} &\Rightarrow \theta_1 < x_m < \theta_0 \quad \text{③} \end{aligned}$$

No região $\theta_1 < \theta_0$, não existe um valor da estatística X_m que satisfaça o parâmetro.

Se $\theta_1 < \theta_0$, tem

$$p_{\theta_1}(x) < K p_{\theta_0}(x) \quad (\phi(x)=0) \quad \frac{x=(\theta_1)^n}{}$$

$$\Rightarrow I(x_m) < I(x_n) \quad \text{④}$$

$$I(x_m) = 0 \quad \text{e} \quad I(x_n) = 1 \quad \text{⑤}$$

$$x_m < 0 \text{ ou } x_m > \theta_1 \quad \text{e} \quad 0 < x_m < \theta_0$$

$$\begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array} \quad \begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array} \quad \begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array} \quad \begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array}$$

No região $\theta_0 < \theta_1 < \theta_0$

$$\begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array} \quad \begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array}$$

$$\text{entre } \theta_0 < \theta_1 < x_m < \theta_0$$



$$\theta_0 < x_m < \theta_0$$

$$\dots \text{Assim: } \phi(x) = 0 \text{ e } \theta_0 < x_m < \theta_0$$

17/11/2010

Considerando 3) H: $\theta = \theta_0$ contra $K_3: \theta = \theta_1 \leq \theta_0 \alpha^n$

Pelo item a) anteriormente por NP tem-se que

$$p_{\theta_1}(x) > p_{\theta_0}(x), \quad \theta_1 > \theta_0$$

$$I(x_m) > K \cdot I(x_n) \quad \frac{1}{(\theta_1)^n} > \frac{1}{(\theta_0)^n} \quad \frac{I(x_m)}{(\theta_1)^n} > \frac{I(x_n)}{(\theta_0)^n}$$

$$\text{Fazendo } K = \left(\frac{\theta_0}{\theta_1}\right)^n \text{ tem-se}$$

$$I(x_m) > I(x_n)$$

E ent\~ao:

$$I(x_m) = 1 \quad \text{e} \quad I(x_n) = 0$$

$$0 < x_m < \theta_1 \quad \text{e} \quad x_n < 0 \text{ ou } x_n > \theta_0$$

$$\begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array}$$

No regi\~ao $\theta_1 < \theta_0$, n\~ao existe um valor da estat\'istica X_m que possa vir a ser alternativa para o par\~ametro θ .

$$\text{Tentemos } \text{NP } p_{\theta_1}(x) < p_{\theta_0}(x) \quad (\phi(x)=0) \quad \frac{K = (\frac{\theta_0}{\theta_1})^n}{\theta_1 < \theta_0}$$

$$\Rightarrow I(x_m) < I(x_n) \Rightarrow$$

$$I(x_m) = 0 \quad \text{e} \quad I(x_n) = 1 \Rightarrow$$

$$\begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array}$$

$$\begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array}$$

$$\begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array}$$

$$\begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array}$$

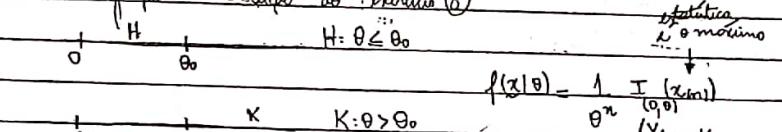
$$\theta_1 < x_m < \theta_0$$

$$\begin{array}{c} \text{---} \\ 0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \\ \text{---} \\ \theta_1 \\ \text{---} \\ \theta_0 \end{array}$$

19/11/2010

Na região, $\theta_1 < \theta_0 < \theta_2$, mas não se sabe se X_m

Estudo um grupo - Resolução do exercício 8)



$X_m > \theta_0$ não se tem problema, rejeita-se no ato.

O problema é ter um $X_m < \theta_0$, o que acontece?

$\theta_1 > \theta_0$ $X_m < \theta_0$

$$f(x|\theta) = \begin{cases} \frac{\theta^n}{\theta_1^n} I(x_m), & x_m > \theta_0 \\ 0, & \text{c.c.} \end{cases}$$

$$E_{\theta_0}(\phi(x)) = \alpha \Leftrightarrow$$

$$P_{\theta_0}(X_m > \theta_0) = \alpha$$

$$X \sim U(0, \theta_0) \quad \begin{array}{c} 0 \\ \hline \theta_0 \end{array}$$

$$\therefore P_{\theta_0}(X_m > \theta_0) = \alpha$$

\rightarrow Sob θ_0 o máximo não vai ser maior que θ_0 . (então o teste não pode ser se $X_m > \theta_0$)

$$\phi(x) = \begin{cases} 1, & x_m > \theta_0 \\ 1, & x_m > K (< \theta_0) \\ 0, & \text{c.c.} \end{cases}$$

$$H: \theta \leq \theta_0 = 10 \quad X_m = 0,0001$$

$$K: \theta > \theta_0 = 10 \quad X_m = 9,9999$$

$$\begin{array}{c} 0 \\ \hline \theta_0 = 10 \\ K \end{array}$$

19/11/2010

$$P(X_m < x) = \binom{x}{\theta}^n$$

$$f_{X_m}(x) = n x^{n-1}$$

$$\alpha = P_{\theta_0}(X_m > K) = 1 - P_{\theta_0}(X_m < K) = 1 - \left(\frac{K}{\theta_0}\right)^n$$

$$\Rightarrow \left(\frac{K}{\theta_0}\right)^n = 1 - \alpha \Rightarrow K = \frac{(1-\alpha)^{\frac{1}{n}}}{\theta_0} \Rightarrow K = \theta_0 \cdot \sqrt[n]{1-\alpha}$$

$$\begin{array}{l|l} \text{fazí } & \phi(x) = \begin{cases} 1, & \text{se } X_m > \theta_0 \\ 0, & \text{c.c.} \end{cases} \\ \text{o teste} & \begin{cases} 1, & \text{se } X_m > \theta_0 \sqrt[n]{1-\alpha} \\ 0, & \text{c.c.} \end{cases} \end{array}$$

Deste modo, não cumpre a propriedade $E_{\theta_0}(\phi(x)) = \alpha$

$$E_{\theta_0}(\phi(x)) = \alpha \rightarrow P_{\theta_0}(X_m > K) = 0 < \alpha \text{ (funciona)}$$

$$E_{\theta < \theta_0}(\phi(x)) \leq \alpha \rightarrow E_{\theta < \theta_0}(\phi(x)) = 1 - \left(\frac{x}{\theta}\right)^n \leq \alpha \quad x = \theta_0$$

Se $X_m > \theta_0$ não entende sempre rejeita

Se $X_m < \theta_0$ entende sempre RVM (X_m) e, elo é monótono não decrescente

$\max\{x_1, \dots, x_n\} < \theta_0 \Leftrightarrow$ máximo deve ser um pouco menor que θ_0 .

$$\begin{array}{c} \text{Rejeita} \\ \text{se} \\ x_m \end{array} \quad \begin{array}{c} \text{Acerto} \\ \text{se} \\ x_m < \theta_0 \end{array} \quad \begin{array}{c} \text{Rejeita} \\ \text{se} \\ x_m > \theta_0 \end{array}$$

$$\theta \leq \theta_0 \quad (\xrightarrow{x_m < \theta_0}) \quad \theta > \theta_0 \quad (\xrightarrow{x_m > \theta_0})$$

como é uma uniforme nenhuma rejeição não se faz

$$\theta = \theta_0 \quad \theta \neq \theta_0$$

$$\theta < \theta_0 \quad \theta > \theta_0$$

$$\xrightarrow{x_m < \theta_0} \text{rejeição}$$

$$\xrightarrow{x_m > \theta_0} \text{não rejeição}$$

$$\xrightarrow{x_m = \theta_0} \text{não se faz}$$

(17/11/2010)

9. Considere uma única observação de uma variável X

(a) Use o teste de Neyman-Pearson para encontrar o teste mais poderoso de nível α de $H: X \sim U(0,1)$ contra $K: X \sim \text{Beta}(1,b)$, sendo $b > 1$ fixado. Se $\alpha = 0,05$ e se foi observado $x=0,1$, qual é seu desvio? Qual é o nível descontínuo ($p\text{-value}$) do teste?

Para teste:

$$H: X \sim U(0,1) \quad \text{vs} \quad K: X \sim \text{Beta}(1,b), \quad b > 1 \text{ fixo}$$

Existe segundo NP um teste MP ϕ e uma constante K tais que:

$$E_\theta \{\phi(X)\} = \alpha.$$

$$\phi(x) = \begin{cases} 1 & \text{quando } p_{\theta}(x) > K, p_0(x) \\ 0 & \text{quando } p_{\theta}(x) \leq p_0(x) \end{cases}$$

$$p_{\theta}(x) = \frac{r(j+b)}{t(j) \cdot r(b)} \cdot x^{j-1} \cdot (1-x)^{b-1} = \frac{b}{t(j)} \cdot (1-x)^{b-1} = \frac{b}{t(j)} \cdot (1-x)^{b-1} \cdot I(x)$$

$$B(1,b)$$

$$p_0(x) = \frac{1}{t(0,1)} \cdot I(x) = \frac{1}{t(0,1)} \cdot I(x)$$

$$\begin{aligned} \text{Se NP tem -se:} \\ p_{\theta}(x) > K \cdot p_0(x) \Rightarrow b(1-x)^{b-1} > K \cdot 1 \quad x \in (0,1) \\ (1-x)^{b-1} > K \\ 1-x > K \\ -x > K \\ x < K \end{aligned}$$

Deste modo, o teste ϕ é rejeitado quando:

$$\phi(x) = \begin{cases} 1 & \text{quando } x < K \\ 0 & \text{quando } x \geq K \end{cases}$$

Para determinar K , tem -se que:

$$E_{\theta_0}(\phi(X)) = \alpha \Rightarrow P_{\theta_0}(X < K) = \alpha = K, \text{ para} \quad \text{não hab } X \sim U(0,1)$$

(17/11/2010)

11. Sejam X_1, \dots, X_n uma amostra aleatória de distribuição exponencial deslocada com função densidade de probabilidade:

$$f(x; \theta, T) = \frac{1}{T} \exp\left(-\frac{x-\theta}{T}\right) I_{(\theta, +\infty)}(x); \quad -\infty < \theta < \infty, T > 0$$

(a) Admita que θ é conhecido. Encontre um teste UMP de $H: T \leq T_0$ contra $K: T > T_0$ de nível $\alpha \in (0,1)$.

$$\begin{aligned} \text{Sup } T_1 > T_0; \quad & \left(\frac{T_1}{T_0}\right)^n \exp\left\{-\sum_{i=1}^n (x_i - \theta)\right\} \cdot \prod_{i=1}^n I_{(\theta, +\infty)}(x_i) \\ p_{\theta}(x) = & \left(\frac{T_1}{T_0}\right)^n \exp\left\{-\sum_{i=1}^n (x_i - \theta)\right\} \prod_{i=1}^n I_{(\theta, +\infty)}(x_i) \\ & = \left(\frac{T_1}{T_0}\right)^n \exp\left\{-\sum_{i=1}^n \left(\frac{x_i - \theta}{T_1}\right) + \sum_{i=1}^n \left(\frac{x_i - \theta}{T_0}\right)\right\} \cdot \prod_{i=1}^n \left(\frac{I(x_i)}{T_1}\right) \cdot \prod_{i=1}^n \left(\frac{I(x_i)}{T_0}\right) \\ & = \left(\frac{T_1}{T_0}\right)^n \exp\left\{-\sum_{i=1}^n \left(\frac{x_i - \theta}{T_1}\right) \cdot \underbrace{\left(-1 + \frac{1}{T_1}\right)}_{< 0} \cdot \sum_{i=1}^n \left(\frac{I(x_i)}{T_0}\right)\right\} \end{aligned}$$

$\Rightarrow p_{\theta}(x) \cdots$ tem IRVM não-decrescente em $T_1(x)$, dado θ

por $T(x) = \sum (x_i - \theta)$ e então existe um teste UMP de nível α para rejeitar $H: T \leq T_0$ vs $K: T > T_0$, em que:

$$\phi(x) = \begin{cases} 1 & \text{quando } T(x) = \sum (x_i - \theta) > c, \quad \theta \text{ conhecido} \\ 0 & \text{quando } T(x) = \sum (x_i - \theta) \leq c. \end{cases}$$

$$E_{\theta_0}(\phi(x)) = \alpha$$

$$X \sim E(\theta, T)$$

$$y = X - \theta \sim ?$$

$$\int e^{-\frac{a}{\theta}} da = \int e^{-c} dc \cdot T = T \cdot e^{-\frac{a}{\theta}}$$

$$c = \frac{a}{\theta}$$

$$dc = \frac{1}{\theta} da \quad da = \theta dc$$

14/11/2010

$$F(y) = P(Y \leq y) = P(X - \theta \leq y) = P(X \leq y + \theta) =$$

$$= \int_{-\theta}^{y+\theta} 1 \cdot e^{-\frac{a-\theta}{\theta}} da = \int_{-\theta}^{y+\theta} e^{\frac{\theta}{\theta}} \cdot \int_0^{y+\theta} e^{-\frac{a}{\theta}} da =$$

$$= \int_0^{y+\theta} e^{\frac{\theta}{\theta}} \cdot e^{\frac{\theta}{\theta}} - e^{-\frac{a}{\theta}} \Big|_0^{y+\theta} =$$

$$= e^{\frac{\theta}{\theta}} \cdot \left(-e^{-\frac{y+\theta}{\theta}} + e^{-\frac{-\theta}{\theta}} \right) = 1 - e^{-\frac{y}{\theta}}$$

$$f(y) = -e^{-\frac{y}{\theta}} \cdot \frac{1}{\theta} = \frac{1}{\theta} e^{-\frac{y}{\theta}}$$

$$y \sim E(\theta)$$

$$\sum_{i=1}^n y_i \sim \text{Gamo}(n, \theta) \sim \chi^2_{2n}$$

$$\frac{1}{T} \sum_{i=1}^n y_i \sim \text{Gamo}(n, \theta) \sim \chi^2_{2n}$$

Então para determinar c_α tem-se que:

$$P_{T_0} (T(X) > c_\alpha) = \alpha$$

$$P_{T_0} (T(X) > c_\alpha) = \alpha$$

$$P_{T_0} \left(\frac{\sum (X_i - \theta)}{T_0} > c_\alpha \right) = \alpha \quad \begin{matrix} \psi(x) = 1, \quad \sum (x_i - \theta) > \chi^2_{2n, 1-\alpha} \\ 0, \quad \text{else} \end{matrix}$$

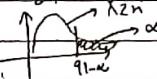
$$P_{T_0} \left(\frac{2 \sum (X_i - \theta)}{T_0} > 2c_\alpha \right) = \alpha$$

$$P_{T_0} \left(\frac{2 \sum (X_i - \theta)}{T_0} > 2c_\alpha \right) = \alpha \quad \begin{matrix} \psi(x) = 1, \quad \sum (x_i - \theta) > \chi^2_{2n, 1-\alpha} \\ 0, \quad \text{else} \end{matrix}$$

$$P_{T_0} \left(\frac{\chi^2_{2n}}{T_0} > 2c_\alpha \right) = \alpha \quad \chi^2_{2n} \text{ é uma v.a. que segue uma dist. } \chi^2_{2n}.$$

$$2c_\alpha = q_{1-\alpha}, \quad \text{em que } q_{1-\alpha} \text{ é o quantil de } T_0 \text{ uma distribuição } \chi^2_{2n}.$$

$$c_\alpha = \frac{q_{1-\alpha}}{2}$$



Portanto, a tese U.M.P. regruta No.s.c. momentâneos: $\sum (X_i - \theta) > T_0 q_{1-\alpha}$,
 $\alpha = P_{T_0} (T(\phi)(X)) = \text{probabilidade de rejeição}$

18/11/2010

(b) Admita que θ é conhecido. Encontre um limite inferior de confiança uniformemente mais acurado para T com coeficiente de confiança $1-\alpha$, ou $\bar{T} \in (0, 1)$

A família de densidades $p_T(x)$, $T \in \Lambda$ possui a propriedade de razão de verossimilhanças monotona em $T(X) = \sum_{i=1}^n (x_i - \theta)$, θ conhecido e, visto a f.d.a. $F_T(t)$, $T = T(X)$ é contínua (quasi-quadra) em cada variável t e T quando a outra é fixada. Pelo corolário p. 50 (motores de auto)

Existe um limite inferior de confiança uniformemente mais acurado \bar{T} para T com coeficiente de confiança $1-\alpha$. Se x denota o valor observado de X e $t = T(x)$ é a solução $F_T(t) = 1-\alpha$ tem uma solução $\bar{T} = \bar{T}$ em \mathbb{R} , visto que a solução é única se $T(x) = \bar{T}$. Desse modo, para se encontrar $\bar{T}(x)$ deve-se resolver a equação:

$$F_T(t) = 1-\alpha$$

$$P_{T_0} (T(X) \leq t) = 1-\alpha$$

$$P_{T_0} (\sum (x_i - \theta) \leq t) = 1-\alpha$$

$$P_{T_0} \left(\frac{2 \sum (x_i - \theta)}{T_0} \leq \frac{2t}{T_0} \right) \leq 1-\alpha$$

$$P_{T_0} \left(\frac{\chi^2_{2n}}{T_0} \leq \frac{2t}{T_0} \right) = 1-\alpha$$

$$\frac{2t}{T_0} = q_{1-\alpha}$$

χ^2_{2n} é uma v.a. com dist. χ^2_{2n} $\frac{2t}{T_0} = q_{1-\alpha}$

Desse modo, se $q_{1-\alpha}$ é o quantil de ordem $1-\alpha$ da distribuição χ^2_{2n} , visto

$$\bar{T}(t) = \frac{2t}{q_{1-\alpha}}$$

18/11/2010

(a) Admita que P é conhecido. Obtenha uma quantidade pivotal que depende do valor apurado através de uma estatística suficiente minimal e obtenha um intervalo de confiança para θ com confiança $1-\alpha$, $\alpha \in (0,1)$

$$p_0(z) = \frac{1}{\theta^n} \exp \left\{ -\sum_{i=1}^n \left(\frac{x_i - \theta}{\theta} \right) \right\} I_{(0,+\infty)}(x_i)$$

$$p_0(z) = \frac{1}{\theta^n} e^{-\frac{\sum x_i}{\theta}} e^{\frac{n\theta}{\theta}} I_{(0,+\infty)}(x_i)$$

$$h(x)$$

$$g(T(x), \theta)$$

file Critério da Fatoração, tem-se que $T(X) = X_{(1)} = \min\{X_1, \dots, X_n\}$ é estatística suficiente para θ .

$$p_0(y) = \frac{1}{\theta^n} \exp \left\{ -\sum_{i=1}^n \left(\frac{x_i - \theta}{\theta} \right) \right\} \exp \left\{ -\frac{\sum y_i + \sum x_i}{\theta} \right\} I_{(0,+\infty)}(x_i) \cdot I_{(y_i < \theta)}(y_i)$$

$$p_0(y) = h(z, y), \text{ para } z = X_{(1)} = y \Leftrightarrow X_{(1)} = y \text{ é estatística suficiente e minimal para } \theta.$$

$$y = X_{(1)}$$

$$F_y(y) = P(Y \leq y) = P(X_{(1)} \leq y) = 1 - P(X_{(1)} > y) = 1 - [P(X_1 > y, X_2 > y, \dots, X_n > y)] =$$

$$= 1 - [P(X_1 > y)]^n = 1 - [1 - P(X_1 \leq y)]^n = 1 - [1 - \int_0^y \frac{1}{\theta} e^{-\frac{x-\theta}{\theta}} \frac{n}{\theta} dx]^n =$$

$$= 1 - [1 - \frac{1}{\theta} e^{\frac{\theta}{\theta}} \int_0^y e^{-\frac{x-\theta}{\theta}} dx]^n = 1 - [1 - \frac{1}{\theta} e^{\frac{\theta}{\theta}} \cdot \left[-e^{-\frac{x-\theta}{\theta}} \right]_0^y]^n =$$

$$= 1 - [1 + e^{-\frac{\theta}{\theta}} - 1]^n = 1 - [e^{-\frac{\theta}{\theta}}]^n = 1 - e^{-\frac{\theta}{\theta}(y-\theta)}$$

$$\therefore f_y(y) = -e^{-\frac{\theta}{\theta}(y-\theta)} \cdot \frac{n}{\theta} = n \cdot e^{-\frac{\theta}{\theta}(y-\theta)}$$

$$X_{(1)} - \theta \sim ?$$

$$y \sim \text{Exp}(\theta, \frac{1}{\theta})$$

18/11/2010

$$\text{Siga } -2f = -X_{(1)} - \theta$$

$$F_z(z) = P(Z \leq z) = P(X_{(1)} - \theta \leq z) = P(X_{(1)} \leq z + \theta) =$$

$$= \int_0^{z+\theta} \frac{n}{\theta} e^{-\frac{(x-\theta)}{\theta}} dx = \dots$$

$$= n \cdot e^{\frac{\theta}{\theta}} \int_0^{z+\theta} e^{-\frac{(x-\theta)}{\theta}} dx =$$

$$= n \cdot e^{\frac{\theta}{\theta}} \cdot \frac{n}{\theta} \left[-e^{-\frac{(x-\theta)}{\theta}} \right]_0^{z+\theta} =$$

$$= e^{\frac{\theta}{\theta}} \cdot \left[-e^{-\frac{(z+\theta-\theta)}{\theta}} + e^{-\frac{\theta}{\theta}} \right] = 1 - e^{-\frac{\theta}{\theta}}$$

$$\therefore f_z(z) = -e^{-\frac{\theta}{\theta}} \cdot \frac{n}{\theta} = n \cdot e^{-\frac{\theta}{\theta}}$$

$$z \sim E\left(\frac{n}{\theta}\right)$$

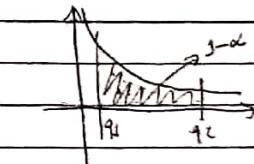
$$X \sim \frac{1}{\lambda} e^{-\frac{x}{\lambda}} E(X) = \lambda$$

$$X_{(1)} \sim n e^{-\frac{\theta}{\theta}} E(X_{(1)}) = \frac{n}{\theta}$$

Desta forma, uma quantidade pivotal é dada por:

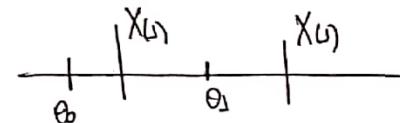
$X_{(1)} - \theta \sim E\left(\frac{n}{\theta}\right)$ que independe de θ .

$$P(q_1 \leq X_{(1)} - \theta \leq q_2) = 1 - \alpha$$



$$P(q_1 - X_{(1)} \leq -\theta \leq q_2 - X_{(1)}) = 1 - \alpha$$

$$\therefore P(X_{(1)} - q_2 \leq -\theta \leq X_{(1)} - q_1) = 1 - \alpha$$



18/11/2010

d) Admita que T é conhecida. Encontre um teste MP de $H: \theta = \theta_0$ contra $K: \theta = \theta_1 (\theta_1 > \theta_0)$ de nível $\alpha \in (0,1)$

for $\theta = \theta_0$ e menor, tem-se que

$$H: \theta = \theta_0 \quad K: \theta = \theta_1 (\theta_1 > \theta_0)$$

$$\Phi(x) = \begin{cases} 1 & \text{quando } p_{\theta}(x) \geq K p_{\theta_1}(x) \\ 0 & \text{quando } p_{\theta}(x) < K p_{\theta_1}(x) \end{cases}$$

$$\therefore E(\Phi(x)) = \alpha$$

Então,

$$p_{\theta}(x) \geq K \cdot p_{\theta_1}(x)$$

$$\frac{1}{n!} \exp \left[-\frac{\theta}{n} \sum_{i=1}^n (x_i - \theta_0) \right] \prod_{i=1}^n I(x_i) \geq K \cdot \frac{1}{n!} \exp \left[-\frac{\theta_1}{n} \sum_{i=1}^n (x_i - \theta_0) \right] \prod_{i=1}^n I(x_i)$$

$$\frac{e^{-\frac{n\theta}{n}}}{(x_1, \dots, x_n)} I(x_1) \geq K \cdot e^{-\frac{n\theta_1}{n}} I(x_1)$$

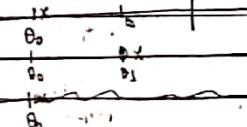
$$\therefore \text{levantando } e^{\frac{n\theta}{n}}, \text{ tem-se:}$$

$$e^{\frac{n\theta}{n}} I(x_1) \geq K \cdot e^{\frac{n\theta_1}{n}} I(x_1)$$

$$I(x_1) \geq I(x_1)$$

$$(x_1, \dots, x_n) \rightarrow (x_1, \dots, x_n)$$

$$\rightarrow X_1 > K$$



Então, um teste mais poderoso por NP para teste $H: \theta = \theta_0$

vs $K: \theta = \theta_1 (\theta_1 > \theta_0)$ é dado por:

$$\Phi(x) = \begin{cases} 1 & \text{quando } X(1) > K \\ 0 & \text{caso contrário} \end{cases}$$

$$\alpha = P_{\theta_0} (X(1) > K) = \int_K^{+\infty} \frac{1}{n!} e^{-\frac{n\theta_0}{n}} \frac{1}{\Gamma(n)} d\theta_0 =$$

$$= n \int_K^{+\infty} e^{-ny} \int_K^{+\infty} e^{-\frac{ny}{n}} dy = n \int_K^{+\infty} e^{-ny} \int_K^{+\infty} e^{-\frac{ny}{n}} dy =$$

$$= e^{\frac{n\theta_0}{n}} \int_K^{+\infty} \left(e^{-\frac{n\theta_0}{n}} \right)^{n-1} d\theta_0 = e^{\frac{n\theta_0}{n}} \int_K^{+\infty} \left(e^{-\frac{n\theta_0}{n}} \right)^{n-1} d\theta_0 =$$

$$= n \ln \alpha = -n(\theta_0 - K) \quad \boxed{K = \theta_0 + \frac{n}{n} \ln \alpha}$$

Portanto, teste alternativo é $X(1) > \theta_0 + \frac{n}{n} \ln \alpha$.

18/11/2010

12. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$. Encontre quantitativas, portanto adequadas e obtenha intervalos de confiança com coeficiente de confiança $1-\alpha$ para μ e para σ^2 .

(Veja Exemplo 4, p. 225 e Exemplo 5, p. 217, TSH)

$$\begin{aligned} p_{\theta}(\mathbf{x}) &= \frac{1}{(\sqrt{2\pi\sigma^2})^n} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right] \\ \theta = (\mu, \sigma^2) &= \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) - \frac{n \log 2\pi\sigma^2}{2} \right\} = \\ &= \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + 2x_i\mu - n\mu^2 - \frac{n \log 2\pi\sigma^2}{2} \right\} \end{aligned}$$

Sendo critério da testagem, tem-se que $T(\mathbf{x}) = (X_1, \dots, X_n)$ não é estatística conjuntamente suficiente para $\theta = (\mu, \sigma^2)$. Além disso, a distribuição pertence à família exponencial de proto completo bimodal, e então a estatística $T(\mathbf{x})$ é suficiente completa e minimal.

Seja \bar{X} um estimador de μ

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_i) = \mu \quad \text{não ruivo} \Rightarrow \text{ENNUVUM p. u.}$$

Seja S^2 um estimador de σ^2

$$\begin{aligned} E(S^2) &= E\left(\frac{1}{n-1} \sum_{i=1}^{n-1} (X_i - \bar{X})^2\right) = E\left(\frac{1}{n-1} \sum_{i=1}^{n-1} X_i^2 - n\bar{X}^2\right) = \\ &= \frac{1}{n-1} \left[n E(X^2) - n \bar{X}^2 \right] = \frac{1}{n-1} \left[n(\sigma^2 + \mu^2) - n(\sigma^2 + \mu^2) \right] = \sigma^2 \\ &\quad \text{não ruivo} \end{aligned}$$

$\Rightarrow \text{ENNUVUM p. u.}$

$$\bar{S}^2 = \frac{1}{n-1} \sum_{i=1}^{n-1} (X_i - \bar{X})^2$$

$$E\left(\frac{1}{n-1} \sum_{i=1}^{n-1} (X_i - \bar{X})^2\right) = \sigma^2$$

$$\boxed{\frac{1}{n-1} \sum_{i=1}^{n-1} (X_i - \bar{X})^2 \sim \chi_{n-1}^2}$$

$$E\left(\frac{1}{n-1} \sum_{i=1}^{n-1} (X_i - \bar{X})^2\right) = \sigma^2$$

i) IC para μ com σ^2 desconhecido

$$X \sim N(\mu, \sigma^2)$$

$$\sum (X_i - \bar{X})^2 \sim \chi^2_{n-1}$$

$$\sigma^2 \sim N(\mu, \sigma^2)$$

$$\bar{X} - \mu \sim N(0, \frac{\sigma^2}{n})$$

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$$

.../...

$$\bar{X} - \mu \sim N(0, 1)$$

$$\sqrt{\frac{\sigma^2}{n}}$$

$$\frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} \sim N(0, 1)$$

\bar{X} e S^2 não independentes | Pelo teorema de Bonf, \bar{X} é estatística suficiente e completa e S^2 é estatística auxiliar

Uma quantidade pivotal não dada por:

$$\frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sqrt{\sigma^2}} = \sqrt{n}(\bar{X} - \mu) \sim N(0, 1)$$

independente de μ

$\frac{\sum (X_i - \bar{X})^2}{\sigma^2} = \frac{\sum (X_i - \bar{X})^2}{\frac{\sigma^2}{n-1}} = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$

$\theta = \sqrt{n}(\bar{X} - \mu) \sim N(0, 1)$

$\theta^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$

$$P\left(-t_{\frac{\alpha}{2}} < \sqrt{n}(\bar{X} - \mu) < t_{\frac{\alpha}{2}}\right) = 1 - \alpha$$

$$P\left(-t_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}} < \sqrt{n}(\bar{X} - \mu) < t_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}\right) = 1 - \alpha$$

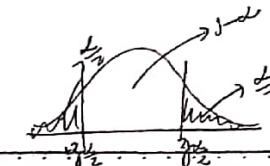
$$P\left(t_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}} < \bar{X} - \mu < t_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}\right) = 1 - \alpha$$

$$P\left(\bar{X} - t_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}} < \mu < \bar{X} + t_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}\right) = 1 - \alpha$$

ii) IC para μ com σ^2 conhecido

$$\theta = \frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} \sim N(0, 1)$$

18/11/2010



$$P\left(-z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} < \bar{X} - \mu < z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$$P\left(\bar{X} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$$P\left(\bar{X} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\frac{1-\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

iii) IC para σ^2 quando μ é conhecido

$$\theta = \frac{\sum (X_i - \mu)^2}{\sigma^2} \sim \chi^2_{n-1}$$

$\theta = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$

$$P\left(q_{\frac{\alpha}{2}} < \frac{\sum (X_i - \mu)^2}{\sigma^2} < q_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

$$P\left(q_{\frac{\alpha}{2}} < \frac{(n-1)S^2}{\sigma^2} < q_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

iv) IC para σ^2 quando μ é desconhecido

$$\theta = \frac{\sum (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2_{n-1}$$

$$P\left(q_{\frac{\alpha}{2}} < \frac{\sum (X_i - \bar{X})^2}{\sigma^2} < q_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

18/11/2016

$$P\left(\frac{1}{q_{1-\alpha}} < \frac{\bar{x}^2}{S^2} < \frac{1}{q_{\alpha}}\right) = 1-\alpha$$

$$P\left(\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{q_{1-\alpha}} < \frac{\bar{x}^2}{S^2} < \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{q_{\alpha}}\right) = 1-\alpha$$

13. Teorema Seja X uma variável ou vetor aleatório cuja distribuição depende de um parâmetro θ desconhecido. Seja $T(X)$ uma estatística a valores reais e, seja $U(X)$ uma estatística a valores reais positivos. Suponha que $(T-\theta)$ seja uma quantidade pivotal com densidade f com hipótese a medida de Lebergue, que é unimodal em $y_0 \in \mathbb{R}$ no sentido de que $f(y)$ é não decrescente para $y \leq y_0$ e não crescente para $y \geq y_0$. Considere a seguinte classe de intervalos de confiança para θ :

$$C = \left\{ [T-b_U, T-a_U] : a \in \mathbb{R}, b \in \mathbb{R}, \int_a^b f(y) dy = 1-\alpha \right\}$$

Se $[T-b_U, T-a_U] \in C$, $f(a_U) = f(b_U) > 0$, e $a_U \leq y_0 \leq b_U$, então o intervalo $[T-b_U, T-a_U]$ tem comprimento mínimo entre todos os intervalos em C .

Suponha X_1, \dots, X_n observações independentes da distribuição $N(\mu, \sigma^2)$ com μ e σ^2 desconhecidos. Considere a seguinte quantidade pivotal:

$$\frac{\sqrt{n}(\bar{X}-\mu)}{S} \text{ onde } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \text{ e } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

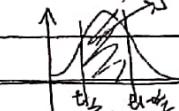
classe C para um valor α encontra um intervalo de confiança para μ com coeficiente de confiança $1-\alpha$ em C com comprimento mínimo.

11

X_1, \dots, X_n r.v.s. $X_i \sim N(\mu, \sigma^2)$ com σ^2 desconhecido

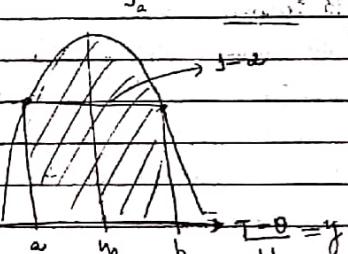
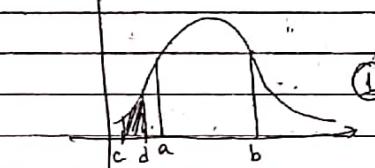
Q quantitade pivotal

$$Q = \frac{\sqrt{n}(\bar{X}-\mu)}{S} = \frac{\bar{X}-\mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$$

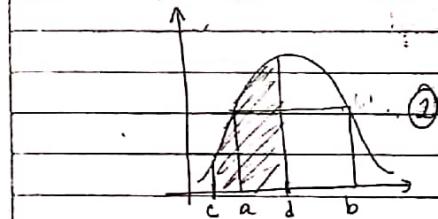


$$C = \left\{ [\bar{X} - b_S^2, \bar{X} - a_S^2] : a \in \mathbb{R}, b \in \mathbb{R}, \int_a^b f(y) dy = 1-\alpha \right\}$$

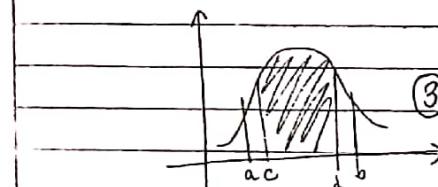
em que f é ftns.
Se $[a,b]$ te dá uma área $1-\alpha$ qualquer
intervalo $[c,d]$ menor que $[a,b]$ te dará uma área menor
 $[c,d]$ tal que $d-c < b-a$



o intervalo mais curto que consegue me dar a área $1-\alpha$.



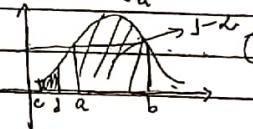
outros outros
intervalos com
essa área
maior de que
menor.



Caso ①

19/11/2020

$$\textcircled{1} \quad \int_c^d f(x) dx \leq f(d)(b-c) \leq f(a)(b-a) \leq \int_a^b f(x) dx = 1-\alpha$$



Caso ②

$$\textcircled{2} \quad \int_c^d f(x) dx = \int_c^a f(x) dx + \int_a^b f(x) dx - \int_d^b f(x) dx < \underbrace{\int_c^a f(x) dx}_{f(a)(a-c)} + \underbrace{(1-\alpha)}_{f(b)(b-d)}$$

$$< f(a)(a-c) + (1-\alpha) - f(b)(b-d) =$$

$$f(a) - f(b) \\ = f(a)(a-c) + (1-\alpha) - f(a)(b-d) =$$

$$= f(a)(a-c-b+d) + (1-\alpha) =$$

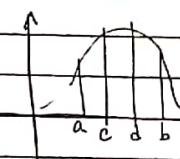
$$= f(a) \underbrace{(d-c-(b-a))}_{<0} + (1-\alpha) =$$

por hipótesis
 $d-c < a-b$

$$< 1-\alpha$$

Caso ③

$$\textcircled{3} \quad \int_c^d f(x) dx < \int_a^b f(x) dx = 1-\alpha$$

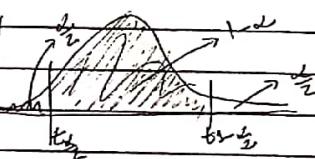


Sempre que a dist for menorada, o intervalo $[a, b]$
máis o maior curto.

1/11/2020

$$C = \left\{ \left[\bar{x} - t_1 \frac{1}{2}, \bar{x} + t_2 \frac{1}{2} \right] : \int_{t_1}^{t_2} f(y) dy = 1-\alpha \right\}$$

un que $f(y) \sim t_{n+2}$



18/11/2010

14. Sejam $f(x)$ duas densidades de probabilidade com respeito a μ . Para testar a hipótese $H: \theta \leq \theta_0$ ou $\theta \geq \theta_1$ ($0 < \theta_0 < \theta_1 < 1$) contra alternativa $\theta_0 < \theta < \theta_1$, na família $\mathcal{P} = \{\theta f(x) + (1-\theta)g(x), 0 \leq \theta \leq 1\}$, o teste $\phi(x) = \alpha$, para todo x , é UMP de nível α .

$$H: \theta \leq \theta_0 \text{ ou } \theta \geq \theta_1 \quad (0 < \theta_0 < \theta_1 < 1) \quad \text{vs. } K: \theta_0 < \theta < \theta_1$$

$$\text{na família } \mathcal{P} = \{\theta f(x) + (1-\theta)g(x), 0 \leq \theta \leq 1\}$$

$\phi(x) = \alpha$ para todo x , $\xrightarrow{\text{quer}} \phi(x) = \alpha$ é teste UMP de nível α .

$$E_{\theta_0}(\phi(x)) = \alpha \rightarrow E_{\theta_0}(\alpha) = \alpha \leq \alpha \quad \forall \theta \in \Lambda_H$$

Outro modo, o teste tem tamanho α .

Além disso,

$$E_{\theta_1}(\phi(x)) = E_{\theta_1}(\alpha) = \alpha$$

o poder do teste é α , e ainda,

$$\beta_\alpha(\phi(x)) = \beta_\alpha(\alpha) = \alpha$$

a função poder é constante, $\forall \theta \in \Lambda_H$.

Siga $\phi^*(x)$ um outro teste cuja $E_{\theta_0}(\phi^*(x)) \leq \alpha$, $\forall \theta \in H$.
Então, se $\theta = 0$

$$E_{\theta=0}(\phi^*(x)) = \int_{\mathbb{R}} \phi^*(x) \cdot [0 \cdot f(x) + (1-0) \cdot g(x)] dx =$$

$$= \int_{\mathbb{R}} \phi^*(x) \cdot g(x) dx \leq \alpha$$

$$\text{Se } \theta = 1 \quad E_{\theta=1}(\phi^*(x)) = \int_{\mathbb{R}} \phi^*(x) \cdot [1 \cdot f(x) + (1-1) \cdot g(x)] dx =$$

$$= \int_{\mathbb{R}} \phi^*(x) \cdot f(x) dx \leq \alpha$$

O poder de ϕ^* para $\theta_0 < \theta < \theta_1$, $\theta \in \Lambda_H$:

$$\beta(\phi^*(x)) = E_{\theta}(\phi^*(x)) = \int_{\mathbb{R}} \phi^*(x) \cdot [\theta f(x) + (1-\theta)g(x)] dx =$$

$$= \theta \int_{\mathbb{R}} \phi^*(x) f(x) dx + (1-\theta) \int_{\mathbb{R}} \phi^*(x) g(x) dx \leq \theta \alpha + (1-\theta) \alpha = \alpha$$

1/1

Então, o poder para qualquer outro teste de nível α é menor ou igual a α ($E_{\theta}(\phi^*(x)) \leq \alpha$, $\forall \theta$ (em especial para $\theta_0 < \theta < \theta_1$)). Como o poder do teste $\phi(x) = \alpha$ é α , tem-se que ele é o teste uniformemente mais poderoso de nível α .

Outra forma:

Negativo	Rapido	Acuado
$0 < \theta_0$	$\theta_0 < \theta < \theta_1$	$\theta_1 < \theta$
$\theta = \pi \theta_A + (1-\pi) \theta_B$	$\pi e(g_1)$	

$$\int_{S^*} \phi^*(\theta f + (1-\theta)g) dx = \int_{S^*} \phi^* [\pi \theta_A f + (1-\pi) \theta_B f + (1 - (\pi \theta_A + (1-\pi) \theta_B)) g] dx$$

S^* : região crítica

$$= \int_{S^*} \phi^* [\underbrace{\pi \theta_A f}_{\text{media ponderada}} + \underbrace{(1-\pi) \theta_B f}_{\text{media ponderada}} + (1 - \pi \theta_A - (1-\pi) \theta_B) g] dx = \int_{S^*} \phi^* [\pi \theta_A f + (1-\pi) \theta_B g] dx +$$

$$+ \int_{S^*} \phi^* [(1-\pi) \theta_B f + (\pi-1) \theta_B g] dx = \pi \int_{S^*} \phi^* [\theta_B f + (1-\theta_B) g] dx +$$

$$+ \int_{S^*} \phi^* (1-\pi) g dx + (1-\pi) \int_{S^*} \phi^* [\theta_B f + (1-\theta_B) g] dx + \int_{S^*} \phi^* (\pi-1) g dx$$

$$\leq \pi \alpha + (1-\pi) \alpha = \pi \alpha + \alpha - \pi \alpha = \alpha$$

Poder $\phi^* \leq \alpha$

Poder $\phi(x) = \alpha \rightarrow \text{UMP } \forall \phi^*$

$$\begin{cases} X_{11}, \dots, X_{1n_1} \\ X_{21}, \dots, X_{2n_2} \end{cases}$$

(18/11/2010)

15. Sejam X_{11}, \dots, X_{1n_1} e X_{21}, \dots, X_{2n_2} observações independentes de distribuições normais de médias μ_1 e variancia σ_1^2 para $i=1,2$, $n_1, n_2 \in \mathbb{N}$, $\sigma_1^2, \sigma_2^2 > 0$.

(a) Obtém o teste da razão de verosimilhanças de H₀: $\mu_1 = \mu_2$ versus $H_1: \mu_1 \neq \mu_2$ de nível de $(0 < \alpha < 1)$ supondo que σ_1^2, σ_2^2 não conhecidos.

$$\text{Sob } H_0: \mu_1 = \mu_2 = \mu$$

$$\begin{aligned} f_{\mu_1=\mu_2}(x) &= \frac{1}{(\sqrt{2\pi\sigma_1^2})^{n_1}} \left[\frac{\sum_{i=1}^{n_1} (x_{1i}-\mu)^2}{2\sigma_1^2} \right] \cdot \frac{1}{(\sqrt{2\pi\sigma_2^2})^{n_2}} \left[\frac{\sum_{i=1}^{n_2} (x_{2i}-\mu)^2}{2\sigma_2^2} \right] = \\ &= \exp \left\{ -\frac{\sum_{i=1}^{n_1} (x_{1i}-\mu)^2}{2\sigma_1^2} - \frac{\sum_{i=1}^{n_2} (x_{2i}-\mu)^2}{2\sigma_2^2} - \frac{n_1 \log 2\pi\sigma_1^2}{2} - \frac{n_2 \log 2\pi\sigma_2^2}{2} \right\} \end{aligned}$$

$$l(\bar{x}, \mu) = -\frac{\sum_{i=1}^{n_1} (x_{1i}-\mu)^2}{2\sigma_1^2} - \frac{\sum_{i=1}^{n_2} (x_{2i}-\mu)^2}{2\sigma_2^2} - n_1 \log 2\pi\sigma_1^2 - n_2 \log 2\pi\sigma_2^2$$

$$\frac{d l(\bar{x}, \mu)}{d\mu} = -\frac{\sum_{i=1}^{n_1} (x_{1i}-\mu)(-1)}{2\sigma_1^2} - \frac{\sum_{i=1}^{n_2} (x_{2i}-\mu)(-1)}{2\sigma_2^2} = 0$$

$$\frac{\sum_{i=1}^{n_1} x_{1i} - n_1 \mu}{\sigma_1^2} + \frac{\sum_{i=1}^{n_2} x_{2i} - n_2 \mu}{\sigma_2^2} = 0$$

$$\sigma_2^2 (\sum_{i=1}^{n_1} x_{1i} - n_1 \mu) + \sigma_1^2 (\sum_{i=1}^{n_2} x_{2i} - n_2 \mu) = 0$$

$$\sigma_2^2 \sum_{i=1}^{n_1} x_{1i} + \sigma_1^2 \sum_{i=1}^{n_2} x_{2i} = \sigma_2^2 n_1 \mu + \sigma_1^2 n_2 \mu$$

$$\hat{\mu} = \frac{\sigma_2^2 \sum_{i=1}^{n_1} x_{1i} + \sigma_1^2 \sum_{i=1}^{n_2} x_{2i}}{\sigma_2^2 n_1 + \sigma_1^2 n_2}$$

$$\hat{\mu} = \frac{n_1 \sigma_2^2 \bar{x}_1 + n_2 \sigma_1^2 \bar{x}_2}{\sigma_2^2 n_1 + \sigma_1^2 n_2}$$

$$\sigma_2^2 n_1 + \sigma_1^2 n_2$$

(18/11/2010)

$$\begin{aligned} &= \exp \left\{ -\frac{1}{2} \left(\frac{n_1 \bar{x}_1^2 + n_2 \bar{x}_2^2}{\sigma_1^2} \right) + \frac{1}{2} \left(\frac{(n_1 \sigma_2^2 \bar{x}_1 + n_2 \sigma_1^2 \bar{x}_2)^2}{\sigma_1^2 \sigma_2^2} \right) - \right. \\ &\quad \left. - \frac{1}{2(n_1 \sigma_2^2 + n_2 \sigma_1^2)} \left[\frac{-\left(\frac{n_1 \bar{x}_1^2 + n_2 \bar{x}_2^2}{\sigma_1^2} \right) (n_1 \sigma_2^2 + n_2 \sigma_1^2)}{\sigma_1^2} + \right. \right. \\ &\quad \left. \left. + \frac{(n_1 \sigma_2^2 \bar{x}_1 + n_2 \sigma_1^2 \bar{x}_2)^2}{\sigma_1^2 \sigma_2^2} \right] \right\} = \\ &= \exp \left\{ -\frac{1}{2(n_1 \sigma_2^2 + n_2 \sigma_1^2)} \left[\frac{-\left(\frac{n_1 \bar{x}_1^2 + n_2 \bar{x}_2^2}{\sigma_1^2} \right) (n_1 \sigma_2^2 + n_2 \sigma_1^2)}{\sigma_1^2} + \right. \right. \\ &\quad \left. \left. + \frac{(n_1 \sigma_2^2 \bar{x}_1 + n_2 \sigma_1^2 \bar{x}_2)^2}{\sigma_1^2 \sigma_2^2} \right] \right\} \\ &= \exp \left\{ -\frac{1}{2(n_1 \sigma_2^2 + n_2 \sigma_1^2)} \left[\frac{-n_1^2 \bar{x}_1^2 \sigma_1^2 - n_1 n_2 \bar{x}_1 \bar{x}_2 \sigma_1^2 \sigma_2^2 - n_2 n_1 \bar{x}_2 \bar{x}_1 \sigma_1^2 \sigma_2^2 - n_2^2 \bar{x}_2^2 \sigma_2^2}{\sigma_1^2 \sigma_2^2} + \right. \right. \\ &\quad \left. \left. + \frac{n_1^2 \sigma_2^4 \bar{x}_1^2 + 2 n_1 n_2 \bar{x}_1 \bar{x}_2 \sigma_1^2 \sigma_2^2 + n_2^2 \sigma_1^4 \bar{x}_2^2}{\sigma_1^2 \sigma_2^2} \right] \right\} \\ &= \exp \left\{ -\frac{1}{2(n_1 \sigma_2^2 + n_2 \sigma_1^2)} [\bar{x}_1^2 - 2\bar{x}_1 \bar{x}_2 + \bar{x}_2^2] \right\} = \\ &= \exp \left\{ -\frac{1}{2(n_1 \sigma_2^2 + n_2 \sigma_1^2)} (\bar{x}_1 - \bar{x}_2)^2 \right\} \leq c \\ \lambda(x_1, x_2) &= \exp \left\{ -\frac{1}{2(n_1 \sigma_2^2 + n_2 \sigma_1^2)} (\bar{x}_1 - \bar{x}_2)^2 \right\} \leq c \end{aligned}$$

Então $\lambda(x_1, x_2)$ é uma função decrescente em $|\bar{x}_1 - \bar{x}_2|$

então $\lambda(x_1, x_2) \leq c \iff |\bar{x}_1 - \bar{x}_2| > c'$

Portanto, o teste da razão de verosimilhanças para teste $H_0: \mu_1 = \mu_2$ vs $H_1: \mu_1 \neq \mu_2$ rejeita H_0 se e somente se

$$\mu_1 = \mu_2 \Leftrightarrow \mu_1 - \mu_2 = 0$$

18/11/2010

$|\bar{X}_1 - \bar{X}_2| > c'$, ou seja $\bar{X}_1 - \bar{X}_2 < -c'$ ou $\bar{X}_1 - \bar{X}_2 > c'$

$$\alpha = P_{H_0}(|\bar{X}_1 - \bar{X}_2| > c')$$

Determinando c'

$$Sob H_0: \mu_1 = \mu_2 = \mu$$

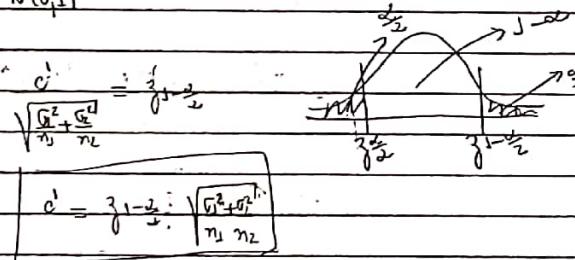
$$\bar{X}_1 \sim N(\mu, \frac{\sigma^2}{n_1})$$

$$\bar{X}_2 \sim N(\mu, \frac{\sigma^2}{n_2})$$

$$\bar{X}_1 - \bar{X}_2 \sim N(0, \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}) \rightarrow \bar{X}_1 - \bar{X}_2 \sim N(0, 1)$$

$$\alpha = P_{H_0}(|\bar{X}_1 - \bar{X}_2| > c) = P_{H_0}\left(|Z| > \frac{c}{\sqrt{\frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}}}\right)$$

$$\text{com } Z \sim N(0, 1)$$



$$c' = z_{1-\alpha/2} \cdot \sqrt{\frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}}$$

21/11/2010

1) Seja X_1, X_n uma amostra aleatória da distribuição exponencial descrevendo uma função densidade de probabilidade:

$$f(x; \theta, T) = \frac{1}{T} \exp\left(-\frac{x-\theta}{T}\right); -\infty < \theta < \infty, T > 0$$

a) Admita que θ é conhecido. Encontre um teste UMP de $H: T \leq T_0$ contra $K: T > T_0$ de nível $\alpha \in (0, 1)$. θ conhecido.

$$\eta(T) = \left(\frac{1}{T}\right)^n \exp\left[-\sum_{i=1}^n \frac{(x_i - \theta)}{T}\right] =$$

$$= \exp\left[-\frac{1}{T} \sum_{i=1}^n (x_i - \theta)\right] = -n \log \frac{T}{\eta(T)}$$

$$\eta'(T) = -\frac{1}{T} \eta(T) = \frac{1}{T^2} > 0 \quad b(T) = -n\theta + n \log T$$

Como a distribuição pertence a família exponencial, $\eta'(T) = 1$.

a) $\eta(T) = -\frac{1}{T}$ é monotona crescente, existe um teste UMP

$$\rho(X) = \begin{cases} 1 & \text{se } T(X) \geq k \\ 0 & \text{caso contrário} \end{cases}$$

$$\alpha = P_{H_0}(T(X) \geq k)$$

$$X_i - \theta \sim E(\theta)$$

$$\xi(X_i - \theta) \sim G(n, \theta)$$

$$\sum \xi(X_i - \theta) \sim \chi_{2n}^2 \sim \text{Gamma}(n, 2)$$

21/11/2010

$$E(X) = \sum_{x=0}^{+\infty} x \cdot \theta^x \cdot (1-\theta) = \theta(1-\theta) \sum_{x=0}^{+\infty} x \cdot \theta^{x-1}$$

$$= \theta(1-\theta) \cdot \sum_{x=0}^{+\infty} \frac{d\theta^x}{d\theta} = \theta(1-\theta) \frac{d}{d\theta} \sum_{x=0}^{+\infty} \theta^x \quad \text{por derivação}$$

$$= \theta(1-\theta) \cdot \frac{d}{d\theta} \frac{1}{1-\theta} = \theta(1-\theta) \frac{\theta}{(1-\theta)^2} = \theta$$

$$E(X) = \frac{\theta}{1-\theta} \quad \theta = X$$

$$\theta = X - \theta X$$

$$\theta + \theta X = X$$

$$\boxed{\begin{array}{l} \theta = X \\ 1 + X \end{array}}$$

$$E(\theta) = \theta$$

$$\sum_{x=0}^{+\infty} s(x) \cdot \theta^x \cdot (1-\theta) = \theta$$

$f(x)$ é família exponencial
de proto-completo $\Rightarrow x$ é int.
não iniciado e função
do est. para comp. $T(x) = x$

$$\sum_{x=0}^{+\infty} s(x) \cdot \theta^x = \theta$$

$$s(0) + \sum_{x=1}^{+\infty} s(x) \cdot \theta^x = \theta$$

$s(1) = 1 \quad x=1, 2, \dots$
 θ não iniciado e função
do est. para comp. $T(x) = x$

$$\theta \sim U(0,1) \quad f(\theta) = 1 \quad T(\theta)$$

$$f(\theta|x) \propto 1 \cdot \theta^x \cdot (1-\theta) \quad I_{(0,1)}(x) \quad \text{Dv Beta}(x+1, 2)$$

Sub $s(x) = E(\theta|x) = \frac{x}{x+1}$
uma quantida

SÁO DOMINGOS

11

$0 < x < \theta$
 $0 < \theta < 1$

$$f(\theta|x) \propto \frac{2x}{\theta^2} \cdot I_{(0,1)}(x) \cdot I_{(0,1)}(\theta) = \frac{2x}{\theta^2} \cdot I(x)$$

$$\int_0^1 c \frac{2x}{\theta^2} d\theta = 1$$

$$2x \cdot \int_0^1 \frac{1}{\theta^2} d\theta = 1$$

$$2x \cdot \left. \frac{\theta^{-1}}{-1} \right|_0^1 = 1$$

$$2x \cdot \left. -1 \right|_0^1 = 1$$

$$2x \cdot \left(-1 + 1 \right) = 1$$

$$c \left(-2x + \frac{2x}{x} \right) = 1$$

$$c = \frac{1}{-2x+2}$$

$$f(\theta|x) = \frac{dx}{d\theta} \cdot \frac{1}{\theta^2} \cdot I_{(0,1)}(\theta) = \frac{x}{1-x} \cdot \frac{1}{\theta^2} \cdot I_{(0,1)}(\theta)$$

$$s_\Delta(x) = \frac{E(w(\theta) g(\theta|x))}{E(w(\theta))}$$

$$E(\theta^2|\theta|x) = E(\theta^3|x) = \int_x^1 \theta^2 \cdot \frac{1}{\theta^2} \cdot \frac{x}{1-x} d\theta =$$

$$= \frac{x}{1-x} \cdot \frac{\theta^2}{2} \Big|_x^1 = \frac{x}{1-x} \cdot \frac{1-x^2}{2} = \frac{x}{1-x} \cdot \frac{(1-x)(x)}{2} = \frac{x(1-x)}{2}$$

$$E(\theta^2 | X) = \int_x^{\infty} \theta^2 \cdot x \cdot \frac{1}{\theta^2} d\theta = x \cdot (2x) = x$$

$$S_{\theta}(x) = \frac{x(3x)}{2} = \frac{(x+1)}{2}$$

Admita que, dado θ , X_1, \dots, X_n sejam iid e tenham distribuição de potência com função densidade de probabilidade

$$f(x; \theta) = \theta \cdot x^{\theta-1} I_{(0,1)}(x); \theta > 0$$

Suponha que, a priori, θ tem distribuição exponencial de parâmetro τ e função densidade de probabilidade $p(\theta) = \tau! \exp(-\theta\tau) I_{(0,+\infty)}$, sendo $\tau > 0$ conhecido. Encontre o estimador de Bayes de θ sob perda quadrática.

$$p(x|\theta) = \theta^n \cdot \left(\prod_{i=1}^n x_i \right)^{\theta-1} I_{(0,1)}(x)$$

$$\begin{aligned} f(\theta|x) &\propto p(x|\theta) \cdot p(\theta) \\ &\propto \theta^n \cdot \left(\prod_{i=1}^n x_i \right)^{\theta-1} \cdot \tau \cdot e^{-\theta\tau} \cdot \exp\{\tau \log \theta + (\theta-1) \sum \log x_i\} \cdot e^{-\theta} \\ &\propto \theta^n \cdot e^{(\theta-1)\log \tau x_i} \cdot e^{-\theta\tau} \cdot \exp\{-\theta\tau + (\theta-1) \sum \log x_i\} \\ &\propto \theta^n \cdot e^{\theta \log \tau x_i} \cdot e^{-\theta\tau} \\ &\propto \theta^n \cdot e^{-\theta(\log \tau x_i + \tau)} \sim \text{Gamma}(n+1, -\frac{1}{\log \tau x_i}) \end{aligned}$$

O estimador de Bayes sob perda quadrática é o dado por

$$E(\hat{\theta} | X=x) = \frac{n+1}{1 - \frac{n}{x} \log x_i}$$

$$\begin{aligned} f(x|z) &= \frac{1}{(\frac{1}{2\pi z^2})^n} \sup \left\{ \frac{-\sum x_i^2}{2z^2} \right\} = \\ &= \frac{1}{(\sqrt{\frac{1}{2}})^n} \sup \left\{ -\frac{\sum x_i^2}{z} \right\} = \\ &= \left(\frac{1}{\pi} \right)^{\frac{n}{2}} \sup \left\{ -\theta \sum x_i^2 \right\} \end{aligned}$$

$$f(\theta|z) \propto \frac{\theta^{\frac{n}{2}}}{\pi^{\frac{n}{2}}} e^{-\theta \sum x_i^2} \cdot 1 \cdot \theta^{a-1} \cdot e^{-\frac{\theta}{b}}$$

$$\propto \theta^{\left(\frac{n}{2}+a\right)-1} e^{-\theta \left[\sum x_i^2 + b\right]} = \theta^{\left(\frac{n}{2}+a\right)-1} e^{-\theta \left[\frac{\sum x_i^2 + b}{b}\right]}$$

$$f(\theta|z) \sim \text{Gamma} \left(\frac{n}{2} + a, \frac{b}{\sum x_i^2 + b} \right)$$

$$g(\theta) = \frac{\theta^2}{2a} = \frac{1}{2a}$$

$$L(\theta, d) = \left(\frac{d}{\theta} - 1 \right)^2 = \left(\frac{d}{2a} - 1 \right)^2 =$$

$$L(\theta, d) = (2ad - 1)^2 = 4a^2 \left(\frac{d-1}{2a} \right)^2$$

$$E\left(\frac{1}{\theta^2} \mid X=x\right) = E\left(\frac{1}{\theta} \mid X=x\right) =$$

$$= \int_0^{+\infty} \frac{2a}{\theta} \cdot \frac{1}{\theta^{\left(\frac{n}{2}+a\right)}} \cdot \left(\frac{b}{\sum x_i^2 + b} \right)^{\frac{n}{2}+a} = 2 \left(\frac{a+n}{2} \right) \left(\frac{-b}{\sum x_i^2 + b} \right)$$

$$S_{\Delta_{b_k}}(x) = \frac{\sum x_i^2}{b_k^2 + n + 2} + \frac{1}{b_k^2 \left(\frac{n+2}{b_k^2} \right)}$$

11

Sig. de minimos dado por:

$$\text{Gauss} \left(\frac{1}{b_k}, b_k \right) \quad \Delta b_k, \quad b_k \rightarrow +\infty \quad x \rightarrow +\infty$$

A sig. de menor dano gerais não depende do dado é definida por:

$$n_{b_k} = R \left(L \left(\sigma^2, S_{\Delta_{b_k}}(x) \right) \right) = F \left(L \left(\sigma^2 G(x) \right) \right) = E \left(\left(\frac{S(x)}{\sigma^2} - 1 \right)^2 \right)$$

$$= E \left[\left(\frac{b_k^2 \sum x_i^2 + 1}{b_k^2 \left(\frac{n+2}{b_k^2} \right) - 1} \right)^2 \right] = E \left[\left(\frac{(b_k^2 \sum x_i^2 + 1)}{b_k^2 G^2 \left(\frac{n+2}{b_k^2} \right)} - 1 \right)^2 \right] =$$

$$= 1 \cdot \frac{(n+2)}{b_k^2 \sigma^2} + 2 \cdot \frac{n+1}{b_k^2 \sigma^2} - \frac{2n}{b_k^2 \sigma^2} -$$

$$\frac{(2+n+2)^2}{b_k^2} \cdot G^4 b_k^4 \left(\frac{n+2}{b_k^2} \right)^2 - \frac{(n+2)^2}{b_k^2}$$

$$\sigma^2 b_k^2 \left(\frac{n+2}{b_k^2} \right)^2$$

$$n = \lim_{n \rightarrow \infty} n_{b_k} = 2 - 1$$

11

Seja X uma variável acrítica aleatória com distribuição pertencente a $P = \{P_0, P_1\}$ e sejam p_0 e p_1 as densidades de probabilidade para P_0 e P_1 , respectivamente. Suponha que $\phi(x)$ é a função crítica do teste mais poderoso (MP) de $H: P_0$ contra $K: P_1$ de nível α ($G(\phi)$) e que $\beta < 1$. Mostre que $1 - \phi(x)$ é a função crítica de um teste MP de $H: P_1$ contra $K': P_0$ de nível $1 - \beta$.

X r.c. $X \sim P_0$ ou $X \sim P_1$ $P = \{P_0, P_1\}$

$$H: P_0 \quad \text{vs} \quad K: P_1 \quad \phi(x) = \begin{cases} 1 & \text{se } p_1 > k_{p_0} \\ 0 & \text{se } p_1 \leq k_{p_0} \end{cases}$$

$$\alpha = E_{P_0}(\phi(X)) = P_0 \left(\frac{p_1}{p_0} > k \right) \quad \beta < \alpha$$

$$\beta = E_{P_1}(1 - \phi(X)) < 1$$

$$H': P_1 \quad \text{vs} \quad K': P_0$$

$$\text{NP} \quad \phi'(x) = \begin{cases} 1 & \text{se } p_0 > k'_{p_1} \\ 0 & \text{se } p_0 \leq k'_{p_1} \end{cases}$$

$$\alpha = E_{P_1}(\phi'(X)) = P_1 \left(\frac{p_0}{p_1} > k' \right) = 1 - P_0 \left(\frac{p_0}{p_1} < k' \right)$$

$$\phi'(x) = \begin{cases} 1 & \text{se } p_0 > k'_{p_1} \\ 0 & \text{se } p_0 \leq k'_{p_1} \end{cases} \iff$$

$$\begin{cases} 1 & \text{se } p_0 > k'_{p_1} \\ 0 & \text{se } p_0 \leq k'_{p_1} \end{cases}$$

$$\begin{cases} 1 & \text{se } p_0 > k'_{p_1} \\ 0 & \text{se } p_0 \leq k'_{p_1} \end{cases} \iff \begin{cases} 1 & \text{se } p_0 > k'_{p_1} \\ 1 & \text{se } p_0 \leq k'_{p_1} \end{cases}$$

$$1 - \phi(x) \quad E_{P_0}(1 - \phi(X)) = 1 - \alpha$$

$$\beta > \alpha$$

$$-\beta < -\alpha$$

$$1 - \beta < 1 - \alpha$$

$$E_\theta(\Phi(x)) = E_\theta(1 - \Phi(x)) = 1 - \alpha > 1 - \beta$$

$$\alpha^* > \underline{1 - \beta}$$

III

$$r(\gamma, s) = E_\theta [R(\theta, s)] = E_\theta [E(L(\theta, s))] =$$

$$= \int_0^1 \left[\int_{\mathbb{R}} L(\theta, s) f(x|\theta) dx \right] r(\theta) d\theta =$$

$$= \int_0^1 \left[\sum_{x=0}^n (\delta(x) - \theta)^2 \binom{n}{x} \theta^x (1-\theta)^{n-x} \right] \theta^{-1} (1-\theta)^{-1} d\theta =$$

$$= \sum_{x=0}^n \left[\int_0^1 (\delta(x) - \theta)^2 r(n) \theta^{x-1} (1-\theta)^{n-x-1} d\theta \right] q(x) dx$$

$$E_\theta [(\delta(x) - \theta)^2 | X=x] =$$

$$= E_\theta [\delta^2(x) - 2\delta(x)\theta + \theta^2 | X=x] =$$

$$= \delta^2(x) - 2\delta(x) \cdot E_\theta[\theta | X=x] + E_\theta[\theta^2 | X=x]$$

Para que $\delta(x)$ sea máximos devemos tener:

$$\partial \delta(x) / \partial E_\theta[\theta | X=x] = 0$$

$$\delta(x) = E_\theta[\theta | X=x] = \tilde{x}$$

11

1. Sejam X_1, X_n variáveis aleatórias independentes tais que X_i tem distribuição exponencial de média $\lambda \beta^i$, $\lambda > 0$, $\beta > 0$, supondo que β é conhecido.

a) Encontre um limite inferior de confiança uniformemente mais acurado para λ com coeficiente de confiança $1-\alpha$.

$$\eta_1(\lambda) = \frac{1}{\lambda^n \prod_{i=1}^n \beta^i} e^{-\sum_{i=1}^n \frac{\lambda}{\lambda \beta^i}}$$

$$\lambda_1 > \lambda_0 \\ p_{\lambda_1}(x) = \frac{1}{\lambda_1^n \prod_{i=1}^n \beta^i} e^{-\sum_{i=1}^n \frac{x_i}{\lambda_1 \beta^i}} = \left(\frac{\lambda_0}{\lambda_1} \right)^n \exp \left(-\sum_{i=1}^n \frac{x_i}{\lambda_1} \left(1 - \frac{1}{\lambda_1 \beta^i} \right) \right)$$

$$\eta_2(\lambda) = \exp \left\{ -\frac{1}{\lambda} \sum_{i=1}^n x_i - n \log \lambda \right\}$$

$$\eta'(\lambda) = -\frac{1}{\lambda^2} + \frac{n}{\lambda} \text{ crescente} \quad b(\lambda) = n \log \lambda - h(\lambda) \text{ crescente}$$

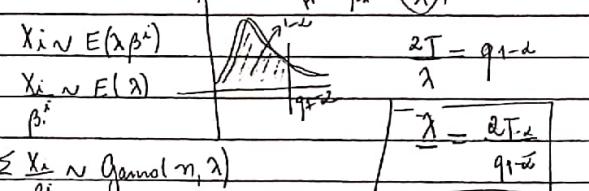
a) A distribuição pertence à família exponencial semiparamétrica
Como $\eta'(\lambda) = -\frac{1}{\lambda^2} + \frac{n}{\lambda}$ é função monótona crescente, cumpre a prop.

de razão de verossimilhança, i.e., um limite superior de confiança novo dado por:

$$P_0(T \leq t) = 1-\alpha$$

$$P_0 \left(\sum_{i=1}^n X_i \leq t \right) = 1-\alpha$$

$$P_0 \left(\sum_{i=1}^n X_i \leq 2t \right) = 1-\alpha$$



$$\frac{2}{\lambda} \sum_{i=1}^n X_i \sim \text{Gamma}(n, 2) \sim \chi_{2n}^2$$

NÃO DOMINADA

11

b) Mostre que $\sum_{i=1}^n X_i$ é uma quantidade pivotal

$$\lambda \beta^i$$

$$X_i \sim E(\lambda \beta^i)$$

$$X_i \sim F(\lambda)$$

$$\beta^i$$

$$X_i \sim F(\lambda)$$

$$\beta^i$$

$$X_i \sim E(1)$$

$$\lambda \beta^i$$

$$\sum_{i=1}^n X_i \sim \text{Gamma}(n, 1)$$

$\lambda \beta^i$ independente de λ

Portanto, é uma quantidade pivotal

c) Construa um intervalo de confiança para o coeficiente de confiança \bar{T} baseado na quantidade pivotal de (b)

$$\sum_{i=1}^n X_i \sim \text{Gamma}(n, 1)$$

$$\lambda \beta^i$$

$$2 \leq \sum_{i=1}^n X_i \sim \text{Gamma}(n, 2) \sim \chi_{2n}^2$$



$$P \left(\frac{2}{\lambda} \sum_{i=1}^n X_i \leq 2T \right) = \bar{\alpha}$$

$$P \left(\frac{q_1}{2 \sum_{i=1}^n X_i} \leq \frac{1}{\lambda} \leq \frac{q_2}{2 \sum_{i=1}^n X_i} \right) = \bar{\alpha}$$

$$P \left(\frac{2 \sum_{i=1}^n X_i}{\lambda} \leq \lambda \leq \frac{2 \sum_{i=1}^n X_i}{q_2} \right) = \bar{\alpha}$$

22/11/2020

2. Sejam X_1, \dots, X_n a.a. do domínio de
 $p_\theta(x) = \theta x^{\theta-1}, 0 < x < 1, \theta > 0$

a) Obtenha um teste UMP de $H_0: \theta \leq \theta_0$ ($\theta_0 > 0$) vs $H_1: \theta > \theta_0$ de nível α .

$$\theta_1 > \theta_0$$

$$\frac{p_\theta(x)}{p_{\theta_0}(x)} = \frac{\theta_1^n (\prod_{i=1}^n x_i)^{\theta_1-1}}{\theta_0^n (\prod_{i=1}^n x_i)^{\theta_0-1}} = \sup \left\{ \log \left[\theta_1^n (\prod_{i=1}^n x_i)^{\theta_1-1} \right] \right\} - \sup \left\{ \log \left[\theta_0^n (\prod_{i=1}^n x_i)^{\theta_0-1} \right] \right\}$$

$$= \sup \left\{ \log \left(\frac{\theta_1}{\theta_0} \right)^n + \log (\prod_{i=1}^n x_i)^{\theta_1-1} - \log (\prod_{i=1}^n x_i)^{\theta_0-1} \right\} = \dots$$

$$= \sup \left\{ \log \left(\frac{\theta_1}{\theta_0} \right)^n + \theta_1 \sum \log x_i + \sum \log x_i - \theta_0 \sum \log x_i + \sum \log x_i \right\}$$

$$= \sup \left\{ \log \left(\frac{\theta_1}{\theta_0} \right)^n + (\theta_1 - \theta_0) \sum \log x_i \right\}$$

$$\frac{\partial}{\partial \theta_1} = \left(\frac{\theta_1}{\theta_0} \right)^{n-1} - \left(\frac{\theta_1}{\theta_0} \right)^n x > 0 \quad T(X) = X \text{ crescente} \quad \theta_1 - \theta_0 = 2$$

$$\text{an } f(x) = \theta x^{\theta-1} = \sup \{ (\theta-1) \ln x + \ln \theta \}$$

$$\eta(\theta) = \theta - 1 \Rightarrow \eta'(\theta) = 1 \text{ crescente}$$

Dai, um t.o.t. η s.t. $H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$ é dado por

$$\eta(X) = \begin{cases} 1 & \text{se } -\sum \ln x_i > C \\ 0 & \text{se } -\sum \ln x_i < C \end{cases}$$

$$X \sim \eta(\theta) = \theta \cdot x^{\theta-1}$$

$$Y = -\sum \ln x_i \sim ?$$

$$P(Y \leq y) = P(-\sum \ln x_i \leq y) = P(\sum \ln x_i \geq -y) =$$

$$= \int_{e^{-y}}^1 \theta a^{\theta-1} da = \theta \left[\frac{a^{\theta}}{\theta} \right]_{e^{-y}}^1 = 1 - e^{-y} \Rightarrow f_Y(y) = -e^{-y} \cdot \theta = \theta e^{-y}$$

$$Y \sim E\left(\frac{1}{\theta}\right)$$

22/11/2020

$$Y \sim E\left(\frac{1}{\theta}\right)$$

$$Y \sim \text{Gamma}\left(1, \frac{1}{\theta}\right)$$

$$\sum Y \sim \text{Gamma}\left(n, \frac{1}{\theta}\right)$$

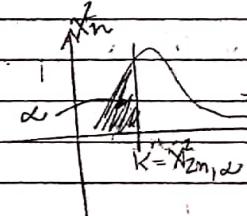
$$\Rightarrow \sum Y \sim \text{Gamma}\left(n, 2\right) \sim \chi^2_{2n}$$

$$\alpha = P_{\theta_0}(\sum \ln x_i > k) =$$

$$= P(-2\theta_0 \leq \sum \ln x_i \leq 2\theta_0)$$

$$2\theta_0 = q_{\alpha}$$

$$C = \frac{q_{\alpha}}{2\theta_0}$$



Rejeita-se H_0 se $-2\theta_0 \leq \sum \ln x_i \leq 2\theta_0$
 $\sum \ln x_i \geq \chi^2_{2n, alpha} \Rightarrow \sum \ln x_i \geq \chi^2_{2n, alpha}$

b) Obtenha um teste UMP de $H_0: \theta \leq \theta_0$ ($\theta_0 > 0$) versus
 $H_1: \theta > \theta_0$ de nível α .

O t.o.t. é o mesmo que é dado anteriormente com as desigualdades invertidas:

$$\text{Rejeita-se } H_0 \text{ se } \sum \ln x_i \leq -\frac{\chi^2_{2n, alpha}}{2\theta_0}$$

c) Encontre um limite inferior de confiança mais acurado com coeficiente de confiança $1-\alpha$.

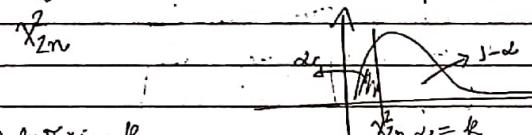
$$\text{R.V.M. } P(T \leq t) = 1-\alpha \quad P(\sum \ln x_i \leq t) = 1-\alpha$$

crescente

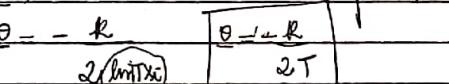
21/01/2010

$$P(-\ln \pi(x) \leq \ln \pi(x)) = 1-\alpha$$

$$P(-2\theta \ln \pi(x) > -2\theta \ln \pi(x)) = 1-\alpha \quad \text{que queremos}$$



$$-2\theta \ln \pi(x) = k$$



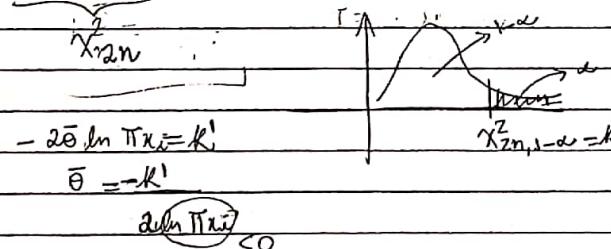
a) Encontre um limite superior de confiança, para qualquer α , com coeficiente de confiança $1-\alpha$.

$$F_\theta(t) = \alpha$$

$$P(T \leq -t) = \alpha$$

$$P(-\ln \pi(x_i) \leq \ln \pi(x)) = \alpha$$

$$P_0(-2\theta \ln \pi(x_i) > -2\theta \ln \pi(x)) = \alpha$$



$$-2\theta \ln \pi(x) = k'$$

$$\theta = -k'$$

$$2\ln \pi(x)$$

$$f_\theta(x) = \frac{1}{(2\theta)^n} \cdot \frac{\prod_{i=1}^n \pi(x_i)}{I_{(-\theta, \theta)}} = \frac{1}{(2\theta)^n} \cdot \frac{\prod_{i=1}^n \pi(x_i)}{I_{(0, \theta)}} = \frac{1}{(2\theta)^n} \cdot \frac{\prod_{i=1}^n \pi(x_i)}{I_{(0, \theta)}} \quad 0 < |x_i| < \theta$$

1 / 1

3. Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes com distribuição $U(\theta, \theta)$, $\theta > 0$.

a) Mostre que o teste ϕ tal que $\phi(X) = 1$, se $\max(|X_1|, \dots, |X_n|) > \theta_0$ e $\phi(X) = 0$, é contínuo, é uniformemente mais poderoso de nível α para testar $H: \theta = \theta_0$ contra $K: \theta > \theta_0$.

Mostre que o teste

$$\phi = \begin{cases} 1 & \text{se } \max(|X_1|, \dots, |X_n|) > \theta_0 \\ 0 & \text{caso contrário} \end{cases}$$

é UMP para detectar $H: \theta = \theta_0$ vs $K: \theta > \theta_0$.

$$\phi(X) = \begin{cases} 1 & \text{se } \max(|X_1|, \dots, |X_n|) > \theta_0 \\ 0 & \text{se } \max(|X_1|, \dots, |X_n|) \leq \theta_0 \end{cases}$$

$$\alpha = E_\theta(\phi(X))$$

$$= X_i \sim U(-\theta, \theta)$$

$$= |y| \sim ?$$

$$P(y \leq z) = P(|X_i| \leq z) = P(-z \leq X_i \leq z) =$$

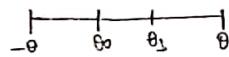
$$= \int_{-z}^z \frac{1}{2\theta} da = \frac{z+z}{2\theta} = \frac{z}{\theta}$$

$$f_y(y) = \frac{1}{\theta} I_{(0, \theta)}(y)$$

$$z = y_m$$

$$P(z \leq z) = P(y_m \leq z) = P(y_1 \leq z, y_2 \leq z, \dots, y_n \leq z) =$$

$$= [P(y_1 \leq z)]^n = \left[\int_0^z \frac{1}{\theta} da \right]^n = \left[\frac{z}{\theta} \right]^n$$



11

$$f_Z(z) = n z^{n-1} \frac{I(z)}{(q_{\theta})}$$

$$E_{\theta_0}(\phi(x)) = 1 \cdot P_{H_0}(z > \theta_0) + \alpha \cdot P_{H_1}(z \leq \theta_0) =$$

$$= \alpha \cdot P(Y_{(n)} < \theta_0) = \alpha \cdot \left[\int_0^{\theta_0} \frac{1}{\theta_0} dz \right] = \alpha \cdot \frac{\theta_0}{\theta_0} = \alpha$$

Q tamando do teste é α .

$$E_{\theta_1}(\phi(x)) = 1 \cdot P_{H_1}(z > \theta_0) + \alpha \cdot P_{H_1}(z \leq \theta_0) =$$

$$= \int_{\theta_1}^{\theta} \frac{1}{\theta_1} dz + \alpha \cdot \int_0^{\theta_0} \frac{1}{\theta_1} dz = \frac{\theta - \theta_1}{\theta_1} + \alpha \cdot \frac{\theta_0}{\theta_1} =$$

$$= \theta + (\alpha - 1) \theta_0$$

01

Outro modo: P_{H_0} NP:

$$\text{H}_0: \theta = \theta_0 \quad \text{vs} \quad \text{H}_1: \theta = \theta_1 \quad (\theta > \theta_0)$$

$$\phi(x) = \begin{cases} 1 & \mu, \quad p_1(x) > k \cdot p_0(x) \\ 0 & \mu, \quad p_1(x) \leq k \cdot p_0(x) \end{cases} \quad \alpha = F_{\theta_0}(\phi(x))$$

$$p_1(x) > k \cdot p_0(x)$$

$$\frac{1}{(2\theta_1)^n} I_{(0,\theta_1)}(|X|_{(n)}) > \frac{k \cdot 1}{(2\theta_0)^n} I_{(0,\theta_0)}(|X|_{(n)})$$

$$\left(\frac{\theta_0}{\theta_1}\right)^n \frac{I_{(0,\theta_1)}(|X|_{(n)})}{I_{(0,\theta_0)}(|X|_{(n)})} > k \quad \text{ou} \quad \left(\frac{\theta_0}{\theta_1}\right)^n \frac{I_{(0,\theta_1)}(|X|_{(n)})}{I_{(0,\theta_0)}(|X|_{(n)})} > \left(\frac{\theta_0}{\theta_1}\right)^n$$

$$\left(\frac{\theta_0}{\theta_1}\right)^n > k \quad \text{ou} \quad |X|_{(n)} > \theta_0$$

$$I_{(0,\theta_1)}(|X|_{(n)}) > I_{(0,\theta_0)}(|X|_{(n)})$$

$$\left(\frac{\theta_0}{\theta_1}\right)^n < 1$$

1:1:1

$$|X|_{(n)} > \theta_0$$

$$\inf_{\delta} \sup_{\theta} R(\theta, \delta) = \sup_{\theta} R(\theta, \delta^M)$$

$$R(\delta, \theta) = \int L(f(x|\theta)) dx$$

0 //

$$E_{\theta_0}(\phi(x)) = \alpha = 1 \cdot P(x^* > \theta_0) + 0 \cdot P(x^* \in [0, \theta_0]) = \pi_1 = \pi$$

$\boxed{\delta=1}$

δ^* r-minimax

$$\inf_{\delta} \sup_{\theta \in \Theta} r(\Delta, \delta) = \sup_{\theta \in \Theta} r(\Delta, \delta^*)$$

prior - π
a priori

$\Gamma = \{$ conjunto de prioris (normal, beta, uniforme, poisson, ...)

$$\delta^* = \bar{x}$$

risco de Bayes sobre um estimador qualquer δ^*

$$r(\delta^*, \Pi) = \int_{\Theta} \int_{\mathcal{X}} L(\delta^*, \theta) f(x|\theta) dx \underbrace{\pi(\theta)}_{\Theta} d\theta$$

após cada estimador calcula-se riscos para cada priori

EST	Risco Bayes Max(Sup)
δ_1	5
δ_2	7
δ_3	(4) menor risco de Bayes

a) $\Gamma = \{ \Delta^* \}$

sobre uma mesma priori, calcula-se o risco

metáfora: todos os estimadores, o estimador de Bayes é aquele que não minimiza o risco de Bayes

Dado Δ^* , o estimador de Bayes δ^B minimiza $r(\delta^B, \Delta^*)$

Logo, $\inf_{\delta} \sup_{\theta} r(\Delta^*, \delta) = r(\Delta^*, \delta^B) = \sup_{\theta} r(\Delta^*, \delta^B)$

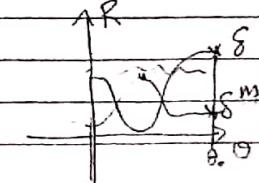
é um risco

b) $\Gamma = \{$ Todos os prioris sobre $\mathcal{X}\}$

$$\delta^M = \delta^*$$

$$\delta \neq \delta^M \Rightarrow \exists \theta_0 \in \Theta \text{ s.t. t.d. que}$$

$$R(\theta_0, \delta) < R(\theta_0, \delta^M)$$



23/11/2019

Siga a opinião $\pi(\theta) = \begin{cases} 1 & \text{se } \theta = \theta_0 \\ 0 & \text{c.c.} \end{cases}$ (colocar como priori que coloca todo

$\pi \in \Gamma$
 \downarrow
 conjunto de todos os
 probabilidade em θ_0

$$r(s, \pi) = \int_{\theta \in \mathbb{R}} R(\theta, s) \pi(\theta) d\theta = R(\theta_0, s) \times 1 = R(\theta_0, s)$$

$$> R(\theta_0, s^m) = r(s^m, \pi)$$

Outra forma:

$$\sup_{\Delta \in \Gamma} r(\Delta, s^m) \leq \sup_{\theta \in \mathbb{R}} R(s^m, \theta)$$

rusco médio menor que rusco máximo

$$\sup_{\Delta \in \Gamma} r(\Delta, s) \leq \sup_{\theta \in \mathbb{R}} R(s, \theta)$$

$$\sup_{\Delta \in \Gamma} r(\Delta, s) \leq \sup_{\theta \in \mathbb{R}} R(\theta, s)$$

(o maior (sup) rusco médio de s^m é menor que o maior (sup) rusco médio de qualquer outro estimador s .

$\Rightarrow s^m \in \Gamma$ -minimax

Siga $s \neq s^m$

$\exists \theta_0 \in \Theta$ tal que $R(s, \theta_0) > \sup R(\theta, s^m)$

$$\pi(\theta) = \begin{cases} 1 & \text{se } \theta = \theta_0 \\ 0 & \text{c.c.} \end{cases} \quad r(s, \pi) = \int R(s, \theta) \pi(\theta) d\theta = R(s, \theta_0) > \sup R(s^m)$$

$$r(s, \pi) > \sup R(\theta, s^m) > \sup_{\Delta \in \Gamma} r(\Delta, s^m)$$

rusco mínimo rusco médio

11

c) s^* é o único estimador de Bayes para priori Δ^*

$\Rightarrow s^* \in \Gamma$ -admissível

(não existe nenhum outro s tal que $r(s, \Delta) \leq r(s^*, \Delta)$ para algum $\Delta \in \Gamma$)

Prova por aberto:

Suponha que existe $\exists s$ tal que $r(s, \Delta) \leq r(s^*, \Delta)$ e $r(s, \Delta') < r(s^*, \Delta')$ para algum $\Delta' \in \Gamma$

$\Rightarrow s^* \in \Gamma$ -minimax

$r(s, \Delta^*) = r(s^*, \Delta^*)$ para s^* estimador de Bayes quando Δ^*

$\Rightarrow s^*$ não é único, mas por hipótese ele é único, aberto!

3) $H: P_0 \quad K: P_1 \quad \phi(X) \cdot M.P. \quad N.P.$

$$\phi(X) = \begin{cases} 1, & \alpha p_0(x) > K p_1(x) \\ 0, & \alpha p_0(x) = K p_1(x) \\ 0, & \alpha p_0(x) < K p_1(x) \end{cases}$$

K fixado, $K > 0$
 $F_0(\phi(X)) = \alpha e(Q_1)$
 $E_1(\phi(X)) = \beta$

$H: P_1$	$K: P_0$	$\begin{cases} 0, & \alpha p_1(x) > K p_0(x) \\ 1 - \alpha, & \alpha p_1(x) = K p_0(x) \\ 1, & \alpha p_1(x) < K p_0(x) \end{cases}$
----------	----------	--

$$\phi^*(X) = 1 - \phi(X) = \begin{cases} 1 - \alpha, & \alpha p_1(x) = K p_0(x) \\ 1, & \alpha p_1(x) < K p_0(x) \end{cases}$$

$$R^* = 1 - \alpha, \quad K^* = 1$$

$$\phi^*(X) = \begin{cases} 1, & \alpha p_1(x) > R^* p_1(x) \\ R^*, & \alpha p_1(x) = K^* p_1(x) \\ 0, & \alpha p_1(x) < K^* p_1(x) \end{cases}$$

①

$$E_1(\phi^*(X)) = 1 - E_1(\phi(X)) = 1 - \beta \quad ②$$

23/11/2010

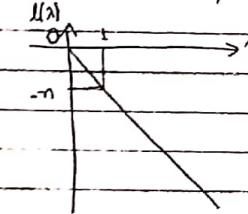
4) $X \sim \text{Poisson}$

a) $f(x|\lambda) = \frac{1}{x!} e^{-\lambda} \lambda^x$

$$m(\lambda) = -\lambda n + \sum_{i=1}^n x_i \log \lambda + c(x),$$

$x_1 = x_2 = \dots = x_n = 0$

$$m(\lambda) = -n\lambda, \quad \hat{\lambda} = 0 \quad \phi(0, +\infty)$$



b) $N, X_N > 0, Y = X_N$

i) $P(Y=y | N=n) = P(Y=y | N=n) \cdot P(N=n)$

$$p = P(X_1=0) = e^{-\lambda}$$

$$P(N=n) = P(X_1=0, X_2=0, X_3=0, \dots, X_{N-1}=0, X_N \neq 0) = p^{N-1} (1-p)^N q_{\text{com}}(1-p)$$

$$P(Y=y | X_1=0, X_2=0, \dots, X_{N-1}=0, X_N > 0)$$

$$P(Y=y | X_1=0, \dots, X_{N-1}=0, X_N > 0) =$$

$$= P(X_N=y | X_1=X_2=\dots=X_{N-1}=0; X_N > 0, N=n)$$

$$= P(X_N=y | X_N > 0) = \frac{e^{-\lambda} \lambda^y}{y!}, \quad y=1, \dots = P(Y=y) \stackrel{\text{de}}{=} \frac{e^{-\lambda} \lambda^y}{y!}$$

$(1-p)$ probabilidade
de retomada

$$P(N=n) = p^{n-1} (1-p)$$

$$P(Y|N) = e^{-\lambda} \lambda^y \quad (1-p)^{n-y} \quad \text{e}^{-\lambda} = e^{-\lambda} \quad \text{então}$$

$$= \frac{y!}{y!} \frac{1-p}{e^{-\lambda}} \frac{(e^{-\lambda})^{n-y}}{\lambda^y} = e^{-\lambda} \lambda^y$$

$y!$

$$P(Y|N=n) \cdot P(N=n) = P(Y=y) \cdot P(N=n) \quad N \text{ e } Y \text{ são independentes}$$

$$\text{i)} f_{Y|N}(N, y) = e^{-\lambda} \lambda^y$$

$$f_{(N, y)} = f_{N, y}(N, y)$$

$$h(y|N) = 1$$

$y!$

$$l(\lambda|y, n) = C(y) - n\lambda + y \log \lambda$$

$$\boxed{\hat{\lambda} = \frac{y}{n}}$$

$$\text{ii)} E_{\lambda}(\hat{\lambda}) = E_{\lambda}(y) \cdot E_{\lambda}\left(\frac{1}{N}\right)$$

$$F_{\lambda}(y) = \sum_{y=1}^{\infty} \frac{y}{y!} \frac{1}{1-p} \frac{e^{-\lambda} \lambda^y}{y!} = \frac{1}{1-p} \sum_{y=1}^{\infty} \frac{y}{y!} \frac{e^{-\lambda} \lambda^y}{y!}$$

Expressão da função de

$$= \frac{\lambda}{1-p}$$

$$E_{\lambda}\left(\frac{1}{N}\right) = \sum_{n=1}^{\infty} \frac{1}{N} p^{n-1} (1-p) = (1-p) \sum_{n=1}^{\infty} \frac{p^{n-1}}{n}$$

Mas:

$$\sum_{n=1}^{\infty} \frac{1}{n} p^n = -\log(1-p).$$

$$E_{\lambda}\left(\frac{1}{N}\right) = -\frac{(1-p)}{p} \log(1-p)$$

$$E_{\lambda}(\hat{\lambda}) = -\log(1-p) \xrightarrow{p}$$

$$\lim_{\lambda \rightarrow 0} F_{\lambda}\left[\frac{\lambda}{\lambda}\right] = \lim_{\lambda \rightarrow \infty} \left(-\frac{\log(1-e^{-\lambda})}{e^{-\lambda}} \right) = +\infty$$

assimétrica, com a direção de tendências infinitas

$$c) Y_1 - Y_2 = -X_n = 0, \quad X_n = y > 0$$

$$f(x|x) = e^{-\lambda} \lambda^y$$

$y!$

$$f(\emptyset|m) = 1 e^{-\frac{\lambda}{m}}$$

$$f(\emptyset|x) \propto \lambda^y \cdot e^{-\lambda \left(\frac{n+1}{m}\right)} \sim \text{gamma}(y+1, \frac{\lambda}{m})$$

$$\boxed{S(x) = \frac{y+2}{1+n}}$$

d)

23/11/2010

8)

$$a) X_1, \dots, X_n \sim U(0, \theta)$$

$$p_\theta(x) = \frac{1}{\theta^n} I(X_m \leq \theta)$$

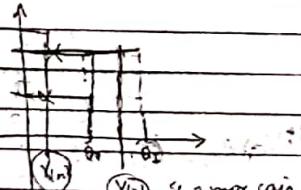
$$H: \theta = \theta_0 \quad K: \theta = \theta_1$$

$$\phi(X) = 1 \Leftrightarrow p_\theta(x) > K p_{\theta_0}(x) \rightarrow$$

$$I(X_m \leq \theta) > K \cdot I(X_m \leq \theta_0)$$

$$S: K = \left(\frac{\theta_1}{\theta_0}\right)^n \Leftrightarrow$$

$$\Leftrightarrow I(X_m \leq \theta) > I(X_m \leq \theta_0)$$



$$S: I(X_m > \theta_0), \phi(X) = 1$$

$$\Leftarrow 1 \cdot P(I(X_m > \theta_0)) + 0 \cdot P(I(X_m \leq \theta_0))$$

0
1

que es cierto que no vale
que no vale
que no vale
que no vale?

$$\alpha = \beta$$

$$P(X_m \leq y) = [P(X_i \leq y)]^n = \left[\int_0^y \frac{1}{\theta} d\theta \right]^n = \left(\frac{y}{\theta} \right)^n$$

$$f_Y(y) = n \cdot y^{n-1} \frac{I(y)}{(\theta)^n}$$

23/11/2010

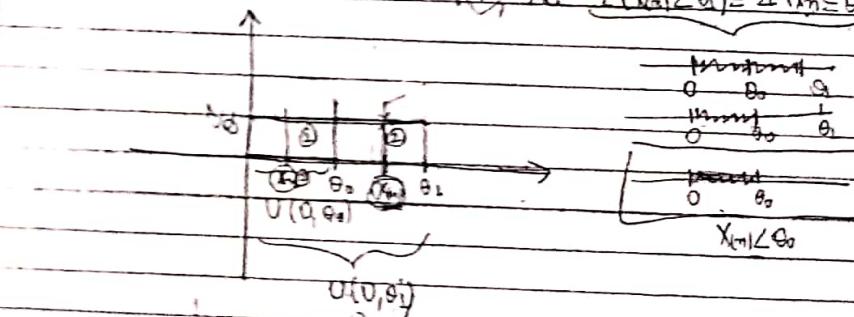
Víctor M. Verdú

$$8a) \quad \begin{cases} 1, & \theta = \theta_0, p_\theta(x) > K p_{\theta_0}(x) \\ P, & \theta = \theta_1, p_\theta(x) = K p_{\theta_0}(x) \\ 0, & \theta = \theta_1, p_\theta(x) < K p_{\theta_0}(x) \end{cases}$$

$$\text{Pois } K = \left(\frac{\theta_1}{\theta_0}\right)^n$$

$$\phi(X) = \begin{cases} 1, & I(X_m < \theta_1) > I(X_m < \theta_0) \\ P, & I(X_m < \theta_1) = I(X_m \leq \theta_0) \\ 0, & I(X_m < \theta_1) < I(X_m \leq \theta_0) \end{cases}$$

$$\phi(X) = \begin{cases} 1, & X_m > \theta_0 \\ P, & I(X_m < \theta_1) = I(X_m \leq \theta_0) \\ 0, & X_m < \theta_0 \end{cases}$$



$$I(X_m < \theta_1) > I(X_m < \theta_0)$$

$$\begin{array}{c} 1 > 1 \\ 1 > 0 \\ 0 < 0 \end{array}$$

$$\begin{array}{c} 1 \\ 1 \\ 0 \end{array} \quad \begin{array}{c} 1 \\ 1 \\ 0 \end{array}$$

$$\begin{array}{c} 1 \\ 0 \\ 0 \end{array} \quad \begin{array}{c} 1 \\ 0 \\ 1 \end{array}$$

$$\begin{array}{c} 1 \\ 0 \\ 0 \end{array} \quad \begin{array}{c} 1 \\ 0 \\ 1 \end{array}$$

23/10/2010

$$\phi(x) = \begin{cases} 1, & X_{(n)} > \theta_0 \\ 0, & X_{(n)} \leq \theta_0 \end{cases} \quad \theta \leq \theta_0$$

$$\theta > \theta_0 \quad (\textcircled{1})$$

$$\alpha = P_{\theta_0} (X_{(n)} > \theta_0) + P_{\theta_0} (X_{(n)} \leq \theta_0) =$$

$$\alpha = P_{\theta_0} \cdot 1 \Rightarrow P_{\theta_0} = \alpha$$

$$\boxed{\phi(x) = \begin{cases} 1, & X_{(n)} > \theta_0 \\ \alpha, & X_{(n)} \leq \theta_0 \end{cases}}$$

b) $H: \theta = \theta_0 \quad \text{vs} \quad K: \theta \neq \theta_0$

$$R_1: \theta = \theta_0 \quad R_2: \theta = \theta_1 \quad R_3: \theta = \theta_2$$

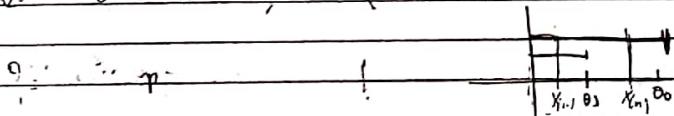
$$R_1: \theta = \theta_0 \quad \text{vs} \quad \theta = \theta_1 \quad (\theta_1 > \theta_0) \quad \textcircled{OK}$$

$$R_2: \theta = \theta_0 \quad \text{vs} \quad \theta = \theta_1 \quad (\theta_1 < \theta < \theta_2)$$

$$R_3: \theta = \theta_0 \quad \text{vs} \quad \theta = \theta_2 \quad (\theta_2 < \theta < \theta_1)$$

R_1 : iden as sten

$$R_2: \theta = \theta_0 \quad \text{vs} \quad \theta = \theta_1 \quad (\theta_1 < \theta < \theta_2)$$



(ii) Rechts H_0: $X_{(n)}$ i.m. maxima

$$\phi(x) = \begin{cases} 1, & X_{(n)} < k = \theta_0 + \alpha \\ 0, & \text{c.c.} \end{cases}$$

$$\alpha = P_{\theta_0} (X_{(n)} \leq k) = \int_0^k \frac{n}{\theta_0^n} y^{n-1} dy = n \int_0^k y^{n-1} dy = n \left[\frac{y^n}{\theta_0^n} \right]_0^k = \frac{k^n}{\theta_0^n}$$

$$\alpha = \frac{k^n}{\theta_0^n}$$

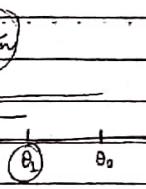
iii) Case (ii) \Rightarrow fiktiv stem kontinuumsfunktion (2).

$$\boxed{(k = \theta_0 + \alpha)}$$

1/1

$$H: \theta = \theta_0 \quad \text{vs} \quad K: \theta = \theta_1 \leq \theta_0 \quad \alpha \stackrel{?}{=} n$$

Numre represe-nce (2)



MAE 5834 - Estatística Avançada I

Lista de Exercícios 5 – 2º semestre de 2005 – Prof. Silvia Ferrari

✓ 4. Quantidade Pivotal

Considere a variável aleatória X com distribuição na família $\mathcal{P} = \{P_\theta, \theta \in \Omega\}$. Uma função $h(X, \theta)$ a valores reais cuja distribuição não depende de θ é chamada de quantidade pivotal. Seja $F_h(y)$ a função distribuição acumulada de $h(X, \theta)$, estritamente crescente e contínua. Mostre que

$$S(x) = \{\theta \in \Omega : h(x, \theta) \leq F_h^{-1}(1 - \alpha)\}$$

é uma região de confiança para θ com coeficiente de confiança $1 - \alpha$.

✓ 5. Sejam X_1, \dots, X_n variáveis aleatórias independentes tais que X_i tem distribuição exponencial de média $\lambda\beta^i$; $\lambda > 0$, $\beta > 0$. Suponha que β é conhecido.

(a) Encontre um limite inferior de confiança uniformemente mais acurado para λ com coeficiente de confiança $1 - \alpha$.

(b) Mostre que $\sum X_i / (\lambda\beta^i)$ é uma quantidade pivotal.

(c) Construa um intervalo de confiança para α com coeficiente de confiança γ baseado na quantidade pivotal dada em (b).

✓ 6. Sejam X_1, \dots, X_n uma amostra aleatória da distribuição exponencial de média θ , $\theta > 0$.

(a) Encontre um teste uniformemente mais poderoso (UMP) de $H_0 : \theta = \theta_0$ versus $H_1 : \theta > \theta_0$ de nível α ($0 < \alpha < 1$).

(b) Se a amostra observada foi $(2.0, 0.2, 1.0, 0.9, 1.0, 0.1, 0.3, 1.3, 1.4, 0.8)$ e $\theta_0 = 1$, qual é sua conclusão ao nível de 5%? Qual é o nível descritivo do teste?

✓ 7. Sejam X_1, \dots, X_n uma amostra aleatória da densidade

$$p_\theta(x) = \theta x^{\theta-1}, \quad 0 < x < 1, \theta > 0.$$

(a) Obtenha um teste UMP de $H_0 : \theta \leq \theta_0$ ($\theta_0 > 0$) versus $H_1 : \theta > \theta_0$ de nível α .

(b) Obtenha um teste UMP de $H_0 : \theta \geq \theta_0$ ($\theta_0 > 0$) versus $H_1 : \theta < \theta_0$ de nível α .

(c) Encontre um limite inferior de confiança mais acurado com coeficiente de confiança $1 - \alpha$.

(d) Encontre um limite superior de confiança mais acurado com coeficiente de confiança $1 - \alpha$.

✓ 8. Para a questão (4), determine uma quantidade pivotal e encontre um intervalo de confiança para θ com coeficiente de confiança $1 - \alpha$.

✓ 9. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$.

(a) Se $\sigma = \sigma_0$ (conhecido), encontre um teste UMP de nível α para testar $H : \mu \leq \mu_0$ contra $K : \mu > \mu_0$.

(b) Se $\mu = \mu_0$ (conhecido), encontre um teste UMP de nível α para testar $H : \sigma \leq \sigma_0$ contra $K : \sigma > \sigma_0$.

✓ 10. Sejam X_i variáveis aleatórias independentes com distribuição $N(d_i\theta, 1)$, $d_i \neq 0$, $i = 1, \dots, n$. Encontre um teste UMP de $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$ de nível α .

✓ 11. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$. Encontre quantidades pivotais adequadas e obtenha intervalos de confiança com coeficiente de confiança $1 - \alpha$ para μ e para σ^2 . [Veja Exemplo 4, p. 215 e Exemplo 5, p. 217, TSH].

$$\text{unp} \left\{ \ln \theta + (n-1) \ln \bar{x} \right\}$$

$$\Theta(\ln \bar{x}) = \theta \quad \eta'(\theta) = 1$$

✓ 12. Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $U(0, \theta)$.

(a) Mostre que, para testar $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$, qualquer teste para o qual $E_{\theta_0}(\phi(X)) = \alpha$, $E_\theta(\phi(X)) \leq \alpha$, para $\theta \leq \theta_0$, e $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$, é UMP de nível α . Sugestão: Use o Lema de Neyman Pearson, com $k = (\theta_0/\theta_1)^n$.

(b) Mostre que, para testar $H : \theta = \theta_0$ contra $K : \theta \neq \theta_0$, o teste $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$ ou $\max(x_1, \dots, x_n) \leq \theta_0 \alpha^{1/n}$ e $\phi(x) = 0$, caso contrário, é UMP.

Sugestão: Considere separadamente 3 situações: (i) $H : \theta = \theta_0$ contra $K_1 : \theta = \theta_1 > \theta_0$; (ii) $H : \theta = \theta_0$ contra $K_2 : \theta = \theta_1, \theta_0 \alpha^{1/n} < \theta_1 < \theta_0$; (iii) $H : \theta = \theta_0$ contra $K_3 : \theta = \theta_1 \leq \theta_0 \alpha^{1/n}$.

✓ 13. Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes com distribuição $U(-\theta, \theta)$, $\theta > 0$.

(a) Mostre que o teste ϕ tal que $\phi(x) = 1$, se $\max(|x_1|, \dots, |x_n|) > \theta_0$ e $\phi(x) = 0$, caso contrário, é uniformemente mais poderoso de nível α para testar $H : \theta = \theta_0$ contra $K : \theta > \theta_0$.

(b) Encontre a função de poder do teste ϕ .

✓ 14. Admita que a densidade $p_\theta(x)$ de X tem razão de verossimilhança monótona em $T(x)$ e considere o problema de testar $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$. Se a distribuição de T é contínua, mostre que o nível descritivo (valor p) do teste UMP é dado por $\hat{\alpha} = P_{\theta_0}(T \geq t)$ onde t é o valor observado de T . Mostre que este resultado também vale sem a suposição de continuidade se, para testes aleatorizados, $\hat{\alpha}$ é definido como o menor nível de significância para o qual a hipótese H é rejeitada com probabilidade 1.

✓ 15. Sejam X_1, \dots, X_n variáveis aleatórias independentes, cada qual com distribuição $\Gamma(g, b)$. Mostre que existe um teste UMP para testar:

(a) $H : b \leq b_0$ contra $K : b > b_0$, quando g é conhecido;

(b) $H : g \leq g_0$ contra $K : g > g_0$, quando b é conhecido.

✓ 16. Uma variável aleatória X tem distribuição de Pareto $P(c, \tau)$ se sua densidade é cr^c/x^{c+1} , $0 < r < x$, $0 < c$. Se X_1, \dots, X_n são variáveis aleatórias independentes, cada qual com distribuição $P(c, \tau)$, obtenha um teste UMP de $H : \tau = \tau_0$ contra $K : \tau \neq \tau_0$, quando b é conhecido.

Sugestão: Use ex. 9.

✓ 17. Sejam X_1, \dots, X_n variáveis aleatórias independentes, cada qual com distribuição Gaussiana inversa $GI(\mu, \tau)$ e densidade

$$\sqrt{\frac{\lambda}{2\pi}} \exp[(\lambda\mu)^{1/2}] x^{-3/2} \exp\left[-\frac{1}{2}\left(\frac{\lambda}{x} + \mu x\right)\right], \quad x > 0, \tau > 0, \mu > 0.$$

Mostre que existe um teste UMP para testar:

(a) $H : \mu \leq \mu_0$ contra $K : \mu > \mu_0$, quando τ é conhecido;

(b) $H : \tau \leq \tau_0$ contra $K : \tau > \tau_0$, quando μ é conhecido.

Em cada caso, dê a forma da região crítica.

✓ 18. Teste Bayesiano

Sejam P_0 e P_1 duas distribuições com densidades p_0 e p_1 respectivamente. Considere o problema de testar $H_0 : P = P_0$ contra $H_1 : P = P_1$ e suponha que as probabilidades $\pi_0 = \pi$ e $\pi_1 = 1 - \pi$ possam ser atribuídas, antes do experimento ser realizado, às hipóteses H_0 e H_1 respectivamente.

(a) Mostre que a probabilidade total de um erro resultante do uso de um teste ϕ é

$$\pi E_{P_0}[\phi(X)] + (1 - \pi) E_{P_1}[1 - \phi(X)].$$

(b) Mostre que o teste que minimiza esta probabilidade, o teste de Bayes, tem a forma do teste de Neyman Pearson com $k = \pi_0/\pi_1$.

Sugestão: Considere $S_1 = \{x : (1 - \pi)p_1 > \pi p_0\}$, $S_2 = \{x : (1 - \pi)p_1 < \pi p_0\}$ e $S_3 = \{x : (1 - \pi)p_1 = \pi p_0\}$.

(c) Mostre que a distribuição condicional de H_i dado $X = x$, a probabilidade a posteriori de H_i , é

$$\frac{\pi_i p_i(x)}{\pi_0 p_0(x) + \pi_1 p_1(x)},$$

e então o teste de Bayes decide em favor da hipótese que tem maior probabilidade a posteriori.

✓ 16. Sejam f e g duas densidades de probabilidade com respeito a μ . Para testar a hipótese $H : \theta \leq \theta_0$ ou $\theta \geq \theta_1$, ($0 < \theta_0 < \theta_1 < 1$) contra alternativas $\theta_0 < \theta < \theta_1$ na família $\mathcal{P} = \{\theta f(x) + (1 - \theta)g(x), 0 \leq \theta \leq 1\}$, o teste $\phi(x) = \alpha$, para todo x , é UMP de nível α .

1) Quantidade Pivotal: Considere a variável aleatória com distribuição na família $\mathcal{P} = \{\theta_0, \theta_1\}$ uma função $t(x, \theta)$ a valores reais cuja distribuição não depende de θ é chamada de quantidade pivotal. Seja $F_t(y)$ a função distribuição acumulada de $t(x, \theta)$, estritamente crescente e contínua. Mostre que

$$S(z) = \{\theta \in \Omega : t(x, \theta) \leq F_t^{-1}(1-\alpha)\} \quad (*)$$

é uma região de confiança para θ com coeficiente de confiança $1-\alpha$.

Pela definição de $S(z)$ $(*)$

$$\theta \in S(z) \Leftrightarrow t(x, \theta) \leq F_t^{-1}(1-\alpha)$$

então

$$\begin{aligned} P(\theta \in S(z)) &= P(t(x, \theta) \leq F_t^{-1}(1-\alpha)) \\ &= F_t(F_t^{-1}(1-\alpha)) \\ &= 1 - \alpha \quad \forall \theta \end{aligned}$$

Portanto

$$P(\theta \in S(z)) = 1 - \alpha \quad \forall \theta \in \Omega$$

então $S(z)$ é uma região de confiança para θ com coeficiente de confiança $1-\alpha$.

d) Sejam x_1, \dots, x_n variáveis aleatórias independentes tais que x_i tem distribuição exponencial de média $\lambda\beta^i$; $\lambda > 0$, $\beta > 0$. Suponha que β é conhecido.

(a) Encontre um limite inferior de confiança uniformemente mais acurado para λ com coeficiente de confiança $1-\alpha$.

Sabemos que

$$x_i \sim \text{Exp}\left(\frac{1}{\lambda\beta^i}\right)$$

então

$$f_{X_i}(x_i) = \frac{1}{\lambda\beta^i} \exp\left\{-\frac{x_i}{\lambda\beta^i}\right\}, \quad x_i > 0$$

ou,

$$f_X(x) = \frac{1}{\lambda^n \prod_{i=1}^n \beta^i} \exp\left\{-\frac{1}{\lambda} \sum_{i=1}^n \frac{x_i}{\beta^i}\right\}$$

$$= \exp\left\{-\frac{1}{\lambda} \sum \frac{x_i}{\beta^i} - n \log \lambda\right\} \frac{1}{\prod \beta^i}$$

$$= \exp\left\{\eta(\lambda) T(x) - B(\lambda)\right\} h(x)$$

que evidencia a família exponencial, onde

$$\eta(\lambda) = -\frac{1}{\lambda}, \quad T(x) = \sum_{i=1}^n \frac{x_i}{\beta^i}, \quad B(\lambda) = n \log \lambda + h(x) = \frac{1}{\prod \beta^i}$$

Temos que

$$\frac{\partial \eta(\lambda)}{\partial \lambda} = \frac{1}{\lambda^2} > 0 \Rightarrow \eta(\lambda) \text{ é estritamente crescente.}$$

Encontrar um limite inferior uniformemente mais acurado para λ com coeficiente de confiança $1-\alpha$ é a solução $\underline{\lambda}$ da inequação

$$P_{\lambda} (T(x) \leq t) = 1-\alpha$$

$$\Leftrightarrow P_{\lambda} \left(\sum \frac{x_i}{\beta^i} \leq t \right) = 1-\alpha$$

Mas no item b) mostramos que

$$\sum \frac{x_i}{\lambda\beta^i} \sim \text{Gamma}(n, \lambda)$$

então

$$\Leftrightarrow \sum \frac{x_i}{\lambda\beta^i} \sim \chi_{2n}^2$$

Logo

$$P_{\lambda} \left(\sum \frac{x_i}{\lambda\beta^i} \leq t \right) = 1-\alpha \Leftrightarrow P \left(\frac{2}{\lambda} \sum \frac{x_i}{\beta^i} \leq \frac{2}{\lambda} t \right) = 1-\alpha$$

$$\Leftrightarrow P \left(\chi_{2n}^2 \leq \frac{2t}{\lambda} \right) = 1-\alpha$$

$$\text{onde } \chi_{2n}^2 = \frac{2}{\lambda} \sum \frac{x_i}{\beta^i} \text{ é uma r.a. com dist. } \chi_{2n}^2.$$

Se $q_{1-\alpha}$ é quantil de ordem $1-\alpha$ da distribuição χ_{2n}^2 então

$$q_{1-\alpha} = \frac{2t}{\lambda} \Rightarrow \underline{\lambda} = \frac{2t}{q_{1-\alpha}}$$

$$\text{onde } t \text{ é o valor observado de } T(x) = \sum \frac{x_i}{\beta^i}.$$

Portanto o limite inferior de confiança uniformemente mais acurado para λ com coeficiente de confiança $1-\alpha$ é

$$\underline{\lambda} = \frac{2t}{q_{1-\alpha}}.$$

b) Mostre que $\sum \frac{x_i}{\lambda \beta^i}$ é uma quantidade pivotal.

Seja $y_i = \frac{x_i}{\lambda \beta^i}$ então

$$\begin{aligned} P(y_i \leq y_i) &= P\left(\frac{x_i}{\lambda \beta^i} \leq y_i\right) \\ &= P(x_i \leq (\lambda \beta^i) y_i) = F_{x_i}(\lambda \beta^i y_i) \end{aligned}$$

Daí,

$$f_{y_i}(y_i) = f_{x_i}(\lambda \beta^i y_i) \lambda \beta^i$$

$$\text{Como } x_i \sim \text{Exp}(\lambda \beta^i) \Rightarrow f_{x_i}(\lambda \beta^i y_i) = \frac{1}{\lambda \beta^i} \exp\left\{-\frac{\lambda \beta^i y_i}{\lambda \beta^i}\right\}$$

Daí

$$\begin{aligned} f_{y_i}(y_i) &= \frac{1}{\lambda \beta^i} \exp\{-y_i\} \lambda \beta^i \\ &= e^{-y_i} \end{aligned}$$

$$\Rightarrow y_i \sim \text{Exp}(1) \Leftrightarrow y_i \sim \text{Goma}(1, 1)$$

$$\text{então } \sum_{i=1}^n y_i \sim \text{Goma}(n, 1)$$

ou seja,

$$\sum \frac{x_i}{\lambda \beta^i} \sim \text{Goma}(n, 1)$$

que não depende de $\alpha \beta^i$. Portanto

$$\sum \frac{x_i}{\lambda \beta^i} \text{ é uma quantidade pivotal.}$$

c) Encontre um intervalo de confiança para λ com coeficiente de confiança α baseado na quantidade pivotal dada em (b).

Sabemos por (b) que

$$\sum \frac{x_i}{\lambda \beta^i} \sim \text{Goma}(n, 1)$$

então

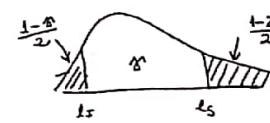
$$2 \sum \frac{x_i}{\lambda \beta^i} \sim \chi^2_{2n}$$

Logo

$$P\left(\frac{l_s}{2} \leq 2 \sum \frac{x_i}{\lambda \beta^i} \leq l_s\right) = \alpha$$

$$\Leftrightarrow P\left(\frac{l_s}{2 \sum x_i / \beta^i} \leq \frac{1}{\lambda} \leq \frac{l_s}{2 \sum x_i / \beta^i}\right) = \alpha$$

$$\Leftrightarrow P\left(\frac{2 \sum x_i / \beta^i}{l_s} \leq \lambda \leq \frac{2 \sum x_i / \beta^i}{l_s}\right) = \alpha$$



Logo um um intervalo de confiança para λ cl coef. de conf α

$$\left(\frac{2 \sum x_i / \beta^i}{l_s}; \frac{2 \sum x_i / \beta^i}{l_s}\right)$$

onde l_s é o quantil de ordem $\frac{1-\alpha}{2} + \alpha$ da distribuição χ^2_{2n}

e l_s é o quantil de ordem $\frac{1-\alpha}{2}$ da dist. χ^2_{2n} .

3) supom x_1, \dots, x_n uma a.a. da distribuição exponencial de média θ , $\theta > 0$

(a) concentre um teste UMP de

$$H_0: \theta = \theta_0 \text{ versus } H_1: \theta > \theta_0$$

de nível α ($0 < \alpha < 1$)

temos $x_i \sim \text{Exp}(\frac{1}{\theta}) \Rightarrow p_{\theta}(x_i) = \frac{1}{\theta} \exp\left\{-\frac{1}{\theta}x_i\right\}$.
então

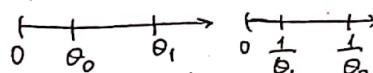
$$p_{\theta_0}(x) = \frac{1}{\theta_0^n} \exp\left\{-\frac{1}{\theta_0} \sum x_i\right\}$$

Daí,

$$\frac{p_{\theta_1}(x)}{p_{\theta_0}(x)} = \left(\frac{\theta_1}{\theta_0}\right)^n \exp\left\{-\frac{1}{\theta_1} \sum x_i + \frac{1}{\theta_0} \sum x_i\right\}$$

$$= \left(\frac{\theta_1}{\theta_0}\right)^n \exp\left\{\left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right) \sum x_i\right\}$$

$$\text{se } \theta_1 > \theta_0 \Rightarrow \frac{1}{\theta_0} - \frac{1}{\theta_1} > 0$$



então $\frac{p_{\theta_1}(x)}{p_{\theta_0}(x)}$ é uma função não decrescente em $\sum x_i$
 $p_{\theta_0}(x)$

Daí $p_{\theta_1}(x)$ tem rácão de verossimilhança monótona em $\sum x_i$

então pelo teorema 24 um teste UMP para testar

$$H_0: \theta = \theta_0 \text{ versus } H_1: \theta > \theta_0$$

de nível α é dado por

$$\phi(x) = \begin{cases} 1 & \text{quando } \sum x_i > c \\ 0 & \text{quando } \sum x_i \leq c \end{cases}$$

onde c é determinado por

$$E_{\theta_0}(\phi(x)) = \alpha$$

mas

$$E_{\theta_0}(\phi(x)) = 1 \times P_{\theta_0}(\sum x_i > c) + 0 \times P_{\theta_0}(\sum x_i \leq c) = \alpha$$

ou seja,

$$P_{\theta_0}[\sum x_i > c] = \alpha \Leftrightarrow P_{\theta_0}[\sum x_i \leq c] = 1 - \alpha$$

Portanto

$$x_i \sim \text{Exp}\left(\frac{1}{\theta}\right) \Leftrightarrow x_i \sim \text{Gama}\left(n, \frac{1}{\theta}\right)$$

então

$$\sum x_i \sim \text{Gama}\left(n, \frac{1}{\theta}\right)$$

Daí

$$\frac{n}{\theta} \sum x_i \sim \chi^2_{2n} \text{ - então de } \Leftrightarrow \text{temos}$$

$$P_{\theta_0}\left(\frac{n}{\theta} \sum x_i \leq \frac{2c}{\theta}\right) = 1 - \alpha$$

$$P\left(\chi^2_{2n} \leq \frac{2c}{\theta}\right) = 1 - \alpha$$

onde $\chi^2_{2n} = -\frac{n}{\theta} \sum x_i$ é uma v.a. c/ dist χ^2_{2n} .

Se $q_{1-\alpha}$ é o quartil de ordem $(1-\alpha)$ da distribuição χ^2_{2n}

então

$$q_{1-\alpha} = \frac{2c}{\theta_0} \Rightarrow c = \frac{q_{1-\alpha} \theta_0}{2}$$

Portanto

$$\phi(x) = \begin{cases} 1 & \text{quando } \sum x_i > q_{1-\alpha} \theta_0 / 2 \\ 0 & \text{quando } \sum x_i \leq q_{1-\alpha} \theta_0 / 2 \end{cases}$$

b) se a amostra observada foi $(2.0, 0.2, 1.0, 0.9, 1.0, 0.1, 0.3, 1.3, 1.4, 0.8)$ e $\theta_0 = 1$ qual é a sua conclusão ao nível de 5%? Qual o nível descritivo do teste?

Temos agora que

$$\sum x_i = 9, \quad \theta_0 = 1 \quad \text{e} \quad \alpha = 0.05 \Rightarrow q_{1-\alpha} =$$

Sabemos por (a) que

- Se $\sum x_i > \frac{q_{1-\alpha}}{2} \Rightarrow \phi(x) = 1$ então rejeita α

$$\text{hipótese } H_0: \theta = \theta_0$$

- Se $\sum x_i < \frac{q_{1-\alpha}}{2} \Rightarrow \phi(x) = 0$ então não há evidência

para rejeitar H_0

Mas agora temos que

$$\sum x_i = 9 \quad \text{e} \quad \frac{q_{1-\alpha}}{2} = \frac{q_{1-\alpha}}{2} =$$

Logo $\sum x_i > \frac{q_{1-\alpha}}{2}$

Então

4) Sejam x_1, \dots, x_n uma amostra aleatória da densidade

$$p_\theta(x) = \theta x^{\theta-1}, \quad 0 < x < 1, \theta > 0$$

(a) Obtenha um teste UMP de $H_0: \theta \leq \theta_0$ ($\theta_0 > 0$) versus $H_L: \theta > \theta_0$ de nível α .

Temos que

$$p_\theta(x) = \prod_{i=1}^n \theta x_i^{\theta-1} = \theta^n \prod_{i=1}^n x_i^{\theta-1}$$

daí

$$\begin{aligned} \frac{p_{\theta_1}(x)}{p_{\theta_0}(x)} &= \left(\frac{\theta_1}{\theta_0}\right)^n \frac{\prod_{i=1}^n x_i^{\theta_1-1}}{\prod_{i=1}^n x_i^{\theta_0-1}} = \exp\left\{\log\left[\frac{\theta_1^n \prod_{i=1}^n x_i^{\theta_1-1}}{\theta_0^n \prod_{i=1}^n x_i^{\theta_0-1}}\right]\right\} \\ &= \exp\left\{n \log\left(\frac{\theta_1}{\theta_0}\right) + (\theta_1 - \theta_0) \sum_{i=1}^n \log x_i - (\theta_0 - 1) \sum_{i=1}^n \log x_i\right\} \\ &= \exp\left\{n \log\left(\frac{\theta_1}{\theta_0}\right) + (\theta_1 - \theta_0) \sum_{i=1}^n \log x_i\right\} \end{aligned}$$

Se $\theta_1 > \theta_0 \Rightarrow \frac{\theta_1}{\theta_0} > 1 \Rightarrow \log\left(\frac{\theta_1}{\theta_0}\right) > 0 \quad \text{e} \quad (\theta_1 - \theta_0) > 0, \text{ mas } \sum \log x_i < 0$

então $\frac{p_{\theta_1}(x)}{p_{\theta_0}(x)}$ é uma função decrescente em $\sum_{i=1}^n \log x_i$

daí temos que $p_{\theta_1}(x)$ é um razão de verossimilhanças monótona em $-\sum_{i=1}^n \log x_i$

então pelo teorema 14 um teste UMP para testar

$$H_0: \theta \leq \theta_0 \quad \text{versus} \quad H_L: \theta > \theta_0$$

de nível α é dado por

$$\phi(x) = \begin{cases} 1 & \text{quando } -\sum \log x_i > c \Leftrightarrow \sum \log x_i < -c \\ 0 & \text{quando } -\sum \log x_i \leq c \Leftrightarrow \sum \log x_i \geq -c \end{cases}$$

pois como X é contínua $\Rightarrow P(\sum \log x_i = c) = 0$. Onde c é determinado a priori

$$E_{\theta_0}(\phi(x)) = \alpha$$

mas

$$E_{\theta_0}(\phi(x)) = 1 \times p_\theta(\sum \log x_i < -c) + 0 \times p_\theta(\sum \log x_i \geq -c) = \alpha$$

ou seja,

$$\begin{aligned} P_{\theta_0}(\sum \log x_i < -c) &= \alpha \iff P_{\theta_0}(-\sum \log x_i > c) = \alpha \not\rightarrow \\ &\iff P_{\theta_0}(-\sum \log x_i \leq c) = 1 - \alpha \end{aligned}$$

Agora devo encontrar $P(\sum \log x_i \leq c)$. Faça $Y = -\log X_i$ então

$$\begin{aligned} P(Y \leq c) &= P(-\log X_i \leq c) \\ &= P(\log X_i \geq -c) \\ &= P(X_i > e^{-c}) = 1 - F_{X_i}(e^{-c}) \end{aligned}$$

$$\Rightarrow F_Y(y) = 1 - F_{X_i}(e^{-c})$$

daí

$$f_Y(y) = -f_{X_i}(e^{-c}) e^{-c} (-1) = f_{X_i}(e^{-c}) e^{-c}$$

$$\text{mas } f_{X_i}(e^{-c}) = \theta (e^{-c})^{\theta-1} \quad \text{logo}$$

$$f_Y(y) = \theta (e^{-c})^{\theta-1} e^{-c} = \theta e^{-\theta c}$$

então

$$Y \sim \text{Exp}(\theta)$$

ou ainda

$$Y \sim \text{Gamma}(1, \theta)$$

$$\Leftrightarrow -\log X_i \sim \text{Gamma}(1, \theta)$$

$$-\sum_{i=1}^n \log X_i \sim \text{Gamma}(n, \theta)$$

$$-2\theta \sum_{i=1}^n \log X_i \sim \chi_{2n}^2$$

OBS:
se $X \sim \text{Gamma}(a, b)$
 $\Rightarrow 2bX \sim \chi_{2a}^2$

Voltando para (*)

$$P(-2\theta \sum_{i=1}^n \log X_i \leq 2\theta c) = 1-\alpha$$

ou ainda,

$$P(-2\theta \sum_{i=1}^n \log X_i \leq 2\theta c) = 1-\alpha \Leftrightarrow P(\chi_{2n}^2 \leq 2\theta c) = 1-\alpha$$

onde $\chi_{2n}^2 = -2\theta \sum_{i=1}^n \log X_i$ representa v.a. cl distr χ_{2n}^2 .

se $q_{1-\alpha}$ é o quantil de ordem $1-\alpha$ da distribuição χ_{2n}^2

então

$$q_{1-\alpha} = 2\theta c \Rightarrow c = q_{1-\alpha}/2\theta$$

zai um teste UMP para testar $H_0: \theta = \theta_0$ versus $H_1: \theta < \theta_0$ de nível α

e dado por

$$\phi(X) = \begin{cases} 1, & \text{quando } \sum_{i=1}^n \log X_i < -q_{1-\alpha}/2\theta \\ 0, & \text{quando } \sum_{i=1}^n \log X_i > -q_{1-\alpha}/2\theta \end{cases}$$

(b) Obtenha um teste UMP de $H_0: \theta \geq \theta_0$ ($\theta > 0$) versus $H_1: \theta < \theta_0$ de nível α

O teorema 14 vale desde que as desigualdades no teste UMP sejam invertidas, ou seja, um teste UMP para testar

$$H_0: \theta \geq \theta_0 \text{ versus } H_1: \theta < \theta_0$$

é dado por

$$\phi(x) = \begin{cases} 1 & \text{quando } \sum \log x_i > -c \\ 0 & \text{quando } \sum \log x_i \leq -c \end{cases}$$

onde c é determinado upon

$$E_{\theta_0}(\phi(x)) = \alpha$$

mas

$$E_{\theta_0}(\phi(x)) = 1 \times P_{\theta_0}(\sum \log x_i > -c) + 0 \times P_{\theta_0}(\sum \log x_i \leq -c) = \alpha$$

daí,

$$P_{\theta_0}(-\sum \log x_i \leq c) = 1-\alpha$$

$$P_{\theta_0}(\sum \log x_i > -c) = \alpha$$

$$P_{\theta_0}(-20 \sum \log x_i \leq 20c) = 1-\alpha$$

$$1 - P_{\theta_0}(\sum \log x_i \leq -c) = \alpha$$

$$P_{\theta_0}(\sum \log x_i \leq -c) = 1-\alpha$$

$$\Rightarrow (-20 \sum \log x_i \leq 20c) = 1-\alpha$$

De acordo,

$$P(X_{2n}^2 \leq +20c) = 1-\alpha$$

onde $X_{2n}^2 = -20 \sum \log x_i$ representa uma v.a. cl dist χ_{2n}^2

Se qta é o quantil de ordem $1-\alpha$ da distribuição χ_{2n}^2
então $c = +q_{1-\alpha} / 20$

$$q_{1-\alpha} / 20$$

Portanto um teste UMP para testar $H_0: \theta \geq \theta_0$ versus

$H_1: \theta < \theta_0$ de nível α é dado por

$$\phi(x) = \begin{cases} 1 & \text{quando } \sum_{i=1}^{2n} \log x_i > -q_{1-\alpha} / 20 \\ 0 & \text{''} \\ \sum_{i=1}^{2n} \log x_i < -q_{1-\alpha} / 20 \end{cases}$$

(c) Encontre um limite inferior de confiança mais acurado com coeficiente de coeficiente de confiança $1-\alpha$

Suje $\underline{\theta}$ o limite inferior de confiança uniformemente mais acurado para θ c/ coeficiente de confiança $1-\alpha$

Sabemos pelo item (a) que $P_0(\underline{z})$ tem razão de verossimilhanças monótonas em $-\sum_{i=1}^n \log x_i$. Portanto um limite inferior uniformemente mais acurado para θ com coeficiente de confiança $1-\alpha$ é a solução $\underline{\theta}$ da equação

$$P_0\left(-\sum_{i=1}^n \log x_i \leq t\right) = 1-\alpha$$

que é equivalente a

$$P_0\left(-20 \sum \log x_i \leq 20t\right) = 1-\alpha$$

$$P_0(X_{2n}^2 \leq 20t) = 1-\alpha$$

onde $X_{2n}^2 = -20 \sum \log x_i$ é uma v.z. c/dist. χ_{2n}^2 .

Se $q_{1-\alpha}$ é o quartil de ordem $1-\alpha$ da distribuição χ_{2n}^2

então

$$q_{1-\alpha} = 20t \Rightarrow \underline{\theta} = \frac{q_{1-\alpha}}{2t}$$

onde $t = \sum_{i=1}^n \log x_i$

(d) Encontre um limite superior de confiança mais acurado com coeficiente de confiança $1-\alpha$.

Como $P_0(\underline{z})$ tem razão de verossimilhanças monotónas em $-\sum_{i=1}^n \log x_i$, então um limite superior uniformemente mais acurado para θ com coeficiente de confiança $1-\alpha$ é a solução $\bar{\theta}$ da equação

$$P_0\left(-\sum_{i=1}^n \log x_i \geq t\right) = 1-\alpha$$

que é equivalente a

$$P_0\left(-20 \sum \log x_i \geq +20t\right) = 1-\alpha \Leftrightarrow P_0\left(-20 \sum \log x_i < -20t\right) = \alpha$$

$$P(X_{2n}^2 < +20t) = \alpha$$

onde $X_{2n}^2 = -20 \sum \log x_i$ é a v.a. c/dist. χ_{2n}^2 .

Se q_{α} é o quartil de ordem α da distribuição χ_{2n}^2
então

$$\bar{\theta} = \frac{q_{\alpha}}{2t}$$

onde $t = \sum_{i=1}^n \log x_i$

5) Para questão 4, determine uma quantidade pivotal e encontre um intervalo de confiança para θ com coeficiente de confiança $1-\alpha$.

Vimos na questão 4, que a densidade $p_\theta(x)$ tem RVH um $-2\sum_{i=1}^n \log x_i$.

Mais disso, temos ainda da questão anterior que

$$-2\sum_{i=1}^n \log x_i \sim \chi_{2n}^2$$

considere $t_h(x, \theta) = -2\sum_{i=1}^n \log x_i$, temos então que a distribuição de $t_h(x, \theta)$ não depende de θ .

Logo $t_h(x, \theta) = -2\sum_{i=1}^n \log x_i$ é uma quantidade pivotal.

Assim podemos encontrar l_I e l_S , que não dependem de θ , tal que

$$P(l_I \leq t_h(x, \theta) \leq l_S) = 1-\alpha \quad (**)$$

Temos $S(\theta) = \{ \theta : l_I \leq t_h(x, \theta) \leq l_S \}$ é uma região de confiança para $\theta \in \Omega$, pois

$$\theta \in S(\theta) \Leftrightarrow l_I \leq t_h(x, \theta) \leq l_S$$

$$P(\theta \in S(\theta)) = P(l_I \leq t_h(x, \theta) \leq l_S)$$

$$= 1-\alpha$$

↳ por $(**)$

De $(**)$ temos que

$$P[l_I \leq -2\sum_{i=1}^n \log x_i \leq l_S] = 1-\alpha$$

$$P[l_I \leq \chi_{2n}^2 \leq l_S] = 1-\alpha$$

onde $\chi_{2n}^2 = -2\sum_{i=1}^n \log x_i$ é uma v.a. el dist. χ_{2n}^2



mas

$$P[l_I \leq \chi_{2n}^2 \leq l_S] = 1 - \{ P(\chi_{2n}^2 > l_S) + P(\chi_{2n}^2 \leq l_I) \} = 1-\alpha$$

$$\Rightarrow P(\chi_{2n}^2 > l_S) + P(\chi_{2n}^2 \leq l_I) = \alpha$$

$$P(\chi_{2n}^2 > l_S) = \frac{\alpha}{2} \quad \text{e} \quad P(\chi_{2n}^2 \leq l_I) = \frac{\alpha}{2}$$

que é equivalente a

$$P(\chi_{2n}^2 \leq l_S) = 1 - \frac{\alpha}{2} \quad \text{e} \quad P(\chi_{2n}^2 \leq l_I) = \frac{\alpha}{2}$$

se $q_{1-\alpha/2}$ é o quantil de ordem $1-\alpha/2$ da dist. χ_{2n}^2 então

$$l_S = q_{1-\alpha/2}$$

e se $q_{\alpha/2}$ é o quantil de ordem $\alpha/2$ da dist. χ_{2n}^2 então

$$l_I = q_{\alpha/2}$$

tendo de $(**)$

$$P\left[\frac{-l_I}{2\sum \log x_i} \leq \theta \leq \frac{-l_S}{2\sum \log x_i}\right] = 1-\alpha$$



temos $q_{\alpha/2} < q_{1-\alpha/2}$ então um intervalo de confiança para θ

com coeficiente de confiança $1-\alpha$ é dado por

$$\left[\frac{-q_{\alpha/2}}{2\sum \log x_i}; \frac{-q_{1-\alpha/2}}{2\sum \log x_i} \right]$$

observada a amostra x_1, \dots, x_n

6) Sejam x_1, \dots, x_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$.

(a) se $\sigma = \sigma_0$ (conhecido), encontre um teste UMP de nível α para testar $H_0: \mu \leq \mu_0$ contra $H_1: \mu > \mu_0$.

Temos

$$\begin{aligned} p_{H_0}(x) &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \\ &= (2\pi)^{-n/2} \sigma^{-n} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n [x_i^2 - 2\mu x_i + \mu^2]\right\} \\ &= \exp\left\{\frac{n\bar{x}\bar{\mu}}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}\right\} (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{\sum x_i^2}{2\sigma^2}\right\} \\ &= \exp\{\eta(\mu) T(x) - \delta(\mu)\} f(x) \quad \text{pertence a família exponencial} \end{aligned}$$

$$\text{onde } f(x) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{\sum x_i^2}{2\sigma^2}\right\}$$

$$\eta(\mu) = \frac{\partial \eta(\mu)}{\partial \mu} = \bar{x} \quad T(x) = \bar{x}$$

Temos que $\frac{\partial \eta(\mu)}{\partial \mu} = \frac{n}{\sigma^2} > 0 \Rightarrow \eta(\mu)$ é estritamente crescente

Então pelo Corolário 15, temos que um teste UMP para testar

$$H_0: \mu \leq \mu_0 \quad \text{e} \quad H_1: \mu > \mu_0$$

de nível α é dado por

$$\phi(x) = \begin{cases} 1 & \text{quando } T(x) > c \\ \frac{1}{2} & \text{se } T(x) = c \\ 0 & \text{se } T(x) < c \end{cases}$$

mas $p(T(x) = c) = 0$ pois \bar{x} é uma v.a. contínua, então

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > c \\ 0 & \text{se } T(x) \leq c \end{cases}$$

onde c é determinado por

$$E_{H_0}\{\phi(x)\} = \alpha$$

mas

$$E_{H_0}\{\phi(x)\} = 1 \times P_{H_0}(T(x) > c) + 0 \times P_{H_0}(T(x) \leq c) = \alpha$$

Daí

$$P_{H_0}(T(x) > c) = \alpha \iff P_{H_0}(\bar{x} > c) = \alpha$$

Como

$$x_i \sim N(\mu, \sigma^2) \Rightarrow \bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Temos que

$$P_{H_0}(\bar{x} > c) = \alpha \iff P\left(\frac{\bar{x} - \mu_0}{\frac{\sigma_0}{\sqrt{n}}} > \frac{c - \mu_0}{\frac{\sigma_0}{\sqrt{n}}}\right) = \alpha$$

$$\text{fazendo } z = \frac{\bar{x} - \mu_0}{\frac{\sigma_0}{\sqrt{n}}} \text{ então } z \sim N(0, 1) \text{ . Logo}$$

$$P\left(z > \frac{c - \mu_0}{\frac{\sigma_0}{\sqrt{n}}}\right) = \alpha \iff P\left(z \leq \frac{\sqrt{n}(c - \mu_0)}{\sigma_0}\right) = 1 - \alpha$$

Daí, temos

$$\Phi\left(\frac{c - \mu_0}{\sigma_0/\sqrt{n}}\right) = 1 - \alpha$$

$$\text{Logo } z_{1-\alpha} = \frac{c - \mu_0}{\sigma_0/\sqrt{n}} \Rightarrow z_{1-\alpha} = \frac{\sqrt{n}(c - \mu_0)}{\sigma_0}$$

$$\Rightarrow \sqrt{n}c - \sqrt{n}\mu_0 = z_{1-\alpha} \sigma_0 \Rightarrow c = \frac{z_{1-\alpha} \sigma_0 + \sqrt{n}\mu_0}{\sqrt{n}} = \frac{z_{1-\alpha} \sigma_0 + \mu_0}{\sqrt{n}}$$

onde $z_{\alpha/2}$ é o quantil de ordem $1-\alpha$ da distribuição $N(0,1)$.

Portanto o teste UMP de nível α para testar $H_0: \mu \leq \mu_0$ contra $H_1: \mu > \mu_0$ é dado por

$$\phi(x) = \begin{cases} 1 & \text{quando } \bar{x} > \frac{z_{1-\alpha/2}}{\sqrt{n}} + \mu_0 \\ 0 & \text{quando } \bar{x} < \frac{z_{1-\alpha/2}}{\sqrt{n}} + \mu_0 \end{cases}$$

b) Seja H_0 H0 (nula), entretanto um teste UMP da hipótese nula em termos de H_0 : $\alpha \leq \alpha_0$ contra H_1 : $\alpha > \alpha_0$

Termos gerais

$$\begin{aligned} p_{\alpha}(x) &= (2\pi)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2 \right\} \\ &= \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2 - \frac{n}{2} \log \sigma^2 \right\} (2\pi)^{-n/2} \\ &= \exp \left\{ \eta(\alpha^2) T(x) - B(\alpha^2) \right\} t(x) \end{aligned}$$

$$\text{onde } \eta(\alpha^2) = -\frac{1}{2\sigma^2}, \quad T(x) = \sum_{i=1}^n (x_i - \mu_0)^2, \quad B(\alpha^2) = \frac{n}{2} \log \sigma^2$$

$$\therefore t(x) = (2\pi)^{-n/2}$$

Então $p_{\alpha}(x)$ pertence a famílias exponenciais

Termos gerais

$$\frac{\partial \eta(\alpha^2)}{\partial \alpha^2} = \frac{1}{2\sigma^4} > 0 \Rightarrow \eta(\alpha^2) \text{ é estritamente crescente}$$

termos gerais constantes 10, termos que um teste UMP para $H_0: \alpha \leq \alpha_0$ contra $H_1: \alpha > \alpha_0$ é dado por

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > c \\ \infty & \text{se } T(x) = c \\ 0 & \text{se } T(x) < c \end{cases}$$

mas $P(T(x) = c) = 0$ queremos $T(x) - \mu_0$ é uma v.a. contínua

então

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > c \\ 0 & \text{se } T(x) \leq c \end{cases}$$

onde c é determinado pela $E_{\alpha_0}(\phi(x)) = \alpha$

mas, $E_{\alpha_0}(\phi(x)) = P_{\alpha}(T(x) > c) = \alpha$

Então

$$X_n \sim N(\mu_0, \sigma^2) \Rightarrow Z_n = \frac{X_n - \mu_0}{\sigma} \sim N(0, 1)$$

então

$$Z_n^2 \sim \chi_n^2$$

$$\text{então } \sum_{i=1}^n Z_i^2 \sim \chi_n^2, \text{ ou seja, } \frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\sigma^2} \sim \chi_n^2$$

Termos gerais

$$P_{\alpha_0}(T(x) > c) = \alpha \Leftrightarrow P \left[\frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\sigma^2} > \frac{c}{\sigma^2} \right] = \alpha$$

$$\Leftrightarrow P \left[\frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\sigma^2} < \frac{c}{\sigma^2} \right] = 1 - \alpha$$

$$P \left(\chi_n^2 \leq \frac{c}{\sigma^2} \right) = 1 - \alpha$$

$$\text{onde } \chi_n^2 = \frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\sigma^2} \text{ é uma v.a. el. dist. } \chi_n^2$$

Se $q_{1-\alpha}$ é o quantil de ordem $1-\alpha$ da distribuição χ_n^2 então

$$q_{1-\alpha} = \frac{c}{\sigma^2} \Rightarrow c = \sigma^2 q_{1-\alpha}$$

Portanto o teste UMP de nível α para testar $H_0: \alpha \leq \alpha_0$ contra $H_1: \alpha > \alpha_0$ é dado por

$$\phi(x) = \begin{cases} 1 & \text{se } \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2 > \sigma^2 q_{1-\alpha} \\ 0 & \text{se } \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2 \leq \sigma^2 q_{1-\alpha} \end{cases}$$

7) Sejam x_i variáveis aleatórias independentes com distribuição $N(d_i\theta, 1)$
 $d_i \neq 0$, $i = 1, \dots, n$. Encontre um teste UMP de $H_0: \theta \leq \theta_0$ versus $H_1: \theta > \theta_0$
de nível α .

Termos

$$\varphi_{\theta}(z) = \frac{1}{(\sqrt{2\pi})^n} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (x_i - d_i\theta)^2 \right\}$$

$$\begin{aligned} \frac{\varphi_{\theta_1}(z)}{\varphi_{\theta_0}(z)} &= \exp \left\{ -\frac{1}{2} \sum (x_i - d_i\theta_1)^2 + \frac{1}{2} \sum (x_i - d_i\theta_0)^2 \right\} \\ &= \exp \left\{ \frac{1}{2} \left[\sum_{i=1}^n (x_i^2 - 2x_i d_i \theta_0 + d_i^2 \theta_0^2 - x_i^2 + 2x_i d_i \theta_1 - d_i^2 \theta_1^2) \right] \right\} \\ &= \exp \left\{ \frac{1}{2} \left[\sum_{i=1}^n \left(2x_i d_i (\theta_1 - \theta_0) + d_i^2 (\theta_0^2 - \theta_1^2) \right) \right] \right\} \\ &= \exp \left\{ \frac{1}{2} \left[2(\theta_1 - \theta_0) \sum_{i=1}^n x_i d_i + (\theta_0^2 - \theta_1^2) \sum_{i=1}^n d_i^2 \right] \right\} \end{aligned}$$

se $\theta_1 > \theta_0 \Rightarrow (\theta_1 - \theta_0) > 0$ então

$\frac{\varphi_{\theta_1}(z)}{\varphi_{\theta_0}(z)}$ é uma função crescente em $\sum x_i d_i$.

Termos que $\varphi_{\theta}(z)$ tem RVM em $\sum x_i d_i$

Pelo teorema da um teste UMP para testar

$$H_0: \theta \leq \theta_0 \text{ versus } H_1: \theta > \theta_0$$

de nível α é dado por

$$\phi(x) = \begin{cases} 1 & \text{quando } \sum x_i d_i > c \\ 0 & \text{quando } \sum x_i d_i \leq c \end{cases}$$

onde c é determinado por

$$E_{\theta_0}(\phi(X)) = c$$

mas

$$E_{\theta_0}(\phi(X)) = P_{\theta_0}\left(\sum d_i x_i > c\right) = \alpha$$

$$\Leftrightarrow P_{\theta_0}\left(\sum d_i x_i \leq c\right) = 1-\alpha$$

Termos

$$x_i \sim N(d_i\theta, 1)$$

$$\Rightarrow d_i x_i \sim N(d_i^2 \theta, d_i^2)$$

então $\sum d_i x_i \sim N(\theta \sum d_i^2, \sum d_i^2)$ pois

$$E[\sum d_i x_i] = \sum d_i E(x_i) = \sum d_i d_i \theta = \theta \sum d_i^2 \in$$

$$\text{var}(\sum d_i x_i) = \sum d_i^2 \text{var} x_i = \sum d_i^2$$

daí, termos

$$\frac{\sum d_i x_i - \theta \sum d_i^2}{\sqrt{\sum d_i^2}} \sim N(0, 1)$$

Logo

$$P_{\theta_0}\left(\sum d_i x_i \leq c\right) = 1-\alpha \Leftrightarrow P_{\theta_0}\left(N(0, 1) \leq \frac{c - \theta \sum d_i^2}{\sqrt{\sum d_i^2}}\right) = 1-\alpha$$

$$\Rightarrow \Phi\left(\frac{c - \theta \sum d_i^2}{\sqrt{\sum d_i^2}}\right) = 1-\alpha. \text{ Se } q_{1-\alpha} \text{ é o quantil de}$$

ordem $1-\alpha$ da $N(0, 1)$ então

$$q_{1-\alpha} = \frac{c - \theta \sum d_i^2}{\sqrt{\sum d_i^2}} \Rightarrow c = q_{1-\alpha} \sqrt{\sum d_i^2} + \theta \sum d_i^2$$

Portanto

$$\phi(x) = \begin{cases} 1 & \text{quando } \sum d_i x_i > q_{1-\alpha} \sqrt{\sum d_i^2} + \theta \sum d_i^2 \\ 0 & \text{quando } \sum d_i x_i \leq q_{1-\alpha} \sqrt{\sum d_i^2} + \theta \sum d_i^2 \end{cases}$$

8) Sejam x_1, \dots, x_n uma amostra aleatória de uma distribuição $N(\mu, \sigma^2)$.
Encontre quantidades pivotais adequadas e obtenha intervalos de confiança com coeficiente de confiança $1-\alpha$ para μ e para σ^2 .

Sabemos que

$$x_i \sim N(\mu, \sigma^2)$$

Daí $\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \Rightarrow \bar{x} - \mu \sim N\left(0, \frac{\sigma^2}{n}\right)$

então $\frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$

Logo uma quantidade pivotal seria

$$t(\bar{x}, \mu, \sigma) = \frac{\sqrt{n}(\bar{x} - \mu)}{\sigma}$$

pois a distribuição de $t(\bar{x}, \mu, \sigma)$ não depende dos parâmetros $\sigma < \mu$.

→ Intervalo de confiança corr. coef de conf. $1-\alpha$ para σ^2

se caso) quando σ^2 é desconhecido

Podemos definir outras quantidades pivotais, com por exm
plo

$$t_1(\bar{x}, \sigma^2) = \frac{\sum(x_i - \bar{x})^2}{\sigma^2} \sim \chi^2_{n-1}$$

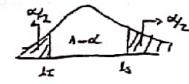
pois a distribuição de $t_1(\bar{x}, \sigma^2)$ não depende de σ^2 .

Daí, temos

$$P(l_I \leq t_1(\bar{x}, \sigma^2) \leq l_S) = 1-\alpha$$

$$\Rightarrow P(l_I \leq \frac{\sum(x_i - \bar{x})^2}{\sigma^2} \leq l_S) = 1-\alpha$$

$$P\left(\frac{l_I}{\sum(x_i - \bar{x})^2} \leq \frac{1}{\sigma^2} \leq \frac{l_S}{\sum(x_i - \bar{x})^2}\right) = 1-\alpha$$



$$P\left(\frac{\sum(x_i - \bar{x})^2}{l_S} \leq \sigma^2 \leq \frac{\sum(x_i - \bar{x})^2}{l_I}\right) = 1-\alpha$$

então um intervalo de confiança para σ^2 com coeficiente de confiança $1-\alpha$ é dado por

$$\left[\frac{\sum(x_i - \bar{x})^2}{l_S}, \frac{\sum(x_i - \bar{x})^2}{l_I} \right]$$

onde l_S é o quantil $\frac{\alpha}{2} + (1-\alpha)$ da χ^2_{n-1} e l_I é o quantil $\frac{\alpha}{2}$
da χ^2_{n-1}

2º caso) quando σ^2 é conhecido

neste caso considere a quantidade pivotal

$$t_2(\bar{x}, \sigma^2) = \frac{\sum(x_i - \bar{x})^2}{\sigma^2} \sim \chi^2_n$$

Daí, temos

$$P(l_I \leq t_2(\bar{x}, \sigma^2) \leq l_S) = 1-\alpha$$

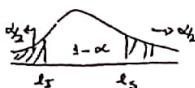
$$P(l_I \leq \frac{\sum(x_i - \bar{x})^2}{\sigma^2} \leq l_S) = 1-\alpha$$

$$P\left(\frac{l_I}{\sum(x_i - \bar{x})^2} \leq \frac{1}{\sigma^2} \leq \frac{l_S}{\sum(x_i - \bar{x})^2}\right) = 1-\alpha$$

$$P\left(\frac{\sum(x_i - \bar{x})^2}{l_S} \leq \sigma^2 \leq \frac{\sum(x_i - \bar{x})^2}{l_I}\right) = 1-\alpha$$

Logo o intervalo de confiança para σ^2 é

$$\left[\frac{\sum (x_i - \bar{x})^2}{l_1}; \frac{\sum (x_i - \bar{x})^2}{l_2} \right]$$



onde l_1 é o quantil $\frac{\alpha}{2}$ e l_2 é o quantil $\frac{\alpha}{2} + 1 - \alpha$ da χ^2_{n-2}

→ Intervalo de confiança com coeficiente de confiança $1-\alpha$ para μ .

1º caso) Quando μ é conhecido

considere a quantidade pivotal

$$t_3(\bar{x}, \mu) = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$$

Dai, temos

$$P\left(l_1 < \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} < l_2\right) = 1 - \alpha \iff P\left(l_1 < \frac{\sqrt{n}(\bar{x} - \mu)}{\sigma} < l_2\right) = 1 - \alpha$$

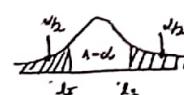
$$P\left(\frac{\sigma l_1}{\sqrt{n}} < \bar{x} - \mu < \frac{\sigma l_2}{\sqrt{n}}\right) = 1 - \alpha$$

$$P\left(-\frac{\sigma l_2}{\sqrt{n}} < \mu - \bar{x} < -\frac{\sigma l_1}{\sqrt{n}}\right) = 1 - \alpha$$

$$P\left(\bar{x} - \frac{\sigma l_2}{\sqrt{n}} < \mu < \bar{x} - \frac{\sigma l_1}{\sqrt{n}}\right) = 1 - \alpha$$

Logo o intervalo de confiança para μ é

$$\left[\bar{x} - \frac{\sigma l_2}{\sqrt{n}}; \bar{x} - \frac{\sigma l_1}{\sqrt{n}} \right]$$



onde

l_1 é o quantil $\frac{\alpha}{2}$ da distribuição $N(0,1)$



l_2 é o quantil $\frac{\alpha}{2} + 1 - \alpha$ da dist. $N(0,1)$

2º caso) Quando μ é desconhecido

considere a quantidade pivotal

$$t_4(\bar{x}, \mu) = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}} \sqrt{\frac{\sum (x_i - \bar{x})^2}{(n-1)\sigma^2}}}$$

$$\text{pois } \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1) \quad \text{e} \quad \frac{\sum (x_i - \bar{x})^2}{\sigma^2} \sim \chi^2_{n-1}$$

então

$$t_4(\bar{x}, \mu) = \frac{\sqrt{n}(\bar{x} - \mu)}{\sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}}} \sim t_{n-1}^2$$

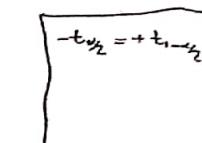
$$\text{mas } S^2 = \frac{\sum (x_i - \bar{x})^2}{n-1} \quad \text{então}$$

$$t_4(\bar{x}, \mu) = \frac{\sqrt{n}(\bar{x} - \mu)}{\sqrt{S^2}} = \frac{(\bar{x} - \mu)}{S/\sqrt{n}}$$

dai

$$P\left(t_{n-1, \alpha/2} < \frac{\sqrt{n}(\bar{x} - \mu)}{S} < t_{n-1, 1-\alpha/2}\right) = 1 - \alpha$$

$$P\left(\bar{x} - t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}} < \mu < \bar{x} + t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}\right) = 1 - \alpha$$



9) Sejam x_1, \dots, x_n forma amostra aleatória de variação descontínua
U(0,1)

(a) Mostre que, para testar $H_0: \theta = \theta_0$ contra $H_1: \theta > \theta_0$, quando
este para o qual $\phi_0(x) = \alpha$, $\phi_1(\phi_0(x)) \geq \alpha$, quando $\theta < \theta_0 \Rightarrow$
 $\phi(x) \leq 1$, quando $\max(x_1, \dots, x_n) > \theta_0$, é UMP da nível α .
Sugestão: use o teorema de Neyman-Pearson, com $(\theta_0/\theta)^n = k$.

Temos que

$$\phi_0(x) = \frac{1}{n} I_{(0,\theta_0)}^{(x)}$$

$$\text{então, } \phi_1(x) = \frac{1}{n} \prod_{i=1}^n I_{(0,\theta_0)}^{(x_i)} = \theta^{-n} I_{(0,\theta_0)}^{(x)}$$

Pelo teorema de Neyman-Pearson queremos que um teste $\phi(x)$ UMP
basta que $\phi(x)$ satisfaça (1) e (2), ou seja,

$$\begin{aligned} \phi(x) &= \begin{cases} 1 & \text{quando } \phi_1(x) > k \phi_0(x) \quad (1) \\ 0 & \text{quando } \phi_1(x) = k \phi_0(x) \quad (2) \\ 0 & \text{quando } \phi_1(x) < k \phi_0(x) \quad (3) \end{cases} \\ \Leftrightarrow E_{\theta_0}(\phi(x)) &= \alpha \quad (2) \end{aligned}$$

→ Verificar (2)

(a)

Usando a sugestão faça $k = \left(\frac{\theta_0}{\theta_1}\right)^n$ então

$$\phi_1(x) > k \phi_0(x) \Leftrightarrow \frac{1}{n} I_{(0,\theta_1)}^{(x)} > \left(\frac{\theta_0}{\theta_1}\right)^n \frac{1}{n} I_{(0,\theta_0)}^{(x)}$$

$$\Leftrightarrow I_{(0,\theta_1)}^{(x)} > I_{(0,\theta_0)}^{(x)} \quad (*)$$

ou seja, $x_{(1)} < \theta_1 \leq x_{(n)} > \theta_0$ (para que a igualdade $(*)$ seja satisfeita)

como $x_{(n)} > \theta_0$ então (por hipótese) $\phi(x) = 1$.

Portanto $\phi(x) = 1$ quando $\phi_1(x) > \phi_0(x)$

(c)

$\phi_1(x) < k \phi_0(x) \Leftrightarrow I_{(0,\theta_1)}^{(x)} < I_{(0,\theta_0)}^{(x)}$

mas isto não pode ocorrer para $\theta_0 < \theta_1$ então

$$\phi_1(x) < k \phi_0(x) = 0$$

então

$$(b) \exists \eta_0(x) = k \phi_0(x) \Leftrightarrow I_{(0,\theta_0)}^{(x)} = I_{(0,\theta_0)}^{(x)}$$

$$\Leftrightarrow (x_{(1)} < \theta_0 & x_{(n)} > \theta_0) \text{ ou } (x_{(1)} > \theta_0 & x_{(n)} < \theta_0)$$

Se $x_{(1)} < \theta_0 & x_{(n)} > \theta_0$

se $x_{(n)} < \theta_0$

Se $x_{(1)} > \theta_0 & x_{(n)} > \theta_0$

mas isto não pode ocorrer para $x_{(1)} \in (0, \theta_0)$ ou $x_{(n)} \in (\theta_0, 1)$
nunca para $x_{(1)} > \theta_0 & x_{(n)} > \theta_0$

Portanto (2) é válido - Temos que (2) é válido por hipótese

então $\phi(x) = 0$ se não satisfece

Então $\phi(x) = 1$ se $\phi_1(x) > \phi_0(x)$ e vice-versa

$$\Leftrightarrow \phi(x) = 0 \text{ ou } 1$$

9

(a) $H: \theta \leq \theta_0$ que mif $\phi(x) = L$ se $x_{(n)} > \theta_0$ qd $E_\theta(\phi(x)) \leq L$ $\forall \theta \leq \theta_0$
 $K: \theta > \theta_0$ $\therefore E_\theta(\phi(x)) = \infty$ UMP de nul ω .

1) Considera
 $H^*: \theta = \theta_0$ $\quad \omega \cap \theta = \theta_0 \quad (\theta_1 > \theta_0)$

Para todo $x_i: i=1, \dots, n$ $0 < x_i < \theta_2$:
 $p_1(x) > K p_0(x) \Leftrightarrow I_{(0, \theta_1)}(x_{(n)}) > I_{(0, \theta_0)}(x_{(n)}) \Leftrightarrow x_{(n)} > \theta_0$
 $R: \left(\frac{\theta_1}{\theta_0}\right)^n$
 $p_1(x) \leq K p_0(x) \Leftrightarrow I_{(0, \theta_1)}(x_{(n)}) \leq I_{(0, \theta_0)}(x_{(n)}) \Leftrightarrow \theta_1 \leq x_{(n)} \leq \theta_0$
 $\{x: I_{(0, \theta_1)}(x_{(n)}) < I_{(0, \theta_0)}(x_{(n)})\} \subset \text{vazio}$
 $p_1(x) = K p_0(x) \Leftrightarrow I \Leftrightarrow x_{(n)} = \theta_0 < \theta_1$

Teste MP de H^* contra K^* é:

$$\phi(x) = \begin{cases} 1 & \text{se } x_{(n)} > \theta_0 \\ 0 & \text{se } x_{(n)} \leq \theta_0 \end{cases}$$

2) O teste ϕ é + poder de H^* cont $K^*: \theta = \theta_0$
 qq $\theta_1 > \theta_0$ - entorno de ω UMP de H^* contra $K: \theta > \theta_0$

3) Sabemos que $E_\theta(\phi(x)) \leq L \quad \forall \theta \leq \theta_0$ então
 O teste ϕ é UMP de H cont K .

b) Mostre que, para testar $H_0: \theta = \theta_0$ versus $H_1: \theta \neq \theta_0$, o teste $\phi(x)$ é UMP.

$\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$ ou $\max(x_1, \dots, x_n) \leq \theta_0 e^{1/n}$

$\phi(x) = 0$, caso contrário, é UMP.

Sugestão: considere separadamente 3 situações: (i) $H_0: \theta = \theta_0 \times H_1: \theta = \theta_1 < \theta_0$
(ii) $H_0: \theta = \theta_0 \times H_1: \theta = \theta_1, \theta_0 e^{1/n} < \theta_1 < \theta_0$; (iii) $H_0: \theta = \theta_0 \times H_1: \theta = \theta_1 \leq \theta_0 e^{1/n}$

$$\phi(x) = \begin{cases} 1 & \text{quando } x_{(n)} > \theta_0 \text{ ou } x_{(n)} \leq \theta_0 e^{1/n} \\ 0 & \text{caso contrário} \end{cases} \quad (*)$$

Considerando as três situações da sugestão:

(i) $H_0: \theta = \theta_0$ contra $H_1: \theta = \theta_1 > \theta_0$

Pela definição de UMP, temos que $\phi(x)$ é UMP.

$$\begin{cases} 1, & x_{(n)} > \theta_0 \\ 0, & \text{medida} \end{cases}$$

(ii) $H_0: \theta = \theta_0$ contra $H_1: \theta = \theta_1, \theta_0 e^{1/n} < \theta_1 < \theta_0$

$$\text{faz } K = \left(\frac{\theta_0}{\theta_1}\right)^n$$

$$I_{(0, \theta_1)}(x_{(n)}) > I_{(0, \theta_0)}(x_{(n)}) \Leftrightarrow x_{(n)} < \theta_1 \Leftrightarrow x_{(n)} > \theta_0 \Leftrightarrow \theta_0 < x_{(n)} < \theta_1$$

mas, por H_1 , temos que $\theta_1 < \theta_0$, daí

$p_1(x) > k p_0(x)$ não pode ocorrer, ou seja,

$$\begin{cases} 1, & p_1(x) > k p_0(x) \\ 0, & \text{medida} \end{cases}$$

$$p_1(x) < k p_0(x) \Leftrightarrow I_{(0, \theta_1)}(x_{(n)}) < I_{(0, \theta_0)}(x_{(n)}) \Leftrightarrow x_{(n)} > \theta_1 + x_{(n)} e^{-\theta_0}$$

$\Leftrightarrow \theta_1 < x_{(n)} < \theta_0$; por H_1 , temos que

$$\theta_0 e^{1/n} < \theta_1 < \theta_0$$

então $\theta_0 e^{1/n} < \theta_1 < x_{(n)} < \theta_0$

Portanto $p_1(x) < k p_0(x) \Leftrightarrow \theta_0 e^{1/n} < x_{(n)} < \theta_0$

Pelo LNP, temos $\phi(x) = 0$ se $p_1(x) < k p_0(x)$ então $\phi(x) = 0$ se $\theta_0 e^{1/n} < x_{(n)} < \theta_0$

(iii) $H_0: \theta = \theta_0$ contra $H_1: \theta = \theta_1 \leq \theta_0 e^{1/n}$

$$\text{considere } K = \left(\frac{\theta_0}{\theta_1}\right)^n \quad \begin{array}{c} 1 \\ \hline \theta_0 e^{1/n} & \theta_1 \\ \hline \theta_0 \end{array} \quad \theta_1 < \theta_0$$

$$p_1(x) > k p_0(x) \Leftrightarrow I_{(0, \theta_1)}(x_{(n)}) > I_{(0, \theta_0)}(x_{(n)}) \Leftrightarrow \theta_0 < x_{(n)} < \theta_1$$

isto não pode ocorrer visto que $\theta_1 < \theta_0$ então

$$\begin{cases} 1, & p_1(x) > k p_0(x) \\ 0, & \text{medida} \end{cases}$$

$$p_1(x) < k p_0(x) \Leftrightarrow I_{(0, \theta_1)}(x_{(n)}) < I_{(0, \theta_0)}(x_{(n)}) \Leftrightarrow \theta_1 < x_{(n)} < \theta_0$$

mais valecer-se se $x_{(n)}$ é menor que $\theta_0 e^{1/n}$ ou maior que $\theta_0 e^{1/n}$
então não se pode obter uso $\phi(x) = 1$ ou uso $\phi(x) = 0$, assim

$$K = \left(\frac{\theta_0}{\theta_1}\right)^n$$

Portanto podemos considerar $K = 0$

$$p_1(x) > k p_0(x) \Leftrightarrow \frac{1}{\theta_1^n} I_{(0, \theta_1)}(x_{(n)}) > 0 \times \frac{1}{\theta_0^n} I_{(0, \theta_0)}(x_{(n)}) = 0$$

$$\Rightarrow I_{(0, \theta_1)}(x_{(n)}) > 0 \Leftrightarrow 0 < x_{(n)} < \theta_1 \text{ mas por } H_1 \quad \theta_1 \leq \theta_0 e^{1/n}$$

então $x_{(n)} \leq \theta_0 e^{1/n}$. Pelo LNP $\phi(x) = 1$ se $p_1(x) > k p_0(x)$ mas

$p_1(x) > k p_0(x) \Leftrightarrow x_{(n)} \leq \theta_0 e^{1/n}$ então $\phi(x) = 1$ se $x_{(n)} \leq \theta_0 e^{1/n}$

$$p_1(x) < k p_0(x) \Leftrightarrow p_1(x) < 0 \Leftrightarrow I_{(0, \theta_1)}(x_{(n)}) < 0$$

mas $I_{(0, \theta_1)}(x_{(n)})$ não pode assumir valores 0 ou 1. O que implica
que $p_1(x) < k p_0(x)$ não pode ocorrer, ou seja,

$$\begin{cases} 1, & p_1(x) < k p_0(x) \\ 0, & \text{medida} \end{cases}$$

Portanto verificamos (i) (definido em a) basta verificar (ii)

$$\begin{aligned}
 E_{\theta_0}(\phi(x)) &= P(X_{(1)} < \theta_0 \alpha^{1/n}) + \underbrace{P(X_{(n)} > \theta_0)}_{0 \text{ pois quando } X_{(n)} > \theta_0 \quad p_\theta(x) > k_{\theta_0}(x)} \\
 &= P(X_{(1)} < \theta_0 \alpha^{1/n}) \\
 &= \prod_{i=1}^n P(X_i \leq \theta_0 \alpha^{1/n}) \\
 &= \prod_{i=1}^n F_{X_i}(\theta_0 \alpha^{1/n})
 \end{aligned}$$

mas

$$F_X(z) = \int_0^z \frac{1}{\theta} dt = \frac{1}{\theta} t \Big|_0^z = \frac{z}{\theta}, \text{ se } z = \alpha^{1/n} \theta_0 \Rightarrow \frac{z}{\theta_0} = \alpha^{1/n}$$

$$\Rightarrow F_{X_i}(\theta_0 \alpha^{1/n}) = \alpha^{1/n} \quad \text{então}$$

$$E_{\theta_0}(\phi(x)) = \prod_{i=1}^n \alpha^{1/n} = (\alpha^{1/n})^n = \alpha$$

então (2) é válido. Portanto $\phi(x)$ é um teste HP

Basta $\Omega_{H_0} = \{\theta_0\}$ ser que

$$E_\theta(\phi(x)) = \alpha \leq \alpha \quad \forall \theta \in \Omega_{H_0} = \{\theta_0\}$$

Logo $\phi(x)$ é UHP

Unicidade: Suponha que existe outro teste $\gamma(x)$ UHP e como

$\Omega_{H_0} = \{\theta_0\}$ então $E_{\theta_0}(\gamma(x)) = \alpha \quad \forall \theta \in \Omega_{H_0}$ (pois de ϵ mais poderoso)

Sabemos que $E_{\theta_0}(\phi(x)) = \alpha$ então

$$E_{\theta_0}(\gamma(x)) - E_{\theta_0}(\phi(x)) = \alpha - \alpha = 0$$

ou

$$\gamma(x) = \phi(x) \quad q.c. = \theta_0$$

Portanto $\phi(x)$ é único teste UMP q.c. θ_0

10) Siga $x = (x_1, \dots, x_n)$ um vetor de n v.r.a. independentes e i.i. distrito $U(0, \theta)$

$\theta > 0$.

(a) mostre que o teste ϕ tal que

$$\phi(x) = \begin{cases} 1 & \text{se } \max\{|x_1|, \dots, |x_n|\} > \theta_0 \\ 0 & \text{c.c.} \end{cases}$$

é UMP de nível α para testar $H_0: \theta = \theta_0$ contra $H_1^*: \theta > \theta_0$.

considere inicialmente as hipóteses $H_0: \theta = \theta_0$ contra $H_1^*: \theta = \theta_1, \theta_1 > \theta_0$

pelo LNP vai um teste uotativo

$$E_{\theta_0}(\phi(x)) = \alpha$$

$$\phi(x) = \begin{cases} 1 & \text{quando } p_1(x) > k p_0(x) \\ 0 & \text{quando } p_1(x) = k p_0(x) \\ & \text{ou quando } p_1(x) < k p_0(x) \end{cases}$$

então da LNP p/ testar H_0 contra H_1^* de nível α .

Se $x_i \in (0, \theta)$ $\Rightarrow |x_i| \in (0, \theta)$ - Siga $y_{(n)} = \max(|x_1|, \dots, |x_n|)$

notamos que $f(x) = \frac{1}{2\theta} I_{(0,\theta)}(x)$ então

$$P(|x_i| < x) = P(-x < x_i < x) = \int_x^{-x} \frac{1}{2\theta} dx_i = \frac{x}{2\theta} \Big|_{-x}^x = \frac{x}{\theta}, \quad 0 < x < \theta$$

$$\Rightarrow f_{|x_i|}(x) = \frac{1}{\theta}, \quad 0 < x < \theta$$

$$\therefore |x_i| \sim U(0, \theta), \quad \text{ou seja, } Y_i \sim U(0, \theta)$$

$$\text{Dá, } P_{\theta_0}(Y_{(n)} \leq \theta_0) = \prod_{i=1}^n P_{\theta_0}(|x_i| \leq \theta_0) = \left[P_{\theta_0}(Y \leq \theta_0) \right]^n = \left[\int_0^{\theta_0} \frac{1}{\theta_0} dy \right]^n = \left[\frac{\theta_0}{\theta_0} \right]^n = 1$$

então

$$E_{\theta_0}(\phi(x)) = P_{\theta_0}(Y_{(n)} > \theta_0) + \alpha P_{\theta_0}(Y_{(n)} \leq \theta_0) = \alpha P_{\theta_0}(Y_{(n)} > \theta_0) = \alpha$$

$$\therefore E_{\theta_0}(\phi(x)) = \alpha$$

$$1) \phi(x) = 1 \quad \text{se } Y_{(n)} > \theta_0$$

temos que $p_1(|x|) = \theta_1^{-n} I_{(0,\theta_1)}(y_{(n)})$ e $p_0(|x|) = \theta_0^{-n} I_{(0,\theta_0)}(y_{(n)})$

onde $|x| = (|x_1|, \dots, |x_n|)$. logo $K = \left(\frac{\theta_0}{\theta_1}\right)^n$

Portanto

$$p_1(|x|) > K p_0(|x|) \Leftrightarrow I_{(0,\theta_1)}(y_{(n)}) > K I_{(0,\theta_0)}(y_{(n)}) \Leftrightarrow \theta_0 < y_{(n)} < \theta_1$$

Portanto

$$\phi(x) = 1 \quad \text{quando } p_1(|x|) > K p_0(|x|)$$

$$2) \phi(x) = 1 \quad \text{se } 0 < y_{(n)} < \theta_0$$

mas

$$p_1(|x|) = K p_0(|x|) \Leftrightarrow I_{(0,\theta_1)}(y_{(n)}) = K I_{(0,\theta_0)}(y_{(n)}) \Leftrightarrow 0 < y_{(n)} < \theta_0$$

$$\text{jogo } p_1(|x|) = K p_0(|x|) \Leftrightarrow y_{(n)} \in (0, \theta_0)$$

Portanto

$$\phi(x) = 1 \quad \text{se } p_1(|x|) = K p_0(|x|)$$

$$p_1(|x|) = K p_0(|x|) \Leftrightarrow I_{(0,\theta_1)}(y_{(n)}) < K I_{(0,\theta_0)}(y_{(n)}) \Leftrightarrow \theta_1 < y_{(n)} < \theta_0$$

absurdo.

$$\text{Então } \phi(x) = \begin{cases} 1 & \text{se } y_{(n)} > \theta_0 \\ 0 & \text{c.c.} \end{cases} \quad \text{é um teste MP para}$$

testar H_0 contra $H_1^*: \theta = \theta_1$ qualquer que seja $\theta_1 > \theta_0$. Portanto
é UMP para testar H_0 contra H_1^* .

(b) concentre a função de poder do teste ϕ

A função poder é dada por

$$\beta_\phi(\theta) = E_{\theta_1} \{ \phi(X) \}$$

$$= P_{\theta_1} \{ Y_{(n)} > \theta_0 \} + \alpha P_{\theta_1} \{ Y_{(n)} \leq \theta_0 \}$$

$$= 1 - P_{\theta_0} \{ Y_{(n)} \leq \theta_0 \} + \alpha P_{\theta_0} \{ Y_{(n)} \leq \theta_0 \}$$

$$= 1 - (1-\alpha) P_{\theta_0} \{ Y_{(n)} \leq \theta_0 \}$$

$$\text{mas } P_{\theta_0} \{ Y_{(n)} \leq \theta_0 \} = \left[P_{\theta_0} (Y \leq \theta_0) \right]^n$$

$$= \left[\int_0^{\infty} \frac{1}{\theta_0} I_{(0,\theta_0)}(y) dy \right]^n \quad \text{pois } Y \sim U(0, \theta)$$

$$= \left[\frac{y}{\theta_0} \Big|_0^{\theta_0} \right]^n = \left(\frac{\theta_0}{\theta_0} \right)^n$$

Logo

$$\boxed{\beta_\phi(\theta) = 1 - (1-\alpha) \left(\frac{\theta_0}{\theta_1} \right)^n}$$

11) Admita que a densidade $p_\theta(x)$ de X tem RVM em $T(x)$ e considere o problema de testar $H_0: \theta \leq \theta_0$ contra $H_1: \theta > \theta_0$. Se a distribuição de T é contínua, mostre que o nível descriptivo (valor α) do teste UMP é dado por $\hat{\alpha} = P_{\theta_0}(T \geq t)$ onde t é o valor observado de T . Mostre que este resultado também vale sem a suposição de continuidade de T , para testes aleatorizados, isto é, definido como o menor nível de significância para o qual a hipótese H_0 é rejeitada com probabilidade 1.

Como $p_\theta(x)$ tem RVM em $T(x)$ então existe teste UMP, para testar $H_0: \theta \leq \theta_0$ contra $H_1: \theta > \theta_0$ dado por

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > c_\alpha \\ \frac{1}{2} & \text{se } T(x) = c_\alpha \\ 0 & \text{se } T(x) < c_\alpha \end{cases} \Leftrightarrow \phi(x) = \begin{cases} 1 & \text{se } T(x) \geq c_\alpha \\ 0 & \text{se } T(x) < c_\alpha \end{cases}$$

\hookrightarrow para continuidade

onde c é determinado por

$$E_{\theta_0} (\phi(x)) = \alpha$$

que é equivalente a

$$P_{\theta_0} (T(x) \geq c_\alpha) = \alpha$$

Sabemos que

$$\hat{\alpha} = \inf \{ \alpha : x \in S_\alpha \} \quad (*)$$

onde S_α região de rejeição

para ter o menor α , dado em (*), temos que c_α deve crescer e isso acontece quando $c_\alpha = t$.



12) Sejam x_1, \dots, x_n v.a. independentes, cada qual com distribuição $\text{r}(q, b)$. Mostre que existe um teste UMP para testar

$H_0: b \leq b_0$ contra $H_1: b > b_0$, quando g é contínua.

Sabemos que

$$\begin{aligned} P_{b_0}(x) &= \prod_{i=1}^n \frac{1}{\Gamma(q)b^q} x_i^{q-1} e^{-x_i/b} \\ &= (n(q)b^q)^{-n} \prod_{i=1}^n x_i^{q-1} \exp\left\{-\frac{1}{b} \sum x_i\right\} \\ &= \exp\left\{-n \log n(q) - n \log b - \frac{1}{b} \sum x_i\right\} \prod_{i=1}^n x_i^{q-1} \\ &= \exp\left\{-\frac{\sum x_i}{b} - n \log b\right\} \exp\{-n \log n(q)\} \prod_{i=1}^n x_i^{q-1} \\ &= \exp\{\eta(b) T(x) - B(b)\} h(x) \quad \text{é fom. exp.} \end{aligned}$$

$$\text{orden } \eta(b) = -\frac{1}{b}, \quad T(x) = \sum x_i, \quad B(b) = n \log b + \frac{n}{b}$$

$$h(x) = \exp\{-n \log n(q)\} \prod_{i=1}^n x_i^{q-1}$$

Sabemos que $\frac{\partial \eta(b)}{\partial b} = \frac{1}{b^2} > 0 \Rightarrow \eta(b)$ é estritamente crescente

Sabemos que $\frac{\partial \eta(b)}{\partial b} = \frac{1}{b^2} > 0 \Rightarrow \eta(b)$ é estritamente crescente

$H_0: b \leq b_0$ contra $H_1: b > b_0$

de nível α é dado por

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > c \\ \frac{1}{2} & \text{se } T(x) = c \\ 0 & \text{se } T(x) < c \end{cases}$$

mas $P(T(x) = c) = 0$ por $T(x)$ é uma v.a. contínua

então

$$\phi(x) = \begin{cases} 1 & \text{se } \sum x_i > c \\ 0 & \text{se } \sum x_i \leq c \end{cases}$$

onde c é determinado por

$$E_{b_0}\{\phi(x)\} = \alpha$$

mas

$$E_{b_0}\{\phi(x)\} = 1 \times P_{b_0}(\sum x_i > c) + 0 \times P_{b_0}(\sum x_i \leq c) = \alpha$$

Logo

$$P_{b_0}(\sum x_i > c) = \alpha$$

Sabemos que

$$x_i \sim \text{Gamma}(q, b)$$

$$\sum x_i \sim \text{Gamma}(nq, b)$$

$$\frac{2}{b} \sum x_i \sim \text{Gamma}(nq, 2) \Leftrightarrow \frac{2}{b} \sum x_i \sim \chi_{2nq}^2$$

Então

$$P_{b_0}(\sum x_i > c) = \alpha \Leftrightarrow P_{b_0}\left(\frac{2}{b} \sum x_i > \frac{2c}{b}\right) = \alpha$$

$$\Leftrightarrow P\left(\frac{2}{b} \sum x_i \leq \frac{2c}{b}\right) = 1 - \alpha$$

$$P\left(\chi_{2nq}^2 \leq \frac{2c}{b}\right) = 1 - \alpha$$

$$\text{onde } \chi_{2nq}^2 = \frac{2}{b} \sum x_i \text{ é uma v.a. cl dist. } \chi_{2nq}^2$$

b) $H_0: g \leq g_0$ versus $H_1: g > g_0$ quando b é conhecido.

Temos que

$$\begin{aligned} P_g(x) &= \exp \left\{ -\frac{\sum x_i}{b} - n g \log b + \log \Gamma(g) + \log \pi(g) - n \log \Gamma(g) \right\} \\ &= \exp \left\{ g \sum \log x_i - n [g \log b + \log \pi(g)] \right\} \exp \left\{ -\frac{\sum x_i}{b} - \log \pi(g) \right\} \\ &= \exp \{ \eta(g) T(x) - B(g) \} \pi(x) \quad \in \text{FE} \end{aligned}$$

onde $\eta(g) = g$, $T(x) = \sum \log x_i$, $B(g) = n [g \log b + \log \pi(g)]$

$$e \quad t(x) = \exp \left\{ -\frac{\sum x_i}{b} - \sum \log x_i \right\}$$

Temos que $\frac{\partial \eta(g)}{\partial g} = 1 > 0 \Rightarrow \eta(g)$ é estritamente crescente

Então pelo corolário 15, temos que um teste UMP para testar

$$H_0: g \leq g_0 \text{ contra } H_1: g > g_0$$

de nível α é dado por

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) > c \\ 0 & \text{se } T(x) \leq c \end{cases}$$

onde c é obtido por

$$E\{\phi(x)\} = \alpha$$

Dai,

$$P(T(x) > c) = \alpha \iff P(\sum \log x_i > c) = \alpha$$

$$\iff P(\sum \log x_i \leq c) = 1 - \alpha$$

Portanto o teste UMP é dado por

$$\phi(x) = \begin{cases} 1 & \text{se } \sum \log x_i > c \\ 0 & \text{se } \sum \log x_i \leq c \end{cases}$$

onde c é determinado por

$$P(\sum \log x_i \leq c) = 1 - \alpha$$

$$Y = \log X$$

$$(Y) = P(Y \leq y) = P(\log X \leq y) = P(X \leq e^y)$$

$$= \int_0^{e^y} \frac{1}{\Gamma(\alpha) \beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx$$

$$f(y) = \frac{1}{\Gamma(\alpha) \beta^\alpha} e^{y(\alpha-1)} e^{-e^y/\beta} \cdot e^y$$

$$= \frac{1}{\Gamma(\alpha) \beta^\alpha} \cdot e^{y\alpha - e^y/\beta}$$

$$x \stackrel{d}{\sim} \frac{e^y}{\beta}$$

13) uma variável aleatória X tem distribuição de Ponto $P(c, \tau)$ sua densidade é

$$\frac{c\tau^c}{x^{c+1}}, \quad 0 < x < \infty, \quad 0 < c \quad c < x < \infty$$

Se x_1, x_2, \dots, x_n não são a. indep. com distribuição Ponto (c, τ) , obtenha um teste UMP de $H_0: \gamma = \tau_0$ contra $H_1: \gamma \neq \tau_0$ quando c é conhecido. Sugestão: use o exercício 9.

Será feita uma transformação em X tal que nos resulte em uma variável aleatória Y com distribuição $U(0, \tau)$.

Queremos Y tq $Y \sim U(0, \tau)$, ou seja,

$$F_Y(y) = P(Y \leq y) = \int_0^y \frac{1}{\tau} dz = \frac{y}{\tau} \quad (1).$$

Além disso, queremos escrever Y em função de X , i.e.,

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = P(X \leq g^{-1}(y)) = F_X(g^{-1}(y)) \quad (2)$$

Equacionando (1) e (2) temos

$$F_X(g^{-1}(y)) = \frac{y}{\tau} \Leftrightarrow P(X \leq g^{-1}(y)) = \frac{y}{\tau}$$

$$\Leftrightarrow \int_x^{g^{-1}(y)} t^{-c} dt = \frac{y}{\tau} \Leftrightarrow \int_x^{g^{-1}(y)} \frac{c\tau^c}{t^{c+1}} dt = \frac{y}{\tau}$$

$$\Leftrightarrow c\tau^c \int_x^{g^{-1}(y)} t^{-(c+1)} dt = \frac{y}{\tau} \Leftrightarrow c\tau^c \left[\frac{t^{-(c+1)+1}}{-c+1} \Big|_x^{g^{-1}(y)} \right] = \frac{y}{\tau}$$

$$\Leftrightarrow \frac{1}{c\tau^c} \Big|_x^{g^{-1}(y)} = \frac{y}{c\tau^c} \Leftrightarrow -\frac{1}{c\tau^c} + \frac{1}{c\tau^c} = \frac{y}{c\tau^{c+1}}$$

$$\Leftrightarrow \frac{1}{\tau^{c+1} g^{-1}(y)^c} = \frac{1}{\tau^{c+1}} - \frac{y}{\tau^{c+1}} \Leftrightarrow \frac{1}{\tau^{c+1} g^{-1}(y)^c} = \frac{\tau - y}{\tau^{c+1}} \Leftrightarrow$$

$$g^{-1}(y) = \left[\frac{\tau^{c+1}}{\tau - y} \right]^{\frac{1}{c}} = \tau \left[1 - \frac{y}{\tau} \right]^{-\frac{1}{c}}$$

Temos que $y = g(x) \Rightarrow g^{-1}(y) = x$ então

$$x = \tau \left(1 - \frac{y}{\tau} \right)^{-\frac{1}{c}}$$

$$\Leftrightarrow x^{-c} = \tau^c \left(1 - \frac{y}{\tau} \right) \Leftrightarrow \left(\frac{x}{\tau} \right)^{-c} = 1 - \frac{y}{\tau} \Leftrightarrow \frac{y}{\tau} = 1 - \left(\frac{x}{\tau} \right)^c$$

$$\Leftrightarrow y = \tau \left(1 - \left(\frac{x}{\tau} \right)^c \right)$$

Sabemos que $\tau < x < \infty \Rightarrow 0 < y < \tau$

Então a transformação em X para termos uma $U(0, \tau)$ é da forma

$$Y = \tau \left[1 - \left(\frac{x}{\tau} \right)^c \right], \quad 0 < y < \tau$$

i.e., $Y \sim U(0, \tau)$

Logo pelo item (b) do exercício 9, um teste UMP é dado por

$$\phi(x) = \begin{cases} 1 & \text{se } y_{(1)} > \tau_0 \text{ ou } y_{(m)} \leq \tau_0 \\ 0 & \text{se } \text{caso contrário} \end{cases}$$

onde $y_{(m)} = \max \{ y_1, \dots, y_m \}$ i.e.,

$$y_{(m)} = \tau \left(1 - \left(\frac{x_{(m)}}{\tau} \right)^c \right)$$

pois quando $x \rightarrow \infty$ o $y \rightarrow \tau$, ou seja quando x cresce, y também cresce.

14) Sejam x_1, \dots, x_n variáveis aleatórias independentes, cada qual com distribuição gaussiana univariada $\text{G}(4, \gamma)$ e densidade

$$\sqrt{\frac{x}{2\pi}} \exp\left[-(\gamma x)^{1/2}\right] x^{-3/2} \exp\left[-\frac{1}{2}\left(\frac{x}{\gamma} + 4x\right)\right], x > 0, \gamma > 0$$

Mostre que existe um teste UMP para testar

(a) $H_0: \gamma \leq \gamma_0$ contra $H_1: \gamma > \gamma_0$, quando γ é conhecido;

Temos que

$$p_{\gamma}(x) = \exp\left\{-(\gamma x)^{1/2} - \frac{1}{2}4x\right\} \exp\left\{-\frac{1}{2}\frac{x}{\gamma}\right\} x^{-3/2} \left(\frac{x}{2\pi}\right)^{1/2}$$

então

$$p_{\gamma}(x) = \exp\left\{-\pi(\gamma x)^{1/2} - \frac{\pi}{2}4x\right\} \exp\left\{-\frac{1}{2}\frac{x}{\gamma}\right\} \pi x^{-3/2} \left(\frac{x}{2\pi}\right)^{1/2}$$

$$= \exp\left\{\eta(\gamma) T(x) - B(\gamma)\right\} h(x) \in \text{FE}$$

onde $\eta(\gamma) = -\frac{\pi\gamma}{2}$; $T(x) = \bar{x}$; $B(\gamma) = -\pi(\gamma)^{1/2}$

$$e h(x) = \exp\left\{-\frac{1}{2}\frac{x}{\gamma} - \frac{1}{2}4x\right\} \pi x^{-3/2} \left(\frac{x}{2\pi}\right)^{1/2}.$$

Temos que $\frac{\partial \eta(\gamma)}{\partial \gamma} = -\frac{\pi}{2} < 0 \Rightarrow \eta(\gamma)$ é estritamente decres-

cente. Portanto um teste UMP para testar

$H_0: \gamma \leq \gamma_0$ contra $H_1: \gamma > \gamma_0$

é dado por

$$\phi(x) = \begin{cases} 1 & \text{se } \bar{x} < c \\ 0 & \text{se } \bar{x} > c \end{cases}$$

onde c é determinado por $E_{\gamma_0}\{\phi(x)\} = \alpha$, ou ainda,

$$P(\bar{x} < c) = \alpha$$

~

é a rejeição crítica é dada por

$$S_c = \{\bar{x} : \bar{x} > c\}$$

(b) $H_0: \tau \leq \tau_0$ contra $H_1: \tau > \tau_0$ quando μ é conhecido;

Termos que

$$\begin{aligned} p_{\tau}(x) &= \exp \left\{ n(\tau_0)^{\frac{1}{2}} - \frac{1}{2} \tau \sum \frac{1}{x_i} + \frac{n}{2} \log \left(\frac{x}{\tau_0} \right) \right\} \exp \left\{ -\frac{n\bar{x}}{2} \right\} \pi x^{-\frac{3}{2}} \\ &= \exp \left\{ \eta(\tau) T(x) - B(\tau) + K(x) \right\} \in \text{FE} \end{aligned}$$

onde $\eta(\tau) = -\frac{\tau}{2}$, $T(x) = \sum \frac{1}{x_i}$, $B(\tau) = -\frac{n}{2} \log \left(\frac{x}{\tau_0} \right) - n(\tau_0)^{\frac{1}{2}}$

$$+ K(x) = \exp \left\{ -\frac{n\bar{x}}{2} \right\} \pi x^{-\frac{3}{2}}$$

Termos que $\frac{\partial \eta(\tau)}{\partial \tau} = -\frac{1}{2} < 0 \Rightarrow \eta(\tau)$ é estritamente decrescente

então um teste UMP para testar $H_0: \tau \leq \tau_0$ contra $H_1: \tau > \tau_0$ é

dado por

$$\phi(x) = \begin{cases} 1 & \text{quando } \sum \frac{1}{x_i} < c \\ 0 & \text{quando } \sum \frac{1}{x_i} > c \end{cases}$$

onde c é determinado por

$$E_{\tau_0}(\phi(x)) = \alpha$$

ou ainda,

$$P\left(\sum \frac{1}{x_i} < c\right) = \alpha$$

O.a rejeição crítica é dada por

$$S_c: \left\{ x : \sum_{i=1}^n \frac{1}{x_i} > c \right\}$$

15) Teste Bayesiano

Sym P_0 e P_1 duas distribuições com densidades p_0 e p_1 respectivamente. Considere o problema de testar $H_0: P=P_0 \cup H_1: P=P_1$ e suponha que as probabilidades $\pi_0 = \pi$ e $\pi_1 = 1 - \pi$ possam ser atribuídas, antes do experimento ser realizado, às hipóteses H_0 e H_1 respectivamente.

(a) mostre que a probabilidade total de um erro resultante do uso de um teste ϕ é

$$\pi E_{P_0}(\phi(x)) + (1-\pi) E_{P_1}(1-\phi(x))$$

Termos que

$$P(H_0) = \pi \quad \text{e} \quad P(H_1) = 1 - \pi. \quad (\text{as priors})$$

$$P(\text{erro total}) = P(\text{erro tipo I}) + P(\text{erro tipo II})$$

$$= P(\text{rejeitar } H_0 \text{ e } H_0 \text{ é verdadeira}) + P(\text{aceitar } H_0 \text{ e } H_0 \text{ é falsa})$$

$$= P(H_0 \text{ é verdadeira}) P(\text{rejeitar } H_0 | H_0 \text{ é verdadeira}) \\ + P(H_0 \text{ é falsa}) P(\text{aceitar } H_0 | H_0 \text{ é falsa}) \\ \text{ou usando } P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$= \pi E_{P_0}(\phi(x)) + (1-\pi) E_{P_1}(1-\phi(x))$$

OBS: $\phi(x)$ é a probabilidade de rejeitar H_0 e $1-\phi(x)$ probabilidade de aceitar H_0

(b) mostre que o teste que minimiza esta probabilidade, o teste de Bayes, tem a forma do teste de Neyman Pearson, com $\kappa = \pi_0 / \pi_1$. Sugestão: Considere $S_L = \{x: (1-\pi) p_1 > \pi p_0\}$, com $S_2 = \{x: (1-\pi) p_1 < \pi p_0\}$ e $S_3 = \{x: (1-\pi) p_1 = \pi p_0\}$

Termos que

$$\begin{aligned} g(\phi(x)) &= \pi E_{P_0}(\phi(x)) + (1-\pi) E_{P_1}(1-\phi(x)) \\ &= \pi \int \phi(x) p_0 d\mu + (1-\pi) \int (1-\phi(x)) p_1 d\mu \\ &= \pi \int \phi(x) p_0 d\mu + (1-\pi) \left[p_1 d\mu - (1-\pi) \int \phi(x) p_0 d\mu \right] \\ &= \pi \int \phi(x) p_0 d\mu - (1-\pi) \int \phi(x) p_1 d\mu + (1-\pi) \\ &= \pi \left[\int_{S_1} \phi p_0^{\frac{\mu}{\mu}} + \int_{S_2} \phi p_0^{\frac{\mu}{\mu}} + \int_{S_3} \phi p_0^{\frac{\mu}{\mu}} \right] - (1-\pi) \left[\int_{S_2} \phi p_1^{\frac{\mu}{\mu}} + \int_{S_3} \phi p_1^{\frac{\mu}{\mu}} \right] \\ &\quad + (1-\pi) \\ &= (1-\pi) - \int_{S_3} \phi \underbrace{[(1-\pi)p_1 - \pi p_0]}_{> 0} d\mu - \int_{S_2} \phi \underbrace{[(1-\pi)p_1 - \pi p_0]}_{< 0} d\mu \\ &\quad - \int_{S_3} \phi \underbrace{[(1-\pi)p_1 - \pi p_0]}_{0} d\mu \\ &= (1-\pi) + \underbrace{\left[\int_{S_1} \phi \underbrace{[(1-\pi)p_1 - \pi p_0]}_{> 0} d\mu - \int_{S_2} \phi \underbrace{[(1-\pi)p_1 - \pi p_0]}_{< 0} d\mu \right]}_{(x)} \end{aligned}$$

queremos que (x) seja mínimo possível. então

$$\phi(x) = \begin{cases} 1 & \text{se } x \in S_1, \\ 0 & \text{se } x \in S_2, \end{cases}$$

Mas se $x \in S_1 \Rightarrow p_1 > \frac{\pi}{1-\pi} p_0 \Leftrightarrow p_1 > \frac{\pi_0}{\pi_1} p_0$ e
se $x \in S_2 \Rightarrow p_2 < \frac{\pi_0}{\pi_1} p_0$.

(c) Mostre que a distribuição condicional de H_i dado $x=x$, a probabilidade a posteriori de H_i é

$$\frac{\pi_L p_L(x)}{\pi_0 p_0(x) + \pi_L p_L(x)}$$

e então o teste de Bayes decide em favor da hipótese que tem maior probabilidade a posteriori

$$\begin{aligned} P(H_i | x=x) &= \frac{P(H_i, x=x)}{P(x=x)} \\ &= \frac{P(x|H_i) P(H_i)}{P(x|H_0) P(H_0) + P(x|H_1) P(H_1)} \\ &= \frac{p_i(x) \pi_i}{p_0(x) \pi_0 + \pi_1 p_1(x)} \end{aligned}$$

onde $P(H_i) = \pi_i$ e $P(x|H_i) = p_i(x)$ para $i = 0, 1$

16) Sejam f e g duas densidades de probabilidade com respeito a H . Para testar a hipótese $H_0: \theta \leq \theta_0$ ou $\theta \geq \theta_1$, ($0 < \theta_0 < \theta_1 < 1$) contra alternativas $\theta_0 < \theta < \theta_1$ na família $\mathcal{F} = \{f_\theta(x) + (1-\theta)g(x), 0 \leq \theta \leq 1\}$, o teste $\phi(x) = d$, para todo x , é UHP de nível α .

Lemma: $\phi(x)$: teste qff de nível α
Sugestão: $E(\phi(x)) \leq d \Leftrightarrow \theta \in H_0$

ou seja, $E_{\theta=0}(\phi(x)) \leq d \Rightarrow E_{\theta=1}(\phi(x)) \leq d$

$$\left\{ \begin{array}{l} E_{\theta=0}(\phi(x)) \leq d \\ E_{\theta=1}(\phi(x)) \leq d \end{array} \right. \begin{array}{l} \xrightarrow{\text{motiva}} \\ \xrightarrow{\text{nao}} \end{array} \left\{ \begin{array}{l} E_\theta(\phi^*(x)) \leq d, \forall \theta \in \theta_0 < \theta < \theta_1 \\ \text{nao} \end{array} \right.$$

$$\Rightarrow E(\phi(x)) - \text{pela } \phi(0) = d \forall x$$

fracionário nulo inclui

MAE 5834 - Estatística Avançada I
Prova 1 - 2º semestre de 2005 - Prof. Silvia L.P. Ferrari

~~✓~~ (2 pontos) Sejam X_1, \dots, X_n variáveis aleatórias independentes com distribuição de Bernoulli com parâmetro $\theta \in (0, 1)$. Encontre o ENVVUM de $g(\theta) = P_\theta(X_1 + \dots + X_m = k)$, onde m e k são fixados, $0 \leq m < n$, $0 \leq k \leq m$.

2. Seja $X = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes cada qual com densidade $f(x - \xi)$, $\xi \in \mathcal{R}$, e $f(x) = \exp\{-\lambda(x+1)\}$, $x \geq -1$.

(a) (1 ponto) Encontre o estimador de máxima verossimilhança $\delta(X)$ de ξ e verifique que é equivariante.

(b) (1 ponto) Encontre a distribuição de $n(\delta(X) - \xi)$. Mostre que $\delta(X)$ é um estimador viciado de ξ e obtenha seu risco sob perda quadrática.

(c) (1 ponto) Obtenha o estimador de Pitman de ξ (estimador equivariante de risco mínimo sob perda quadrática). Mostre que é não viciado e calcule seu risco. Mostre que o estimador $\delta(X)$ é inadmissível.

3. (a) (1 ponto) Estatística completa, mas não suficiente.

Sejam X_1, \dots, X_n ($n \geq 2$) variáveis aleatórias independentes com distribuição $N(\theta, 2)$ quando $\theta = 0$ e $N(\theta, 1)$ quando $\theta \in \mathcal{R}$ e $\theta \neq 0$. Mostre que a média amostral \bar{X} é uma estatística completa para θ mas não é suficiente.

(b) (1 ponto) Estatística suficiente completa se o espaço paramétrico é Ω , mas apenas suficiente (e não completa) se o espaço paramétrico é $\Omega_0 \subset \Omega$.

Sejam X_1, \dots, X_n ($n \geq 2$) variáveis aleatórias independentes com distribuição $U(0, \theta)$, $\theta \in \Omega = (0, +\infty)$. Já mostramos que $X_{(n)} = \max(X_1, \dots, X_n)$ é uma estatística suficiente completa para θ . Considere agora que o espaço paramétrico é $\Omega_0 = [1, +\infty)$. Mostre que $X_{(n)}$ é suficiente, mas não é completa.

4. Suponha que X_1, \dots, X_n sejam variáveis aleatórias independentes com distribuição $N(\mu, \sigma^2)$, sendo $-\infty < \mu < +\infty$ desconhecido e $\sigma^2 > 0$ conhecido.

(a) (1 ponto) Obtenha o ENVVUM de e^μ .

Sugestão: Usar a função geradora de momentos da distribuição normal.

(b) (1 ponto) Compare a variância do estimador obtido em (a) com o limite inferior de Cramér-Rao para a variância de estimadores não viciados de e^μ .

(c) (1 ponto) Considere o problema de estimar e^μ com perda

$$L(\mu, d) = \frac{d}{e^\mu} - 1 - \log \frac{d}{e^\mu}$$

Entre os estimadores da forma $c\bar{X}$, onde $\bar{X} = \sum X_i/n$ e $c > 0$, encontre aquele que minimiza o risco.

$$C = e^{\sigma^2/2n}$$

Prava da EAI

$$1) \delta(x) = \begin{cases} 1, & \text{se } \sum_{i=1}^m x_i = k \\ 0, & \text{caso contrário} \end{cases} \quad \text{ou} \quad \delta(x) = \begin{cases} \binom{m}{k} & \text{se } x_1 = \dots = x_k = 1, \\ 0 & \text{se } x_{k+1} = \dots = x_m = 0, \end{cases}$$

$$g(\theta) = \binom{m}{k} \theta^k (1-\theta)^{m-k} = P_\theta(x_1 + \dots + x_m = k)$$

$E_\theta(\delta(x) | T) = \text{ENVVUM de } g(\theta), \text{ onde } T = \sum_{i=1}^m x_i \quad \text{ou } X$

$$\delta(x) = \begin{cases} \frac{\binom{m}{k} (\binom{n-k}{\sum_{i=1}^m x_i - k})}{\binom{n}{\sum_{i=1}^m x_i}} & \text{se } \sum_{i=1}^m x_i \geq k \\ 0 & \text{se } \sum_{i=1}^m x_i < k \end{cases}$$

$$2) f(x_1, \dots, x_n) = \prod_{i=1}^n f(x_i - \xi) = \prod \text{rep} \{- (x_i - \xi + 1)\} \underset{[-\infty, +\infty]}{\mathbb{I}}$$

$$(a) = \exp \{-n\bar{x} + n(\xi - 1)\} \mathbb{I}_{(-\infty, x_{(1)} + 1]}$$

$$L(\xi; \bar{x}) = \exp \{-n\bar{x} + n(\xi - 1)\} \mathbb{I}_{(-\infty, x_{(1)} + 1]}, \quad \bar{x} \in \mathbb{R}^n$$

$$= \begin{cases} 0, & \xi > x_{(1)} + 1 \\ \text{unif. e crescente}, & \xi \leq x_{(1)} + 1 \end{cases}$$

$$\therefore \hat{\xi} = x_{(1)} + 1 \text{ é a ENV de } \xi, \text{ onde } \hat{\xi} = \delta(x)$$

P/ mostrar q e equiv: $\delta(x+a) = \delta(x)+a$

$$(b) n(\delta(x) - \xi) \sim \text{Exp}(1)$$

$$E_\xi [n(\delta(x) - \xi)] = 1 \Rightarrow E_\xi \underbrace{(\delta(x) - \xi)}_{\text{més}} = \ln.$$

$$\delta(x) = x_{(1)} + 1$$

$$\delta(x+\theta) = \min \{x_1 + \theta, x_2 + \theta, \dots, x_{(1)} + \theta\} + 1$$

$$= x_{(1)} + 1 + \theta$$

$$a_1^* = \frac{1}{\sqrt{r}} \sum_{i=1}^r a_i = \frac{1}{\sqrt{r}} I_r^T a$$

$$e^* = \Gamma_r e \Gamma_c^T = \left(\frac{1}{\sqrt{r}} I_r^T \right) \begin{pmatrix} e_{11} & \dots & e_{1c} \\ \vdots & \ddots & \vdots \\ e_{r1} & \dots & e_{rc} \end{pmatrix} \left(\frac{1}{\sqrt{c}} I_c \quad C_c^T \right)$$

$$= \left(\frac{1}{\sqrt{r}} \dots \frac{1}{\sqrt{r}} \right) \begin{pmatrix} e_{11} & \dots & e_{1c} \\ \vdots & \ddots & \vdots \\ e_{r1} & \dots & e_{rc} \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{c}} & & \\ \vdots & \ddots & \\ \frac{1}{\sqrt{c}} & & C_c^T \end{pmatrix}$$

$$= \left(\frac{1}{\sqrt{r}} \sum_{i=1}^r e_{i1} \quad \frac{1}{\sqrt{r}} \sum_{i=1}^r e_{i2} \quad \dots \quad \frac{1}{\sqrt{r}} \sum_{i=1}^r e_{ic} \right) \begin{pmatrix} \frac{1}{\sqrt{c}} & & \\ \vdots & \ddots & \\ \frac{1}{\sqrt{c}} & & C_c^T \end{pmatrix}$$

$$= \begin{pmatrix} \frac{1}{\sqrt{rc}} \sum_{i=1}^r \sum_{j=1}^c e_{ij} & [\frac{1}{\sqrt{rc}} \sum_{i=1}^r e_{i1} \dots \frac{1}{\sqrt{rc}} \sum_{i=1}^r e_{ic}] C_c^T \\ C_r e \begin{pmatrix} \frac{1}{\sqrt{c}} \\ \vdots \\ \frac{1}{\sqrt{c}} \end{pmatrix} & C_r e C_c^T \end{pmatrix}$$

$$e_1^* = \frac{1}{\sqrt{rc}} I_r^T e I_c.$$

Então

$$Z_{11} = \theta \sqrt{rc} + (\sqrt{r})^{-1} I_r^T a \sqrt{c} + (\sqrt{rc})^{-1} I_r^T e I_c$$

$$= \theta \sqrt{rc} + (\sqrt{rc})^{-1} c I_r^T a + (\sqrt{rc})^{-1} I_r^T e I_c$$

$$= (\sqrt{rc})^{-1} \{ \theta c + I_r^T a c + I_r^T e I_c \}$$

e depois de alguns cálculos temos

$$R(\xi, \delta) = E_\xi \left[\eta^2 (\delta(x) - \xi)^2 \right] = \frac{1}{n^2} = \frac{2}{n^2}$$

(c) Estimador de Pitman

$$\hat{\delta}^* = \frac{\int_{-\infty}^{\infty} u f(x_1-u, \dots, x_n-u) du}{\int_{-\infty}^{\infty} f(x_1-u, \dots, x_n-u) du}$$

$$= \dots = \frac{\int_{-\infty}^{x_{(1)}+1} u e^{-nu} du}{\int_{-\infty}^{x_{(1)}+1} e^{-nu} du} = \dots = x_{(1)} + 1 - \frac{1}{n}$$

∴ est. Pitman é ENV.

$$\text{Como } \epsilon \in \text{ENV}, R(\xi, \delta^*) = \text{Var}(\hat{\delta}^*) = \frac{1}{n^2} < R(\xi, \delta)$$

EMV é inadmissível

3)

$$(a) P_0 = \{N(\theta, 1), \theta \in \mathbb{R} \setminus \{0\}\}$$

$$P_1 = \{N(\theta, 1), \theta \in \mathbb{R} \setminus \{0\}\} \cup \{N(0, 2)\}$$

\bar{x} é est. suf. e comp. p/ P_0 (propried. com exp de post compl.)

Como \bar{x} é comp. p/ P_0 ; $E(h(\bar{x})) = 0$ p/ esperança calculada

sob todos dist. de $P_0 \Rightarrow h(\bar{x}) = 0$ q.c. P_0

$$= 0 \cdot \mu(\{x \in \mathbb{R}^n : h(\bar{x}) \neq 0, \text{ c/ } \bar{x} = \sum x_i / n\}) = 0$$

(μ : medida da desloque) $\Rightarrow h(\bar{x}) = 0$, q.c. P_1 .

Como $\text{tr}(Y^T Y) = \sum_{i=1}^r \sum_{j=1}^c Y_{ij}^2$ e $\text{tr}(Z^T Z) = \sum_{i=1}^r \sum_{j=1}^c Z_{ij}^2$, logo

$$\begin{aligned} \sum_{i=1}^r \sum_{j=1}^c Y_{ij}^2 &= \text{tr}[(Y \Gamma_c^\top)(\Gamma_c Y^\top)] = \text{tr}(\Gamma_c Y^\top Y \Gamma_c^\top) \\ &= \text{tr}(\Gamma_c Y^\top \Gamma_r^\top \Gamma_r Y \Gamma_c^\top) = \text{tr}(Z^T Z) \\ &= \sum_{i=1}^r \sum_{j=1}^c Z_{ij}^2 \end{aligned}$$

No lema abaixo obtemos as expressões de U , S_1^2 e S_2^2 em termos dos Y_{ij} 's.

Lema 2.3: U , S_1^2 e S_2^2 podem também serem escritos como

$$U = \bar{Y}_- \cdot S_1^2 = c \sum_{i=1}^r (\bar{Y}_i - \bar{Y}_-)^2, \quad S_2^2 = \sum_{i=1}^r \sum_{j=1}^c (Y_{ij} - \bar{Y}_i)^2,$$

onde $\bar{Y}_- = (rc)^{-1} \sum_{i=1}^r \sum_{j=1}^c Y_{ij}$ e $\bar{Y}_i = c^{-1} \sum_{j=1}^c Y_{ij}$.

Dem.: Pela definição de Γ_s , vimos que

$$Z_{11} = \theta \sqrt{rc} + a_1^* \sqrt{c} + e_{11}^*,$$

mas, observando que

$$\begin{aligned} a^* = \Gamma_s a &= \begin{pmatrix} \frac{1}{\sqrt{c}} I_r^\top \\ C_r \end{pmatrix} \begin{pmatrix} a_1 \\ \vdots \\ a_r \end{pmatrix} = \begin{pmatrix} \frac{1}{\sqrt{r}} & \frac{1}{\sqrt{r}} & \cdots & \frac{1}{\sqrt{r}} \\ & C_r & & \end{pmatrix} \begin{pmatrix} a_1 \\ \vdots \\ a_r \end{pmatrix} \\ &= \begin{pmatrix} \frac{1}{\sqrt{r}} \sum_{i=1}^r a_i \\ C_r a \end{pmatrix}, \end{aligned}$$

P/ mostrar que \bar{x} é uma est. suf p/ θ_1 , basta
mostrar que a dist. cond. de x_{1-1}, x_n dados \bar{x} , não é
a mesma, & a dist. em θ_2 (depende de θ).

$$P/x_1, \dots, x_n \in \mathbb{R}, \sum_{i=1}^n x_i = n\bar{x}$$

$$f_{x_1, \dots, x_n | \bar{x}=\bar{x}}(x_1, \dots, x_n; \theta) = ?$$

$$\partial_\theta^2 = \int_{-\infty}^{\infty} x \theta - \infty$$

$$\therefore ? = \frac{n}{(\sqrt{2\pi})^{n-1} \sigma_\theta^{n-1}} \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{2 \sigma_\theta^2} \right\}$$

(b) Suf é simples: $\begin{cases} (\text{i}) \text{ crit fator} \\ (\text{ii}) \text{ suf de suf: se } x_{(n)} \text{ é suf p/ } \theta \in (0, \infty) \\ \text{f}_{x_1, \dots, x_n | x_{(n)}, (x_1, \dots, x_n; \theta)} \text{ não dep de } \theta, \\ \forall \theta \in (0, \infty), \text{ logo, não dep. de } \theta, \forall \theta \in [0, \infty) \end{cases}$

não Completuridde

Devo mostrar q. $\exists h(x_{(n)})$ é identica a nula + q

$$E_\theta(h(x_{(n)})) = 0, \forall \theta \in [0, \infty)$$

$$f_{x_{(n)}}(y) = \frac{ny^{n-1}}{\theta^n}, 0 < y < \theta$$

$$\begin{aligned} E_\theta(h(x_{(n)})) &= \int_0^\theta h(y) \frac{ny^{n-1}}{\theta^n} dy = \frac{n}{\theta^n} \int_0^\theta h(y) y^{n-1} dy \\ &= \frac{n}{\theta^n} \left[\int_0^1 h(y) y^{n-1} dy + \int_1^\theta h(y) y^{n-1} dy \right] \end{aligned}$$

$$= \frac{\exp \left[-\frac{1}{2} \left(\frac{(\sigma_\theta^2)}{\sigma_a^2 + \sigma_e^2} \right) \right]}{(2\pi)^{\frac{c}{2}} (\sigma_a^2 + \sigma_e^2)^{\frac{c(c-1)}{2}}} \exp \left[\frac{z_{11}\theta\sqrt{rc}}{\sigma_a^2 + \sigma_e^2} - \frac{z_{11}^2 + s_1^2}{2(\sigma_a^2 + \sigma_e^2)} - \frac{s_2^2}{2\sigma_e^2} \right].$$

Como o espaço paramétrico de $\left(\frac{\sqrt{rc}\theta}{\sigma_a^2 + \sigma_e^2}, \frac{-1}{2(\sigma_a^2 + \sigma_e^2)}, \frac{-1}{2\sigma_e^2} \right)$ contém retângulos tridimensionais abertos, então a distribuição conjunta dos Z_{ij} 's pertence à família exponencial de posto completo e assim, $(Z_{11}, Z_{11}^2 + S_1^2, S_2^2)$ é uma estatística suficiente completa. E como (U, S_1^2, S_2^2) é uma função inversível de $(Z_{11}, Z_{11}^2 + S_1^2, S_2^2)$, então é também uma estatística suficiente e completa.

(b) Pelo Teorema 2.1, como os Z_{ij} 's são todos independentes segue que

$$U = (\sqrt{rc})^{-1} Z_{11}, \quad S_1^2 = \sum_{i=2}^r Z_{i1}^2, \quad S_2^2 = \sum_{i=1}^r \sum_{j=2}^c Z_{ij}^2,$$

também são independentes. Como $Z_{11} \sim N(\sqrt{rc}\theta, \sigma_a^2 + \sigma_e)$ então $U = (\sqrt{rc})^{-1} Z_{11} \sim N(\theta, \frac{\sigma_a^2 + \sigma_e}{rc})$. De $Z_{i1} \sim N(0, \sigma_a^2 + \sigma_e)$, para $i > 1$, temos que $\frac{Z_{i1}}{\sqrt{\sigma_a^2 + \sigma_e}} \sim N(0, 1) \Rightarrow \frac{Z_{i1}^2}{\sigma_a^2 + \sigma_e} \sim \chi^2_1(0)$. Então $S_1^2 = \sum_{i=2}^r Z_{i1}^2 \sim (\sigma_a^2 + \sigma_e)\chi^2_{r-1}(0)$. Analogamente, como $Z_{ij} \sim N(0, \sigma_e^2)$, para $j > 1$, então

$$S_2^2 = \sum_{i=1}^r \sum_{j=2}^c Z_{ij}^2 \sim \sigma_e \chi^2_{(c-1)}(0),$$

E a demonstração está feita

Agora expressaremos U, S_1^2 e S_2^2 em termos dos Y_{ij} 's. Para isto, necessitamos do lema seguinte.

Lema 2.2:

$$\sum_{i=1}^r \sum_{j=1}^c Y_{ij}^2 = \sum_{i=1}^r \sum_{j=1}^c Z_{ij}^2$$

Dem.: Para demonstração deste lema usaremos traço de matriz.

$$\text{Defino } h(y) = \begin{cases} 0 & y \geq 1 \\ \frac{y-1}{y^{n-1}} & y \in (0,1) \end{cases}$$

$h(y)$ é ident/c nula mas $E(h(X_{(1)})) = 0$

4) (a): \bar{x} é est. suf. comp p/θ

$$\bar{x} \sim N(\mu, \sigma^2/n)$$

$$E(e^{t\bar{x}}) = M_{\bar{x}}(t) = \exp \left\{ \mu t + \frac{\sigma^2}{2n} t^2 \right\}$$

$$\delta(x) = \exp \left\{ \bar{x} - \frac{\sigma^2}{2n} \right\} ; \text{ EN VWM de } e^x$$

(b)

$$\text{Var}(\delta(x)) = e^{2\mu} \left\{ \exp \left(\frac{\sigma^2}{n} \right) - 1 \right\}$$

$$\text{LICR: } e^\mu = g(\mu)$$

$$\frac{[\delta(x)]^2}{I(\mu)} = \frac{\sigma^2}{n} e^{2\mu}$$

$$\text{Var}(\delta(x)) - \text{LICR} = e^{2\mu} \left[\exp \left(\frac{\sigma^2}{n} \right) - 1 - \frac{\sigma^2}{n} \right]$$

Logo, $Z_{11} \sim N(\sqrt{c}\theta, c\sigma_a^2 + \sigma_e^2)$.

2.1.1. Estatística Suficiente e Completa

Agora encontraremos uma estatística suficiente e completa para o modelo de efeitos aleatórios com um fator, sua distribuição e vamos expressá-la em termos dos Y_{ij} originais. Considere

$$U = (\sigma)^{-1/2} Z_{11}, \quad S_1^2 = \sum_{i=2}^r Z_{i1}^2, \quad S_2^2 = \sum_{i=1}^r \sum_{j=2}^c Z_{ij}^2.$$

Teorema 2.2: (a) (U, S_1^2, S_2^2) é uma estatística suficiente e completa para um modelo de efeitos aleatórios com um fator.

(b) U, S_1^2 e S_2^2 são independentes e $U \sim N(\theta, \frac{\sigma^2 + \sigma_e^2}{\sigma})$, $S_1^2 \sim (c\sigma_a^2 + \sigma_e^2)\chi_{r-1}^2(0)$ e $S_2^2 \sim (\sigma_e^2)\chi_{(c-1)}^2(0)$.

Dem.: (a) A função densidade conjunta dos Z_{ij} 's é

$$\begin{aligned} f_Z(z) &= f_{Z_{11}}(z_{11}) \prod_{i=2}^r f_{Z_{i1}}(z_{i1}) \prod_{i=1}^r \prod_{j=2}^c f_{Z_{ij}}(z_{ij}) \\ &= \frac{1}{\sqrt{2\pi}\sqrt{c\sigma_a^2 + \sigma_e^2}} \exp \left[-\frac{(z_{11} - \sqrt{c}\theta)^2}{2(c\sigma_a^2 + \sigma_e^2)} \right] \cdot \\ &\quad \prod_{i=2}^r \frac{1}{\sqrt{2\pi}\sqrt{c\sigma_a^2 + \sigma_e^2}} \exp \left[-\frac{z_{i1}^2}{2(c\sigma_a^2 + \sigma_e^2)} \right] \\ &\quad \prod_{i=1}^r \prod_{j=2}^c \frac{1}{\sqrt{2\pi}\sqrt{\sigma_e^2}} \exp \left[-\frac{z_{ij}^2}{2\sigma_e^2} \right] \\ &= \frac{1}{(2\pi)^{\frac{1}{2}(1+r-1+c-r)} (c\sigma_a^2 + \sigma_e^2)^{\frac{1}{2}(1+r-1)} (\sigma_e^2)^{\frac{1}{2}(r(c-1))}} \quad (2.1.6) \\ &\quad \exp \left[-\frac{1}{2} \left[\frac{(z_{11} - \sqrt{c}\theta)^2}{c\sigma_a^2 + \sigma_e^2} + \frac{s_1^2}{c\sigma_a^2 + \sigma_e^2} + \frac{s_2^2}{\sigma_e^2} \right] \right] \end{aligned}$$

$$h(y) = e^y - 1 - y, y > 0$$

$$h'(y) > 0$$

$$h(y) \rightarrow 0 \text{ quando } y \rightarrow 0$$

$$h(y) \rightarrow \infty \text{ se } y \rightarrow \infty$$

(estudar o comportamento da função h para mostrar que

$$h\left(\frac{\theta}{\sigma_a^2}\right) > 0 \quad (\text{concluir})$$

$$(c) L(\mu, d) = \frac{d}{e^\mu} - 1 - \log \frac{d}{e^\mu}$$

$$S(\bar{x}) = c e^{\bar{x}}$$

$$R(\mu, \delta_c) = E_\mu(L(\mu, \delta_c(x)))$$

$$R'(\mu, \delta_c) = 0 \quad (\text{encontrar } c)$$

$$R''(\mu, \delta_c) > 0$$

$$c = e^{-\sigma_a^2 / 2n}$$

$$\begin{aligned} M_{e^*}(t) &= E[\exp[tr(e^* T^T)]] \\ &= E[\exp[tr(\Gamma_r e \Gamma_c^T T^T)]] \\ &= E[\exp[tr(e \Gamma_c^T T^T \Gamma_r)]] \quad (\text{Fato 2}) \\ &= E[\exp[tr(e (\Gamma_r^T T \Gamma_c)^T)]] \\ &= M_e(\Gamma_r^T T \Gamma_c) \\ &= \exp\left[\sigma^2 \operatorname{tr}\left[\frac{(\Gamma_r^T T \Gamma_c)(\Gamma_r^T T \Gamma_c)^T}{2}\right]\right] \\ &= \exp\left[\sigma^2 \operatorname{tr}\left[\frac{\Gamma_r^T T \Gamma_c \Gamma_c^T T^T \Gamma_r}{2}\right]\right] \\ &\vdots \exp\left[\sigma^2 \operatorname{tr}\left[\frac{T T^T}{2}\right]\right] \\ &= M_e(t). \end{aligned}$$

Logo, $M_{e^*}(t) = M_e(t)$, ou seja, e e e^* tem a mesma função geradora de momentos e, consequentemente, a mesma distribuição.

Teorema 2.1: Os Z_{ij} 's são todos independentes, $Z_{11} \sim N(\sqrt{c}\theta, c\sigma_a^2 + \sigma_c^2)$, $Z_{ii} \sim N(0, c\sigma_a^2 + \sigma_c^2)$, $i > 1$, e $Z_{ij} \sim N(0, \sigma_c^2)$, $j > 1$.

Dem.: Por (2.1.4), sabemos que

$$Z_{11} = \sqrt{c}\theta + \sqrt{c}a_1^* + e_{11}^*,$$

$$Z_{ii} = \sqrt{c}a_i^* + e_{ii}^*, \quad i > 1,$$

$$Z_{ij} = e_{ij}^*, \quad j > 1,$$

e, pelo Lema 2.1, temos que $a_i^* \sim N(0, \sigma_a^2)$ e $e_{ij}^* \sim N(0, \sigma_c^2)$. Daí temos que $Z_{ij} = e_{ij}^* \sim N(0, \sigma_c^2)$, para $j > 1$. Temos ainda que

$$\begin{aligned} E(Z_{11}) &= \sqrt{c}E(a_1^*) + E(e_{11}^*) = 0, \quad i > 1 \quad e \\ Var(Z_{11}) &= cVar(a_1^*) + Var(e_{11}^*) = c\sigma_a^2 + \sigma_c^2, \quad i > 1. \end{aligned}$$

Logo, $Z_{11} \sim N(0, c\sigma_a^2 + \sigma_c^2)$, $i > 1$. Além disso,

$$\begin{aligned} E(Z_{11}) &= \sqrt{c}\theta + \sqrt{c}E(a_1^*) + E(e_{11}^*) = \sqrt{c}\theta, \quad e \\ Var(Z_{11}) &= cVar(a_1^*) + Var(e_{11}^*) = c\sigma_a^2 + \sigma_c^2. \end{aligned}$$

LISTA DE EXERCÍCIOS 5
Estatística Avançada

2. Sejam X_1, \dots, X_n uma amostra aleatória da densidade $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, $\theta > 0$

a) Obtenha um teste UMP de $H_0: \theta \leq \theta_0$ ($\theta_0 > 0$) versus $H_1: \theta > \theta_0$ de nível α .

O interesse é testar:

$$H_0: \theta \leq \theta_0 \quad \text{vs} \quad H_1: \theta > \theta_0 \quad (1)$$

$$\text{Seja } \Omega_0 = \{\theta > 0 : \theta \leq \theta_0\} \text{ e } \Omega_1 = \{\theta > 0 : \theta > \theta_0\}$$

Temos que a razão de verossimilhanças $RV(X) = P_{\theta_0}(X)/P_{\theta_1}(X)$ é a seguinte:

$$RV(X) = \frac{\theta_0^n \prod_{i=1}^n X_i^{\theta_0-1}}{\theta_1^n \prod_{i=1}^n X_i^{\theta_1-1}},$$

onde θ_0 e θ_1 pertencem a Ω_0 e Ω_1 , respectivamente. Então:

$$RV(X) = \left(\frac{\theta_0}{\theta_1}\right)^n \left(\prod_{i=1}^n X_i\right)^{\theta_0-\theta_1}$$

Como $\theta_1 > \theta_0$, então $RV(X)$ é uma função não decrescente de $T(X) = \prod_{i=1}^n X_i$. Então, segundo o Teorema do pag. T27 das notas de aula tem-se que o teste UMP para (1) é dado por:

$$\phi(X) = \begin{cases} 1 & \text{se } T(X) > C \\ \gamma & \text{se } T(X) = C \\ 0 & \text{se } T(X) < C \end{cases}$$

Onde C e γ são determinados por:

$$E_{\theta_0}[\phi(X)] = \alpha = P_{\theta_0}[T(X) > C] + \gamma P_{\theta_0}[T(X) = C]$$

Para obter essa esperança vamos considerar o seguinte:

Seja $Y = -\log(X)$, vamos obter $F_Y(y)$ e $f_Y(y)$, então:

$$F_Y(y) = P(Y \leq y) = P(-\log(X) \leq y) = P(X \geq e^{-y}) = P(X \geq e^{-y})$$

$$= 1 - F_X(e^{-y})$$

$$f_Y(y) = f_X(e^{-y}) e^{-y} = \theta e^{-y(\theta-1)} e^{-y} = \theta e^{-y\theta}$$

Então como $Y \in (0, \infty)$ temos que

$$Y \sim \exp(\theta), \text{ ou seja, } E(Y) = 1/\theta$$

Daí, $\sum_{i=1}^n -\log(X_i) = \sum_{i=1}^n Y_i = W$, em que $W \sim \text{Gama}(n, \theta)$, pois os X_i 's e os Y_i 's são independentes (2)

Então

$$E_{\theta_0}[\phi(X)] = P_{\theta_0}\left(\prod_{i=1}^n X_i > C\right) + \gamma P_{\theta_0}\left(\prod_{i=1}^n X_i = C\right) = \alpha$$

$$\begin{aligned} E_{\theta_0}[\phi(X)] &= P_{\theta_0}\left(\log\left(\prod_{i=1}^n X_i\right) > C'\right) + \gamma P_{\theta_0}\left(\log\left(\prod_{i=1}^n X_i\right) = C'\right) = \alpha \\ &= P_{\theta_0}\left(-\log\left(\prod_{i=1}^n X_i\right) < C''\right) + \gamma P_{\theta_0}\left(-\log\left(\prod_{i=1}^n X_i\right) = C''\right) \\ &= P_{\theta_0}\left(-\sum_{i=1}^n \log(X_i) < C''\right) + \gamma P_{\theta_0}\left(-\sum_{i=1}^n \log(X_i) = C''\right) \\ &= P_{\theta_0}(W < C'') + \gamma P_{\theta_0}(W = C'') = \alpha \end{aligned}$$

em que $W \sim \text{Gama}(n, \theta_0)$ segundo (2)

Com $C' = \bar{T}_{\alpha}(n, \theta_0)$ e $\gamma = 0$ pois $P_{\theta_0}(W = C'') = 0$ temos que $E_{\theta_0}[\phi(X)] = \alpha$, em que $\bar{T}_{\alpha}(n, \theta_0)$ é o quantil α da distribuição W . Daí

$$\phi(X) = \begin{cases} 1 & \text{se } T(X) > \exp\{-\bar{T}_{\alpha}(n, \theta_0)\} \\ 0 & \text{se } T(X) < \exp\{-\bar{T}_{\alpha}(n, \theta_0)\}. \end{cases}$$

Dado que, se $Z \sim \text{Gama}(a, b)$ então $2bZ \sim \chi^2_{(2a)}$ temos que $\bar{T}_{\alpha}(n, \theta_0) = \chi^2_{\alpha}(2n)/2\theta_0$.

b) Obtenha um teste UMP de $H_0: \theta \geq \theta_0$ ($\theta_0 > 0$) versus $H_1: \theta < \theta_0$ de nível α .

O interesse é testar:

$$H_0: \theta \geq \theta_0 \quad \text{vs} \quad H_1: \theta < \theta_0$$

$$\text{Seja } \Omega_0 = \{\theta > 0 : \theta \geq \theta_0\} \text{ e } \Omega_1 = \{\theta > 0 : \theta < \theta_0\}$$

Temos que

$$RV(X) = \left(\frac{\theta_0}{\theta_1}\right)^n \left(\prod_{i=1}^n X_i\right)^{\theta_0-\theta_1}$$

Onde θ_0 e θ_1 pertencem a Ω_0 e Ω_1 , respectivamente.

Como $\theta_1 < \theta_0$ a $RV(X)$ é não decrescente como função de $T(X) = \prod_{i=1}^n X_i$.

Então, o teste UMP de nível α está dado por:

$$\phi(X) = \begin{cases} 1 & \text{se } T(X) < C \\ \gamma & \text{se } T(X) = C \\ 0 & \text{se } T(X) > C \end{cases}$$

Onde C e γ são determinados por:

$$E_{\theta_0}[\phi(X)] = \alpha = P_{\theta_0}(T(X) < C) + \gamma P_{\theta_0}(T(X) = C)$$

Usando que

$$\sum_{i=1}^n -\log(X_i) = W, \quad W \sim \text{Gama}(n, \theta) \quad (\text{Resultado obtido em (a)})$$

Temos que

$$E_{\theta_0}[\phi(X)] = P_{\theta_0}(W > C'') = \alpha$$

com $C'' = \bar{T}_{1-\alpha}(n, \theta_0)$, em que $\bar{T}_{1-\alpha}(n, \theta_0)$ é o quantil $(1-\alpha)$ da distribuição de W . Então:

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) < \exp\{-\Gamma_{1-\alpha}(n, \theta_0)\} \\ 0 & \text{se } T(x) \geq \exp\{-\Gamma_{1-\alpha}(n, \theta_0)\} \end{cases}$$

ou equivalente

$$\phi(x) = \begin{cases} 1 & \text{se } T(x) < \exp\{-\chi^2_{1-\alpha}(2n)/2\theta_0\} \\ 0 & \text{se } T(x) \geq \exp\{-\chi^2_{1-\alpha}(2n)/2\theta_0\} \end{cases}$$



c) Existe teste UMP de $H_0: \theta = \theta_0 (\theta_0 > 0)$ versus $H_1: \theta \neq \theta_0$ de nível α ? Justifique.

Não existe um teste UMP de $H_0: \theta = \theta_0 (\theta_0 > 0)$ versus $H_1: \theta \neq \theta_0$. Justificativa.

Segundo (a) e (b) o teste UMP para $H_0: \theta = \theta_0$ versus $H_1: \theta = \theta_1$ depende de θ_1 , em particular, depende do sinal da diferença

$$\Delta = \theta_0 - \theta_1$$

Quando $\Delta > 0$ o teste UMP é dado por (b), enquanto que, para $\Delta < 0$ o teste UMP é dado por (a) e os testes dados em (a) e (b) são diferentes.

d) Encontre o teste da razão de verossimilhanças de $H_0: \theta = \theta_0 (\theta_0 > 0)$ versus $H_1: \theta \neq \theta_0$ de nível α .

Temos que o teste da razão de verossimilhanças está definido por

$$\phi_{RV}(x) = \begin{cases} 1 & \text{se } -2 \log \left\{ \frac{\sup_{\theta \in \Theta_0} P(x)}{\sup_{\theta \in \Theta_1} P(x)} \right\} = \lambda(x) > c \\ 0 & \text{c.c.} \end{cases}$$

Então

$$\lambda(x) = -2 \log \left\{ \frac{P_{\theta_0}(x)}{\sup_{\theta \in \Theta_1} P(x)} \right\}, \text{ para } \Theta_1 = \{\theta_0\}$$

em que

$$P_{\theta_0}(x) = \theta_0^n \left(\prod_{i=1}^n x_i \right)^{\theta_0-1}, \quad T(x) = \prod_{i=1}^n x_i$$

$$\text{Temos que } \frac{\partial P_{\theta_0}(x)}{\partial \theta} = n \theta^{n-1} (T(x))^{\theta_0-1} + \theta^n (T(x))^{\theta_0-1} \log(T(x)) = P'_{\theta_0}(x)$$

Então

$$\begin{aligned} P'_{\theta_0}(x) &= 0 \Rightarrow n \hat{\theta}^{n-1} (T(x))^{\hat{\theta}-1} + \hat{\theta}^n (T(x))^{\hat{\theta}-1} \log(T(x)) = 0 \\ &\Rightarrow \hat{\theta} = \frac{-n}{\log(T(x))} = -\frac{1}{\log \left[\left(\prod_{i=1}^n x_i \right)^{\theta_0} \right]} = \frac{1}{n} \sum_{i=1}^n [-\log(x_i)] \end{aligned}$$

Temos que $\frac{\partial^2 P_{\theta_0}(x)}{\partial \theta^2} < 0$

$$\Rightarrow \sup_{\theta \in \Theta_1} P(x) = P_{\theta_0}(x)$$

$$\boxed{\hat{\theta} = \frac{n}{W}, \text{ com } W = \sum_{i=1}^n -\log(x_i) \text{ e } W \sim \text{Gamma}(n, \theta)}$$

Então

$$\lambda(x) = -2 \log \left\{ \frac{P_{\theta_0}(x)}{P_{\theta_1}(x)} \right\} = -2 \log \left\{ \frac{\theta_0^n (T(x))^{\theta_0-1}}{\hat{\theta}^n (T(x))^{\hat{\theta}-1}} \right\} > c$$

$$\lambda(x) = -2 \{ n \log \theta_0 + (\theta_0-1) \log(T(x)) - n \log \hat{\theta} - (\hat{\theta}-1) \log(T(x)) \} > c$$

$$\lambda(x) = -2 \left\{ n \log \left(\frac{\theta_0}{\hat{\theta}} \right) + (\theta_0 - \hat{\theta}) \log(T(x)) \right\} > c.$$

$$\lambda(x) = -2 \left\{ n \log \left(\frac{\theta_0 W}{n} \right) - \left(\theta_0 - \frac{n}{W} \right) W \right\} > c$$

$$\lambda(x) = -2 n \log(\theta_0 W) + 2\theta_0 W + 2n \log(n) - 2n > c$$

$$\Rightarrow \boxed{-n \log(W) + W \theta_0 > c' \quad (1).}$$

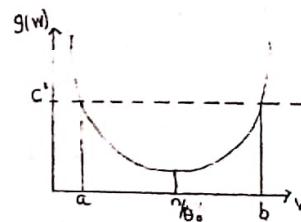
Seja $g(w) = -n \log(w) + w \theta_0$

$$g'(w) = \frac{\partial g(w)}{\partial w} = -\frac{n}{w} + \theta_0 = 0$$

Dai $\frac{n}{\theta_0} = \theta_0 \Rightarrow w = \frac{n}{\theta_0}$ é um valor mínimo de $g(w)$

$$\text{pois } g''(w) = \frac{\partial^2 g(w)}{\partial w^2} = \frac{n}{w^2} > 0 \quad \forall w$$

Então:



Então (1) implica que

$$\phi_{RV}(x) = \begin{cases} 1 & \text{se } w < a \text{ ou } w > b \\ 0 & \text{c.c.} \end{cases}$$

Dai $a, b > 0$, $a < b$ tal que $P_{\theta_0}[W < a] + P_{\theta_0}[W > b] = \alpha$, ou seja, $F_{\theta_0}(b) - F_{\theta_0}(a) = 1 - \alpha$, em que $F_{\theta_0}(\cdot)$ é a função de distribuição acumulada de W sob H_0 e $g(a) = g(b)$. Note que sob H_0 , $W \sim \text{Gamma}(n, \theta_0)$

e) Encontre um limite inferior de confiança mais acurado com coeficiente de confiança $1-\alpha$.

Dos items anteriores sabemos que $RV(x)$ é uma função não decrescente como função de $T(x) = \prod_{i=1}^n x_i$. Então, pelo corolário da pag. T50

das notas de aula temos que, o limite inferior de confiança uniformemente mais acurado, $\underline{\theta}$, para θ com coeficiente de confiança $1-\alpha$ existe e é a solução à seguinte equação (em relação a $\underline{\theta}$)

$$F_{\underline{\theta}}(t) = 1 - \alpha$$

onde $F_{\underline{\theta}}(\cdot)$ é a função de distribuição acumulada de T .

Então

$$\begin{aligned} F_{\underline{\theta}}(t) &= P_{\underline{\theta}}(T \leq t) = 1 - \alpha, \quad T(\mathbf{x}) = \prod_{i=1}^n x_i \\ &= P_{\underline{\theta}}(\log(T(\mathbf{x})) \leq \log t) = 1 - \alpha \\ &= P_{\underline{\theta}}\left(\sum_{i=1}^n \log(x_i) \geq -\log t\right) = 1 - \alpha. \end{aligned}$$

Temos que $W = \sum_{i=1}^n \log(x_i)$ onde $W \sim \text{Gama}(n, \theta)$

Além temos que $2\theta W \sim \chi^2(2n)$

Então

$$\begin{aligned} F_{\underline{\theta}}(t) &= P_{\underline{\theta}}(2\theta W \geq -2\theta \log(t)) = 1 - \alpha \\ &= P_{\underline{\theta}}(\chi^2(2n) \geq -2\theta \log(t)) = 1 - \alpha. \end{aligned}$$

Seja $\chi^2_{\alpha}(2n)$ o quantil α do distribuição $\chi^2(2n)$. Então:

$$\begin{aligned} -2\theta \log(t) &= \chi^2_{\alpha}(2n) \\ \Rightarrow \underline{\theta}(t) &= \frac{\chi^2_{\alpha}(2n)}{-2 \log(T(\mathbf{x}))} \end{aligned}$$

Então $\underline{\theta}(t)$ é o limite inferior de confiança mais acurado

f) Encontre um limite superior de confiança mais acurado com coeficiente de confiança $1-\alpha$.

Usando de novo o corolário do pg 750 das notas de aula temos que, o limite superior de confiança uniformemente mais acurado, $\bar{\theta}$, para θ é a solução à seguinte equação (em relação a $\bar{\theta}$).

$$F_{\bar{\theta}}(t) = \alpha$$

em que $F_{\bar{\theta}}(\cdot)$ é a f.d.a de T .

$$\begin{aligned} \text{Então } F_{\bar{\theta}}(t) &= P_{\bar{\theta}}(T \leq t) = \alpha, \quad T(\mathbf{x}) = \prod_{i=1}^n x_i \\ &= P_{\bar{\theta}}(\log(T(\mathbf{x})) \leq \log t) = P_{\bar{\theta}}\left(\sum_{i=1}^n \log(x_i) \leq -\log t\right) = \alpha \\ &= P_{\bar{\theta}}(2\theta W \leq -2\theta \log(t)) = \alpha, \quad W \sim \text{Gama}(n, \theta) \\ &= P_{\bar{\theta}}(\chi^2(2n) \leq -2\theta \log(t)) = \alpha \quad 2\theta W \sim \chi^2(2n) \end{aligned}$$

Seja $\chi^2_{1-\alpha}(2n)$ o quantil $(1-\alpha)$ do distribuição $\chi^2(2n)$.

$$\begin{aligned} \text{Então:} \quad -2\theta \log(t) &= \chi^2_{1-\alpha}(2n) \\ \Rightarrow \bar{\theta}(t) &= \frac{\chi^2_{1-\alpha}(2n)}{-2 \log(T(\mathbf{x}))} \end{aligned}$$

Daí, $\bar{\theta}(t)$ é o limite superior de confiança mais acurado.

g) Determine uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente minimal e encontre um intervalo de confiança para θ com coeficiente de confiança $1-\alpha$.

Temos que

$$\begin{aligned} P(\mathbf{x}; \theta) &= \theta^n \prod_{i=1}^n x_i^{\theta-1}, \quad T(\mathbf{x}) = \prod_{i=1}^n x_i \\ \exp\{n \log \theta + \theta - 1\} f(\mathbf{x}) &= \exp\{n \log \theta + \theta \log(T(\mathbf{x}))\} (T(\mathbf{x}))^{-1} \\ &= \exp\{\theta A(\mathbf{x}) - B(\theta)\} \cdot h(\mathbf{x}), \end{aligned}$$

com $A(\mathbf{x}) = \log(T(\mathbf{x}))$, $B(\theta) = -n \log \theta$ e $h(\mathbf{x}) = (T(\mathbf{x}))^{-1}$.

Então, $P(\mathbf{x}; \theta)$ pertence à família exponencial unidimensional (posto completo), então, a estatística $A(\mathbf{x}) = \log(T(\mathbf{x}))$ é suficiente, completa e minimal para θ .

Dos itens anteriores sabemos que $Q = -2\theta A(\mathbf{x}) \sim \chi^2(2n)$, ou seja, a distribuição de Q não depende de θ , então, esta estatística pode ser usada como quantidade pivotal.

Então

$$\begin{aligned} P\left[\chi^2_{\alpha/2}(2n) \leq Q \leq \chi^2_{1-\alpha/2}(2n)\right] &= 1 - \alpha \\ P\left[\chi^2_{\alpha/2}(2n) \leq -2\theta A(\mathbf{x}) \leq \chi^2_{1-\alpha/2}(2n)\right] &= 1 - \alpha \\ P\left[\frac{\chi^2_{\alpha/2}(2n)}{2A(\mathbf{x})} \geq -\theta \geq \frac{\chi^2_{1-\alpha/2}(2n)}{2A(\mathbf{x})}\right] &= 1 - \alpha \\ P\left[\frac{\chi^2_{\alpha/2}(2n)}{-2A(\mathbf{x})} \leq \theta \leq \frac{\chi^2_{1-\alpha/2}(2n)}{-2A(\mathbf{x})}\right] &= 1 - \alpha \end{aligned}$$

Daí temos que um intervalo de confiança para θ com coeficiente de confiança $1-\alpha$ está dado por:

$$[\underline{\theta}; \bar{\theta}] = \left[\frac{\chi^2_{\alpha/2}(2n)}{-2A(\mathbf{x})}, \frac{\chi^2_{1-\alpha/2}(2n)}{-2A(\mathbf{x})} \right]$$

Note que este intervalo não é único, pois existem infinitos números $0 < a < b$ tais que: $P(a \leq Q \leq b) = 1 - \alpha$.

a) Segundo que o parâmetro θ tem distribuição exponencial de média λ e função densidade de probabilidade $p_{\theta}(x) = \lambda e^{-\lambda x}$ ($x > 0$), sendo λ o parâmetro basta ter a estimativa de λ para obter $\hat{\theta}$ (o seu ponto quadrático).
 Temos que $E(\theta) = \text{exp}(\bar{x}) = E(\bar{x}) + \text{exp}(\bar{x})^2$.

卷之三

$$\begin{aligned} \text{var } f(t) &= \int_{-\infty}^t \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} t^2 \exp(-\lambda t) d\theta_1 d\theta_2 dt = \frac{t^2}{\lambda^3}, \\ f(t) &= \int_{-\infty}^t \left[\theta_1 \exp\left(\theta_2 - \log(1/\lambda) - \theta_1\right) \right] d\theta_1 = \exp\left(-\log(1/\lambda)t\right) \int_{-\infty}^t \theta_1 \exp\left(\theta_2 - \log(1/\lambda)\theta_1\right) d\theta_1 \\ &= \exp\left(-\log(1/\lambda)t\right) \frac{\partial}{\partial \theta_2} \int_{-\infty}^t \frac{\left(\theta_2 - \log(1/\lambda)\theta_1\right)^2}{2} \theta_1 \exp\left(\theta_2 - \log(1/\lambda)\theta_1\right) d\theta_1 \end{aligned}$$

新文庫

$$\frac{d\ln f}{dt} = \frac{\partial^2 \exp\left(t - \log(f(t)) - \alpha T\right)}{\partial t^2} f'(t) (T - \log(f(t)))$$

$$= \frac{\partial^2 \exp\left(t - \log(f(t))\right)}{\partial t^2} f'(t) (T - \log(f(t)))$$

Table 1. Summary of the following

O comitê de Boas-vindas que reuniu o mundo da literatura para a cerimônia de abertura.

$$\frac{1}{2} + \frac{1}{2} \left(\frac{1}{2} / \frac{1}{2} \right) = \frac{1+1}{2} = \frac{2}{2} = 1 \quad (\text{Nega Tercima p. 112})$$

Si $T_{\text{corte}}(k_0) \geq k_0$, se tiene una muestra aleatoria de una distribución $\text{Dir}(k)$. Si $T_{\text{corte}}(k_0) < k_0$, cualquier teste para H_0 que pase testar H_0 en cierto $k \leq k_0$, quedaría teste para H_0 cuando $T_{\text{corte}}(k_0) = k$. Es decir, para $k \leq k_0$, $\alpha(k) = 1$ quando

Suppose the α -term is defined below, with $\beta = (\text{body})^\theta$.
 Then we have $P(\beta) = \frac{1}{\theta} \int_{\partial B(0,1)} f(z) dz$, where $f(z) = \max(1 - |z|, 0)$.

América Latina de Naciones Unidas que para este año

$$B_1 \otimes B_2 = B_2 \otimes B_1, \quad B_1 \otimes B_2 = B_2 \otimes B_1, \quad B_1 \otimes B_2 = B_2 \otimes B_1.$$

→ book → e-books

（三）中班《谁的尾巴长》大班《小兔和狼》

$$\rho(x) = \begin{cases} 1 & \text{if } L_{\text{min}}(x) > \frac{1}{2} L_{\text{max}}(x) \\ 0 & \text{otherwise} \end{cases}$$

Since $\{x_n\}$ converges to x , we have $\lim_{n \rightarrow \infty} f(x_n) = f(x)$.
 It suffices to prove that $f(x) = 0$. Since $x_n > 0$ for all n , we have
 $f(x_n) \geq 0$ for all n . As $f(x_n) \rightarrow 0$ as $n \rightarrow \infty$, we get $f(x) = 0$.

Finalmente, se $\lambda_{\text{max}}(f_{\text{red}}) > 1$, o que implica que $\lambda_{\text{max}}(f_{\text{red}}) \geq 1$, visto que $f_{\text{red}} = f$ em $\text{Im}(f)$. No entanto, se $\lambda_{\text{max}}(f_{\text{red}}) > 1$, é fácil ver que $\lambda_{\text{max}}(f) > 1$.

Questa serie di dati può essere fatta avere una validità di quasi 4 anni e per le 4-5a nel 1947 ha probabilmente significato

$$f_{\text{min}} = \pi/2\omega_0 \approx 9.8 \times 10^9 \text{ Hz} = 9$$

For example, a 100% profit point is 100% gross margin + 100% net profit.

卷之三

五、上課時間：每週二堂課，每堂課一小時，學生需

3) Now we can take $\delta = \epsilon$, with $\delta > 0$, so that $\forall x \in \mathbb{R}$ such that $|x| < \delta$, $|f(x)| < \epsilon$. In fact, $\lim_{n \rightarrow \infty} f_n(x) = f(x)$, for all $x \in \mathbb{R}$.

Impacts: Economic requirements & aftermath will add to the costs, (i) & (ii) & (iii) in the short term, but "a lot" longer, (iv) will add to the long-term costs.

中華書局影印
新編藏書票

Tomas sur R. 2 + 3 km (km), con fincación (km), km tiene relación de
correspondencia con la distancia en R. 2 km, pero

書名：新編中華書局影印，卷之三
頁數：三

³ See the notes on the article 20(3) and section 17(a) from *Legal Basis (2005)* "Administrative Decisions", 2005, 206.

लेकिन यह एक अचूक प्रयोग है जो व्यापक रूप से व्यवसायी व्यक्ति द्वारा किया जाता है।

卷之三

entre $\text{E}(\text{S}(\text{B}))$ e os valores da $\text{E}(\text{S})$ dependem dos seguintes fatores:

$$\text{Como } P_{\theta_0}(X_{(n)} = c) = 0 \text{ então} \\ \alpha = P_{\theta_0}(X_{(n)} > c)$$

ou seja, c é o quantil $(1-\alpha)$ da distribuição de $X_{(n)} | \theta = \theta_0$.

Das notas de aula pag. 51 temos que $P_{\theta}(X_{(n)} < x) = \left(\frac{x}{\theta}\right)^n I_{(0, \theta]}(x) + I_{(\theta, \infty)}(x)$
portanto temos que

$$d = 1 - \left(\frac{c}{\theta_0}\right)^n \Rightarrow \frac{c^n}{\theta_0^n} = 1 - \alpha$$

$$\Rightarrow (1-\alpha)^{1/n} \theta_0 = c$$

Seja $\theta > \theta_0$ um valor possível para θ sob K , então o poder de $\phi(\underline{x})$ em θ , é o seguinte

$$P_{\theta_1}(X_{(n)} > (1-\alpha)^{1/n} \theta_0) = 1 - \left(\frac{(1-\alpha)^{1/n} \theta_0}{\theta_1}\right)^n = 1 - (1-\alpha) \frac{\theta_0^n}{\theta_1^n} = \alpha \left(\frac{\theta_0}{\theta_1}\right)^n$$

Por outro lado, seja $\phi^*(\underline{x})$ um teste tal que $\phi^*(\underline{x}) = 1$ se $X_{(n)} > \theta_0$ ou $X_{(n)} \leq \theta_0 d^{1/n}$ e $\phi^*(\underline{x}) = 0$, caso contrário. O nível de $\phi^*(\underline{x})$ pode ser calculado como:

$$P_{\theta_0}(X_{(n)} > \theta_0) + P_{\theta_0}(X_{(n)} \leq \theta_0 d^{1/n}) \\ = 0 + \left(\frac{\theta_0 d^{1/n}}{\theta_0}\right)^n = \alpha \quad (2)$$

Então $\phi^*(\underline{x})$ é de nível α para (1)

E, o poder de $\phi^*(\underline{x})$ pode ser calculado como

$$P_{\theta_1}(X_{(n)} > \theta_0) + P_{\theta_1}(X_{(n)} < \theta_0 d^{1/n}) \\ = 1 - \left(\frac{\theta_0}{\theta_1}\right)^n + \left(\frac{\theta_0 d^{1/n}}{\theta_1}\right)^n = 1 - (1-\alpha) \left(\frac{\theta_0}{\theta_1}\right)^n = \alpha \left(\frac{\theta_0}{\theta_1}\right)^n$$



(i) Então, o poder dos testes $\phi^*(\underline{x})$ e $\phi(\underline{x})$ são iguais, o que implica que $\phi^*(\underline{x})$ é UMP de nível α para (1).

Seja

$$H: \theta = \theta_0 \text{ contra } K: \theta < \theta_0 \quad (3)$$

Temos que $P(\underline{x})$ tem razão de verossimilhanças não decrescente em $T(\underline{x}) = X_{(n)}$.
Então, o teste UMP para (3) de nível α tem a seguinte forma e é denotado como $\phi(\underline{x})$

$$\phi(\underline{x}) = \begin{cases} 1 & \text{se } X_{(n)} < c \\ \gamma & \text{se } X_{(n)} = c \\ 0 & \text{se } X_{(n)} > c \end{cases}$$

os valores de γ e c dependem da seguinte equação:

$$E_{\theta_0}(\phi(\underline{x})) = \alpha = P_{\theta_0}(X_{(n)} < c) + \gamma P_{\theta_0}(X_{(n)} = c)$$

como $P_{\theta_0}(X_{(n)} = c) = 0$ então

$$\alpha = P_{\theta_0}(X_{(n)} < c) \Rightarrow \alpha = \left(\frac{c}{\theta_0}\right)^n \Rightarrow c = \theta_0 d^{1/n}$$

Seja $\theta_1 < \theta_0$ então o poder de $\phi(\underline{x})$ é o seguinte:

$$B_{\phi}(\theta_1) = P_{\theta_1}(X_{(n)} > \theta_0) + P_{\theta_1}(X_{(n)} < \theta_0 d^{1/n})$$

$$\text{A) Se } \theta_0 d^{1/n} < \theta_1 < \theta_0 \Rightarrow B_{\phi}(\theta_1) = P_{\theta_1}(X_{(n)} < \theta_0 d^{1/n}) = \left(\frac{\theta_0 d^{1/n}}{\theta_1}\right)^n = \alpha \left(\frac{\theta_0}{\theta_1}\right)^n$$

$$\text{B) Se } \theta_1 \leq \theta_0 d^{1/n} \Rightarrow B_{\phi}(\theta_1) = 1$$

Segundo (2) o nível de $\phi^*(\underline{x})$ é α para (3).

O poder $\phi^*(\underline{x})$ pode ser calculado como

$$B_{\phi^*}(\theta_1) = P_{\theta_1}(X_{(n)} > \theta_0) + P_{\theta_1}(X_{(n)} < \theta_0 d^{1/n}), \quad \theta_1 < \theta_0$$

$$\text{A) } \theta_0 d^{1/n} < \theta_1 < \theta_0 \Rightarrow B_{\phi^*}(\theta_1) = P_{\theta_1}(X_{(n)} < \theta_0 d^{1/n}) = \alpha \left(\frac{\theta_0}{\theta_1}\right)^n$$

$$\text{B) } \theta_1 \leq \theta_0 d^{1/n} \Rightarrow B_{\phi^*}(\theta_1) = P_{\theta_1}(X_{(n)} < \theta_0 d^{1/n}) = 1$$

Então:

(ii) $\phi(\underline{x})$ e $\phi^*(\underline{x})$ tem o mesmo poder, ou seja, $\phi^*(\underline{x})$ é UMP de nível α para (3)

De (i) e (ii), temos que $\phi^*(\underline{x})$ é UMP de nível α para

$$H: \theta = \theta_0 \text{ contra } K: \theta \neq \theta_0$$

11) Sejam X_1, \dots, X_n uma amostra aleatória da distribuição exponencial deslocada com função densidade de probabilidade

$$f(x; \theta, \gamma) = \frac{1}{\gamma} \exp\left(-\frac{x-\theta}{\gamma}\right) I_{(\theta, \infty)}(x), \quad -\infty < \theta < \infty$$

a) Admita que θ é conhecido. Encontre um teste UMP de $H: \gamma \leq \gamma_0$ contra $K: \gamma > \gamma_0$ de nível $\alpha \in (0, 1)$.

O interesse é testar

$$H_0: \gamma \leq \gamma_0 \text{ vs } K: \gamma > \gamma_0 \quad (1)$$

$$\text{Seja } \Omega_0 = \{\gamma > 0 : \gamma \leq \gamma_0\} \text{ e } \Omega_1 = \{\gamma > 0 : \gamma > \gamma_0\}$$

Temos que

$$P(\underline{x}) = P(X_1, \dots, X_n; \gamma) = \frac{1}{\gamma^n} \exp\left\{-n(\bar{x}-\theta)\right\}$$

A razão de verossimilhanças $RV(\underline{x}) = P_{\gamma_0}(\underline{x}) / P_{\gamma_1}(\underline{x})$ é a seguinte.

$$RV(\underline{x}) = \left(\frac{\gamma_0}{\gamma_1}\right)^n \exp\left\{-\frac{n(\bar{x}-\theta)}{\gamma_1} + \frac{n(\bar{x}-\theta)}{\gamma_0}\right\} = \left(\frac{\gamma_0}{\gamma_1}\right)^n \exp\left\{-n(\bar{x}-\theta)\left(\frac{1}{\gamma_1} - \frac{1}{\gamma_0}\right)\right\} \\ = \left(\frac{\gamma_0}{\gamma_1}\right)^n \exp\left\{-n\bar{x}\left(\frac{1}{\gamma_1} - \frac{1}{\gamma_0}\right) + n\theta\left(\frac{1}{\gamma_1} - \frac{1}{\gamma_0}\right)\right\}$$

como $\gamma_1 > \gamma_0$, então $RV(\underline{x})$ é uma função não decrescente de $T(\underline{x}) = n\bar{x}$

Então, segundo o Teorema do pag. 127 das notas de aula tem-se que o teste UMP para (1) é dado por

$$\phi(\underline{x}) = \begin{cases} 1 & \text{se } T(\underline{x}) > c \\ \gamma & \text{se } T(\underline{x}) = c \\ 0 & \text{se } T(\underline{x}) < c \end{cases}$$

onde c e γ são determinados por:

$$E_{\delta_0}(\phi(x)) = \alpha = P_{\delta_0}(T(x) > c) + \eta P_{\delta_0}(T(x) = c).$$

$E_{\delta_0}(\phi(x)) \leq \alpha$ para $\underline{x} \leq x_0$

Para obter $E_{\delta_0}(\phi(x))$ vamos a considerar $Z = X - \theta$ então

$$F_Z(z) = P(Z \leq z) = P(X - \theta \leq z) = P(X \leq z + \theta) = F_X(z + \theta)$$

$$\text{e } f_Z(z) = f_X(z + \theta) = \frac{1}{\theta} \exp\{-z/\theta\} I_{(0, \infty)}(z)$$

$$\Rightarrow Z \sim \exp(1/\theta) \text{ e } E(Z) = \theta$$

$$\text{Dai, } Y = \sum_{i=1}^n Z_i = \sum_{i=1}^n (X_i - \theta) = n\bar{X} - n\theta = n(\bar{X} - \theta) \Rightarrow Y \sim \text{Gama}(n, 1/\theta)$$

Dado que se $Q \sim \text{Gama}(a, b)$ então $2bQ \sim \chi^2(2a)$ temos que

$$Y \sim \text{Gama}(n, 1/\theta) \Rightarrow \frac{2Y}{\theta} \sim \chi^2(2n)$$

$$\text{Então } W = \frac{2n(\bar{X} - \theta)}{\theta} \sim \chi^2(2n)$$

$$\begin{aligned} \Rightarrow E_{\delta_0}(\phi(x)) &= P_{\delta_0}(T(x) > c) + \eta P_{\delta_0}(T(x) = c) = \alpha \\ &= P_{\delta_0}(n\bar{X} > c) + \eta P_{\delta_0}(n\bar{X} = c) \\ &= P_{\delta_0}(n(\bar{X} - \theta) > c') + \eta P_{\delta_0}(n(\bar{X} - \theta) = c') \\ &= P_{\delta_0}(W > c'') + \eta P_{\delta_0}(W = c'') \end{aligned}$$

em que $W \sim \chi^2(2n)$ e com $C'' = \chi^2_{1-\alpha}(2n)$ e $\eta = 0$ pois $P_{\delta_0}(W = c'') = 0$ temos que

$E_{\delta_0}(\phi(x)) = \alpha$, em que $\chi^2_{1-\alpha}(2n)$ é o quantil $1-\alpha$ do distribuição $\chi^2(2n)$.

Dai,

$$\phi(x) = \begin{cases} 1 & \text{se } \frac{2n(\bar{X} - \theta)}{\theta} > \chi^2_{1-\alpha}(2n). \\ 0 & \text{se } \frac{2n(\bar{X} - \theta)}{\theta} < \chi^2_{1-\alpha}(2n) \end{cases}$$

ou

$$\phi(x) = \begin{cases} 1 & \text{se } \bar{X} > (\chi^2_{1-\alpha}(2n)\theta + 2n\theta)/2n \\ 0 & \text{se } \bar{X} < (\chi^2_{1-\alpha}(2n)\theta + 2n\theta)/2n \end{cases}$$

b) Admita que θ é conhecido. Encontre um limite inferior de confiança uniformemente mais acurado para \underline{x} com coeficiente de confiança $1-\alpha$, $\alpha \in (0, 1)$. Do item anterior sabemos que $RV(x)$ é uma função não decrescente como função de $T(x) = n\bar{X}$. Então pelo corolário do pag. T50 notas de aula temos que, o limite inferior de confiança uniformemente mais acurado, \underline{x} , para

\underline{x} com coeficiente de confiança $1-\alpha$ existe e é a solução à seguinte equação (em relação a \underline{x})

$$F_{\underline{x}}(t) = 1 - \alpha$$

onde $F_{\underline{x}}(\cdot)$ é o f.d.a de T .

Então

$$\begin{aligned} F_{\underline{x}}(t) &= P(T \leq t) = 1 - \alpha, \quad T(x) = n\bar{X} \\ &= P(n\bar{X} \leq n\underline{x}) = P(2n(\bar{X} - \theta) \leq 2n(\underline{x} - \theta)) \\ &= P(W \leq 2n(\underline{x} - \theta)/\theta) = 1 - \alpha \end{aligned}$$

onde $W \sim \chi^2(2n)$

Então

$$2n(\underline{x} - \theta)/\theta = \chi^2_{1-\alpha}(2n)$$

$$\Rightarrow \underline{x}(t) = \frac{2n(\bar{X} - \theta)}{\chi^2_{1-\alpha}(2n)}$$

Então $\underline{x}(t)$ é o limite inferior de confiança mais acurado para \underline{x} .

c) Admita que θ é conhecido. Obtenha uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente minimal e obtenha um intervalo de confiança para θ com coeficiente de confiança de $1-\alpha$.

Temos que

$$P(X_1, \dots, X_n; \theta) = \frac{1}{\theta^n} \exp\left\{-\frac{n(\bar{X} - \theta)}{\theta}\right\} I_{(0, \infty)}(X_{(1)})$$

com $X_{(1)} = \min(X_1, \dots, X_n)$.

$$P(X_1, \dots, X_n; \theta) = \frac{1}{\theta^n} \exp\left\{-\frac{n\bar{X}}{\theta}\right\} \exp\left\{\frac{n\theta}{\theta}\right\} I_{(0, \infty)}(X_{(1)})$$

$$= g_\theta(M(x)) h(x)$$

pelo critério da fatoração $M(x) = X_{(1)}$ é uma estatística suficiente para θ com $h(x) = \frac{1}{\theta^n} \exp\left\{-\frac{n\bar{X}}{\theta}\right\}$ e $g_\theta(M(x)) = \exp\left\{\frac{n\theta}{\theta}\right\} I_{(0, \infty)}(M(x))$

Do exercício 17a Lista 2 temos que $M(x) = X_{(1)}$ é uma estatística suficiente completa para θ .

Do exercício 1a Lista 3 temos que se $T(x)$ é uma estatística suficiente completa então ela é suficiente minimal.

Daí podemos concluir que $M(x)$ é uma estatística suficiente minimal para θ .

Sabemos que $X_{(1)} \sim E(\theta, \theta/n)$ (Veja Exercício 19 Lista 2)

Seja $Z = X_{(1)} - \theta$, $Z \sim E(0, \theta/n)$ ou $Z \sim \exp(\theta/n)$ e $E(Z) = \theta/n$

Temos que a distribuição de Z não depende de θ , então, esta estatística pode ser usada como quantidade pivotal.

Então

$$P[a \leq Z \leq b] = 1 - d$$

em que $a=0$, pois a função de densidade de probabilidade de Z é monotonamente decrescente. Então b é tal que

$$P(Z \leq b) = 1 - d$$

$$F_Z(b) = 1 - d \quad F_Z(z) = 1 - \exp\left\{-\frac{z}{\sigma}\right\}$$

$$\Rightarrow 1 - \exp\left\{-\frac{bn}{\sigma}\right\} = 1 - d$$

Dai

$$d = \exp\left\{-\frac{bn}{\sigma}\right\} \Rightarrow \log(d) = -\frac{bn}{\sigma}$$

$$\Rightarrow b = -\frac{\log(d)\sigma}{n}$$

O intervalo de confiança para θ é tal que

$$P(X_{(1)} - \theta \leq -\log(d)\sigma/n) = 1 - d.$$

$$P\left(\theta \geq X_{(1)} + \frac{\log(d)\sigma^2}{n}\right) = 1 - d$$

Então $A = \{\theta : \theta \geq X_{(1)} + \log(d)\sigma^2/n\}$ é uma região de confiança de $1-d$ para θ . Note que este intervalo não é único pois existem outras maneiras de selecionar a e b .

d) Admita que μ é conhecido. Encontre um teste MP de $H_0: \theta = \theta_0$ contra $K: \theta = \theta_1 (\theta_1 > \theta_0)$ de nível d .

Segundo o Lema de Neyman Pearson o teste MP de nível d é parcialmente dado por

$$\phi(\underline{x}) = \begin{cases} 1 & \text{se } P_1(\underline{x}) \geq K P_0(\underline{x}) \\ 0 & \text{se } P_1(\underline{x}) < K P_0(\underline{x}) \end{cases}$$

neste caso

$$\phi(\underline{x}) = \begin{cases} 1 & \text{se } \exp\left\{\frac{n\theta_1}{\sigma^2}\right\} I_{(\theta_1, \infty)}(X_{(1)}) > K \exp\left\{\frac{n\theta_0}{\sigma^2}\right\} I_{(\theta_0, \infty)}(X_{(1)}) \\ 0 & \text{se } \exp\left\{\frac{n\theta_1}{\sigma^2}\right\} I_{(\theta_1, \infty)}(X_{(1)}) < K \exp\left\{\frac{n\theta_0}{\sigma^2}\right\} I_{(\theta_0, \infty)}(X_{(1)}) \end{cases}$$

$$\text{e } E_{\theta_0}(\phi(\underline{x})) = d$$

com $K = \exp\left\{\frac{n(\theta_1 - \theta_0)}{\sigma^2}\right\}$, temos que

$$\phi(\underline{x}) = \begin{cases} 0 & \text{se } \theta_0 < X_{(1)} \leq \theta_1 \\ \eta & \text{se } X_{(1)} > \theta_1 \end{cases}$$

$$\begin{aligned} \text{Dai } E_{\theta_0}(\phi(\underline{x})) &= d = \eta P_{\theta_0}(X_{(1)} > \theta_1) = \eta P_{\theta_0}(X_{(1)} - \theta_0 > \theta_1 - \theta_0) \\ &= \eta P_{\theta_0}(Z > \theta_1 - \theta_0), Z \text{ definido como no item anterior} \\ &= \eta \exp\left\{-\frac{(\theta_1 - \theta_0)n}{\sigma^2}\right\} = d, \end{aligned}$$

Então $\eta = \exp\left\{\frac{(\theta_1 - \theta_0)n}{\sigma^2}\right\}$. Mas, como η pode ser maior do que 1 para alguns valores de θ_1 , então $\eta = \min\left\{\exp\left\{\frac{(\theta_1 - \theta_0)n}{\sigma^2}\right\}, 1\right\}$

Dai o teste MP de $H_0: \theta = \theta_0$ vs $K: \theta = \theta_1$ de nível d é dado por

$$\phi(\underline{x}) = \begin{cases} 0 & \text{se } \theta_0 < X_{(1)} \leq \theta_1, \\ \min\left\{\exp\left\{\frac{(\theta_1 - \theta_0)n}{\sigma^2}\right\}, 1\right\} & \text{se } X_{(1)} > \theta_1, \end{cases}$$

15. Sejam X_1, \dots, X_n e Y_1, \dots, Y_n amostras aleatórias de distribuições exponenciais de médias $\mu > 0$ e $\lambda > 0$ respectivamente. Obtenha o teste da razão de verossimilhanças de $H_0: \mu = \lambda$ versus $H_1: \mu \neq \lambda$ de nível d . Temos que

$$P(\underline{x}; \mu) = \frac{1}{\mu^n} \exp\left\{-\frac{n\bar{x}}{\mu}\right\} \text{ e } P(\underline{y}; \lambda) = \frac{1}{\lambda^n} \exp\left\{-\frac{n\bar{y}}{\lambda}\right\}$$

$$P(\underline{x}, \underline{y}; \mu, \lambda) = \frac{1}{(\mu\lambda)^n} \exp\left\{-\frac{n\bar{x}}{\mu} - \frac{n\bar{y}}{\lambda}\right\}$$

$$L(\mu, \lambda) = \log(P(\underline{x}, \underline{y})) = -\frac{n\bar{x}}{\mu} - \frac{n\bar{y}}{\lambda} - n \log(\mu) - n \log(\lambda)$$

$$\Rightarrow U(\mu) = \frac{\partial L(\mu, \lambda)}{\partial \mu} = \frac{n\bar{x}}{\mu^2} - \frac{n}{\mu} \Rightarrow U(\hat{\mu}) = 0 \Rightarrow \hat{\mu} = \bar{x}$$

$$\Rightarrow U(\lambda) = \frac{\partial L(\mu, \lambda)}{\partial \lambda} = \frac{n\bar{y}}{\lambda^2} - \frac{n}{\lambda} \Rightarrow U(\hat{\lambda}) = 0 \Rightarrow \hat{\lambda} = \bar{y}$$

Dai temos que os EMV de μ e λ são \bar{x} e \bar{y} , respectivamente

Seja $\theta = (\mu, \lambda)$ então o EMV de θ , $\tilde{\theta} = (\hat{\mu}, \hat{\lambda}) = (\bar{x}, \bar{y})$.

Sob $H_0: \mu = \lambda = \theta$, então temos

$$l(\theta) = \log(P(\underline{x}, \underline{y})) = -\frac{n}{\theta}(\bar{x} + \bar{y}) - 2n \log \theta$$

$$\Rightarrow U(\theta) = \frac{\partial l(\theta)}{\partial \theta} = \frac{n(\bar{x} + \bar{y})}{\theta^2} - \frac{2n}{\theta} \Rightarrow U(\tilde{\theta}) = 0$$

$$\Rightarrow \tilde{\theta} = \frac{\bar{x} + \bar{y}}{2}$$

Dai temos que o EMV sob H_0 de θ , $\tilde{\theta} = \frac{\bar{x} + \bar{y}}{2}$

Então

$$\lambda(\underline{x}, \underline{y}) = -2 \log \left\{ \frac{\sup_{\theta \in \Omega} P(\underline{x}, \underline{y})}{\sup_{\theta \in \Omega} P_0(\underline{x}, \underline{y})} \right\} = -2 \log \left\{ \frac{P(\underline{x}, \underline{y})}{P_0(\underline{x}, \underline{y})} \right\}$$

$$\Rightarrow \lambda(\underline{x}, \underline{y}) = -2 \log \left\{ \frac{\tilde{\theta}^{-2n} \exp\{-n\tilde{\theta}^{-1}(\bar{x} + \bar{y})\}}{\hat{\mu}^{-n} \hat{\lambda}^{-n} \exp\{-n\hat{\mu}^{-1}\bar{x} - n\hat{\lambda}^{-1}\bar{y}\}} \right\}$$

$$\Rightarrow \lambda(\underline{x}, \underline{y}) = -2 \log \left\{ \frac{[(\bar{x} + \bar{y})/2]^{2n} \exp\{-n[(\bar{x} + \bar{y})/2]^{-1}(\bar{x} + \bar{y})\}}{\bar{x}^{-n} \bar{y}^{-n} \exp\{-2n\}} \right\} = -2 \log \left\{ \frac{(\bar{x} + \bar{y})^n 2^{2n}}{(\bar{x} + \bar{y})^{2n}} \right\}$$